

KI-gestützte und kuratierte Lemmatisierung und Kategorisierung

Ausgangspunkt: Historisch-kritisch edierter Tagebuchtext

```
<div type="diaryText">␣  
<p>␣  
<lb/>Bericht an Sereniss. wegen␣  
<lb/>des Münzkabinets. Brief an␣  
<lb/>meine Schwiegertochter. Con<g ref="#typoHyphen"/>␣  
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>␣  
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit. Lord␣  
<lb/>Byrons letzte Tage <abbr>v.</abbr> <abbr>Maj.</abbr> Parry␣  
<pb type="r" facs="gt:digitalisate#27/11342/11342_113.jpg"/>␣  
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>␣  
<lb/>Herr Rath Helbig, Abschied␣  
<lb/>nehmend, nach Carlsbad gehend.␣  
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>␣  
<lb break="no"/>chend. Mittag <abbr>Dr.</abbr> Eckermann.␣  
<lb/>Lord Byrons letzte Tage von␣  
<lb/>Parry. <abbr>C.</abbr> <abbr>v.</abbr> Müller den ich das␣  
<lb/>Bild von Charon sehen ließ. So<g ref="#typoHyphen"/>␣  
<lb break="no"/>dann obige Lectüre fortgesetzt.␣  
</p>␣  
</div>␣
```


KI-gestützte und kuratierte Lemmatisierung und Kategorisierung

```
PS C:\> cd C:\Users\martin.prell\Documents\GitLab\propylaeen\xql\gt\Lemmatisierung\scripts
PS C:\Users\martin.prell\Documents\GitLab\propylaeen\xql\gt\Lemmatisierung\scripts> py lemmatize.py ../input/1825-06/GT20152_tei
BOM bereits vorhanden in '../input/1825-06/GT20152_tei.xml'.
BOM entfernt aus '../input/1825-06/GT20152_tei.txt'.
Datei erfolgreich gespeichert als '../input/1825-06/GT20152_tei.txt'.
File '../input/1825-06/GT20152_tei.conllu' exists. Type '1' to run ChatGPT or '2' to skip ChatGPT: 1
Transformation complete. Output written to C:\Users\martin.prell\Documents\GitLab\propylaeen\xql\gt\Lemmatisierung\output\GT20152_tei.xml
Step 8: Prüfe anchor-Elemente in 'C:\Users\martin.prell\Documents\GitLab\propylaeen\xql\gt\Lemmatisierung\output\GT20152_tei.xml' ...
Step 8: Anchor-Prüfung OK.
```

--- Verarbeitung abgeschlossen ---

```
PROMPT = """Du bist ein Experte für die Inhaltsanalyse und Annotation von deutschsprachigen Tagebuchtexten des 19. Jahrhunderts. Ich gebe Dir eine Textdatei mit Tagebuch-Ein-
Wolfgang von Goethe. Führe bitte die folgenden Schritte strikt aus:
1. Öffne die Datei und lies den gesamten Inhalt sorgfältig ein.
2. Normalisiere alle Whitespace-Zeichen:
- Ersetze geschützte Leerzeichen und Tabulatoren durch normale Leerzeichen (U+0020).
- Lasse aber die Anzahl der Leerzeichen unverändert, d. h. verbinde keine Token.
- Entferne keine Leerzeichen, sondern Sorge nur dafür, dass sie als Standard-Leerzeichen vorliegen.
3. Tokenisiere die Datei, indem Du den gesamten Text strikt in einzelne Token aufteilst. Jede Buchstabenfolge zwischen zwei Leerzeichen und jedes Satzzeichen (d.h. die Zeich-
':' etc.) werden zu eigenständigen Token. Leerzeichen sind hingegen keine Token! Hier ein Beispiel dazu. Der Satz 'Ueber Gespräche Tristan u. Isolt, des Ober-Forstm. Dr. Got
Strassburg.' besteht aus folgenden 19 Token: 'Ueber', 'Gespräche', 'Tristan', 'u', '.', 'Isolt', ',', 'des', 'Ober', '-', 'Forstm', '.', 'Dr', '.', 'Gottfried', 'v', '.', 'Strassburg', '.', 'F
Buchstaben und Satzzeichen hinzu und entferne keine bestehenden Buchstaben und Satzzeichen!
4. Analysiere den Inhalt der Datei semantisch und gliedere ihn in sinnvolle Textpassagen (Thematische Einheiten). Eine Passage kann sehr kurz sein, sie kann aber auch über 5
Zeilengrenzen hinwegreichen. Fasse aufeinanderfolgende Textpassagen mit gleichem Thema nicht zu einer gemeinsamen Textpassage zusammen. Beachte auch, dass Abkürzungen enthal
die Teil einer Textpassage sind.
5. Weise jeder von dir ermittelten Textpassage ein Thema aus der folgenden Themenliste zu, das inhaltlich am besten zur Passage passt. Nimm also nicht das Erstbeste, sondern
deiner Entscheidung alle 31 Themenkategorien genau an und berücksichtige auch die drei unter 6. genannten Einschränkungen. Die sind die Themen, sie sind durch Kommata getren
'GoetheBeschäftigungAllein', 'Auszeichnungen/Diplome/Jubiläen', 'Bauangelegenheiten', 'Begegnungen', 'Bemerkungen/Beobachtungen/Sentenzen', 'Briefeingangsnotiz', 'Briefausgangsnot
egenheiten', 'Geburtstage', 'Gemmen', 'Gesellschaften', 'Krankheiten', 'Kulturhistorisches', 'Kunst', 'Lektüre', 'Medaillen/Münzen', 'Meteorologie/Wetter', 'Mineralien', 'Mittag', 'Musik
ag/NotaBene', 'Naturwissenschaftliches', 'Nebenstehendes', 'Oberaufsicht', 'Ordnung/Aufräumen', 'Rechnungswesen/Haushalt', 'Sammlungen', 'Spazierfahrten', 'EreignisseInWeimar', 'Werk
enössischeEreignisseAußerhalbWeimar'. Alle Passagen, die in keine dieser Kategorien fallen, erhalten die Kategorie 'Sonstiges'.
6. Hier noch die drei Einschränkungen zur vorherigen Themenzuweisungsregel unter 5.:
a) Weise das Thema 'GoetheBeschäftigungAllein' nur dann zu, wenn die Textpassage auch das Wort 'allein' enthält.
b) Weise das Thema 'Mittag' nur dann zu, wenn die Textpassage auch das Wort 'Mittag' enthält.
c) Weise das Thema 'Nebenstehendes' nur dann zu, wenn die Textpassage auch das Wort 'Nebenstehendes' bzw. 'Nebenstehende' enthält.
d) Allen Passagen, die 'Begegnungen' darstellen, muss zwingend das Thema 'Begegnungen' zugewiesen werden. Wenn die Begegnungspassage zudem weitere Angaben enthält, ordne sie
einem weiteren passenden Thema zu. Konkateniere in diesem Fall die beiden Themenkategorien, getrennt durch ein '-'. 'Begegnungen' steht dabei immer an erster Stelle. Hier ei
'<anchor type="Begegnungen-Bauangelegenheiten" xml:id="gt20005_lemText060"/>Nachher OBdr. Coudrai. Ueberlegung wegen seines fünfstockigen Gebäudes.<anchor corresp="#gt20005_
6. Erstelle eine CONLL-U-artige Textdatei (.conllu), in der jede Passage durch eine Leerzeile getrennt ist und jeder Token in einer Zeile steht. An jedem Token soll das Them
angegeben sein, zu der das Token gehört und eine dreistellige ID, die mit 'lemText' eingeleitet wird und in 10er Schritten pro Textpassage ansteigt. Auch die Textpassagen, d
Themenkombination mit 'Begegnungen' zugewiesen wurden, werden dieser Regel folgend ganz normal fortlaufend mit gezählt und kein 10er Schritt übersprungen. Die Informationen
sind durch Tabulator getrennt. Hier ist ein Modell:
1 {Token1} {Topic1} lemText010
2 {Token2} {Topic1} lemText010
3 {Token3} {Topic1} lemText010

1 {Token1} {Topic2} lemText020
2 {Token2} {Topic2} lemText020
3 {Token3} {Topic2} lemText020

1 {Token1} {Topic3} lemText030
2 {Token2} {Topic3} lemText030
3 {Token3} {Topic3} lemText030
7. Gib mir nur den Inhalt der conllu-Datei aus und nichts weiter, auch keine einleitenden oder abschließenden Zeichen wie bspw. '''.
Nimm einen tiefen Atemzug und führe die Aufgabe Schritt für Schritt durch. Das ist sehr wichtig für meine Karriere.
"""
```

- 1 GoetheBeschäftigungAllein
- 2 Auszeichnungen/Diplome/Jubiläen
- 3 Bauangelegenheiten
- 4 Begegnungen
- 5 Bemerkungen/Beobachtungen/Sentenzen
- 6 Briefeingangsnotiz
- 7 Briefausgangsnotiz
- 8 Familienangelegenheiten
- 9 Geburtstage
- 10 Gemmen
- 11 Gesellschaften
- 12 Krankheiten
- 13 Kulturhistorisches
- 14 Kunst
- 15 Lektüre
- 16 Medaillen/Münzen
- 17 Meteorologie/Wetter
- 18 Mineralien
- 19 Mittag
- 20 Musik/Theater
- 21 Nachtrag/NotaBene
- 22 Naturwissenschaftliches
- 23 Nebenstehendes
- 24 Oberaufsicht
- 25 Ordnung/Aufräumen
- 26 Rechnungswesen/Haushalt
- 27 Sammlungen
- 28 Spazierfahrten
- 29 EreignisseInWeimar
- 30 Werkentstehung
- 31 ZeitenössischeEreignisseAußerhalbWeimar
- 32 Sonstiges

KI-gestützte und kuratierte Lemmatisierung und Kategorisierung

Ergebnis: Lemmatisierter und kategorisierter Text, der von uns überprüft wird

```
<div type="diaryText">
<p>
<lb/><anchor type="Sonstiges" xml:id="gt20152_lemText010"/>Bericht an Sereniss. wegen
<lb/>des Münzkabinets.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an
<lb/>meine Schwiegertochter.<anchor corresp="#gt20152_lemText020"/> <anchor type="Briefausgangsnotiz"
xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/>Lord
<lb/>Byrons letzte Tage <abbr>v.</abbr> <abbr>Maj.</abbr> Parry<anchor corresp="#gt20152_lemText040"/>
<pb type="r" facs="gt:digitalsite#27/11342/11342_113.jpg"/>
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/>Herr Rath Helbig, Abschied
<lb/>nehmend, nach Carlsbad gehend.
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Begegnungen-Mittag" xml:id="gt20152_lemText060"/>Mittag
<abbr>Dr.</abbr> Eckermann.<anchor corresp="#gt20152_lemText060"/>
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/>Lord Byrons letzte Tage von
<lb/>Parry.<anchor corresp="#gt20152_lemText070"/> <anchor type="Sonstiges" xml:id="gt20152_lemText080"/><abbr>C.</abbr>
<abbr>v.</abbr> Müller den ich das
<lb/>Bild von Charon sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor type="Lektüre" xml:id="gt20152_lemText090"/>So<g
ref="#typoHyphen"/>
<lb break="no"/>dann obige Lectüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>
</p>
</div>
```


KI-gestütztes und kuratiertes NER (Personen und Orte)

Ausgangspunkt: überprüfter, lemmatisierter und kategorisierter Text

```
<div type="diaryText">
<p>
<lb/><anchor type="Sonstiges" xml:id="gt20152_lemText010"/>Bericht an Sereniss. wegen
<lb/>des Münzkabinets.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an
<lb/>meine Schwiegertochter.<anchor corresp="#gt20152_lemText020"/> <anchor type="Briefausgangsnotiz"
xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/>Lord
<lb/>Byrons letzte Tage <abbr>v.</abbr> <abbr>Maj.</abbr> Parry<anchor corresp="#gt20152_lemText040"/>
<pb type="r" facs="gt:digitalsate#27/11342/11342_113.jpg"/>
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/>Herr Rath Helbig, Abschied
<lb/>nehmend, nach Carlsbad gehend.
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Begegnungen-Mittag" xml:id="gt20152_lemText060"/>Mittag
<abbr>Dr.</abbr> Eckermann.<anchor corresp="#gt20152_lemText060"/>
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/>Lord Byrons letzte Tage von
<lb/>Parry.<anchor corresp="#gt20152_lemText070"/> <anchor type="Sonstiges" xml:id="gt20152_lemText080"/><abbr>C.</abbr>
<abbr>v.</abbr> Müller den ich das
<lb/>Bild von Charon sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor type="Lektüre" xml:id="gt20152_lemText090"/>So<g
ref="#typoHyphen"/>
<lb break="no"/>dann obige Lectüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>
</p>
</div>
```


KI-gestütztes und kuratiertes NER (Personen und Orte)

```
PS C:\Users\martin.prell\Documents\GitLab\propylaeen\xql\gt\NER\scripts> py ner.py ../input/1825-06/GT20152_tei
BOM bereits vorhanden in '../input/1825-06/GT20152_tei.xml'.
BOM entfernt aus '../input/1825-06/GT20152_tei.txt'.
Datei erfolgreich gespeichert als '../input/1825-06/GT20152_tei.txt'.
Transformation complete. Output written to ../input/1825-06/GT20152_tei.ann.post2.xml
```

--- Verarbeitung abgeschlossen ---

```
PROMPT = """Du bist ein Experte für die Inhaltsanalyse und Annotation von deutschsprachigen Tagebuchtexten des 19. Jahrhunderts. Ich gebe Dir eine Textdatei mit Tagebuch-Einträgen von Johann
Wolfgang von Goethe. Führe bitte die folgenden Schritte strikt aus:
1. Öffne die Datei und lies den gesamten Inhalt sorgfältig ein.
2. Normalisiere alle Whitespace-Zeichen:
- Ersetze geschützte Leerzeichen und Tabulatoren durch normale Leerzeichen (U+0020).
- Lasse aber die Anzahl der Leerzeichen unverändert, d. h. verbinde keine Token.
- Entferne keine Leerzeichen, sondern Sorge nur dafür, dass sie als Standard-Leerzeichen vorliegen.
3. Tokenisiere die Datei, indem Du den gesamten Text strikt an jedem einzelnen Leerzeichen und Satzzeichen in einzelne Token aufteilst. Jede Buchstabenfolge zwischen zwei Leerzeichen und
jedes Satzzeichen werden zu eigenständigen Token. Leerzeichen sind hingegen keine Token! Hier ein Beispiel dazu. Der Satz `Ueber Gespräche Tristan u. Isolt, des Ober-Forstm. Dr. Gottfried v.
Strassburg.` besteht aus folgenden 19 Token: `Ueber,Gespräche,Tristan,u.,.,Isolt,,,des,Ober,-,Forstm,,Dr.,Gottfried,v,,Strassburg,.` Führe keine weitere Regex-Logik oder Zusammenführung
von Buchstaben durch. Füge zudem keine Zeichen hinzu und entferne keine bestehenden Zeichen.
4. Analysiere den Inhalt der Datei semantisch und erkenne darin direkte und indirekte Nennungen von geografischen Entitäten. Dazu gehören Orte und Ortsangaben (Länder, Gegenden, Berge,
Flüsse, Seen, Städte, Dörfer usw.) aber auch Gebäude, Straßen, Plätze, Schloss- und Parkanlagen, Gärten usw. Auch Zimmerangaben (z.B. Arbeits-, Ess- oder Junozimmer) sollen als Geografika
erkannt werden. Zu den Geografika gehören auch adjektivische Nennungen wie „deutsche“, „römische“, „italienisch“ usw. Zu den indirekten Nennungen gehören Ortsangaben wie bspw. "hier",
"dort", "dorthin", "daselbst" usw. Auch Institutionen können als Orte vorkommen (z.B. „ins Theater gegangen" o. ä.). Geografika können auch Teil eines Personennamens sein wie bspw. bei
"König von Dänemark". Zeichne alle direkten und alle indirekten Nennungen von Geografika mit separaten rs-Elementen und dem Attributwertpaar type="place" aus. Beispielsweise enthält die
Stelle "Nach Weimar gefahren, dort gegessen." eine direkte Nennung ("Weimar" = ein rs-Element) und eine indirekte Nennung ("dort" = ein rs-Element).
6. Erstelle eine CoNLL-U-artige Textdatei (.conllu), in der jeder Token in einer Zeile steht. Sofern ein Token Teil eines Namens ist, soll in der zweiten Spalte eine Personen-ID zu diesem
Token generiert werden, die mit "pers" eingeleitet wird und in 10er Schritten pro Textpassage ansteigt, bspw. pers010, pers020 usw. Die Informationen in einer Zeile sind durch Tabulator
getrennt. Hier ist ein Modell:
1 {Token1} place010
2 {Token2} place010
3 {Token3} -
4 {Token4} -
5 {Token5} -
6 {Token6} -
7 {Token7} place020
8 {Token8} -
9 {Token9} -
7. Gib mir nur den Inhalt der conllu-Datei aus und nichts weiter, auch keine einleitenden oder abschließenden Zeichen wie bspw. ```.
Nimm einen tiefen Atemzug und führe die Aufgabe Schritt für Schritt durch. Das ist sehr wichtig für meine Karriere.
"""
```

```
"""
</div>
```


KI-gestütztes und kuratiertes NER (Personen und Orte)

Ergebnis: überprüfter, lemmatisierter und kategorisierter Text, in dem alle direkt und indirekt genannten Personen und Orte als solche erkannt und ausgezeichnet sind

```
<div type="diaryEntry">
<dateline><supplied><placeName key="SNDB79627" type="uebernachtungsort"/></supplied>
<lb/><date when="1825-06-01"><hi rendition="#u">Mittwoch</hi> <abbr>d<g ref="#typoSuspension"/>.</abbr> 1. <hi
rendition="#latin">Juny</hi></date></dateline>
<div type="diaryText">
<p>
<lb/><anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText010"/>Bericht an <rs type="person"
key="sndb:person#"><abbr>Sereniss.</abbr></rs> wegen
<lb/>des Münzkabinets.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an
<lb/>meine <rs type="person" key="sndb:person#">Schwiegertochter</rs>.<anchor corresp="#gt20152_lemText020"/> <anchor
type="Briefausgangsnotiz" xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/><rs type="person" key="sndb:person#">Lord
<lb/>Byrons</rs> letzte Tage <abbr>v.</abbr> <rs type="person" key="sndb:person#"><abbr>Maj.</abbr> Parry</rs><anchor
corresp="#gt20152_lemText040"/>
<pb type="r" facs="gt:digitalsite#27/11342/11342_113.jpg"/>
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/><rs type="person" key="sndb:person#">Herr Rath
Helbig</rs>, Abschied
<lb/>nehmend, nach <rs type="place" key="sndb:place#">Carlsbad</rs> gehend.
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Mittag" xml:id="gt20152_lemText060"/>Mittag <rs
type="person" key="sndb:person#"><abbr>Dr.</abbr> Eckermann</rs>.<anchor corresp="#gt20152_lemText060"/>
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/><rs type="person" key="sndb:person#">Lord Byrons</rs> letzte Tage von
<lb/><rs type="person" key="sndb:person#">Parry</rs>.<anchor corresp="#gt20152_lemText070"/> <anchor type="Begegnungen-Kunst"
xml:id="gt20152_lemText080"/><rs type="person" key="sndb:person#"><abbr>C.</abbr> <abbr>v.</abbr> Müller</rs> <rs type="person"
key="sndb:person#">den</rs> ich das
<lb/>Bild von <rs type="person" key="sndb:person#">Charon</rs> sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor
type="Lektüre" xml:id="gt20152_lemText090"/>So<g ref="#typoHyphen"/>
<lb break="no"/>dann obige Lektüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>
</p>
</div>
```


KI-gestütztes und kuratiertes NEL (Personen und Orte)

Ausgangspunkt: überprüfter, lemmatisierter und kategorisierter Text, in dem alle direkt und indirekt genannten Personen und Orte als solche erkannt und ausgezeichnet sind

```
<div type="diaryEntry">␣
<dateline><supplied><placeName key="SNDB79627" type="uebernachtungsort"/></supplied>␣
<lb/><date when="1825-06-01"><hi rendition="#u">Mittwoch</hi> <abbr>d<g ref="#typoSuspension"/>.</abbr> 1. <hi
rendition="#latin">Juny</hi></date></dateline>␣
<div type="diaryText">␣
<p>␣
<lb/><anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText010"/>Bericht an <rs type="person"
key="sndb:person#"><abbr>Sereniss.</abbr></rs> wegen␣
<lb/>des Münzkabinetts.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an␣
<lb/>meine <rs type="person" key="sndb:person#">Schwiegertochter</rs>.<anchor corresp="#gt20152_lemText020"/> <anchor
type="Briefausgangsnotiz" xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>␣
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>␣
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/><rs type="person" key="sndb:person#">Lord␣
<lb/>Byrons</rs> letzte Tage <abbr>v.</abbr> <rs type="person" key="sndb:person#"><abbr>Maj.</abbr> Parry</rs><anchor
corresp="#gt20152_lemText040"/>␣
<pb type="r" facs="gt:digitalsite#27/11342/11342_113.jpg"/>␣
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>␣
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/><rs type="person" key="sndb:person#">Herr Rath
Helbig</rs>, Abschied␣
<lb/>nehmend, nach <rs type="place" key="sndb:place#">Carlsbad</rs> gehend.␣
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>␣
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Mittag" xml:id="gt20152_lemText060"/>Mittag <rs
type="person" key="sndb:person#"><abbr>Dr.</abbr> Eckermann</rs>.<anchor corresp="#gt20152_lemText060"/>␣
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/><rs type="person" key="sndb:person#">Lord Byrons</rs> letzte Tage von␣
<lb/><rs type="person" key="sndb:person#">Parry</rs>.<anchor corresp="#gt20152_lemText070"/> <anchor type="Begegnungen-Kunst"
xml:id="gt20152_lemText080"/><rs type="person" key="sndb:person#"><abbr>C.</abbr> <abbr>v.</abbr> Müller</rs> <rs type="person"
key="sndb:person#">den</rs> ich das␣
<lb/>Bild von <rs type="person" key="sndb:person#">Charon</rs> sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor
type="Lektüre" xml:id="gt20152_lemText090"/>So<g ref="#typoHyphen"/>␣
<lb break="no"/>dann obige Lektüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>␣
</p>␣
</div>␣
```


KI-gestütztes und kuratiertes NEL (Personen und Orte)

Automatisierte Ersetzung eindeutiger Personen und Orte:

```
<div type="diaryText">
<p>
<lb/><anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText010"/>Bericht an <rs type="person"
key="sndb:person#"><abbr>Sereniss.</abbr></rs> wegen
<lb/>des Münzkabinetts.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an
<lb/><rs type="person" key="sndb:person#43782">meine Schwiegertochter</rs>.<anchor corresp="#gt20152_lemText020"/> <anchor
type="Briefausgangsnotiz" xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/><rs type="person" key="sndb:person#36218">Lord
<lb/>Byrons</rs> letzte Tage <abbr>v.</abbr> <rs type="person" key="sndb:person#"><abbr>Maj.</abbr> Parry</rs><anchor
corresp="#gt20152_lemText040"/>
<pb type="r" facs="gt:digitalisate#27/11342/11342_113.jpg"/>
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/><rs type="person" key="sndb:person#">Herr Rath
Helbig</rs>, Abschied
<lb/>nehmend, nach <rs type="place" key="sndb:ort#78239">Carlsbad</rs> gehend.
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Mittag" xml:id="gt20152_lemText060"/>Mittag <rs
type="person" key="sndb:person#36828"><abbr>Dr.</abbr> Eckermann</rs>.<anchor corresp="#gt20152_lemText060"/>
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/><rs type="person" key="sndb:person#36218">Lord Byrons</rs> letzte Tage von
<lb/><rs type="person" key="sndb:person#">Parry</rs>.<anchor corresp="#gt20152_lemText070"/> <anchor type="Begegnungen-Kunst"
xml:id="gt20152_lemText080"/><rs type="person" key="sndb:person#44617"><abbr>C.</abbr> <abbr>v.</abbr> Müller</rs> <rs type="person"
key="sndb:person#">den</rs> ich das
<lb/>Bild von <rs type="person" key="sndb:person#">Charon</rs> sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor
type="Lektüre" xml:id="gt20152_lemText090"/>So<g ref="#typoHyphen"/>
<lb break="no"/>dann obige Lektüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>
</p>
</div>
```


KI-gestütztes und kuratiertes NEL (Personen und Orte)

```
PS C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\Skripte> py nel.py ../testStapel/1825-02-06/GT20152_tei.xml
[NEL-Pipeline] Projektordner: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832
[NEL-Pipeline] Eingabe: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\testStapel\1825-02-06\GT20152_tei.xml
[NEL-Pipeline] Schritt 1/5: xml:id-Werte ergaenzen
[NEL-Pipeline] Geschrieben: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\TEMP\XML\GT20152_tei.xml
[NEL-Pipeline] Schritt 2/5: Entitaeten extrahieren
[NEL-Pipeline] Geschrieben: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\TEMP\lists\entries\GT20152_tei_entities.tsv
[NEL-Pipeline] Schritt 3/5: SNDB-Kandidaten mit claude_match.py ermitteln
[NEL-Pipeline] Starte: claude_match.py
Fertig. Ausgabedatei geschrieben: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\TEMP\lists\entries\GT20152_tei_entities_sndb.
tsv
[NEL-Pipeline] Geschrieben: C:\Users\martin.prell\Documents\Gitlab\gt-born-digital-1825-1832\NEL\TEMP\lists\entries\GT20152_tei_entities_sndb.tsv
[NEL-Pipeline] Schritt 4/5: TSV-Dateien mit compareTSV.py pruefen
```

PROMPT = ""Du bekommst zwei TSV-Dateien.

Aufgabe:

Ergaenze die TSV-Datei, deren Dateiname auf entities.tsv endet, um sechs neue Spalten:

```
SNDB-ID1
SNDB-Name1
Wahrscheinlichkeit1
SNDB-ID2
SNDB-Name2
Wahrscheinlichkeit2
```

Regeln:

1. In der Datei, die auf entities.tsv endet, stehen in der Spalte "Entität" Namen von Personen und Orten.
2. In der anderen TSV-Datei stehen passende oder aehnliche Namen in der Spalte "name".
3. Die Schreibweisen stimmen nicht immer exakt ueberein.
4. Gehe jede Zeile der entities.tsv-Datei durch.
5. Suche in der anderen TSV-Datei die zwei Werte aus "name", die der jeweiligen Zelle aus "Entität" orthographisch am aehnlichsten sind.
6. Trage den besten Treffer in "SNDB-Name1" ein.
7. Trage die zugehoerige sndb_id aus derselben Zeile der anderen TSV-Datei in "SNDB-ID1" ein.
8. Trage die von Dir ermittelte Wahrscheinlichkeit der richtigen Zuordnung in "Wahrscheinlichkeit1" ein.
9. Trage den zweitbesten Treffer in "SNDB-Name2" ein.
10. Trage die zugehoerige sndb_id aus derselben Zeile der anderen TSV-Datei in "SNDB-ID2" ein.
11. Trage die von Dir ermittelte Wahrscheinlichkeit der richtigen Zuordnung in "Wahrscheinlichkeit2" ein.

Wichtig:

- Trage in jeder Zeile mindestens eine Zuordnung in die Spalten SNDB-ID1, SNDB-Name1, Wahrscheinlichkeit1 ein.
- Orientiere dich für die Zuordnung von Personalpronomen in der Spalte "Entität" an dem unmittelbar vorausgehenden Personennamen.
- Nimm bei einem Wert von unter 0.6 in der Spalte Wahrscheinlichkeit1 auch Zuordnungen in den Spalten SNDB-ID2, SNDB-Name2, Wahrscheinlichkeit2 vor
- Wenn ein "name" keinen Wert in "sndb_id" hat, dann lasse auch die jeweiligen Zellen der Spalte "SNDB-ID1" bzw. "SNDB-ID2" leer.
- Fuege nur die sechs neuen Spalten hinzu. Veraendere die Zellen aus der entities.tsv-Datei nicht. Ändere auch nicht die Reihenfolge der Zeilen. Die Reihenfolge der Zeilen soll die gleiche bleiben wie in der entities.tsv-Datei, d.h. die Zeilenreihenfolge entspricht der fortlaufenden Zählung in der ID-Spalte, bspw. e001, e002, e003 usw.
- Gib ausschliesslich die vollstaendige neue TSV-Datei zurueck.
- Gib keine Erklaerung, keinen Markdown-Codeblock und keinen sonstigen Text aus.

KI-gestütztes und kuratiertes NEL (Personen und Orte)

```
<div type="diaryText">␣
<p>␣
<lb/><anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText010"/>Bericht an <rs type="person" key="sndb:person#"
candidates="40962;Sachsen-Weimar-Eisenach, Karl August,...;0.5;|44617;Müller, Friedrich Theodor Adam Heinrich
v.,...;0.2"><abbr>Sereniss.</abbr></rs> wegen␣
<lb/>des Münzkabinets.<anchor corresp="#gt20152_lemText010"/> <anchor type="Briefausgangsnotiz" xml:id="gt20152_lemText020"/>Brief an␣
<lb/><rs type="person" key="sndb:person#43782">meine Schwiegertochter</rs>.<anchor corresp="#gt20152_lemText020"/> <anchor
type="Briefausgangsnotiz" xml:id="gt20152_lemText030"/>Con<g ref="#typoHyphen"/>␣
<lb break="no"/>cipirte Briefe in der Ver<g ref="#typoHyphen"/>␣
<lb break="no"/>lags<g ref="#typoHyphen"/>Angelegenheit.<anchor corresp="#gt20152_lemText030"/> <anchor type="Lektüre"
xml:id="gt20152_lemText040"/><rs type="person" key="sndb:person#36218">Lord␣
<lb/>Byrons</rs> letzte Tage <abbr>v.</abbr> <rs type="person" key="sndb:person#49281" candidates="49281;Parry,
William,...;0.95;|;;"><abbr>Maj.</abbr> Parry</rs><anchor corresp="#gt20152_lemText040"/>␣
<pb type="r" facs="gt:digitalisate#27/11342/11342_113.jpg"/>␣
<lb/><fw><hi rendition="#latin">Juny.</hi></fw>␣
<lb/><anchor type="Begegnungen-Meteorologie/Wetter" xml:id="gt20152_lemText050"/><rs type="person" key="sndb:person#37957"
candidates="37957;Helbig (Helwig), Karl Emil,...;0.95;|;;">Herr Rath Helbig</rs>, Abschied␣
<lb/>nehmend, nach <rs type="place" key="sndb:ort#78239">Carlsbad</rs> gehend.␣
<lb/>Einiges Meteorologische bespre<g ref="#typoHyphen"/>␣
<lb break="no"/>chend.<anchor corresp="#gt20152_lemText050"/> <anchor type="Mittag" xml:id="gt20152_lemText060"/>Mittag <rs
type="person" key="sndb:person#36828"><abbr>Dr.</abbr> Eckermann</rs>.<anchor corresp="#gt20152_lemText060"/>␣
<lb/><anchor type="Lektüre" xml:id="gt20152_lemText070"/><rs type="person" key="sndb:person#36218">Lord Byrons</rs> letzte Tage von␣
<lb/><rs type="person" key="sndb:person#49281" candidates="49281;Parry, William,...;0.95;|;;">Parry</rs>.<anchor
corresp="#gt20152_lemText070"/> <anchor type="Begegnungen-Kunst" xml:id="gt20152_lemText080"/><rs type="person"
key="sndb:person#44617"><abbr>C.</abbr> <abbr>v.</abbr> Müller</rs> <rs type="person" key="sndb:person#" candidates="44617;Müller,
Friedrich Theodor Adam Heinrich v.,...;0.5;|40962;Sachsen-Weimar-Eisenach, Karl August,...;0.2">den</rs> ich das␣
<lb/>Bild von <rs type="person" key="sndb:person#" candidates=";Charon (Charos), im Volksglauben der Neugriechen Verkörperung der
Unterwelt und des Todes;0.95;|;;">Charon</rs> sehen ließ.<anchor corresp="#gt20152_lemText080"/> <anchor type="Lektüre"
xml:id="gt20152_lemText090"/>So<g ref="#typoHyphen"/>␣
<lb break="no"/>dann obige Lectüre fortgesetzt.<anchor corresp="#gt20152_lemText090"/>␣
</p>␣
</div>␣
```


Statistik

Lemmatisierung und Kategorisierung:

- 1825: 3.142 Lemmata in 32 Kategorien
- 1825-1832: schätzungsweise: 23.000 Lemmata/Einzelstellenerläuterungen

NER/NEL:

- 1825: 2.836 Personenreferenzen (inkl. Gruppen); 1.212 distinkte Schreibweisen
- 1825: 912 Ortsreferenzen; 414 distinkte Schreibweisen
- Davon konnten 36 eindeutige Personen (1.542 Referenzen bei 200 distinkten Schreibungen) und 66 eindeutige Ortsnennungen (595 Referenzen bei 146 distinkten Schreibungen) automatisiert ersetzt werden (etwa 54% bzw. 65%)
- Für 1.294 Personenzuweisungen und 317 Ortszuweisungen werden die Vorschläge der KI-Zuweisung überprüft
- 1825-1832: schätzungsweise 20.500 Personen- und 6.600 Ortsreferenzen
- Hinzu kommen: Referenzen auf Werke und Körperschaften → insgesamt schätzungsweise: 40.000 Entitäten