



Fotis Jannidis / Hubertus Kohle /
Malte Rehbein (Hg.)

Digital Humanities

Eine Einführung



J.B. METZLER



J.B. METZLER

Fotis Jannidis / Hubertus Kohle / Malte Rehbein (Hg.)

Digital Humanities

Eine Einführung

Mit Abbildungen und Grafiken

J.B. Metzler Verlag

Die Herausgeber

Fotis Jannidis ist Professor für Computerphilologie und Neuere Deutsche Literaturgeschichte an der Julius-Maximilians-Universität Würzburg.

Hubertus Kohle ist Professor für Mittlere und Neuere Kunstgeschichte an der Ludwig-Maximilians-Universität München.

Malte Rehbein ist Professor für Digital Humanities an der Universität Passau.



Gedruckt auf chlorfrei gebleichtem, säurefreiem und alterungsbeständigem Papier

Bibliografische Information der Deutschen Nationalbibliothek

Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über <http://dnb.d-nb.de> abrufbar.

ISBN 978-3-476-02622-4

ISBN 978-3-476-05446-3 (eBook)

Dieses Werk einschließlich aller seiner Teile ist urheberrechtlich geschützt. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ist ohne Zustimmung des Verlages unzulässig und strafbar. Das gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmungen und die Einspeicherung und Verarbeitung in elektronischen Systemen.

J.B. Metzler, Stuttgart

© Springer-Verlag GmbH Deutschland, 2017

Einbandgestaltung: Finken & Bumiller, Stuttgart (Foto: shutterstock)

Satz: primustype Hurler GmbH, Notzingen

Druck und Bindung: Ten Brink, Meppel, Niederlande

J.B. Metzler ist Teil von Springer Nature

Die eingetragene Gesellschaft ist Springer-Verlag GmbH Deutschland

www.metzlerverlag.de

info@metzlerverlag.de

Inhaltsverzeichnis

Warum ein Lehrbuch für Digital Humanities?	XI
--	----

I Grundlagen

1 Geschichte der Digital Humanities	3
1.1 Texte und Informationstechnologie: Der Gründungsmythos der Digital Humanities	3
1.2 Eine Community entsteht: Die frühen Jahre	5
1.3 Die Welt wird einfacher – Programmpakete	6
1.4 Die Welt wird noch einfacher – der Personal Computer	7
1.5 Vernetzungen von Personen und Ressourcen	9
1.6 Das WWW als einheitliches Interface	10
1.7 Das Beste kommt erst noch	11
2 Digital Humanities als Wissenschaft	13
2.1 Die Digital Humanities: Ein weites Feld	13
2.2 Die Digital Humanities: Werkzeug oder Methode?	13
2.3 Die Digital Humanities im Kontext der geisteswissenschaftlichen Disziplinen	14
2.4 Die Digital Humanities jenseits einzelner geisteswissenschaftlicher Disziplinen	15
2.5 Die Digital Humanities und die Informatik	17
2.6 »Die Digital Humanities«	18
3 Theorien digitaler Medien	19
3.1 Digitalisierung als Medien- und Wissensgeschichte	19
3.2 Medienarchäologie und Software Studies	22
3.3 Digitalisierung und Gesellschaft	26
3.4 Digitale Methoden	29
4 Aufbau des Computers und Vernetzung	35
4.1 Aufbau eines Computers	35
4.2 Eingabeperipherie, Ausgabeperipherie, Speicherperipherie	39
4.3 Computertypen	42
4.4 Benutzerschnittstellen	43
4.5 Vernetzung	45
4.6 OSI-Modell	46
4.7 TCP-IP-Modell	48
4.8 Netztopologie	50
4.9 Internet Protokoll	52
4.10 E-Mail und Webserver	54
5 Zahlen und Zeichen	59
5.1 Analog, digital und das Bit	59
5.2 Binäre Zahlen und Dezimalzahlen	60
5.3 Zeichenkodierung	61
5.4 Offene Probleme	66

6	Grundbegriffe des Programmierens	68
6.1	Anweisungen	69
6.2	Datentypen	70
6.3	Datenstrukturen 1: Listen	73
6.4	Ausdrücke, die Wahrheitswerte zurückgeben	74
6.5	Schleifen	77
6.6	Bedingte Verzweigungen	80
6.7	Datenstrukturen 2: assoziatives Feld	82
6.8	Modularisierung	84
6.9	Algorithmisches Denken	89
II	Datenmodellierung	
7	Grundlagen der Datenmodellierung	99
7.1	Grundbegriffe der Datenmodellierung	100
7.2	Stufen der Datenmodellierung	102
7.3	Datenmodellierung in der Praxis	104
7.4	Datenmodellierung in den Digital Humanities	106
8	Datenbanken	109
8.1	Datenverarbeitung und -organisation	109
8.2	Erstellen eines Datenmodells: Relationale Datenbank	112
8.3	Datenbankabfragen	123
8.4	Andere Datenbankmodelle	126
9	XML	128
9.1	Anwendung und Grundbegriffe	128
9.2	Grundstrukturen	130
9.3	Konzepte und Datenmodell	132
9.4	Modelle und Schemata	135
9.5	XPath	138
9.6	XSLT	141
9.7	X-Technologien im Einsatz	144
10	Netzwerke	147
10.1	Grundlagen	147
10.2	Rechnen mit Graphen	151
10.3	Den kürzesten Weg finden	154
10.4	Angewandte Netzwerkanalyse	157
10.5	Fazit	160
11	Ontologien	162
11.1	Begriff und Einordnung	162
11.2	Grundlegende Konzepte	164
11.3	Ein Beispiel	166
11.4	RDF	168
11.5	Speicherung, Retrieval und Datenintegration	172
11.6	Ontologien in den Digital Humanities	174

III Digitale Objekte

12	Digitalisierung	179
12.1	Grundlagen digitaler Bilder	181
12.2	Bilddigitalisierung	187
12.3	Erschließung der Digitalisate	192
12.4	Textdigitalisierung	193
12.5	Weitere Digitalisierungsverfahren	196
13	Digitales Publizieren	199
13.1	Eine Revolution	199
13.2	Neue Medien imitieren alte Medien	200
13.3	Eigenschaften der digitalen Publikation	201
13.4	Open Access	202
13.5	Neue Publikationsmodelle im Digitalen	204
14	Digitale Wissensproduktion	206
14.1	Was ist digitale Wissensproduktion?	206
14.2	Umgang mit Datenbanken	207
14.3	Crowdsourcing	208
14.4	Kollaboratives Schreiben: Wikipedia	209
14.5	Konsequenzen	211
15	Bibliothek, Archiv, Museum	213
15.1	Gedächtnisinstitutionen	213
15.2	Einheitliche Beschreibung von Objekten und Sammlungen	215
15.3	Wichtige Informationsportale	217
15.4	Gedächtnisinstitutionen als Forschungs- und Informationsinfrastrukturen für die Digital Humanities	220
16	Aufbau von Datensammlungen	223
16.1	Einleitung: Was sind Datensammlungen?	223
16.2	Erheben von Informationen über den gesamten Gegenstandsbereich ...	225
16.3	Sammeln, Zusammenführen und Säubern von Datensätzen	227
16.4	Erheben und Hinzufügen von Informationen über die Daten	228
16.5	Verfügbarmachen der Datensammlung	230
16.6	Fazit	232
17	Digitale Edition	234
17.1	Drei Beispiele zur Einführung	234
17.2	Worum geht es?	237
17.3	Definitiverischer Rahmen	238
17.4	Paradigmen digitaler Editionen	240
17.5	Methoden und die Realisierung digitaler Editionen	241
17.6	Editionen als Projekte	244
17.7	Technologien und Standards	245
17.8	Fragestellungen	248

IV Digitale Methoden

18	Manuelle und automatische Annotation	253
18.1	Was sind Annotationen?	253
18.2	Formalisierung und Operationalisierung	255
18.3	Annotationstypen und -funktionen	257
18.4	Annotationsverfahren	260
18.5	Objekte	262
19	Information Retrieval	268
19.1	Messwerte für IR-Systeme	269
19.2	Indexierung	270
19.3	Suchstrategien	271
19.4	Weitere Retrieval-Systeme	278
20	Quantitative Analyse	279
20.1	Was ist quantitative Analyse	279
20.2	Statistische Grundlagen	280
20.3	Maschinelles Lernen	289
20.4	Neuere Entwicklungen	297
21	Geographische Informationssysteme	299
21.1	GIS Datenmodelle	300
21.2	Raumprojektionen in gängigen Koordinatensystemen im Vergleich	303
21.3	Unsicherheiten von Raum- und Zeitangaben in historischen Quellen ...	305
21.4	Datenintegration und Kartentypen	307
21.5	GIS-Aufbau und -Komponenten	309
21.6	GIS-Methoden	311
21.7	Kartenrepositorien via Web WMS (World Map Services)	312
22	Digitale Rekonstruktion und Simulation	315
22.1	Definitionen	315
22.2	Digitale Rekonstruktion	315
22.3	Digitale Simulation	323
23	Informationsvisualisierung	328
23.1	Informationsvisualisierung in historischer Perspektive	328
23.2	Definitionen und Funktionen	330
23.3	Informationsvisualisierung im Forschungsprozess	331
23.4	Referenzmodell und Datenmodellierung	333
23.5	Datentypen	335
23.6	Visuelle Strukturen	336
23.7	Kritische Informationsvisualisierung	341

V Recht und Ethik

24	Recht	345
24.1	Digitale Objekte – mehr als nur ein Medienwandel.....	345
24.2	Digital Humanities und Open Access.....	350
24.3	Rechtsfragen digitaler Geistes- und Kulturwissenschaft: Ein Forschungsgegenstand der Digital Humanities?	351
25	Ethik	353
25.1	Ethische Fragen in den Digital Humanities: Eine Fallstudie	353
25.2	Moral, Ethik, Angewandte Ethik.....	354
25.3	Verantwortung als analytische Schlüsselkategorie.....	355

VI Anhang

26	Auswahlbibliographie	361
26.1	Allgemein.....	361
26.2	Fachspezifisch	361
26.3	Fachzeitschriften	362
	Autorinnen und Autoren	363
	Sach- und Personenregister	364

Warum ein Lehrbuch für Digital Humanities?

Digitalisierung und Vernetzung haben unsere Welt verändert. Das gilt auch für die Gegenstände und Methoden der Wissenschaften im Allgemeinen und der Geisteswissenschaften im Besonderen. Dieser schon länger dauernde Prozess kristallisiert sich heraus in der Etablierung neuer Studiengänge sowie der Einrichtung neuer Professuren, Buchreihen, internationaler Konferenzen unter der Bezeichnung ›Digital Humanities‹. Dabei hat sich die Arbeitspraxis aller Geisteswissenschaften dadurch verändert, dass viele ihrer Gegenstände nun in digitaler Form vorliegen, deutlich leichter erreichbar sind als früher, neue Zugriffsmöglichkeiten erlauben und auch die wissenschaftliche Kommunikation zunehmend digital geschieht. Einerseits sind in diesem Sinne also inzwischen fast alle Geisteswissenschaften auch digital, andererseits hat sich ein neues Arbeitsfeld etabliert, das an der Schnittstelle zwischen den Geisteswissenschaften und der Informatik angesiedelt ist.

Die Forscherinnen und Forscher in diesem Feld beschäftigen sich damit, neue Entwicklungen in der Informatik auf ihre Verwendbarkeit in den Geisteswissenschaften zu prüfen oder eigenständig geeignete Verfahren zu entwickeln, und sie erforschen die Algorithmen und Datenstrukturen, die sich als geeignet erwiesen haben. ›Digital Humanities‹ bezeichnet damit auch eine Transformationswissenschaft, da sie die von ihr entwickelten Theorien, Methoden und Verfahren den geisteswissenschaftlichen Fachdisziplinen zur Nutzung anbieten. Digitale Geisteswissenschaften in diesem engeren Sinn setzen selektive, aber solide Kenntnisse in einigen Teilgebieten der Informatik voraus, zugleich aber ebenso profunde Kenntnisse in Bezug auf Fragestellungen und Methoden zumindest einiger Geisteswissenschaften. Das vorliegende Buch soll Studierenden und interessierten Kollegen einen Überblick über die Wissensbestände und Denkverfahren geben, die sich in den letzten rund fünf Jahrzehnten in diesem Forschungsfeld etabliert haben.

Die Digital Humanities in diesem Verständnis sind ein äußerst anspruchsvolles Forschungsprogramm, da die Forschungsparadigmen in den beiden Feldern, die hier zusammengebracht werden, eher in einem anregenden Spannungsverhältnis zueinander stehen, als sich zwanglos ergänzen. Sie können gerade in den historisierenden Wissenschaften, aber auch dort, wo etwa die Kunst- oder Literaturwissenschaften sich stärker um die Genese als um die Geltung eines Phänomens kümmern, an Traditionen anknüpfen, die schon immer in formalen Kategorien argumentiert haben. Sozialhistorische Forschung ist jenseits messbarer Kategorien gar nicht denkbar; aber etwa auch Rezeptionsverläufe und -häufigkeiten in der bildenden Kunst und Literatur lassen sich im Idealfall eindeutig quantifizieren. Und schließlich sind manche Verfahrensweisen der Digital Humanities erst einmal nur Fortsetzungen und Erweiterungen traditioneller Praktiken. Das reicht von elektronisch gestützten Editionen, die eine ehrwürdige und Jahrhunderte währende Tätigkeit der klassischen Geisteswissenschaften auf neue Füße stellen bis hin zum Aufbau von digitalen Bilddatenbanken, die die alten Diatheken ersetzen. Außerordentlich reizvoll wird es jedoch vor allem dann, wenn computergestützte Verfahren dort eingesetzt werden, wo die traditionellen Methoden an ihre Grenzen stoßen, wo Denkanstöße aus ungewöhnlichen Richtungen kommen und wir somit neues Forschungsterrain betreten können.

Zum Aufbau des Buches: Dieser Band ist eine Einführung in die wichtigsten Aspekte der Digital Humanities. Dazu stellt das Buch die grundlegenden Theorien des Faches vor, definiert zentrale Begriffe und erklärt wesentliche Methoden. Ein Leit-

prinzip ist es dabei, immer wieder die Rückkopplung der gängigen technischen Verfahrensweisen zu Fragestellungen aus den Geisteswissenschaften vorzunehmen.

Der erste Teil vermittelt Basiswissen, dies reicht von der Geschichte der Digital Humanities und einer Einführung in die Theorie digitaler Medien über fundamentale Erklärungen zur Konstruktionsweise von Computer und Internet bis hin zu den elementaren Konzepten des Programmierens.

Der zweite Teil widmet sich der Datenmodellierung, die vielfach als die zentrale Schaltstelle der Digital Humanities angesehen wird. Hierbei geht es um die Frage, wie die Gegenstände der Geistes- und Kulturwissenschaften so aufbereitet und formalisiert werden, dass sie für einen computergestützten Zugang überhaupt erst nutzbar werden. Nach konzeptuellen Vorüberlegungen und einer Einführung in die Datenbanktechnologien werden hierarchische Datenstrukturen, Netzwerkanalysen und ontologische Wissensrepräsentationen thematisiert.

Der dritte Teil führt zunächst kurz ein in die traditionellen Institutionen des kulturellen Gedächtnisses, wie Archive, Bibliotheken sowie Museen und widmet sich den organisatorischen und technischen Fragen der Digitalisierung ihrer Bestände. Hier werden darüber hinaus die Bedingungen in einem digitalen Raum sich verändernder Kulturen von Wissensproduktion und -publikation mit besonderem Schwerpunkt auf digitale Sammlungen und digitale Editionen behandelt.

Gegenüber diesen digitalen Objekten geht es dann im vierten Teil um die computergestützten Methoden, die wir für einen Einstieg in die Digital Humanities als zentral erachten. Einzeln eingeführt wird in Annotation, Retrieval, quantitative Analyse, Geographische Informationssysteme, Simulation und Rekonstruktion sowie Informationsvisualisierung.

Abgerundet wird der Band im fünften Teil mit den wichtigen, bisweilen unterschätzten normativen Aspekten der Digital Humanities: Recht und Ethik. Somit hoffen wir insgesamt, mit dieser Einführung auch einen Beitrag zur weiteren Etablierung der Digital Humanities in der deutschsprachigen Wissenschaftslandschaft zu leisten und zu zeigen, dass es um eine interessante und nachhaltige Erweiterung des geistes- und kulturwissenschaftlichen Kanons geht und nicht um eine Modeerscheinung.

Zur Nutzung des Buches: Bei der Konzeption des Bandes hatten wir zwei Zielgruppen vor Augen. Zum einen wollen wir Studierenden einschlägiger Fächer und Studienprogramme der Digital Humanities einen fundierten und verständlichen Überblick an die Hand geben. Zum anderen soll diese Einführung aber auch allen anderen, Studierenden wie Wissenschaftlern wie interessierten Laien zugleich, Orientierungswissen bieten und ihnen helfen, die Verfahrensweisen der Digital Humanities kennenzulernen und kritisch einzuordnen. Dabei setzen wir lediglich eine allgemeine Vorbildung und ein grundlegendes und wohlwollendes Verständnis geistes- und kulturwissenschaftlicher Gegenstände und Fragestellungen, etwas Schulmathematik und natürlich eine gewisse Aufgeschlossenheit der Computertechnologie gegenüber voraus (aber keine Vorkenntnisse derselben).

Der Leser wird feststellen, dass die einzelnen Kapitel dieses Buches unterschiedlich gestaltet sind. Dies ist der Sache geschuldet. Erstens erfordert die Vielfalt der Aspekte der Digital Humanities und ihre verschiedenen Methoden eine gewisse Varianz an Darstellungen; manche Themen lassen sich durch sorgfältiges Lesen erschließen, andere hingegen erfordern das eigene Ausprobieren und Experimentieren mit den vorgestellten Methoden am heimischen Rechner, um diese wirklich zu verstehen. Und zweitens eröffnen die verschiedenen Kapitel unterschiedliche, durchaus auch

wechselnde und sich gegenseitig ergänzende Perspektiven auf verwandte Fragestellungen. Der Leser ist eingeladen, diese miteinander zu vergleichen und kritisch zu hinterfragen.

Das Buch ist so konzipiert, dass es sowohl begleitend zu Lehrveranstaltungen der Digital Humanities als auch im Selbststudium gelesen werden kann. In beiden Fällen runden Anwendungsbeispiele, Übungsaufgaben (im Internet unter <http://www.metzlerverlag.de/9783476026224> (Downloads)), Literaturangaben und ein Register die Einführung ab. Die Anordnung der Kapitel ist von uns didaktisch bewusst gewählt; diese Reihenfolge beim Lesen einzuhalten, erscheint uns zwar durchaus sinnvoll, ist aber nicht notwendig. Der Leser sei ermutigt, den Querverweisen zu folgen, eigene Lesepfade einzuschlagen und eigene Schwerpunkte zu setzen.

Apropos ›der‹ Leser: Der besseren Lesbarkeit willen verwenden wir durchgängig das generische Maskulinum, und wir meinen damit natürlich Menschen jeden Geschlechts. Wissenschaftler sind stets auch Wissenschaftlerinnen, Forscher Forscherinnen und Leser Leserinnen.

Einige abschließende Worte des Dankes: Ohne die freundliche und stetige Ermutigung durch unsere Lektorin, Ute Hechtfisher, wäre der Band nicht in der vorliegenden Form entstanden. Katharina Vukadin übernahm die grafische Gestaltung der Schaubilder, Stefanie Schneider einen redaktionellen Durchgang. Ein ganz besonderer Dank geht an Dominika Heublein, die mit großer Sorgfalt und unermüdlichem Einsatz nicht nur die Texte in die richtige Form gebracht, sondern auch wertvolle Gestaltungs- und Korrekturarbeit geleistet hat.

I Grundlagen

1 Geschichte der Digital Humanities

1.1 | Texte und Informationstechnologie: Der Gründungsmythos der Digital Humanities

Informationstechnologien werden heute in allen Fächern der geisteswissenschaftlichen Fakultäten und Fachbereiche verwendet. Die frühesten Beispiele dafür finden sich in den Fächern, die sich mit Texten beschäftigen, sei es im sprach- oder literaturwissenschaftlichen Sinn. Aus den Anfängen der Verwendung der frühen Computertechnologie im Umgang mit Texten sticht vor allem eine Geschichte hervor, die geradezu als ›Gründungsmythos‹ der Digital Humanities gelten kann. 1940 arbeitete ein junger Jesuit, **Roberto Busa**, an einer Dissertation zum Thema des Präsenzbegriffes bei Thomas von Aquin. Sehr bald musste er feststellen, dass das offensichtliche, die Suche nach dem Wort ›praesentia‹, wenig brachte, da das zu Grunde liegende intellektuelle Konzept meist nur indirekt durch die Verwendung der Präposition ›in‹ angezeigt wurde. Als Funktionswort tritt ›in‹ nicht selten auf und fehlt in allen Registern der gedruckten Edition der Texte; die einzige Möglichkeit bestand also darin, Tausende von Druckseiten Zeile für Zeile und Wort für Wort durchzugehen und, sobald ›in‹ gefunden war, festzustellen, ob seine Verwendung in diesem Fall auf das untersuchte Phänomen verwies.

10.000 handgeschriebene Karteikarten und einen Weltkrieg später verteidigte Padre Busa 1946 seine Dissertation erfolgreich – und war von seinen Ordensoberen dazu bestimmt, seine Laufbahn weiterhin dem Denken des Aquinaten zu widmen. Zutiefst davon überzeugt, dass seine Konzeption, dass die Interpretation der einem Texte zu Grunde liegenden Philosophie besser auf dem Studium unbewusst verwendeter Worte und Konstruktionen aufbauen solle, als auf der Analyse der offensichtlich bedeutungstragenden, schlug er noch 1946 vor, dafür eine **Konkordanz**, also ein Verzeichnis *aller* bei **Thomas von Aquin** vorkommenden Worte, jeweils begleitet von einem kurzen Stück Kontext, zu produzieren, um diesen Ansatz für die weitere Forschung systematisch zu unterstützen. Dass dies mit herkömmlichen Mitteln nur wenig erfolgversprechend war, hatten ihn die 10.000 Karteikarten gelehrt.

Auf der Suche nach geeigneten Technologien gelang es ihm 1949 schließlich, IBM, damals vor allem als Hersteller von Lochkartensortiermaschinen profitabel, für die technische und finanzielle Unterstützung des Vorhabens zu gewinnen. Er war nicht nur ein hervorragender Wissenschaftler, sondern auch ein gewiefter Forschungspolitiker, und konnte so bald danach schließlich darauf verweisen, dass Remington Rand – ein Konkurrent von IBM – einen anderen Forscher bereits mit seinen Computern und Magnetbändern bei der ähnlichen Aufgabe der Erstellung einer Bibelkonkordanz unterstützte. Was dazu führte, dass auch der Aquinat von diesem Zeitpunkt an von den Lochkartensortierern auf die ersten Generationen von IBM Computern transferiert wurde.

Abgesehen davon, dass die Geschichte eines (bis zu seinem Lebensende) von Charme und Charisma übersprühenden jungen Forschers, der einen der einflussreichsten Industriellen seiner Zeit davon überzeugte, einem genuin geisteswissenschaftlichen Vorhaben, der Untersuchung der Gedankenwelt Thomas von Aquins, seine uneingeschränkte Unterstützung zu leihen, einen hervorragenden Einstieg in die Geschichte einer Disziplin darstellt, versteckt sich darin ein leicht übersehbarer Zwiespalt, der die Digital Humanities bis heute prägt. Offensichtlich wurde die frühe

Rechnertechnologie hier als ein **Werkzeug** verwendet, das den Zeitaufwand für die Bewältigung von Routineaufgaben signifikant verringerte. Padre Busa selbst betont in seiner Geschichte des ›Index Thomisticus‹, wie die Konkordanz genannt wurde, aber gar nicht so sehr den Nutzen des Werkzeugs: Ihn fasziniert in diesem Aufsatz viel mehr die Erkenntnis, dass die Konzentration auf unbewusste sprachliche Merkmale – Funktionswörter, also: ›in‹ – im Gegensatz zu den offensichtlich bedeutungstragenden, einen **methodisch** völlig neuen Zugang zu der in einem Text ausgedrückten Gedankenwelt ermöglicht, per Definition also einen Zugang, der über die einzelne Studie hinausgeht.

In der Tat hat die Beschäftigung mit den nicht-intentionalen sprachlichen Merkmalen in den Digital Humanities eine zweite Wurzel etwa zur selben Zeit. In der Geschichte der amerikanischen Verfassung sind eine Serie politischer Essays – die »**Federalist Papers**« –, die unter einem gemeinsamen Pseudonym von Alexander Hamilton, James Madison, und John Jay zur Zeit der Debatte über ihre Ratifizierung geschrieben wurden, von großer Bedeutung. Festzustellen, wer der tatsächliche Verfasser eines kleinen Teils davon war, bei dem nur das Pseudonym, nicht der wirkliche Autor bekannt war, galt lange Zeit als eine der spannenderen Fragen der amerikanischen Verfassungsgeschichte – nicht so sehr, weil daran die Interpretation der Verfassung gehangen hätte, wohl aber, weil sich hier an einem Detailproblem zeigen lässt, was die Kritik historischer Texte herausfinden kann und was nicht.

Schon 1940/1941, in etwa zu der Zeit, als Padre Busa seine Karteikarten füllte, beschäftigte sich der amerikanische Statistiker Frederick Mosteller, zusammen mit Frederick Williams mit der Frage, ob man das beschriebene Rätsel durch Wahrscheinlichkeitstheoretische Ansätze klären könne. Ein Ansatz, der damals abgebrochen, nach der Verfügbarkeit der ersten Rechnergenerationen jedoch von Frederick Mosteller, nunmehr zusammen mit David L. Wallace, zu einer Untersuchung ausgebaut wurde, die 1964 als *Inference and Disputed Authorship: Federalist Papers* erschien und gemeinhin als Ausgangspunkt der rechnergestützten Beschäftigung mit Fragen des Stils und der Verfasserschaft gilt, die sich ebenfalls auf **nicht bewusste Spracheigentümlichkeiten**, Funktionswörter, stützt und womit sich die Verbindung zu Roberto Busa schließt. Beziehungsweise zur Erscheinung, dass arbeitstechnische Erleichterungen die Anwendung neuer methodischer Herangehensweisen ermöglichen.

Wir haben hier also Beispiele dafür, wie die neuen Technologien Vorgehensweisen erlaubten, die schon früher erwogen worden waren, aber als zu aufwändig nicht umgesetzt werden konnten. Wobei es Versuche, allgemeine Einschätzungen durch die penible Untersuchung für sich gesehen trivial wirkender Details zu untermauern auch in anderen Disziplinen schon früher gab – ein Beispiel dafür bilden die Versuche des Kunsthistorikers Giovanni Morelli im 19. Jahrhundert, allgemeine stilistische Aussagen durch den peniblen Vergleich des Umgangs mit häufig wiederkehrenden, etwa anatomischen, Details in Bildern zu untermauern. Dementsprechend wäre es auch falsch zu glauben, dass die Beschäftigung mit der neuen Rechnertechnologie in den Geisteswissenschaften sich ausschließlich auf die Untersuchung sprachlicher Phänomene bezogen hätte: In der wohl ersten internationalen von Dell Hymes organisierten Konferenz des entstehenden Forschungsfeldes 1962 auf der Burg Wartenstein, mit dem erst 1965 erscheinenden Konferenzband *The Use of Computers in Anthropology*, war bereits die ganze Bandbreite der geisteswissenschaftlichen Disziplinen vertreten, wobei sich die Anwendungen zwischen der Nutzung statistischer Herangehensweisen und dem analytischen Herangehen an Texte in etwa gleich verteilen.

1.2 | Eine Community entsteht: Die frühen Jahre

Trotz dieses Bandes ist nicht wirklich klar, welche Konsequenzen die Verfügbarkeit der Rechnertechnologie – aufbauend auf Busas Beispiel, aber auch häufig in Unkenntnis dessen –, in den 1950er Jahren in den Geisteswissenschaften insgesamt hatte. Knapp nach der Konferenz von 1962 wurden jedoch die Vortragsbände mehrerer einschlägiger Konferenzen sichtbar, die eine erstaunlich stark entwickelte Forschungsszene zeigen: Es gab zahlreiche Konkordanzprojekte und auch erste Zentren für die systematische Anwendung der elektronischen Technik, etwa in Cambridge, wo Roy Wisbey 1964 ein *Linguistic Computing Centre* gründete, das sich seinen eigenen Forschungsinteressen entsprechend überwiegend dem Mittelhochdeutschen widmete. In der Archäologie gab es große, auf sehr intensive statistische Analysen ausgerichtete Fachkongresse. Sobald das Bild klarer wird, zeigte es bereits eine erstaunliche Vielfalt, eine Community von Forschern, die einander auf den Konferenzen dieser ersten Welle aber wohl überwiegend überrascht darüber begegneten, wie reich die Szene schon war.

Diese Überraschung ist nicht ganz unbegründet: Nicht nur musste selbst die Unterscheidung zwischen Groß- und Kleinbuchstaben auf Lochkarten mit ziemlichem Aufwand dargestellt werden; ein wesentliches Problem wird klar, wenn wir die Einleitung des Herausgebers der Tagung von 1962 lesen: Nachdem moderne **Macroassembler** jetzt den Zugriff auf den Maschinencode unnötig gemacht hätten, sei ein Benutzerkomfort bei der Programmierung erreicht, der die zusätzlichen Vereinfachungen durch Höhere Programmiersprachen nicht mehr unbedingt erforderlich mache. Was damals nicht ganz so obskur erschien wie heute, das Problem fehlender *rechnerferner* Software jedoch sehr gut indirekt beschreibt.

Die weitere Entwicklung war durch zwei wichtige Schritte gekennzeichnet: Einerseits organisierte sich die wissenschaftliche Community der Geisteswissenschaftler, die die Informationstechnologie nutzten, selbst, so dass der Informationsaustausch vereinfacht wurde. Seit 1966 erschien, lange Jahre als zentrales Informationsmedium des Faches, unter der Herausgeberschaft von Joseph Raben die Zeitschrift ***Computers and the Humanities*** (CHum), deren Bedeutung, später, als sie in kommerzielle Hände gefallen war, und seit 2005 als *Language Resources and Evaluation* erschien, freilich stark abgenommen hat. Damals war sie jedoch ein zentrales Medium, das andererseits maßgeblich mitgeholfen hat, **Fachgesellschaften** ins Leben zu rufen (In Europa seit 1973 die »Association for Literary and Linguistic Computing«, etwas später, 1978, die amerikanische »Association for Computers and the Humanities«).

Durch diese Verbände entstanden auf der Basis jährlicher Konferenzen Foren, in denen die einzelnen – wie wir ja gesehen haben, sehr zahlreichen – Ansätze verglichen werden konnten, was die Möglichkeit zur Entwicklung gemeinsamer Ansätze, über die Nützlichkeitsabwägungen eines einzelnen Projekts hinaus bot. Bei ähnlichen **Konferenzserien**, wie der ebenfalls 1973 ins Leben gerufenen und ungemein einflussreichen »Computer Applications and Quantitative Methods in Archaeology« (CAA), wird der tragende Verein hinter der Konferenzserie als solcher gar nicht sichtbar. Und diese Verbände fungieren auch als Träger von **Zeitschriften**, die die Gemeinsamkeiten des Umgangs mit informationstechnischen Methoden, jenseits der Spezifika des jeweiligen disziplinären Kontexts, schärfer zeigen, als dies in den Kontexten anderer Publikationen möglich wäre: So die Zeitschrift *Literary and Linguistic*

Computing seit 1973 (seit 2015 fortgeführt als *Digital Scholarship in the Humanities*) oder die reine Internetzeitschrift *Digital Humanities Quarterly*, seit 2007 unter <http://www.digitalhumanities.org/dhq/> erreichbar und unter der Ägide der Alliance of Digital Humanities Organization (ADHO) erscheinend, die sich bemüht, die Tätigkeit der älteren Verbände zu bündeln.

1.3 | Die Welt wird einfacher – Programmpakete

Dieser kurze Vorgriff auf die Gegenwart darf freilich keinesfalls den Blick auf die andere, noch entscheidendere Entwicklung im Umgang von Geisteswissenschaftler mit der Informationstechnik in den späten 1960er und frühen 70er Jahren verstellen: Die Verfügbarkeit von **Programmpaketen**, die den Zugang auf bestimmte technische Verfahren, als Implementation bestimmter methodischer Ansätze, entscheidend vereinfachte. Aus den Bemühungen von Wilhelm Ott in Tübingen, zunächst Assemblerfunktionen bereitzustellen, die den Umgang mit Texten in der Programmierung erleichtern sollten, entstand »TU-STEP«, das für die Umsetzung gedruckter Editionen auf dem Rechner den entscheidenden Schritt von der Formulierung von Auswertungswünschen in einer auf das technologische Werkzeug ausgerichteten höheren Programmiersprache in eine an den Auswertungswünschen orientierte Scriptsprache bedeutete. Wobei die Tatsache, dass neben der Vorbereitung der Edition für den Druck auch zahlreiche vorbereitende technische Dienste und Analysemöglichkeiten zugänglich wurden, von höchster Bedeutung war.

In anderen Fällen war der Unterschied in der Komplexität der Programmierung in einer Programmiersprache und der in der Kommandosprache eines Programmpaketes noch drastischer: Anspruchsvolle statistische Analysen durchzuführen, setzte zunächst erhebliche mathematische und Programmierkenntnisse voraus. Mit der Verfügbarkeit statistischer Anwendungssoftware, wie dem »Statistical Package for the Social Sciences« (seit 1968), wurde es möglich, komplexe statistische Berechnungen durchzuführen, ohne die Verfahren zu verstehen, was die Anzahl **quantitativer Untersuchungen** in den frühen 1970er Jahren, quer durch alle Disziplinen der Geisteswissenschaften, buchstäblich explodieren ließ. Das Wort Emmanuel le Roy Laduries, eines der prominentesten französischen Historiker des vorigen Jahrhunderts »dans ce domaine au moins, l'historien de demain sera programmeur ou il ne sera plus« (*Le Nouvel Observateur*, 8 mai 1968) greift hier nur voraus. Freilich: Das Geschenk der Anwendbarkeit von Verfahren, die man nicht verstehen musste, war auch gefährlich und manche der frühen quantitativen Analysen enthalten unerfreuliche Kunstfehler.

Diese zu vermeiden, war bei den Programmpaketen einfacher, die direkt aus der entstehenden Community, welche sich aus Geisteswissenschaftlern zusammensetzte, die Rechner verwendeten, abstammen – das »Oxford Concordance Program« (OCP), die »Text Analysis Computing Tools« (TACT) oder »WordCruncher« versuchten, die aus der Busa'schen Tradition entstandenen Konkordanzansätze ohne die Notwendigkeit eigener Programmierarbeiten zu unterstützen, freilich meist in gewisser Hinsicht »trivialisieren«. Während ein wesentlicher Bestandteil der Thomaskonkordanz ein aufwändiges Verfahren war, die Wortformen – *facio*, *fecit*, *factum*, ... – auf Wortstämme oder Lemmata – *facere* oder *fac* – zurückzuführen, damit man nicht von nicht bedachten Flexionsproblemen in die Irre geführt werde, hat sich die große Mehrzahl im weitesten Sinne konkordanzorientierter Projekte hier meist wesentlich bescheidener gegeben. In der Tat kam es in den 1970er und 80er Jahren auch zu ei-

ner deutlichen Trennung zwischen dem Computereinsatz in den Sprachwissenschaften und allen anderen Geisteswissenschaften, einschließlich der literaturwissenschaftlichen Disziplinen: In der Sprachwissenschaft etablierte sich mit der **Computerlinguistik** eine gut definierte akademische Disziplin, für die der Umgang mit morphologischen und grammatikalischen Fragen zentral war, während die Abgrenzung zwischen Computeranwendern und nicht -anwendern unter den Wissenschaftlern in allen anderen Disziplinen sehr viel fließender war.

In der Tat sollte nie übersehen werden, dass die große Mehrzahl der Geisteswissenschaftler, die die neuen technischen Möglichkeiten einsetzten, dies **rein pragmatisch** getan haben: Sie haben sie als Werkzeuge verwendet, die den Zeitaufwand für die Bewältigung von Routineaufgaben signifikant verringern. Dementsprechend war auch der Boom der **quantitativen Verfahren** in den 1970er Jahren nicht so sehr vom Wunsch geprägt, methodisch innovativ zu sein, als vielmehr davon, sich in einer schwer überschaubaren Zahl von Quellenbelegen zu orientieren. Als dies durch die leichtere Verfügbarkeit von Datenbanken in den 1980er Jahren *ohne* statistische Kodierungen möglich war, da nunmehr relativ leicht zugängliche **Datenbanksysteme** zur Verfügung standen, ebnete die Begeisterung für quantitative Anwendungen rasch ab. Wie gewichtig dieser neue Trend war, lässt sich am deutlichsten dadurch belegen, dass Joseph Raben, den wir schon als Pionier kennengelernt haben, sich in den 1980er Jahren aus den Vorläufern der Digital Humanities weitgehend zurück zog und einige Jahre als Organisator einer eigenen Konferenzreihe »Databases in the Humanities and the Social Sciences« wirkte, die damals deutlich mehr Teilnehmer anzog, als die etablierten traditionellen Konferenzserien.

1.4 | Die Welt wird noch einfacher – der Personal Computer

Vereinfacht kann man sagen, dass sich damals die Vorläufer der heutigen Digital Humanities als jene Gruppe bildeten, die darauf bestanden, dass der Einsatz der jetzt leichter zugänglichen Technologien nicht nur auf den eines reinen Werkzeuges hinauslaufen sollte, sondern auch **methodische Weiterungen** und Überlegungen nach sich ziehen könne. Dieses Phänomen verschärfte sich durch den nächsten technologischen Durchbruch: Während bis Mitte der 1980er Jahre »Rechnereinsatz« den Zugang zu einem Großrechner erforderte, also oftmals logistisch gut geplante Ausflüge in ein oft universitäres Neubaugebiet ausgelagertes Rechenzentrum, holte der Personal Computer die Rechnerleistung plötzlich auf den Schreibtisch – zusammen mit aus heutiger Sicht bescheidenen, damals aber völlig neuen graphischen Möglichkeiten. Zunächst trennte das die »methodisch bewusst« arbeitenden Forscher eher von den zahlreichen gelegentlichen Anwendern. Die Verarbeitung von Texten – im Sinne der heutigen Textverarbeitung – war lange Zeit ein Spezialgebiet des Rechnereinsatzes in den Geisteswissenschaften, das sich mit den Verbindungen von aus wissenschaftlichen Ansprüchen her maschinenlesbar gemachten Texten zu **elektronischen Satzsystemen** beschäftigte. Als Spezialgebiet kollabierte dieser Bereich innerhalb kurzer Zeit: »Microsoft Word« sowie seine Vorläufer und verdrängten Konkurrenten verwandelten vergleichsweise arkanes Wissen über die Produktion von Texten in eine allgemeine Kulturtechnik.

Was nun selbstverständlich nicht heißen soll, dass die PC-Revolution der Verwendung der Rechner in den methodenbewussteren Teilen der Geisteswissenschaft-

ten geschadet hätte. Abgesehen davon, dass es für weite Bereiche der Geisteswissenschaften damit möglich wurde, technische Werkzeuge einzusetzen, ohne weiter darüber nachzudenken, abgesehen auch davon, dass natürlich die bisherigen Ansätze zur Erschließung von Texten oder zur quantitativen Analyse nochmals sehr viel einfacher einsetzbar wurden, als durch die Entstehung darauf spezialisierter Programmpakete, eröffneten sich völlig neue Möglichkeiten. Wie bereits erwähnt war die Vorbereitung komplexer Druckbilder lange Zeit ein Spezialgebiet, das hohen Stellenwert genoss. Dies gilt ganz besonders für den Bereich der **kritischen Editionen**, die anstreben, Texte in einer Form zugänglich zu machen, die schwierige Überlieferungssituationen in mehreren getrennten Manuskripten (›Textzeugen‹) verständlich macht und gleichzeitig einen authentischen Text bereitstellt. Meist mit mehreren Anmerkungsapparaten versehen, war der Druck dieser Werke immer extrem kostspielig und die erwähnte Tradition der elektronischen Erstellung des Drucksatzes versuchte weiterhin zu ermöglichen, was anders nicht mehr finanzierbar gewesen wäre.

Soweit ging es jedoch nur um eine Beibehaltung des Erreichten. Mit der Verbreitung der Personal Computer ging die Entwicklung des Konzepts digitaler oder **dynamischer Editionen** einher, die nicht mehr den Druck, sondern den Bildschirm des Rechners als Medium für die Darstellung des Textes ansehen.

Ansätze dazu gibt es seit der Frühzeit der PCs, und zwischen 1985 und den späteren 1990er Jahren entstand mit den Arbeiten – neben vielen anderen – von Peter Robinson (vor allem: *Canterbury Tales*), Kevin Kiernan (*Electronic Beowulf*), Claus Huitfeldt (Wittgenstein Nachlass), Paolo D'Iorio (*Hypernietzsche*), Friedbert Aspetsberger (Musil Nachlass) und Walter Morgenthaler (Gottfried Keller) eine Tradition CD-basierter digitaler Editionen, die als einen inoffiziellen de facto-Standard etwa Folgendes erwartet: Ein Text kann wahlweise mindestens als (a) buchstabengeheure Transkription, mit Darstellung von Streichungen, Varianten etc. und (b) als geglätteter Lesetext so dargestellt werden, dass zu jeder Textstelle das dazugehörige Manuskript einsehbar ist bzw. die dazugehörigen Manuskripte einsehbar sind und der Text von einem ausführlichen Kommentar begleitet wird.

Natürlich gilt auch hier, dass nicht alle geisteswissenschaftlichen Projekte zwischen 1985 und der Jahrtausendwende digitale Editionen waren, genauso, wie nicht alle Projekte der 1970er Jahre mit quantitativen Verfahren und nicht alle Projekte der frühen 1980er Jahre mit Datenbanken gearbeitet haben. Sie sind aber besonders typisch für die Optionen, die sich durch die Nutzung der neuen technischen Möglichkeiten ergaben. Die digitalen Editionen beschreiben daher vielleicht am besten, was die wesentlichen Auswirkungen der PC-Technologie waren: Die Rechenleistung war unmittelbar am Arbeitsplatz verfügbar, und sie konnte auch für die Darstellung von Ergebnissen, nicht nur für die analytische Erzeugung dieser Ergebnisse, verwendet werden. In vielen Fällen führte dies dazu, dass wohlbekannte ›Produkte‹ der rechnergestützten Geisteswissenschaften ihr Gesicht völlig wandelten: Die Konkordanz, mit der wir diese Geschichte von Begegnungen der Geisteswissenschaften mit der Informationstechnik begannen, existiert so nicht mehr. Freilich ist die abstrakte Aufgabe »untersuche alle Kontexte, in denen in einer Gruppe von Texten eine bestimmte Wortform vorkommt« alles andere als erledigt: Sie wird seit dem Ende des vorigen Jahrhunderts aber nicht mehr im Druck, sondern dynamisch erledigt. Sie wird nicht als vollständiges Verzeichnis aller möglichen Fundstellen im Druck eingefroren, sondern als Softwarepaket mit einem bestimmten Leistungsspektrum zusammen mit den dazu benötigten Daten ausgeliefert.

Darüber hinaus hat die Möglichkeit, den Rechner auch als **graphisches Präsentationsmedium** zu nutzen, natürlich ganze Anwendungsfamilien geschaffen: Die systematische Erfassung und Publikation kunsthistorischer Objekte in bildlicher Form auf CDs nahm an der Schwelle der 1980er zu den 1990er Jahren ihren Anfang. Die Vorstellung, PCs könnten als Lehrmittel eingesetzt werden, oft auf der Basis von **Lehrprogrammen**, die dieses Konzept der Kombination von softwaretechnischen Möglichkeiten mit einem darauf abgestellten, gerne auch multimedialen, Datenpaket für didaktische Zwecke einsetzen sollten, tat dies ebenso.

Um zu verstehen, wie sich daraus der nächste Schritt ergab, müssen wir zunächst noch einmal einen zurückgehen. Eine der größten Schwierigkeiten der frühen Stadien des Rechnereinsatzes in den Geisteswissenschaften war immer die Erzeugung der vom Rechner zu verarbeitenden Daten. In nicht ganz wenigen Fällen wiederholte sich in den frühen Jahren die Situation, dass nach mehrjähriger mit großer Hingabe durchgeführter **Dateneingabe** die Daten für die Analyse ungefähr zu dem Zeitpunkt abgeschlossen vorlagen, zu dem auch die Finanzierung des Projekts endete. Dies besserte sich über die Zeit hinweg – an der Tastatur eines PCs einen Text abzutippen, braucht einen Bruchteil des Aufwandes, der benötigt wird, um ihn unter Kodierung aller Großbuchstaben, nationalen Sonderzeichen und sonstiger Besonderheiten (z. B. Längenbezeichnung der Vokale in mittelhochdeutschen Texten) auf Lochkarten zu übertragen.

So erfreulich dies ist, ändert es aber zunächst nichts an der Tatsache, dass manche Textmerkmale gekennzeichnet werden müssen: Stellt ein Wort einen Personennamen oder eine topographische Bezeichnung dar? So lange dies von jedem Wissenschaftler ausschließlich für die Zwecke der eigenen Studie gelöst wird, bleiben die Daten nur für diese Studie nutzbar. Wenn wir aber, nach dem oben Gesagten, davon ausgehen, dass Geisteswissenschaftler, die informationstechnische Möglichkeiten nutzen, nicht mehr nur die einmal gedruckten analytischen Ergebnisse als ihr ›Produkt‹ verstehen, sondern die Verbindung aus programmtechnischen Möglichkeiten und dafür passendem ›Corpus‹ als wesentlich ansehen, liegt es ungemein nahe, danach zu suchen, wie man die Daten so vorbereiten kann, dass sie auch für andere Softwareanwendungen genutzt werden können. Und noch viel näher liegt die Idee, dass es nützlich sein könnte, eine bestimmte analytische Idee an bereits vorliegenden Daten auszuprobieren, bevor man selbst mehrere Jahre in die Dateneingabe investiert. Von der Möglichkeit, mit Hilfe der »Optical Character Recognition« (OCR) diese Dateneingabe massiv zu beschleunigen, bzw. den Umfang des analysierbaren Corpus massiv zu vergrößern, ganz abgesehen.

1.5 | Vernetzungen von Personen und Ressourcen

Ebenfalls Mitte der 1980er Jahre wandelte sich die Vorstellung von den Informationstechnologien (IT) schließlich in die der »Informations- und Communicationstechnologien« (ICT) – anders ausgedrückt, mit Verbreitung der E-Mail etablierte sich der Rechner als **Kommunikationsgerät**, was für die Community der informationstechnisch arbeitenden Geisteswissenschaftler die Frage löste, wie man zwischen den Jahreskonferenzen den Kontakt aufrechterhalten könne, was zur Etablierung mehrerer Fachforen führte, von denen die Mailingliste »Humanist«, ins Leben gerufen und betrieben von Willard McCarty seit 1987, am wichtigsten war und wohl auch immer noch ist.

Ungefähr zeitgleich mit der Verbreitung der Personal Computer ergab sich also der Wunsch, Daten soweit als möglich so aufzubereiten, dass sie wiederverwertbar und von den unmittelbar anstehenden analytischen Plänen, vor allem aber von den Anforderungen eines spezifischen zunächst ins Auge gefassten Softwaresystems, unabhängig werden sollten. Parallel dazu entstanden Möglichkeiten wesentlich engerer kommunikativer Vernetzung mit den Kollegen. Daraus entwickelte sich das Konzept einer gemeinsamen Anstrengung der Community zur Verbesserung der Fähigkeiten, Daten auszutauschen und für möglichst viele Softwarelösungen verarbeitbar zu machen. Die **Text Encoding Initiative** entstand als Antwort auf diesen Wunsch im Spätherbst 1987 (s. Kap. 17.7 und 18.5). Für die weitere Entwicklung des damals generell als Humanities' Computing bezeichneten Feldes ist hauptsächlich wichtig, dass sie aus dem Verständnis entsprang, dass es projektübergreifende Herausforderungen von geisteswissenschaftlichen Projekten gibt, die die Informationstechnik nutzen und von den disziplinären Fragestellungen einzelner Vorhaben unabhängig sind, d. h. durch Anstrengungen unterstützt werden sollten, die ebenfalls die Einzeldisziplinen übergreifen.

Wir haben schon gesagt, dass die digitalen Editionen ein besonders gutes Beispiel für die neuen Möglichkeiten der Informationstechnologie mit Ausbreitung der PC Technologie darstellen und dass es knapp vor der Jahrtausendwende ein informelles, aber in sich konsistentes, Paradigma gab, wie man derartige Editionen gestalten sollte. Nichtsdestoweniger haben gerade Pioniere, wie Peter Robinson, Mitte der 2010er Jahre ein vergleichsweise deprimierendes Bild dieses Ansatzes geboten. Hierfür ist ein der damaligen Vorgehensweise geschuldetes Problem verantwortlich: Gedruckte Editionen haben zahlreiche dem statischen Medium **inhärente Beschränkungen**. Kann man eine davon verwenden und hat verstanden, was ein gedruckter kritischer Apparat ist, kann man aber alle lesen und alle Apparate gleichermaßen ignorieren. Eine PC-gestützte, auf einer CD-ROM ausgelieferte Edition setzt jedoch voraus, dass man die für diese eine spezielle Edition benötigte Software installiert und zu benutzen lernt. Was sich bei der nächsten PC-gestützten, auf einer CD-ROM ausgelieferten Edition wiederholt, da sich weder die Software noch das realisierte Userinterface ähneln.

1.6 | Das WWW als einheitliches Interface

Dies änderte sich dadurch, dass sich mit der Verbreitung des WWW eine völlig neue **Umwelt für die Benutzung der Informationstechnologie** in den Geisteswissenschaften ergab. Das Interesse der bereits beschriebenen Mehrheit der Geisteswissenschaftler, die die methodischen Implikationen der technischen Verfahren nie wirklich interessiert hatten, wandten sich dem neuen Medium zu. Diejenigen, die an den Verfahren grundsätzliches Interesse zeigten, waren dagegen nach wie vor an den eigentlichen Forschungsfragen zugewandt. Das spiegelt sich deutlich darin wieder, dass das fachliche Interesse an den Jahrestagungen der Fachverbände zwischen 1995 und 2005 zeitweise sehr gering war, während zwischen 1996 und 2005 eine Tagungsserie mit dem Titel »Digital Resources for the Humanities« in Großbritannien erhebliches Aufsehen einer sehr viel weiteren Fachöffentlichkeit erregte. Einer Fachöffentlichkeit, die darunter wohl implizit die Frage verstand, was das WWW für die Geisteswissenschaftler tun könne.

Die offizielle Begründung für diese neue Konferenzserie las sich natürlich etwas

anders: »The over-arching rationale for creating DRH was a perceived need for a broader, inclusive treatment of the creation and use of digital resources within the humanities« (<http://www.ahds.ac.uk/news/newsletters/spring-2005/spring-2005-newsletter.pdf>). Mit anderen Worten: Die in der traditionellen interdisziplinären Community als Nebeneffekt entwickelte, in der TEI ausgedrückte Vorstellung, dass es notwendig sei, projektübergreifende Ressourcen anzubieten, schob sich durch die Entstehung einer inhaltsneutralen Informationsinfrastruktur, eben dem WWW, soweit in den Vordergrund, dass die Frage der analytischen Nutzung plötzlich sekundär zu sein schien, was neue Strukturen erfordere. Eine Entwicklung, die noch dadurch verstärkt wurde, dass die Gedächtniseinrichtungen – **Archive, Bibliotheken, Museen** – die innerhalb der geisteswissenschaftlichen Auseinandersetzung mit den informationstechnologischen Möglichkeiten bisher eine sehr marginale Rolle gespielt hatten, als Herrscher über die zu digitalisierenden Bestände der **kulturellen Überlieferung** plötzlich sehr zentral wurden.

Der Namenswechsel vom traditionellen »Humanities Computing« zu den »Digital Humanities«, die mit dem Compendium von Schreibman, Siemens und Unsworth(2004) ins Leben traten, spiegelt letzten Endes hauptsächlich den Versuch wieder, zwei Stränge zu versöhnen: Die analytischen Traditionen, die aus den Disziplinen der Geisteswissenschaften herrühren, und versucht haben, ausgehend von einzelnen Projekten zu gemeinsamen Konzepten zu gelangen und die Vorstellung, das WWW erfordere Ansätze zur Bereitstellung von Ressourcen, die die analytische Arbeit durch andere erst ermöglichen sollten.

Zehn Jahre später können wir konstatieren, dass der Versuch eindeutig gelungen zu sein scheint: Die analytischen Traditionen des Umgangs mit Texten auf philologischer Basis, der statistischen Untersuchung geisteswissenschaftlicher Sachverhalte und vieler anderer, hier nur gestreifter, oder überhaupt nicht angesprochener, sind mittlerweile in die Diskussion um die dazu nötigen **Infrastrukturen** eng eingebunden. Was sich vielleicht am besten dadurch illustrieren lässt, dass das Paradigma digitaler Editionen, essentiell funktional vollständig vor fünfzehn Jahren und danach anscheinend gescheitert, in den letzten fünf Jahren zu einer rasant steigenden Zahl derartiger Editionen im Internet geführt hat – in einem Medium, in dem die Unterschiede zwischen den einzelnen Editionen (fast) so belanglos werden, wie zuvor im Druck.

1.7 | Das Beste kommt erst noch

Die Geschichte endet nicht im Jahr 2016. Auch nicht die der Digital Humanities. Zu glauben, dass die Informationstechnologie keine weitere Entwicklung haben wird, ist, wie alles Naive, amüsant. Aber auch die neuen, heute noch nicht absehbaren Entwicklungen werden daraufhin untersucht werden müssen, wieweit sie geeignet sind, »als Werkzeuge den Zeitaufwand für die Bewältigung von Routineaufgaben signifikant verringern können« und wieweit sie »einen methodisch völlig neuen Zugang ermöglichen«. Dies zu untersuchen, bleibt die Aufgabe der Digital Humanities – ganz unabhängig davon, wie sie im Jahr 2066 heißen mögen.

Literatur

- Anderson, Ian: »History and computing« (2008), http://www.history.ac.uk/makinghistory/resources/articles/history_and_computing.html (26.4.2016).
- Busa, Roberto/Jones, Steven E.: »The Annals of Humanities Computing: the Index Thomisticus«. In: *Computers and the Humanities* 14 (1980), 83–90.
- Laflin, Susan: »Computer Applications in Archaeology 1973–1995« (2014), <https://www.lulu.com/> (10.6.2016).
- McGann, Jerome: *Radiant Textuality: Literature after the World Wide Web*. Houndmills 2001.
- Schreibman, Susan/Siemens, Ray/Unsworth, John (Hg.): *A Companion to Digital Humanities*. Oxford 2004.
- Terras, Melissa/Nyhan, Julianne/Vanhoutte, Edward: *Defining Digital Humanities*. Farnham 2013.
- Winter, Thomas Nelson: »Roberto Busa, S. J., and the Invention of the Machine-Generated Concordance« (1999), <http://digitalcommons.unl.edu/classicsfacpub/70> (26.4.2016).
- Zweig, Benjamin: »Forgotten Genealogies: Brief Reflections on the History of Digital Art History«. In: *International Journal of Digital Art History* 1 (2015), <http://nbn-resolving.de/urn:nbn:de:bsz:16-dah-216330> (26.4.2016).

Manfred Thaller

2 Digital Humanities als Wissenschaft

2.1 | Die Digital Humanities: Ein weites Feld

Verstehen wir die **Digital Humanities als die Summe aller Versuche, die Informationstechniken auf den Gegenstandsbereich der Geisteswissenschaften anzuwenden**, ergibt sich ein ungemein breites Bild (ohne Anspruch auf Vollständigkeit):

- Viele Anwendungen beschäftigen sich mit **Text** als solchem. Dies kann sich auf, meist den Literaturwissenschaften dienende, Fragen nach der Entwicklung des Wortschatzes einzelner Verfasser beziehen, im Bereich der Editionsphilologie auf die beste Art, verwirrend überlieferte Texte zu rekonstruieren oder auf die Untersuchung sprachlicher Eigenschaften im Sinne der Linguistik.
- Eine andere, große Gruppe von Projekten beschäftigt sich mit der Handhabung nicht-textueller Medien: Von Bildern, Plastiken oder Gebäudemodellen für die Kunstgeschichte und Archäologie, von Klängen und Notensätzen zum besseren Verständnis musikalischer Entwicklungen, oder von Filmen zur Beantwortung medienwissenschaftlicher Fragestellungen.
- Wichtig, vor allem in den historischen Disziplinen, sind ferner Anwendungen, die Texte und Bilder nicht um ihrer selbst willen, sondern als Quellen von Belegen für historische Entwicklungen verwenden, sei es als Inhalte von Datenbanken, sei es als Ausgangspunkt der Untersuchung geographischer Verteilungen im Rahmen geographischer Informationssysteme.
- Schließlich gibt es Projekte, die die neuen Technologien selbst zum Gegenstand machen: Sei es in der Analyse der Auswirkungen moderner Medien auf unser Gesellschaft, sei es zum grundsätzlichen Studium der für die Geisteswissenschaften gebotenen methodischen Möglichkeiten – bis hin zur Frage, wie geisteswissenschaftliche Forschung durch Techniken der Künstlichen Intelligenz stimuliert werden kann.

2.2 | Die Digital Humanities: Werkzeug oder Methode?

Trotz dieser Breite des Forschungsfeldes gibt es Gemeinsamkeiten der Spielarten der Digital Humanities. Schon Padre Busa, mit dem die Geschichte der Anwendungen der Informationstechnik in den Geisteswissenschaften üblicherweise eröffnet wird (s. Kap. 1), war zunächst aus Gründen der Arbeitsökonomie an den neuen Technologien interessiert. Er wird aber gleichzeitig von vielen Forschern auch als einer der Begründer der Computerlinguistik gesehen, also einer Form der Linguistik, die sich von deren anderen Ausprägungen nicht nur durch ihre **Arbeitstechniken und Werkzeuge**, sondern auch durch ihre **Fragestellungen und Methoden** unterscheidet. Dieser Gegensatz kann auch als Frage formuliert werden: **Wenn Geisteswissenschaftler die Informationstechnologie einsetzen, tun sie das, um dieselben Ergebnisse, die sie auch ohne diese Technologie erreicht hätten, schneller und effektiver zu erreichen – oder streben sie Ergebnisse an, die ohne sie nicht erreichbar gewesen wären? Wenn Ergebnisse angestrebt werden, die ohne Informationstechnologie nicht erzielt werden können: Sind diese dann ›besser‹ als die in den Disziplinen auf traditionelle Weise erzielten?**

Die erste Schwierigkeit, möchte man diese Frage beantworten, ergibt sich, sobald

man die auf den ersten Blick plausible Unterscheidung zwischen Werkzeugen und Methoden zu präzisieren versucht. Durchsucht man mit technischen Mitteln einen Text von tausend Seiten nach dem Kontext, innerhalb dessen ein Wort verwendet wird, erledigt man dies etwas schneller, als es menschlichen Forschern, die dies mit dem die Zeile entlanglaufenden Bleistift ohne technische Unterstützung tun, möglich wäre. Tut man dasselbe informationstechnisch unterstützt in einer der großen digitalen Textsammlungen, die tausende Bände enthalten, erhält man Ergebnisse, die ohne diese Unterstützung nicht erzielt werden könnten. Dadurch werden Fragestellungen möglich, die ohne das Werkzeug nicht aufkommen können – die aber in weiterer Folge auch neue **methodische Überlegungen** erfordern können.

Das beantwortet natürlich *nicht* die Frage, ob Geisteswissenschaftler sich mit Problemen beschäftigen *sollen*, die nur beantwortet werden können, wenn man tausende von Seiten durchsucht. Man kann auch der Ansicht sein, dass sich die Geisteswissenschaften ganz bewusst auf Fragestellungen konzentrieren sollen, die innerhalb eines kleinen Bestandes an herausragenden Texten – beispielsweise denen einzelner Verfasser – beantwortet werden können. Die Gegenpositionen sind etwa folgende: Der Auffassung, dass die Geisteswissenschaft lehren soll, die gedanklichen (und zuvor: sprachlichen) Strukturen einzelner Verfasser möglichst detailliert zu schätzen und zu verstehen, kann eine andere gegenüberstehen, die betont, dass es wichtig sei, dieselben Strukturen innerhalb des gedanklichen (und zuvor: sprachlichen) Kontexts des Jahrhunderts der jeweiligen Verfasser zu verstehen. Und daraus kann schließlich die Vorstellung erwachsen, dass eigentlich das Verständnis der aus dem sprachlichen Befund ableitbaren gedanklichen Strukturen einer Epoche wichtiger sei, als die einzelner Verfasser.

2.3 | Die Digital Humanities im Kontext der geisteswissenschaftlichen Disziplinen

Die Entscheidung, welche dieser drei Fragestellungen – Verständnis einzelner Verfasser, Verständnis des Verhältnisses einzelner Verfasser zu den intellektuellen Kontexten, in denen sie lebten, Verständnis dieser intellektuellen Kontexte – am wichtigsten sei, ist selbstverständlich eine, die nicht aus den Digital Humanities allgemein hergeleitet werden kann, sondern aus denen der inhaltlichen Disziplinen abgeleitet werden muss. Welche Werkzeuge der Informationstechnologie für welche geisteswissenschaftlichen Fächer besonders angemessen sind, hängt ganz wesentlich vom **Selbstverständnis des jeweiligen Faches** ab. So gab es in den 1960er und 1970er Jahren starke Strömungen in den Geisteswissenschaften, Fragestellungen und Methoden der Sozialwissenschaften aufzugreifen. Ganz besonders in den Geschichtswissenschaften, aber auch in der ganzen Breite der geisteswissenschaftlichen Fächer führte das zu einem großen Interesse an quantitativ/statistischen Verfahren beziehungsweise an der Nutzung von Datenbanken. Die Nutzung beider Techniken ging zurück, als das interdisziplinäre Interesse an sozialwissenschaftlichen Ansätzen und damit mittelbar an deren empirischen Vorgehensweisen wieder abnahm.

Das gilt ganz explizit nicht nur den Arbeitstechniken, sondern auch den methodischen Annahmen, die ihre Anwendung erfordern oder mindestens plausibel machen. **In erster Linie ist hier die Einstellung gegenüber dem Verhältnis zwischen den Geistes- und den Naturwissenschaften zu verstehen. Im Deutschen – und der deutschen akademischen Community – besteht überwiegend die Vorstellung, dass**

es eine Vorstellung von Rationalität gäbe, die allen ›Wissenschaften‹ gemein sei. Auch wenn es, nach Forschern wie Wilhelm Dilthey, fundamentale, methodische Unterschiede gibt, sind Geistes- und Naturwissenschaften deshalb trotzdem nicht wesensfremd. Im Englischen gibt es das Konzept ›Wissenschaft‹ als übergeordneten Begriff, der das Gegensatzpaar ›Science‹ und ›Humanities‹ vereint, nicht; daraus entsteht dann leicht die Vorstellung, dass es zwischen Naturwissenschaften und Geisteswissenschaften keine Berührungspunkte gäbe, ja, dass die Geisteswissenschaften der Kunst sehr viel näher stünden als der ›Wissenschaft‹.

Unabhängig von dieser Frage, derer man sich beim Lesen englischsprachiger Literatur zu den Methoden der Digital Humanities stets bewusst sein sollte, hängt die Einstellung zu methodischen Folgen aus der Anwendung informationstechnischer Werkzeuge ganz besonders davon ab, welche Position Forscher in der Frage haben, was eine **angemessene Beweisführung** in ihrer geisteswissenschaftlichen Disziplin sei. Wird mit Paul Feyerabend überhaupt verneint, dass es so etwas wie eine verbindliche Methode geben könne, so beschränkt sich die Relevanz der Digital Humanities darauf, Werkzeuge für den Umgang mit Dokumenten und Bildern auf rein technischer Ebene bereitzustellen. Wird die Bedeutung der **Hermeneutik**, im Sinne holistischer Durchdringung eines Sachverhaltes durch ein individualistisches Verständnis betont, können die Digital Humanities aber bereits methodisch signifikant werden, weil der Umgang mit digital gespeicherter Information oft leichter nachvollziehbar und für andere dokumentierbar ist, als dies bei der Verwendung persönlicher Notizen der Fall wäre. Bei allen Ansätzen schließlich, bei denen ein ›Beweis‹ im Sinne quantitativ/statistischer Argumentation verlangt wird, ist der methodische Schwerpunkt eindeutig.

Zu betonen ist dabei jedoch, dass selbst Paul Feyerabend Werkzeuge der Digital Humanities hätte verwenden können, um ihn interessierende Texte zu finden: Die Digital Humanities insgesamt erlauben also methodische Positionen, verlangen sie aber nicht und finden in der ganzen Breite der möglichen methodischen Haltungen der Geisteswissenschaften ihre Berechtigung. Die Digital Humanities sind **methoden-neutral**, trotz der methodischen Implikationen, die wir einleitend erwähnt haben.

2.4 | Die Digital Humanities jenseits einzelner geisteswissenschaftlicher Disziplinen

Unabhängig davon, wie man sie gegenüber den Naturwissenschaften abgrenzt, besteht jedenfalls Konsens, dass es von ihnen unterschiedene Geisteswissenschaften gibt. Trotzdem kann man kein Studium der *Geisteswissenschaft* beginnen, sondern nur eines einer spezifischen Disziplin: Germanistische oder Historische Seminare begegnen häufig an den Universitäten, ›geisteswissenschaftliche‹ nie. Wieweit kann es dann eine digitale Geisteswissenschaft als universitäres Fach geben, wenn es keine Geisteswissenschaft als solche gibt?

Auf der Werkzeugebene gibt es eine einfache Antwort: Für Geisteswissenschaftler, die sich dafür interessieren, wie man möglichst effektiv in großen Mengen an Texten sucht, ist es zunächst unerheblich, ob sie dies tun, weil sie feststellen wollen, ob eine sprachliche Konstruktion für bestimmte Verfasser typisch ist, oder weil sie wissen wollen, ab wann die Schlagworte einer bestimmten politischen Richtung in digitalen Zeitungen auftauchen. Das Handwerkszeug ist für die philologischen Disziplinen das gleiche, wie für die der historischen Forschung. Daran könnte man so-

gar eher die Frage anschließen, ob diese Neutralität des Werkzeugs nicht so ausgeprägt sei, dass es auch unerheblich werde, ob Geisteswissenschaftler oder Physiker Texte durchsuchen. Auf allgemeinsten technischer Ebene wäre das auch zu bejahen: Der kompetente Umgang mit den informationstechnischen Werkzeugen, die heute allgemein verbreitet sind, ist für alle wissenschaftlichen Disziplinen nötig und begründet keine akademische oder fachspezifische Qualifikation.

Intuitiv kann man den Unterschied zwischen **allgemeiner Kulturtechnik** und geisteswissenschaftlicher, aber **fachübergreifender, Qualifikation** dort sehen, wo die Anwendung auf die fachspezifischen Daten oder Texte fachspezifische Kenntnisse voraussetzt. Nach wie vor intuitiv wird dies illustriert durch die Probleme, die sich ergeben, wenn wir große Textmengen aus dem 18. Jahrhundert bearbeiten wollen: Auch hier sind die nötigen Qualifikationen zum Umgang mit Texten in älterer Orthographie und älteren Sprachformen unabhängig davon, ob hinter der Beschäftigung mit dem Material eine philologische oder eine historische Fragestellung steht. Für beide geisteswissenschaftlichen Hintergründe sind diese Qualifikationen notwendig. Für die Beschäftigung von Naturwissenschaftlern mit gegenwartsbezogenen Texten nicht.

Und diese disziplinübergreifenden Eigentümlichkeiten gehen über den Umgang mit Texten hinaus. Sollen räumliche Phänomene in historische Landkarten eingezeichnet werden, ist es unabhängig vom disziplinären Interesse notwendig zu verstehen, wie sich die Methoden, nach denen diese Karten gezeichnet wurden (die sogenannte ›Projektion‹), von denen für heutige Karten üblichen unterscheiden (s. Kap 21.2). Werden Noten zur Klärung musikwissenschaftlicher Fragen analysiert, ist zu klären, wie man die vorgefundene Notation verarbeitet – soll eben komponierte Musik in Notenform ausgegeben werden, kann einfach jenes Verfahren gewählt werden, das das zur Eingabe der Noten verwendete Programm vorgibt.

Diese Notwendigkeit, aus den Quellen, die zur Untersuchung des die Geisteswissenschaftler interessierenden Phänomens vorliegen, Daten zu extrahieren und in eine Form zu bringen, die ihre Untersuchung mit informationstechnischen Mitteln erlaubt, ist Bestandteil des Konzepts der **Modellierung** (s. Kap. 7). Hier liegt der fachübergreifende Kern der Digital Humanities: Es besteht Konsens darüber, dass für die adäquate Modellierung von geisteswissenschaftlichen Sachverhalten für die Informationstechnik Kenntnisse und Vorgehensweisen benötigt werden, die mehreren geisteswissenschaftlichen Disziplinen gemein sind, sich aber von den in den Naturwissenschaften benötigten unterscheiden. Um einem Missverständnis vorzubeugen: Die Modellierung von Sachverhalten in einer Form, die sie für informationstechnische Systeme verarbeitbar macht, ist eine unabdingbare Voraussetzung für den Einsatz solcher Systeme in absolut jeder Anwendungsdomäne. Die dafür einzusetzen den Konzepte in den Geisteswissenschaften unterscheiden sich jedoch von denen in anderen Disziplinen signifikant. Um einem anderen Missverständnis vorzubeugen: Modelle an sich sind den Geisteswissenschaften nicht fremd. Die für den Einsatz der Informationstechnologien notwendigen stehen in einer langen Tradition, die vor allem Willard McCarty sehr plausibel beschrieben hat. Er lässt seinen **Stammbaum der Modellierung** bei der Verwendung von veranschaulichenden **Analogien** beginnen, die versuchen, den Wesenskern eines Problems sichtbar zu machen und führt ihn über verschiedene Darstellungstechniken weiter zu Konzepten wie dem Experiment und der Simulation.

Vertrautes und Neues stehen hier nebeneinander: Dass die Zusammenhänge mehrerer Konzepte durch ein Diagramm anschaulicher werden, ist ein allgemein be-

kanntes Beispiel für ein ›Modell‹ in diesem allgemeineren Sinn. Simulationen – etwa die im Fernsehen gezeigten visuellen Simulationen die Erde umkreisender Satelliten – scheinen den Geisteswissenschaften zunächst wesensfremd. Denken wir an Beispiele, wo die archäologischen Fächer 3D-Modelle generieren, die es erlauben, sich, unter Umständen durch Techniken der Virtuellen Realität, in virtuellen Rekonstruktionen nicht mehr existierender Gebäude zu bewegen, haben wir jedoch ein unmittelbar plausibles Beispiel für diese Art von ›Modell‹ in den Geisteswissenschaften, das offenbar eine sehr viel detailfreudigere ›Modellierung‹ erfordert, als die in ein Diagramm mündende. Dass solche **Simulationen** weit über die Wiedergabe nicht mehr existierender Objekte hinausgehen und sich auch auf die Untersuchung rein konzeptueller Zusammenhänge auswirken können, sei hier nur angemerkt. Beispiele für die Praxis des ›Modellierens‹ finden sich in anderen Kapiteln dieses Bandes.

2.5 | Die Digital Humanities und die Informatik

Ein 3D-Modell, das ein zerstörtes Gebäude im virtuellen Raum wieder erstehen lässt, klingt im Jahr 2016 immer noch ein wenig nach Hightech. Die Fähigkeit, in einigen tausend Büchern nach Regelmäßigkeiten zu suchen, die als Kontext der Beobachtungen an einem einzelnen Text verwendet werden können, eigentlich nicht minder. Heißt das, die Digital Humanities hätten ein besonders enges Verhältnis zur Informatik?

Nicht unbedingt, noch nicht einmal häufig. ›Die Informatik‹ umfasst mittlerweile ein Spektrum fachlicher Spezialisierungen, das kaum weniger breit ist, als das der Geisteswissenschaften, ganz sicher nicht weniger breit, als das einer ihrer großen Teilbereiche, etwa ›der Philologien‹. Der Kern der Informatik besteht stets in der Untersuchung der Frage, wie man Information am Rechner darstellen und verarbeiten kann. Nun haben wir zuletzt eben auf die Verwendung von 3D-Modellen verwiesen: Muss die Frage, wie man ein solches, zunächst sehr komplexes Modell auf dem Rechner darstellt, dann ein Beispiel dafür sein, dass sich Informatik und Geisteswissenschaften, hier repräsentiert durch die Archäologie, eng berühren? Nicht notwendiger Weise. Zwar gibt es innerhalb der Informatik in der Tat ein Spezialgebiet, das sich mit genau dieser Frage – wie man 3D-Modelle definiert und visualisiert – auseinandersetzt, in aller Regeln findet diese Auseinandersetzung aber auf einem sehr viel allgemeineren Niveau statt, wo man sich nicht mit der Frage beschäftigt, wie man **ein ganz bestimmtes Gebäude** modelliert und darstellt, sondern wie man diese Fragen für **alle überhaupt vorstellbaren Objekte** lösen kann. Was mutatis mutandis dann auch wieder für den Umgang mit großen Textmengen gilt.

Während es einzelne Ansätze zur Untersuchung der Eignung von Grundkonzepten der Informatik auf die Geisteswissenschaften gibt, beschäftigen sich nahezu alle Vertreter der Digital Humanities jedoch mit der Frage, wie man die Informationstechnologie, also die aus den abstrakten Konzepten der Informatik abgeleiteten praktischen Lösungen, für die Geisteswissenschaften nutzbar machen kann.

2.6 | ›Die Digital Humanities‹

Beispiele der Digital Humanities aus dem Bereich der Quantitativen Analyse (s. Kap. 20) haben gemein, dass die quantitative Aussage letzten Endes der detaillierten Betrachtung der Texte folgt. Die Beschäftigung mit dem intensiv gelesenen Text steht also am Anfang, die quantitative Betrachtung folgt. Wir gingen in diesem Kapitel schon darauf ein, dass es Fragen geben könne, denen wir uns nähern könnten, wenn wir eine Sammlung von tausenden von Bänden durchsuchen könnten. Wenn wir tausende von Bänden nach Wörtern durchsuchen können, können wir diese Wörter auch zählen. Wir können diese tausende von Bänden aber nicht mehr intensiv lesen. Die quantitative Ergänzung der verstehenden Interpretation wird also nicht mehr statistisch ergänzt (**deskriptive Statistik**) oder methodisch abgesichert (**schließende Statistik**), sondern sie fehlt zunächst, und die statistische Annäherung an die große Textmenge ist Ausgangspunkt der Analyse (und kann ggf. erst sekundär durch die intensive Lektüre von einzelnen Texten im quantitativ erschlossenen Gesamtbestand ergänzt werden).

In den Diskussionen der letzten Jahre wird der Zugang zu Texten über die intensive Lektüre einzelner Texte (der durch statistische Analysen ergänzt werden kann, aber nicht muss) oft als **close reading** bezeichnet; der Zugang zu großen Textsammlungen über statistische Aussagen über die Texte in der Sammlung insgesamt (der durch die intensive Lektüre von Einzeltexten ergänzt werden kann, aber nicht muss) als **distant reading**.

Wir haben damit begonnen aufzuzeigen, dass sich hinter diesem Begriff Anwendungen verbergen, die scheinbar wenig gemeinsam haben: Was hat die Rekonstruktion des ursprünglichen Bauzustandes eines Barockschlosses in der Virtuellen Realität mit der statistischen Analyse frühneuzeitlicher Steuerlisten zu tun?

Was sie miteinander und dem gewählten Beispiel zu den quantitativen Verfahren gemein haben, ist zweierlei. Sie bieten Werkzeuge an, mit denen die Forschungsgegenstände der Geisteswissenschaften, mit unveränderter Methodologie, intensiver und gründlicher untersucht werden können. Und sie *können* wissenschaftstheoretische Fragen eröffnen. Aristotelisch ausgedrückt: Wenn wir maschinellen Zugang zu allen in einem Jahrhundert gedruckten literarischen Werken haben, ist die Konzentration auf einen Kanon von hundert besonders wichtigen ein Teil der **Substanz** der geisteswissenschaftlichen Arbeit? Oder ist es ein **Akzidens**, zufälliges Nebenprodukt der Arbeitsbedingungen unter denen sich die Geisteswissenschaften vor der digitalen Verfügbarkeit der großen Textmengen entwickelt haben?

Literatur

- Bodenhamer, David J./Corrigan, John/Harris, Trevor M. (Hg.): *The Spatial Humanities*. Bloomington/Indianapolis 2010.
 Gold, Matthew K. (Hg.): *Debates in the Digital Humanities*. Minneapolis/London 2012.
 McCarty, Willard: *Humanities Computing*. Houndmills 2005.
 Moretti, Franco: *Distant Reading*. London 2013.
 Schreibman, Susan/Siemens, Ray/Unsworth, John (Hg.): *A New Companion to Digital Humanities*. Chichester 2016.
 Thaller, Manfred (Hg.): »Controversies around the Digital Humanities«. In: *Historical Social Research* 37/3 (2012), 7–23.

Manfred Thaller

3 Theorien digitaler Medien

Digitale Medien werden im Rahmen ihrer theoretischen Reflexion oft in Grundsatzfragen der Gegenwartskultur verortet. Die Geschichte des digitalen Zeitalters und die Anfänge der digitalen Welt können gleichfalls in einem größeren historischen Rahmen betrachtet werden. Insofern fragt sich eine wissenschafts- und mediengeschichtliche Theorie der digitalen Kulturen, wie und wo die Anfänge der **Digitalisierung** in der Menschheitsgeschichte zu verorten sind. Vor diesem Hintergrund kann die historische Rolle des Denkens in Netzwerkmodellen und die Formalisierung der Zeichenwelten vor dem Computerzeitalter rekonstruiert werden. Ausgehend von dieser längeren Perspektive der Geschichtsschreibung von Digitalität können die bis heute geltend gemachten Leitdifferenzen, Abgrenzungsversuche und Systematisierungen der digitalen Medientheorien sondiert werden, anhand derer man ihre Ausdifferenzierungsprozesse festmachen kann.

Das hier vertretene Konzept der **Theoriereflexion** bietet keinen autorzentrierten und chronologisch geordneten Überblick über Medientheorien, sondern geht problemorientiert vor und betrachtet Medien als »konstitutive Faktoren von Selbst, Gesellschaft und Kultur« (Lagaay/Lauer 2004, 12). Infolgedessen können Theoriediskurse zu Medieninhalten und empirisch-quantitative Forschungen nicht berücksichtigt werden. Die hier vorgestellten Medientheorien des Digitalen setzen sich mit den Umbrüchen, Strukturierungen und Formatierungen unserer Wahrnehmungen, Handlungen und Denkweisen auseinander und entwickeln ein Repertoire von Begriffen und Figuren, welches unterschiedliche Schnittstellen für die Anschlusskommunikation eröffnet.

Mit Figuren des Umbruchs wie etwa »analog/digital«, »kontinuierlich/diskret«, »materiell/immateriell« kommen in Theorien oft auch vorentscheidende Ordnungs- und Selektionsprinzipien zum Ausdruck, wie spezifische Gegenstandsbereiche der digitalen Kultur überhaupt angemessen zu fassen sind. Mit ihren Trennungen und Gegenüberstellungen begründen Theoriediskurse digitaler Medien ihre dichotome Methode, die auf Einteilungen in jeweils zwei Teile beruht. Indem Leitbegriffe in den Debatten die Eigenschaft erlangen, Vorurteile zu schaffen und auf das Erkennen und Handeln Einfluss nehmen, kann ihnen der Status von Ideen zugeschrieben werden. In dieser Hinsicht stellen theoretisch gerahmte Leitdifferenzen und Schlüsselbegriffe wirkmächtige Orientierungsgrößen dar, mit denen Medientheorien als Teil kultureller Entwicklungen integriert oder als Auftakt eines generellen Paradigmenwechsels verstanden werden können. Vor diesem Hintergrund wird zusammenfassend die Frage aufgeworfen, welchen Stellenwert das Digitale bei der medialen Präfiguration der Gesellschaft leistet und wie sich aus der gegenwärtigen Theoriebildung heraus künftige Entwicklungstendenzen der digitalen Gesellschaft verstehen lassen können.

3.1 | Digitalisierung als Medien- und Wissensgeschichte

Der Begriff »Digitalität« wird üblicherweise mit der technischen Funktionsweise rechnerbasierter Medien in Verbindung gebracht. Unter der Berücksichtigung, dass Computer alle ihre Informationen binär kodieren und einen zunehmenden Einfluss auf unsere Weltwahrnehmung in allen Teilen der Gesellschaft ausüben, macht es Sinn, den Medienwechsel der Gegenwartsgesellschaft mit historischen Umbruchs-situatio-

nen und Entwicklungsprozessen zu vergleichen. In diesem Sinne setzt sich Werner Faulstich für einen Perspektivenwechsel in der Medientheorie ein und plädiert für eine mediengeschichtliche Ausrichtung digitaler Theoriebildung: »Medientheorie muß sich hier nur stärker als Mediengeschichte begreifen« (Faulstich 1991, 76).

Anfänge der digitalen Kultur: Allerdings herrscht in den Theorien der digitalen Medien keine Einigkeit über die Anfänge der digitalen Kultur. Brian Rotman ortet in *Die Null und das Nichts* (2000) Anfänge der digitalen Idee in der Verbreitung der **Null** durch die Araber. Im 10. Jahrhundert migrierte diese Vorstellung in den Raum der Iberischen Halbinsel. Durch die Einbeziehung der Null kann jede Kombination und jeder Stellenwert ausgedrückt werden. Allerdings wird mit der Null noch kein **binäres Rechensystem** etabliert. Erst das von Leibniz um 1700 erfundene binäre Zahlensystem schafft die für die Digitalität grundlegende Unterscheidung von 0/1. Barbara Flückiger weist darauf hin, dass noch vor Leibniz Juan Caramuel y Lobkowitz 1670 eine Abhandlung publizierte, die das binäre Prinzip beschreibt (Flückiger 2008, 33). Doch erst in seinem 1701 veröffentlichten Aufsatz »Wunderbarer Ursprung aller Zahlen aus 1 und 0, welcher ein schönes Vorbild gibe des Geheimnisses der Schöpfung, da alles von Gott und sonst aus nichts entstehet« gelang Leibniz die mathematische Berechnung der Binärthese und wurde seither als Erfinder und Vorläufer des digitalen Kodes angesehen (vgl. Bredekamp 2008, 101).

In diesem Zusammenhang weist Jens Schröter darauf hin, dass die Idee des Digitalen auf keine sukzessiv verlaufene Fortschrittsgeschichte verweist, sondern sich vielmehr in räumlich und zeitlich verstreute Projekte aufteilt (2004, 29). Daher sehen andere Historiographien der digitalen Medien erst in Charles Babbage und seiner 1837 entworfenen Rechenmaschine »**Analytical Engine**« einen Vordenker des modernen Computers, der mittels programmierbarer Rechenvorschriften Daten verarbeitet (Turing 1936–37).

Materialorientierte Geschichtsschreibungen der digitalen Medien nennen hingegen als Vorläufer der digitalen Kodierungsform Joseph-Marie Jacquards automatischen Webstuhl, der auf Lochkarteneingabe basierte, oder Herman Holleriths Tabulating Machines (Coy 2005, 18; Essinger 2004, 151). Nach 1945 setzte sich schließlich mit der sequenziellen **Von-Neumann-Architektur** die binäre Beschreibung digitaler Daten im Rahmen von Computeranwendungen durch, da elektronische Schaltungen das Prinzip von 0 (On) und 1 (Off) einfach umsetzen konnten. Von-Neumann-Systeme bilden bis heute die Referenzmodelle für die Arbeitsweise der gängigen Computer (Neumann 1993, 27–75).

Berücksichtigt man also die Vielfalt der historischen Anwendungskontexte, dann bietet das Konzept der Digitalität divergierende Möglichkeiten, numerische Prinzipien medialer Anordnungen und Verhältnisse zu beschreiben. Als ein Grundprinzip des Computers gilt die Überführung aller Zeichen und Zeichenvorgänge in Rechenoperationen. In dieser Hinsicht verweist die Vorgeschichte der digitalen Rechenmaschinen auf ältere Denktraditionen, die bereits eine Automatisierung von Berechnungen im Blick hatten (Rieger 1997, 190). Entgegen der theoretischen Tendenz problematisiert Timothy Murray in *Digital Baroque* (2008) die These, dass die Durchsetzung der digitalen Medien auf radikale Weise mit der medialen Vergangenheit bricht und rekuriert in seiner Beschäftigung mit prädigitalen Technologien nicht auf jüngere Entwicklungen, sondern auf barocke Kulturtechniken.

Die Wiederentdeckung des Barock für die Geschichtsschreibung digitaler Medien und Netzwerke hat in der rezenten Theoriebildung einen Boom ausgelöst (vgl. Cubitt 2004; Ndalians 2005; Munster 2006). Neuere Medien beschäftigen sich mehr

oder weniger grundlegend mit Konzepten des operativen Symbolgebrauchs, welche die Entwicklungsgeschichte des Computers richtungsweisend vorbereitet haben. Als bedeutende Hauptakteure der späteren Digital Humanities rücken die arithmetischen, algebraischen und logischen Kalküle des operativen Symbolgebrauchs in das Zentrum der medienarchäologischen Perspektivierung der digitalen Medien. In diesem Zusammenhang gerät die Idee der Formalisierung als einem schematischen und interpretationsfreien Gebrauch von schriftlichen Symbolen zur wissensgeschichtlichen Voraussetzung digitaler Medienkulturen. In *Symbolische Maschinen* (1988) hat Sybille Krämer die diesbezüglichen Ursprünge der mathematischen Revolution systematisch herausgearbeitet. Dementsprechend betont Friedrich Kittler in *Phänomenologie versus Medienwissenschaft* (1989) die historische Kontinuität des formalmathematischen Denkens als Ermöglichung rechnerbasierter Medientechnik:

»Die Algorithmen zunächst der neuen Geometrie und später auch der neuen Algebra standen zuerst als Regeln über dem handwerklichen Tun von Künstlern, zogen dann als selbstläufige Maschinen in den Medienpark des neunzehnten Jahrhunderts um und sind schließlich dieser Tage, nach einer systematischen digitalen Transkription aller Algorithmen, mit der Hard- und Software von Computern eins geworden« (Kittler 1989, 1).

Dementsprechend interpretiert Krämer den Computer als ein symbolisch organisiertes Medium, welches sie als einen Apparat versteht, »um Möglichkeiten zu eröffnen, über die wir ohne die Apparatur nicht etwa abgeschwächt, sondern überhaupt nicht verfügen« (1998a, 32). Diese These der medialen Ermöglichung mittels digitaler Medien erweitert Elena Esposito, indem sie die These vertritt, dass der Computer eine Maschine sei, die nicht nur symbolische Welten ermögliche, sondern mögliche Welten – verstanden als virtuelle Realität – interaktiv erschließbar mache (Esposito 1995).

Inspiziert durch die algebraischen Methoden der Mathematik propagiert René Descartes in seinen *Regulae ad directionem ingenii* von 1628 erstmals den Gedanken der Einheit eines rationalen, vernunftgesteuerten Denkens, einer *mathesis universalis*. Die Idee einer Mathematik als einer Methode des Erkenntnisgewinns, die ohne Objektgebundenheit funktioniert, wurde von der analytischen Geometrie von Pierre de Fermat (1630) übernommen und von Gottfried Wilhelm Leibniz in seiner Frühschrift *Dissertatio de Arte combinatoria* von 1666 weiterentwickelt (vgl. Yates 1966, 45 f.). Mit seiner *characteristica universalis*, einer universell gültigen Wissenschaftssprache, schuf Leibniz eine für alle Wissensgebiete verbindliche Symbolik, die nach mathematischem und naturwissenschaftlichem Vorbild konstruiert ist. Leibniz ist der Ansicht, dass alles, was existiert, durch Rechenoperationen von Nullen und Einsen, d. h. durch ein universelles Kalkül, erzeugt werden kann. In diesem Zusammenhang verweist Michel Foucault auf die »Logique de Port-Royal«, die 1683 den entscheidenden Schritt zu einer »binären Organisation« des Zeichens unternommen hat (Foucault 1974, 98).

Zum Begriffspaar digital/analog: Das von Descartes, Fermat und Leibniz beschriebene universale Kalkül, mit dem jede mögliche Manipulation der Dinge als binäre Operation von Nullen und Einsen angeschrieben werden kann, ist aber selbst nicht frei von Figuren der körperlichen Repräsentation und folglich nicht losgelöst von Figuren materieller Metaphorik. In diesem Sinne basiert das scheinbar abstrakte Konzept der Digitalisierung auf der Figur einer haptischen Intervention, die verdeutlicht, dass Digitalität und digitale Medien konstitutiv mit spezifischen Körperbildern verbunden sind. Denn in Anknüpfung an den lateinischen Wortursprung von *digitus*

(›Finger‹, ›Zehe‹) vergleicht die **Medienphilologie** des digitalen Wissens die einzelnen Elemente menschlicher Gliedmaßen, die gemeinsam ein Ganzes ergeben, mit den Bytes, die für eine Folge von 8 Bits – der Maßeinheit der Digitaltechnik – stehen.

Auch das Anzeigen einer Zahl mit den Fingern wird als eine klar abgestufte (›diskrete‹) Geste verstanden, die dem Analogen als fließender Übergang gegenübergestellt wird. Den Nachweis einer ersten Begriffsverwendung von ›digital‹ für Technologien, die nur diskrete, d. h. unstetige arithmetische Größen verwenden, hat Loleit (2004, 205) für das Jahr 1946 nachgewiesen. Die Bezeichnung ›digital‹ wurde aber erst populär mit der breitenwirksamen Markteroberung der Musik-CD (Compact Disc) in den 1980er Jahren (Schröter 2004, 16). Ein Bit stellt die kleinste Informationseinheit in der Computertechnik dar, und ein Byte ist die kleinste adressierbare Einheit in Rechnerarchitekturen. Indem die Information eines Bits entweder 0 oder 1 beträgt, beruht die gesamte Medienkultur des Digitalen auf der Grundeigenschaft, dass digitale Daten aus diskreten Zahlenfolgen bestehen. Dahingehend wird die binäre Repräsentation von Digitalität zum Ausgangspunkt eines umgreifenden gesellschaftlichen Wandels aufgefasst, der alles, was teilbar und abgestuft ist, dem analogen Zeitalter gegenübergestellt wird, das als die Ära des Stufenlosen, Kontinuierlichen aufgefasst wird (Negroponte 2012).

Die Anfänge der Digitalisierung werden in der Theoriebildung jedoch nicht nur auf den epistemischen Bruch von analog auf digital reduziert, sondern auf umfassendere Wissenskulturen der mathematischen Mediatisierung der Wahrnehmung ausgedehnt. In diesem Sinne kann mit dem historischen Konzept der Digitalität sowohl die Spezifik älterer Mediensysteme und ihrer syntagmatischen Logik des Symbolischen als auch die Taktilität des Computers hinsichtlich seiner apparativen Funktionsweise (Bits, Bytes) und seiner haptischen Vermittlungsleistung und Bedienbarkeit (Tastatur, Maus, Touchscreen) beschrieben werden.

Vor diesem Hintergrund sieht Kippenhahn in der Kryptografie des 17. Jahrhunderts einen Wegbereiter für Alan Turings Dechiffrierung des Enigma-Codes (Kippenhahn 1999). Auch die im 19. Jahrhundert entwickelte **Boolesche Algebra** von George Boole steht in der Tradition des barocken Traums einer universellen Maschine, das menschliche Denken und Handeln mit Hilfe formaler Methoden präzise beschreiben und regeln zu können. Mit seinen *Laws of Thought* (1854) legte George Boole den Grundstein der mathematischen Logik und etablierte in Form der **Schaltalgebra** das mathematische Fundament der gesamten technischen Informatik. Die hier skizzierte Entwicklung einer sicheren logischen Symbolsprache bildet die operationale Grundlage der modernen Computertechnik und des Internets (Nahin 2012). Und Friedrich Kittlers These einer umfassenden ›Gleichschaltung‹ heterogener Phänomene, die vorher »Symbolisches, Mathematisches oder Sprachliches« (Kittler 1994, 113) waren, kann als Fortschreibung des barocken Traums einer universalen Rechenkunst gelesen werden.

3.2 | Medienarchäologie und Software Studies

Die historisch vergleichende Medien- und Kulturanalyse der digitalen Datenverarbeitung unter Berücksichtigung der materiellen Kultur von Datenpraktiken vom 19. bis zum 21. Jahrhundert hat aufgezeigt (Gitelman/Pingree 2004), dass bereits im 19. Jahrhundert die mechanischen Datenpraktiken das taxonomische Erkenntnisinteresse der Forscher maßgeblich beeinflussten – lange bevor es computerbasierte

Methoden der Datenerhebung gab. In seiner Medienarchäologie der Datenverarbeitung unterscheidet Kevin Driscoll drei historische Perioden:

»The first period begins in the late-19th century with the development of mass-scale Information processing projects and the electro-mechanical punched card systems that made them possible. Although these early machines were gradually replaced by programmable computers in the 1950s and 1960s, the organizational logic embedded in such systems persisted more or less unchanged until the 1970s.

The second period is marked by the rise of database populism and the increasing availability of microcomputers in the late-1970s. Implementations of the relational data model enabled the production of more accessible interfaces for non-specialists and large institutional databases were increasingly accompanied by small personal databases built by individuals and stored on microcomputers.

In the third period, however, small personal databases receded from the desktop with the increasing sophistication of spreadsheet software and the diffusion of internet access. In the early 21st century, the demanding task of tracking millions of users through highly-centralized communication systems such as Facebook brought about new approaches to database design that departed significantly from the previous four decades.« (Driscoll 2012, 6 f.)

Die von Driscoll herausgearbeitete Periodisierung der digitalen Datenpraktiken bildet einen vielversprechenden Ansatz, um die Geschichte der **digitalen Informationsverarbeitung** als eine Entwicklung ihrer Medienumbrüche – im Sinne eines »progressiven kulturellen Wandels« (Rusch 2007, 83) – aufzeigen zu können.

Weiterführende Untersuchungen haben die sozialen und politischen Bedingungen und Auswirkungen des Übergangs von der mechanischen Datenauszahlung der ersten Volkszählungen um 1890 über die elektronischen Datenverarbeitungen der 1950er Jahre bis zum digitalen Social Monitoring der unmittelbaren Gegenwart untersucht (Bollier 2012, 3). 1937 veröffentlichte der britische Mathematiker und Logiker Alan Mathison Turing seine Arbeit »On Computable Numbers with an Application to the Entscheidungsproblem«, in der er ein mathematisches Maschinenmodell entwickelte, das bis heute für die Theoriegeschichte der modernen Informations- und Computertechnologie von größter Bedeutung ist (Turing 1936–37).

Mit dem von Turing entwickelten Universal-Modell der **Turingmaschine** gilt er heute als einer der einflussreichsten Theoretiker der frühen Computerentwicklung. Im Jahr 1946 entwickelte der Mathematiker John von Neumann die bis heute gültigen Funktionseinheiten des Computers: Steuerwerk, Rechenwerk, Speicher, Eingabewerk und Ausgabewerk. Weil der Computer als erweiterte Rechenmaschine alle Informationen in einen binären Code übersetzt und als Signale elektrisch überträgt, ist er als umfassendes Hypermedium in der Lage, nicht nur sprachliche Texte, sondern auch visuelle und auditive Texte in einem multimedialen Konvergenzraum zu speichern, zu bearbeiten und zu verteilen (Cioffi-Revilla 2010). Friedrich Kittler verortet demnach das maßgeblich Neue des Computers in seiner Eigenschaft, alle bisherigen Medien in sich zu vereinen – ein Charakteristikum, das in der rezenten Theorie der digitalen Medien mit den Begriffen der **Medienkonvergenz** und des **Hypermediums** umschrieben wird:

»Wenn Filme und Musiken, Anrufe und Texte über Glasfaserkabel ins Haus kommen, fallen die getrennten Medien Fernsehen, Radio, Telefon und Briefpost zusammen, standardisiert nach Übertragungsfrequenz und Bitformat. [...] In der allgemeinen Digitalisierung von Nachrichten und Kanälen verschwinden die Unterschiede zwischen einzelnen Medien. Nur noch als Oberflächeneffekt, wie er unter dem schönen Namen Interface beim Konsumenten ankommt, gibt es Ton und Bild, Stimme und Text« (Kittler 1986, 7).

In seinem 1993 veröffentlichten Aufsatz »Es gibt keine Software« stellte er seine provokante These vor, dass Software bloß eine Imagination sei, die den Blick auf das tatsächlich bedeutende – die Hardware – verdeckte (Kittler 1993). Stattdessen forderte er mit seiner an Michel Foucault angelehnten **Medienarchäologie** die materiellen Bedingungen der Kulturinformatik stärker in den Blick zu nehmen: »Archäologien der Gegenwart müssen auch Datenspeicherung, -übertragung und -berechnung in technischen Medien zur Kenntnis nehmen« (Kittler 1985, 501). Seine medienarchäologischen Analysen haben die Theorien der digitalen Medien maßgeblich beeinflusst und konzentrieren sich auf die Untersuchung der »Netzwerke von Technik und Institutionen, die einer gegebenen Kultur die Adressierung, Speicherung und Verarbeitung von Daten erlauben« (ebd.).

Matthew Kirschenbaum ist ein Vertreter dieses medienmaterialistischen Ansatzes und beschäftigt sich mit den medienarchäologischen Aspekten der Computerkultur. Im Zentrum seiner im Jahr 2008 veröffentlichten Untersuchung *Mechanisms: New Media and the Forensic Imagination* steht das wichtigste Speichermediums der Gegenwart: das **Festplattenlaufwerk**. In seiner Auseinandersetzung mit den maßgeblichen Theorien der digitalen Medien kritisiert er, dass sie ihr Augenmerk auf den Bildschirm gelegt haben und andere Formen von Materialität ausgeblendet haben. In Anlehnung an Nick Monfort nennt er diese einseitige Ausrichtung »Screen Essentialism« (Kirschenbaum 2008, 31) und bezichtigt die Media Studies, eine Art De-materialisierung des Forschungsgegenstandes betrieben zu haben, die das Wesentliche der Medien aus dem Blick verliert. Dabei ruft er in Erinnerung, dass sich die medienmaterialistische Theoriebildung nur mit bestimmten Formen der physikalischen Materialität digitaler Medien, den Mikroprozessoren und Schaltkreisen, beschäftigt habe. Er räumt ein, dass die medialen Grundfunktionen des Speicherns von der Medientheorie bisher vernachlässigt wurden.

Mit dem Begriff der »forensic materiality« bezeichnet Kirschenbaum den Umstand, dass der gesamte Prozess der Aufzeichnung, Verbreitung, Verarbeitung und Überlieferung von Daten von physikalischen Trägermedien, z. B. dem Festplattenlaufwerk, abhängt: »[...] computer forensics depends upon the behaviors and physical properties of various computational storage media« (Kirschenbaum 2008, 45). Die Festplatte entzieht sich der Wahrnehmung der Nutzer und kann von ihnen nur als eine Black Box angesehen werden. Mit der *formal materiality* bezeichnet er die symbolische Ebene von konzeptionellen und logischen Objekten des Mensch-Maschine-Interface: »Formal materiality thus follows as the name I give to the imposition of multiple relational computational states on a data set or digital object. Phenomenologically, the relationship between these states tends to manifest itself in terms of layers or other relative measures, though in fact each state is arbitrary and self-consistent/self-contained« (Kirschenbaum 2008, 12). Mit der Perspektive der *formal materiality* können zwar die Zwänge, welche die Anwendungen und das Betriebssystem mittels der Schaltflächen auf dem Bildschirm auf die Nutzer ausübt, thematisiert werden, aber die tieferen Schichten rechnerbasierter Medialität lassen sich nur mittels der *forensic materiality* erschließen. Mit seiner kritischen Revision medienmaterialistischer Positionen leistet Kirschenbaum einen wertvollen Beitrag zur Ausdifferenzierung medienarchäologischer Theoriebildung.

Kittlers programatische These »Es gibt keine Software« wurde lange Zeit als **Grundsatz der Medienwissenschaft** gehandelt, und möglicherweise hat die in seinem Aufsatz vertretene Gegenüberstellung von »Materialität« versus »Immaterialität« in der Nachfolge dazu beigetragen, dass dem Aspekt der Software in den Kultur-

und Medienwissenschaften weniger Aufmerksamkeit geschenkt wurde. Zehn Jahre nach Kittlers richtungsweisendem Text formierten sich jedoch eine Reihe von Veröffentlichungen, die der einseitigen Vorstellung von der Immaterialität von Software widersprochen haben (exemplarisch: Fuller 2003). Entgegen der weitverbreiteten Meinung wurde der Software durchaus eine gewisse Materialität zugesprochen, die sich auf verschiedenen Ebenen manifestiert und wirksam wird (Chun 2008, 299–324). Im Zentrum zahlreicher Studien stehen die konzeptuellen und technologischen Grundlagen des Computers und die besonderen Charakteristika von Algorithmen, Programmiersprachen und Interfaces (Galloway 2004, 2006).

Insofern stehen die *Software Studies* in der Tradition medienmaterialistischer wie auch medienarchäologischer und kulturgeschichtlicher Ansätze, indem sie Software als etwas begreifen, das eine eigene Geschichte hat und somit nicht nur durch Medientechnologie, sondern ebenso durch soziale, institutionelle und kulturelle Rahmenbedingungen bedingt ist.

Die *Critical Code Studies* und die *Software Studies* stehen heute für ein heterogenes Diskursfeld innerhalb der Theorien der digitalen Medien, das sich mit den Algorithmen, Graphen und Protokollen digitaler Umgebungen auseinandersetzt (Mackenzie 2006; Fuller 2008; Wardrip-Fruin 2011). In diesem Theoriestrang überlagern sich medienarchäologische und datenkritische Problemstellungen, die sich mit den sozialen Steuerungsprozessen und machtpolitischen Aspekten beschäftigen, die der Erzeugung von datengenerierter Forschung und materiellen Datenkulturen inhärent sind (Gillespie 2010, 347–364). Sie gestehen der **Vernetzungstechnologie** selbst eine strukturbildende Macht zu und interpretieren die digitalen Informations- und Kommunikationstechnologien als eine rechner- und softwarebasierte Ermöglichungsmacht sozialer und kultureller Praktiken, die weite Bereiche der Alltagskommunikation dominieren.

Eine Vielzahl von Forschungsrichtungen dient den *Software Studies* als theoretischer und methodischer Impulsgeber, da ihre Forschungsgegenstände in den unterschiedlichsten Anwendungsfeldern integriert sind. So fragen Industriedesigner, Anthropologen, Humanbiologen, Architekten, Soziolinguisten, Informatiker und Vertreter der Science & Technology Studies in gemeinsamen Projekten nach dem Stellenwert von kollektiven Schrift-, Sprach-, Bild- und Gedächtnissystemen, die von rechnerbasierten Codes, Standards, Protokollen, Programmen, Datenverarbeitungen und Datenbanken produziert, prozessiert und statistisch analysiert werden (Fuller 2008). Heute hat sich das Forschungsfeld der *Software Studies* ausdifferenziert und es werden die unterschiedlichsten Verflechtungen von Software, Kultur und Gesellschaft wissenschaftlich untersucht.

Die von Alexander Galloway projektierte Medien- und Machttheorie der »protokolllogischen« Kontrolltechniken verfolgt den Anspruch, einen spezifischen Machttypus der verteilten Kontrollgesellschaft zu beschreiben (Galloway 2004). Die Protokolle interpretiert er als Medien einer liberalen Regierungstechnologie, die hochgradige Spielräume an unregulierter Kommunikation und flexibilisierter Distribution von Inhalten für einen taktischen Mediengebrauch bereithält. Protokolle operieren unterhalb der sichtbaren Anwendungsschichten im Verborgenen und werden daher nicht als mediale Beschränkung von Informationsflüssen wahrgenommen, sondern als herrschafts- und machtnutrales Tool. In der Tradition medienmaterialistischer Ansätze und vor dem Theoriehintergrund der Science Studies fragt er nach dem Stellenwert von informatischen Konzepten und Benutzerschnittstellen bei der Herausbildung sozialer Formationen und interpretiert die algorithmischen Standards, Normen und Protokolle also in erster Linie als vermittelnde Instanz zwischen den kul-

turellen Praktiken und den technischen Infrastrukturen. Vor diesem Hintergrund untersucht er nicht nur die technischen Möglichkeiten der politischen Kontrolle durch Algorithmen und Protokolle, sondern thematisiert die politischen Handlungsmöglichkeiten von netzwerkbasierten Bewegungen.

3.3 | Digitalisierung und Gesellschaft

Im Jahr 1945 veröffentlichte der US-amerikanische Ingenieur und Pionier des Analog-Rechners Vannevar Bush seinen 1939 geschriebenen Aufsatz »Wie wir denken werden«, in dem er eine fiktive Maschine, *Memex* (*Memory Extender*) genannt, vorstellte (Bush 2010, 101–108). Dieser richtungsweisende Aufsatz gilt als die erste Beschreibung einer informationsverarbeitenden Maschine als persönlichem Werkzeug und thematisiert erstmalig das Konzept der »**Mensch-Computer-Interaktion**«. Die mögliche Weiterfindung, die Vannevar Bush skizziert, kann als Anknüpfung historischer Kontexte der anthropologischen Organerweiterungstheorie gesehen werden, die in den 1940er und 1950er Jahren sehr populär war. In seiner Potentialisierung technologisch basierter Weiterfahrung geht Bush vom Menschen als einem Mängelwesen aus, der seine Fähigkeiten mit Hilfe der Maschine als Instrument erweitert. Der Computer wird seither in der Theorie oft als Medium gesteigerter Selbstpräsenz angesehen, der darüber hinaus einen entscheidenden Beitrag zur technologischen Neukonstituierung der Gesellschaft liefert.

Dass die Geschichte digitaler und vernetzter Medien nicht von ihrer kulturellen und sozialen Dynamik zu trennen ist, wird zusehends zum Thema in den Theorien der digitalen Medien. In den kulturalistischen Ansätzen von Sherry Turkle (1995; 2011), Siegfried J. Schmidt (1994, 592–623) und Sybille Krämer (1998a) wird diese Tendenz klar erkennbar, indem sie die Digitalisierung und das Internet zum Gegenstand einer umfassenden Kultur- und Zeitdiagnose erklären. So geht Schmidt davon aus, dass die traditionelle Differenzierung zwischen medial vermittelten und medial unvermittelten Erfahrungen längst hinfällig geworden ist. Die mittels der digitalen Medien, des Internets und der mobilen Medien mögliche Omnipräsenz von Medienangeboten verändert nach Schmidt sowohl die individuellen wie auch die sozialen Wirklichkeitskonstruktionen. Insgesamt war die Theoriediskussion des **Cyberspace** ab Mitte der 1980er Jahre beherrscht vom Diskurs der **Virtuellen Realität**, mit der das Denken von medial erzeugten, künstlichen Welten und ihren Techniken der Simulation bestimmend wurde (Reetze 1993; Rötzer 1996).

Bereits 1984 beschrieb William Gibson in seinem Roman *Neuromancer* seine Wortschöpfung »Cyberspace« als technische Möglichkeit sozialer Subversion und technisch induzierter Bewusstseinerweiterung. In seiner Deklaration »Das interpersonale, interaktive, interdimensionale Interface« (2007) nahm Timothy Leary an, ein kommendes globales »Weltgehirn« werde die Menschheit erwecken. Die virtuelle Welt, der Cyberspace, wurde zum Sammelbegriff für entkörperlichte Subjekterfahrungen, die in der realen Lebenswelt mit ihren biologischen und physikalischen Rahmenbedingungen nicht möglich wären. Auch die von John Perry Barlow mit großem Pathos propagierte »Deklaration der Unabhängigkeit des Cyberspace« (1996) lud das Internet normativ als einen herrschaftsfreien Raum auf.

Doch seit Beginn der 1990er Jahre bahnt sich nach Sybille Krämer »ein Perspektivenwechsel in der Computerinterpretation an: Der Computer fasziniert nicht mehr nachhaltig als Instrument der Intelligenzverstärkung, sondern beschäftigt eher als

ein Medium der Kommunikation« (Krämer 1998b, 10). Schon bald mehrten sich theoretische Abhandlungen, die das Internet als eine kommunikative und soziale Technologie zur Herstellung von Überwachung und Kontrolle interpretierten (Lyon 1994; 2001; Andrejevic 2002). In dieser Hinsicht vollzieht der Computer als Medium einen Registerwechsel, insofern er von einer Medienkultur, die das Speichern privilegiert, zu einer Medienkultur der permanenten Übertragung und Vernetzung mutiert und damit die gegenwärtige Vernetzungskultur vorwegnimmt.

In diesem Kontext trat die Medienwissenschaft in einen – sowohl was ihre Gegenstände als auch was ihre Theorien und Methoden betraf – erweiterten Kontext ein, in dem sie sich in einem Spannungsfeld zwischen **Kulturtheorie** und **Gesellschaftsdiagnose** wiederfand. Bereits 1982 sprach Jean Baudrillard in *Der symbolische Tausch und der Tod* von einer Ära der elektronischen Medien, mit der eine künstliche Welt als Realität geschaffen wird: »Der alte Slogan ›Die Realität geht über die Fiktion hinaus‹, die dem surrealistischen Stadium dieser Ästhetisierung des Lebens noch entsprach, ist überholt. Es gibt keine Fiktion mehr, der sich das Leben, noch dazu siegreich, entgegenstellen könnte – die gesamte Realität ist zum Spiel der Realität übergegangen« (Baudrillard 1982, 116). Baudrillard bezeichnet dieses Prinzip der simulierten Realität als »**Hyperrealismus**« und dessen medial erzeugte Formen als »**Simulacra**«. Hyperrealismus kennzeichnet die nicht mehr als Simulation wahrgenommene Projektion der *imaginatio* in den Realraum. Damit meint Baudrillard, dass wir in der Epoche der digitalen Medien mit der medialen Verdrängung unserer anthropologischen Grunderfahrung auskommen müssen.

Mehr als ein Jahrzehnt später wirft Martin Warnke in seinen *Theorien des Internet* die Frage auf, ob uns die klassischen Theorien der digitalen Medien in der Gegenwartskultur überhaupt noch hilfreich sein können. In diesem Sinne problematisiert er u. a. Alan Turings Gründungstext der Informatik und fragt, ob dieser die »informatischen Grundfragen der heutigen Informationsgesellschaft noch zureichend« (Warnke 2011, 158) beschreiben könne. In einer kritischen Absetzbewegung argumentiert er, dass eine informatische Theorie des Internets den Ansatz von Turing wesentlich zu erweitern hat. Für ihn besteht »der entscheidende Schritt nun darin, dass [...] nicht mehr nur ein Mensch mit einem Computer interagiert, sondern viele Menschen und viele Automaten miteinander verschaltet werden, wie wir es weltumspannend im Internet vorfinden« (Warnke 2011, 169).

Ausgehend von dieser Beobachtung macht er darauf aufmerksam, dass die Bedienoberflächen nicht die unbedingte Macht der Ingenieure gegenüber den ihnen ohnmächtig ausgelieferten Usern repräsentieren, da sie es nicht mehr schaffen würden, Kontrolle zu simulieren: »Die Phänomene emergieren und lassen sich nicht aus der Beschaffenheit der vernetzten Konstituenten ableiten, wenngleich unverdrossene Modellierer das noch immer versuchen« (Warnke 2011, 171). Mit der widerständigen Denkfigur der **Emergenz** versucht Warnke, das von Howard Rheingold entwickelte Konzept der »*Smart Mobs*« (Rheingold 2002) theoretisch weiterzuentwickeln, mit der Absicht, die bisher in der deutschsprachigen Medientheorie stark vernachlässigten Potenziale eines emanzipatorischen Mediengebrauchs zu verankern. Neben den neuen Technologien zur Herstellung digitaler Kommunikationsgemeinschaften haben sich in den Peer-to-Peer-Netzwerken und Online-Portalen aber auch traditionelle Leitbilder des gesellschaftlichen Zusammenlebens und -arbeitens erhalten, die zur Konstruktion sozialer, kultureller und politischer Identität eingesetzt werden. Die Gemeinschaftsidee ist heute zum Angelpunkt der Legitimation der Sozialen Medien im **Web 2.0** aufgestiegen (van Dijck, 2012).

Die kulturalistischen Strömungen in der Medientheorie nahestehende Position einer emanzipatorisch verfassten Internetöffentlichkeit wird von Theoretikern kritisiert, die sich mit den technologisch-infrastrukturellen Aspekten des Internets auseinandersetzen und betonen, dass die Demokratisierung der Netzkultur nur für die oberflächlichen Anwendungsschichten im Front-End geltend gemacht werden kann. Betrachtet man die exkludierende Back-End-Struktur des Internets, offenbare sich ein asymmetrisches Verhältnis zwischen der Benutzeroberfläche im Front-End und dem von Informatikern verwalteten Datenraum im Back-End-Bereich. Da in diesem vom Host verwalteten Backoffice alle Prozesse der Datenverarbeitung und -weitergabe zusammenlaufen, wird diese Wissens- und Beteiligungskluft in der datenkritischen Literatur unter den Leitbegriffen »**Digital Divide**« und »**Participatory Gap**« (Taewoo/Stromer-Galley 2012) diskutiert.

In diesem Zusammenhang kritisiert Lev Manovich die sozialen Auswirkungen gegenwärtiger Massendatenforschung, welche das Datenwissen einseitig kumuliert und verteilt sowie zu Machtasymmetrien zwischen Forschern *innerhalb* und *außerhalb* der Netzwerke führen könnte: »Nur Social-Media-Unternehmen haben Zugang zu wirklich großen sozialen Daten – insbesondere zu Transaktionsdaten. Ein Anthropologe, der für Facebook arbeitet, oder ein Soziologe in den Diensten von Google wird Zugang zu solchen Daten haben, die übrige wissenschaftliche Community hingegen nicht« (Reichert 2014). Dieses ungleiche Verhältnis festigt die Stellung der sozialen Netzwerke als computerbasierte Kontrollmedien, die sich Datenwissen entlang einer vertikalen und eindimensionalen Netzkommunikation aneignen:

- Sie ermöglichen einen kontinuierlichen Fluss von Daten.
- Sie sammeln und ordnen diese Daten.
- Sie etablieren geschlossene Wissens- und Kommunikationsräume für Experten und ihre Expertisen, welche die kollektiven Daten zu Informationen verdichten und interpretieren.

In der jüngsten Gegenwart ist »**Big Data**« zum populären Schlagwort aufgestiegen und wird oft als Sammelbegriff für digitale Technologien verwendet, die in technischer Hinsicht für eine neue Ära digitaler Kommunikation und Verarbeitung und in sozialer Hinsicht für einen gesellschaftlichen Umbruch verantwortlich gemacht werden. In Anlehnung an die von Manovich geäußerte Datenkritik haben Danah Boyd und Kate Crawford ihre Forschungen am technisch-infrastrukturellen Aufbau der Netzwerkcommunication weitergeführt und auf die hierarchisch und pyramidal angeordnete Schichtung der Sozialen Medien bezogen: »The current ecosystem around Big Data creates a new kind of digital divide: the Big Data rich and the Big Data poor« (Boyd/Crawford 2011).

Neben ihrer luziden Analysen zur digitalen Ökonomie eröffnen sie aber auch für die künftige Datenkritik eine vielversprechende Perspektive, indem sie sich von einem zentralen Glaubensgrundsatz des Informationsmanagements distanzieren, der die Entwicklung der digitalen Gesellschaften der Spätmoderne von der zunehmenden Nutzung digitaler Medien und ihrer Großdaten abhängig sieht.

3.4 | Digitale Methoden

In seinem geschichtsphilosophischen Werk *Die Ordnung der Dinge* (1974; frz. 1966) bezeichnet Michel Foucault mit dem Begriff ›**Episteme**‹ die Ordnungen des Wissens, die in einer Epoche geltend gemacht werden. Innerhalb dieser Episteme formieren sich die historisch veränderbaren Möglichkeitsbedingungen des Wissbaren und Wahrnehmbaren, die mittels gesellschaftlicher Praktiken und Diskurse vermittelt werden. In der aktuellen Theoriebildung ist man sich darin einig, dass mit dem Aufkommen der naturwissenschaftlich dominierten Ära »Big Science« (Solla Price 1963) und ihrer quantifizierenden Großdatenforschung tiefgreifende Veränderungen der Kultur und der Gesellschaft hervorgebracht werden.

Big Data: Weniger Klarheit herrscht allerdings darüber, welche konkreten Technologien, Wissensformen und Datenpraktiken diesen Medienumbruch und die damit einhergehenden gesellschaftlichen Veränderungen bedingen. Historische Kartographien dieser digitalen Regierungskunst haben herausgearbeitet, dass während der Aufbruchssituation der ›**Big Science**‹ im Rahmen des Internationalen Geophysischen Jahres (1957–1958) Weltdatenzentren (World Data Centers) geschaffen wurden, die bis heute einen richtungsweisenden Stellenwert für die Erzeugung weltweiter Datennetzwerke und die Organisation großer Datenbanken einnehmen (vgl. Aronova/Baker/Oreskes 2010).

Seit dem späten 20. Jahrhundert zählen die digitale Großforschung und ihre großen Rechnerzentren und Serverfarmen zu den zentralen Bausteinen der Herstellung, Verarbeitung und Verwaltung von informatischem Wissen (Reichert 2014, 7). Damit einhergehend rücken mediale Technologien der Datenerfassung und -verarbeitung und Medien, die ein Wissen in Möglichkeitsräumen entwerfen, in die Mitte der Wissensproduktion und der sozialen Kontrolle. In diesem Sinne kann man sowohl von *datenbasierten* als auch von *datengesteuerten* Wissenschaften sprechen, da die Wissensproduktion von der Verfügbarkeit computertechnologischer Infrastrukturen und der Ausbildung von digitalen Anwendungen und Methoden abhängig geworden ist.

Einflussreiche Theoretiker der digitalen Medien sind sich darin einig, dass sich mit dem Aufstieg und der breiten Durchsetzung der **Online-Kommunikation** und der mobilen Medien nicht nur die Alltagskommunikation verändert hat, sondern diese auch als ein Anzeichen gewertet werden kann, dass sich die Gesellschaft in einer grundlegenden Veränderung befindet (Manovich 2012; Dijck 2013). In der Ära der Big Data hat sich nicht nur der Stellenwert des gesellschaftlichen, sondern auch jener des wissenschaftlichen Wissens radikal verändert. Soziale Netzwerke, mobile Medien und technische Assistenzsysteme fungieren heute als gigantische Datensammler und als relevante Datenquellen der digitalen Kommunikationsforschung: »Social media offers us the opportunity for the first time to both observe human behavior and interaction in real time and on a global scale« (Golder/Macy 2012, 7).

Die großen Datenmengen werden in verschiedenartigen Wissensfeldern gesammelt: Biotechnologie, Genomforschung, Arbeits- und Finanzwissenschaften und Trendforschung berufen sich in ihren Forschungen auf die Ergebnisse der Informationsverarbeitung der Big Data und formulieren auf dieser Grundlage aussagekräftige Modelle über den gegenwärtigen Status und die künftige Entwicklung von sozialen Gruppen und Gesellschaften. Die digitale Massendatenforschung hat sich innerhalb der letzten Jahre erheblich ausdifferenziert, und es sind zahlreiche Studien veröffentlicht worden, die mit Hilfe maschinenbasierter Verfahren wie der Textanalyse

(quantitative Linguistik), der Sentimentanalyse (Stimmungserkennung), der sozialen Netzwerkanalyse oder der Bildanalyse anderweitiger maschinenbasierter Verfahren computerbasierte Social-Media-Analysen betreiben.

Die sich neu formierende Disziplin der **Computational Social Science** (Lazer et al. 2009; Conte et al. 2012) wertet die großen Datenmengen der Online-Nutzung im Backend-Bereich aus und hat sich als eine neue Leitwissenschaft bei der Erforschung der Sozialen Medien des Web 2.0 herausgebildet. Sie bietet eine gemeinsame Plattform für die Computerwissenschaften und die Sozialwissenschaften und verknüpft die unterschiedlichen Fachexpertisen zu Informatik, Gesellschaft und kulturellen Prozessen. Die Computerwissenschaft beschäftigt sich mit der rechnerbasierten Erschließung großer Datenbestände, die mit den herkömmlichen Methoden der statistischen Sozialwissenschaften nicht mehr zu bewältigen sind. Ihr Ziel ist es, die sozialen Verhaltensmuster der Online-Nutzung auf der Grundlage spezifischer Algorithmen und Verfahren des *Data Mining* herauszuarbeiten:

»To date, research on human interactions has relied mainly on one-time, self-reported data on relationships« (Lazer et al. 2009, 722). Um diese Frage nach den sozialen Verhaltensweisen gehaltvoll beantworten zu können, benötigt die Computerwissenschaft den methodologischen Input der Sozialwissenschaften, die mit ihrem Wissen über Theorien und Methoden des sozialen Handelns einen wertvollen Beitrag bei der Formulierung relevanter Fragestellungen leisten können.

Die in den zeitgenössischen Debatten häufig anzutreffenden Figuren vom »Kontrollverlust durch Datenwachstum«, von der »Automatisierung von Entscheidungsprozessen« oder von der »Intransparenz der Datenspeicherung« können als Hinweise dafür verstanden werden, dass der Zeitdiagnose ein zentraler Stellenwert in den Theorien der digitalen Medien eingeräumt wird. Wie verhält sich die Datenproblematik angesichts der überwiegenden Digitalität der Daten? Die Digitalität der Daten führt zu einer weitreichenden Automatisierung der Datenerhebung und der Datenauswertung. Eine Vielzahl von neuen Einflüssen und Entscheidungen sind bei der Informatisierung und Digitalisierung von Daten beteiligt und haben in der Informatik die Frage aufgeworfen, wie diese Elemente, die ein Computer verarbeiten kann, beschrieben werden können.

Die Kriterien **Digitalität**, **Maschinenlesbarkeit** und die **automatische Verarbeitung** von Daten in Form numerischer Kodierungen und informatischer Operationen können als der zentrale Eigenschaftsstatus von digitalen Datensätzen verstanden werden. Inwiefern verändert die Digitalität der Datensätze die Perspektive auf Daten, Informationen und Wissen, wenn Fragen etwa nach den Ähnlichkeiten oder den Mustern von Datensätzen in den Vordergrund rücken? Diese Vorstellung von Daten als binären Nachrichten, die zur Kommunikation dienen, eröffnet für Jakob Voß die epistemische Perspektive, den Datenbegriff ohne Rekurs auf den Informationsbegriff denken zu können:

»Während bei Daten als Fakten und Daten als Beobachtungen die Frage im Vordergrund steht, welche Informationen in den Daten »enthalten« sind, ist bei Daten als digitalen Dokumenten deutlich, dass je nach Rezeptionskontext ganz unterschiedliche Inhalte im Vordergrund stehen können« (Voß 2013). Wenn der gleiche Datensatz in verschiedenen Kontexten in unterschiedlichen Repräsentationsformen auftreten kann und ungleichartige Informationen »enthalten« kann, dann steht die Vorstellung von Daten als Bits im Vordergrund und löst die Vorstellung vom Bezug der Daten zur Realität ab. Mit der umgangssprachlichen Phrase »Big Data« wurde der Wirklichkeitsverlust der Daten weiter verschärft (vgl. kritisch Floridi 2012).

An der Schnittstelle zwischen der »*computational social science*« (Lazer et al. 2009) und der »*cultural analytics*« (Manovich 2009) hat sich ein interdisziplinäres Theoriefeld herausgebildet, das die neuen Herausforderungen der digitalen Internetforschung reflektiert. Die Vertreter der sogenannten »**Digital Methods**« verfolgen den Anspruch, die Nutzungsforschung neu zu denken, indem sie die Nutzungspraktiken des Internets als kulturelle Veränderungen und als gesellschaftliche Sachverhalte interpretieren (Rogers 2011, 63). Sie vertreten die Ansicht, dass analoge Methoden, die zur Erforschung interpersonaler oder Massenkommunikation entwickelt wurden, nicht einfach auf digitale Kommunikationspraktiken übertragen werden können. Als Digitale Methoden lassen sich Ansätze verstehen, die nicht schon bestehende Methoden für die Internetforschung adaptieren, sondern die genuinen Verfahrensweisen digitaler Medien aufgreifen. Es handelt sich folglich um Forschungsansätze, die sich große Mengen digitaler Kommunikationsdaten zunutze machen, um diese mit computergestützten Verfahren zu modellieren.

Sowohl der Ansatz der »Computational Social Science« als auch die Überlegungen der »Digital Methods« stehen für die fundamentale Annahme, dass man von den Daten ausgehend, die Social-Media-Plattformen erzeugen, neue Einsichten in menschliches Verhalten bzw. soziale Sachverhalte jenseits dieser Plattformen bzw. ihrer Software erlangen kann. Zahlreiche Repräsentanten der computerbasierten Sozial- und Kulturwissenschaften vertreten die Annahme, dass man Online-Daten als soziale **Gegebenheiten** interpretieren könne. Damit fixieren sie die Praktiken der Internet-Nutzung mit Hilfe eines positivistischen Datenbegriffs, der die Nutzerpraktiken als Ausdruck einer spezifizierbaren sozialen Handlung versteht. Der soziale Positivismus der »Computational Social Science« von Social-Media-Plattformen vernachlässigt allerdings die sinnstiftende und handlungsanweisende Rolle der Medien bei der Hervorbringung sozialer Rollen und stereotyper Handlungsformen im Umgang mit dem Medium. In dieser Hinsicht kann der soziale Behaviorismus der Online-Forschung hinsichtlich seiner Objektivitätspostulate in Frage gestellt werden.

Die Vision einer solchen nativ-digitalen Forschungsmethodik, ob in Gestalt einer »Computational Social Science« (Lazer 2009) oder von »Cultural Analytics« (Manovich 2009) ist jedoch noch unvollständig und verlangt nach einer epistemischen Befragung der digitalen Methoden in der Internetforschung folgender Bereiche:

1. Digitale Methoden als **geltungstheoretisches Projekt**: Dieses steht für ein bestimmtes Verfahren, das soziale Geltung von Handlungsorientierungen beansprucht. Die Wirtschaftsinformatik, die Computerlinguistik und die empirische Kommunikationssoziologie bilden nicht nur ein Geflecht wissenschaftlicher Felder und Disziplinen, sondern entwickeln in ihren strategischen Verbundprojekten bestimmte Erwartungsansprüche, die soziale Welt erklärend zu erschließen und sind insofern intrinsisch verbunden mit epistemischen und politischen Fragen. Vor diesem Hintergrund setzt sich eine das Selbstverständnis der digitalen Methoden befragende Epistemologie mit der sozialen Wirkmächtigkeit der digitalen Datenwissenschaften auseinander.

2. Digitale Methoden als **konstitutionstheoretisches Konstrukt**: Der Gegenstandsbezug der Big Data-Forschung ist heterogen und setzt sich aus unterschiedlichen Methoden zusammen. Mit ihren Technologien der Schnittstellen, den Verfahren des Datentrackings, des Keyword-Trackings, der automatischen Netzwerkanalyse, der Sentiment- und Argumentanalysen oder dem maschinenbasierten Lernen ergeben sich daher kritische Perspektivierungen der Datenkonstrukte. Vor diesem Hintergrund versuchen die Critical Code Studies, die medialen Techniken von infor-

matischen Machtverhältnissen sichtbar zu machen und untersuchen die technisch-infrastrukturellen Regulative von Layermodellen, Netzwerkprotokollen, Zugangspunkten und Algorithmen.

3. Digitale Methoden können letztlich auch als eine **gründungstheoretische Fiktion** aufgefasst werden. Die einschlägige Forschungsliteratur hat sich eingehend mit der Reliabilität und der Validität der wissenschaftlichen Datenerhebung beschäftigt und ist zum Ergebnis gekommen, dass die Datenschnittstellen des Social Net (Twitter, Facebook, YouTube) mehr oder weniger als dispositive Anordnungen fungieren. Denn als Filterschnittstellen erzeugen die API's (*application programming interfaces*) ökonomisch motivierte Exklusionseffekte für die Netzforschung, die von ihr aus eigener Kraft nicht kontrolliert werden können.

Lazer et al. fordern von künftigen *computer scientists* einen verantwortungsvollen Umgang mit zugänglichen Daten und sehen in einem fahrlässigen Umgang große Gefahren für die Zukunft der Disziplin selbst:

»A single dramatic incident involving a breach of privacy could produce a set of statutes, rules, and prohibitions that could strangle the nascent field of computational social science in its crib. What is necessary, now, is to produce a self-regulatory regime of procedures, technologies, and rules that reduce this risk but preserve most of the research potential« (Lazer et al. 2009, 722).

Wenn es um die Erforschung sozialer Zusammenhänge mit Hilfe von Computer Science und Big Data geht, dann rückt der verantwortungsvolle Umgang mit Daten und die Beachtung datenschutzrechtlicher Vorgaben auch in die Theoriebildung ein. Insofern haben sich vor dem Hintergrund des digitalen Wandels von Wissen, Macht und Ökonomie die Erwartungen an die Theorien der digitalen Methoden des 21. Jahrhunderts maßgeblich verändert. In den Debatten werden zunehmend Forderungen laut, die darauf bestehen, die historisch, sozial und ethisch einflussreichen Aspekte der digitalen Datenpraktiken systematisch aufzuarbeiten – verknüpft mit dem Ziel, diese künftig in den digitalen Wissenschaftskulturen der Datenerzeugung und -analyse nachhaltig zu verankern.

Literatur

- Andrejevic, Mark: »The work of being watched: Interactive media and the exploration of self-disclosure«. In: *Critical Studies in Media Communication* 19/2 (2002), 231–248.
- Aronova, Elena/Baker, Karen/Oreskes, Naomi: »Big Science and Big Data in biology: From the International Geophysical Year through the International Biological Program to the Long-Term Ecological Research Program, 1957-present«. In: *Historical Studies in the Natural Sciences* 40/2 (2010), 183–224.
- Baudrillard, Jean: *Der symbolische Tausch und der Tod*. München 1982.
- Bollier, David: *The Promise and Peril of Big Data*. Washington, DC 2012. Online: http://www.aspeninstitute.org/sites/default/files/content/docs/pubs/The_Promise_and_Peril_of_Big_Data.pdf.
- Boyd, Danah/Crawford, Kate: »Six provocations for Big Data«. In: *Conference Paper, A Decade in Internet Time: Symposium on the Dynamics of the Internet and Society*. Oxford 2011. Online: http://papers.ssrn.com/sol3/papers.cfm?abstract_id=1926431.
- Bredenkamp, Horst: *Die Fenster der Monade. Gottfried Wilhelm Leibniz' Theater der Natur und Kunst*. Berlin 2008.
- Bush, Vannevar: »Wie wir denken werden« [1945]. In: Karin Bruns/Ramón Reichert (Hg.): *Reader Neue Medien. Texte zur digitalen Kultur und Kommunikation*. Bielefeld 2007, 106–125.
- Chun, Wendy H.: »On ›Sourcery‹, or code as fetish«. In: *Configurations* 16 (2008), 299–324.
- Chun, Wendy H.: *Programmed Visions: Software and Memory*. Cambridge 2011.
- Cioffi-Revilla, Claudio: »Computational social science«. In: *Wiley Interdisciplinary Reviews: Computational Statistics* 2/3 (2010), 259–271.

- Conte, Rosaria et al.: »Manifesto of computational social science«. In: *European Physical Journal: Special Topics* 214 /1 (2012), 325–346.
- Coy, Wolfgang: *Zur Ortsbestimmung analoger und digitaler Medien*. Bielefeld 2005.
- Dijk, José van: *The Culture of Connectivity: A Critical History of Social Media*. Oxford 2013.
- Driscoll, Kevin: »From punched cards to »Big Data«: A social history of database populism«. In: *Communication + 1/1* (2012). Online: <http://kevindriscoll.info/>.
- Esposito, Elena: »Illusion und Virtualität: Kommunikative Veränderungen der Fiktion«. In: Werner, Rammert (Hg.): *Soziologie und Künstliche Intelligenz*. Frankfurt a. M. 1995, 187–216.
- Essinger, James: *Jacquard's Web. How a Hand-loom led to the Birth of the Information Age*. New York/Oxford 2004.
- Faulstich, Werner: *Medientheorien*. Göttingen 1991.
- Florida, Luciano: »Big Data and their epistemological challenge«. In: *Philosophy of Information* 25 (2012), 435–437.
- Flückiger, Barbara: *Visual Effects. Filmbilder aus dem Computer*. Marburg 2008.
- Foucault, Michel: *Die Ordnung der Dinge. Eine Archäologie der Humanwissenschaften*. Frankfurt a. M. 1974.
- Fuller, Matthew: *Behind the Blip: Essays on the Culture of Software*. London 2003.
- Fuller, Matthew: *Software Studies: A Lexicon*. Cambridge, Mass. 2008.
- Galloway, Alexander: *Protocol. How Control Exists after Decentralization*. Cambridge, Mass. 2004.
- Gillespie, Tarleton: »The relevance of algorithms«. In: Tarleton Gillespie/Pablo Boczkowski/Kirsten Foot (Hg.): *Media Technologies*. Cambridge, Mass. 2012.
- Gitelman, Lisa/Jackson, Virginia: »Raw data« Is an Oxymoron. Cambridge, Mass 2013.
- Gitelman, Lisa/Pingree, Geoffrey B.: *New Media: 1740–1915*. Cambridge, Mass. 2004.
- Golder, Scott/Macy, Michael: »Social Science with Social Media«. In: *footnotes* 40/1 (2012). Online: http://www.asanet.org/footnotes/jan12/socialmedia_0112.html.
- Kippenhahn, Rudolf: *Code Breaking: A History and Exploration*. Woodstock 1999.
- Kippenhahn, Rudolf: *Mechanisms: New Media and the Forensic Imagination*. Cambridge Mass 2008.
- Kirschenbaum, Matthew G.: »Extreme inscription: Towards a grammatology of the hard drive«. In: *TEXT Technology* 2/1 (2004), 91–125.
- Kittler, Friedrich: *Aufschreibesysteme 1800/1900*. München 1985.
- Kittler, Friedrich: *Grammophon. Film. Typewriter*. Berlin 1986.
- Kittler, Friedrich: *Phänomenologie versus Medienwissenschaft* (1989).
- Kittler, Friedrich: »Es gibt keine Software«. In: Friedrich Kittler (Hg.): *Draculas Vermächtnis. Technische Schriften*. Leipzig 1993, 225–242.
- Kittler, Friedrich: »Wenn die Freiheit wirklich interessiert, dann soll sie heraus. Friedrich Kittler im Gespräch mit Rudolf Maresch«. In: Rudolf Maresch (Hg.): *Am Ende vorbei*. Wien 1994, 95–129.
- Krämer, Sybille: *Symbolische Maschinen. Die Idee der Formalisierung in geschichtlichem Abriss*. Darmstadt 1988.
- Krämer, Sybille: »Zentralperspektive, Kalkül, Virtuelle Realität. Sieben Thesen über die Weltbildimplikationen symbolischer Formen«. In: Gianni Vattimo/Wolfgang Welsch (Hg.): *Medien-Welten. Wirklichkeiten*. München 1998a, 27–37.
- Krämer, Sybille (Hg.): *Medien Computer Realität. Wirklichkeitsvorstellungen und Neue Medien*. Frankfurt a. M. 1998b.
- Lazer, David et al.: »Computational Social Science«. In: *Science* 323/5915 (2009), 721–723.
- Leary, Timothy: »Das interpersonale, interaktive, interdimensionale Interface«. In: Karin Bruns/Ramón Reichert (Hg.): *Reader Neue Medien. Texte zur digitalen Kultur und Kommunikation*. Bielefeld 2007, 126–131.
- Loleit, Simone: »»The Mere Digital Process of Turning over Leaves«. Zur Wort- und Begriffsgeschichte von »digital«. In: Jens Schröter/Alexander Böhnke (Hg.): *Analog/Digital – Opposition oder Kontinuum? Zur Theorie und Geschichte einer Unterscheidung*. Bielefeld 2004, 193–214.
- Lyon, David: *The Electronic Eye: The Rise of Surveillance Society*. Minneapolis 1994.
- Lyon, David: *Surveillance Society: Monitoring Everyday Life*. New York 2001.
- Mackenzie, Adrian: *Cutting Code: Software and Sociality*. Oxford 2006.
- Manovich, Lev: »How to follow global digital cultures: Cultural analytics for beginners«. In: Konrad Becker/Felix Stalder (Hg.): *Deep Search: The Politics of Search beyond Google*. Edison, NJ. 2009, 198–212.
- Manovich, Lev: »Trending: The promises and the challenges of Big Social Data«. In: Matthew K. Gold (Hg.): *Debates in the Digital Humanities*. Minneapolis 2012, 460–475.
- Munster, Anna: *Materializing New Media: Embodiment in Information Aesthetics*. Dartmouth 2006.
- Nahin, Paul J.: *The Logician and the Engineer: How George Boole and Claude Shannon Created the Information Age*. Princeton 2012.

- Ndalianis, Angela: *Neo-Baroque Aesthetics and Contemporary Entertainment*. Cambridge, Mass. 2005.
- Negroponce, Nicholas: *Being Digital*. New York 2012.
- Neumann, John von: »First draft of a report on the EDVAC«. In: *IEEE Annals of the History of Computing* 15/4 (1993), 27–75.
- Reetze, Jan: *Medienwelten: Schein und Wirklichkeit in Bild und Ton*. Berlin u. a. 1993.
- Reichert, Ramón: *Big Data. Analysen zum digitalen Wandel von Wissen, Macht und Ökonomie*. Bielefeld 2014.
- Rheingold, Howard: *Smart Mobs: The Next Social Revolution*. Cambridge 2002.
- Rieger, Stefan: *Speichern, Merken. Die künstlichen Intelligenzen des Barock*. München 1997.
- Rogers, Richard: *Digital Methods*. Cambridge, Mass. 2013.
- Rotman, Brian: *Die Null und das Nichts. Eine Semiotik des Nullpunktes*. Berlin 2000.
- Rötzer, Florian: *Digitaler Schein. Ästhetik der elektronischen Medien*. Frankfurt a. M. 1996.
- Rusch, Gebhard: »Mediendynamik. Explorationen zur Theorie des Medienwandels«. In: *Navigationen* 1/2007 (2011), 13–93.
- Schmidt, Siegfried J.: »Konstruktivismus in der Medienforschung: Konzepte, Kritiken, Konsequenzen«. In: Klaus Merten/Siegfried J. Schmidt/Siegfried Weischenberg (Hg.): *Die Wirklichkeit der Medien*. Opladen 1994, 592–623.
- Schröter, Jens: »Analog/ Digital – Opposition oder Kontinuum?«. In: Jens Schröter/Alexander Böhnke (Hg.): *Analog/ Digital – Opposition oder Kontinuum?* Bielefeld 2004, 7–30.
- Solla Price, Derek de: *Little Science, Big Science*. New York 1963.
- Turing, Alan: »On computable numbers, with an application to the Entscheidungsproblem«. In: *Proceedings of the London Mathematical Society* 2/42 (1936–7), 230–265.
- Turkle, Sherry: *Life on the Screen: Identity in the Age of the Internet*. New York 1995.
- Turkle, Sherry: *Alone Together*. New York 2011.
- Van Dijck, José: *The Culture of Connectivity: A Critical History of Social Media*. Oxford 2012.
- Voß, Jakob: »Was sind eigentlich Daten?«. In: *LIBREAS. Library Ideas* 23 (2013). Online: <http://libreas.eu/ausgabe23/02voss/>
- Wardrip-Fruin, Noah: *Expressive Processing*. London 2011.
- Warnke, Martin: *Theorien des Internet zur Einführung*. Hamburg 2011.
- Yates, Frances A.: *The Art of Memory*. London 1966.

Ramón Reichert

4 Aufbau des Computers und Vernetzung

4.1 | Aufbau eines Computers

Grundlage der computergestützten Arbeit in den Geisteswissenschaften ist die Datenverarbeitung, d. h. das Prinzip, dass jedes Problem, das sich mathematisch beschreiben lässt, auch mit einer Maschine zu lösen ist. Alan Turing definierte dafür ein universelles Automatenmodell. Darin lassen sich alle Rechenvorschriften in das Modell der **Turing-Maschine** überführen. Um Daten mit dieser Maschine verarbeiten zu können, müssen diese zunächst als Bitfolgen vorliegen, auf die dann in einem zweiten Schritt Algorithmen angewendet werden, um diese Daten mit entsprechenden Anweisungen zu verarbeiten.

Wie eine solche universelle Rechenmaschine aufgebaut ist, ist eine Frage ihrer Architektur, welche die Eingabe, Berechnung und Ausgabe sowie die Programmierung des Rechners erlaubt. Heutige Computer, etwa Schreibtischrechner oder auch Mobilcomputer (Laptop, Smartphone), bauen auf derselben Architektur auf, die aus Prozessoreinheit, Speicherelementen, weiteren Chips für spezielle Aufgaben sowie Anschlüssen und Peripheriegeräten besteht.

Datenverarbeitung allgemein: Daten im Binärsystem (auch Dualsystem genannt) darzustellen, bedeutet, eine Folge von Nullen und Einsen zu erzeugen. Diese können – ähnlich wie im Dezimalsystem – mithilfe von Rechenregeln verarbeitet werden. Da Dezimalzahlen in Binärzahlen umgewandelt werden können, kann auf diese Weise gerechnet werden (s. Kap. 5 zu »Zahlen und Zeichen«). Der Vorteil ist, dass Binärzahlen, die technisch »Spannung ein« (1) bzw. »Spannung aus« (0) bedeuten können, beliebige Inhalte, wie Bilder oder Töne, repräsentieren können, die gespeichert und verarbeitet werden. Die Zweiwertigkeit liegt auch in Booleschen Variablen vor, die ebenfalls nur zwei Werte annehmen (wahr/falsch) und mithilfe der Booleschen Algebra verarbeitet werden können. Auf eine Maschine übertragen, spricht man von einer **Schaltalgebra**, die mit »Spannung an«/»Spannung aus« arbeitet und die Rechenoperationen mit hoher Geschwindigkeit verarbeiten kann. Zur Verarbeitung einer oder mehrerer Eingangsbitfolgen (A, B), z. B. einer Rechenaufgabe bestehend aus Werten und Anweisungen, zu einer Ausgangsbitfolge (Y), z. B. dem Rechenergebnis, kann die Logik auf eine Kombination von nur drei verschiedenen Schaltfunktionen reduziert werden, die auf einer Rechenmaschine implementiert werden muss (entwickelt von Willard Van Orman Quine und Edward J. McCluskey; vgl. McCluskey 1956):

- **NOT:** Negation
- **AND:** Konjunktion
- **OR:** Disjunktion




Abb. 1 NOT-, AND- und OR-Funktion als Wahrheitstabelle und Schaltsymbol

Diese Funktionen liegen allen weiteren, komplexeren Funktionen zugrunde, so dass bei der technischen Umsetzung tatsächlich nur diese drei Schaltungen konstruiert werden müssen. Solche Schalter befinden sich heute im Prozessorchip (**CPU**).

Prozessor: Schalterkombinationen dieser Logik waren zunächst selbst große Maschinen. So konstruierte Konrad Zuse im Jahr 1937 mithilfe von beweglichen Blechen einen ersten Computer mit frei programmierbarem Rechenwerk, das mit binären Zahlen arbeitete. Üblicher, weil zuverlässiger, wurden elektromagnetische Relais, die Eingangssignale zu Ausgangssignalen verarbeiteten. Da diese sich jedoch mechanisch bewegen, ist mit der Rechengeschwindigkeit schnell eine Grenze erreicht, und die Relais wurden durch Elektronenröhren abgelöst. Der in den Jahren 1942 bis 1946 entwickelte, zimmergroße ENIAC basierte auf der Elektronenröhre.

Der **Transistor** (*transfer resistor*), welcher von 1946 bis 1949 von William B. Shockley, Walter H. Brattain und John Bardeen (Nobelpreis für Physik, 1956) entwickelt wurde (Shockley 1956), ist das zentrale Bauelement eines Elektronenrechners, da er mittels eines Halbleiters einen Stromfluss mithilfe eines anderen Stromflusses regulieren kann. Im Gegensatz zu vorigen Technologien kommt der Transistor ohne bewegliche Teile aus, ist auf diese Weise schneller, kostengünstiger und kann so für logische Schaltungen verwendet werden.

Die Rechenoperationen werden im Computer mittels Transistoren ausgeführt. So sind beispielsweise für eine AND-Schaltung drei Transistoren notwendig. Die Fertigung von hochminiaturisierten Transistor-Schaltkreisen auf Silizium-Basis führte schließlich zu den heute eingesetzten **Mikrochips** (seit 1959). Die Möglichkeit der schnellen und vergleichsweise günstigen Fertigung einer großen Anzahl kompakter Transistoren in stromsparender Bauweise ermöglichte eine Massenproduktion, die zu einem Einsatz dieser Technik in immer mehr Bereichen führte. Marktführer ist weiterhin das Unternehmen Intel sowie im Mobilbereich das Unternehmen ARM, das Prozessorchips nicht selbst herstellt, sondern für deren Architektur Lizenzen vergibt. Gordon Moore, Mitbegründer von Intel, beobachtete, dass sich die Komplexität von Prozessoren und damit ihre Rechengeschwindigkeiten alle 12 bis 18 Monate verdoppeln. Diese als »Moore'sches Gesetz« bekannt gewordene Prognose ist seit seiner Veröffentlichung im Jahr 1965 bis heute gültig und lässt sich entsprechend auch auf die Kapazitäten von Massenspeichern übertragen.

John von Neumann definierte 1945 folgende Regeln, nach denen ein frei programmierbarer Rechner aufgebaut ist:

1. Es werden folgende Komponenten getrennt: Steuerwerk, Rechenwerk, Speicher, Ein- und Ausgabegeräte.
2. Die Struktur ist getrennt von den zu verarbeitenden Inhalten.
3. Im Speicher liegen Programme und Daten.
4. Der Speicher ist durchlaufend adressiert und damit eindeutig zugreifbar.
5. Ein Programm ist eine Befehlsfolge, die nacheinander ausgeführt wird und nicht die Daten, nur deren Adressen enthält.
6. Die Befehlsfolge kann durch Sprünge, die von Daten abhängig sind, von der Reihenfolge abweichen.
7. Es wird Binärcode verwendet.

Nach diesen sieben Prinzipien sind heute praktisch alle Rechner – vom Taschenrechner bis zum Großrechner – aufgebaut. Der Vorteil liegt darin, dass das Programm nicht fest vorgegeben ist, sondern zusammen mit den Daten ebenfalls im Speicher liegt und so während der Laufzeit verändert werden kann. Die Architektur




Abb. 2 Schema des Aufbaus eines Von-Neumann-Rechners

der allgemeinen Rechnerarchitektur, die als Von-Neumann-Rechner bezeichnet wird und Grundlage praktisch aller heutigen Computer ist, besteht aus folgenden Elementen:

Die **Zentraleinheit** beschreibt das Prinzip der zentralen Recheneinheit, die heute in Form der Prozessoren (Central Processing Unit, CPU) realisiert sind. Diese erhalten ihre Daten aus einem Speicher, der mittels eines sogenannten Datenbusses mit dem Prozessor verbunden ist und die zu bearbeitenden Daten sowie das Befehlsprogramm enthält. Ähnlich wie der Prozessor ist auch der Speicher in Form von Speicherchips in einem Computergehäuse auf einer elektronischen Platine verbaut. Zudem dienen ein Eingabe- und ein Ausgabewerk der Bedienung und dem Ablesen von Ergebnissen. Dies kann beispielsweise mit einer Tastatur bzw. einem Bildschirm realisiert werden.

Das **Steuerwerk** als Teil der Zentraleinheit koordiniert und kontrolliert den Ablauf der Operationen, liest Befehle aus dem Arbeitsspeicher, interpretiert sie und gibt sie an das Rechenwerk oder den Speicher weiter. So wird das Programm in den Arbeitsspeicher geladen, der erste Befehl in ein Register geladen und entschlüsselt. Ist darin angegeben, Daten zu laden, werden diese ebenfalls in ein Register geholt. Anschließend wird das Rechenwerk mit der auszuführenden Operation beschäftigt. Dies wird wiederholt, bis das Programmende erreicht ist. Die logischen Arbeitseinheiten liegen in Schaltnetzen vor, die schaltungstechnisch die Boolesche Algebra umsetzen. Das Schaltnetz verknüpft die Eingangsvariablen in Form von Spannungswerten (»an« für 1 und »aus« für 0) mit einer Booleschen Funktion zu Ausgangsvariablen. Diese können wiederum Eingangswerte für weitere Gitter sein, die zu komplexen Schaltwerken zusammengeschlossen werden können.

Ein **Register** dient zur Speicherung kleiner Mengen an Daten und Befehlen bei der Übergabe vom Speicher zum Rechenwerk. Das Ergebnis findet sich ebenfalls zunächst in einem Register und wird anschließend in den Hauptspeicher geschrieben. Der Befehlszähler ist ein Register, das die Adresse des nächsten Befehls enthält. Der Decoder überführt die Befehle in Anweisungen für die Maschine, die Schaltungen im Chip entsprechen. Das Befehlsregister enthält die Befehle, Werte und Ergebnisse für das Rechenwerk. Ein 64-bit-Prozessor hat eine Registerbreite von 64 Bit und kann so-



Abb. 3 Speicherchip am Beispiel eines nichtflüchtigen, reprogrammierbaren Speichers (EPROM) aus dem Jahr 1984. Deutlich sichtbar der Chip mit Zuleitungen sowie die sockelbasierte Bauweise

mit theoretisch in einem Takt doppelt so viele Daten verarbeiten wie ein 32-bit-Prozessor (in der Praxis ist dies nicht unbedingt der Fall). Die Taktrate gibt die Rechengeschwindigkeit an. Beispiel: Der Homecomputer Commodore 64 aus dem Jahr 1982 lief mit einer Taktrate von bis zu 1,023 MHz, das iPhone 6S aus dem Jahr 2015 mit 1,86 GHz über 1800 Mal so schnell.

Während ein **Prozessor** Instruktionen nacheinander verarbeitet, ist es auch möglich, zwei oder mehr Prozessoren parallel zu schalten. Auf diese Weise lässt sich die Verarbeitung voneinander unabhängiger Prozesse erhöhen. Ein Geschwindigkeitsgewinn ist jedoch nur dann gegeben, wenn die seriellen Prozesse auch parallelisierbar sind, also einzelne Prozesse nicht auf das Ergebnis anderer Prozesse warten müssen. Ein Beispiel parallelisierbarer Prozesse ist die Grafikerzeugung, bei der Pixel unabhängig voneinander berechnet werden können. Daher sind spezialisierte Grafik-Chips häufig Parallelprozessoren. In anderen Prozessen, in denen ein Befehl auf das Ergebnis der vorhergehenden Auswertung warten muss, ist dies jedoch nur eingeschränkt möglich. Teilaufgaben müssen bereits in der Programmierung zerlegt werden, um gleichzeitig verarbeitet werden zu können.

Speicher und Bus: Der Arbeitsspeicher dient der Ablage von Binärdaten, auf die das Steuerwerk zugreift. Häufig benötigte Daten werden üblicherweise in einem Cache gepuffert, um schnelleren Zugriff darauf zu haben. Im Arbeitsspeicher hat jede Speicherstelle eine eindeutige Adresse. Jedes Schaltelement entspricht 1 Bit, das auf 0 oder 1 geschaltet werden kann. Die Kapazität des Chips entspricht daher der Formel 2^n mit n der Anzahl an Schaltelementen. Diese liegen heute häufig bei 4GB, also 4×2^{30} Byte = 4.294.967.296 Byte (streng genommen handelt es sich hierbei entsprechend der IEC-Präfixe um Gibibyte). Beispiel: Der Homecomputer Commodore 64 besaß 64 KB Speicher, ein Apple iPhone 6S 2 GB.

Im Computer werden schnelle dynamische Speicher verwendet, die ihre Daten bei Stromabschaltung verlieren. Im Gegensatz dazu behalten statische Speicher die Informationen auch wenn sie von der Spannung getrennt werden (z. B. Flash-Speicher).

Die Verbindung von Zentraleinheit und Ein- und Ausgabegeräten wird über ein Bussystem betrieben, das von einem eigenen Prozessor gesteuert wird und dessen Taktrate und Bitbreite entscheidende Faktoren in der Geschwindigkeit des Gesamtrechners darstellen.




Abb. 4 Bussystem

Das Bussystem ermöglicht es auch, weitere Bauteile, wie beispielsweise Netzwerkkarten, Soundkarten, Grafikkarten etc. in das System zu integrieren und damit modular um weitere Funktionen zu erweitern.

4.2 | Eingabeperipherie, Ausgabeperipherie, Speicherperipherie

Eingabeperipherie: In ein solches System müssen Daten und Programm ein- und Ergebnisse ausgegeben werden können. Dazu dienen verschiedene Peripheriegeräte. Zu den Eingabegeräten gehört zunächst die **Tastatur**, die textliche Eingabe durch Menschen ermöglicht. Die Bedienung einer klassischen graphischen Benutzeroberfläche mit Desktop-Metapher wird üblicherweise über die von Douglas Engelbart im Jahr 1963 entwickelte **Computermaus** gesteuert, die einen Pfeil in x- und y-Richtung über die Oberfläche steuert und Klick-Ereignisse erzeugt. Andere Bauformen sind der Trackball, der mithilfe einer Kugel häufig präziser in der Eingabe ist und daher in der Grafikverarbeitung eingesetzt wird, oder einem Trackpad, über das per Finger-geste virtuelle Objekte zu manipulieren sind. Im Gaming-Bereich ist ein Joystick üblich wie auch Steuerungen, die Bewegungsgesten an das System weiterleiten können.

Seit dem Jahr 2007 ist für Mobilgeräte vor allem der **Touchscreen** üblich geworden, der den Mauspfeil obsolet macht, da Objekte per Fingerberührung virtuell direkt bewegt und berührt werden können. Zudem erlaubt er die Verwendung einer virtuellen Tastatur, die nach Bedarf ein- und ausgeblendet werden kann. Inzwischen ebenfalls im breiten Markteinsatz ist die Spracheingabe, die vor allem im mobilen Bereich eine Texteingabe erleichtert, da eine Stifteingabe mit Schrifterkennung aufgrund der kleinen Bauformen weniger sinnvoll ist. Weitere **Human-Machine-Interfaces** (HMI) sind in der Entwicklung. Vor allem Virtual-Reality- und Augmented-Reality-Headsets sind in den nächsten Jahren zu erwarten. Dies bedeutet, dass ein teiltransparentes Stereodisplay sowohl reale Objekte erkennen, wie auch virtuelle Objekte im Raum erscheinen und diese dann miteinander interagieren lassen kann.

Für die Bildverarbeitung von besonderer Bedeutung sind Scanner und Kameras. **Scanner** tasten Text- oder Bildmedien zeilenweise nach Helligkeitswerten im RGB-Teilspektrum ab, die über einen Analog-Digital-Wandler als Daten abgelegt werden (zu Auflösung, Farbqualität und Farbtiefe s. Kap. 12.1). Ebenso können **Kameras**, die in Mobilgeräten häufig in das Gerät integriert sind, Bilder an das System




Abb. 5 Pixelmatrix eines TFT-Monitors

übertragen. Nach dem Prinzip der Camera Obscura wird die Szene auf eine Fläche projiziert, die aus zeilenweise aufgebauten und mit RGB-Filtern versehenen Lichtsensoren besteht (Bayer-Filter), deren Spannung je nach Helligkeit variiert und ebenfalls über einen Analog/Digital-Wandler als Datei abgelegt wird. Zunehmend kommen 3D-Scanner zum Einsatz, die mit ihrem Sensor beispielsweise Körperbewegungen aufnehmen und als Befehlseingabe interpretieren können (s. auch Kap. 12.1).

Ausgabeperipherie: Zu den Ausgabemedien gehört vor allem der Bildschirm. Längst ist die Kathodenstrahlröhre (CRT) durch Flachbildschirme abgelöst worden. Vor allem Thin-Film-Transistor (TFT) und Flüssigkeitskristall-Bildschirme (LCD) sind in Gebrauch. Zunehmend steigt die Bedeutung von organischen Polymeren (OLED). Gemeinsam haben diese Technologien, dass sie das Bild augenfreundlich, da flimmerfrei auf einer planen Ebene wiedergeben und keine elektromagnetischen Strahlungen abgeben.

Dabei werden die Bildinhalte in Bildelemente (Pixel) aufgelöst, die über einen Grafik-Chip angesteuert werden und Farben mithilfe der RGB-Subpixel wiedergeben. RGB steht für die Farbanteile der additiven Farbmischung: Rot, Grün und Blau. Auf Mobilgeräten geht die Tendenz zu höherer Auflösung pro Zoll (dpi), bei Desktop-Rechnern vor allem zu einer höheren Gesamtpixelzahl von inzwischen nicht selten 33,2 Megapixel (7680×4320 entspricht 8K UHD).

Ähnlich wie ein Display funktioniert ein **Beamer** (oder auch Videoprojektor genannt), der das Bild auf eine Oberfläche projiziert. Dieser kann nach unterschiedlichen Prinzipien funktionieren. LCD-Projektoren verwenden Pixelmatrizen, die mit einem Linsensystem durchleuchtet werden. DLP-Projektoren (Digital Light Processing) verwenden kleine kippbare Spiegel, die das Licht ablenken. Auch hier geht die Tendenz zur Miniaturisierung. Sogenannte Pico-Projektoren sind inzwischen in handlichem Format mit für viele Anwendungen ausreichender Lichtstärke zu haben. Aufgrund der hohen Verbreitung boten Flachbildschirme und Beamer noch lange einen VGA-Anschluss an. Das analoge Signal wurde durch die Grafikkarte erzeugt, um analoge Röhrenbildschirme zu betreiben. Jedoch ist für den Signallauf zwischen Computer und dem ebenfalls digital arbeitenden Monitor eine Analogwandlung sowie Rückumwandlung notwendig, die vor allem zu einem Schärfeverlust führen kann und noch dazu höhere Bildschirmauflösungen nicht unterstützt. Daher wurde **DVI** (Digital Visual Interface) entwickelt, das sowohl digitale wie analoge Signale übertragen kann. In der Unterhaltungsindustrie ist der **HDMI**-Standard verbreitet



Abb. 6 Festplatte. Deutlich sichtbar die Metallplatte sowie die Schreib-/Leseköpfe

(High Definition Multimedia Interface), der sehr hohe Datenübertragungsraten und Auflösungen sowie ein Digital Rights Management (Kopierschutz) unterstützt.

Sollen Informationen nicht auf dem Bildschirm, sondern auf Papier ausgegeben werden, ist ein **Drucker** notwendig sowie ein sogenannter **Treiber**, der die Inhalte in einer Form weiterleitet, die der Drucker als Vorlage des Drucks verwenden kann. Im Einsatz sind heute vor allem preiswerte Tintenstrahldrucker, die durch eine Düse Farbtropfen auf das Papier sprühen. Auf diese Weise lassen sich leicht Farbdrucke erstellen, indem die Farben CMYK (die Farbanteile der subtraktiven Farbmischung: Cyan, Magenta, Yellow und Schwarz »Key«) auf das Papier gebracht werden. Laserdrucker erhalten die Druckinformationen meist in der Seitenbeschreibungssprache **PostScript**, die bestimmt, an welchen Stellen der Laserstrahl eine negativ geladene Walze zeilenweise entlädt. An den verbleibenden geladenen Stellen haftet das Tonerpulver und wird auf das positiv geladene Papier übertragen und dort per Hitze fixiert. Zunehmend sind auch 3D-Drucker verfügbar, die aufgrund von 3D-Daten schichtweise ein Objekt extrudieren. Hier nicht weiter beschrieben sind Geräte der Audio-Ausgabe über Soundkarte und Lautsprecher.

Standard der Datenübertragung zu Peripheriegeräten ist heute der USB-Anschluss (Universal Serial Bus), der als USB 2.0 Übertragungsgeschwindigkeiten von bis zu 480 MBit/s erreicht, USB 3.0 sogar bis zu 5 Gbit/s. Vorteil gegenüber älteren Systemen ist, dass das Kabel nicht nur Daten überträgt, sondern auch eine Spannungsversorgung anbietet. Auf diese Weise ist es möglich, externe Festplatten oder USB-Sticks ohne zusätzliches Stromkabel zu betreiben oder den Akku eines Mobilgeräts an diesem Port aufzuladen. Die Thunderbolt-Verbindung übersteigt die Datenraten noch, kann zudem Bildschirminformationen übertragen und ist mit älteren Standards protokollkompatibel. Um dies zu erreichen, sind in ein Thunderbolt-Kabel mehrere Prozessoren integriert.

Speicherperipherie: Auf Massendatenträgern können Daten in großen Mengen dauerhaft gespeichert werden. Dabei kommen vor allem sogenannte **Festplatten** zum Einsatz. Der Name ist nicht auf das Fehlen beweglicher Teile zurückzuführen, sondern auf die Festigkeit der rotierenden Platten (*hard disc*) im Gegensatz zur Floppy-Disc (*floppy* = schlaff). Dabei wird mithilfe eines Schreib-/Lesekopfes, der sich aerodynamisch in sehr geringem Abstand über die Platte bewegt, induktiv die Oberfläche an den jeweiligen Stellen magnetisiert oder entmagnetisiert und so 0- und 1-Werte geschrieben bzw. gelesen. Heute werden sie zunehmend von Flash-Speichern abgelöst, da diese schneller und aufgrund des Fehlens beweglicher Teile

(*Solid State*) stromsparender sind. Hinzu kommt, dass sie nicht mehr magnetisch arbeiten und so sicher vor magnetischen Einflüssen sind und inzwischen ebenfalls im Gigabyte-Bereich zu konkurrenzfähigen Preisen angeboten werden können.

4.3 | Computertypen

Als »Computer« wird hier der Typ von Rechner bezeichnet, der nach den Prinzipien von John von Neumann aufgebaut ist, also mit einer Trennung von Steuerwerk, Rechenwerk, Speicher, Ein- und Ausgabegeräten sowie der Verwendung von Binär-code. Denkbar sind selbstverständlich auch andere Varianten. Vor allem Analogrechner hatten einst einen sinnvollen Einsatz, denn die Welt ist analog (z. B. die menschliche Sprache über Schallwellen), das heißt stufenlos und muss, wenn sie als Daten in ein digitales System eingelesen werden soll, diskretisiert werden, also in ein nicht-kontinuierliches, gestuftes Signal umgewandelt werden.

Beispielsweise wird ein **Audiosignal**, das über die Membran eines Mikrophons als Spannungsschwankungen ankommt, zur Verarbeitung und Speicherung auf einem Computer zunächst einen Analog-Digital-Wandler durchlaufen, wodurch bereits Qualitätsunterschiede entstehen können. **Analogcomputer** können jedoch mit einem kontinuierlichen Signal Berechnungen (z. B. elektrische Spannung) durchführen. Ihr Vorteil ist eine große Verarbeitungsgeschwindigkeit, die jedoch vor allem durch geringe Rechengenauigkeit erkauft wird. Mit der ständig steigenden Geschwindigkeit von Digitalrechnern ist die Verwendung von Analogrechnern bereits seit den 1930er Jahren nicht mehr üblich. Im Folgenden wird daher weiterhin von dem weit verbreiteten Von-Neumann-Rechner gesprochen.

Rechner, die entsprechend den Prinzipien von John von Neumann aufgebaut sind und mittels Peripherie Daten ein- und ausgeben können, bestehen – je nach Einsatzzweck – in unterschiedlichen Bauformen, deren Grenzen zueinander fließend sind.

Waren die ersten Rechner, wie der ENIAC, zunächst aufgrund der Größe seiner Bauelemente zimmerfüllend, so ging der Trend mit der Entwicklung des Mikrochips stetig in die Richtung der Miniaturisierung. Trotzdem gibt es auch heute noch **Großrechner**, die ganze Stockwerke einnehmen. Dies sind Mainframes für hoch komplexe Berechnungen, wie beispielsweise für die Klimaforschung. Hier ist eine sehr große Anzahl an Speicher sowie an parallel arbeitenden Prozessoren notwendig, die aufgrund ihrer Rechengeschwindigkeit eine besondere Kühlung benötigen. Derzeit geht der Trend hin zur Verlagerung von Speicher- und Rechenkapazitäten in die **Cloud**, in Servercluster, die diese Dienste über das Netz bereitstellen. Im Zuge dessen sind sogenannte Serverfarmen entstanden, die eine große Anzahl solcher speziell ausgelegten Computer enthalten und deren geographischer Standort fast gleichgültig ist, da sie von jedem Client-Rechner über das Internet erreichbar sind.

Des Weiteren sind sogenannte **Desktops-PCs** verfügbar, die ausgehend von dem Original Personal Computer von IBM entwickelt wurden, der in seiner modularen Bauweise mit einem Intel x86-kompatiblen Prozessor lange Zeit der Standard der Computer im Geschäfts- und Privatbereich war. Die Oberklasse dieser Rechner stellen weiterhin Gaming PCs dar, die vor allem für schnelle Grafikanwendungen konzipiert sind. Große Marktanteile haben diese Schreibtischrechner jedoch an **Laptops** und Notebooks verloren, die transportable Rechner mit aufklappbarem LCD-Bildschirm sind und für die meisten Anwendungen von Privatpersonen eine ausreichende Leistung verfügbar machen. Netbooks mit sehr kleiner Tastatur und Bild-

schirm und einem schwach dimensionierten Prozessor im unteren Preissegment haben sich mit Einführung der Tablets nicht dauerhaft am Markt halten können.

Dies liegt vor allem am Erfolg der anders konzipierten **Mobilgeräte**. Im Jahr 2007 kam das iPhone auf den Markt, das mit seinem Touchscreen und dem damit verbundenen Betriebssystem iOS ein neues Konzept für Kleinstrechner darstellte. Im Vergleich zur indirekten Maussteuerung war die direkte Objektmanipulation per Touch vor allem für den breiten Markt an Privatpersonen intuitiver und im mobilen Einsatz praktischer. Die Erweiterung dieses Prinzips von Smartphones auf Tablets erschloss eine neue Marktnische, die bisher von Laptops besetzt war. Das leichte, flache und tragbare Gerät mit langer Batterielaufzeit und ständiger Internet-Verbindung (*always-on*) bietet Nutzern eine elegante Möglichkeit, alltägliche Aufgaben, wie E-Mails schreiben, Webseiten lesen oder Fotos ansehen, zu erledigen, so dass für viele Kunden, die Anschaffung eines Laptops nicht mehr notwendig scheint. Die Geräte sind zwar von der Rechenleistung vergleichsweise schwach, stellen aber mit ihrer Struktur an kleinen Softwareprogrammen (Apps) einen bequemen und vielseitigen Einstieg in Internetanwendungen zur Verfügung, wobei deren Rechenleistung ohnehin zu einem großen Teil in der Cloud abgewickelt wird.

Der Trend zur Miniaturisierung schreibt sich weiter fort in der Entwicklung von Smartwatches, die proaktive Assistenten für den Benutzer darstellen, da sie biometrische Körperdaten sammeln und an Cloudrechner zur Analyse senden, oder E-Mails anzeigen und Navigationssysteme beinhalten. Dies ist ein erster Schritt hin zu weiteren Kleinstrechnern, die in Objekte des täglichen Lebens eingebaut werden, um diese *smart* und *connected* zu machen. Das *Connected Home*, indem mithilfe einer App beispielsweise die Beleuchtung sowie die Heizkörper aus der Ferne reguliert werden können, ist der Beginn einer Entwicklung, die als *Internet of Things* bezeichnet wird: der Vernetzung aller Geräte miteinander, um in großen Mengen Daten zu erheben, mit denen das tägliche Leben sowie Produktionsprozesse überwacht, gesteuert und vorausgesagt werden können.

4.4 | Benutzerschnittstellen

Da ein Mensch nicht binär denkt und ein Computer nicht wie ein Gehirn arbeitet, ist die Gestaltung der Schnittstelle zwischen Mensch und Maschine entscheidend für das Funktionieren der Kommunikation dieser beiden Systeme und dessen Nutzwert. Im Laufe der Zeit wurden verschiedene Ansätze erprobt, um es den Benutzern zu erleichtern, mit dem Computer zu interagieren und über das Interface Eingaben zu tätigen und gewünschte Rückgaben zu erhalten.

Wie einfach eine Benutzerschnittstelle sein kann, wird ersichtlich, wenn man den ersten für Privatpersonen erschwinglichen Computer betrachtet, der auf einem Mikrochip basierte, der Bausatz Altair 8800 aus dem Jahr 1974. Dieser wurde ohne weitere Peripherie über Kippschalter bitweise programmiert, die Ausgabe erfolgte ebenso bitweise durch LED-Lämpchen. Erst später wurde ein Fernschreiber als Peripherie angeschlossen, der eine Tastatur als Ein- und einen Drucker als Ausgabe-Einheit besaß. Zudem konnte ein Lochstreifenleser angeschlossen werden, über den eine höhere Programmiersprache aufgespielt werden konnte (Altair BASIC). Eine Programmiersprache ist an die menschliche Sprache angelehnt und ein darin geschriebener Quellcode wird von dem Interpreter in Maschinencode, der für den Rechner verständlich ist, übersetzt. Mit diesem Zwischenschritt ist es für die Benut-

zer einfacher, mit dem Computer zu kommunizieren und Befehle einzugeben. Ein solcher Befehl kann z. B. einfach lauten: `Print 2+2.`

Dies ergibt die Ausgabe der Rechenoperation, also »4«. Durch den Einsatz von Peripherie und die Zwischenebene des Interpreters (oder Compilers, der das Programm nicht zeilenweise übersetzt, sondern komplett vor der Ausführung) ist der Umgang mit dem Rechner sehr vereinfacht.

Eine ähnliche Aufgabe kommt dem Betriebssystem zu (*Operating System*, OS). Es übernimmt die Organisation von Ein- und Ausgabe sowie der Datenträger. PCs von IBM und deren technisch kompatible Nachbauten waren mit MS-DOS ausgestattet, also dem Disc Operating System von Microsoft. Um sich beispielsweise den Inhalt des Dateisystems anzeigen zu lassen, gab man `dir` ein, der Kurzform von *directory*. Daraufhin wurde eine Liste der Titel von den auf dem Datenträger vorhandenen Inhalten ausgegeben. Sprachnahe Befehle erleichtern also die Bedienung eines Computers. Trotzdem erfordert eine solche textbasierte Schnittstelle weiterhin das Erlernen von Kommandos bzw. einer Programmiersprache und einen gewissen Grad an Abstraktion. Gerade um den Computer auch weiteren Benutzergruppen zu erschließen und einen intuitiveren Umgang damit zu ermöglichen, wurden graphische Benutzerschnittstellen entwickelt.

Das klassische **GUI** (*Graphical User Interface*) besteht aus einer Mausperipherie, die einen graphischen Pfeil auf dem Bildschirm bewegt und per Klick und Bewegung Symbole manipuliert, die Dateien oder in einer Menüstruktur Befehle repräsentieren. Mithilfe einer Schreibtisch-Metapher, bei der ein Papierkorbsymbol das Löschen einer Datei und ein Ordner eine Sammlung an Dateien darstellt, wird zwischen Computer und Benutzer eine Interaktion ermöglicht, die rein auf einer visuellen Abstraktion beruht, bei der nicht mehr ein Befehlssatz, sondern nur noch die grundlegenden Gesten, wie Klicken und Ziehen, erlernt werden müssen, um ein Programm zu bedienen.

Ursprünglich 1973 am Forschungslabor Xerox Parc für den Alto-Rechner entwickelt, hat dieses Prinzip sich vor allem auf dem **Apple Macintosh** und auf **PCs mit Windows-Betriebssystem** für den Massenmarkt durchgesetzt (Pratschke 2008). Auf Desktop-Rechnern war Windows von Microsoft der Quasi-Standard des Betriebssystems, in Nischen hielt sich das Open Source OS Linux in verschiedenen Varianten sowie das Betriebssystem OS X von Apple. Der Markt für Smartphones wird zu etwa zwei Dritteln von **Googles Android**, einem Linux-Derivat, beherrscht, einen weiteren großen Teil nimmt iOS von Apple ein. Textbasierte Schnittstellen kommen heute nur noch in maschinennahen Anwendungen, wie der Programmierung, oder als Betriebssysteme von Serversystemen und Supercomputern zum Einsatz, die meist unter Linux laufen.

Jenseits des Tischrechners wurden immer wieder auch mobile Rechner getestet. So war der Apple Newton einer der ersten kommerziell erfolgreichen Handheld-PCs, der mithilfe einer Stifteingabe benutzt wurde. Nachfolger dieses Computertyps wurden als **PDA**s bezeichnet (Personal Digital Assistant), da sie vor allem für die Terminverwaltung eingesetzt wurden. Mit der Einführung schneller Mobilfunktechnik (UMTS) gewannen diese Kleinrechner weiter an Bedeutung, da sie nun auch zur Kommunikation mithilfe von Internettechnologie (Web, E-Mail) eingesetzt wurden.

Doch das »mobile Internet« benötigte neue Paradigmen der Benutzerschnittstelle. Weder die mausbasierte Fensterumgebung noch die Stifteingabe erschien eine adäquate Lösung. Vor allem die Texteingabe auf einem Smartphone mit einer winzigen Tastatur schien nicht befriedigend. Mit der Einführung des Apple iPhone war der ka-

pazitive Touchscreen, der die scheinbar direkte Berührung und Manipulation von graphischen Objekten mit einem oder mehreren Fingern erlaubte (**Multi-Touch**), zum Standard von Smartphones geworden. Vorteil ist hier, dass der Bildschirm die gesamte vordere Oberfläche des Gerätes einnehmen kann und eine virtuelle Tastatur nur eingeblendet wird, wenn sie zur Eingabe benötigt wird (Klinke 2011). Was auf kleinen Bildschirmen funktionierte, wurde bald auch auf größere übertragen (z. B. Apple iPad) und ist zur Zeit das verbreitetste Prinzip auf Mobilgeräten mit Betriebssystemen wie Apple iOS, Google Android oder Microsoft Windows 10 Mobile. Die Schreibtisch-Metapher ist damit obsolet geworden, Fenster, Menüs und Dateiordner erscheinen hier nicht mehr. Nach einer Phase eines GUI-Designs, das physischen Oberflächen nachempfunden wurde (skeuomorphisches Design), hat sich schließlich auf allen Plattformen eine abstrakte, reduzierte sowie leicht auf Berührung reagierende Großflächigkeit durchgesetzt (Flat Design).

Gerade auf **Mobilgeräten** kleinster Bauweise – wie etwa Geräten mit der Form einer Uhr – ist eine graphische Benutzeroberfläche, die auf Fingereingabe angewiesen ist, häufig nicht ausreichend, da hier selbst das Berühren des Symbols mit dem Finger die eigentlich zu manipulierende Information verdeckt. Daher sind längst über die graphische Schnittstelle hinausgehende Technologien auf dem Markt. Statt Tastatur, Maus, Stift oder Finger kann die Sprache selbst zur Eingabe verwendet werden. Systeme wie »Siri« von Apple, »Google Now« oder »Microsoft Cortana« können eine Reihe von Sprachbefehlen erkennen und verstehen sich als proaktive Assistenten, die ihre Rückmeldung mithilfe von Sprachsynthese akustisch zurückgeben können.

Wie in der Vergangenheit ist die weitere Entwicklung solcher **Interfaces** eng mit der Entwicklung von Peripherie-Hardware verbunden. In der Entwicklung sind sogenannte Natural User Interfaces (NUI), zu denen der Touchscreen zu zählen ist, aber auch Gestensteuerung, die optisch die Körperbewegung aufnimmt, wie beispielsweise bei der Kinect-Konsole von Microsoft. Tangible User Interfaces (TUI) verwenden physische Objekte zur Interaktion mit dem Computer. Und schließlich benötigen Brain Computer Interfaces (BCI) gar keine körperliche Bewegung mehr, um an den Computer Befehle zu interagieren, indem sie beispielsweise Elektroenzephalographie-Daten des Gehirns verwenden. Sie überbrücken somit am weitesten die semantische Lücke zwischen Mensch und Computer.

4.5 | Vernetzung

Wurde bisher vorwiegend vom Einzelrechner gesprochen, der mittels externer Speicher und Peripherie Daten einliest und ausgibt, so stellt die Vernetzung von Computern sowohl einen qualitativen wie quantitativen Sprung dar. Sie erlaubt, dass Rechner auf Daten eines anderen Rechners zugreifen und so Menschen mithilfe von Computern untereinander kommunizieren können. Telekommunikation lässt sich im Prinzip so vorstellen, wie die Funktionsweise des von Samuel Morse 1837 entwickelten Telegrafen. Dabei wurden mittels eines Kupferkabels sehr lange Stromkreise geschlossen bzw. geöffnet und auf diese Weise datenträgerlos Informationen übermittelt. Der Morse-Code (lange und kurze Intervalle) entspricht, ähnlich wie der Binärcode, einer dualen Notation. Deren Folgen kann mithilfe einer Tabelle in Buchstaben und damit in Worte und Sätze rückübersetzt werden. Guglielmo Marconi übertrug dieses Prinzip ab 1895 in die drahtlose Telegrafie, die nun keine Kabel mehr als Trägermedium benötigte.

Die Computervernetzung funktioniert im Prinzip genauso, nur dass nicht mehr Menschen Telegrafen bedienen, sondern Rechner miteinander verbunden sind und automatisiert Binärdaten senden und empfangen können. Eine solche Kommunikation – wie jede Kommunikation – benötigt jedoch vereinbarte Regeln, damit das Gesendete auch vollständig empfangen und korrekt interpretiert werden kann. Dies betrifft sowohl die Organisation der Trägermedien, als auch die Struktur der Datenfolge sowie die Mechanismen der Fehlererkennung und -korrektur u. v. m.

Es ist also nicht ausreichend, an einem Ausgangsport des Computers An/Aus-Signale zu senden, wenn beispielsweise mit dem Empfänger keine Geschwindigkeit des Sendens ausgehandelt wurde oder über dieses Aushandeln keine Vereinbarung getroffen wurde, wenn es keinen Mechanismus gibt, um sicherzustellen, dass die gesendeten Daten auch korrekt angekommen sind oder wie Daten überhaupt übertragen werden, oder wenn keine direkte Verbindung zwischen zwei Rechner besteht, sondern die Übertragung über ein Netzwerk von Rechnern erfolgt. Unklarheiten wie diese, die auf verschiedenen Ebenen der Kommunikation entstehen können, müssen für eine erfolgreiche Datenübertragung vorab geregelt werden. Um diese Ebenen voneinander zu trennen und systematisch anzugehen, benötigt es eine allgemeine Repräsentation von einer Klasse von Sachverhalten, die als Grundlage spezieller Sachverhalte dienen können, also ein Referenzmodell.

4.6 | OSI-Modell

Ein solches Referenzmodell für die Datenübertragung hat die International Organization for Standardization (ISO) seit 1977 entwickelt, bei der Datenübertragung auf verschiedenen Ebenen im Allgemeinen definiert wird, um spezielle Vereinbarungen des Austauschs definieren zu können. Es handelt sich um das OSI-Modell (**Open Systems Interconnection Modell**), das als Schichtenarchitektur angelegt ist.

Schicht 7	Anwendungsschicht (<i>application layer</i>)
Schicht 6	Darstellungsschicht (<i>presentation layer</i>)
Schicht 5	Sitzungsschicht (<i>session layer</i>)
Schicht 4	Transportschicht (<i>transport layer</i>)
Schicht 3	Vermittlungsschicht (<i>network layer</i>)
Schicht 2	Sicherungsschicht (<i>data link</i>)
Schicht 1	Bitübertragungsschicht (<i>physical layer</i>)

Tab. 1 OSI-Modell

Zunächst besteht eine Verbindung zwischen Rechnern, beispielsweise über ein Kupferkabel. In der **Bitübertragungsschicht** wird definiert, wie ein Bit übertragen wird und am Ende als solches ankommt. Dies kann über die Modulierung elektromagnetischer Wellen, aber genauso über die Länge der Pulse erfolgen, wie dies beim Morse-Code der Fall ist. Bei Lichtleitern sind dies optische, bei Funkverbindungen elektromagnetische Signale. Ebenso wird bestimmt, wie viele Kabel verwendet werden, beispielsweise wenn es möglich sein soll, parallel weitere Daten zu übertragen oder einen Rückkanal einzurichten. Und schließlich wird auf dem *physical layer* vereinbart, wie die Verbindung anschließend wieder beendet wird.

Diese Verbindung benötigt eine Sicherung, um eine möglichst fehlerfreie Übertragung zu gewährleisten. Dabei wird beispielsweise im Fall unterschiedlicher Geschwindigkeiten zwischen Sender und Empfänger vermittelt. Wird für das andere Ende zu schnell gesendet, können diese Daten nicht aufgenommen und verarbeitet werden. Diese Aufgabe übernimmt die **Sicherungsschicht**, die einen bestimmten Rahmen an Daten sendet (*data frame*), dem eine Prüfsumme hinzugefügt wird, und darauf einen definierten Satz an Daten zurückerhält (*acknowledgment frame*), der den korrekten Erhalt bestätigt oder Probleme meldet. Dies kann je nach Netzwerktopologie (z. B. einer Ringstruktur oder einem Bus) ganz unterschiedlich erfolgen.

Ist dies sichergestellt, ist es gerade in einem vermaschten Netzwerk, bei dem jeder Knoten mit mindestens einem anderen verbunden ist, notwendig, die Daten in Pakete aufzulösen und die Routen dieser Datenpakete auszuwählen (**Vermittlungsschicht**). Dies ist einerseits notwendig, um eine schnelle Verbindung zu gewährleisten, vor allem aber, um ggf. ausgefallene Geräte zu umgehen und eine Alternativverbindung zu suchen. Die Route kann zu Beginn der Übertragung ausgewählt werden oder einzeln für jedes Paket. Auf diese Weise kann eine einmal gewählte Verbindung kontinuierlich für die Übertragung genutzt werden (z. B. für Videoübertragung) oder die Pakete über verschiedene Verbindungen verteilt werden, was einen Geschwindigkeitsvorteil haben kann.

Bis zu dieser Schicht handelt es sich um Vereinbarungen, die in einem Rechnernetz von einem Rechner zum nächsten Rechner abgewickelt werden. Die weiteren Schichten können nun auf eine Verbindung aufbauen, mit der von einem Ende zum anderen Ende Daten übertragen werden können, auch wenn dazwischen viele **Router** liegen, also Netzwerkgeräte, die über die Weitervermittlung von Datenpaketen entscheiden.

Auf der **Transportschicht** findet die Aufteilung des Datenstromes sowie das Vermeiden von Datenstau statt. Ist diese Segmentierung erfolgt, kann auf der **Sitzungsschicht** entschieden werden, welcher der Teilnehmer gerade senden darf. Sollte die Verbindung unterbrochen sein, werden hier auch Punkte gesetzt, an denen eine Sitzung mit der Gegenseite wiederaufgenommen werden kann, ohne wieder von neuem beginnen zu müssen.

Während bisher nur Bitfolgen unabhängig von ihrer Bedeutung verhandelt werden, geht es auf der **Darstellungsschicht** um Syntax und Semantik. Beispielsweise werden ASCII-Zeichen in ein einheitliches Format umgewandelt (Abstract Syntax Notation One). Aber auch Fragen der Kompression und der Verschlüsselung werden auf dieser Ebene behandelt.

Auf oberster Ebene, der **Anwendungsschicht**, kommen schließlich Vereinbarungen über den Ablauf der Kommunikation (Protokolle) zum Einsatz, die bestimmte Anwendungen des Netzes betreffen. Darunter fallen beispielsweise die Protokolle von E-Mail-Diensten, des Web oder der Dateiübertragung, aber auch Videotelefonie und Chat-Anwendungen nutzen eigene Protokolle.

Mithilfe dieser Trennung der Kommunikation auf verschiedene hierarchische Schichten werden die Aufgaben getrennt, und die jeweils höhere Schicht kann auf bestimmte Dienste der unteren Schicht aufbauen; oder umgekehrt, die jeweilige Schicht stellt der jeweils höheren bestimmte Dienste zur Verfügung. So kommt es nicht nur zu einer Kommunikation zwischen zwei Rechnern, sondern auch zu einer Kommunikation zwischen den Schichten, zwischen denen wiederum Interfaces bestehen.




Abb. 7 Protokolle und Interfaces im OSI-Modell

Vorteil dieses Modelles ist es, dass für jede Schicht, unabhängig von der anderen, Protokolle entwickelt werden können, ohne dass die jeweils höhere Schicht davon betroffen ist. Das OSI-Referenzmodell wird vorwiegend verwendet, um die Kommunikation zwischen Netzbetreibern zu koordinieren.

4.7 | TCP-IP-Modell

Neben dem OSI-Modell wird vor allem das TCP/IP-Referenzmodell verwendet, das ebenfalls ein hierarchisches Modell ist, jedoch auch erlaubt, Zwischenschichten zu überspringen. Es besteht nur aus vier Schichten und bildet die Grundlage der Protokolle, die in der Internetkommunikation verwendet werden. Es wurde ursprünglich für das amerikanische Verteidigungsministerium entwickelt, um unterschiedliche Netzwerke zusammenzuschließen.

OSI-Schicht	TCP/IP-Schicht
Anwendungsschicht	Anwendungsschicht
Darstellungsschicht	
Sitzungsschicht	
Transportschicht	Transportschicht
Vermittlungsschicht	Internetschicht
Sicherungsschicht	Netzzugangsschicht
Bitübertragungsschicht	

Tab. 2 Vergleich OSI-Referenzmodell und TCP/IP-Referenzmodell

Bei dem **Transmission Control Protocol/Internet Protocol** (TCP/IP) handelt es sich um eine Familie an Netzwerkprotokollen, die zum Ziel haben, eine hohe Ausfallsicherheit zu gewährleisten und Netze unterschiedlichster Beschaffenheit zusammenzuschließen.

Im Gegensatz zum Telefonnetz, das beim Ausfall einer oder mehrerer Vermitt-




Abb. 8 Netzwerktypen: Zentralisiert, dezentralisiert und verteilt

lungsstationen nicht mehr funktionsfähig ist, wurde im Auftrag des amerikanischen Verteidigungsministeriums ab 1968 ein Datennetzwerk entwickelt, das auch dann noch einsatzfähig ist, wenn Knoten des Netzes zerstört sein sollten. Daher wurde an einem verteilten Netz gearbeitet, das nach der Forschungsbehörde Arpanet genannt wurde (Advanced Research Projects Agency) und über die USA verteilt war. Ein solches Netz kann auch dann noch Daten über andere Geräte zu einem Empfänger vermitteln, wenn Zwischenstationen ausgefallen sind, nämlich indem es eine andere Route dorthin wählt.

Seit 1983, als dieses Netz auch für universitäre Forschungseinrichtungen geöffnet wurde und mehr und mehr Sub-Netze sich anschlossen, setzte man hierfür TCP/IP als Protokoll ein.

Das **Transmission Control Protocol** (TCP) und das **Internet Protocol** (IP) erleichtern den Zusammenschluss von Teilnetzen zu einem Gesamtnetzwerk (Internetwork). Das Internet ist im Prinzip eine Anwendung von TCP/IP, davon jedoch der am weitesten verbreitete Zusammenschluss von Datennetzen. Ziel des vereinfachten Zusammenschlusses ist es, dass eine Schicht verwendet wird, die virtuelle Verbindungen zwischen zwei Punkten herstellen kann, über die Daten ausgetauscht werden können, ganz unabhängig von der Topologie der darunterliegenden Netze und der über diese auf unteren Ebenen verwendeten Protokolle. Auf diese Weise ist es möglich, Teil eines Netzwerks zu werden und Daten auszutauschen, unabhängig davon, ob die Verbindung kabelgebunden ist (z. B. ein Desktop-Rechner) oder per Funk organisiert wird (z. B. ein Mobilfunkgerät). Es können sowohl Teilnetze mit der Topologie eines Rings (**Token Ring**) als auch eines vermaschten Netzes (z. B. **Ethernet**) eingebunden werden. Selbst das Telefonnetz kann zum Transport von Daten nach dem TCP/IP-Protokoll verwendet werden.

Die Protokolle liefern die Grundlage für zahlreiche Dienste auf der Anwendungsschicht, die heute zum Teil weit verbreitet sind. Dazu gehören E-Mail, das World Wide Web oder die Videotelefonie. Die einzelnen Funktionen der Protokolle können auf den einzelnen Schichten hier nicht im Detail dargestellt werden (zu Einzelheiten vgl. Tanenbaum 2003, 119–856). Es soll hier nur beschrieben werden, was zum Verständnis eines lokalen Netzwerkes (LAN) und des Internets mit seinen Diensten notwendig ist.

4.8 | Netztopologie

Die einfachste denkbare Verbindung zwischen zwei Computern ist der Austausch von Datenträgern (offline), was bei großen Datenmengen auch heute noch Sinn machen kann, oder schlicht ein Kabelpaar (online), mit sehr kurzen Reaktionszeiten. Damit das isolierte Kabelpaar nicht als Antenne fungiert und somit Störungen aufnimmt, werden sie miteinander verdreht. Diese einfache Verbindung wird **Twisted Pair**-Kabel genannt und wird beispielsweise bei Telefonverbindungen verwendet. Besser abgeschirmt und ebenso weit verbreitet ist ein isoliertes Kupferkabel, das mit einem Leitermaterial umflochten ist, dadurch störungssicherer ist und somit höhere Bandbreiten vermitteln kann. Dieses **Koaxial**-Kabel kommt beispielsweise beim Kabelfernsehen zum Einsatz.

Sollen jedoch mehr als zwei Computer verbunden werden, gilt es, sich über die Struktur des Netzes Gedanken zu machen (**Netztopologie**). Die teilnehmenden Geräte können in einer Ringstruktur angeordnet sein oder in einer Linie, sie können sternförmig mit einem zentralen Knoten verbunden sein oder alle mit allen. Letzteres war die ursprüngliche Struktur des Telefonnetzes, was aber schnell an die Grenzen der Skalierbarkeit kam, denn je mehr Teilnehmer es gibt, desto mehr Verbindungen müssen von einem Gerät ausgehen und umso mehr Kabel müssen verlegt werden. Daher wurden hierarchische Einheiten gebildet, die sich heute noch in den Telefonnummern wiederfinden (Landesvorwahl, Ortsvorwahl, Rufnummer und Durchwahl). Ein internes Telefonnetz ist Teil eines Ortsnetzes, das über Vermittlungsstellen in andere Orts- oder Landesnetze vermitteln kann. Es ist ein Beispiel eines hierarchisch gegliederten dezentralen Netzwerkes.

Ein lokales Netzwerk (**LAN**, Local Area Network) wird meist als Ethernet (kabelgebunden) oder Wi-Fi (kabellos) organisiert.

Ethernet: Der Begriff »Ethernet« bezieht sich auf die historische Vorstellung, Funksignale würden über einen »Äther« übertragen. Im Jahr 1976 entwickelten Robert M. Metcalfe und David R. Boggs im Xerox-Forschungszentrum PARC eine Technologie, um Computer miteinander in einem lokalen Datennetz zu verbinden (Metcalfe/Boggs 1976). Das unter der Norm IEEE 802.3 spezifizierte Protokoll definiert den Netzzugang, auf dem in höheren Schichten TCP/IP aufbauen kann.

Ethernet transportiert Daten in **Datenrahmen** (*frames*), die folgendermaßen formatiert sind:

Präambel	Zieladresse	Quelladresse	Länge	Daten	Pad	Prüfsumme
----------	-------------	--------------	-------	-------	-----	-----------

Die Präambel ist eine Bitfolge, die zur Erkennung des Rahmens und Synchronisierung mit dem Empfänger vorangestellt wird und aus 8 Byte mit je 10101010 als Inhalt besteht (bis auf das letzte Byte mit 11 am Ende). Es folgt die Adresse des Empfängers und die des Absenders von je 6 Byte. Anschließend wird die Länge des Frames benannt. Dann folgen die Nettodaten, die bis zu 1500 Byte lang sein können, jedoch mindestens 46 Byte lang sein müssen. Sind sie doch kürzer, füllt das Feld Pad (Füllung) dies bis zur Minimallänge auf. Anschließend wird eine Prüfsumme von 23 Bit übertragen, mit der festgestellt werden kann, ob die Daten korrekt eingetroffen sind.

Dies macht deutlich, dass – nachdem auf dem *physical layer* definiert wurde, wie Bits übertragen werden – hier eine Bitübertragung folgt, die jedoch einem bestimmten Format unterliegt, die die Daten sichert, ihre Länge definiert, den Zielrechner an-

gibt und für Rückantworten diesem die Absenderadresse mitteilt. Die Adressen werden **MAC-Adressen** genannt (MAC leitet sich nicht vom Macintosh-Rechner ab, sondern bedeutet *Media-Access-Control*) und sind von dem Verband IEEE vergebene weltweit eindeutige 48-Bit-Zahlen, die von dem Hersteller der Hardware in die Netzwerkkarte einprogrammiert wird (z. B. 9C-4F-36-BB-4-A-38).

Wird dieser Frame in einem auf diese Weise per Kabel verbundenen Rechnernetz gesendet, kann es dazu kommen, dass gerade ein anderes Gerät sendet und es zu einer **Kollision** kommt. Diese Kollision kann erkannt werden. Das geschieht rein analog: Während des Sendens wird das Medium (hier das Kabel) abgehört. Ist das Empfangssignal nicht gleich dem Gesendeten, wird eine Kollision festgestellt. Vereinbarungen über den Ablauf der Kommunikation (Protokolle) lösen das Problem belegter Leitungen dadurch, dass das Senden nach einer zufällig bestimmten Zeit wiederholt wird (z. B. das ALOHA-Protokoll). Würde es nach immer der gleichen Zeit wiederholt werden, würde auch das andere Gerät senden und es würde wieder zu einer Kollision kommen. Besser jedoch sind Protokolle mit Trägerprüfung, beispielsweise das bei Ethernet verwendete Mehrfachzugriffsverfahren **CSMA** (Carrier Sense Multiple Access). Dabei wird der Kanal geprüft und gewartet, bis er frei ist, um dann, genauso wie ALOHA nach einer zufällig langen Wartezeit zu senden. Kommt es zu einer Kollision, wird nicht erst der Frame zu Ende übertragen, sondern sofort abgebrochen. Dieses erweiterte Verfahren wird **Collision Detection** genannt (CSMA/CD) und bildet die Grundlage des Ethernets.

Kollisionen verzögern die gesamte Übertragung. Mit den genannten Verfahren ist die Verzögerung bei geringer Auslastung jedoch ebenfalls gering und steigt mit der Auslastung. Es wurden auch **kollisionsfreie Protokolle** entwickelt, die jedoch kaum im Einsatz sind, vor allem, weil ihr Overhead statisch ist und bei geringer Auslastung selbst relativ hohe Verzögerungen verursacht.

Die Übertragungsgeschwindigkeit reduziert sich jedoch nach dem beschriebenen Prinzip auch durch die Anzahl von Teilnehmern im Netzwerk, weil jedem einzelnen mit steigender Zahl immer weniger effektive Bandbreite zur Verfügung steht. Daher ist das heutige Ethernet ein **Switched Ethernet**, denn die Geräte sind mit einem Switch verbunden, der den jeweiligen Rahmen nicht an alle Geräte weiterleitet, sondern nur an jenes, an das es adressiert ist. Das erhöht die Performance des Netzes und führt gleichzeitig zu höherer Sicherheit, weil nicht mehr alle Geräte alle Datenrahmen erhalten.

Ethernet ist ein einfaches und weit verbreitetes Verfahren, um ein lokales Netzwerk einzurichten. Jedoch kann es bauliche Schwierigkeiten geben, Rechner kabelgebunden miteinander zu verbinden oder man möchte mobile Geräte in ein Netz einbinden, deren Funktion gerade darin besteht, herumgetragen zu werden und nicht per Kabel verbunden zu sein. Der naheliegende Gedanke ist, Ethernet per Funk zu verbreiten, also als Medium elektromagnetische Wellen zu verwenden. Allerdings ist es nicht möglich, auf einer Frequenz gleichzeitig zu senden und zu empfangen, um eine Kollision zu erkennen. Daher ist ein anderes Verfahren heranzuziehen, das sich CSMA/CA nennt und **Collision Avoidance** bedeutet. Dies löst das Problem, indem vom Empfänger ein Bestätigungspaket zurückgesendet wird (ACK, Acknowledgement), bevor weitere Pakete gesendet werden. Andere Sender warten bis zum Ende der Übertragung, senden dann aber nicht sofort, sondern nach einer zufällig langen Zeitverzögerung. Wer zuerst sendet, verschiebt die Sendung des anderen auf den nächsten Zeitpunkt nach dem ACK.

Damit lassen sich zunächst Daten innerhalb dieses Netzwerkes austauschen und

z. B. auf einen gemeinsamen Dateiserver zugreifen. Sollen solche lokalen Netzwerke mit anderen zusammengeschlossen werden oder diesen ein Zugang zu dem Internet vermittelt werden, werden über das Ethernet die Protokolle des TCP/IP gelegt. Die Vermittlungsschicht hat dabei vor allem die Aufgabe der Adressierung der einzelnen Geräte, zum anderen die Bestimmung der Wege durch das Netz (**Routing**).

Das TCP/IP-Netzwerk hat aus den oben beschriebenen Gründen die Struktur eines verteilten Netzwerkes, das mehrere Wege von einem Sender zum Empfänger erlaubt. Es verwendet dabei das Prinzip des **Packet Switching** (Paketvermittlung): Die Daten werden in Pakete aufgeteilt, die jeweils ganz unterschiedliche Routen durch das Netz nehmen können (je nach Auslastung) und am Ende wieder in der richtigen Reihenfolge zusammengesetzt werden. Das Netz ist so effizienter ausgelastet und bei Ausfall einer Route kann der Datenstrom umgeleitet werden. Jedoch kann keine Datenrate garantiert werden und einzelne Stationen können überlastet werden. Dies ist das Prinzip des TCP/IP-basierten Internets.

Das Bestimmen der Route eines Datenpakets kann aufgrund von Routing-Tabellen geschehen. Ein Verfahren, das sich aber schlecht auf große Netze skalieren lässt. Daher wird, ähnlich wie bei der Telefonvermittlung ein hierarchisches Prinzip angewendet, bei dem jedes Gerät nur Informationen über sein eigenes Netz besitzt und nur sollte das Ziel außerhalb liegen an einen Router auf höherer Ebene vermittelt.

4.9 | Internet Protokoll

Der Vorteil des Internetworking ist es, dass Daten an jedes andere Gerät innerhalb des Gesamtnetzes gesendet werden können. Wie bereits beschrieben, legten Vinton G. Cerf und Robert E. Kahn 1974 daher eine weitere Schicht über das Netz, so dass TCP/IP eine Art Meta-Netz darstellt, dessen Hauptaugenmerk nicht auf dem physischen Netz und seinen Protokollen liegt, sondern nur noch auf der Versendung von darauf transportierten Daten (Cerf/Kahn 1974). Das IP (**Internet Protokoll**) organisiert vor allem die Adressierung der Teilnehmer im Netz, die im Header des Pakets – ganz ähnlich wie bei Ethernet – als Source und Destination angegeben werden. Die **IP-Adressen** sind jedoch nicht mit der Hardware verbunden, sondern werden dynamisch zugewiesen und sind hierarchisch aufgebaut. Jedes neu angeschlossene Gerät stellt zunächst eine Anfrage an einen im Netz befindlichen **DHCP-Server** (Dynamic Host Configuration Protocol), der dem Gerät eine freie Adresse für eine bestimmte Zeitspanne zuweist. Auf diese Weise gehen beim Verlassen des Netzes keine Adressen verloren.

Eine IP-Adresse besteht aus 32 Bit, die jeweils zu 8 Bit durch Punkte getrennt dezimal dargestellt werden (z. B. 10.180.1.95). Die Adresse 127.0.0.1 bezieht sich im Übrigen immer auf das eigene System (**Local Host**), das manchmal sinnvollerweise quasi von außen angesprochen werden soll. Mit 32 Bit können theoretisch 2^{32} , also über 4 Milliarden Geräte adressiert werden. Praktisch führt jedoch die blockweise Zuteilung von Adressen an Institutionen oder Telekommunikationsanbieter zu Subnetzen, in denen nicht alle Adressen genutzt werden. Mit dem Wachstum des Internets reicht so die Anzahl der Adressen nicht aus. Daher werden mit der Version 6 des Internets Protokolls (**IPv6**) für die Adresse 128 Bit zur Verfügung gestellt. Mit 2^{128} können 340 Sextillionen und damit alle zurzeit denkbaren Geräte im Internet adressiert werden.

Mithilfe der IP-Adresse kann theoretisch jedes Gerät jedem anderen Gerät Daten

schicken. Allerdings sind diese Adressen für den Menschen nicht nur noch schlechter zu merken als Telefonnummern, sondern diese können sich auch beim Umzug einer Ressource (z. B. eines Webserver) auf einen anderen Rechner auch verändern. Daher können sie in Namen, also Buchstabenfolgen umgewandelt werden, die ihnen dauerhaft zugewiesen werden. Dazu dient seit 1983 das **Domain Name System** (DNS), das hierarchisch aufgebaut ist und verteilt funktioniert. Dazu wird ein **Resolver** aufgerufen, dessen Funktion es ist, den Namen auf dem DNS-Server nachzuschlagen und die IP-Adresse zurückzugeben, mit der dann per TCP/IP eine Verbindung hergestellt werden kann.

Ein Domainname ist ähnlich wie eine Postadresse, die aus Land, Stadt, Straße, Hausnummer und Name besteht, ebenfalls strukturiert. Am Ende steht die **Top Level Domain**. Dies ist entweder ein Kürzel, das Ländern entspricht, beispielsweise »de« für Deutschland oder »fr« für Frankreich, oder allgemeine Begriffe wie »edu« für Bildungseinrichtungen oder »com« für kommerzielle Anbieter. Zunehmend werden von der ICANN (Internet Corporation for Assigned Names and Numbers), der Organisation der Vergabe von Top Level Domains, weitere Suffixe erlaubt, wie »biz« oder »museum«. Vor der Top Level Domain steht mit einem Punkt abgetrennt der Name der Organisation oder des Unternehmens. Dieser kann frei bestimmt werden, soweit er noch verfügbar ist, und wird von der nationalen Agentur registriert (in Deutschland DE-NIC). Dem geht meist ein Suffix voran, das den jeweiligen Dienst bezeichnet, der von dem Rechner angeboten wird, z. B. »www« für einen Webserver. Auf diese Weise entstehen Domain-Namen wie »www.lmu.de«, die auch **Internetadressen** genannt werden.

Ähnlich im Fall von Nameservern wäre es sehr aufwändig, sie zentral zu organisieren. Zudem würde bei einem Ausfall des zentralen Rechners die Namensauflösung nicht mehr funktionieren und damit wären die Rechner nicht mehr über ihren Namen erreichbar. Daher kennt ein Root-Nameserver nur die Nameserver der Top Level Domains, deren Name und Adresse er zurückliefert. Dieser wiederum kennt die Second Level Domain und leitet dann zur IP-Adresse der Third Level Domain weiter, die anschließend kontaktiert werden kann.

Das Verhältnis der Rechner untereinander kann im Internet unterschiedlich gestaltet sein. Zunächst ist es möglich, dass sich die Rechner auf gleicher Ebene befinden und gleiche Aufgaben haben. Ein **Peer-to-Peer-Netzwerk** funktioniert so, dass jeder Rechner sowohl Sender als auch Empfänger ist. In einem solchen Netzwerk ist es etwa möglich, große Dateien in Teile aufzuteilen (Chunks) und von mehreren Rechnern gleichzeitig zum Herunterladen anzubieten. Dies erhöht die effektive Bandbreite des Downloaders über die Bandbreite des einzelnen Anbieters hinaus. Da der Downloader gleichzeitig seine Chunks wieder anbietet, werden diese Dateien schnell auf vielen Rechnern miteinander abgeglichen. Aus diesem Grund sind sie sehr beliebt als (häufig, aber nicht immer) illegale Tauschbörsen von Musik- und Filmdateien (z. B. mithilfe des BitTorrent-Protokolls).

Üblicher ist aber die **Client-Server-Architektur**, bei der der Server vor allem Anbieter von Daten ist, der ununterbrochen mit dem Netz verbunden ist. Hingegen verbindet sich der Client nur zeitweise mit dem Netz, um Daten von Servern abzurufen. Server können verschiedene Funktionen haben und auf der Anwendungsschicht unterschiedliche Protokolle einsetzen. Webserver bieten ihre Inhalte per http an, Mailserver nutzen SMTP und IMAP, POP3 oder Microsoft Exchange. Zur Verbindung mit einem Dateiserver kommt FTP zum Einsatz. Als Beispiele der Anwendungen, die auf oberster Ebene der Schichtenhierarchie Daten über das Netz senden und empfangen, seien hier nur ein Mailserver und ein Webserver vorgestellt.

4.10 | E-Mail und Webserver

Eine der populärsten Anwendungen des Internets ist die Versendung von elektronischer Post. Eine E-Mail ist schnell und praktisch kostenlos. Das Komfortable daran ist, dass der abrufende Rechner nicht ständig erreichbar sein muss, sondern dass im Netz von Anbietern Mailserver betrieben werden, die nach Bedarf kontaktiert werden können. Eine E-Mail ist letztlich eine ASCII-Textdatei mit einem Header, der unter anderem den Absender, den Adressaten, eine Betreffzeile, die Sendedaten und den Textkörper enthält. Damit auch über die Möglichkeiten von ASCII (s. Kap. 5) hinaus Umlaute und Sonderzeichen eingesetzt und Multimediadaten gesendet werden können, wurde der **MIME-Standard** eingeführt (Multipurpose Internet Mail Extensions), der weitere Header erlaubt, die umfangreicher den Inhalt beschreiben können.

Diese Datei wird auf dem Client-Rechner mithilfe des Mailprogramms erstellt und per SMTP (Simple Mail Transfer Protocol) an den eigenen Mailserver gesendet (z. B. an den des Mailserver des Rechenzentrums der LMU: postout.lrz.de). Nach einer Identifizierung per Username und Passwort wird die Datei entgegengenommen. Der Absender wird dabei nicht verifiziert und der Inhalt wird im Klartext übertragen, könnte also von Dritten mitgelesen werden. Der **S/MIME-Standard** erlaubt zwar die Verschlüsselung des Nachrichtentextes, jedoch nicht der Verbindungsdaten, der Header. Zur Sendung vom Mailserver zum empfangenden Mailserver wird das DNS-System verwendet, und eine MX-Anfrage (Mail eXchange) gesendet, bei der der Domain-Teil der E-Mail-Adresse aufgelöst wird.

Beispielsweise beschreibt max.mustermann@lmu.de den Benutzer max.mustermann als Teilnehmer des Mailservers lmu.de. Das Abrufen der dort empfangenen Mail durch den Empfänger funktioniert über das Anfragen des Mailservers (z. B. mailin.lrz.de) über das IMAP-Protokoll, das im Gegensatz zum älteren POP3-Protokoll nicht nur die jeweilige MIME-Datei herunterladen, sondern auch nur die Headerliste anfordern, die Mails in Ordnern organisieren, mit einer Markierung versehen oder Suchanfragen an den Server stellen kann. Dieses Protokoll überträgt die Daten vom empfangenden Mailserver an den Mailclient des Empfängers.

Webserver: Die Begriffe ›Web‹ und ›Internet‹ werden häufig synonym verwendet. Strenggenommen ist das Internet jedoch ein spezielles Internetwork, das durch physische Verbindungen und Protokolle bestimmt ist, und das ›Web‹ bezeichnet den Internetdienst **World Wide Web** (WWW), der sich durch eine Hypertextstruktur auszeichnet, in der Verknüpfungen (**Links**) zu anderen Bereichen des Dokuments springen lassen, aber auch zu anderen Texten auf dem Webserver oder sogar auf anderen Webservern. Ursprünglich im Jahr 1989 von Tim Berners-Lee am CERN in Genf entwickelt, hat es durch seine vergleichsweise intuitive Bedienung die Verbreitung des Internets über die Grenzen der Universitäten und Unternehmen hinaus vorangetrieben. Verschiedene Programme zu seiner Bedienung (Browser) und zahlreiche Unternehmen verwenden die Infrastruktur von Internet und Web als Basis ihres Geschäftsmodells (Google, Facebook etc.).

Ähnlich wie eine E-Mail ist eine Webseite zunächst nichts weiter als eine ASCII-Textdatei, die auf einem **Webserver** liegt. Tatsächlich könnte man in diese Datei nichts weiter als das Wort ›Text‹ hineinschreiben. Die erste Datei, die im Dateisystem des Webservers liegt, wird meist als `index.html` benannt. Die Aufgabe des Servers ist es, auf Anfragen von Clients zu warten und diesen dann zunächst diese Datei zu sen-

```

X-Envelope-From: <max.mustermann@lmu.de>
X-Envelope-To: <anna.musterfrau@uni-goettingen.de>
X-Delivery-Time: 1453741919
X-UID: 1416
Return-Path: <max.mustermann@lmu.de>
Authentication-Results: strato.com 1;
    spf=none
        smtp.mailfrom="max.mustermann@lmu.de";
    dkim=none;
    domainkeys=none;
    dkim-adsp=none
        header.from="max.mustermann@lmu.de"
X-Strato-MessageType: email
X-RZG-CLASS-ID: mi
Received-SPF: none
    client-ip=2001:4ca0:0:103::81bb:ff89;
    helo="postout1.mail.lrz.de";
    envelope-from="max.mustermann@lmu.de";
    receiver=smtpin.rzone.de;
    identity=mailfrom;
Received: from postout1.mail.lrz.de ([IPv6:2001:4ca0:0:103::81bb:ff89])
    by smtpin.rzone.de (RZmta 37.15 OK)
    with ESMTPS id A06708s0PHBxp44
    (using TLSv1.2 with cipher ECDHE-RSA-AES256-GCM-SHA384
    (curve secp521r1 with 521 ECDH bits, eq. 15360 bits RSA))
    (Client did not present a certificate)
    for <anna.musterfrau@uni-goettingen.de>;
    Mon, 25 Jan 2016 18:11:59 +0100 (CET)
Received: from lxmhs51.srv.lrz.de (localhost [127.0.0.1])
    by postout1.mail.lrz.de (Postfix) with ESMTTP id 3ppyRM4bVrzySq
    for <anna.musterfrau@uni-goettingen.de>; Mon, 25 Jan 2016 18:11:59
+0100 (CET)
X-Virus-Scanned: by amavisd-new at lrz.de in lxmhs51.srv.lrz.de
X-Spam-Flag: NO
X-Spam-Score: -2.881
X-Spam-Level:
X-Spam-Status: No, score=-2.881 tagged above=-999 required=5
    tests=[ALL_TRUSTED=-1, BAYES_00=-1.9, LRZ_FROM_AP_PHRASE=0.001,
    LRZ_FROM_PHRASE=0.001, LRZ_FROM_PRE_SUR_PHRASE=0.001,
    LRZ_MSGID_AN_AN=0.001, LRZ_MSGID_HU8_HU7=0.001, LRZ_MSGID_MOZ=0.001,
    LRZ_MSGID_SPAM_68=0.001, LRZ_TO_SHORT=0.001, LRZ_UA_MOZ=0.001,
    T_HK_NAME_DR=0.01] autolearn=no
Received: from postout1.mail.lrz.de ([127.0.0.1])
    by lxmhs51.srv.lrz.de (lxmhs51.srv.lrz.de [127.0.0.1]) (amavisd-new,
port 20024)
    with LMTP id wlliu4Qe6Gfj for <anna.musterfrau@uni-goettingen.de>;
    Mon, 25 Jan 2016 18:11:59 +0100 (CET)
Received: from [IPv6:2001:4ca0:0:f222:2869:79d2:188c:b8b7] (unknown
[IPv6:2001:4ca0:0:f222:2869:79d2:188c:b8b7])
    (using TLSv1.2 with cipher ECDHE-RSA-AES256-SHA (256/256 bits))
    (No client certificate requested)
    by postout1.mail.lrz.de (Postfix) with ESMTPSA id 3ppyRM2wpwzyRx
    for <anna.musterfrau@uni-goettingen.de>; Mon, 25 Jan 2016 18:11:59
+0100 (CET)
From: "Max Mustermann" <max.mustermann@lmu.de>
Organization: =?UTF-8?Q?LMU_M=c3=bcnchen?=
To: anna.musterfrau@uni-goettingen.de
Subject: test
Message-ID: <56A6575E.7010102@lmu.de>
Date: Mon, 25 Jan 2016 18:11:58 +0100
User-Agent: Mozilla/5.0 (Windows NT 6.1; WOW64; rv:38.0) Gecko/20100101
Thunderbird/38.5.1
MIME-Version: 1.0
Content-Type: text/plain; charset=utf-8; format=flowed
Content-Transfer-Encoding: 7bit

Dies ist der Text.

```

Abb. 9 Beispiel des Quelltextes einer empfangenen E-Mail. Sichtbar sind die Header, der Inhalt selbst befindet sich in der letzten Zeile.

den. Auf dem Clientrechner läuft ein Programm, das diese Anfrage sendet und die empfangene Datei anzeigt; das ist der Browser (z. B. Mozilla Firefox oder Google Chrome). Um diese Datei auf einem bestimmten Webserver abzurufen, bedient man sich des oben beschriebenen DNS-Server-Systems. Eine Adresse wie `http://www.uni-muenchen.de/index.html` wird als **Uniform Resource Locator** (URL) bezeichnet und kennzeichnet eine Ressource sowie die Zugriffsmethode. Sie besteht aus einem Schema, das das Protokoll bezeichnen kann (hier `http`, aber beispielsweise auch die Weiterleitung einer Mailadresse an den Mailclient mit `mailto`). Nach einem Doppelpunkt und zwei Schrägstrichen folgt die Adresse und nach einem weiteren Schrägstrich kann eine bestimmte Datei aufgerufen werden (bleibt dies frei, wird meist `index.html` aufgerufen). Es können auch eine Portnummer und Variablen in der URL übergeben werden. Der Browser fragt die Domain zunächst über das DNS-System ab und stellt anschließend über TCP/IP eine Anfrage an die aufgelöste IP-Adresse, bei der mithilfe des **Hypertext Transfer Protocols** (`http`) eine Anfrage nach der Textdatei gestellt wird (Request). Eine solche Anfrage kann folgendermaßen aussehen:

```
GET www.uni-muenchen.de HTTP/1.1
User-Agent: Mozilla/5.0 (Windows NT 6.1; WOW64; rv:46.0) Gecko/20100101
Firefox/46.0
Accept: */*
Accept: image/gif
Accept: image/x-bitmap
Accept: image/jpeg
```

Soll diese Übertragung verschlüsselt erfolgen, ist das Hypertext Transfer Protocol Secure (`https`) zu verwenden, vorausgesetzt der Server bietet dieses Protokoll an. Der Client erhält daraufhin eine Antwort (Response). Sollte die Datei nicht vorhanden sein, ist dies eine Fehlermeldung (in diesem Fall »404 Not Found«), ansonsten folgt ein »OK«, Informationen über den Webserver und verschiedene Metadaten:

```
HTTP/1.1 200 OK
Date: Sat, 12 December 2015 10:00:00 GMT
Server: Apache/2.4.6 (CentOS) OpenSSL/1.0.1e-fips
MIME-version: 1.0
Content-type: text/html; charset=UTF-8
```

Es folgt der Inhalt der Datei, der im Browserfenster dargestellt wird. Im obigen Beispiel würde die nicht weiter formatierte Buchstabenfolge `Text` erscheinen. Um jedoch eine solche Seite zu formatieren, Links einzufügen und ggf. Multimediaelemente einzubetten, ist eine Textauszeichnungssprache notwendig. Diese Auszeichnungssprache ist die **Hypertext Markup Language** (HTML). Diese definiert mit sogenannten Tags die Darstellung der Seite, die die betreffenden Textteile mit eckigen Klammern umschließen. So bedeutet `<H1>Fachverband Digital Humanities</H1>`, die Wörter »Fachverband Digital Humanities« als Überschrift (engl. *heading*) erster Ordnung darzustellen. Umschließt der Anchor-Tag, der das Linkziel enthält einen Text, so wird dieser von einem graphischen Browser als klickbarer Text angezeigt, der auf ein anderes Dokument verweisen kann. `<A HREF="http://dig-hum.de">Link zur Website</A>` verweist auf einen anderen Webserver, von dem bei einem Klick auf »Link zur Website« die dortige Datei `index.html` abgerufen

würde. `<IMG SRC="dhdlogo.png"></IMG>` bindet eine auf dem gleichen Server liegende Bilddatei mit ein. Der Browser, der die HTML-Datei darstellt (rendert), erkennt dies und stellt einen Request auf diese Datei und bindet sie entsprechend in den Text ein.

Der HTML-Code

```
<H1>Fachverband Digital Humanities</H1>
<A HREF="http://dig-hum.de">Link zur Website</A>
<IMG SRC="dhdlogo.png"></IMG>
```

würde folgendermaßen gerendert werden:



Abb. 10 Browserdarstellung des HTML-Codes

Neben diesem einfachen Beispiel ist in HTML eine große Anzahl an Auszeichnungstags definiert. Eine HTML-Datei ist üblicherweise in einen Kopf- und einen Hauptteil unterteilt. Im Header können Metainformationen wie der Titel der Seite oder Stichworte angegeben sein. Im Hauptteil steht der Inhalt. Zudem ist die Art, wie die Tags graphisch interpretiert werden nicht starr festgelegt, sondern kann mit Anweisung verändert werden. **Cascading Style Sheets (CSS)** definieren unabhängig vom Inhalt die Darstellung und werden meist in einer separaten Datei eingebunden und vom Browser interpretiert. Selbst die HTML-Inhalte müssen nicht statisch sein, sie können je nach Kontext von einer serverseitigen Software dynamisch generiert werden (Content Management Systeme, CMS), sie können sich aber auch clientseitig zur Laufzeit verändern. So kann mithilfe der Scriptsprache **JavaScript** auf Benutzerereignisse reagiert werden, ohne einen weiteren Request an den Server zu senden, was der Geschwindigkeit dient und erweiterte Funktionalitäten bietet. Vor allem die **AJAX-Technologie** (Asynchronous JavaScript and XML), eine Kombination mehrerer Technologien, erlaubt es, Daten vorzuladen und so einen kontinuierlichen Arbeitsfluss zu gewährleisten, der nicht durch das erneute Laden einer Seite unterbrochen wird. Cookies ermöglichen den Webseiten, Variablen auf der Clientseite abzulegen, um beispielsweise User wiederzuerkennen. Und schließlich ist auch HTML selbst einer Entwicklung unterworfen. In der jüngsten Spezifikation **HTML5** ist es beispielsweise auch möglich, Vektorgrafiken und bestimmte Formate an Audio- und Video-Dateien ohne weitere Plug-Ins darzustellen und Frameworks zu entwickeln, die Echtzeitkommunikation, wie beispielsweise Videochat, erlauben.

Dies sind nur wenige Beispiele für die Nutzung der Infrastruktur des weltweiten Datennetzes. Dateiserver, auf die mittels des FTP-Protokolls zugegriffen wird, oder die paketvermittelte Sprachübertragung per VoIP könnten hier auch noch zur Spra-

che kommen. Als Zukunftsaussblick sei hier nur an einen obigen Abschnitt angeknüpft: Zusammen mit der Miniaturisierung der Rechner und deren Vernetzung über Standardtechnologien wie TCP/IP werden Computer in unseren Alltag noch umfangreicher eindringen als bisher. Vernetzte Gebäude, Autos und schließlich Menschen werden miteinander kommunizieren, Daten erheben und verarbeiten. Neben allen kritischen Betrachtungen ist vor allem auf die Chancen hinzuweisen, die diese Technologien für die digitalen Geisteswissenschaften bedeuten. Das Verständnis dieser Technologie erlaubt es den Digital Humanities, einerseits deren Auswirkungen einschätzen zu können, andererseits sich diese selbst als Mittel der Erkenntnis verfügbar zu machen und einzusetzen.

Literatur

- Cerf, Vinton G./Kahn, Robert E.: »A protocol for packet network intercommunications«. In: *IEEE Transactions on Communication* COM-22/5 (1974), 637–648.
- Ernst, Hartmut/Schmidt, Jochen/Beneken, Gerd: *Grundkurs Informatik: Grundlagen und Konzepte für die erfolgreiche IT-Praxis*. Wiesbaden ⁵2015.
- Hellmann, Roland: *Rechnerarchitektur: Einführung in den Aufbau moderner Computer*. München 2013.
- Klinke, Harald: »Strategisches Design. Wie Neues alt erscheint. Grundprinzipien der Produktgestaltung bei Apple«. In: *Apple Design* [1998]. Hamburg 2011, 42–53.
- McCluskey, Edward J.: »Minimization of Boolean Functions«. In: *Bell System Technical Journal* 35/6 (1956), 1417–1444.
- Metcalfe, Robert M./Boggs, David R.: »Ethernet: distributed packet switching for local computer networks«. In: *Communications of the ACM CACM Homepage archive* 19/7 (1976), 395–404.
- Pratschke, Margarete: »Interaktion mit Bildern. Digitale Bildgeschichte am Beispiel grafischer Benutzeroberflächen«. In: Horst Bredekamp/Birgit Schneider/Vera Dünkel (Hg.): *Das technische Bild*. Berlin 2008, 68–81.
- Shockley, William: *Electrons and Holes in Semiconductors, with Applications to Transistor Electronics*. Malabar 1956.
- Tanenbaum, Andrew S.: *Computernetzwerke*. München ⁴2003.

Harald Klinke

5 Zahlen und Zeichen

5.1 | Analog, digital und das Bit

Der Begriff ›**digital**‹ ist zentral für alles, was mit Computern zusammenhängt, so zentral, dass er im Namen ›Digital Humanities‹ als Repräsentant steht für den Bereich des Computers und der Informatik als zugehöriger Wissenschaft. Aber was bedeutet es eigentlich, wenn wir davon sprechen, etwas sei »digital«? In der Messtechnik, wo der Begriff seinen Ursprung hat, wird ein Signal als digital bezeichnet, das nur bestimmte Werte annehmen kann und das nur in bestimmten Zeiteinheiten, es ist dann wert- und zeitdiskret. Ein **analoges** Signal dagegen kann – innerhalb einer bestimmten Spanne – ganz beliebige Werte einnehmen. Das digitale Signal weist also im Gegensatz zum analogen Signal abzählbare Einheiten und Größen auf.

Der Unterschied zwischen **analog** und **digital** hat durch die digitale Speicherung von Musik und den damit verbundenen Siegeszug von neuen Tonträgern und Musikformaten Eingang in den allgemeinen Sprachgebrauch gefunden (Schröter 2004). Speichert man Musik analog, bestimmt etwa im Fall einer Schallplatte der physische Schalldruck die Tiefe und Form der Markierung im Speichermedium – mit unendlich vielen möglichen Zwischenstufen und Formen. Die digitale Speicherung auf einer CD-Rom dagegen beruht letztendlich auf einer langen Folge von vorhandenen (*pit*) oder fehlenden (*land*) Vertiefungen. Der Übergang von einer Vertiefung zum Fehlen einer Vertiefung (und umgekehrt) wird als 1 gelesen, bleibt der Zustand gleich, wird dies als 0 gelesen. Dieses Beispiel macht etwas Allgemeineres deutlich: Im Digitalen kann jeder mögliche physikalische Zustand als Kodierung verwendet werden. So kann etwa dem Zustand geschlossenes Relais, angeschaltetes Licht oder Wechsel der Magnetisierungsrichtung (im Fall von Festplatten) die Information 1 zugewiesen werden und dem jeweiligen komplementären Zustand, also offenes Relais, ausgeschaltetes Licht, oder gleichbleibende Magnetisierungsrichtung, die Information 0. Auf diese Weise wird jeweils 0 oder 1 kodiert. 0/1 ist auch der kleinste Baustein, aus dem alle Informationen in einem Computer aufgebaut sind. Er wird **Bit** genannt. Der Begriff wurde als Abkürzung für *binary digit* von dem Statistiker John Tukey vorgeschlagen und durch die Informationstheorie von Claude Shannon etabliert.

Das Bit stellt eine Abstraktion gegenüber dem realen Speichermedium dar. Egal wie es physikalisch modelliert wird, in der Verarbeitungslogik interessiert uns nur noch der Umstand, dass es sich um eine 0 oder eine 1 handelt. Diese Abstraktion erlaubt es auch, bei gleichbleibender Verarbeitung die physikalische Ebene komplett durch eine andere zu ersetzen. So verwenden heute die meisten Menschen keine CDROMs mehr, um ihre Musik digital zu speichern, sondern Speicherkarten, z. B. in ihrem Handy.

In modernen Computern wird auf den verschiedenen Ebenen des Rechners, sei es der externe oder interne Speicher, der Datenbus (s. Kap. 4.1) usw. zumeist mehr als nur 1 Bit auf einmal verarbeitet. Wir sprechen von 8-Bit-, 16-Bit-, 32-Bit- oder 64-Bit-Rechnern. Stets handelt es sich dabei um ein vielfaches von 2. In den heute üblichen Computern werden die Bits zu größeren Einheiten zusammengefasst. Die wichtigste Einheit ist das **Byte**, das aus 8 Bits besteht. Mit einem Byte kann ich eine binäre Zahl speichern, die 256 unterschiedliche Werte, z. B. 0 bis 255, kodieren kann. Das Kunstwort ›Byte‹ wurde übrigens eingeführt, da das eigentliche Wort ›bite‹, also Bissen, zu leicht mit ›bit‹ verwechselt werden konnte.

5.2 | Binäre Zahlen und Dezimalzahlen

Das Bit ist die Grundeinheit der digitalen Informationsverarbeitung. Mit Bits werden auch alle Zahlen notiert und Zeichen kodiert. Beginnen wir mit den Zahlen. Auf den ersten Blick sieht es ja so aus, als ob wir beim Bit bereits eine Zahl vor uns haben würden, nämlich 0 oder 1. Und es ist auch richtig, wir können ein Bit so verwenden. Aber viel häufiger wird es als Ziffernsymbol verwendet, um eine **binäre Zahl** zu schreiben. Ein Ziffernsymbol ist im Gegensatz zu einer Zahl Teil eines Ausdrucks, der eine Zahl repräsentiert. So steht die 6 in der Folge 264 nicht als Zahl da, sondern als Symbol in dem gesamten Ausdruck. Mit einem Bit können wir zwei Zahlen schreiben: 0 und 1. Hier sind die ersten zehn Zahlen des binären Zahlensystems mit ihren Entsprechungen im Dezimalsystem:

Dezimalzahl	0	1	2	3	4	5	6	7	8	9	10
Binäre Zahl	0	1	10	11	100	101	110	111	1000	1001	1010

Auch beim Dezimal-Zahlen-System wird das Ziffernsymbol verwendet, um eigentlich etwas Komplexeres zu notieren, nämlich eine Multiplikation der Ziffer mit einer Zahl, und welche Zahl das ist, legt die Position fest. Bei der Ziffernfolge 264 steht die 4 auf der Einerstelle, die 6 auf der Zehnerstelle und die 2 auf der Hunderterstelle. So ist die Ziffernfolge 264 eine Kurzform für

$$2 \times 100 + 6 \times 10 + 4 \times 1$$

Nun kann man die Zahlen 1, 10, 100 auch als Potenz von 10 schreiben:

$$264$$

$$\times 10^2 \times 10^1 \times 10^0$$

Dezimalzahl bedeutet also, dass die Stellen der Zahl jeweils mit 10 hoch n multipliziert werden, wobei n auf der ersten Stelle 0 ist, auf der zweiten Stelle 1 usw. (immer von rechts).

Nun haben wir eigentlich schon alles zusammen, um einen erneuten, etwas abstrakteren Blick auf das binäre Zahlensystem zu werfen. Hier ist nicht die 10, sondern die 2 die Grundzahl. Die binäre Zahl 101 bedeutet also:

$$101$$

$$\times 2^2 \times 2^1 \times 2^0$$

Oder: $1 \times 4 + 0 \times 2 + 1 \times 1 = 5$ (als Dezimalzahl).

Will man eine Dezimalzahl in eine binäre Zahl umwandeln, so dividiert man sie durch 2, notiert das Ergebnis und schreibt den Rest als erste Ziffer der Binärzahl (von rechts gesehen). Im Folgenden wird ermittelt, wie die Zahl 8 als Binärzahl geschrieben wird:

$$\begin{aligned}
 8 / 2 &= 4 \text{ Rest } 0 \\
 4 / 2 &= 2 \text{ Rest } 0 \\
 2 / 2 &= 1 \text{ Rest } 0 \\
 1 / 2 &= 0 \text{ Rest } 1
 \end{aligned}$$

Die Dezimalzahl 8 schreibt man als Binärzahl 1000.

Hexadezimalzahlen: Computer arbeiten intern mit **Binärzahlen**, aber für Menschen sind diese schnell kaum zu überblicken. Deswegen werden in vielen Kontexten Hexadezimalzahlen (vom griechischen Wort *hexa* für sechs und dem lateinischen Wort *decem* für 10) verwendet; es handelt sich also um ein Zahlensystem, das auf der Zahl 16 beruht. Da man nur Ziffernsymbole für 0–9 hat, verwendet man für die restlichen die Buchstaben A–F. Der Hexadezimalzahl A entspricht also die Dezimalzahl 10, B im Hexadezimalsystem ist 11 im Dezimalsystem usw. Die Hexadezimalzahl 1B4 ist also so zu lesen:

1 B 4

$$\times 16^2 \times 16^1 \times 16^0$$

Wenn man sie in eine Dezimalzahl umwandeln will, dann rechnet man: $1 \times 256 + 11 \times 16 + 4 \times 1 = 436$.

Wenn aus dem Kontext nicht klar ist, dass es sich um Hexadezimalzahlen handelt, dann wird ein kleines h an die Ziffer angehängt: $11h = 17$.

5.3 | Zeichenkodierung

In Computern können Texte nur bearbeitet werden, wenn sie als Folge von Zeichen vorliegen. Man kann z. B. nur in ihnen suchen, wenn die Texte eine Kette von alphanumerischen Zeichen sind, also Buchstaben, Satzzeichen, Leerzeichen usw. Das ist etwas weniger trivial als es sich anhört, da Computer Texte auch als Bilder speichern können, also als Folge von Punkten (s. Kap. 12.2). Für nahezu alles, was in diesem Buch besprochen wird, ist es aber wichtig, dass die Texte als Zeichenfolge vorliegen. Wie aber weiß der Computer, was ein Buchstabe ist?

Zeichen und Glyphen: Beginnen wir mit einer grundsätzlichen Unterscheidung: Computer kodieren Texte in der Form von abstrakten **Zeichen**, z. B. der Großbuchstabe ›D‹ des lateinischen Alphabets – gedacht noch ohne die Realisierung in einer bestimmten Ausprägung z. B. in einer Handschrift oder im Druck. Diese konkrete Ausprägung des Zeichens bezeichnet man als **Glyphe**; das gleiche Zeichen kann, etwa für die Ausgabe auf dem Bildschirm oder Drucker, in verschiedenen Glyphen wiedergegeben werden: z. B.

D D D  

Glyphen sind also die Bilder, die das Zeichen, oder einen Teil davon, repräsentieren. Sie können, je nach Schriftart, unterschiedliche Gestalt und Größe haben. Das **Verhältnis von Zeichen zu Glyphen** sieht zumeist also so aus:




Abb. 11 Verhältnis von Zeichen und Glyphen

Das Verhältnis von Glyphen zu Zeichen ist außerdem nicht eindeutig, d. h. nicht immer entspricht eine Glyph einem Zeichen. Die Zeichenfolge »ff« kann als Folge von zwei Glyphen oder in Form einer Ligatur als eine Glyph dargestellt werden:

ff ff

Abb. 12 Zeichenfolge in zwei Glyphen oder einer Glyph (Ligatur)

Umgekehrt kann auch ein Zeichen durch ein oder mehrere Glyphen wiedergegeben werden, z. B. »Ĉ« durch Ĉ oder durch C und ^ . Außerdem können in einer Schriftart auch verschiedene Glyphen für das gleiche Zeichen vorkommen. Ob ein Zeichen bzw. mehrere Zeichen durch ein oder mehrere Glyphen wiedergegeben werden, ist eine interpretatorische Entscheidung, zu der auch die Möglichkeiten und Grenzen der jeweils verwendeten Programme und des Betriebssystems beitragen. Um die Dinge noch etwas komplizierter zu machen: Ein und dieselbe Glyph kann auch mehrere Zeichen repräsentieren. So kann die Glyph A sowohl den lateinischen Großbuchstaben »A« als auch ein griechisches großes Alpha repräsentieren.

Computer verwenden Zahlen zur internen Repräsentation von Zeichen. Jedem abstrakten Zeichen wird eine Zahl eindeutig zugeordnet, d. h. jeder **Zeichencode** gehört zu einem bestimmten Zeichen und jedes Zeichen hat einen ganz bestimmten Zeichencode. Aus diesen Zuordnungen ergibt sich insgesamt die Zeichenkodierung, z. B. 0 = A, 1 = B, 2 = C usw. Wir müssen also unsere Grafik von oben um eine Spalte erweitern (s. Abb. 13):

Die Art der Zuordnung von Zahlen zu Zeichen ist im Prinzip völlig willkürlich; entsprechend wichtig ist die Verwendung von Standards, da ansonsten ein Text völlig unverständlich wird, der auf dem einen System nach dem Modell (0 = A, ...) kodiert wurde und nun auf ein System transportiert wird, das nach dem Modell (5 = A, 6 = B, ...) kodiert. Wenn der Benutzer auf dem ersten System die Zeichen-




Abb. 13 Verhältnis von Zeichencode, Zeichen und Glyphe

folge »LIEBE« eingibt, dann wird das systemintern kodiert als »12,9,5,2,5«. Diese Folge wird dann auf dem zweiten System in folgende Zeichen dekodiert: »HEA?A«.

Standards

Da man nur durch die Einführung und allgemeine Verwendung von Standards solche Probleme vermeiden kann, wurden recht früh Standards zur Zeichenkodierung entwickelt. Ausgesprochen weite Verbreitung fand **ASCII** (*American Standard Code for Information Interchange*), der 1963 in einer ersten Version publiziert wurde und einen geräteübergreifenden Code zur Kodierung für 128 Zeichen definierte. Er entwickelte sich aus einem Teleprinter-Code – deshalb dienen die ersten 31 Zeichen auch häufig Übertragungszwecken und werden heute größtenteils nicht mehr verwendet – und wurde einer der erfolgreichsten Standards weltweit. Aus Kapazitätsgründen war die Länge der binären Zahlen, die zur Zeichenkodierung verwendet wurden, lange Zeit auf 7, später 8 Stellen begrenzt (= 1 Byte). Mit 7 Bits kann man 2^7 Zeichen kodieren, also eben die 128 des ursprünglichen ASCII-Codes. Es fehlten allerdings Zeichen für die Besonderheiten der anderen, nicht-englischen europäischen Sprachen, z. B. Umlaute oder Akzente, ganz zu schweigen vom Zeichenreichtum nicht-europäischer Sprachen.

Erste Abhilfe wurde durch den **Standard ISO 8859** (International Organization for Standardization) geschaffen, der eine Reihe von 8-Bit-Zeichensätzen definiert, z. B. 8859-1 (Latin-1, Westeuropäisch) oder 8859-5 (Kyrillisch). In der Regel sind die ersten 127 Codes identisch mit dem ASCII-Zeichensatz, während die Zeichen über 127 die für die jeweilige Sprache notwendigen zusätzlichen Zeichen kodieren. Sehr bald war klar, dass damit das Problem nicht grundsätzlich gelöst sein würde, da die Dateien bei einem Wechsel von einem System auf ein anderes, das einen anderen Zeichensatz verwendet, unlesbar wurden.

Unicode / ISO 10646: Gelöst werden konnte dieses Problem erst durch einen Zeichensatz, der groß genug ist, um alle Zeichen der Welt gleichzeitig zu kodieren. Dieser Zeichensatz wurde mit Unicode geschaffen (Unicode 2006). Anfangs war Unicode ein 16-bit-Zeichensatz, womit 65.536 (2^{16}) Zeichen definiert werden können, doch erwies sich das bald als zu wenig. Heute ist Unicode ein Zeichensatz, der theoretisch über eine Millionen Zeichen enthalten kann. In der aktuellen Version 9x.0 sind rund 128.000 verschiedene Zeichen enthalten. Der Standard umfasst Zeichensätze für europäische Alphabete wie das Kyrillische, Koptische und Georgische, für das Arabische und Hebräische, für mehrere indische Sprachen, chinesische und japanische Schriftzeichen sowie für alte Sprachen wie das Altgriechische, die Keilschrift, Linear B oder das Gotische. Nur der Antrag, auch das Klingonische in Unicode zu kodieren, wurde abschlägig beschieden. Jedes Jahr kommen ca. 1000 Zeichen hinzu. Für die Kodierung moderner deutschsprachiger Texte hat sich nicht viel geändert, da die ersten 256 Zeichen von Unicode identisch sind mit ISO 8859-1. Allerdings hat erst Unicode die Kodierung von mittelalterlichen Texten ohne eigene Zeichendefinitionen ermöglicht.

Unicode definiert für jedes Zeichen einen individuellen **Codepoint**, also den Zeichencode, und einen einzigartigen Namen, z. B.

0041 A LATIN CAPITAL LETTER A

00DF ß LATIN SMALL LETTER SHARP S

Unicode definiert mit den Codepoints das Verhältnis von Zeichencode zum abstrakten Zeichen, das durch seine Form und vor allem durch seinen Namen definiert ist. Unicode ist in Ebenen organisiert. Die **Basic Multilingual Plane (BMP)** enthält 65.536 Codepoints und damit Definitionen für alle größeren Sprachen der Welt. Weitere Sprachen und zusätzliche Zeichen sind auf den ergänzenden Ebenen definiert. Der Codepoint wird – für die Zeichen auf der BMP – als vierstellige Hexadezimalzahl notiert und üblicherweise mit einem vorangestellten U angegeben: U + 00DF. Für die Codepoints der ergänzenden Ebenen werden längere Zahlen verwendet. Rund 6400 Zeichen der BMP sind für den privaten Gebrauch bestimmt, d. h. diese Codepoints können verwendet werden, um etwa innerhalb eines Projekts Zeichen zu definieren, die nicht in Unicode enthalten sind. Allerdings muss man dem Benutzer dann auch entsprechend angepasste Fonts zur Verfügung stellen, da in den normalen Unicode-Fonts für diese Codepoints keine Glyphen enthalten sind.

Neben der Definition der Codepoints leistet der Unicode-Standard noch mehr. Er beschreibt für jedes Zeichen,

- in welcher Klasse es ist, d. h. ob es sich um einen Buchstaben, ein Satzzeichen, eine Zahl, ein Trennzeichen usw. handelt.
- ob es sich um einen Groß- oder Kleinbuchstaben handelt, soweit diese Unterscheidung in dem Zeichensystem verwendet wird.
- darstellungsbezogene Eigenschaften, z. B. die Schreibrichtung.

UTF-8: Ein offensichtlicher Nachteil von Unicode ist der deutliche höhere Bedarf an Speicher, da nun für das Speichern eines Zeichens nicht mehr ein Byte, sondern vier Byte verwendet werden, d. h. dass eine ASCII-Datei viermal so umfangreich wird. Das verschwendet bei Texten, die z. B. nur die ersten 256 Zeichen von Unicode verwenden, besonders viel Platz. Deshalb gibt es für Unicode verschiedene Formen der Speicherung, z. B. UTF-8 (8-Bit *Unicode Transformation Format*). Diese Speicherverfahren

verwenden eine variable Anzahl von Bytes, um Unicode-Texte zu speichern, nämlich von den 4 notwendigen Bytes zur Kodierung eines Unicode-Zeichens immer nur so viele, wie tatsächlich benötigt werden, um die Zahl zu notieren. UTF-8 verwendet zur Kodierung des ursprünglichen ASCII-Formats tatsächlich nur 1 Byte; für lateinische Zeichen mit diakritischen Zeichen, also Akzenten, Umlauten, werden 2 Byte verwendet, aber auch für Griechisch, Kyrillisch usw. Für die Zeichen auf den höheren Ebenen von Unicode – das Unicode-Konsortium hat den Zeichenvorrat in verschiedene Ebenen (*planes*) eingeteilt – müssen drei oder auch vier Byte verwendet werden. Auf diese Weise entstehen recht kompakte Textdateien, die zugleich alle Vorteile von Unicode haben. Außerdem ist UTF-8 noch rückwärts kompatibel mit ASCII, d. h. die ersten 127 Zeichen sind identisch mit der Zeichenkodierung von ASCII. Daher ist UTF-8 inzwischen das häufigste Verfahren, um Unicode-Dateien abzuspeichern.

Unicode regelt nur die Beziehung zwischen dem Zeichencode und dem Zeichen. Ob das Zeichen auch dargestellt werden kann, sei es auf dem Bildschirm oder einem Drucker, hängt davon ab, ob auch entsprechende Schriftarten-Dateien (Fonts) zur Verfügung stehen. Viele moderne Betriebssysteme unterstützen zwar Unicode, installieren aber nicht unbedingt auch Schriftarten für alle Zeichen in Unicode. Und auch neue Schriftarten unterstützen oft nur einen relativ kleinen Teil von Unicode – was bei der Auswahl der Schriftarten für die Publikation von Projektergebnissen zu berücksichtigen ist.

Warum sind Standards wichtig?

In den wenigen Jahrzehnten, seitdem es Computer gibt, sind zahlreiche Standards entwickelt worden, die die Interoperabilität und Nachhaltigkeit überhaupt erst ermöglichen. Das betrifft das hier ausführlich erklärte Problem der Zeichenkodierung mit Unicode, das Internetprotokoll TCP/IP, aber auch die Gestalt von Programmiersprachen wie C oder JAVA. Standards sind notwendig, um Interoperabilität und Nachhaltigkeit zu gewährleisten. Allerdings kann es sich als Problem erweisen, dass Organisationen deutlich weniger schnell und flexibel als die Entwicklungen in der IT-Welt sind. Gerade die Modularität und Vernetzung von Computern macht es aber auf allen Ebenen, sei es Hardware, Betriebssystem, Datenformate für spezifische Anwendungsfelder oder Internetprotokolle, wichtig, neue Standards zu entwickeln oder vorhandene anzupassen. Firmen preschen deswegen immer wieder mit Eigenentwicklungen vor, nicht zuletzt auch in der Hoffnung, auf diese Weise de facto Standards zu setzen, und so finanzielle oder Informationsvorteile gewinnen zu können. Es gibt eine Reihe von Standardisierungsorganisationen, die in diesem Kontext immer wieder auftauchen, womit die Hoffnung auf eine gewisse Unabhängigkeit der Standards von Firmeninteressen verbunden ist. Um nur einige der wichtigsten zu nennen:

- Die International Organization for Standardization (ISO), ein internationaler Zusammenschluß nationaler Standardisierungsgremien, dem auch das deutsche Deutsche Institut für Normung (DIN) angehört.
- Die Internet Engineering Task Force (IETF), ein eher informeller Zusammenschluss von Interessierten, ist für die Weiterentwicklung von technischen Internetprotokollen zuständig.
- Das World Wide Web-Konsortium (W3C) hat ebenfalls zahlreiche Internet-Standards entwickelt, z. B. HTML, CSS und eben auch XML, das im Folgenden eine wichtige Rolle spielen wird.

Gute Standards machen ihre Dokumentation frei und öffentlich zugänglich, damit sie von vielen geprüft und umgesetzt werden können.

Auch bei einem Standard ist es nicht ganz unwichtig, wer ihn unterstützt. Unicode wird vom Unicode-Konsortium entwickelt, dem zahlreiche große Firmen der IT-Branche wie IBM, Microsoft oder Google angehören, aber auch institutionelle Mitglieder und zahlreiche Einzelpersonen. Vor allem aber ist Unicode in enger Abstimmung mit dem internationalen Standard ISO/IEC 10646 entwickelt worden, mit dem es Zeichen für Zeichen äquivalent ist (s. Kasten S. 65). Unicode / ISO 10646 wird inzwischen von allen wichtigen modernen PC Betriebssystemen unterstützt und ist auch Bestandteil anderer Standards wie XML geworden. UTF-8 wird gemeinsam vom IETF, dem Unicode Consortium und der ISO gepflegt. D. h. in beiden Fällen spricht vieles dafür, dass diese Standards langfristig verfügbar sein werden.

5.4 | Offene Probleme

Das klingt so, als wären nun eigentlich alle Zeichenkodierungsprobleme für die digitalen Geisteswissenschaften gelöst. Leider ist dies (noch) nicht der Fall. Es gibt drei Probleme: erstens Zeichen, die noch nicht im Unicode-Standard definiert sind; zweitens wichtige Daten aus der Zeit vor der Einführung von Unicode; drittens, die Darstellung von »exotischen« Zeichen.

1. Es gibt immer noch Zeichen, die von Textwissenschaftlern benötigt werden, aber nicht im Unicode-Standard definiert sind. Europäische Mediävisten, um ein Beispiel zu nennen, hatten das Problem, dass sie die Zeichenvielfalt, die sich in mittelalterlichen Handschriften findet, nicht in den ersten Versionen von Unicode repräsentieren konnten. In einem ersten Schritt definierte die Arbeitsgruppe Medieval Unicode Font Initiative, um die Interoperabilität mediävistischer Projekte zu gewährleisten, im private use area von Unicode Codepoints für die fehlenden Zeichen. Außerdem reichte die Arbeitsgruppe beim Unicode-Konsortium eine Liste der fehlenden Zeichen ein, und inzwischen sind die meisten Zeichen Teil der neueren Unicode-Versionen.

2. Es gibt viele Dateien mit hochwertigen Texten, die vor der Durchsetzung des Unicode-Standards erstellt wurden. Die Konvertierung von Textdateien, die nicht in Unicode oder ASCII kodiert sind, kann, je nach dem gewählten Kodierungsformat und dem Zustand der Dokumentierung, sehr schwierig werden. Insbesondere die Kodierung von den Zeichen, die im ursprünglichen Zeichensatz eigentlich nicht vorgesehen waren und durch spezielle Platzhalter kodiert wurden, kann aufwendig werden, wenn man nicht genau weiß, welche Zeichen wie kodiert wurden. Im Prinzip wird dabei immer ein sogenanntes Escape-Zeichen verwendet. Ein Escape-Zeichen hat die Funktion zu notieren, dass das folgende Zeichen nicht für sich selbst steht, sondern ein Platzhalter ist oder ein Teil davon. Üblicherweise wird auch das Ende der Zeichenfolge, die den Platzhalter kodiert, durch ein spezielles Zeichen notiert. Kommt im Text das Escape-Zeichen selbst vor, muss es logischerweise selbst wiederum durch einen Platzhalter repräsentiert werden.

Ein Beispiel: In HTML 4.01, der Hypertext Markup Language mit der die Webseiten im Internet aufbereitet sind, wird der Zeichensatz Unicode verwendet, aber den Autoren von Webseiten letztendlich die Freiheit gelassen, einen Zeichensatz zu wählen, der für Ihre Bedürfnisse geeignet ist. Browser sind in der Lage, die Zeichensätze zu verarbeiten und, soweit es die vorhandenen Fonts erlauben, zu repräsentieren. Gesteuert wird dies häufig über eine Angabe im Kopf der HTML-Datei:

```
<meta http-equiv="content-type" content="text/html; charset=iso-8859-1">
```

Sollen nun Zeichen kodiert werden, die im gewählten Zeichensatz, hier ISO 8859-1, nicht vorhanden sind, dann werden sogenannte **Entities** verwendet. Häufig findet man z. B. Umlaute so kodiert: ›Ä‹ wird kodiert als Ä das Zeichen ›&‹ hat dabei die Funktion eines Escape-Zeichens. Alles was danach kommt, steht nicht für sich selbst, sondern ist Teil der Entity. Mit dem Semikolon ›;‹ wird das Ende der Entity notiert; was danach kommt, wird wieder als normaler Text gelesen. Soll in HTML das Escape-Zeichen & kodiert werden, muss eine Entity verwendet werden, in diesem Fall & (von der englischen Bezeichnung *ampersand* für das Kaufmannsund). Tadellöser & Wolff sieht in dieser Kodierung also so aus:

```
Tadell&ouml;ser &amp; Wolff
```

Zwar kann man aus einem Text aufgrund der eindeutigen Kodierung durch Escape-Zeichen sehr schnell die Liste aller verwendeten Ersetzungszeichen extrahieren, aber deren Bedeutung ist ohne gute Dokumentierung häufig kaum zu erkennen.

3. Das dritte Problem betrifft die Repräsentation eines Zeichens auf dem Bildschirm bzw. auf dem Drucker. Ein abstraktes Zeichen kann, wie oben ausgeführt, durch verschiedene Glyphen repräsentiert werden. Auf modernen PCs wird dies durch die installierten Schriftarten (auch *fonts*) geregelt, zumeist mittels Outline-Schriften wie TrueType. Nur sehr wenige Schriftarten unterstützen jedoch den vollständigen Unicode-Zeichensatz. Will man also sehr neue Versionen von Unicode verwenden oder gar Zeichen ausdrucken, die mittels einer eigenen Zuordnung auf einer privaten Ebene von Unicode definiert wurden, dann muss man eine entsprechend angepasste Schriftart auf dem Rechner installieren und verwenden.

Literatur

Schröter, Jens: »Analog/Digital – Opposition oder Kontinuum?«. In: Ders./Alexander Böhnke (Hg.): *Analog / Digital – Opposition oder Kontinuum? Zur Theorie und Geschichte einer Unterscheidung*. Bielefeld 2004, 7–30.

The Unicode Consortium: »The Unicode Standard, Version 9.0«, <http://www.unicode.org>.

Fotis Jannidis

6 Grundbegriffe des Programmierens

Programmieren ist doppelte Kommunikation. Ein Programm besteht aus einer Reihe von Anweisungen an den Computer, zugleich richtet es sich an den Programmierer und alle, die den Code lesen können, und informiert darüber, was das Programm wie tut. Programmieren muss beiden Anforderungen genügen. Anders als sein Ruf in der Öffentlichkeit es nahelegt, ist Programmieren inzwischen eine sehr soziale Tätigkeit, da kaum noch ein Programm von jemandem ganz alleine und nur für sich selbst geschrieben wird.

Die Regeln und Gepflogenheiten, denen Programmierer folgen müssen und sollen, haben sich etabliert, weil sie dazu beitragen, erfolgreich Programme mit anderen und für andere zu schreiben. Zuerst werden wir uns vor allem auf die Anforderungen konzentrieren, die sich aus der Kommunikation mit der Maschine ergeben. Dann werden wir uns ausführlicher mit dem algorithmischen Denken beschäftigen, das eine wichtige Grundlage für erfolgreiches Programmieren ist. Im letzten Abschnitt gehen wir dann kurz auf die praktischen Aspekte ein, die das Programmieren bestimmen.

Seitdem die ersten Programmierer in Maschinensprache Anweisungen geschrieben haben, hat sich dieses Arbeitsfeld sehr weiterentwickelt. Heute arbeiten die meisten mit höheren Programmiersprachen, die von den Spezifika der konkreten Rechnerarchitektur absehen; ja, in vielen Bereichen haben sich Sprachen durchgesetzt, die von Aspekten wie etwa der Speicherverwaltung vollständig abstrahieren. Andererseits muss insbesondere für zeitkritische Anwendungen immer noch maschinennaher Code geschrieben werden.

Imperative und deklarative Sprachen: Die höheren Programmiersprachen können wir in imperative und deklarative Sprachen unterteilen. Zu den imperativen Sprachen gehören z. B. C, Java oder Python. Innerhalb dieser Gruppe kann man noch die objektorientierten Sprachen wie etwa Java von den anderen unterscheiden. Zu den deklarativen Sprachen gehören funktionale Programmiersprachen wie Scheme, logische Programmiersprachen wie Prolog und manche domänenspezifischen Sprachen wie SQL oder XSLT. Während man in imperativen Sprachen eine Problemlösung als eine genaue Folge von Arbeitsschritten vorgeben muss, reicht es in deklarativen Sprachen, das Problem und die Ausgabe abstrakt anzugeben. Allerdings sind viele Sprachen, die heute weite Verbreitung haben, Multiparadigmen-sprachen, d. h. sie folgen zumeist einem Paradigma, haben aber viele effiziente Konzepte anderer Paradigmen übernommen. Das gilt auch für die Sprache Python, die wir im Folgenden verwenden werden. Sie gehört zu den beliebtesten Programmiersprachen weltweit und wird für die Datenanalyse, für serverseitige Webentwicklung, Systemadministration u. a. m. verwendet (Eine kurze Beschreibung, wie Sie Python auf Ihrem Rechner installieren können, finden Sie auf der Webseite zum Buch).

Python ist eine interpretierte Sprache – im Gegensatz zu kompilierten Sprachen wie z. B. C. Um zu verstehen, was das heißt, müssen wir einen kurzen Blick auf den Anwendungszyklus eines Programms werfen. Der Quellcode, der in einer höheren Programmiersprache verfasst wird, muss in die Maschinensprache übersetzt werden, die der jeweilige Prozessor bzw. die jeweilige Rechnerarchitektur versteht. Im Fall von kompilierten Sprachen geschieht dies beim Programmierer: Er übersetzt seinen gesamten Programcode mit einem **Compiler** in Maschinensprache. Die maschinenlesbare Datei ist für den Menschen nicht lesbar, aber innerhalb der Rechner-

architektur selbstständig lauffähig. Bei einem interpretierten Programm wird der Quellcode in ein Zwischenformat übersetzt und dann schrittweise zur **Laufzeit** in Maschinensprache übersetzt und gleich ausgeführt. Der Vorteil besteht darin, dass anders als beim Kompilieren jeweils der gesamte Code kompiliert sein muss. Allerdings muss im Fall interpretierter Sprachen der Code jedes Mal, wenn er läuft, übersetzt werden – daher sind interpretierte Sprachen langsamer als kompilierte. Ein weiterer Nachteil besteht darin, dass der Interpreter beim Benutzer schon installiert sein muss, da das Programm oder Skript alleine nicht lauffähig ist. Allerdings ist das Programm überall lauffähig, wo ein Interpreter installiert ist – unabhängig von der darunterliegenden Rechnerarchitektur. Interpretierte Sprachen haben oft eine höhere Produktivität und eignen sich besonders, um kleinere und mittelgroße Anwendungen zu schreiben.

6.1 | Anweisungen

Die Grundeinheit des imperativen Programmierens besteht aus **Anweisungen**. Eine einfache Anweisung kann z. B. so aussehen (Im Folgenden wird die Ausgabe eines Programms mit ›› eingeleitet):

```
print("Hallo Welt!")
›› Hallo Welt!
```

Führt man das Programm aus, dann wird der Text zwischen den Anführungszeichen ausgegeben. Die meisten Anweisungen haben allerdings eine Form wie diese:

```
x = x + 1
```

Hier wird der Wert der Variablen *x* um eins erhöht und das Ergebnis wird wiederum in der Variablen *x* abgelegt. Diese Anweisung besteht aus drei Teilen, die wir uns genauer anschauen wollen. Beginnen wir mit dem mittleren Teil, dem Zeichen ›=‹. Es handelt sich hier *nicht* um das Zeichen aus der Mathematik, mit dem man Äquivalenz ausdrückt, z. B. $4 = 2 + 2$. Vielmehr ist es ein **Zuweisungszeichen**. Dem, was links von dem Zuweisungszeichen steht, wird als neuer Wert das Ergebnis des Ausdrucks rechts vom Zuweisungszeichen zugeschrieben. Das mathematische Äquivalenzzeichen drückt einen statischen Zusammenhang aus. Das Zuweisungszeichen im Code drückt dagegen eine Handlung aus: Nimm den Ausdruck rechts, hier also ›*x* + 1‹, berechne ihn und weise das Ergebnis der Variablen zu, die links steht.

Wir haben damit auch schon den nächsten Begriff eingeführt, nämlich den des Ausdrucks. Ein **Ausdruck** ist eine Kombination von Literalen, Variablen, Operatoren und Funktionen, die berechnet wird und ein Ergebnis hat. Ein sehr einfacher Ausdruck besteht z. B. aus dem **Literal** 1 und dem Operator +, also:

```
1 + 1
```

Andere Literale sind etwa "Hallo Welt", 1.345, True.

Eine **Variable** können wir uns als einen Platz im Arbeitsspeicher des Rechners vorstellen, und dieser Platz hat den Namen der Variablen. Der Name einer Variable sollte sprechend und möglichst selbsterklärend sein. Die letzte Zuweisung bestimmt,

was an dieser Stelle gespeichert ist. Was auf dem Speicherplatz liegt, kann sehr einfach sein, z. B. eine Zahl, aber es kann auch eine sehr komplexe Datenstruktur sein. Die Anweisung

```
x = 1
```

stellt also nicht fest, dass x den Wert 1 hat, sondern sie löscht, was immer der vorherige Wert von x war, und legt als neuen Wert nun 1 fest. Wenn bislang noch keine Variable mit dem Namen x existiert, dann wird durch diese Anweisung ein neuer Speicherplatz mit Namen » x « eingerichtet. Abkürzend können wir also sagen, dass wir etwas in einer Variablen abspeichern. Selbst wenn nicht alle Programmiersprachen Variablen wirklich in dieser Weise einrichten und verwalten, ist es ein sehr praktisches Modell, um sich die Funktionsweise von Variablen klar zu machen.

Fassen wir zusammen: Anweisungen haben sehr häufig die grundlegende Struktur

```
<Variable> = <Ausdruck>
```

Das Ergebnis des Ausdrucks wird der Variablen links vom Zuweisungszeichen zugeschrieben. Kehren wir mit diesem Wissen zu unserem Beispiel zurück. Wir können annehmen, dass in einer Zeile der Variablen x ein Wert zugeschrieben wurde, z. B. 1, und in der Anweisung wird dieser um 1 erhöht:

```
x = 1
x = x + 1
```

Nach diesen beiden Anweisungen hat die Variable nun den Wert 2. Es ist offensichtlich sehr wichtig, sich klar zu machen, welchen Wert Variablen vor der Berechnung eines Ausdrucks haben und welcher Wert nach der Berechnung dann einer Variablen zugeschrieben wird.

6.2 | Datentypen

Bislang haben wir uns nur mit Variablen beschäftigt, denen ganze Zahlen zugeschrieben wurden. Wie schon erwähnt, können wir Variablen alle möglichen Informationen zuschreiben. Wir hatten oben bereits verschiedene Literale aufgelistet: »Hallo Welt«, 1.345, True. Das erste ist eine **Zeichenkette**, das zweite eine **Fließkommazahl** und das dritte ein **Wahrheitswert**. In höheren Programmiersprachen wird explizit oder implizit sehr genau zwischen diesen verschiedenen Datentypen unterschieden. Dafür gibt es zwei Gründe. Erstens werden Zahlen und andere Informationen wie Zeichen, Zeichenketten, Wahrheitswerte usw. im Computer unterschiedlich gespeichert (s. Kap. 4 und 5 zum Aufbau des Computers bzw. Zeichenkodierung). Zweitens sind für die verschiedenen Datentypen unterschiedliche Operationen sinnvoll.

Datentypen sind daher formal definiert durch zwei Mengen: die Objekte und die zulässigen Operationen. So kennen z. B. viele Programmiersprachen einen Datentyp **Integer** (ganze Zahl, oft abgekürzt: int), dessen Objektmenge bzw. Wertebereich häufig -2^{31} bis $2^{31} - 1$ umfasst, also die ganzen Zahlen, die man mit 32 Bit kodieren kann. Operationen für diesen Datentyp sind $+$, $-$, $\times$, $/$, $<$, $>$, Äquivalenz und Modulo, also

das Berechnen des Rests einer Division. Ein anderer elementarer Datentyp ist *Character* (Zeichen). Der Wertebereich ist der von der Programmiersprache unterstützte Zeichensatz, in modernen Programmiersprachen also zumeist Unicode. Die erlaubten Operationen sind die Feststellung von Gleichheit, $>$, $<$ (bezogen auf die Position im Zeichensatz) und die Ermittlung der Position im Zeichensatz in Form einer Zahl.

Manche Programmiersprachen verwenden die gleichen Operationszeichen, um ganz verschiedene Operationen auszudrücken. Welche gemeint sind, wird durch den Datentyp der Variablen und Literale festgelegt:

```
x = 5 + 7
y = "Hallo " + "Welt!"
```

x hat den Wert 12, während y den Wert »Hallo Welt!« hat. In solchen Kontexten führt die folgende Anweisung zu einem Problem:

```
x = 5 + " und hallo"
```

Hier bleibt unklar, welchen Datentyp die Variable x haben soll, daher wird diese Mischung von Datentypen vom Compiler oder Interpreter zumeist als Fehler behandelt.

Auch wenn die meisten höheren Programmiersprachen intern mit verschiedenen Datentypen arbeiten, so unterscheiden sie sich doch sehr stark in den Fragen, wann die Datentypen der Variablen überprüft werden und ob der Datentyp von Variablen explizit im Programm genannt werden muss. Im Fall von **statisch typisierten** Programmiersprachen wird die Überprüfung bei der Kompilierung des Programms vorgenommen, während dies bei **dynamisch typisierten** Sprachen zur Laufzeit des Programms geschieht. Eine **explizite Typisierung** liegt vor, wenn der Datentyp im Programm genannt werden muss. In Java sieht die Anweisung, mit der einer Variablen namens »message« die Zeichenkette »hello world« zugewiesen wird, so aus:

```
String message = "hello world"
```

»String« vor dem Variablennamen legt den Datentyp der Variablen fest. **Implizierte Typisierung** liegt vor, wenn Compiler bzw. Interpreter auf den Datentyp schlussfolgern. In Python sieht die gleiche Zuweisung so aus:

```
message = "hello world"
```

Wenn man in Python anschließend die Anweisung

```
print(message + "!")
> hello world!
```

ausführen lässt, dann sieht man als Ergebnis die ergänzte Zeichenkette »hello world!«, weil der Datentyp aufgrund des Inhalts der Variable und des Datentyps des Literals richtig erkannt wird. Skriptsprachen haben häufig eine dynamische und implizite Typisierung, während kompilierte Sprachen häufig eher statisch und explizit typisiert sind.

Der Datentyp einer Variable bestimmt, wie gesagt, welche Operationen darauf ausgeführt werden. Manchmal ist es notwendig, den Datentyp explizit zu wechseln,

z. B. wenn wir eine Benutzereingabe in Form eines Strings haben, aber eigentlich eine Zahl brauchen, damit wir mit dieser dann Rechenoperationen ausführen können. (Das Zeichen `#` leitet in Python einen Kommentar ein, d. h. alles rechts des Zeichens wird vom Interpreter ignoriert.)

```
eingabe = "41"           # Datentyp der Variable: String
i = int(eingabe)         # Konversion des Datentyps zu int
sinn_des_lebens = i + 1  # Zuweisung des um 1 erhöhten Werts zu
                        # einer neuen Variablen
```

Nach der **Typenkonversion** (englisch: type cast) können wir mit den Operationen des neuen Datentyps arbeiten. Für die Ausgabe, müssen wir häufig Informationen, die in Form von Zahlen- oder Wahrheitswerten vorliegen, zu Zeichenketten umwandeln, um sie mit anderen Zeichenketten verknüpfen zu können:

```
a = 3 + 5
print("Nur " + str(a) + " Personen haben an der Studie teilgenommen.")
> Nur 8 Personen haben an der Studie teilgenommen.
```

Durch den Ausdruck `str(a)` wird der Typ der Variablen `a` von `int` zu `String` geändert – und erst dann kann die Verknüpfung der drei Zeichenketten zu einer erfolgreich durchgeführt werden.

Eingabe/Ausgabe: Die Eingabe von Informationen und die Ausgabe der Ergebnisse sind offensichtlich zentral. Moderne Programmiersprachen unterstützen die einfache Eingabe auf der Kommandozeile, Befehle, die das Programm anhalten, bis der Nutzer eine Eingabe gemacht hat, komplexe Komponenten graphischer Benutzeroberflächen, aber auch das Lesen von Dateien oder das direkte Einlesen von Internetquellen. Für die Ausgabe haben wir bereits die Funktion `print()` kennengelernt. Und auch hier ist die Bandbreite möglicher Ausgabeformen und Formate sehr groß: Anzeigen auf dem Bildschirm, akustische Signale, 3-D Projektionen, Ausgabe in eine Datei usw. Damit wir im Folgenden zumindest Werte vom Benutzer abfragen können, sei der Befehl, mit dem man in Python solche Eingaben steuert, kurz erklärt. Die Funktion heißt `input` und sie hält das Programm an, bis der Benutzer eine Eingabe gemacht hat. Die Eingabe des Benutzers weist man dann einer Variablen zu. Hier ein Beispiel. Der Text in der Klammer ist die Eingabeaufforderung an den Nutzer:

```
a = input("Bitte eine Zahl eingeben: ")  # Abfrage der Eingabe
print("Sie haben " + a + " eingegeben.")  # Ausgabe der Eingabe
> Bitte eine Zahl eingeben: 7
> Sie haben 7 eingegeben.
```

Das kleine Programm hält nach der Ausgabe von `Bitte eine Zahl eingeben:` an und wartet auf die Benutzereingabe. In diesem Beispiel haben wir eine 7 eingegeben und dann auf Return gedrückt. Die 7 wird dann in der Variablen `a` gespeichert. In der `print`-Anweisung wird dann die Variable `a` verwendet.

Der Wert der Eingabe mittels `input()` hat immer den Datentyp `String`. Wenn wir mit eingegebenen Zahlen rechnen wollen, dann müssen wir den Typ konvertie-

ren. Mit diesem Programm erfragen wir zwei Zahlen, addieren das Ergebnis und geben es aus:

```
a = input("Bitte erste Zahl eingeben: ")
b = input("Bitte zweite Zahl eingeben: ")
resultat = int(a) + int(b)          # Konversion des Datentyps zu Integer
print("Ergebnis der Addition: " + str(resultat))
> Bitte erste Zahl eingeben: 7
> Bitte zweite Zahl eingeben: 6
> Ergebnis der Addition: 13
```

Da die Variable ›resultat‹ den Datentyp `int` hat, muss dieser nach `String` konvertiert werden, da wir sonst die nicht-gültige Anweisung geben würde, eine Variable mit dem Datentyp `String` und eine Variable mit dem Datentyp `int` mit dem Operator `+` zu verknüpfen.

6.3 | Datenstrukturen 1: Listen

Die Datenstrukturen unterscheiden sich vor allem darin, welche Operationen mit ihnen besonders einfach auszuführen sind. Um diese abstrakten Aussagen etwas konkreter zu machen, soll in diesem Abschnitt eine grundlegende Datenstruktur höherer Programmiersprachen vorgestellt werden. Die Liste (auch Feld oder Array) ist abstrakt gesehen eine Folge von Speicherplätzen. Jeder Listenplatz kann über seine Hausnummer bzw. den Index angesprochen werden (Abb. 14).

Üblicherweise werden in Listen Daten des gleichen Datentyps abgelegt. Man kann auf ein Element in einer Liste mit seiner Positionsnummer zugreifen. Das könnte etwa so aussehen:

```
autoren = ["Goethe", "Schiller", "Mann", "Kafka"]
```

Will man auf ein Element zugreifen, so wird das als Index angegeben, z. B. so:

```
autoren[1]
```

Da der erste Platz einer Liste in vielen Programmiersprachen und auch in Python die Nummer 0 hat, greift man in diesen Sprachen mit `autoren[1]` auf den zweiten Eintrag, hier also ›Schiller‹, zu:

```
print(autoren[1])
> Schiller
```




Abb. 14 Visualisierung einer Liste

Die grundlegenden Operationen für Listen sind: Anhängen von Daten, Einfügen, Löschen sowie Suchen. Sucht man nach einem Wert, dann erhält man die Positionsnummer als Antwort. Hier einige Beispiele in Python:

Das Erstellen einer Liste:

```
primes = [2, 3, 5, 7, 13, 15, 17]
```

Das Anfügen eines Werts:

```
primes.append(19)
```

Das Einfügen eines Werts (im Folgenden wird die 11, die ja auch eine Primzahl ist, an die richtige Stelle eingefügt, also die fünfte Position, die aber mit 4 adressiert wird, da man bei 0 anfängt):

```
primes.insert(4, 11)
```

Das Entfernen eines Werts. Hier wird die 15 gelöscht:

```
primes.remove(15)
```

Das Suchen eines Werts, wobei man als Ergebnis den Index des gesuchten Werts erhält:

```
print(primes.index(7))  
> 3
```

Man kann also mit der Anweisung

```
primes[3]
```

auf den Wert 7 zugreifen.

Listen werden sehr häufig verwendet, da sie es so leicht machen, auf alle Elemente einer Menge zuzugreifen, indem man erst das erste Element adressiert, dann das zweite usw. Man muss nach jedem Zugriff immer nur den Zeiger auf den Listenplatz um eins erhöhen.

Hier sollen nur die basalen Konzepte des Programmierens vorgestellt werden. Daher wurde von den Details, wie Listen implementiert sind, abgesehen, z. B. ob es sich stets um veränderliche oder etwa um unveränderliche Konstrukte handelt und wie schnell oder langsam bestimmte Operationen auf Listen sind.

6.4 | Ausdrücke, die Wahrheitswerte zurückgeben

In vielen Kontexten brauchen wir Ausdrücke, deren Ergebnis ein Wahrheitswert ist, also entweder wahr oder falsch. Der einfachste Ausdruck ist der Wahrheitswert selbst, der in vielen Programmiersprachen in englischer Sprache notiert wird, z. B.:

```
True
```

Aber im Normalfall ist er das Ergebnis einer Operation, z. B. wenn wir prüfen wollen, ob zwei Variablen den gleichen Wert haben. Angenommen, die Variablen ›anfang‹ und ›ende‹ haben beide den Wert 7, dann wird dieser Ausdruck das Ergebnis ›True‹ haben:

```
anfang = 7
ende = 7
anfang == ende
> True
```

Da es sich hier tatsächlich um eine Gleichsetzung handelt, genauer gesagt, um die Behauptung, dass diese beiden den gleichen Wert haben, wird ein anderes Zeichen als das Zuweisungszeichen verwendet, häufig wie in Python das doppelte ›==‹. Den Unterschied zwischen Zuweisungszeichen und Gleichheitszeichen zu vergessen, ist ein typischer Anfängerfehler.

Man kann auch auf Ungleichheit prüfen:

```
anfang != ende
> False
```

In der gleichen Weise kann man auch eine Reihe von anderen Operatoren verwenden, z. B. die Ungleichheitszeichen kleiner als < oder größer als > :

```
5 < 3
> False
```

Diesen Vergleich kann man, wie oben erwähnt, auch mit Zeichen machen:

```
'a' < 'b'
> True
```

Das Ergebnis des Ausdrucks ist ›True‹, weil der Codepunkt von ›a‹ in Unicode kleiner ist als der von ›b‹. Dagegen ist das Ergebnis dieses Ausdrucks falsch, da die Großbuchstaben in Unicode kleinere Codepunkte haben als die Kleinbuchstaben unseres Alphabets:

```
'a' < 'B'
> False
```

Ein Zahlen-Operator, dem man in der Schulmathematik kaum begegnet, ist modulo. Er berechnet den Rest einer Division. Nur den Rest! So ist 10 modulo 4 gleich 2. 4 passt zweimal in 10, dann bleibt ein Rest von 2. Oder 14 modulo 5 gleich 4. 5 passt zweimal in 10, bleibt ein Rest von 4. Und wenn es keinen Rest gibt, lautet das Ergebnis 0. Das kann man nun etwa dazu verwenden, um zu prüfen, ob eine Zahl gerade ist:

```
anfang % 2 == 0
> False
```

Da die Variable ›anfang‹ oben den Wert 7 zugewiesen bekommen hat, bleibt ein Rest von 1, und $1 \neq 0$ ist falsch. (Das Gegenstück zum Modulo-Operator ist übrigens die Abrundungsdivision mit ›//‹. Sie gibt immer eine ganze Zahl zurück, nämlich wie oft die zweite Zahl in die erste passt, also $10//4 = 2$ und $14//5 = 2$)

Neben diesen häufig genutzten Operatoren geben auch viele Funktionen einen Wahrheitswert zurück. So gibt etwa die Methode `String.isdecimal()` ›True‹ zurück, wenn String erfolgreich in eine Dezimalzahl umgewandelt werden könnte:

```
x = input("Geben Sie eine Zahl ein: ")
x.isdecimal()
> Geben Sie eine Zahl ein: 5
> True
```

Das wird noch interessanter, wenn wir uns die Möglichkeiten anschauen, wie man Ausdrücke kombinieren kann, die Wahrheitswerte zurückgeben. So können wir z. B. zwei Ausdrücke durch ein logisches UND kombinieren. Dieses logische UND wird in vielen Programmiersprachen als ›and‹ oder mit ›&‹ notiert. Wenn beide Teilausdrücke wahr sind, dann ist auch der gesamte Ausdruck wahr:

```
(3 < 4) and (5 < 7)
> True
```

Ist einer der Teilausdrücke oder gar beide falsch, dann ist auch der gesamte Ausdruck falsch.

Operatoren haben eine Rangfolge, wie man das aus der Mathematik kennt, da bei einem Ausdruck wie $4 + 3x$ zuerst die Multiplikation $3 * x$ ausgeführt wird und dann die Addition. So kann man den obenstehenden Ausdruck $(3 < 4) \text{ and } (5 < 7)$ in Python und vielen anderen Sprachen auch ohne Klammern schreiben, da der Vergleichsoperator ›<‹ Vorrang vor dem ›and‹ hat, d. h. zuerst werden die Vergleiche ausgeführt und dann die Konjunktion. Mit Klammern kann man immer festlegen, welche Operation zuerst ausgeführt werden soll.

Zwei weitere Operatoren sind ebenfalls in allen höheren Programmiersprachen zu finden: Disjunktion und Negation. Beim logischen nicht-ausschließenden ODER (›or‹ oder ›|‹) reicht es, dass einer der Teilausdrücke wahr ist, damit der Gesamtausdruck wahr ist:

```
(4 != 4) or (5 < 7)
> True
```

Der erste Teilausdruck ist offensichtlich falsch, aber der zweite ist wahr, daher ist der gesamte Ausdruck ebenfalls wahr.

Der letzte Operator, der hier eingeführt werden soll, ist die logische Negation. Er verkehrt den Wahrheitswert eines Ausdrucks ins Gegenteil:

```
a = True
not a
> False
```

Hier kommen die Wahrheitstabeln der Aussagenlogik zum Einsatz. Im Folgenden stehen a und b für die Teilausdrücke, also z. B. $(4 \neq 4)$ und T für True und F für False für den Wahrheitswert der Teilaussage. Dann kann man in der Tabelle schnell sehen, welchen Wahrheitswert etwa die Kombination einer wahren Teilaussage mit einer falschen Teilaussage hat, wenn sie mit einem ODER verknüpft sind:

a	b	a and b	a or b	not a
T	T	T	T	F
T	F	F	T	F
F	T	F	T	T
F	F	F	F	T

Tab. 3 Wahrheitstafel für Boolesche Operatoren

Man kann auch mehr als zwei Teilausdrücke in dieser Weise verknüpfen.

In den kommenden beiden Abschnitten werden wir zwei zentrale Anwendungsfelder für die Ausdrücke kennenlernen, die wir eben gesehen haben: Schleifen und bedingte Verzweigungen.

6.5 | Schleifen

Die Programme, die wir mit den Mitteln, die wir bislang kennengelernt haben, schreiben könnten, wären in ihrer Leistungsfähigkeit sehr eingeschränkt oder sie würden sehr lang werden, wenn wir etwa eine Operation für jedes Element einer Liste ausführen wollen. Schleifen erlauben es, Programmschritte wiederholt anzuwenden, bis ein gewünschtes Ziel erreicht ist. Zwei Typen von Schleifen finden sich in den meisten imperativen Sprachen. Die erste Schleife wird so lange durchlaufen, bis ein bestimmter Zustand wahr ist. Der zweite Typ ist ein sehr häufig verwendeter Sonderfall des ersten: Die Schleife wird so lange durchlaufen, bis ein Zähler einen bestimmten Wert erreicht hat (s. Ablaufplan in Abb. 15).




Abb. 15 Ablaufplan für eine while-Schleife

Der erste Typ wird zumeist mit einem Konstrukt wie dem Folgenden umgesetzt:

```

<letzte Anweisung vor der Schleife>
<while><Ausdruck, der einen Wahrheitswert zurückgibt>
    <1. Anweisung in der Schleife>
    ...
    <Letzte Anweisung in der Schleife>
<erste Anweisung nach der Schleife>

```

Solange der Ausdruck im Schleifenkopf, der einen Wahrheitswert zurückgibt, wahr ist, werden die Anweisungen in der Schleife ausgeführt. Wenn der Ausdruck »falsch« zurückgibt, wird der Schleifenkörper übersprungen und die erste Anweisung nach der Schleife ausgeführt. Ein Beispiel macht das klarer:

```

x = 3                # Initialisierung der Variablen
y = 0
while x > y:         # Ausdruck wahr, solange x größer als y
    print(x)         # Gibt x aus
    x = x - 1        # Weist x als neuen Wert x-1 zu
> 3
> 2
> 1

```

Der Code im Schleifenkörper wird durch eine Einrückung vom Rest unterschieden. Das ist in Python verpflichtend, andere Sprachen verwenden Klammern oder Schlüsselwörter zur Segmentierung, dann ist die Einrückung üblich, aber optional. In den ersten beiden Zeilen werden den Variablen *x* und *y* jeweils Werte zugewiesen (3 und 0), so dass der Ausdruck *x > y* wahr ist. Dann wird die Schleife das erste Mal durchlaufen: Der Wert von *x* wird ausgegeben und dann wird der Wert von *x* um eins verringert, also auf 2, und wiederum in *x* gespeichert. An dieser Stelle ist der Schleifenkörper zu Ende, und die Schleife springt zurück zum Anfang. Erneut wird der Ausdruck berechnet, und da 2 größer ist als 0 wird die Schleife ein weiteres Mal durchlaufen und *x* wird auf 1 gesetzt. Auch 1 ist größer als 0, deshalb wird die Schleife ein letztes Mal durchlaufen: Die 1 wird ausgegeben und dann wird der Wert von *x* auf 0 gesetzt. An dieser Stelle ergibt die Prüfung im Kopf der Schleife den Wahrheitswert »falsch«, da 0 nicht größer als 0 ist. Der Schleifenkörper wird übersprungen und die anschließenden Anweisungen ausgeführt oder, wie in unserem Fall, das Programm beendet, da keine Anweisungen mehr folgen.

Was passiert, wenn der Ausdruck im Schleifenkopf immer den Wert »True« zurückgibt, etwa, weil wir *x-1* statt *x+1* geschrieben haben? Dann gerät das Programm in eine Endlosschleife und hört nicht auf zu arbeiten. Das ist in den meisten Fällen nicht wünschenswert.

Die Kombination von Listen mit Schleifen ist besonders leistungsfähig. Im Folgenden geben wir alle Elemente einer Liste aus. Die Funktion `len( <Liste> )` gibt die Anzahl der Elemente von `<Liste>` zurück. Die Variable »counter« wird einmal eingesetzt, um die Schleife zu steuern. Zugleich verwenden wir sie als Index für die Adressierung der Elemente in der Liste.

```

autoren = ["Goethe", "Schiller", "Mann", "Kafka"] # Listendefinition
counter = 0                                     # Initialisierung des Zählers
while len(autoren) > counter:                   # Wahr, solange der Zähler kleiner als
    print(autoren[counter])                     # Listenlänge ist. / Ausgabe
    counter = counter + 1                       # Erhöht Zählerwert um 1
> Goethe
> Schiller
> Mann
> Kafka

```

In einem Programm alle Elemente einer Liste zu adressieren, wird auch **Iterieren** über die Elemente der Liste genannt. Da diese Form der Schleife, bei der die Anzahl der Wiederholungen eigentlich schon feststeht, sehr häufig ist, gibt es in vielen Programmiersprachen eine eigene Konstruktion dafür:

```

for each <element> in <Liste>:
    tue etwas mit <element>

```

Die for each-Konstruktion wird syntaktisch recht unterschiedlich umgesetzt. Python z. B. verwendet dafür die for-Schleife (Abb. 16)

In Python können wir z. B. so alle Elemente einer Liste ausgeben:

```

autoren = ["Goethe", "Schiller", "Mann", "Kafka"] # Listendefinition
for name in autoren:
    print(name)
> Goethe
> Schiller
> Mann
> Kafka

```




Abb. 16 Ablaufplan für die for-Schleife in Python

Im ersten Durchlauf wird das erste Element aus der Liste genommen und der Variablen ›name‹ zugeschrieben, so dass im Schleifenkörper dann auf dieses Element der Liste mit dem Bezeichner ›name‹ zugegriffen werden kann. Im zweiten Durchlauf geschieht dies mit dem zweiten Element der Liste usw., bis die Liste erschöpft ist. Schleifen gehören zu den **Kontrollstrukturen**, mit denen beim Programmieren der Ablauf eines Programms gesteuert wird.

6.6 | Bedingte Verzweigungen

Die zweite Kontrollstruktur, die wir uns genauer anschauen wollen, ist die bedingte Verzweigung. Der etwas umständliche Name bezeichnet eine ebenso einfache wie mächtige Konstruktion:

```
<letzte Anweisung vor der Verzweigung>
<if><Ausdruck, der einen Wahrheitswert zurückgibt>:
    <1. Anweisung in der Verzweigung>
    ...
    <Letzte Anweisung in der Verzweigung>
<erste Anweisung nach der Verzweigung>
```

Die bedingte Verzweigung funktioniert wie eine Zugweiche: Nur, wenn der Ausdruck wahr ist, führt das Programm den Code innerhalb der Verzweigung aus. Im Prinzip haben wir die gleiche Struktur wie bei der while-Schleife vor uns, aber der Codeblock in der Verzweigung wird nur einmal abgearbeitet (Abb. 17). Auch hier wird der Codeblock durch eine Einrückung vom Rest abgesetzt.

Hier ein Beispiel für eine einfache bedingte Verzweigung in Python:

```
i = input("Geben Sie eine Zahl ein: ")
if i % 2 == 0: # Prüfung, ob bei Division durch 2 ein Rest da ist
    print("Eingabe ist eine gerade Zahl.")
print("Ende")
> Geben Sie eine Zahl ein: 6
> Eingabe ist eine gerade Zahl.
> Ende
```




Abb. 17 Ablaufplan für eine einfache bedingte Verzweigung




Abb. 18 Ablaufplan einer if-else-Verzweigung

Der Ausdruck $i \% 2 == 0$ ist wahr, wenn i eine gerade Zahl ist. Unsere Eingabe 6 ist eine gerade Zahl, also wird der Code in der Verzweigung ausgeführt.

Wir können bedingte Verzweigungen dadurch etwas komplexer gestalten, dass wir auch festlegen, was geschehen soll, wenn die Bedingung nicht erfüllt ist (Ablaufplan s. Abb. 18).

Wir können die Kontrollstruktur noch komplexer gestalten, indem mehrere Bedingungen geprüft werden, z. B. so (elif ist die Abkürzung für *else if*). Das benutzen wir um in dem folgenden Beispiel ein kleines Benutzermenü zu gestalten. Aus Platzgründen stehen die Kommentare zu einer Zeile immer in der vorangehenden Zeile:

```

# Endlose while-Schleife
while True:
    # Eingabe des Benutzers inkl. Menüausgabe
    raw_input = input("Bitte Menüpunkt wählen \n(1) Primzahlen," +
                      "(2) Fibonacci-Zahlen, (3) Ende: ")
    # Datentyp der Eingabe wird nach int konvertiert
    menu_item = int(raw_input)
    # Nutzer wählt Menüpunkt 1
    if menu_item == 1:
        print("Die ersten 5 Primzahlen: ")
        # Schleife zur Ausgabe der Primzahlen
        for i in [2, 3, 5, 7, 11]:
            print(i)
    # Nutzer wählt Menüpunkt 2
    elif menu_item == 2:
        print("Die ersten 5 Fibonaccizahlen: ")
        for i in [1, 1, 2, 3, 5]:
            print(i)
    # Nutzer will das Programm verlassen
    elif menu_item == 3:
        print("Auf Wiedersehen!")
        # Die Anweisung break beendet die while-Schleife
        break
    else:
        # Benutzer-Erziehung
        print("Bitte wählen Sie 1, 2, oder 3")
  
```

```

> Bitte Menüpunkt wählen
> (1) Primzahlen, (2) Fibonacci-Zahlen, (3) Ende: 2
> Die ersten 5 Fibonaccizahlen:
> 1
> 1
> 2
> 3
> 5
> Bitte Menüpunkt wählen
> (1) Primzahlen, (2) Fibonacci-Zahlen, (3) Ende: 3
> Auf Wiedersehen!

```

Die bedingte Verzweigung arbeitet die Bedingungen der Reihe nach ab. Sobald eine wahre Bedingung gefunden wird, wird diese ausgeführt und das Programm wird mit den Anweisungen nach der Verzweigung fortgeführt. Durch die Endlosschleife, wird das Menü immer wieder angezeigt, wenn einer der Menüpunkte abgearbeitet wurde.

Mit den drei Strukturen, die wir kennengelernt haben – dem schrittweisen Abarbeiten von Anweisungen, der Schleife und der bedingten Verzweigung – kann man im Prinzip bereits alle Algorithmen aufbauen.

6.7 | Datenstrukturen 2: assoziatives Feld

Die zweite grundlegende Datenstruktur, die von höheren Programmiersprachen zur Verfügung gestellt wird, ist das assoziative Feld (auch: *dictionary* oder *map*). Es handelt sich dabei um eine Menge von Schlüssel-Wert-Paaren. Die Besonderheit liegt darin, dass wir nicht eine Zahl verwenden, um auf ein Element zuzugreifen, sondern einen Schlüssel. Das kann ein Buchstabe sein, eine Zeichenkette oder auch eine komplexere Datenstruktur. Die Elemente eines assoziativen Feldes folgen keiner vorgegebenen internen Struktur, vielmehr greift man immer nur über den Schlüssel auf sie zu. Abbildung 19 zeigt die drei Elemente eines assoziativen Feldes namens *titel*. Dem Schlüssel ›Mann‹ ist der Wert ›Die Buddenbrooks‹ zugeordnet; dem Schlüssel ›Goethe‹ der Wert ›Faust‹. Eine Tragödie usw.




Abb. 19 Aufbau eines assoziativen Feldes (*dictionary*) mit 3 Schlüssel-Wert-Paaren

Der folgende Code setzt das Beispiel als *dictionary* in Python um:

```
titel = {"Mann": "Buddenbrooks", "Goethe": "Faust. Eine Tragödie",
        "Schiller": "Der Geisterseher"}
```

Wir können nun wie in einem Wörterbuch – daher der Name – einen Eintrag über das Stichwort, also den Schlüssel, aufrufen:

```
print(titel["Goethe"])
> Faust. Eine Tragödie
```

Wenn wir nur den Inhalt des Eintrags, also z. B. ›Faust. Eine Tragödie‹ kennen, aber den zugehörigen Schlüssel ermitteln wollen, müssen wir alle Werte durchsuchen, bis wir den richtigen gefunden haben.

Es gehört, wie gesagt, zu ihren Besonderheiten, dass assoziative Felder die Folge ihrer Elemente nicht festlegen. Man kann sich in Python z. B. den gesamten Inhalt des dictionaries anzeigen lassen und wird, wenn man dies wiederholt, eine andere Reihenfolge der Elemente finden:

```
print(titel)
> {'Mann': 'Buddenbrooks', 'Goethe': 'Faust. Eine Tragödie', 'Schiller':
  'Der Geisterseher'}
print(titel)
> {'Goethe': 'Faust. Eine Tragödie', 'Schiller': 'Der Geisterseher',
  'Mann': 'Buddenbrooks'}
```

Folgende Operationen sind mit assoziativen Feldern möglich: ein neues Schlüssel-Wert-Paar hinzufügen und ein Schlüssel-Wert-Paar löschen. Hier die Anweisungen in Python:

```
titel["Lessing"] = "Nathan der Weise"
del(titel ["Mann"])
print(titel)
> {'Schiller': 'Der Geisterseher', 'Lessing': 'Nathan der Weise', 'Goethe':
  'Faust. Eine Tragödie'}
```

Außerdem können wir mit einer Schleife über alle Schlüssel-Wert-Paare iterieren:

```
for key in titel.keys():
    print(key + " " + titel[key])
>Schiller: Der Geisterseher
>Lessing: Nathan der Weise
>Goethe: Faust. Eine Tragödie
```

Die Methode ›keys()‹ gibt Schlüssel des *dictionaries* ›titel‹ in einer Art Liste aus, von der wir in der for-Schleife ein Element nach dem anderen bearbeiten. Die Schleife speichert dabei jeweils den aktiven Wert aus der Liste in der Variablen ›key‹ (die natürlich auch ganz anders heißen könnte). Der Ausgabebefehl, der mit ›print‹ beginnt, gibt zuerst den Wert der Variablen ›key‹ aus, fügt dann ein Leerzeichen hinzu und gibt dann den Wert aus, der dem Schlüssel zugeordnet ist.

6.8 | Modularisierung

Funktionen

Wir haben nun im Prinzip alle Mittel in der Hand, um Programme zu schreiben, aber wir würden bald feststellen, dass wir unsere Programme, wenn sie etwas länger werden, nicht mehr warten können, weil es sehr schwer wird, Fehler zu finden oder das Programm um neue Funktionen zu erweitern. Viele zentrale Strategien der Software-Entwicklung zielen vor allem darauf ab, diese Probleme zu bewältigen, die, um die Unterscheidung vom Anfang wieder aufzugreifen, insgesamt weniger mit der Kommunikation mit der Maschine zu tun haben, sondern vor allem mit der Kommunikation mit dem Menschen. Zu den Konzepten, die man dafür in den letzten Jahren entwickelt hat, zählen die Modularisierung von Programmen in Funktionen und Modulen, das Paradigma des Objektorientierten Programmierens (OOP) und vieles andere mehr. In diesem Abschnitt soll es um die Modularisierung in Funktionen und Modulen gehen.

Funktionen dienen dazu, klar definierte Aufgaben zu erledigen. Sie zu definieren, ist zumeist sehr einfach, schwieriger ist es schon zu entscheiden, was genau Teil einer Funktion sein soll. Beginnen wir aber erst einmal mit den Grundbegriffen. Wir haben bislang schon wiederholt mit Funktionen gearbeitet. Eine davon wollen wir uns näher ansehen: die Funktion `len(liste)`. Sie gibt die Anzahl der Elemente einer Liste zurück:

```
a = [1, 2, 3]      # definiert eine Liste
i = len(a)         # weist der Variablen i als Wert deren Länge zu
print(i)          # gibt i aus
> 3
```

Nach dem Namen einer Funktion folgt in Klammern die Angabe der **Parameter** oder **Argumente**; in unserem Beispiel ist das der Name der Liste, deren Länge ermittelt werden soll. Auf diese Weise werden Funktionen Werte übergeben, die sie dann weiterverarbeiten. Ein **Parameter** oder **Argument** der Funktion `len()` ist der Name der Variable, unter der eine Liste gespeichert ist, oder die Liste selbst. Ihr **Rückgabewert** ist ein einzelner Wert: die Länge der Liste. Funktionen sind also definiert durch ihren Namen und die Folge der Argumente, die der Funktion übergeben werden, sowie durch ihren Rückgabewert, der auch leer sein kann. Das ist ihre **Signatur**. Bei explizit typisierten Programmiersprachen gehört außerdem der Datentyp der Argumente und des Rückgabewerts zur Signatur. Die Argumente können optional sein oder obligatorisch, häufig sind einige obligatorisch und andere optional.

Schauen wir uns eine weitere Funktion an, mit der wir bereits gearbeitet haben: `print()`. Das wichtigste Argument ist der Text, der ausgegeben werden soll. Hat `print()` einen Rückgabewert? Z. B. den Text? Dass `print()` Text im Konsolenfenster ausgibt, ist ein Nebeneffekt, aber diese Funktion hat keinen Rückgabewert. Man kann das einfach selbst ausprobieren, indem man den Rückgabewert von `print()` einer Variablen zuschreibt und sich dann den Inhalt der Variablen ansieht.

Eine der Stärken von Funktionen ist die Tatsache, dass man sie verschachteln kann, dass also der Rückgabewert einer Funktion gleich wieder zur Eingabe einer

anderen wird. So können wir die Zeilen zwei und drei unseres letzten Beispiels auch so zusammenschreiben:

```
print(len(a))
> 3
```

Die Rückgabe des Funktionsaufrufs `len(a)` wird zur Eingabe der Funktion `print()`. Wir können solche Verschachtelungen immer weiter treiben, allerdings ist die Lesbarkeit dann oft bald nicht mehr gegeben. Zu lesen sind solche verschachtelten Ausdrücke immer von innen nach außen.

Schauen wir uns ein häufig verwendetes Konstrukt an, das eine Schleife *n*-mal durchläuft, wobei *n* eine beliebige ganze Zahl sein kann, z. B. die Länge einer Liste:

```
zahlen = [1, 4, 6]
for i in range(len(zahlen)):
    print(zahlen[i])
> 1
> 4
> 6
```

`len()` gibt die Anzahl der Elemente in der Liste `zahlen` zurück, also 3. Diese Zahl dient wiederum als Argument für die Funktion `range()`. `range(n)` erzeugt im Prinzip eine Liste mit ganzen Zahlen von 0 bis *n* (ausschließlich *n*), hier also `[0, 1, 2]`. Wir benutzen die Zahlen als Index für die Elemente in der Liste und können so über die Liste iterieren.

Bislang haben wir uns angesehen, wie man Funktionen aufruft. Nun wollen wir uns damit beschäftigen, wie man selbst Funktionen definiert. Die Definition einer Funktion muss die eben erläuterten Komponenten enthalten. Sie muss die Signatur festlegen, also welchen Namen die Funktion hat, welche Argumente beim Aufruf anzugeben sind oder optional ergänzt werden können, wie der Rückgabewert aussieht sowie – bei explizit typisierten Programmiersprachen – auch die jeweiligen Datentypen. Außerdem muss sie natürlich den Code enthalten, der die Funktionalität leistet. In Python sieht die Definition einer Funktion, die die Länge einer Liste berechnet, so aus (Der Text zwischen den beiden `"""` ist ebenfalls Kommentar):

```
def len_list(alist):          # definiert Funktion mit dem Namen len_list
                              # und dem Argument alist
    """Berechnet Anzahl der Elemente einer Liste. Rückgabewert: Anzahl
    der Elemente. """
    cnt = 0                   # initialisiert Zähler
    for i in alist:           # Schleife über alle Elemente in der Liste
        cnt += 1              # erhöht Zähler um 1
    return cnt                # gibt Zähler zurück
```

Das Schlüsselwort `def` besagt, dass es sich um die Definition einer Funktion handelt. `len_list()` ist der Name der Funktion und `alist` ist ein Argument der Funktion. Der Name des Arguments ist frei wählbar. Über ihn können wir auf den beim Aufruf

der Funktion übergebenen Wert im Innern der Funktion zugreifen, so wie wir es von Variablen gewohnt sind. Wenn wir die definierte Funktion verwenden, z. B. so:

```
x = len_list([1,2,3])
```

dann wird das Argument, das in der Klammer steht, für die Dauer des Funktionsaufrufs der Variablen `alist` zugeschrieben, so als hätten wir geschrieben:

```
alist = [1, 2, 3]
```

Wie wir sehen, wird der Datentyp des Arguments nicht bestimmt, zugleich geht die Funktion davon aus, dass ihr eine Liste übergeben wird. Im Körper der Funktionsdefinition sehen wir, dass anfangs ein Zähler auf 0 gesetzt wird. Dann wird über jedes Element der Liste iteriert und dabei wird der Zähler um eins erhöht. In der letzten Zeile steht ein weiteres Schlüsselwort, das für Funktionen reserviert ist: `return`. Es besagt, dass der Wert des anschließenden Ausdrucks der Rückgabewert ist. In unserem Beispiel ist das naheliegender Weise der Zähler. Testen wir unsere Funktion:

```
a = ["a", "b", "c"]
print(len_list(a))
> 3
```

Funktionen sind in sich abgeschlossene Einheiten mit genau definierten Schnittstellen nach außen: die Argumente, mit denen sie aufgerufen werden, dienen als Eingabe, und der Rückgabewert als Ausgabe. Sind Funktionen einmal geschrieben und gut getestet, dann sollte für alle Anwender der Funktion – einschließlich des Autors der Funktion – kein Bedarf mehr bestehen, über ihr Innenleben Bescheid zu wissen. Und umgekehrt: Es ist auf diese Weise möglich, das Innenleben einer Funktion völlig zu verändern, also z. B. einen effizienteren Algorithmus zu implementieren, ohne dass derjenige, der die Funktion verwendet, selbst etwas an seinem Code verändern muss. Eine Funktion abstrahiert also auf diese Weise von den konkreten Details der Implementierung. Diese Abstraktion ist zentral für das Management von Komplexität beim Programmieren.

Ein weiterer Vorteil von Funktionen besteht darin, dass wir Code einsparen können. Wenn wir am Anfang eines längeren Programms die Länge einer Liste berechnen müssen und das auch wieder am Ende tun müssen, dann können wir unsere einmal geschriebene Funktion an beiden Stellen verwenden, müssen den Code dafür also nur einmal schreiben. Und wenn wir einen Fehler in unserem Code entdecken oder einen schnelleren Algorithmus entdeckt haben, müssen wir unser Programm auch nur noch an einer Stelle verändern. Außerdem stehen die Chancen gut, dass wir eine Funktion, die wir einmal geschrieben haben, auch an anderen Stellen wieder verwenden werden. Das Einsparen von Code und seine Wiederverwendbarkeit tragen ebenfalls zur Reduktion von Komplexität bei.

Gültigkeit von Variablen: Ein positiver Effekt von Funktionen besteht darin, dass sie die Reichweite der Gültigkeit von Variablen einschränken. Eine Variable, die global definiert ist, ist immer gültig. Das klingt zuerst nach einem Vorteil, ist aber schnell ein Nachteil, wenn ich nicht genau sehen kann, welcher Teil des Programms gerade auf sie zugreift und wie sie wann verändert wurde. Variablen, die innerhalb

von Funktionen definiert wurden, sind nur dort gültig. Ihr Speicher wird nach dem Funktionsaufruf freigegeben, und es kann auch keine Verwirrung dadurch entstehen, dass eine andere Funktion darauf zugreift. Die Einschränkung der Gültigkeit einer Variablen (engl. *scope of a variable*) macht Programme ebenfalls einfacher zu verstehen und zu warten.

Damit Codeeinsparung und Wiederverwendbarkeit aber gut funktionieren, können wir nicht einfach irgendwo den Code einteilen, sondern müssen die Modularisierung so vornehmen, dass die Funktionen gut wieder zu verwenden sind. Eine wichtige Rolle spielt dabei die Frage, was alles Teil einer Funktion sein soll. Wenn wir z. B. in unserem Programm immer auch die Länge der Liste ausgeben müssen, könnten wir überlegen, die Ausgabe gleich zum Teil der Funktion zu machen. Wir brauchen dann nur einen Funktionsaufruf und haben die Berechnung und die Ausgabe erledigt. Langfristig aber würde das die Wiederverwendbarkeit der Funktion stark einschränken, da wir sie nun nur dort einsetzen können, wo wir diese zwei Operationen benötigen. Wenn wir aber Berechnung und Ausgabe in zwei Funktionen auslagern, können wir diese unabhängig voneinander wiederverwenden. Funktionen sollten also stets möglichst einfache, klar definierte Aufgaben erledigen.

Abstraktion: Außerdem spielt Abstraktion eine zentrale Rolle für die effiziente Modularisierung. Wir müssen die Aufgabe, die wir mit der Funktion lösen wollen, immer genau analysieren: Ist sie eine spezielle Anwendung eines allgemeinen Falles? Wenn ja, können wir die Funktion so gestalten, dass wir durch eine geeignete Parametrisierung unser spezifisches Problem als Sonderfall des allgemeinen formulieren können. Das klingt etwas abstrakt und sei daher mit einem Beispiel verdeutlicht. Angenommen wir wollen mit einem Text eine stilometrische Untersuchung durchführen und dafür zählen, wie viele Vokale jeweils in einem Wort vorkommen. Dann können wir natürlich eine entsprechende Funktion schreiben: `count_vowels(word)`, deren Rückgabewert die Anzahl der Vokale ist. Aber wir könnten dies auch als einen Sonderfall eines allgemeineren Problems begreifen: Wir haben eine Folge, in unserem Fall die Zeichen im Wort, und eine Menge, z. B. Vokale, und wir wollen wissen, wie häufig die Elemente der Menge in der Folge vorkommen. Um diesen generischen Fall zu bearbeiten, brauchen wir also eine Funktion, die als Argumente die Folge und die Menge akzeptiert und dann die Häufigkeit zurückgibt:

```
count_elements(folge, menge)
```

Wollen wir nun Vokale zählen, dann können wir direkt die generische Methode verwenden:

```
count_elements(word, ["A", "E", "I", "O", "Ü", "a", "e", "i", "o", "u"])
```

Wenn wir unsere Funktion zum Zählen der Vokale aber häufiger verwenden und feststellen, dass wir anfangen, die lange Vokalliste zu kopieren, bei der die Umlaute und Vokale mit Akzent ja sogar noch fehlen, dann sollten wir eine Funktion schreiben, die auch dies wiederum nur einmal leistet:

```
def count_vowels(word):
    return count_elements(word, ["A", "E", "I", "O", "Ü", "a", "e", "i", "o", "u"])
```

Wichtig ist, dass wir nun die beiden Operationen – Zählen, Auflisten der Vokale – ge-

trennt haben und nun etwa ohne großen Aufwand eine Funktion schreiben könnten, die Konsonanten zählt.

Es sollte deutlich geworden sein, wie zentral Abstraktion für effizientes Programmieren ist: Dadurch wird der Code sehr modular, gut wiederverwendbar und auch besser wartbar.

Objekt-orientierte Programmierung: Ein wichtiges Konzept zur Modularisierung und Abstraktion in imperativen Sprachen ist die objekt-orientierte Programmierung (OOP). In diesem Ansatz werden zusammengehörige Daten und Funktionen in einem Objekt gespeichert; solche Funktionen werden dann **Methoden** genannt. Außerdem werden die Objekte selbst in Klassenhierarchien organisiert, so dass Unterklassen, z. B. Quadrat, von Oberklassen, z. B. Rechteck, Attribute und Methoden erben können. Python unterstützt objektorientiertes Programmieren, tatsächlich ist alles in Python ein Objekt. Wir haben oben auch schon den Unterschied zwischen einer Funktion und einer Objektmethode kennengelernt, als wir die Methode `isdecimal()` der Klasse `String` verwendet haben. Objektmethoden lassen sich auch ohne tiefere Kenntnis der OOP verwenden, solange man sich daran erinnert, dass sie syntaktisch mit dem Objekt verbunden sind. Aus Platzgründen können wir hier nicht auf die OOP eingehen, aber die gängigen Einführungen in Python (z. B. Zelle 2010) behandeln die OOP ausführlich.

Programmbibliotheken

Höhere Programmiersprachen ermöglichen es, mehrere Funktionen zusammen in einem Paket zu bündeln. Dieses Paket kann dann von anderen Programmen angesprochen werden, so dass diese dessen Funktionen nutzen können. Man spricht dann von einer **Programmbibliothek** oder einfach nur Bibliothek. Bibliotheken sind üblicherweise nicht selbst lauffähig, sondern dienen vor allem dazu, Funktionen zur Verfügung zu stellen. Zumeist ist es dabei noch nicht einmal notwendig, dass die Bibliotheken als Code vorliegen, vielmehr reicht es für viele Zwecke aus, sie in kompilierter Form vorliegen zu haben. Man kann nicht genug betonen, wie zentral Bibliotheken für das Programmieren sind. Sie sind kondensierte, gespeicherte Arbeitszeit und Intelligenz und ermöglichen jedem, der auf sie zugreifen kann, diese Zeit und Problemlösungskompetenz in den Dienst der eigenen Sache zu stellen.

Da die Mechanismen, wie eine Bibliothek konstruiert und verwendet wird, von Sprache zu Sprache wechseln, sei dies im Folgenden wieder mit Python-Beispielen demonstriert. In Python werden Bibliotheken Module genannt, genauer: eine Bibliothek besteht aus einem oder mehreren Modulen. Ein Modul ist nichts anderes als eine Textdatei, in der der Code für die Funktionen des Moduls steht. Der Name der Datei – ohne die Endung `.py` – ist der Name des Moduls. Legen wir eine Textdatei namens `prettyprint.py` an, in der wir die folgende Funktion abspeichern, die Text zentriert ausgibt. Der Text zwischen den beiden `"""` ist wieder Kommentar.

```
def centerprint(text):
    """
    Zeige Text zentriert an (in einem 80 Zeichen-breiten Feld)
    """
    print('{: ^80}'.format(text)) # verwendet die Methode format der
                                # Klasse String, um die Darstellung
                                # zu bestimmen
```

Die Datei `prettyprint.py` ist nun unsere Bibliothek. Um darauf zugreifen zu können, legen wir im gleichen Verzeichnis eine neue Datei an, in die das Programm geschrieben wird, das die Funktion `centerprint()` verwendet. Wir müssen angeben, auf welches Modul wir zugreifen wollen. Dazu verwenden wir eine `import`-Anweisung, üblicherweise am Anfang des Programmcodes:

```
import prettyprint
```

Und nun können wir die Funktion verwenden. Allerdings müssen wir immer den Namen des Moduls voransetzen:

```
prettyprint.centerprint("Hier steht die Überschrift!")
```

Warum müssen wir hier den Namen des Moduls angeben? Beim Ausführen eines Programms werden die Namen der Variablen und der Funktionen des Programms in einer **Symboltabelle** gespeichert. In der **globalen Symboltabelle** werden die Namen gespeichert, die für das ganze Programm zugänglich sind. Wir hatten oben schon darüber gesprochen, dass hier möglichst wenige veränderliche Variablen stehen sollten. Außerdem gibt es lokale Symboltabellen, etwa durch den Import einer Bibliothek oder auch für den eingeschränkten Gültigkeitsbereich etwa innerhalb einer Funktion. Durch den Namen des Moduls geben wir an, wo die Funktion zu finden ist.

Der Zugriff auf das Modul, den wir hier beschrieben haben, setzt voraus, dass die Bibliothek im gleichen Verzeichnis liegt. Das wäre bei umfangreichen Bibliotheken und Anwendungen auf Dauer unpraktisch, deshalb gibt es in der Regel eine Reihe von Orten, an denen man Bibliotheken für eine Programmiersprache ablegen kann.

Höhere Programmiersprachen werden mit einer umfangreichen Standardbibliothek ausgeliefert, die zahlreiche Funktionen zur Verfügung stellt. In Python enthält die Standardbibliothek Module für reguläre Ausdrücke, verschiedene Datenstrukturen, Zugriff auf Internetprotokolle und vieles andere mehr. Einige neuere Sprachen verfügen außerdem über einen Paketdienst, der es erlaubt, Bibliotheken mit einem einfachen Kommando aus einem zentralen Repository im Internet lokal zu installieren und zu verwenden. Für Python ist dieses Repository unter der Adresse <https://pypi.python.org/> zu finden; es hat im September 2016 rund 88.000 Pakete, deren Umfang von einer kleinen Helferbibliothek zum Ausdruck von Daten, über komplexe Bibliotheken etwa zur Datenanalyse, bis hin zu umfangreichen Anwendungen, etwa modularen Webservern, reicht. Wenn man sich überlegt, welche Programmiersprache man erlernen will, dann sollte auch Art und Umfang dieses ›Ökosystems‹ der Sprache eine Rolle spielen.

6.9 | Algorithmisches Denken

Die eigentliche Herausforderung beim Programmieren besteht weniger darin, die konkrete Syntax einer Programmiersprache zu erlernen, sondern vielmehr darin, ein Problem so zu betrachten, dass sich dessen Lösung als eine Serie von klar definierten Einzelschritten darstellt. Diese Fähigkeit, das algorithmische Denken, wird inzwischen allgemein als Kernkompetenz eines Informatikers und Programmierers angesehen. Wie bei allen Kompetenzen hilft Begabung, vor allem aber ist Übung der Schlüssel, um gute Resultate zu erzielen. Es handelt sich, wie das Sprechen einer

Sprache, Tanzen oder Fahrradfahren um prozedurales Wissen. Und so wie man ohne Übung nicht lernen kann, wie man eine Fremdsprache spricht, so kann man ohne wiederholte und dauerhafte Übung, etwa durch die Analyse und Anwendung von existierenden Algorithmen (Sedgewick/Wayne/Dondero 2015) auch das algorithmische Denken nicht erlernen.

Was genau ist mit **algorithmischen Denken** (manchmal auch *computational thinking*) gemeint? Auch wenn die genauen Definitionen immer wieder etwas anders aussehen, so ist doch eine Liste wie die Folgende eine ganz gute Orientierung (vgl. Futschek 2006). Danach ist algorithmisches Denken die Fähigkeit,

- ein gegebenes Problem zu analysieren
- einfache Schritte festzulegen, um das Problem zu lösen
- aus den einfachen Schritten eine Lösung für das Problem zu erstellen, d. h. einen vollständigen und korrekten Algorithmus zu konstruieren
- die Fähigkeit, alle typischen und ungewöhnlichen Fälle des Problems zu bedenken
- die Fähigkeit, die Effizienz eines Algorithmus zu verbessern

Wir wollen einige dieser Aspekte an einem einfachen Beispiel diskutieren (nach Zelle 2010: Kap. 13). Es wird dabei schnell deutlich werden, dass viele der Punkte, die wir oben im Zusammenhang mit dem Schreiben von Funktionen angesprochen haben, ebenfalls schon Beispiele für das algorithmische Denken sind.

Das Problem, das wir lösen wollen, ist recht einfach: Wir haben eine lange Liste mit positiven ganzen Zahlen vor uns, z. B. Jahreszahlen, Nummern in Geburtsregistern, Personalnummern usw. Wir wollen schnell herausfinden, an welcher Position der Liste eine gegebene Zahl x steht, falls sie in der Liste enthalten ist. Wir wissen von der Liste, dass die Zahlen darin aufsteigend sortiert sind. Wie können wir die Suche effizient gestalten?

Die einfachste Möglichkeit besteht darin, das erste Element der Liste mit x zu vergleichen, dann das zweite Element mit x zu vergleichen usw. Sobald der Vergleich positiv ausfällt, haben wir den Platz in der Liste gefunden und können die Information ausgeben. Wenn wir am Ende der Liste sind und x noch nicht gefunden haben, dann geben wir -1 aus, um darüber zu informieren, dass das Element nicht enthalten ist

```
def simple_search(x, alist):
    """Search for x in list and return index or -1 if not found"""
    for i in range(len(alist)):
        if alist[i] == x:                # wahr, wenn x gefunden wurde
            return i
    return -1                          # x wurde nicht gefunden
```

Wir haben eine Schleife definiert, in der i alle Werte von 0 bis zur Länge der Liste minus 1 annimmt. i dient dann als Index für unsere Liste. In der Verzweigung wird geprüft, ob der Wert am i -ten Listenplatz gleich x ist. Wenn der Ausdruck wahr ist, dann haben wir das Gesuchte gefunden und können die Suche abbrechen und den Wert zurückgeben. Verwenden wir die Funktion und schauen uns dabei an, welche Werte die Variablen haben. Mit den folgenden zwei Zeilen definieren wir eine Liste und suchen dann in der Liste nach der Position der Zahl 4:

```
a = [1, 3, 4, 7, 9, 10, 11, 15]
print(simple_search(4, a))
> 2
```

Ruft man die Funktion auf, so wird, da die Liste 8 Elemente hat, im Kopf der Schleife bestimmt, dass die Schleife acht Mal durchlaufen werden soll. *i* hat im ersten Durchgang den Wert 0. Der erste Wert in der Liste ist nicht der gesuchte: $1 \neq 4$ gibt False zurück. Im zweiten Durchgang hat *i* den Wert 1 und die Zahl aus der Liste ist die 3. Wieder ist der Ausdruck in der Verzweigung falsch. Im dritten Durchgang hat *i* den Wert 2. Auf dem dritten Platz der Liste steht die 4. Sie ist identisch mit dem gesuchten Wert, daher ist der Ausdruck `alist[i] == x` wahr und die 2 wird zurückgegeben.

Der Algorithmus löst das Problem. Allerdings hat er einen kleinen Schönheitsfehler: Je länger die Liste ist, umso länger wird man suchen, besonders, wenn man das Pech hat, einen Eintrag gegen Ende der Liste zu suchen. Die Suchzeit ist direkt von der Länge der Liste abhängig; verdoppeln wir die Länge der Liste, verdoppeln wir auch die Suchzeit. Der Zusammenhang zwischen Länge der Liste und Suchzeit ist also linear. Einen Algorithmus, der ein Problem so direkt angeht wie dieser, nennt man auch einen *brute-force*-Algorithmus, da er ohne größere Raffinesse auf bloße Rechenleistung setzt. Vielleicht finden wir etwas Schnelleres.

Eine erste Verbesserung könnte darin bestehen, dass wir uns den Umstand zunutze machen, dass die Liste sortiert ist. Wenn also der Wert aus der Liste, den wir mit dem gesuchten Wert vergleichen, größer ist, dann wissen wir, dass wir nicht weitersuchen müssen, sondern -1 zurückgeben können. Für die Suche nach Werten, die nicht in der Liste sind, können wir die Suchzeit im Durchschnitt also etwa halbieren. Das kann im Einzelfall wichtig sein. Interessanter wäre es aber, einen Algorithmus zu finden, der die Suchzeit in allen Fällen verkürzt.

Tatsächlich können wir hierfür eine Strategie verwenden, auf die wir auch zurückgreifen, wenn jemand uns fragt, ob wir eine Zahl zwischen 1 und 100 erraten. Wir teilen den Suchraum in zwei gleiche Teile, indem wir erst einmal 50 raten. Würden wir dann die Antwort erhalten, die Zahl sei kleiner, dann teilen wir den Raum zwischen 1 und 50 in zwei gleiche Teile und sagen 25 usw. (Zelle 2010: 428; Sedgewick/Wayne/Dondero 2015: Kap. 4.2). Diese Suchstrategie wird von einem Algorithmus umgesetzt, der **binäre Suche** heißt, da wir den Suchraum bei jedem Schritt in zwei Hälften teilen. Hier eine Umsetzung in Python.

```
def binary_search(x, alist):
    """Search for x in list and return index or -1 if not found"""
    low = 0
    high = len(alist) - 1
    while low <= high:
        mid = (low + high) // 2      # ermittelt die Mitte der Liste
        if alist[mid] > x:           # Wenn Listenmitte größer als x
            high = mid - 1          # mache die Mitte zum oberen Ende
        elif alist[mid] < x:        # Wenn Listenmitte kleiner als x
            low = mid + 1           # mache die Mitte zum unteren Ende
        else:
            return mid              # wenn mid weder größer noch kleiner
                                   # ist als mid ist, haben wir x gefunden
    return -1
```

In den ersten beiden Anweisungen der Funktion wird der untere und der obere Endpunkt des Suchraums jeweils einer Variable zugewiesen. Am Anfang ist der untere Punkt 0 und der obere Punkt ist die Position des letzten Werts in der Liste, also die

Länge der Liste minus 1. Nun kommt der Anfang der Schleife. Die Schleife läuft solange wie der untere Endpunkt kleiner oder gleich dem oberen Endpunkt ist. Wenn die Schleife aufhört zu laufen, weil dieser Ausdruck falsch ist, bedeutet dies, dass die gesuchte Zahl nicht gefunden wurde, deshalb steht im Anschluss an die Schleife die Anweisung, -1 zurückzugeben. Diese Anweisung wird nur erreicht, wenn der gesuchte Wert nicht in der Liste ist. Der Code in der Schleife beginnt mit einem Ausdruck, der der Variablen »mid« zugewiesen wird und die Mitte zwischen dem oberen und dem unteren Endpunkt berechnet.

Da wir nur mit ganzzahligen Indizes für die Listen arbeiten können, wird die Division mit dem doppelten Strich verwendet »//«. Wie oben schon ausgeführt, ist das Ergebnis einer Division von Zahlen mit // immer eine ganze Zahl. Diese Zeile entspricht dem Raten der mittleren Zahl, also bei einer Zahl zwischen 1 und 100 50 und dann 25 usw. Die anschließende Verzweigung entspricht dem Antworten des Rätsellers und legt fest, ob wir uns im nächsten Schritt die untere Hälfte oder die obere Hälfte des Suchraums vornehmen – oder ob wir hier die gesuchte Zahl schon gefunden haben. `alist[mid] > x` ist wahr, wenn `x` in der unteren Hälfte der Liste ist, deshalb wird für den nächsten Durchgang die mittlere Zahl nun zur Obergrenze gemacht. Umgekehrt ist `alist[mid] < x` wahr, wenn die gesuchte Zahl über dem mittleren Wert liegt; deshalb wird im folgenden Schleifendurchlauf der mittlere Wert zum neuen unteren Wert. Testen wir die Funktion:

```
a = [2, 3, 5, 7, 9, 11, 14, 16, 19, 22, 23, 24, 25, 27, 33, 67]
print(binary_search(7, a))
> 3
```

Das Ergebnis ist richtig: Die gesuchte Zahl 7 ist der vierte Wert der Liste.

Die binäre Suche hat den Vorteil, dass sie den Suchraum bei jedem Schleifendurchlauf halbiert. Die lineare Suche hat ihn bei jedem Durchlauf um $1/n$ (n = Anzahl der Elemente in der Liste) verringert. Wenn wir eine lange Liste verdoppeln, dann müssen wir im Fall der linearen Suche auch doppelt so viele Durchläufe machen. Im Fall der binären Suche müssen wir lediglich einen Durchlauf mehr machen. Was wir hier eher informell gemacht haben, nämlich die Laufzeit von zwei Algorithmen zu vergleichen, ist unter dem Namen der Komplexitätstheorie ein Teilgebiet der theoretischen Informatik (Hoffmann 2011: Kap. 7). Ein Ziel ist die Einordnung eines Algorithmus in eine Komplexitätsklasse, zwei typische Zeitkomplexitäten in Abhängigkeit von der Menge der Eingabedaten haben wir schon kennengelernt, eben die lineare und die logarithmische Komplexität. Algorithmen in diesen beiden Klassen weisen günstige Laufzeiten auf, während z. B. eine exponentielle Komplexität – bei jedem Anstieg von n um 1 verdoppelt sich die Laufzeit – ausgesprochen ungünstig ist, da ein Algorithmus mit exponentieller Komplexität nicht mehr als praktisch berechenbar gilt.

Praxis des Programmierens

Die Entwicklung von Programmen geschieht idealtypisch in den folgenden Schritten:

- **Problem analysieren:** Grundlage eines guten Programms ist ein genaues und umfassendes Problemverständnis.
- **Spezifikation erstellen:** Eine Spezifikation ist eine genaue Beschreibung der Eingabe, der Ausgabe und der gewünschten Funktionalität sowohl auf einer allgemeinen Ebene wie auch im Detail. Dieses Dokument ist die Grundlage aller weiteren Schritte.
- **Design erstellen:** In diesem Schritt wird ein Gesamtentwurf des Programms einschließlich der wichtigsten Algorithmen konzipiert.
- **Design implementieren:** Das Design wird in einer konkreten Programmiersprache umgesetzt.
- **Programm testen und Fehler suchen:** Das Programm wird getestet, um festzustellen, ob es noch Fehler enthält und ob es sich so verhält, wie gewünscht. Idealerweise werden auch automatische Tests erstellt, die die Funktionalität von Bibliotheken überprüfen.
- **Programm dokumentieren:** Spätestens jetzt muss der Code ausführlich dokumentiert und eine Anleitung für die Anwender verfasst werden (Auch wenn in diesem Text Variablennamen und Kommentare zur Vereinfachung deutsch waren, so sind sie normalerweise in englischer Sprache).
- **Programm warten und weiterentwickeln:** Da Programme kaum 100 % fehlerfrei sind und außerdem die Bibliotheken, die sie nutzen, sich weiterentwickeln, z. B. um Sicherheitslücken zu stopfen, müssen sie gewartet werden. Außerdem entwickeln sich die Anforderungen der Nutzer ständig weiter und dem müssen die Programme, wenn sie in Gebrauch bleiben sollen, auch angepasst werden.

Viele dieser Schritte geschehen in Kooperation mit anderen. Häufig lösen Programme Probleme in spezifischen Anwendungsdomänen. D. h. um das Problem angemessen lösen zu können, muss viel Domänenwissen vorausgesetzt werden, was sich als schwierig erweist, da dieses Wissen oftmals selbst bei den Domänenexperten nur implizit vorhanden ist. Die Spezifikation als gemeinsamer Kontrakt zwischen dem zukünftigen Verwender des Programms und dem Programmierer ist in der Praxis oft sehr dynamisch, besonders bei innovativer Software, da mit der Existenz des Programms häufig neue Funktionalitäten überhaupt erst vorstellbar werden.

Agile Softwareentwicklungsmethoden versuchen, das Gewicht der Spezifikation zu reduzieren, indem sie auf einen ständigen Informationsaustausch zwischen Entwickler und Anwender setzen. Die Erfahrung hat nämlich gezeigt, dass die Spezifikation eigentlich nie so vollständig ist, dass sie allein Grundlage des Programmierens sein kann. Durch schnelles und wiederholtes Feedback der Anwender und Anpassung der Funktionalität soll dies aufgefangen werden. Agile Methoden zerlegen nicht nur das Problem, sondern auch den Prozess in möglichst kleine Teilmodule, für die man den Prozess jeweils schnell durchlaufen kann.

Über die beiden Schritte »Design Erstellen« und »Implementieren« haben wir bereits ausführlich gesprochen.

Debuggen: Bei der Fehlersuche in Programmen können wir wieder zwischen den Fehlern zum Zeitpunkt der Kompilierung und den Fehlern während der Laufzeit unterscheiden. Fehler der ersten Art werden vom Compiler mit meistens sehr klaren

Hinweisen zu ihrem Ort im Code und der Art des Fehlers ausgewiesen. Laufzeitfehler sind komplizierter, da es sich bei solchen Fehlern um recht komplexe Phänomene handeln kann, die sich erst beim Zusammenwirken verschiedener Bibliotheken und spezifischer Eingaben zeigen. Die Suche nach solchen *Bugs* wird inzwischen mit spezialisierter Software vorgenommen, einem **Debugger**, der es erlaubt, das Programm an bestimmten Stellen schrittweise auszuführen und dabei die Werte der Variablen zu inspizieren. Insgesamt ist die Fehlersuche in Programmen langwierig und ernüchternd – und sie trägt zur Selbsterkenntnis bei: »Als Programmierer ist man bei der Fehlerforschung in einer privilegierten Position: Man kann der Erkenntnis, unrecht gehabt zu haben, weniger leicht ausweichen als im Rest des Lebens« (Passig/Jander 2013).

Software muss ausführlich getestet werden, bevor sie in der Praxis eingesetzt wird. Das geschieht in Betatests, in denen die zukünftigen Anwender das bereits funktionstüchtige Programm erproben und die Fehler zurückmelden. Als gutes Werkzeug, um die Wartung und Weiterentwicklung von Software möglichst einfach zu gestalten, haben sich außerdem Modultests (engl. *unit tests*) erwiesen. Die Grundidee besteht darin, für jede Komponente (z. B. jede Funktion) kleine Testfunktionen zu schreiben, die prüfen, ob die Komponente für typische Eingaben die erwarteten Ausgaben liefert. Nach Veränderungen am Programm kann man durch automatisiertes Ausführen aller Tests überprüfen, ob die Änderung unerwünschte Nebenwirkungen hat und so Bugs frühzeitig entdecken. Oft werden auch erst die Tests geschrieben und dann die Funktionen so implementiert, dass die Tests erfolgreich sind (*test driven development*).

Software ohne Dokumentation ist selbst für Entwickler nur schwer zu nutzen. Zugleich aber ist fast jeder Programmierer direkt nach dem Schreiben eines Programms der Meinung, dass es praktisch selbsterklärend sei, weshalb man auf Dokumentation verzichten könne. Um Programmierern das Dokumentieren leichter zu machen und auch, damit Dokumentation und Software nicht so leicht asynchron werden, kann man in modernen Sprachen wichtige Teile der Dokumentation in den Programmcode schreiben, so dass eine Dokumentation der Bibliothek im Anschluss automatisch generiert werden kann.

Programmierung, Wartung und Weiterentwicklung von Software geschieht in zwei vollständig unterschiedlichen Paradigmen. Das erste ist das Modell, das viele Firmen verwenden, die ihren Umsatz durch den Verkauf der Software erwirtschaften. Der Programmcode ist der Öffentlichkeit nicht zugänglich; der Anwender erhält nur das kompilierte Programm. Wartung und Weiterentwicklung geschehen firmenintern. Daneben gibt es das Open Source-Modell, das sich insbesondere im Bereich der Wissenschaft, aber auch in vielen kommerziellen Feldern als Standardmodell etabliert hat. Der Programmcode wird neben dem kompilierten Programm frei zugänglich angeboten. Entsprechende Lizenzen erlauben die Nachnutzung – meist auch kommerziell, oft allerdings unter der Maßgabe, Weiterentwicklungen unter derselben Lizenz zur Verfügung zu stellen. Beide Paradigmen nutzen ein Werkzeug zur Entwicklung von Software in Teams: die **Versionsverwaltung** mittels eines zentralen **Repositories**.

Im Bereich der Open Source-Software sind öffentliche Repositories wie z. B. *GitHub* auch der Ort, wo der Quellcode für Programme zugänglich ist. Zentrale Versionsverwaltungen ermöglichen es Programmierern, Versionen ihres Quellcodes zur Verfügung zu stellen, verschiedene Versionen nebeneinander zu pflegen und Verbesserungsvorschläge von anderen Programmierern einfach einzupflegen. Sie sind ein

zentrales Werkzeug für das gemeinschaftliche Programmieren, das inzwischen zum Standardmodell der Softwareentwicklung geworden ist.

Zuletzt sei eine Frage angesprochen, die im Digital Humanities-Kontext häufig gestellt wird: Muss ich als Digital Humanist programmieren können? Es gibt eine Reihe von Bereichen, wie etwa die Annotation, die digitale Edition, Theorie u. a. m., in denen auch ohne Programmierkenntnisse sehr komplexe Probleme gelöst werden. Andererseits eröffnet das Programmieren gedanklich die Welt des algorithmischen Denkens; dessen Grundbegriffe sind sicherlich eine wichtige Grundlage für ein tieferes Verständnis unserer technisch durchgestalteten Welt und auch für jede Kommunikation mit Entwicklern. Vor allem aber ermächtigt Programmieren den Programmierer. Da inzwischen so viele und so umfangreiche wie leistungsfähige Bibliotheken vorliegen, kann man mit nur wenig Erfahrung an einem riesigen Wissensbestand partizipieren und all die gespeicherte Arbeit und Intelligenz für die eigenen Forschungsinteressen und andere Belange nutzbar machen.

Literatur

- Futschek, Gerald: »Algorithmic thinking: The key for understanding computer science«. In: *Lecture Notes in Computer Science* 4226 (2006), 159–168.
- Hoffmann, Dirk W.: *Theoretische Informatik*. München 2011.
- Passig, Katrin/Jander, Johannes: *Weniger schlecht programmieren*. Sebastopol 2013.
- Sedgewick, Robert/Wayne, Kevin/Dondero, Robert: *Introduction into programming in Python. An Interdisciplinary Approach*. Ann Arbor 2015.
- Zelle, John: *Python Programming. An Introduction to Computer Science*. Wilsonville/Oregon 2010.

Fotis Jannidis

II Datenmodellierung

7 Grundlagen der Datenmodellierung

Stellen wir uns vor, wir würden ein Blatt vorgelegt bekommen, das mit dem folgenden Text beginnt:

Weimar den 24. Nov. 1797.

Ich schicke die Garvischen Briefe mit Dank zurück, und wünschte der arme alte kranke Mann schölte noch viel ärger auf uns, wenn er dadurch nur für seine übrige Lebenszeit gesund und froh werden könnte.

Wir erkennen sofort, dass es sich um einen Brief handelt, obwohl ein kennzeichnendes Merkmal eines Briefs, die Anrede, fehlt. Ort und Datum am Anfang sind typisch für die Textsorte ›Brief‹. Diese Identifikation und Verarbeitung von spezifischen Textmerkmalen sind die Grundlage des Lesens als Form menschlicher Informationsverarbeitung. Für den Computer dagegen handelt es sich hierbei um eine einzige lange, undifferenzierte Kette von gleichwertigen Zeichen. Ohne zusätzliche Hilfe kann er keine Strukturen erkennen. Erst wenn explizit die Information gegeben ist, dass es sich bei der Zeichenkette ›Weimar‹ um einen Ort und bei ›24. Nov. 1797.‹ um eine Datumsangabe handelt, können diese Teile des Textes entsprechend prozessiert werden. Das könnte z. B. so geschehen:

[Ort-start]Weimar[Ort-ende] den [Datum-start]24. Nov. 1797[Datum-ende].

Die Markierungen, die wir hier in eckige Klammern gesetzt haben, nennt man **Markup**. Nachdem das Markup eingetragen wurde, ist es ein Leichtes, ein Programm zu schreiben, das den auf diese Weise ausgezeichneten Text, also den Text zwischen Start- und End-**Tag**, extrahiert. Die Bedeutung des Textsegments ist im Namen des Markups festgehalten. Wie zu sehen ist, besteht das Markup aus mehreren Teilen, nämlich: dem Namen, z. B. ›Ort‹, der die Semantik festhält, und dem ›start‹- oder ›end‹-Suffix, das die Position des Markup-Elements in Relation zum annotierten Text festhält. Weniger offensichtlich ist die Funktion der öffnenden eckigen Klammer. Sie kommuniziert dem Programm: Was nun folgt, ist kein normaler Text, sondern Markup. Und die schließende Klammer kippt den Schalter sozusagen in die andere Richtung: Was folgt, ist wieder normaler Text.

Ist Text in dieser Weise ausgezeichnet, können wir z. B. die Datumsangaben von allen Briefen einsammeln und ein entsprechendes Register erstellen oder visualisieren, von wo Goethe, der die Briefe verfasst hat, diese verschickt hat. Durch die eingetragenen Informationen wird aus dem gleichförmigen Strom von Zeichen etwas Strukturiertes. Selbst die für uns selbstverständliche Angabe, was ein Wort ist, muss explizit angegeben werden. Erst durch diese zusätzliche Erschließung von Informationen können wir diese mit dem Computer gezielt verarbeiten und dessen Fähigkeiten nutzen, sehr viele Informationen in kurzer Zeit zu prozessieren.

Es gibt zwei Möglichkeiten, solche strukturellen Informationen einzutragen: **Manuell** oder **automatisch**. Für eine automatisierte Eintragung kann man z. B. versuchen, mit Regeln oder mit maschinellern Lernen festzuhalten, was ein Wort ist, so dass man z. B. den Text in seine Worte zerlegen und diese zählen kann. Oder man kann in einer Edition alle Ortsangaben, Daten und erwähnten Namen manuell eintragen. Stets geht es darum, über die erste Informationsstruktur, in unserem Beispiel

die lange Zeichenkette, eine zweite aufzubauen, die z. B. Einheiten wie Briefsammmlung, Einzelbrief, Autor, Adressat, Ort, Datum, erwähnte Namen u. a. m. erhält. Ein beträchtlicher Teil dieses Bandes beschäftigt sich damit, wie man solche Informationsstrukturen aufbaut, welche Funktionalitäten sie zur Verfügung stellen und wie man diese zur Beantwortung von geisteswissenschaftlichen Fragestellungen anwendet. In diesem Kapitel wird es darum gehen, einige grundlegende Konzepte einzuführen, die allen diesen Aspekten der Datenmodellierung gemeinsam sind.

7.1 | Grundbegriffe der Datenmodellierung

Was ist nun genau gemeint, wenn wir von Datenmodellierung sprechen? Für den Oberbegriff ›**Modell**‹ lassen sich drei Aspekte festhalten (Stachowiak 1972):

1. Ein Modell ist ein Modell von etwas. Ein Modell ist somit immer eine Abbildung; es repräsentiert etwas, ein Ding, einen Begriff, in einem anderen Medium, z. B. Sprache, Bild, oder Ton.
2. Ein Modell ist nicht das Original und auch keine Kopie des Originals. Anders als eine Kopie hat es nicht alle Merkmale des Originals, sondern nur ausgewählte. Die Auswahl beruht auf Annahmen des Modellierers, welche Merkmale für die intendierte Verwendung des Modells relevant sind.
3. Ein Modell soll von jemandem für etwas verwendet werden. Es hat einen oder mehrere Verwendungszwecke. Zumindest für einige Operationen und für bestimmte Zeit kann das Modell als Ersatz für das Original verwendet werden.

Datenmodelle: Datenmodelle sind Modelle in diesem Sinne, aber es kommt eine weitere Eigenschaft hinzu. Modelle im Allgemeinen sind nicht automatisch von Computern prozessierbar. Um das zu erreichen, müssen sie in einer eindeutigen und expliziten Form vorliegen. Erst so können sie vom Computer verarbeitet werden und erst dann sind es formale Modelle. Ein Datenmodell ist also ein formales Modell, das zur Repräsentation eines oder mehrerer Objekte – seien es konkrete oder abstrakte – dient.

Datenmodelle haben mehrere **Funktionen**:

- Sie ermöglichen, wie schon gesagt, komplexe maschinelle Operationen auf den Daten.
- Sie dienen als Grundlage der Kommunikation über die Daten, z. B. zwischen Endanwendern und Entwicklern.
- Sie sichern eine höhere Qualität der Daten, indem sie Bedingungen formulieren, denen Daten bei der Eingabe entsprechen müssen.
- Sie ermöglichen, wenn sie Standards folgen, den Austausch oder das Zusammenführen von Daten und tragen so zur Nachhaltigkeit der Daten bei.

Schon eine dieser Funktionen wäre Grund genug, digitale Objekte mittels Datenmodellierung aufzubereiten. In der Praxis spielen sie aber zumeist zugleich eine Rolle.

(Digitale) Objekte sind stets Teil von Prozessen. So wird ein Brief, der in einem Archiv liegt, evtl. restauriert, nochmals digitalisiert oder ausgeliehen. Auch diese Prozesse müssen formal modelliert werden. Wir sollten aber so klar wie möglich zwischen der Datenmodellierung und der **Prozessmodellierung** unterscheiden, auch wenn es im Bereich der administrativen Metadaten (s. u.) Überschneidungen gibt

(Außerdem gibt es den Bereich der **Systemmodellierung**, also der Modellierung von Softwaresystemen.).

Bei der Beschreibung eines digitalen Objekts, wie dem Brief aus unserem Beispiel, unterscheidet man zwischen den Daten, die etwas über das gesamte Objekt aussagen, den **Metadaten**, und den Daten, die etwas zu Aspekten des Objekts aussagen, etwa dass es sich beim Anfang um eine Datumsangabe handelt. Letztere nennt man **Annotationen**. Schauen wir uns als Beispiel einige Metadaten für den Brief an, dessen Anfang wir oben kennengelernt haben. Sie könnten so aussehen:

Verfasser: Johann Wolfgang Goethe
 Adressat: Friedrich Schiller
 Datum: 24.11.1797
 Ort: Weimar
 Signatur des Archivs: GSA 28/1050 BR 204VS
 URL des Digitalisats: <http://ora-web.swkk.de/...>
 Schrift: z. T. Geist
 Editor: Erich Schmidt
 Restauriert: Nein
 Ausgeliehen an: Goethemuseum Frankfurt

Typen von Metadaten: Einige der Angaben, z. B. Verfasser und Adressat, sind wesentlicher und unveränderlicher Teil des Objekts, was natürlich nicht ausschließt, dass man Fehler korrigiert. Andere Angaben haben eher etwas mit den technischen Gegebenheiten zu tun, z. B. die URL, unter der es zu erreichen ist. Andere mit den internen Arbeitsabläufen im Archiv, z. B. der Name desjenigen, der die Abschrift verfasst hat, oder die Information darüber, ob der Brief bereits restauriert wurde. Wir können von den Metadaten im engeren Sinne also **technische** und **administrative Metadaten** unterscheiden (s. Kap. 12.3).

Datenmodelle spielen auf verschiedenen Ebenen des Modellierens eine Rolle: Wenn wir in einem einzelnen Brief Informationen über Datum, Ort und erwähnte Personen auszeichnen, dann verwenden wir dabei ein generisches Datenmodell, das stets für mehrere Objekte des gleichen Typs gedacht ist. Wir können an dieser Stelle also zwischen der **modellierten Instanz** und dem Datenmodell unterscheiden. Bei der Gestaltung des Datenmodells verwendet man wiederum eine der oben genannten generischen Technologien; bei ihnen handelt es sich um **Metamodelle**.

Verbreitete Metamodelle: Da Daten überhaupt erst durch die formale Modellierung verwendbar werden, gibt es eine ganze Reihe von etablierten Technologien, um solche Modelle zu formulieren. Die wichtigste ist wohl immer noch die **relationale Datenbank**, die auch mit zu den ältesten gehört. Ihre Stärke ist die schnelle Verarbeitung von großen Mengen sehr klar und repetitiv strukturierter Daten. So wäre sie etwa für die oben aufgeführten Metadaten auch bei Millionen von Briefen ein ideales Instrument. Anders verhält es sich mit dem Text von Briefen und anderen schwach und variabel strukturierten Objekten. Hier hat sich **XML** als Standard der formalen Modellierung etabliert – einschließlich einer ganzen Familie von flankierenden Standards zur Verarbeitung von und Suche in XML-Daten. Soll dagegen im Vordergrund stehen, wer mit wem kommuniziert hat und wie viele Schritte wohl ein Gedanke durchlaufen musste, bis er ausgehend von einem der intellektuellen Zentren der damaligen Welt, Paris, den Weimarer Hof erreicht hat, dann sind **Netzwerke** eine geeignete Repräsentation. Diese drei Technologien sind generisch, d. h. sie können auf

ganz unterschiedliche Sachverhalte angewandt werden. Außerdem gibt es aufgrund ihrer großen Verbreitung viele fertige Werkzeuge für sie, die es auch Nichtprogrammierern ermöglichen, alle Schritte von der Dateneingabe bis zur Ausgabe und Visualisierung zu bewältigen. Sollte all dies nicht ausreichen, kann man immer noch sein eigenes Modell mit eigenen Funktionalitäten in einem eigenen Programm umsetzen, muss dann aber alle Werkzeuge zur Dateneingabe und -ausgabe selbst erstellen. Auch werden die Operationen auf den Daten erst durch eigene Software ermöglicht.

Auch wenn es auf den ersten Blick so scheinen mag, als ob die Technologien der Datenmodellierung ganz getrennte Provinzen eines großen Reiches darstellen, so täuscht dies. Tatsächlich sind sie durch eine Reihe von wiederum basaleren formalen Denkformen verbunden, von denen insbesondere die Mengenlehre, die Logik sowie Formen zur Beschreibung von Sequenzen wie ›Extended Backus Naur‹ zu nennen sind. Sie hier ausführlicher darzustellen, würde den Rahmen sprengen (vgl. etwa (Jannidis/Flanders 2017 für eine sehr grundlegende Einführung)). Mengenlehre, Logik und Sequenzbeschreibungen bilden die gemeinsame Grundlage für alle Formen der Formalisierung, und über sie lässt sich auch ein Sachverhalt, der in einem Metamodell notiert ist, in ein anderes Metamodell übersetzen.

Research-driven vs. curation-driven: Zuletzt sei noch eine weitere begriffliche Unterscheidung eingeführt, die mit der Zweckgebundenheit von Datenmodellen zu tun hat. Wir hatten oben festgestellt, dass Modelle immer etwas für einen bestimmten Zweck repräsentieren. Dabei können wir idealtypisch zwei Situationen unterscheiden: Es gibt Datenmodelle, die geschaffen werden, um bestimmte Forschungsfragen zu modellieren und somit bearbeitbar zu machen. Die Modellierung wird hierbei ganz auf die Forschungsfrage zugeschnitten sein (*research-driven*), und es wäre Zufall, wenn sie für andere direkt nachnutzbar wäre. Den zweiten Typus bilden dagegen Modellierungen, die extra dazu geschaffen werden, um digitale Ressourcen nachhaltig erschließen zu können. Sie werden häufig von Bibliotheken oder Archiven oder auch von Kooperationen zwischen Fachwissenschaftlern erstellt (*curation-driven*).

7.2 | Stufen der Datenmodellierung

Am Anfang jeder Datenmodellierung steht ein Ausschnitt der Welt, der modelliert werden soll. Die Menge an Informationen in diesem Ausschnitt ist bei genauerer Betrachtung unerschöpflich groß. Wenn wir etwa ein Datenmodell für Briefe erstellen wollen, dann haben wir Informationen zum Autor und Absender, zur Seiten- und Zeichenanzahl, zu Größe und Gewicht des Briefpapiers, zur Versandart und dem Porto, zu Themen und erwähnten Kunstwerken, Personen, Orten und vieles andere mehr. Um ein brauchbares Modell zu erstellen, muss aus dieser Fülle eine Auswahl getroffen werden, und das wichtigste Kriterium für diese Auswahl ist der Verwendungszweck des Modells. Er bestimmt, welche Informationen des Weltausschnitts in das Modell aufgenommen werden müssen, um die Operationen mit dem Modell durchführen zu können, für die es geschaffen wurde. Begrenzt wird die Modellierung vor allem durch die verfügbaren Ressourcen. Wieviel Geld und wieviel Zeit steht zur Verfügung, um das Modell zu erstellen und – wichtiger noch – dann die Instanzen zu modellieren.

Konzeptuelles Datenmodell: Ein erster Schritt in der Modellierung besteht darin, die relevanten Entitäten sowie deren Attribute und Relationen zu identifizieren. ›Relevant‹ sind diese nicht in einem objektiven Sinne, sondern in Bezug auf den inten-

dierten Verwendungszweck. Dies ist die **konzeptuelle Ebene** der Modellierung. Der Begriff ›**Entität**‹ ist dabei sehr abstrakt zu verstehen: Es kann sich um Objekte handeln, aber auch um Begriffe, Ereignisse, Sachverhalte oder Prozesse usw. Alles, was man als Einheit denken kann, kann als Entität behandelt werden. Entitäten haben **Attribute**, mit denen sie individualisiert und beschrieben werden. **Relationen** modellieren die Beziehungen der Entitäten untereinander. So könnten wir etwa eine Sammlung von Schriftsteller-Briefen für ein Literaturarchiv so modellieren, dass wir als Entitäten ›Brief‹, ›Autor‹ und ›erwähnte Person‹ festlegen. Attribute der Entität Brief könnten dann etwa sein: ›Datum‹, ›Ort‹, ›Adressat‹ und die oben schon erwähnten Metadaten. Und als Relation könnte man etwa die Beziehung ›schreiben‹ zwischen Autor und Brief bestimmen: Ein Autor kann einen oder mehrere Briefe verfassen.

In der konzeptuellen Modellierung wird eine zweckgebundene Abbildung aus der Fülle der realweltlichen Informationen auf eine überschaubare Menge von Entitäten, Attributen und Relationen erstellt. Diese Abbildung ist stets eine Konstruktion des Modellierenden. Sie spiegelt nicht die Realität, sondern sie erstellt ein Bild aus einem interessegeleiteten Gesichtspunkt. So kann das Attribut ›Datum‹ für manche einfache Zwecke reichen, aber für andere Zwecke mag es nützlich oder sogar notwendig sein, zwischen dem Datum der Niederschrift und dem Datum des Versendens zu unterscheiden. Evtl. wird man auch zwischen dem Datum auf dem Brief und dem realen Datum unterscheiden müssen, etwa um nicht Fehler des Autors in die Datenbank übernehmen zu müssen. Selbst die Feststellung, was genau nun eine Entität ist und wo ihre Grenzen sind, ist nicht selbstverständlich. So kann man etwa als ›Brief‹ Verschiedenes zusammenfassen, was möglicherweise unter einem anderen Verwendungszweck getrennt modelliert werden muss: Den Brief als physikalisches Objekt im Archiv und das Digitalisat des Briefs als digitales Objekt, z. B. weil man mehrere digitale Repräsentationen des gleichen physischen Objekts verwalten will.

Für die Beschreibung der konzeptuellen Ebene von relationalen Datenbanken hat man das **Entity-Relationship-Modell** entwickelt, das entweder selbst oder in der Weiterentwicklung als **Unified Modeling Language** auch jenseits der Datenbankmodellierung zur Anwendung kommt, weil es erlaubt, Entitäten, Attribute und Relationen in übersichtlicher Form zu erfassen und zu visualisieren.

Logisches Datenmodell: Das logische Datenmodell entsteht dadurch, dass das konzeptuelle Modell auf die Struktur einer bestimmten Technologie abgebildet wird, z. B. auf ein Datenbank-Schema in der relationalen Datenbank oder auf ein bestimmtes XML-Schema. Wie das genau aussieht, wird in den einschlägigen Kapiteln dieser Sektion dargestellt. Erst in dieser Gestalt hat das Datenmodell eine Form, die es ermöglicht, es maschinell zu prozessieren und die spezifischen Operationen des jeweiligen Modells zu verwenden. Liegen die Daten zum Beispiel in Tabellen vor, so kann man etwa Operationen der relationalen Algebra wie INTERSECT oder JOIN als Teil der Abfragesprache SQL ausführen. Jedes Metamodell ermöglicht sein eigenes Set von Operationen.

Die logische Ebene ermöglicht einen Blick auf Daten, der immer noch recht abstrakt ist. Wie nun ein spezifisches Modell konkret umgesetzt wird, wie also etwa Tabellen und Indizes, mit denen Suchzugriffe beschleunigt werden, konkret als bestimmte Datenstrukturen im Arbeitsspeicher oder einem externen Speicher abgelegt sind, wird als **physische Ebene des Datenmodells** bezeichnet. Sie ist für die Datenmodellierung üblicherweise uninteressant. Mehr noch: Die saubere Unterscheidung zwischen der physischen Ebene und den darüber liegenden Ebenen stellt einen we-

sentlichen Fortschritt in der Datenmodellierung dar. Sie erlaubt es im Prinzip, die konkrete Implementierung vollständig auszutauschen, ohne auf der logischen Ebene etwas zu verändern. Das führt zu einer größeren Freiheit gegenüber der verwendeten Software und stellt sicher, dass das Datenmodell auch in Zukunft zugänglich und brauchbar ist.

7.3 | Datenmodellierung in der Praxis

Die Praxis des Datenmodellierens ist in vielen Punkten abhängig von der jeweils verwendeten Technologie. Aber dennoch gibt es einige übergreifende Konzepte. Beginnen wir mit der Unterscheidung zwischen Datenmodell, Datenstruktur und Datentyp.

Unter **Datenstruktur** verstehen wir die konkrete Implementierung einer Struktur, in die Daten abgelegt werden können. Sie spielen beim Programmieren eine zentrale Rolle. Beispiele für Datenstrukturen sind z. B. Listen oder Dictionaries. Datenmodelle sind zumeist abstrakter als Datenstrukturen. Als Details der Implementierung gehören Datenstrukturen typischer Weise der physischen Ebene an, d. h. ein Datenmodell wird in einer oder mehreren Datenstrukturen realisiert.

Auch der Begriff des **Datentyps** spielt beim Programmieren eine zentrale Rolle. Wenn Daten einer Variablen zugewiesen werden, dann geschieht das explizit oder implizit immer mit einer Angabe dazu, welchen Datentyp diese Daten haben. Der Datentyp bestimmt, welche Art Informationen abgelegt und welche Operationen mit den Daten ausgeführt werden können. **Einfache Datentypen** sind Zahlen (aus Gründen der internen Repräsentation von Zahlen wird unterschieden nach ganzen Zahlen und Gleitkommazahlen, um nur die wichtigsten zu nennen), Zeichen bzw. Zeichenketten und die Wahrheitswerte (boolean) wahr/falsch. Aus ihnen können dann komplexere Datentypen zusammengesetzt werden, z. B. kann eine moderne europäische Datumsangabe festgelegt werden als dd.dd.dddd, wobei »d« für eine positive ganze Zahl steht; oder man kann ein Datum noch genauer festlegen als T.M.J, wobei $0 < T < 32$ und $0 < M < 13$ und J eine ganze Zahl ist. Sowohl einfache als auch komplexe Datentypen spielen in Datenmodellen eine Rolle, da die Metamodelle es erlauben, Datentypen festzulegen. Die Festlegung von Datentypen kann bei der Eingabe von Daten dazu beitragen, die Qualität der Daten zu gewährleisten. Muss etwa eine ISBN-Nummer als Attribut angelegt werden, kann man festlegen, dass an dieser Stelle nur Zahlen, und zwar genau 13, zulässig sind. Da die Korrektur von Daten mit hohen Kosten verbunden ist, sind solche Kontrollmechanismen zur Erstellung von hochwertigen Daten sehr wichtig.

Um die nächsten beiden Begriffe zu erläutern, sei nochmals auf das Briefbeispiel zurückgegriffen. In dem Brief heißt es: »Ich schicke die Garvischen Briefe mit Dank zurück«. Hier wird der Name eines Aufklärungsphilosophen erwähnt, »Garve«, und wenn wir diesen annotieren wollen, dann gibt es verschiedene Möglichkeiten. Z. B. könnten wir den String »Garvischen« mit einer Annotation versehen. Aber da der Name hier als Adjektiv verwendet wird, kann man den richtigen Namen nicht daraus ableiten. Also wäre es besser, den richtigen Namen und dann auch gleich den vollständigen Namen zu ergänzen. Zum Beispiel so:

```
Ich schicke die [Person-start name="Garve, Christian"]Garvischen[Person-
end] Briefe mit Dank zurück,
```

Auf diese Weise können wir nun alle Verweise auf die Person, ganz unabhängig von der tatsächlichen Schreibweise im Text, zusammenführen. Das ist schon ein wichtiger Schritt, aber der Umstand, dass wir stets eine lange Zeichenkette eingeben müssen, macht das Verfahren fehleranfällig. Außerdem wird es problematisch, wenn zwei Personen den gleichen Namen haben und sich nur durch weitere Informationen, z. B. Geburts- und Sterbedatum, unterscheiden. Nun könnten wir solche weiteren Informationen, die zur eindeutigen Identifikation wichtig sind, hier einfügen, aber die Zeichenkette, die man jeweils eingeben müsste, wird dadurch noch länger und das Verfahren noch fehleranfalliger. In solchen Situationen kommen zwei Konzepte ins Spiel: eindeutige Kennungen (*unique identifier*) und Indirektion (*indirection*).

Unter einer **eindeutigen Kennung** verstehen wir eine Bezeichnung, die auf nur ein Element in einer explizit oder implizit definierten Menge verweist. Typische Beispiele für solche eindeutigen Kennungen sind z. B. ISBN-Nummern für Bücher, Personalausweisnummern oder Kreditkartennummern. Eindeutige Kennungen sind in vielen Kontexten relevant, um stabile Verweise oder die Einzigartigkeit von Datensätzen zu garantieren.

Unter **Indirektion** versteht man in der Informatik das Verfahren, statt direkt auf einen Wert, z. B. einen Namen, zu verweisen, auf etwas Anderes zu verweisen, z. B. eine Nummer, die wiederum auf den Wert verweist. Es kann mehrere Ebenen der Indirektion geben. Indirektion ist ein sehr weit verbreitetes Verfahren der Informatik, das auch außerhalb der Datenmodellierung viel Anwendung findet. In unserem Beispiel können wir die beiden Konzepte nun zusammen verwenden, indem wir nicht direkt auf den Namen verweisen, sondern auf eine Nummer, die wiederum auf einen Namen verweist (Indirektion). Als Nummer verwenden wir wiederum eine eindeutige Kennung, die uns von einer **Normdatei** für Personen zur Verfügung gestellt wird. Dadurch stellen wir sicher, dass unsere Referenz auch langfristig verwendbar ist und unsere Annotation auch leicht mit anderen zusammen verwendet werden kann. Die Annotation würde dann z. B. so aussehen:

```
Ich schicke die [Person-start name="gnd:118537636"]Garvischen[Person-end]
Briefe mit Dank zurück,
```

Wir verweisen hier auf die gemeinsame Normdatei (GND) der deutschen Nationalbibliothek. Der Anfang des Eintrags zu Garve in der GND sieht so aus:

Link zu diesem Datensatz	http://d-nb.info/gnd/118537636
Person	Garve, Christian
Akademischer Grad	Prof.
Geschlecht	männlich
Andere Namen	Garve
	Garve, Ch.
	Garve, C.
	Garve, Christianus

Die GND gibt somit auch eine definitive Form des Namens vor. Da bekanntlich nicht nur in früheren Zeiten oft mehrere Schreibweisen für Namen verwendet werden, ist es wichtig, eine Normierung vorzunehmen. Außerdem bietet die GND weitere Angaben, etwa Geburts- und Sterbejahr sowie Informationen zum Beruf und zu Publikationen. Insgesamt sind Normdateien wie die GND zentrale Ressourcen für die Di-

gital Humanities, um digitale Objekte zu erschließen und sie zum Teil eines gemeinsamen semantischen Raumes zu machen.

Abstraktion: Durch die Verwendung einer eindeutigen Kennung und Indirektion wie in dem eben geschilderten Fall kann man die Komplexität von Datenmodellen besser verwalten. Gerade bei größeren Projekten mit vielen Tausenden von Einträgen erweist sich das als ausgesprochen wichtig. Muss man etwa Fehler in der Schreibung eines Namens verbessern, so muss dies nur an einer Stelle vorgenommen werden, nämlich dort, worauf verwiesen wird – in unserem Beispiel also in der GND –, während man sonst alle Verweise im Text korrigieren müsste. Indirektion ist ein Beispiel für das allgemeinere Prinzip der Abstraktion, das für die Datenmodellierung und die Informatik zentral ist. Man versteht darunter die Trennung zwischen einem Konzept, z. B. einer Person, und seiner Umsetzung. Durch Abstraktion wird nicht das spezifische Modell, wie die Person repräsentiert wird, Teil des Textmodells. Vielmehr wird es durch einen Verweis ersetzt, so dass die konkrete Umsetzung des Personenmodells nun eine reine Aufgabe der Normdatei ist. Das Personenmodell kann nun verändert werden, ohne dass die Textannotation ebenfalls modifiziert werden müsste.

7.4 | Datenmodellierung in den Digital Humanities

Was bislang über Datenmodellierung gesagt wurde, gilt fast immer für den ganzen Bereich der digitalen Informationsverarbeitung. Es stellt sich daher die Frage, ob die Digital Humanities nur eine Reihe von Anwendungsfeldern unter anderen darstellen oder ob es hier etwas Besonderes zu beachten gilt. Die Antwort auf diese Frage wird deutlich, wenn wir einen genaueren Blick auf den Gegenstand der Geisteswissenschaften werfen: Es handelt sich um Artefakte, also um von Menschen hervorgebrachte Objekte, Konzepte, Ereignisse, Prozesse, Relationen usw. Diese Artefakte haben außerdem eine Geschichte, die für die Wissenschaften, die sich mit ihnen beschäftigen, relevant ist und in Erinnerung gehalten werden sollte. So kann etwa ein Blatt mit dem Entwurf einiger Zeilen eines Dramas Teil eines größeren Blattes gewesen sein, das aber vom Dichter geteilt und dann auf zwei Konvolute verteilt wurde. Eine moderne Edition würde z. B. sowohl den Zustand der Blätter abbilden, so wie sie jetzt in den Archiven liegen, wie auch den Zustand des Blattes, als es noch eine Einheit war – und das Datenmodell müsste diese Relationen nachvollziehen.

Aber auch die Beschäftigung der Geisteswissenschaften mit den Gegenständen hat eine Geschichte, und oft soll auch diese präsent gehalten werden. Das kann relativ überschaubare Aspekte betreffen wie z. B. die wechselnde Siglierung von Handschriften. (Eine Sigle ist die eindeutige Kennung, unter der ein Archiv eine Handschrift ablegt oder mit der eine Edition diese adressiert.) Es kann aber auch komplexere Zusammenhänge betreffen, wenn etwa die älteren Konzepte selbst problematisch geworden sind, wie es etwa beim Begriff des Stemmas, also des aus den Handschriften erschlossenen Überlieferungsbaums, der Fall ist. Das Datenmodell muss insgesamt komplex genug sein, um den Anforderungen aufgrund dieser **Historizität** der Objekte und des geisteswissenschaftlichen Beschreibungs- und Analyseinventars gerecht zu werden.

Diese Historizität bedingt einen weiteren Aspekt, der für die Gegenstände der Digital Humanities typisch ist, wenn er auch nicht nur bei ihnen zu finden ist: Die Unschärfe von Informationen. Computer eignen sich besonders gut zur Verarbeitung

von diskreten Informationen, z. B. einer Information wie: ›Dieser Text stammt aus dem Jahre 1774.‹ Viele Informationen der Geisteswissenschaften sind aber nicht genau festzulegen. Wenn es etwa heißt, diese Handschrift stammt vom Ende des 8. Jahrhunderts nach Christus, dann suggeriert eine Übersetzung dieser Formulierung in die Angabe ›775–799 n. Chr.‹, wie sie oft vorgenommen wird, eine Genauigkeit, die in dieser Weise nicht gegeben ist. Die angemessene Modellierung von Ungenauigkeiten und Unschärfen stellt zurzeit noch ein nicht immer glücklich gelöstes Problem dar, das besonders für die Geisteswissenschaften sehr relevant ist.

Geisteswissenschaftler denken in größeren Zeitspannen. Wissenschaftliche Werke aus früheren Jahrhunderten können immer noch relevant sein. Entsprechend besteht auch ein ausgesprochen großes Interesse daran, die Erträge der digitalen geisteswissenschaftlichen Arbeit langfristig verfügbar zu halten – einschließlich der Datenmodellierung. Deshalb bildet der Teil der Datenmodellierung, der oben als *curation-driven* bezeichnet wurde, einen wesentlichen Teil der Digital Humanities. Das kann man besonders gut an der Text Encoding Initiative (TEI) zeigen, die zu den großen Erfolgsgeschichten der Digital Humanities zählt. Im Kern handelt es sich um ein XML-konformes Textauszeichnungssystem, mit dem Textwissenschaftler für sie relevante Informationen in Texten annotieren können. Zugleich aber handelt es sich um eine Institution, die die Wartung und Weiterentwicklung des Auszeichnungssystems organisiert und die dazu notwendigen Gelder beschafft und verteilt. Und nicht zuletzt handelt es sich um eine soziale Gruppe, bestehend aus Experten und Anfängern, die sich gegenseitig informieren und auf Konferenzen zusammenkommen. Nicht alle Datenmodelle beruhen auf einer so komplexen Struktur, aber die TEI zeigt, wie vielschichtig ein erfolgreiches Datenmodell ist.

In den Geisteswissenschaften sind erkenntnistheoretische Positionen, die sich mehr oder weniger eindeutig als Varianten eines nicht zu radikalen Konstruktivismus beschreiben lassen, besonders häufig anzutreffen. Entsprechend wichtig ist daher der Grundgedanke, dass Informationen nicht einfach objektiv gegeben sind, sondern immer auch einem erkennenden Subjekt oder einer Gruppe zuzuschreiben sind. Diese Perspektivenbedingtheit betrifft nicht nur die modellierten Instanzen, sondern auch die Datenmodelle, nicht zuletzt weil sie ja Verwendungszwecken unterliegen und damit Interessen abbilden. Auch dieser Umstand gehört zu den Aspekten, die zur möglichen Komplexität von geisteswissenschaftlichen Modellen beitragen können.

Und schließlich sei eine grundsätzliche Spannung erwähnt, die im Verhältnis der Geisteswissenschaftler zur Modellierung zu finden ist: Es gibt in den Geisteswissenschaften ein systembedingtes Primat des Individuellen vor dem Allgemeinen. Man interessiert sich mehr für einen einzelnen Roman, z. B. Goethes *Wahlverwandtschaften*, als für die Klasse, sei es nun der Romane um 1800 oder der Eheromane. Modellierung dagegen ignoriert alles, was sich nicht im Verhältnis zum Allgemeinen ausdrücken lässt. So kann die Datenmodellierung oft als zu oberflächlich wahrgenommen werden, weil sie das Individuelle des Werks nicht erfasst. Aber das ist ja auch gar nicht die Aufgabe des Datenmodells. Vielmehr soll es ein Beschreibungsinventar anbieten, mit dem alle Elemente einer Klasse sinnvoll in Beziehung zueinander gesetzt werden können.

Insgesamt kann man kaum überschätzen, wie wichtig Datenmodelle und die Datenmodellierung für die Digital Humanities sind. Es gibt einflussreiche Stimmen, die sie für den Kern der Digital Humanities halten (McCarty 2005), da die Modellierung der Punkt ist, wo das geisteswissenschaftliche Verständnis eines Weltausschnitts

und die Kompetenz zur formalen Modellierung zusammentreffen und im besten Fall neue Fragestellungen und neue Forschungen ermöglichen.

Literatur

- Flanders, Julia/Jannidis, Fotis: »Data Modeling in a Digital Humanities Context«. In: dies. (Hg.): *The Shape of Data in Digital Humanities. Modeling Texts and Text-based Resources*. London 2017.
- Jannidis, Fotis/Flanders, Julia: »A gentle introduction into Data Modeling«. In: dies. (Hg.): *The Shape of Data in Digital Humanities. Modeling Texts and Text-based Resources*. London 2017.
- Kastens, Uwe/Kleine Büning, Hans: *Modellierung. Grundlagen und formale Methoden*. München 2014.
- McCarty, Willard: »Modelling«. In: Willard McCarty (Hg.): *Humanities Computing*. Basingstoke 2005, 20–72.
- Stachowiak, Herbert: *Allgemeine Modelltheorie*. Wien/New York 1973.

Fotis Jannidis

8 Datenbanken

8.1 | Datenverarbeitung und -organisation

Die Digital Humanities eint der Wille, den geisteswissenschaftlichen Fächern den Computer als Hilfsmittel der Erkenntnisgewinnung zur Verfügung zu stellen. Im Zentrum steht dabei die Datenverarbeitung. Um Daten zu verarbeiten, müssen diese jedoch zunächst erhoben, in einer Form abgelegt und schließlich abgerufen werden können. Gerade, wenn es sich um eine sehr große Datenmenge handelt, stehen deren strukturierte Speicherung und der effiziente Zugriff im Vordergrund. Daher kommen Datenbanksysteme zum Einsatz, die im Kontext einer spezifischen Anwendung dafür sorgen, dass der ›Rohstoff des 21. Jahrhunderts‹ verfügbar ist und bleibt.

Datenverarbeitung: Unter **Daten** werden hier Zeichen verstanden, die eine gewisse Syntax miteinander verbindet und die der Verarbeitung sowie der Ergebnisdarstellung dienen. Erst wenn Daten mit Bedeutung (Semantik) versehen werden, werden sie als ›Information‹ bezeichnet. Die Vernetzung von Informationen kann schließlich neue Erkenntnis generieren und Wissen erzeugen – das Ziel einer jeden Wissenschaft. Ein **Datenbanksystem** beinhaltet einerseits ein **Datenbankmanagementsystem** (DBMS) und andererseits die Datenbank mit den gespeicherten Daten selbst. Damit hilft das System diese Daten dauerhaft, effizient sowie widerspruchsfrei zu verwalten und zugreifbar zu halten. Des Weiteren stellt es der jeweiligen Anwendung eine Schnittstelle für die Abfrage, Auswertung, Veränderung und Verwaltung dieser Daten zur Verfügung.

In Abgrenzung dazu ist das Datenbankmanagementsystem die Software, die das Datenbankmodell festlegt und die Funktionalität sowie die Performanz des Gesamtsystems bestimmt. Außerdem ermöglicht es den problemlosen Zugriff auf die Daten im Mehrbenutzerbetrieb. Der Begriff ›Datenbank‹ bezeichnet einen logisch zusammengehörigen Datenbestand, der auf physischen Speichern abgelegt ist.

Daten könnte man einfach als Textdatei ablegen. Jedoch führt das Ablegen in einem hierarchischen Dateisystem, in dem die Daten in Verzeichnissen und Unterverzeichnissen organisiert sind, häufig zu Doppelungen (Redundanzen) und mit steigender Menge an Inhalten wird somit ein schnelles Auffinden der jeweiligen aktuellen Werte schwieriger. Selbst die Ablage von Daten in Tabellenform stößt schnell an die Grenzen der Auswertungsmöglichkeiten, da Tabellen keine flexiblen Strukturen ermöglichen. Um diesen Problemen zu begegnen, bedarf es einer Datenorganisation.




Abb. 20 Begrifflichkeiten

Daten müssen organisiert werden, um schnell darauf zugreifen zu können. Um Daten zu verarbeiten, müssen sie außerdem schnell verändert und auch bei einem Mehrbenutzerzugriff ausgewertet werden können, ohne Inkonsistenzen zu erzeugen. Und schließlich sind Fragen des berechtigten Zugriffs zu beachten (Datenschutz) sowie die Wirtschaftlichkeit der Speicherung.

Datenorganisation: Wenn mithilfe eines Datenbanksystems auf Daten zugegriffen werden soll, ist zunächst zu überlegen, welche Daten man wie verarbeiten möchte. Oder anders ausgedrückt, was ist ein für die anschließende Verarbeitung relevanter Ausschnitt aus der realen Welt, der mithilfe strukturierter Daten dargestellt werden soll. Diese Untersuchung ist die **Anforderungserhebung** und damit der erste Schritt in der Entwicklung einer Datenbank. Anschließend ist von diesem Ausschnitt ein **konzeptuelles Modell** zu erstellen. Dieses beinhaltet die Ausarbeitung einer Struktur und die Realisierung eines semantischen Datenmodells dieses Ausschnitts. Dieses Modell ist dann in einen logischen Entwurf zu überführen. Ein **logischer Entwurf** stellt den eigentlichen Datenbankentwurf dar, in dem die Objekte bezeichnet werden, über die Informationen gespeichert werden sollen. Schließlich muss dieser Entwurf implementiert, also in eine tatsächlich verwendbare Datenbank überführt werden.




Abb. 21 Entwicklung einer Datenbankanwendung

An einem praktischen Beispiel wird dies deutlich: Angenommen, es soll eine kunsthistorische Datenbank verwirklicht werden, in der Werke sowie die Künstler, darüber hinaus der Standort des Werkes und Informationen darüber, wer den Datensatz angelegt hat zu finden sind. Nun wäre es bei einer sehr kleinen Menge an Daten naheliegend, diese zunächst in einer Liste anzulegen. Dies erfordert den geringsten Aufwand. Jede Zeile würde ein Werk repräsentieren, die Zusatzinformationen könnten durch Kommata getrennt angefügt werden. Sobald diese Liste jedoch über ein paar Seiten hinausgeht, müsste man mit der Suchfunktion arbeiten, und beispielsweise nach dem Titel suchen. Wie häufig der Titel auch bei anderen Künstlern vorkommt oder wie viele Werke eines Künstlers in der Liste vorhanden sind, ist dann schwer zu erkennen. Auch eine Sortierung nach verschiedenen Kriterien oder ein Auszug aus der Liste ist nur sehr aufwändig zu erzeugen.

Um einen Künstler und seine Werke besser zu finden, wäre es denkbar, mit steigender Länge der Liste diese aufzuteilen und im Dateisystem nach Anfangsbuchstaben des Künstlers in hierarchischen Ordnern abzulegen. Hier könnte zwar nach dem Künstlernamen, nicht aber nach dem Werktitel gesucht oder eine andere Auswertung vorgenommen werden. Zudem werden Redundanzen, beispielsweise fälschlicherweise doppelt angelegte Werke, nicht automatisch erkannt. Die Auswertung des Datenbestandes ist wenig flexibel, Such- und Sortiervorgänge müssen dem ständig vorausgehen.

Schließlich könnte man auf die Idee kommen, diese Daten in Form einer Tabelle anzulegen, in der jede Spalte eine Bedeutung trägt. Beispielsweise Name, Vorname, Titel etc. Tatsächlich lässt sich mit einem Tabellenkalkulationsprogramm vieles bewerkstelligen. So kann die Tabelle nach verschiedenen Spalten sortiert und auch die Vorkommenshäufigkeit dargestellt werden.

	A	B	C	D	E	F	G	H	I
1	Name	Vorname	Geburtsjahr	Starbejahr	Werkstitel	Datierung	Sammlung	Ort	
2	Dürer	Albrecht	1471	1528	Selbstbildnis	1500	Alte Pinakothek	München	
3	Dürer	Albrecht	1471	1528	Landauer Altar	1516	Kunsthistorisches Museum	Wien	
4	Cranach	Lucas	1472	1553	Kreuzigung Christi	1501	Kunsthistorisches Museum	Wien	
5									
6									
7									

Abb. 22 Lösung mithilfe eines Tabellenkalkulationsprogramms.

Redundanzen sind aber auch hier vorhanden. So muss in jeder Zeile der Künstlername wiederholt eingegeben werden, vielleicht hundertfach, wenn hunderte Werke des Künstlers vorhanden sind. Gleiches gilt für den Aufbewahrungsort des Werkes und für den Namen des Bearbeiters, der in jeder Zeile erscheinen muss. Mehrere Bearbeiter können nur schwer gleichzeitig an diesem Dokument arbeiten, Versionskonflikte sind ein ständig zu lösendes Problem.

Anforderungen an eine Datenbank: Tatsächlich wurde sehr früh in der Informatik dieses Problem erkannt. Die Organisation von Daten soll diese verfügbar halten, auch wenn das Programm, das damit gearbeitet hat, beendet ist. Die Datenbank soll also unabhängig von der Anwendung sein. Auf diese Weise kann auch von einer anderen Anwendung darauf zugegriffen werden. Das Datenbankmanagementsystem soll also das Anlegen, Ändern und Löschen von Daten übernehmen und nur eine Schnittstelle zur Anwendung bieten. Ein solches System sollte dem Anwender benutzerfreundlich nur eine Struktur der Daten vermitteln, ohne dass dieser sich um die physische Datenablage kümmern muss. Ein Datenbankmanagementsystem sollte einen Mehrfachbenutzerzugriff erlauben, um von verschiedenen Systemen auf die Daten zugreifen zu können, ohne dass dadurch Kollisionen entstehen (**Transaktionssicherheit**). Schließlich soll ein solches System schnell im Zugriff sein, zudem Zugriffsberechtigungen verwalten und eine Fallsicherheit bieten. Daten sollen vollständig, korrekt, exakt, aktuell und widerspruchsfrei sein. Falsche Eingaben über das Anwenderprogramm sollen nicht zu Inkonsistenzen in der Datenbank führen. Und schließlich sollen Elemente nur einmal gespeichert werden.

Bereits in den 1950er Jahren wurden Datenbankmodelle entwickelt, die hierarchisch strukturiert wurden, die jedoch zu unflexibel waren. Netzwerkmodelle, die jedoch sehr komplex werden konnten, hatten die Aufgabe, gerade der hohen Redundanz entgegen zu wirken. Edgar F. Codd entwickelte seit den 1970er Jahren daher das **relationale Datenbankmodell**, das Redundanz reduziert und eine leicht verständliche Struktur aufweist (Codd 1970, 377–387).

In der Mathematik wird eine Beziehung zwischen Elementen als Relation beschrieben; sie kann mit der Mengenlehre und mit relationaler Algebra untersucht werden.

Relationale Datenbank: Definition

In einer relationalen Datenbank stehen Datenfelder und Tabellen miteinander in Beziehung und können mithilfe von Anweisungen ausgewertet werden. Das Modell der relationalen Datenbank bietet flexible Datenstrukturen und eine hohe Verarbeitungsgeschwindigkeit.

Es ist heute am weitesten verbreitet und findet sich sowohl in kommerziellen Produkten, ist aber auch die Basis vieler Open-Source-Datenbankmanagementsysteme, wie z. B. »MySQL«. Dieses Modell soll hier vor allem im Zentrum stehen.

Um den Anforderungen an ein Datenbanksystem gerecht zu werden, schlug 1975

das Standards Planning and Requirements Committee (SPARC) of the American Standards Committee on Computers and Information Processing (ANSI/X3) die Trennung von drei Ebenen vor:

- Die **externe Ebene** beschreibt die Sichten verschiedener Nutzergruppen auf die Daten. So können ein Administrator, die Person, welche die Daten eingibt, und ein Benutzer, der diese nur liest, ganz unterschiedliche Darstellungsformen auf dieselben Daten verlangen. Jeder sieht so nur, was er sehen darf.
- Die **konzeptuelle Ebene** ist eine Abstraktion der Struktur der Daten, die alle Sichten vereinheitlicht und unabhängig von der Anwendung ist.
- Die **interne Ebene** beschreibt die physische Ablage der logischen Strukturen auf einem oder mehreren Datenträgern. Dies bleibt für den Anwender unsichtbar (transparent).

8.2 | Erstellen eines Datenmodells: Relationale Datenbank

Konzeptuelles Datenbankschema: Entity-Relationship-Modell

Entsprechend der Phasen des Datenbankentwurfs (s. Abbildung 21) wird auf der konzeptionellen Ebene das konzeptuelle Schema der Datenbank modelliert. Dies erfolgt grafisch mithilfe des 1976 von Peter Chen (1976, 9–36) vorgeschlagenen **Entity-Relationship-Modells** (ERM). Dabei handelt es sich um ein semantisches Datenmodell, bei dem die Struktur der Daten und Beziehungen untereinander von Bedeutung sind. In einem Datenmodell ist ein immaterielles Abbild eines relevanten Ausschnitts der Realität repräsentiert. Mithilfe des ERM kann dieser Ausschnitt systemunabhängig abstrahiert dargestellt und anschließend von einem Administrator mithilfe der Datenbeschreibungssprache umgesetzt werden.

So würde man sich am Beispiel einer kunsthistorischen Datenbank zunächst überlegen, welche eindeutig identifizierbaren Objekte oder Sachverhalte (Entitäten) in dieser Datenbank erscheinen sollten. Darin würden zunächst die Künstler sowie ihre Werke enthalten sein. Da diese Entitäten verschiedene Eigenschaften haben, die sie auszeichnen, können diese als Attribut hinzugefügt werden. In diesem Fall wäre das für den Künstler beispielsweise der Name, für das Werk der Titel. Und da diese Entitäten eine bestimmte Beziehung zueinander haben (in diesem Fall hat der Künstler ein Werk erstellt), können diese als Relationen zu den Entitäten dargestellt werden.

Der logische Entwurf repräsentiert im nächsten Schritt, wie diese Elemente in Tabellen überführt werden können. Dabei werden die Entitäten mit ähnlichen Eigenschaften (Attribute) als Klassen (Entitätstypen) behandelt. Beispielsweise werden alle Künstler als eine **Klasse** zusammengefasst, die einen Vor- und Nachnamen sowie ein Geburts- und Sterbedatum besitzen. Anschließend werden diese Entitätstypen miteinander in Beziehung gesetzt (**Assoziation**). So können Künstler mit ihren Werken in ein Verhältnis gebracht werden und die Werke mit ihren Standorten. Häufig wird auch eine **Aggregation** vorgenommen, bei der Entitäten zu einer höheren Einheit zusammengefasst werden, wie beispielsweise Gemälde und Skulptur zur Klasse ›Werk‹. Auch werden Entitäten, die unterschiedliche, aber auch gemeinsame Eigenschaften haben, zusammengefasst, um Redundanz zu vermeiden (**Generalisierung**). In einer kunsthistorischen Datenbank könnte man beispielsweise Künstler und Kunsthistoriker, die zwar unterschiedliche Funktionen haben, aber

gleichermaßen Name und Lebensdaten besitzen, zu einer Entität ›Person‹ zusammenfassen.


Logisches Datenbankschema

Nun wird für jeden Entitätstypen eine Tabelle angelegt, bei der der Name der Tabelle dem Entitätstypen entspricht – die Attribute bezeichnen die Spalten.


Aus der Anforderungserhebung ergeben sich folgende Entitäten:

1. Der **Künstler** des Originalwerks mit Vorname, Nachname, Geburtsjahr und Sterbejahr als Attribute (weitere Attribute sind hier zur Vereinfachung ausgelassen)
2. Das **Bildobjekt** (Digitalisat) mit einer Identifikationsnummer und Datum der Erstellung als Attribut
3. Die **Sammlung**, in der sich das Originalwerk befindet
4. Der **Ersteller** des Digitalisats mit einer Identifikationsnummer, Vorname, Nachname und zugehöriger Institution als Attribut


Daraus ergeben sich folgende Entitäten im logischen Entwurf mit Beispieldaten:




KID	VName	NName	GJahr	SJahr
123	Albrecht	Dürer	1471	1528
124	Lucas	Cranach	1472	1553



BID	Titel	Datierung	KID	SID	EID	EDatum
66	Selbstbildnis	1500	123	80	1	15.12.2015
67	Landauer Altar	1516	123	81	1	10.05.2016
68	Kreuzigung Christi	1501	124	81	1	10.05.2016



SID	SName	Ort	Land
80	Alte Pinakothek	München	Deutschland
81	Kunsthistorisches Museum	Wien	Österreich



EID	VName	NName	Institution
1	Max	Mustermann	Universität Musterstadt

Relationen: Das Werk ist durch Titel und Datierung nicht notwendigerweise eindeutig identifizierbar. So könnte ein Selbstbildnis von 1500 sowohl auf das von Albrecht Dürer, wie auch auf das von Pietro Perugino zutreffen. Daher wird neben den Attributen jedem Datensatz auch eine eindeutige fortlaufende Zahl (ID) beigelegt (starker Entitätstyp). Zudem sind die Objekte möglicherweise nur in der Verbindung mit anderen Entitäten sinnvoll zu beschreiben (schwacher Entitätstyp), beispielsweise das Werk durch den Künstler. Daher können mithilfe von Schlüsseln Beziehungen zwischen Entitäten hergestellt werden.

Schlüssel: Ein Datensatz wird über den **Primärschlüssel** eindeutig gekennzeichnet. Dies kann ein Attribut oder eine Attributkombination sein. Häufig handelt es sich jedoch um zusätzlich hinzugefügte fortlaufende Zahlen, die nur einmal vergeben werden. Auf diese Weise können beispielsweise zwei Personen mit dem gleichen Namen voneinander unterschieden werden und auch bei Namensänderung identifizierbar bleiben. Ein solcher Schlüssel kann auch in einer anderen Tabelle vorkommen (Fremdschlüssel) und auf diese Weise Entitäten zweier Tabellen miteinander verbinden.

So enthält die Entität ›Bildobjekt‹ den Namen des Künstlers, der Sammlung und des Erstellers nicht direkt, sondern nur über einen Verweis auf dessen **Schlüssel** (hier KID, SID und EID). Es werden drei verschiedene Relationen unterschieden (Kardinalität):

- **1:1-Beziehung:** Dabei besteht eine eineindeutige Beziehung, d. h. einer Entität wird genau eine andere Entität zugeordnet (und umgekehrt). Beispielsweise kann einer Person genau ein Personalausweis zugeordnet werden. Dieser eine Ausweis verweist umgekehrt auf genau eine Person. Hier muss der Primärschlüssel einer Tabelle als Fremdschlüssel in der anderen eingesetzt werden (die Richtung ist dabei gleichgültig).

Person			
PID	VName	NName	AID
1	Max	Mustermann	37

Fremdschlüssel in der einen Tabelle ist Primärschlüssel der anderen Tabelle

Ausweis	
AID	EDatum
37	01.01.2015

- **1:n-Beziehung:** Dies bedeutet, dass jede Entität eines Entitätstyps mit beliebig vielen Entitäten eines anderen Entitätstyps in Beziehung steht. Umgekehrt steht jede Entität des einen Entitätstyps mit einer Entität des anderen Entitätstyps in Beziehung. So könnte man ein Werk einem Museum zuordnen, in dem sich eine Reihe von Werken befinden. Hier wird der Entitätstyp, der auf der ›n-Seite‹ liegt,

um den Fremdschlüssel ergänzt (nicht umgekehrt). In diesem Beispiel kann so das Bildobjekt nur in einer Sammlung sein, die Sammlung aber auf verschiedene Objekte verweisen.

Bildobjekt			
BID	Titel	Datierung	SID
66	Selbstbildnis	1500	80
67	Landauer Altar	1516	81

Sammlung			
SID	SName	Ort	Land
80	Alte Pinakothek	München	Deutschland
81	Kunsthistorisches Museum	Wien	Österreich

- **n:m-Beziehung:** Auf beiden Seiten können beliebig viele Entitäten in Beziehung zueinander stehen. Zum Beispiel gehören einer Epoche mehrere Künstler an, aber Künstler können auch mehr als einer Epoche angehören. Dazu wird eine dritte Tabelle erzeugt, die die Beziehung zwischen den beiden Entitätstypen vermittelt. Darin werden die Primärschlüssel beider Entitätstypen eingetragen.

Künstler				
KID	VName	NName	GJahr	Slahr
123	Albrecht	Dürer	1471	1528
132	Michelangelo	Buonarroti	1475	1564
156	Peter Paul	Rubens	1577	1640

Gehört_an	
KID	EID
123	15
132	15
156	16

Epoche	
EID	ENAME
15	Renaissance
16	Barock

Im obigen Beispiel liegen (vereinfacht) zwischen den Entitäten jeweils 1:n-Beziehung vor: Das Objekt wird in einer Sammlung aufbewahrt, das mehrere Objekte enthalten kann. Es wird von genau einem Bearbeiter digitalisiert, der mehrere Objekte erstellen kann. Und das Werk wurde von einem Künstler geschaffen, der mehrere Werke produziert haben kann. Stellt man diese Zusammenhänge in einem Entity-Relationship-Modell dar, erscheint dies folgendermaßen:




Abb. 23 Entity-Relationship-Modell der Beispieldatenbank

Deutlich werden hier die Beziehungen ›aufbewahrt‹, ›digitalisiert‹ und ›geschaffen‹, die in einer 1:n-Beziehung zum Bildobjekt stehen. Das bedeutet, das Bildobjekt befindet sich in einer Sammlung, wurde von einem Künstler erschaffen und von einem Ersteller digitalisiert. Der Ersteller kann aber beliebig viele Bildobjekte digitalisieren, jede Sammlung kann mehrere Objekte aufbewahren und der Künstler viele Objekte schaffen. Auf diese Weise sind alle Entitäten eindeutig identifizierbar und miteinander verknüpft.

Die Normalisierung eines logischen Entwurfs dient der Verringerung der Redundanz und wird in drei Schritten durchgeführt (Pernul/Unland 2009, 143). Zunächst sind die Attribute zu atomisieren (1NF). Dies bedeutet, in jeder Spalte darf nur ein Wert stehen. Beispielsweise wäre Vor- und Nachname voneinander zu trennen. Dies ist in dem Beispiel bereits der Fall.

Die zweite Normalform (2NF) ist gegeben, wenn 1NF erreicht ist und die Nicht-Schlüssel-Attribute voll funktional abhängig von dem Primärschlüssel sind. Dies ist bei der Entität ›Künstler‹ und ›Sammlung‹ der Fall. Sieht man sich im Zuge der Normalisierung die Entität ›Ersteller‹ genauer an, fällt auf, dass das Attribut ›Institution‹ streng genommen eine eigene Entität ist. Wird dies aufgelöst, so dass die Institution des Erstellers getrennt von der Person erscheint, ist es möglich, weitere Ersteller dieser Institution unabhängig zuzuordnen. Hierbei wird dem Ersteller der Fremdschlüssel der Institution hinzugefügt und so eine weitere 1:n-Beziehung dargestellt. Dann sehen diese Entitäten, verknüpft durch eine Institutions-ID, folgendermaßen aus:

Ersteller			
EID	VName	NName	IID
1	Max	Mustermann	37

Institution	
IID	IName
37	Universität Musterstadt

Untersucht man die Entität ›Bildobjekt‹, so wird deutlich, dass die Nicht-Schlüssel von dem Primärschlüssel BID voll funktional abhängig sind, solange die Digitalisate der Originalwerke damit bezeichnet sind. Geht man jedoch davon aus, dass von einem Originalwerk, das mit Titel, Künstler, Datierung und Sammlung bezeichnet

ist, mehrere Digitalisate in unterschiedlicher Qualität existieren können, so muss zwischen der Entität ›Digitalisat‹ (bisher ›Bildobjekt‹) und Objekt (Originalwerk) unterschieden werden. Jedes reale Kunstobjekt kann mehrere ihm zugehörige digitale Reproduktionen in der Datenbank besitzen. Jedes Digitalisat ist jedoch nur einem Originalwerk zuzuordnen. Es handelt sich also auch hier um eine 1:n-Relation, die durch das Einfügen des Primärschlüssels der 1-Seite (Objekt) auf der n-Seite (Digitalisat) als Fremdschlüssel dargestellt wird. Entsprechend liegen die beiden Entitäten auf folgende Weise miteinander verknüpft vor:

Objekt				
OID	Titel	Datierung	KID	SID
2345	Selbstbildnis	1500	123	80

Digitalisat			
BID	OID	EDatum	EID
66	2345	15.08.2013	1

Auf diese Weise können mehrere Bilder auf ein Objekt verweisen. Ersteller und Erstelldatum beziehen sich somit nur auf das Digitalisat. Titel, Datierung, Künstler-ID und Sammlung sind voll funktional abhängig von der Objekt-ID. Das Attribut des Erstelldatums ›EDatum‹ wird vom System zum Zeitpunkt der Erstellung des Datensatzes durch den Ersteller automatisch eingefügt.

Die dritte Normalform ist gegeben, wenn 2NF erreicht ist und kein Nicht-Schlüssel-Attribut von einem anderen Nicht-Schlüssel-Attribut funktional abhängig ist. Dies ist hier der Fall. Mithilfe dieses Entwurfs könnte nun zur Implementierung übergegangen werden.

Implementierung

Nachdem die konzeptuelle Modellbildung und der logische Entwurf vorgenommen wurden, ist die Datenbank tatsächlich zu erstellen und mit Daten zu füllen. Für relationale Datenbanken hat sich dazu die standardisierte Sprache **Structured Query Language (SQL)** durchgesetzt. Die meisten relationalen Datenbanksysteme basieren auf dieser Sprache und setzen sie weitgehend kompatibel zueinander um.

Datenbank erstellen: SQL wird auf den verschiedenen Schichten in drei Untersprachen aufgeteilt:

- Data Definition Language (DDL), mit der die Datenbank in ihrer Struktur erstellt wird
- Data Manipulation Language (DML), mit der Daten gesucht und verändert werden
- Data Storage Description Language (DSDL), mit der die Struktur auf dem Datenträger beschrieben wird

Zur Datendefinition stehen folgende Befehle zur Verfügung:

- **CREATE:** zur Erstellung von Datenbanken und einzelnen Tabellen
- **DROP:** zum Löschen von Tabellen inklusiv ihrer Inhalte
- **ALTER:** zum Verändern der Tabellenstruktur
- **RENAME:** zur Namensänderung einer Tabelle

Ergänzt um den Begriff DATABASE, den Namen der Datenbank und ein abschließendes Semikolon kann diese mit dem folgenden Befehl erstellt werden:

```
CREATE DATABASE bilddatenbank;
```

Tabellen erstellen: Die Datenbank besteht nun, ist aber noch leer. Daher müssen nach demselben Prinzip die Tabellen erstellt werden. Diese bekommen nicht nur einen Namen, sondern auch die Spalten müssen definiert werden. Je nach den Inhalten werden zudem bestimmte Datentypen und Begrenzungen zugewiesen. So sind unter anderem folgende Datentypen möglich:

- **INT:** ›Integer‹ steht für Ganzzahlen von -2^{31} bis $2^{31} - 1$.
- **FLOAT:** Dieser Datentyp steht zur Verfügung, wenn Fließkommazahlen benötigt werden, z. B. 1,25.
- **DATE:** Hierbei handelt es sich um ein Datumsformat, das auf den Tag genau angegeben wird.
- **VARCHAR:** Steht für ›character‹, also eine bestimmte Anzahl von Buchstaben. Die maximale Länge wird in Klammern dahinter festgelegt. Im Gegensatz zu CHAR, bei dem der maximale Speicherplatz reserviert wird, werden nur so viele Bytes verbraucht, wie Zeichen gespeichert werden.
- **TEXT:** Ähnlich wie VARCHAR kann hier eine Buchstabenfolge von maximal 65535 Zeichen gespeichert werden.

Soll nun die Institution des Erstellers als Tabelle angelegt werden, so wird folgender Befehl eingegeben:

```
CREATE TABLE 'institution' (
  'IID' int NOT NULL AUTO_INCREMENT,
  'IName' varchar(50) NOT NULL);
```

Die Angabe von NOT NULL bedeutet, dass der Wert nicht leer sein darf. Auf diese Weise wird verhindert, dass keine Institution angelegt wird, ohne eine eigene ID oder Namen anzugeben. Der Versuch, diese Felder leer zu lassen wird von dem System mit einer Fehlermeldung beantwortet. Ebenso die Eingabe einer bereits verwendeten Zahl. Fügt man dem Befehl den Zusatz AUTO_INCREMENT an, wird beim Anlegen eines Datensatzes automatisch die ID um eins erhöht.

Die Tabelle, die verschiedene Ersteller von Digitalisaten fassen soll, wird nach dem gleichen Prinzip folgendermaßen erstellt:

```
CREATE TABLE IF NOT EXISTS 'ersteller' (
  'EID' int NOT NULL AUTO_INCREMENT,
  'VName' varchar(20) NOT NULL,
  'NName' varchar(20) NOT NULL,
  'IID' int NOT NULL);
```

Hier ist nun die Bedingung IF NOT EXISTS hinzugefügt, die zunächst prüft, ob eine Tabelle gleichen Namens bereits vorhanden ist. Wäre dies der Fall, würde dies eine Fehlermeldung erzeugen und die vorhandene Tabelle nicht mit einer neuen leeren überschrieben werden. Der Variablentyp VARCHAR ist hier mit einer Zeichenlänge von 20 Buchstaben definiert.

```
CREATE TABLE IF NOT EXISTS 'sammlung' (
  'SID' int NOT NULL AUTO_INCREMENT,
  'SName' varchar(50) NOT NULL,
  'Ort' varchar(50),
  'Land' varchar(50)
) DEFAULT CHARSET=latin1;
```

Beim Anlegen der Tabelle »Sammlung« ist in diesem Beispiel zusätzlich der verwendete **Zeichensatz** angegeben. »latin1« entspricht einem westeuropäischen Zeichensatz. Um deutsche Umlaute verwenden zu können, sollte genauer »latin1_german1_ci« angegeben werden. Werden die Daten über einen Webbrowser eingegeben, der meist die Codierung UTF8 hat, sollte hier »utf8« angegeben werden. Schließlich werden noch die Tabellen für die Objekte und Künstler erstellt:

```
CREATE TABLE IF NOT EXISTS 'objekt' (
  'OID' int NOT NULL AUTO_INCREMENT,
  'Titel' varchar(100) NOT NULL,
  'Datierung' int,
  'KID' int NOT NULL,
  'SID' int NOT NULL
) DEFAULT CHARSET=utf8;
CREATE TABLE IF NOT EXISTS 'kuenstler' (
  'KID' int(11) NOT NULL,
  'VName' varchar(50) NOT NULL,
  'NName' varchar(50) NOT NULL,
  'GJahr' int(11) DEFAULT NULL,
  'SJahr' int(11) DEFAULT NULL
) DEFAULT CHARSET=utf8;
```

Der Einfachheit halber wird für das Geburts- und Sterbedatum des Künstlers nur die Jahreszahl eingetragen, sinnvoller wäre es, den **Datentyp** DATE zu verwenden, um auf den Tag genau zu sein. Da das Datum der Digitalisierung eines Werks genau vorliegt und vom System übernommen werden kann, ist es hier als DATE definiert:

```
CREATE TABLE IF NOT EXISTS 'digitalisat' (
  'BID' int NOT NULL AUTO_INCREMENT,
  'OID' int NOT NULL,
  'EDatum' date NOT NULL,
  'EID' int NOT NULL
) DEFAULT CHARSET=utf8;
```

Wie im logischen Entwurf dargestellt, ist in jeder Tabelle ein Feld als Primärschlüssel definiert, um die Datensätze eindeutig zu identifizieren. Auch dies ist in der Datenbank zu implementieren. Dabei wird mithilfe des ALTER-Befehls der jeweiligen Tabelle ein Feld als Primärschlüssel zugewiesen. In unserem Beispiel sieht das so aus:

```
ALTER TABLE 'institution' ADD PRIMARY KEY('IID');
ALTER TABLE 'sammlung' ADD PRIMARY KEY('SID');
ALTER TABLE 'objekt' ADD PRIMARY KEY('OID');
```



```

ALTER TABLE 'kuenstler' ADD PRIMARY KEY('KID');
ALTER TABLE 'ersteller' ADD PRIMARY KEY('EID');
ALTER TABLE 'digitalisat' ADD PRIMARY KEY('BID');

```

Ist dies getan, fehlen noch die Beziehungen zwischen den Tabellen. Das bedeutet, die jeweiligen Fremdschlüssel müssen mit den Primärschlüsseln der jeweiligen anderen Tabelle verbunden werden. Dies geschieht ebenfalls über den Befehl ALTER für alle fünf Verknüpfungen folgendermaßen:

```

ALTER TABLE 'objekt' ADD FOREIGN KEY ('SID') REFERENCES 'bilddaten-
bank'.'sammlung'('SID') ON DELETE RESTRICT ON UPDATE CASCADE;
ALTER TABLE 'objekt' ADD FOREIGN KEY ('KID') REFERENCES 'bilddaten-
bank'.'kuenstler'('KID') ON DELETE RESTRICT ON UPDATE CASCADE;
ALTER TABLE 'digitalisat' ADD FOREIGN KEY ('OID') REFERENCES 'bilddaten-
bank'.'objekt'('OID') ON DELETE RESTRICT ON UPDATE CASCADE;
ALTER TABLE 'digitalisat' ADD FOREIGN KEY ('EID') REFERENCES 'bilddaten-
bank'.'ersteller'('EID') ON DELETE RESTRICT ON UPDATE CASCADE;
ALTER TABLE 'ersteller' ADD FOREIGN KEY ('IID') REFERENCES 'bilddaten-
bank'.'insitution'('IID') ON DELETE RESTRICT ON UPDATE CASCADE;

```

Mit dem Zusatz ON UPDATE CASCADE werden bei Änderung des Fremdschlüssels in der Tabelle die Primärschlüssel in der Primärtabelle ebenso geändert. Das Löschen wird jedoch mit ON DELETE RESTRICT verhindert. Visualisiert sehen diese Verbindungen folgendermaßen aus:




Abb. 24 Verknüpfung der Tabellen

Daten eingeben und ändern: Sind diese Tabellen erstellt, sind sie jedoch noch leer und müssen mit Inhalt gefüllt werden. Dies geschieht mit den Datenbearbeitungsbefehlen (DML):

- **INSERT** fügt der Tabelle eine neue Zeile hinzu.
- **UPDATE** verändert eine bestimmte Zeile in einer Tabelle.
- **DELETE** löscht eine Zeile in einer Tabelle.
- **TRUNCATE TABLE** entspricht DELETE, löscht jedoch alle Zeilen.

Werden Daten geschrieben oder verändert, so werden diese Änderungen intern nicht direkt am Datenbestand vorgenommen, sondern gesammelt und dann erst umgesetzt. Eine solche **Transaktion** ist eine übliche Möglichkeit, um Inkonsistenzen zu vermeiden, die beispielsweise entstehen können, wenn Änderungen an vielen Datensätzen vorgenommen werden. Werden sie korrekt und vollständig umgesetzt, endet die Transaktion mit einem ›commit‹, wurden sie jedoch von einem Fehler unterbrochen, sind die Änderungen vollständig widerrufbar (›rollback‹)

Eine Transaktion erfüllt idealerweise vier Bedingungen, die in dem Akronym ACID zusammengefasst sind:

- **Atomicity:** Die Unteilbarkeit bedeutet, dass Operationen immer nur vollständig ausgeführt und nicht von anderen Operationen unterbrochen werden. Aus der Außensicht kann erst dann, wenn eine Transaktion abgeschlossen ist, eine weitere durchgeführt werden. Ist die vollständige Umsetzung nicht möglich, ist die Transaktion komplett rückgängig zu machen (*rollback*) und wird so auf den Ursprungszustand zurückgesetzt (Prinzip: alles oder nichts).
- **Consistency:** Konsistenz bedeutet, dass der Datenbestand stets korrekt ist, dass also alle Attribute im Wertebereich liegen (Bereichsintegrität), jedes Objekt einen eindeutigen Primärschlüssel besitzt (Entitätsintegrität), jeder Fremdschlüssel existiert (referentielle Integrität) und definierte Strukturen eingehalten werden (logische Konsistenz). Auf diese Weise kann die Anwendung stets von korrekten Daten ausgehen.
- **Isolation:** Unterschiedliche Formen der Isolation verhindert die Kollision gleichzeitiger Operationen vor allem bei Lese- und Schreib-Sequenzen.
- **Durability:** Operationen, die abgeschlossen sind, liegen garantiert dauerhaft in der Datenbank vor, selbst wenn Systemfehler auftreten.

Wird in die Tabelle ›Institution‹ eine Zeile eingetragen, müssen in der SQL-Anweisung die jeweiligen Spalten und deren Inhalte in Klammern zusammengefasst angegeben werden:

```
INSERT INTO 'institution' ('IID', 'IName') VALUES
(37, 'Universität Musterstadt');
```

Hier wird deutlich, dass Zahlenwerte in der Instruktion für sich stehen, Texteingaben jedoch in einfachen Anführungsstrichen eingegeben werden. Soll ebenso ein Ersteller zur Tabelle ›Ersteller‹ angefügt werden, so geschieht dies über folgenden Befehl:

```
INSERT INTO 'ersteller' ('EID', 'VName', 'NName', 'IID') VALUES
(1, 'Max', 'Mustermann', 37);
INSERT INTO 'sammlung' ('SID', 'SName', 'Ort', 'Land') VALUES
(80, 'Alte Pinakothek', 'München', 'Deutschland');
```

```
INSERT INTO 'objekt' ('OID','Titel','Datierung','KID','SID') VALUES (2345,
'Selbstbildnis im Pelzrock', 1500, 123, 80);
INSERT INTO 'objekt' ('OID','Titel','Datierung','KID','SID') VALUES (2000,
'Porträt des Oswald Krell', 1499, 123, 80);
```

Es können auch mit einem Befehl gleichzeitig mehrere Zeilen hinzugefügt werden:

```
INSERT INTO 'kuenstler' ('KID','VName','NName','GJahr','SJahr') VALUES
(123, 'Albrecht','Dürer', 1471, 1528),
(132, 'Michelangelo','Buonarroti', 1475, 1564),
(156, 'Peter Paul','Rubens', 1577, 1640);
```

Damit ist die Tabelle »Künstler« nun so gefüllt:

KID	VName	NName	GJahr	SJahr
123	Albrecht	Dürer	1471	1528
132	Michelangelo	Buonarroti	1475	1564
156	Peter Paul	Rubens	1577	1640

Auf diese Weise sind nun eine Institution, ein Ersteller, ein Objekt und mehrere Künstler in die Datenbank aufgenommen. Wird nun ein Werk dieser Künstler digitalisiert, wird dies in der Datenbank verzeichnet:

```
INSERT INTO 'digitalisat' ('BID', 'OID', 'EDatum', 'EID') VALUES
(66, 2345, '2015-12-15', 1);
```

Deutlich wird hier der Verweis auf das Digitalisat, das Objekt sowie den Ersteller. Das Datum der Erstellung wird im Format Jahr, Monat, Tag übergeben. Angenommen, es wäre hier zu einem Fehler gekommen und das Digitalisat bezieht sich nicht auf Objekt 2345, sondern fälschlich auf Objekt 2344, so könnte die Zeile mit dem UPDATE-Befehl auch wieder korrigiert werden. Dazu muss dem System mitgeteilt werden, in welcher Spalte welcher Wert neu gesetzt werden soll sowie in welcher Zeile. Letzteres wird mit dem Zusatz WHERE bewerkstelligt. Hier soll die Zeile verändert werden, in der die ID des Digitalisats den Wert 66 besitzt:

```
UPDATE 'digitalisat' SET 'OID'=2345 WHERE 'BID'=66;
```

Die Tabelle hat nun folgende Inhalte:

BID	OID	EDatum	EID
66	2345	2015-12-15	1

8.3 | Datenbankabfragen

Die Daten liegen nun in der Datenbank vor und können mithilfe von SQL über das Datenbankmanagementsystem abgerufen und ausgewertet werden. Bei einer solchen Abfrage an das System werden zunächst die gewünschten Spalten und Relationen selektiert. Wird zudem ein Suchkriterium übergeben, können bestimmte Datensätze ausgewählt werden. Eine SQL-Abfrage setzt sich daher aus folgenden Teilen zusammen:

1. **SELECT:** Welche Daten soll das Ergebnis darstellen, also welche Spalten sind anzuzeigen?
2. **FROM:** Welche Datenbasis soll abgefragt werden, also welche Tabellen sind zu untersuchen?
3. **WHERE:** Welche Bedingungen müssen Daten erfüllen, um zum Ergebnis zu führen, also welche Teilmenge soll erzeugt werden?

Angenommen, es sollen alle Spalten aus der Tabelle »Künstler« dargestellt werden, so würde das SQL-Kommando folgendermaßen lauten:

```
SELECT 'KID', 'VName', 'NName', 'GJahr', 'SJahr' FROM 'kuenstler' WHERE 1
```

Hier werden alle Spalten der Tabelle ausgewählt. Dies könnte auch mit dem einfachen »*«-Zeichen ersetzt werden:

```
SELECT * FROM 'kuenstler' WHERE 1
```

Diese Spalten werden aus der Tabelle »Künstler« genommen. Die Zahl »1« hinter WHERE bedeutet, dass keine Bedingung gestellt wird, also alle Inhalte ausgegeben werden sollen. In diesem Fall wären das die drei eingegebenen Künstler. Eine Bedingung könnte jedoch lauten, nur Künstler aus der Datenbank anzuzeigen, die zwischen 1450 und 1500 geboren sind. Die Anweisung würde lauten:

```
SELECT * FROM 'kuenstler' WHERE ('GJahr'>1450 AND 'GJahr'<1500)
```

Das Ergebnis wäre

KID	VName	NName	GJahr	SJahr
123	Albrecht	Dürer	1471	1528
132	Michelangelo	Buonarroti	1475	1564

Sollen nur Vor- und Nachname der Künstler ausgegeben werden, die zwischen 1450 und 1500 geboren wurden und die Liste nach dem Nachnamen alphabetisch aufsteigend sortiert werden, so lautet der Aufruf:

```
SELECT kuenstler.VName, kuenstler.NName
FROM kuenstler
WHERE (kuenstler.GJahr >1450)
AND (kuenstler.GJahr <1500)
ORDER BY kuenstler.NName ASC
```

Hier wird deutlich, dass die Spalten auch mit dem Tabellennamen vorangestellt und durch Komma getrennt aufgerufen werden können. Dies ermöglicht es, auch Spalten gleichen Namens anderer Tabellen aufzurufen. Die Namen können auch ohne Anführungsstriche angegeben werden. ›ASC‹ bedeutet ›ascending‹, also aufsteigend sortiert. Das Ergebnis ist folgende Tabelle:

VName	NName
Michelangelo	Buonarroti
Albrecht	Dürer

Nun können auch Abfragen über verknüpfte Tabellen gestellt werden. Sollen alle Werke nach alphabetischer **Sortierung** des Künstlernamens mit der jeweiligen Sammlung ausgegeben werden, so sind per SELECT zunächst die Spalten aus den drei Tabellen auszuwählen und die Verknüpfungen zwischen dem Objekt und dem Künstler bzw. der Sammlung über die Künstler-ID und die Sammlungs-ID herzustellen. Anschließend ist diese Liste sortiert auszugeben:

```
SELECT 'kuenstler'.VName,'kuenstler'.NName,'objekt'.Titel,'objekt'.
'Datierung','sammlung'.SName,'sammlung'.Ort
FROM 'kuenstler','objekt','sammlung'
WHERE ('kuenstler'.KID = 'objekt'.KID AND 'objekt'.SID =
'sammlung'.SID)
ORDER BY 'kuenstler'.NName ASC
```

Das Ergebnis ist eine Tabelle mit folgenden Inhalten:

VName	NName	Titel	Datierung	SName	Ort
Albrecht	Dürer	Porträt des Oswald Krell	1499	Alte Pinakothek	München
Albrecht	Dürer	Selbstbildnis im Pelzrock	1500	Alte Pinakothek	München

Sollen alle Digitalisate mit ihrer ID und dem Werktitel ausgegeben werden, die der Ersteller mit der ID 1 erzeugt hat, so ist folgender Befehl auszuführen:

```
SELECT 'digitalisat'.BID, 'objekt'.Titel
FROM 'ersteller','digitalisat','objekt'
WHERE ('ersteller'.EID = 1) AND ('ersteller'.EID = 'digitalisat'.EID)
AND ('digitalisat'.OID = 'objekt'.OID)
```

Das Ergebnis ist nur eine Zeile mit Dürers Selbstbildnis, da das ›Porträt des Oswald Krell‹ zwar als Original verzeichnet ist, aber noch nicht digitalisiert vorliegt. Die AND-Verkettung nach WHERE dient zunächst der Festlegung der Ersteller-ID, diese muss aber auch mit der des Digitalisats übereinstimmen, und aus den Objekten werden nur jene dargestellt, die auch die Objekt-ID mit dem ausgewählten Digitalisat gemeinsam haben.

Ein praktisches Beispiel macht deutlich, wie diese Verkettung dabei hilft, für die Forschung relevante Daten aus der Datenbank zu erhalten, und wie Abfragen in Einzelaufgaben zerlegt werden: Das Browsergame »Artigo.org« hat zum Ziel, eine kunsthistorische Datenbank über die klassischen Metadaten hinaus mit Inhaltsschlagworten zu versehen. Dazu werden dem Benutzer Bilder aus der Datenbank gezeigt, zu




Abb. 25 Beispiel Artigo-Datenbank

denen dieser in einer beschränkten Zeit und gegen einen virtuellen Gegenspieler Tags eingibt, Spielpunkte sammelt und dadurch in einer Bestenliste erscheinen kann.

Die dahinterliegende Datenbank wird auf diese Weise mit **User Generated Content** befüllt, die für die Digitale Kunstgeschichte von hohem Wert ist. Diese Datenbank besteht aus zahlreichen Tabellen, von denen in der Visualisierung (Abb. 25) eine Auswahl dargestellt ist. Soll nun eine Tabelle ausgegeben werden, in der zu jedem Werk, das mit Künstlernamen, Titel und dem Pfad zur Bilddatei (»path«) angegeben wird, die Tags zugeordnet werden, so sind, ähnlich wie im obigen Beispiel, Verknüpfungen herzustellen. Die Tabelle »artresource« beinhaltet das Objekt, das seinen Titel aus der Tabelle »artresourcetitel« erhält und den Künstlernamen aus »person«. Diesem jeweiligen Objekt ist eine Anzahl von Tags zugeordnet, die jedoch nicht gemeinsam und damit redundant in einer Tabelle stehen (*tagging*), sondern auf eine weitere Tabelle verweisen (*tag*), in der die jeweiligen Tags nur einmal vorkommen.

In der Darstellung sind mit Häkchen die Felder ausgewählt, die in der resultierenden Tabelle erscheinen sollen. Die Verbindungen symbolisieren die Bedingungen, die zwischen bestimmten (zum Teil nicht ausgegebenen) Feldern bestehen müssen. So muss das Feld »resource_id« aus der Tabelle »tagging« mit der jeweiligen id aus »artresource« und »artresourcetitel« übereinstimmen. Die »tag_id« muss mit der ID aus der Tabelle tag übereinstimmen, aus der der Name, also der Tag selbst, entnommen wird. Und schließlich muss die ID des Künstlers mit der aus der Tabelle »person« übereinstimmen, aus der der Vor- und Nachname entnommen wird.

Dies sind grundlegende Funktionen einer relationalen Datenbank, die mit SQL abgefragt wird (weitere Informationen finden sich in Pernul/Unland 2009, 255–456). Dieses Datenbankmodell ist heute weit verbreitet, weil es zu vergleichsweise über-

sichtlichen Strukturen führt und schnellen Zugriff ermöglicht. Außerdem sind sie in Open-Source-Software, wie MySQL, vor allem auf Webservern im Einsatz. Relationale Datenbanken sind jedoch nicht immer die beste Wahl. Je nach Datenstruktur kommen zunehmend auch andere Modelle zum Einsatz.

8.4 | Andere Datenbankmodelle

Das **Graphdatenbankmodell** bietet extrem schnellen Zugriff auf vernetzte Daten. Diese liegen beispielsweise in Geoinformationen, Verkehrsbewegungen oder komplexen Beziehungsstrukturen vor, in denen Personen als **Knoten** (*nodes*) und deren Beziehung zueinander als **Kanten** (*edges*) dargestellt werden (s. Kap. 10.1). Alleine mit diesen beiden Elementen lässt sich ein Graph sehr einfach modellieren. Abbildung 26 zeigt als Beispiel das Schülerverhältnis verschiedener Künstler zueinander.

Knoten und Kanten können darüber hinaus mit Eigenschaften (*properties*) versehen werden, beispielsweise mithilfe einfacher Schlüssel-Wert-Paare, wie ›geboren_in: Nürnberg‹ oder ›Schüler_seit: 1486‹ (**Property-Graphen**). In einer Datenbank, in der die Beziehungen zwischen Objekten repräsentiert sind, liegt der Schwerpunkt von Abfragen in der Suche nach einem bestimmten Knoten oder einer bestimmten Kante mit einem bestimmten Attribut, wie sie auch in relationalen Datenbanken möglich ist. Die Besonderheit liegt jedoch darin, dass auch das schrittweise Durchlaufen von Knoten zu Knoten entlang von Kanten möglich ist (traversieren). So kann beispielsweise nach Nachbarschaften gefragt werden, wie auch nach dem kürzesten Weg von einem Knoten zu einem anderen (Routen). Im obigen Beispiel könnte zunächst nach dem Knoten ›Hans Schäufelin‹ gesucht und dann nach den ausgehenden Kanten gefragt werden. Ergebnis wäre die Ausgabe von ›Albrecht Dürer‹ und ›Marcantonio Raimondi‹.

Bei einer Abfrage wird also nicht der vollständige Datenbestand herangezogen, sondern nur das jeweilige Objekt und dessen direkten Nachbarn betrachtet. Auf




Abb. 26 Beispiel eines Beziehungsnetzwerks

diese Weise ist die Performance unabhängig von der Anzahl der Knoten und damit besonders skalierbar. Die Abfragesprache ist bisher nicht standardisiert. Die Graphdatenbank »Neo4j« setzt beispielsweise die strukturierte Sprache Cypher ein, in der der Anfangsknoten mit START ausgewählt wird, mit MATCH die zu verfolgenden Verbindungen definiert, mit WHERE (ähnlich wie in SQL) die Ergebnisse gefiltert und mit RETURN die Rückgabedaten festgelegt werden.

XML-Datenbanken empfehlen sich, wenn in einem Projekt XML-Daten zum Einsatz kommen. Mit XML können komplexe Objekte flexibel angelegt werden, da auch verschachtelte Strukturen möglich sind. Diese Dateien können jedoch sehr groß sein und benötigen mit wachsendem Umfang gegebenenfalls einen schnellen Mehrbenutzerzugriff. Eine Konvertierung in eine relationale Datenbank, die dies leistet, würde die Struktur der Daten jedoch verändern und dadurch möglicherweise Fehler erzeugen. Bei der Verwendung einer XML-Datenbank kann der Vorteil der Dokumentenstruktur jedoch erhalten bleiben. Zudem können die Dokumente über eine Sprache, wie XPath, abgefragt und somit auch etwa über eine Schnittstelle mit dem Web verbunden werden.

Im Zuge der Zusammenlegung heterogener Datenstrukturen und der schnellen Erhebung von Daten mittels Sensoren entsteht **Big Data**, also große Datenmengen, die in Echtzeit verarbeitet werden müssen. Mit der Struktur relationaler Datenbanken sind der Zugriff und die Verarbeitung aufgrund der hohen Anforderungen an Speicher und Prozessor oft nicht in ausreichender Geschwindigkeit möglich. Daher werden neue Formen der Datenorganisation getestet.

NoSQL-Datenbanken, wie beispielsweise »MongoDB«, die nicht nur (»Not only«) aus wohl strukturierten SQL-Daten bestehen, sondern beispielsweise auch aus Textdokumenten und Bildern, werden vor allem in Unternehmen verwendet, deren Datenvolumen unter anderem in unstrukturierten Daten vorliegt. Beispielsweise erlaubt es das Software Framework »Hadoop« der Apache Foundation, Daten im Petabyte-Bereich auf verteilten Systemen abzulegen und schnell zu analysieren. Aufgrund der notwendigen Geschwindigkeitserfordernisse werden diese Daten häufig nicht mehr nur auf Festplatten, sondern vollständig im schnellen Arbeitsspeicher abgelegt (**In-Memory-Datenbank**), was neuartige Methoden der Ausfallsicherung benötigt.

Big Data ist eine Herausforderung nicht nur in der Industrie, sondern ebenso in der Wissenschaft. Die Aufgabe der Digital Humanities ist es zunehmend, Erkenntnisse auch aus einem »distant reading« oder »distant viewing« heraus zu generieren. Umso wichtiger ist es, mit der Entwicklung technischer Möglichkeiten vertraut zu sein und drauf zugreifen zu können, wo es notwendig ist.

Literatur

- Chen, Peter Pin-Shan: »The Entity-Relationship Model. Toward a unified view of data«. In: *ACM Trans. Database Syst.* 1/1 (1976), 9–36.
- Codd, Edgar F.: »A relational model of data for large shared data banks«. In: *Communications of the ACM* 13/6 (1970), 377–387.
- Geisler, Frank: *Datenbanken: Grundlagen und Design*. Heidelberg u. a. ⁵2014.
- Pernul, Günther/Unland, Rainer: *Datenbanken im Unternehmen. Analyse, Modellbildung und Einsatz*. München/Wien ²2009.
- Vossen, Gottfried: *Datenmodelle, Datenbanksprachen und Datenbankmanagementsysteme*. München u. a. ⁵2008.

Harald Klinke

9 XML

9.1 | Anwendung und Grundbegriffe

XML steht für **eXtensible Markup Language** und bezeichnet ein Verfahren, um **Texte auszuzeichnen** und **Informationen zu kodieren**. Es ist entwickelt worden, um die Strukturen eines Dokuments kenntlich und damit für den Computer verarbeitbar zu machen, indem Kodierungen (»Auszeichnungen«) in einen laufenden Text eingefügt werden. Mit XML können aber auch andere, multimediale Datenbestände organisiert werden, indem textliche oder numerische Informationen in eine Struktur eingefügt werden.

XML verwendet für die Kodierungen die gleichen Zeichen wie für den Text oder die zu beschreibenden Daten. Diese **Zeichendaten** stammen aus einem bestimmten Zeichenvorrat (s. Kap. 5), heutzutage meistens Unicode in der Form UTF-8. Das sorgt dafür, dass XML mit allen gängigen Editoren geschrieben, auf allen Plattformen und Betriebssystemen gelesen werden kann und deshalb als sehr zukunftssicher gilt. Die Kodierung von Information mit den gleichen Zeichen, die für den Text verwendet werden, und mit sprechenden Codes hat den Vorteil, dass die Textauszeichnung für Menschen ebenso wie für Maschinen lesbar ist.

Um zwischen Kodierungen und Text zu unterscheiden, legt XML einige Regeln fest. Typisch für XML sind die spitzen Klammern (< und >): Text innerhalb der spitzen Klammern ist Markup, außerhalb der eigentliche Text. Die mit den spitzen Klammern angezeigten Kodierungen heißen **tag** (engl. »Etikett«, »Kennzeichner«). Die **tags** bilden normalerweise korrespondierende Paare aus einem Anfangstag bzw. öffnen den **tag** (<gedicht>) und einem Endtag bzw. schließenden **tag**, das den gleichen Namen hat wie das Anfangstag, aber von einem Schrägstrich eingeleitet wird (</gedicht>). So kann man mit den Kodierungen Textbereiche markieren und ihnen Bedeutungen zuweisen. Im Beispiel 1 werden z. B. »Krethi & Plethi« als Titel und »Kurt Tucholsky« als Autor markiert oder **ausgezeichnet**.

Beispiel 1: Ein in XML kodiertes Gedicht (Auszug)

```
<?xml version="1.0" encoding="UTF-8"?>
<gedichtsammlung xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xmlns="http://gedichtforschung.org/gedichtsammlungen"
  xsi:SchemaLocation="http://gedichtforschung.org/gedichtsammlung.
xsd">
  <gedicht>
    <bibliografisch>
      <titel>Krethi & Plethi</titel>
      <autor typ="normiert" identifikation="gnd_11862444X">
        <name><vorname>Kurt</vorname> <nachname>Tucholsky</nachname></name>
        <name typ="alias">Theobald Tiger</name>
        <!-- unter diesem Pseudonym veröffentlicht -->
      </autor>
```

```

<quelle>Berliner Tageblatt, Nr. 487
  <datum normiert="1918-09-23">23. September 1918</datum>
</quelle>
</bibliografisch>
<text sprache="deutsch">
  <strophe>
    <vers><name typ="person" identifikation="gnd_116996595">Vater
      <nachname>Liebert</nachname></name> hat eine Rede vom Stapel
      gelassen,</vers>
    <vers>in der er sagte, der <name typ="institution" identifikation=
      "gnd_35236-6"> Reichstag</name> täte ihm nicht mehr passen.</vers>
  </strophe>
  <strophe>
    <vers>Denn in diesen durchaus traurigen Verein</vers>
    <vers>kämen ja sogar <redewendung>Krethi und Plethi</redewendung>
      hinein.</vers>
  </strophe>
  <strophe>
    <vers>Ich weiß nun nicht genau, wer Krethi und Plethi sind;</vers>
    <vers>vielleicht meint er damit meinen Vater oder dein Enkelkind.
      </vers>
  </strophe>
  <strophe>
    <vers>Aber das weiß ich: die <name typ="ereignis" identifikation=
      "wikidata_Q28205"> Schlacht bei Warschau</name> und <name typ=
      "ereignis" identifikation="wikidata_Q1926157">in den Argonnen
      </name>,</vers>
    <vers>die haben Deutschlands Krethi und Plethi gewonnen.</vers>
  </strophe>
  <luecke grund="auswahl"/> <!-- weiterer Text fehlt hier -->
</text>
</gedicht>
<gedicht>
  <bibliografisch><!--...--></bibliografisch>
  <text><!--...--></text>
</gedicht>
</gedichtsammlung>

```

Da Textinhalte und XML-Codes wie z. B. *tags* mit dem gleichen Zeichenvorrat geschrieben werden, ist es notwendig, bestimmte Zeichen zu reservieren. Sie müssen dann durch eine sogenannte Zeichenentität (**character entity**) ersetzt werden, die die allgemeine Form `&Entitätsname;` hat. Damit ist neben der spitzen Klammer auch das `&` ein Signalzeichen mit einer besonderen Bedeutung. Für den normalen Gebrauch im Text und zur Vermeidung von Konflikten in bestimmten Kontexten sind sie deshalb ggf. zu ersetzen:

Zeichen	Entity	Bedeutung
<	<	less than
>	>	greater than
&	&	ampersand
"	"	quotation mark
'	'	apostrophe

Tab. 4 Character Entities

Die Einheit aus *tags* und allem, was zwischen den *tags* steht, heißt **Element**. Elemente können Textinhalt oder andere Elemente oder beides enthalten. Im Beispiel gibt es ein Element *vers*, das Text enthält, der teilweise wieder mit anderen tags (z. B. *>name*) ausgezeichnet ist. Elementnamen berücksichtigen Groß- und Kleinschreibung (sind *case sensitive*): *titel* und *Titel* sind zwei verschiedene Elementtypen. Elementnamen müssen mit einem Buchstaben oder einem Unterstrich beginnen; sie dürfen Buchstaben, Zahlen, Bindestriche, Unterstriche und Punkte, aber keine Leerzeichen enthalten.

Wenn Elemente keinen Inhalt, also weder Textdaten noch andere Elemente enthalten, nennt man sie **leere Elemente**. Statt `<luecke></luecke>` wird im Beispiel deshalb die abgekürzte Schreibweise `<luecke/>` verwendet.

Elemente können mit **Attributen** um weitere Informationen ergänzt werden: `<text sprache="deutsch">`. Attribute sind Teil des Anfangstags und bestehen aus einem Attributnamen und einem in Anführungszeichen stehenden Attributwert, die mit einem Gleichheitszeichen verbunden sind. Ein Element kann viele verschiedene Attribute enthalten, die durch ein Leerzeichen getrennt werden. Zwei Attribute gleichen Namens darf es innerhalb eines Elements nicht geben. Attributnamen beginnen mit einem Buchstaben oder dem Unterstrich und unterscheiden zwischen Groß- und Kleinschreibung.

XML-Dokumente können **Kommentare** enthalten, die nur für den menschlichen Leser gedacht sind und von der Software ignoriert werden, die die Dokumente dem Regelwerk von XML entsprechend einlesen und vorverarbeiten (parsen). Kommentare haben eine spezielle Kodierungsform für Anfang und Ende: `<!-- Kommentar -->`

9.2 | Grundstrukturen

Schachtelung: XML-Elemente können andere Elemente enthalten. Umgekehrt wird daraus die wichtigste Regel von XML: Alle Elemente müssen vollständig in einem anderen Element enthalten sein. Diese Schachtelung führt dazu, dass:

- die Struktur der Kodierungen strikt hierarchisch ist.
- alles in einem obersten Element enthalten ist, das man Wurzelement (*root*) nennt.

Bei dieser Hierarchie der sich auffächernden Elemente spricht man von einer **Baumstruktur**.

Die Elemente eines XML-Dokuments werden **Knoten** (*nodes*) genannt. In der hierarchischen Ordnung spricht man von über- und untergeordneten Elementen, die in einer sogenannten **Eltern-Kind-Relation** stehen. Man sagt, dass *gedichtsam-*




Abb. 27 Schematische Darstellung der (Baum-)Struktur der XML-Kodierung in Beispiel 1

lung ein Elter (*parent*) von *gedicht* ist und dass *strophe* ein Kind (*child*) von *text* ist. Auch sagt man, dass sich *text* und *vers* wie Vorfahre (*ancestor*) und Nachkomme (*descendant*) verhalten, wobei diese Relation beliebig viele Ebenen überspringen kann. Zugleich haben XML-Dokumente eine **sequentielle Ordnung**: Elemente stehen vor (*preceding*) und hinter (*following*) anderen Elementen. So sind z. B. alle *strophe*-Elemente nachfolgend (*following*) zum *bibliografisch*-Element. Haben Elemente das gleiche Elternelement, dann nennt man sie **Geschwister** (*siblings*). Alle Strophen eines Textes sind Geschwister. Die Strophen verschiedener Texte sind aber nur die Nachkommen des gemeinsamen Vorfahren *gedichtsammlung*.

In XML dürfen sich Elemente **nicht überlappen**: Jedes Element, das in einem anderen enthalten ist, muss geschlossen werden, bevor das Elternelement endet. Eine Struktur `<a> ... <b> ... </a> ... </b>` überlappt (*overlap*) und ist nicht erlaubt, weil hier nicht mehr klar ist, was eigentlich in was enthalten ist und damit keine klare Hierarchie mehr besteht.

Die Struktur eines XML-Dokuments besteht im Wesentlichen aus einem **Baum**. Es hat ein Wurzelement, das alle weiteren Elemente und Inhalte einschließt. Zusätzlich gibt es aber noch den sogenannten **Prolog**, der vor dem Starttag des Wurzelements steht. Diese enthält mindestens die XML-Deklaration (mit Angaben zur XML-Version und zur Zeichencodierung, Zeile 1 in Beispiel 1) und weitere optionale Angaben, wie z. B. *processing instructions* dazu, welchem Regelwerk (Schema) das Dokument entsprechen oder mit welchen Verarbeitungsanweisungen es transformiert werden soll.

Programme, die XML-Daten einlesen und prüfen, heißen »Parser«. Werden die grundlegenden Regeln eingehalten, dann kann der Parser aus dem Dokument die Baumstruktur der Daten konstruieren und für die weitere Arbeit damit zur Verfügung stellen. Dokumente, die die **grundlegenden Regeln einhalten**, nennt man **wohlgeformt** (*well formed*). Kann ein Parser außerdem feststellen, dass ein Dokument die in einem **Schema** (s. u.) festgelegten Regeln der Verwendung von Elementen und Attributen einhält, dann gilt es außerdem als **gültig** bzw. valide (*valid*). Die kontinuierliche Validierung stellt sicher, dass auch über viele Dokumente oder Bearbeiter hinweg die gleichen Regeln zur Beschreibung und Strukturierung von Textdaten eingehalten werden.

9.3 | Konzepte und Datenmodell

Die Idee, Text mit Markierungen zu versehen, die zusätzliche Informationen für die weitere Verarbeitung und Darstellung geben, stammt aus der Welt des Drucksatzes: Strukturell bestimmte Textpassagen (z. B. Überschriften) wurden im Manuskript gekennzeichnet, damit im Druck dann besondere Schrifteigenschaften wie fett gesetzte Buchstaben oder Unterstreichungen verwendet wurden. Diese Konzepte wurden schon in den 1960er Jahren auf die Textverarbeitung mit dem Computer übertragen. Textauszeichnungssprachen beruhen wie XML meist darauf, dass Kodierungen mit demselben Zeichensatz wie der eigentliche Text in diesen eingefügt werden, verwenden jedoch eine unterschiedliche Syntax und verfolgen unterschiedliche Ziele. Textauszeichnungssprachen wie LaTeX, Markdown oder das Wiki-Markup stellen die Verarbeitung und die Darstellung des Textes in den Vordergrund. Textauszeichnung für Verarbeitung des Textes wird »**prozedurale Auszeichnung**« (*procedural markup*), Textauszeichnung für die Darstellung »**präsentationale Auszeichnung**« (*presentational markup*) genannt. Einen anderen Ansatz verfolgt die »**deskriptive Auszeichnung**« (*descriptive markup*). Sie geht davon aus, dass sich die Bedeutung von Textdaten von ihrer Darstellung trennen lässt und dass die Auszeichnung dazu dient, die Bedeutung von Textabschnitten zu beschreiben, die unabhängig von ihrer Darstellung kodiert werden kann.

Das Konzept deskriptiver Auszeichnungssprachen ist in den 1970er Jahren u. a. von Charles M. Goldfarb eingeführt worden. Es führte zur Entwicklung der »Standardized General Markup Language« (SGML), die 1986 als ISO 8879 normiert wurde. XML ist eine Weiterentwicklung von SGML, die das komplexe Regelwerk so reduziert, dass nach XML kodierte Daten leichter von Programmen verarbeitet werden können. Dies liegt vor allem am Verzicht auf Mechanismen zur Beschreibung von impliziten (schließende Tags sind nicht notwendig) und von überlappenden Strukturen (CONCUR Funktion).

Lesbarkeit für Mensch und Maschine: Zu den Grundprinzipien von SGML und damit auch von XML gehört, dass der in den Text eingefügte Code nicht nur von Maschinen sondern auch von Menschen lesbar sein sollte. Dieses Prinzip schließt binäre Kodierungen aus, da sie nicht unmittelbar lesbar wären. Zur guten Praxis von XML gehört auch, dass die Namen von Elementen und Attributen sprechend sind. Von Programmierern wird diese »Weitschweifigkeit« als Problem wahrgenommen, weil sie z. B. die zu übertragende Datenmenge erhöht. Aus Sicht der digitalen Geisteswissenschaften ist diese Weitschweifigkeit eine vorteilhafte Eigenschaft, denn sie erlaubt es, mit dem in XML kodierten Text in einer Art und Weise umzugehen, die dem Gebrauch natürlicher Sprache sehr ähnlich ist.

XML in der Version 1.0 ist 1998 vom World Wide Web Consortium (W3C) als Standard (*recommendation*) verabschiedet worden und im Grunde heute noch gültig. Selbst die fünfte Auflage von 2008 hat nur Unwesentliches geändert. Das gleiche gilt für die XML-Version 1.1 von 2004, die nur den Umgang mit Unicode betrifft, und das 2001 neu eingeführte »XML Infoset«, das gemeinsame konzeptionelle und definitorische Grundlage für die gesamte XML-Sprachfamilie festlegt.

XML ist eine Auszeichnungssprache, die sonst z. B. durch typografische oder Layout-Strukturen oder durch menschliches Kontextwissen implizit gegebene Informationen explizit macht. Was in einem Dokument zentriert und fett gedruckt ist, kann als Element vom Typ `Überschrift` identifiziert und markiert werden;

›Vater Liebert‹ (aus unserem Beispiel 1) kann als Bezeichnung für eine bestimmte *Person* erkannt und ausgezeichnet werden, um zusätzliches Wissen an den Text anzulagern und die Stelle z. B. als Registerbegriff zu verwenden; die bibliographische Angabe ›23. September 1918‹ kann als *Datum* beschrieben und mit einer formalisierten Zusatzangabe ›1918-09-23‹ versehen werden, um sie mit dem Computer leichter berechenbar zu machen. Ebenso können Festlegungen getroffen werden, wie dass *Strophen* *Verse* enthalten oder *Personennamen* in *Vor-* und *Nachnamen* gegliedert sind. XML erlaubt es so, genau festgelegte Strukturen für die Beschreibung von Texten je nach Dokumentart oder Wissensbereich zu schaffen. Man kann mit XML Gedichte ebenso systematisch kodieren wie Banküberweisungen oder das Wissen zu den Beständen eines Ersatzteillagers. XML ist deshalb eine Technologie, die es ermöglicht, Sprachen zu erschaffen, mit denen wir höchst strukturiert und sehr explizit mit Informationen umgehen können. Gleichzeitig können wir mit XML nah an unserer natürlichen Verwendung von Sprache bleiben, und mit eingeführten Begriffen über die Objekte sprechen, die vom Computer verarbeitet werden sollen.

XML selbst ist strenggenommen gar keine Auszeichnungssprache, sondern eine **Metasprache**, weil sie nur ein allgemeines Regelwerk zur Textauszeichnung liefert, die Festlegung des eigentlichen Vokabulars und seiner Verwendung aber nicht vorwegnimmt. Das ›eXtensible‹ in XML steht dafür, dass man seine eigenen Beschreibungsmodelle und Konstrukte kreieren kann. XML sagt ›erfinde Deine eigenen Elemente‹. XML ist die Grundlage vieler konkreter Sprachen bzw. Standards zur Beschreibung von Informationsdomänen, die **Anwendungen** von XML sind. Dies sind z. B. wichtige Sprachen in den digitalen Geisteswissenschaften, wie die Regeln der Text Encoding Initiative (TEI), Metadatenstandards wie Dublin Core (DC), METS (Metadata Encoding and Transmission Standard) oder LIDO (Lightweight Information Describing Objects). Aber auch in vielen anderen Domänen wird XML zur Beschreibung und zum Austausch von Daten verwendet. Dies reicht von Überweisungen zwischen Banken bis hin zu Büro-Anwendungen wie Microsoft Office-Programmen oder OpenOffice. Wenn man einmal hinter die Kulissen schaut, entdeckt man heute in fast allen Bereichen der Datenhaltung und des Datenaustauschs XML.

Universalität von XML: Die Benutzung einfacher Zeichendaten, die Plattformunabhängigkeit, der Charakter als offener und voll dokumentierter W3C-Standard, die Einfachheit, die Menschenlesbarkeit, der breite Einsatzbereich und die weite Verbreitung sind Argumente für die Verwendung von XML. In den Geisteswissenschaften spielen aber noch weitere Eigenschaften eine Rolle, die XML auch von anderen Technologien zur Organisation von Daten unterscheidet. Hier ist zunächst der merkwürdige Doppelcharakter von XML als hierarchischem Baum *und* als sequentielllem Dokument zu bedenken. Während Auszeichnungssprachen zunächst für die Kodierung von Texten und Dokumenten geschaffen worden sind, haben sie sich inzwischen zu einem allgemeinen Austauschformat für alle möglichen Daten und Datenstrukturen entwickelt. Damit gehen zwei grundverschiedene Verwendungsweisen einher.

- **Dokumentorientiertes Markup:** Auf der einen Seite spricht man von dokumentorientiertem Markup, wenn man bestehende Textdaten allmählich auszeichnet, auf ihrer Grundlage ein Modell entwickelt und damit zu komplexen, tief gestaffelten Strukturen kommt, die häufig Elemente mit **mixed content** (Elemente *und* Textdaten) aufweisen.

- **Datenzentriertes Markup** hingegen speichert in eher klaren und strikten Strukturen und weniger tief hierarchisierten Bäumen kontrollierte Werte. Hier wird XML oft als Austauschformat für Anwendungen verwendet, die selbst z. B. ein relationales Datenbankmodell implementieren.

Beide Sichtweisen gehen von unterschiedlichen Startpunkten aus. Die eigentliche Intention bei XML war ursprünglich die Repräsentation, Explikation und Annotation bestehender Daten. Das Verhältnis des XML-Modells zur Welt ist hier deshalb eher **deskriptiv** (beschreibend). XML kann aber auch verwendet werden, um Daten in ein bestimmtes Modell der Welt einzufüllen – es wird dann eher **präskriptiv** (vorschreibend) verwendet.

In der Praxis gehen beide Prinzipien Hand in Hand: Modelle und Sprachen werden als Beschreibung der Welt und bestehender Objekte entwickelt, dienen dann aber auch als kodifizierter Konsens des Sprechens über Phänomene, als Vorgabe und als Kontrollmechanismus für erhobene Daten. Seine Stärke hat XML aber immer dort, wo es um die Verwaltung komplexer, lose strukturierter Wissensbestände mit dem Bedarf an flexibler Modellierung und der Verwaltung von *mixed content*-Phänomenen geht. Gerade das letztere ist ein Alleinstellungsmerkmal im Vergleich mit anderen Datenmodellen wie dem relationalen Datenbankmodell oder JSON (JavaScript Object Notation) (s. u.).

Das **relationale Datenbankmodell** (s. Kap 8) basiert auf der relationalen Algebra und verfügt damit über ein abgesichertes mathematisches Modell. Mit den Modellierungsprinzipien der Normalisierung führt es zu sehr klaren, rationalen, redundanzarmen Strukturen. Gute Kontrollmöglichkeiten bei den Datentypen und die Ausgereiftheit, die einfache Benutzbarkeit und die gute Performanz von Datenbankmanagementsystemen haben diesen Ansatz so sehr zum Normalfall gemacht, dass in der Alltagssprache fast immer ›relationale Datenbanken‹ gemeint sind, wenn ›Datenbank‹ gesagt wird. Das Konzept stößt aber an seine Grenzen, wenn es um dokumentorientierte oder Textdaten geht, die mit einem komplexen oder semistrukturierten Modell beschrieben werden sollen. Die Verwendung von XML ist vorzuziehen, wenn die Sequentialität des Textes, komplexe Hierarchien, eher lockere Beschreibungsmodelle und *mixed content*-Phänomene wichtige Modellaspekte sind, die als strukturierte Datenbasis verwaltet und algorithmisch verarbeitet werden sollen.

In letzter Zeit erfreut sich die ›JavaScript Object Notation‹ (JSON) zunehmender Beliebtheit. Dieses Format ist ebenfalls textbasiert, menschenlesbar und prinzipiell hierarchisch organisiert. Im Gegensatz zu XML gilt das Format als leichtgewichtiger und weniger weitschweifig, und es lässt sich einfach mit den aktuellen Webtechnologien verarbeiten, weil die Strukturen von JSON direkt in JavaScript-Objekte übersetzt werden. Die Kontrollmöglichkeiten durch Datentypen und festgelegte Schemata stehen derzeit noch am Anfang der Entwicklung. Von der Ausdrucksmächtigkeit her kann man zugespitzt sagen: ›JSON ist wie XML ohne *mixed content*‹.

XML selbst ist also prinzipiell ausdrucksmächtiger als das relationale Datenmodell oder JSON, dadurch aber unter Umständen auch komplexer. XML findet seine Grenze der Ausdrucksmächtigkeit vor allem an Phänomenen überlappender Hierarchien, für die es zwar mit leeren Elementen und dem sogenannten stand-off-markup Lösungsansätze gibt; diese führen aber zu einer noch höheren Komplexität. In der Praxis versucht man deshalb, überlappende Hierarchien zu vermeiden. Ist das nicht möglich, muss man die Komplexität in Kauf nehmen oder auf andere Auszeichnungssprachen ausweichen, in denen *overlap* möglich ist.

9.4 | Modelle und Schemata

XML legt nicht fest, welche Elemente und Elementnamen verwendet werden. Mit XML kann man deshalb frei gewählte Strukturen von Texten und Daten kodieren. Es gibt aber ein paar praktische Hinweise, wie man seine eigenen Elementnamen und Strukturen bildet: Elemente dienen der Abstraktion von Textphänomenen oder der Beschreibung von Strukturen. Man definiert deshalb Elemente für Phänomene, die voraussichtlich häufiger vorkommen bzw. auf mehrere Texte oder Dokumente anwendbar sind. Elementnamen sollten sprechend und verständlich aber kurz sein. Bindestriche und Punkte sind in Elementnamen unüblich. Es gibt Stile für Elementnamen wie z. B. ›CamelCase‹ (wenn sich ein Elementname aus mehreren Wörtern zusammensetzt, werden diese mit Großbuchstaben voneinander getrennt). Man ist hier frei, sollte aber im Vorgehen konsistent sein.

Man kann viele Textphänomene oder Strukturen mit Elementen *oder* mit Attributen ausdrücken, z. B. `<text><autor>Kurt Tucholsky</autor>...</text>` und `<text autor="Kurt Tucholsky">...</text>`. Man bevorzugt **Elemente**, wenn man komplexe Inhalte beschreiben will, die vielleicht später weiter ausgezeichnet oder annotiert werden sollen. Man verwendet **Attribute** für eher technische Informationen über ein Element oder für einfache Inhalte, insbesondere wenn sie kontrolliert und systematisch gebraucht werden, z. B. wenn man auf eine Identifikationsnummer für eine Person verweisen will: `<autor gnd="11862444X">Panter, Peter</autor>` oder `<zahl wert="141">CXLI</zahl>`. Mehrere Inhalte in einer Attributkategorie sollten keinesfalls mit mehreren Attributen (`autor="Kafka, Franz" autor1="Brod, Max"`), sondern als wiederholte Unter-elemente (`<autor>Kafka, Franz</autor><autor>Brod, Max</autor>`) ausgedrückt werden.

Strukturlogik: Mit Hilfe von **Schemata** kann man Elemente und Attribute definieren sowie ihre Verschachtelung und ihre Inhaltstypen festlegen. Man kann mit einem Schema also eine bestimmte Logik der Text- und Datenstrukturen festlegen und so ein Modell kodifizieren (s. Kap. 2.1 zu »Datenmodellierung«). Ein Schema erlaubt es damit einerseits, bei der Auszeichnung von Text bzw. der Erfassung von Daten gemeinsame Regeln zu verwenden, und damit sicherzustellen, dass bestimmte Informationen auch erfasst werden, oder bestimmte Strukturen ausgeschlossen sind. Andererseits unterstützt ein Schema die Weiterverarbeitung und den Austausch von Daten, indem sie die Funktion und das Verhalten von Elementen beschreiben (im Beispiel: `titel` und `autor` sind Teil der bibliografischen Beschreibung eines gedichts).

Wenn ein XML-Dokument den Regeln eines Schemas entspricht, wird es, wie gesagt, als ›valid‹ gegen das Schema bezeichnet. Die Validität gegen ein Schema kann von Software (den oben erwähnten XML-Parsern) überprüft werden. Mit einer solchen Prüfung wird sichergestellt, dass Dokumente einem gemeinsamen Modell entsprechen. Es ist aber damit noch nichts darüber ausgesagt, ob die Kodierung auch inhaltlich richtig ist oder was die Kodierung eigentlich meint.

Um Modelle in XML zu beschreiben, gibt es verschiedene Schemasprachen, die sich vor allem in ihrer Syntax, teilweise aber auch in ihrer Ausdrucksmächtigkeit unterscheiden: Mit manchen Schemasprachen kann man z. B. genauer festlegen, welche Datentypen ein Element enthält. Für die Beschreibung von Schemata für XML-Daten sind die folgenden vier besonders erwähnenswert:

- **DTD (Document Type Definition)**: die älteste Schemasprache, die zwar leicht erlernbar und gut lesbar ist, aber nur noch selten verwendet wird, weil sie nicht der XML-Syntax folgt und etwas weniger ausdrucksmächtig als andere Sprachen ist.
- **XSD (XML Schema Definition)**: die vom W3C entwickelte Schemasprache, die selbst in XML formuliert ist. Sie ist sehr ausdrucksmächtig, für den menschlichen Leser aber relativ unübersichtlich.
- **RNG (Relax NG = Regular Language Description for XML New Generation)**: Eine Schemasprache die zwei Arten von Syntax anbietet: eine nach den Regeln von XML wohlgeformte und eine kompaktere Syntax; etwas weniger ausdrucksmächtig als XSD.
- **Schematron**: Eine in XML ausgedrückte Sprache zur Validierung von XML-Dokumenten, die nicht eine Struktur definiert, sondern nur wann ein XML-Element einer Struktur widerspricht. Einzelne Elemente der Regeldefinitionen sind in XSD 1.1 übernommen worden; wenig verbreitet.

Ein Schema für unser Beispiel könnte in XSD ungefähr so aussehen:

Beispiel 2: Ausschnitt aus einem XML Schema

```
<xs:schema xmlns:xs="http://www.w3.org/2001/XMLSchema" elementFormDefault="qualified" targetNamespace="http://gedichtforschung.org/gedichtsammlungen" xmlns="http://gedichtforschung.org/gedichtsammlungen">
<!-- ... -->
  <xs:element name="bibliografisch">
    <xs:annotation>
      <xs:documentation>Das Element enthält die bibliografischen Angaben des Gedichts.</xs:documentation>
    </xs:annotation>
    <xs:complexType>
      <xs:sequence minOccurs="0">
        <xs:element ref="titel"/>
        <xs:element ref="autor"/>
        <xs:element ref="quelle"/>
      </xs:sequence>
    </xs:complexType>
  </xs:element>
  <xs:element name="titel" type="xs:string"/>
  <xs:element name="autor">
    <xs:complexType>
      <xs:sequence>
        <xs:element maxOccurs="unbounded" ref="name"/>
      </xs:sequence>
      <xs:attribute name="identifikation" use="required" type="xs:NCName"/>
      <xs:attribute name="typ" use="required" type="xs:NCName"/>
    </xs:complexType>
  </xs:element>
<!-- ... -->
</xs:schema>
```

Das Schema im Beispiel 2 enthält eine Liste von Elementdefinitionen (`<xs:element>`), zu denen jeweils der Name definiert ist (Attribut `name`). Der Inhalt jedes Elements ist über den Datentyp (Attribut `type`), oder ein komplexeres Inhaltsmodell `<xs:complexType>` für Kindelemente und *mixed content* definiert. Das Beispiel verwendet die einfachen Datentypen `xs:string` und `xs:date`. Diese Typen sind vom W3C definiert und stehen für einfachen Text (`xs:string`) bzw. eine Datumsangabe im Schema JJJJ-MM-TT (`xs:date`).

Weitere häufiger gebrauchte Datentypen könnten sein `xs:integer` für ganze Zahlen (positive wie negative) und `xs:double` für Kommazahlen. `<xs:complexType>` steht für eine Struktur, die mehr als nur einfachen Text oder Zahlen enthält. Mit dem Attribut `mixed` wird angegeben, ob das Element sowohl Text als auch Elemente enthalten kann. Bei der Auszeichnung von Texten ist das der Normalfall. Die Kindelemente können nun als Sequenz von Elementen (`<xs:sequence>`) oder als ein Element von vielen (`<xs:choice>`) definiert sein. In der Sequenz ist die Reihenfolge des Vorkommens der Elemente festgelegt. Die Attribute `minOccurs` und `maxOccurs` in der Definition des `<xs:complexType>` geben an, ob das Kindelement vorkommen muss und wie häufig es vorkommen kann. Die Schemadefinition `minOccurs="0"` sagt also, dass ein Element nicht vorkommen muss, aber kann, während `minOccurs="1"` sagt, dass ein Element vorkommen muss (nämlich mindestens einmal). Die Angabe `maxOccurs="unbounded"` sagt aus, dass ein Element beliebig häufig vorkommen kann, während `maxOccurs="1"` festlegt, dass ein Element nur genau einmal vorkommen darf.

Die Definition des `<xs:complexType>` enthält auch die Liste der möglichen Attribute für ein Element (`<xs:attribute>`). Ein Attribut, dass in jedem Fall vergeben werden muss, wird mit `use="required"` angegeben. Die Definition kann Elemente und Attribute explizit definieren oder nur auf sie verweisen (Attribut `ref`), was es erlaubt, Elemente und Attribute allgemein zu definieren und an verschiedenen Stellen zu verwenden. Im Bereich `<xs:annotation>` werden Anmerkungen zur Elementdefinition gegeben, wie z. B. in `<xs:documentation>` eine Beschreibung der Funktion des Elements.

Die Verwendung von Elementnamen hängt an dem Wissensbereich (der **Domäne**), um die es geht: Das obige Beispiel versteht unter »Text« den Text eines Gedichts, der aus Versen besteht. In anderen Gattungen muß Text aber nicht aus Versen bestehen. Eine »Mutter« ist in der Welt der Werkzeuge etwas anderes als in einer Datenbank zu Familienverhältnissen. Um diesen gebundenen Gebrauch von Elementnamen klar zu machen, gibt es das Konzept des sogenannten **Namensraums** (*namespace*). In unserem Beispiel 1 wird im Wurzelement angegeben, dass das XML-Dokument den Regeln des XML-Schemas unter <http://gedichtforschung.org/gedichtsammlung.xsd> folgt (Attribut `xsi:SchemaLocation`) und die Elemente damit dem Namensraum <http://gedichtforschung.org/gedichtsammlungen> angehören (Attribut `xmlns`). In einem XML-Dokument können grundsätzlich Elemente aus mehreren Namensräumen vermischt werden, sofern sie entsprechend deklariert sind: `<familie:mutter>Conny</familie:mutter> gab ihm eine <werkzeug:mutter>12er</werkzeug:mutter>`.

Namensräume werden normalerweise im Wurzelement eines XML-Dokuments deklariert und mit Hilfe von Attributen abgekürzt: `xmlns:tei="http://www.tei-c.org/ns/1.0"` erlaubt es so, im Dokument Elementnamen mit dem Präfix `tei:` zu versehen. Ein solches Präfix legt fest, dass das Element aus dem Namensraum der TEI stammt. Der Standardnamensraum eines XML-Dokuments wird mit

dem Attribut `xmlns` festgelegt. Elementnamen ohne Präfix stammen dann aus diesem Namensraum. Namensräume richtig zu bezeichnen, ist insbesondere bei der Umwandlung von XML zu HTML mit XSLT notwendig, denn dort werden sowohl Elemente aus dem Schema des Ausgangsdokuments als auch Elemente aus HTML und schließlich noch Elemente aus dem XML-Schema für die Transformation (XSLT) verwendet.

Auszeichnungssprachen: Konkrete Auszeichnungssprachen, die durch Schemata kodifiziert und dann zur Auszeichnung von Texten oder zur Beschreibung von Daten eingesetzt werden, sind Anwendungen von XML. Es gibt sehr viele auf XML basierende oder XML als Metagrammatik oder Syntax benutzende Sprachen. Zu den bekanntesten gehören die TEI (Text Encoding Initiative) für die Kodierung von Texten, XHTML als XML-konforme Variante der Sprache für Webseiten, DocBook für die Erstellung von Dokumentationen, MathML für die Beschreibung mathematischer Formeln oder SVG (Scalable Vector Graphics) für die Beschreibung von Vektorgrafiken.

9.5 | XPath

```
/gedichtsammlung/gedicht/bibliografisch/titel
```

Dies ist ein XPath-Ausdruck. Im Eingangsbeispiel werden damit alle Titel der Gedichtsammlung geliefert. Es ist ein formaler Ausdruck für die Anordnung »gib mir alle Elemente, die diese Bedingung erfüllen: es gibt ein Element `gedichtsammlung`, das ein Kindelement `gedicht` hat, das ein Kindelement `bibliografisch` hat, das ein Kindelement `titel` hat«.

XML beschreibt strukturierte Informationen. Um mit XML etwas zu tun, braucht man zunächst XPath, die Pfadsprache zur Navigation in XML-Dokumenten und zur Adressierung, Selektion, Vorverarbeitung und Rückgabe von verschiedenen Informationen. Weitere XML-Standards benutzen XPath, um in XML-Daten etwa bestimmte Stellen anzusteuern: XSLT als Transformationssprache oder XQuery als Abfragesprache im Zusammenspiel mit XML-Datenbanken. Man kann XPath aber auch für sich nutzen, um z. B. Daten abzufragen und zu analysieren.

XPath-Ausdrücke, manchmal auch Lokalisierungspfade genannt, können sehr komplex werden. Sie bestehen aber zunächst einfach aus **Lokalisierungsschritten**, die mit dem rechtsgeneigten Schrägstrich (*slash* `/`) verkettet werden: Lokalisierungsschritt/Lokalisierungsschritt/Lokalisierungsschritt. Dabei ist zu beachten, dass XPath-Ausdrücke von der Wurzel des Baums oder einer bestimmten Stelle ausgehen können. Die Stelle, an der man sich in einer komplexeren Anwendung gerade befindet, wird **Kontext** genannt. XPath beschreibt also **absolute** oder **relative Pfade**.

Die einzelnen Lokalisierungsschritte bestehen aus bis zu drei Elementen: einem Achsenbezeichner (*Achse*::), einem Knotentest und einem Prädikat. Die **Achse** bezeichnet die Richtung, in der nach einem Knoten gesucht werden soll. Sie wird vor einem doppelten Doppelpunkt angegeben (z. B. `ancestor::`). Es gibt zunächst zwei Grunddimensionen: vertikale Achsen, mit denen im Baum ab- oder aufwärts navigiert wird und horizontale Achsen, mit denen im sequentiell verstandenen Dokument vorwärts oder rückwärts navigiert wird. Häufig benutzte Achsen heißen:

Achse	Kurz	Beschreibung
self	.	Der aktuelle Kontextknoten
child	(Nichts)	Kinder des Kontextknotens
parent	..	Eltern des Kontextknotens
descendant	//	Nachkommen in beliebiger Tiefe des Baumes
ancestor		Vorfahren in beliebiger Höhe des Baumes
following		In der Dokumentreihenfolge nach dem Kontextknoten kommende Knoten
preceding		In der Dokumentreihenfolge vor dem Kontextknoten kommende Knoten
attribute	@	Attributknoten des Kontextknotens

Tab. 5 XPath-Achsen

Der Ausdruck

```
child::gedichtsammlung/descendant::autor/attribute::identifikation
```

ist ein XPath-Ausdruck, der zunächst zu allen name-Elementen in *gedichtsammlung* geht, um das Attribut *identifikation* im Elternelement auszulesen, egal wie das Elternelement heißt. Das Sternchen (*Asterisk*) ist ein Platzhalter (*Wildcard*) für einen beliebigen Elementnamen. In der Regel benutzt man aber eine abgekürzte Schreibweise. Der obige Ausdruck ist äquivalent zu:

```
./gedichtsammlung//autor/@identifikation
```

Prädikate in XPath-Ausdrücken enthalten Bedingungen. Diese werden in eckigen Klammern [] angegeben. Zusätzlich stehen etliche **Funktionen** zur Verfügung, die grundsätzlich die Form *funktionsname()* haben. In den runden Klammern kann der Funktion etwas übergeben werden: Zahlen, Zeichenketten oder auch das Ergebnis von XPath-Ausdrücken. Manche Funktionen erwarten allerdings keine Übergabe. Außerdem kann man mit XPath auch *rechnen*, also mathematische Operationen durchführen.

```
count(//gedicht[position()='1']//strophe)
```

oder kürzer

```
count(//gedicht[1]//strophe)
```

Das heißt auf Deutsch: »Zähle die Strophen im ersten Gedicht«. Oder etwas ausführlicher: Übergib der Funktion *count()* die Ergebnismenge der Navigation zu allen Nachkommen *strophe* des Elements *gedicht*, das die Bedingung erfüllt, dass dieses Elements in seiner Geschwisterschar die erste Position einnimmt. Die Rückgabe lautet für unser Beispiel »4« und ist vom Datentyp »Zahl«. XPath-Ausdrücke und Funktionen können grundsätzlich verschiedene Arten von Rückgaben haben: einzelne Elemente, Element-Sets, Sequenzen (geordnete Reihen von Dingen wie Strings oder Elementen etc.), Zahlen, Zeichenketten oder Wahrheitswerte (*Booleans*).

```
count(//gedicht[1]//strophe) > 3
not(//gedicht//luecke/text())
```

Das sind zwei Ausdrücke, die beide den Wahrheitswert ›true‹ zurückliefern. Gefragt war hier »hat das erste Gedicht mehr als drei Strophen?« und »es gibt doch wohl keine Gedichte, bei denen das Element `luecke` doch Textzeichen enthält?«

Der XPath-Standard 1.0 wurde 1999 vom W3C verabschiedet, mit Version 2.0 sind 2007 viele neue Funktionen und einige neue Konzepte hinzugekommen. Kleinere Änderungen sind bei Version 3.0 hinzugekommen, die 2014 eine W3C *recommendation* wurde. Es empfiehlt sich, in der Praxis mindestens XPath 2.0 zu verwenden, auch wenn manche Technologien oder Programmiersprachen(-Bibliotheken) auf dem Stand von 1.0 stehengeblieben sind.

Es gibt inzwischen über 130 Funktionen in XPath. Zu den häufig gebrauchten gehören z. B.

Funktionsname (Übergabe)	Rückgabe	Beschreibung
<code>position()</code>	Zahl	Position eines Elements in seinem Kontext; abgekürzte Syntax <code>[n]</code>
<code>not (XPath)</code>	Boolean	Kehrt den Wahrheitswert des XPath-Ausdrucks um
<code>count (XPath)</code>	Zahl	Anzahl der Knoten in einer Knotenmenge
<code>contains (string, string)</code>	Boolean	Enthält die erste Zeichenkette (die der Rückgabewert eines XPath-Ausdrucks sein kann) die zweite Zeichenkette?
<code>matches (string, string)</code>	Boolean	Testet, ob der reguläre Ausdruck in der zweiten Zeichenkette auf die erste Zeichenkette passt.
<code>substring (string, number, number?)</code>	String	Extrahiert aus einer Zeichenkette einen Teil ab der zuerst genannten Position, in der Länge der zweiten Zahl.
<code>name ()</code> bzw. <code>local-name ()</code>	String	Name des aktuell angesteuerten Elements oder Attributs
<code>distinct-values ()</code>	Sequenz	Liefert aus einer gegebenen Menge nur die Menge unterschiedlicher Dinge zurück.
<code>string (object)</code>	String	Verwandelt etwas explizit in eine Zeichenkette.
<code>number (object)</code>	Zahl	Verwandelt etwas explizit in eine Zahl.

Tab. 6 XPath Funktionen

XPath ist eine formale Sprache. Man kann, wie wir oben gesehen haben, zwischen normaler (z. B. deutscher) Sprache und XPath hin und her übersetzen, wobei dies zugleich ein Prozess fortschreitender Formalisierung ist:

1. »Wie alt ist das erste Gedicht?« wird formalisiert zu ...
2. »Bilde die Differenz zwischen 2016 und dem bei den bibliografischen Angaben zu findenden Jahr der Quelle«. Dies wiederum bedeutet auf XPath-Pseudocode ...
3. `2016-(Jahr der Quelle des ersten Gedichts)`, oder als etwas präziserer Pseudocode ...
4. `2016-(Jahr der Quelle von //gedicht[1])`, oder als etwas präziserer Pseudocode ...
5. `2016-(//gedicht[1]/bibliografisch/quelle/datum/@normiert)`, ... noch das Jahr extrahieren ...
6. `2016-(//gedicht[1]/bibliografisch/quelle/datum/substring(@normiert,1,4))`, und in eine Zahl verwandeln ...
7. `2016-number(//gedicht[1]/bibliografisch/quelle/datum/substring(@normiert,1,4))`

9.6 | XSLT

Transformation von XML-Dokumenten: XSL (eXtensible Stylesheet Language) ist eine Gruppe von Sprachen zur Transformation von XML-Dokumenten. Häufig wird XSL synonym mit XSLT verwendet, obwohl letzteres formal nur einer von zwei Teilen ist. XSLT ist eine Programmiersprache, mit der ein XML-Dokument in ein anderes Dokument in einem beliebigen textbasierten Format umgewandelt werden kann. Ein **XSLT-Prozessor** verarbeitet ein oder mehrere XML-Dokumente gemäß der Angaben in einem XSLT-Dokument und erzeugt ein oder mehrere Ergebnisdokumente in einem Format, welches vom XSLT-Dokument bestimmt wird (s. Abb. 28). In XSL wird XPath zur Adressierung von Elementen und anderen Inhalten in XML-Dokumenten verwendet.




Abb. 28 Schematische Darstellung einer XSLT-Transformation

Oft sind das Ziel der Umwandlung HTML-Dokumente, also Webseiten. Dadurch können Inhalte eines projektspezifischen Datenmodells, das zur Auszeichnung von Texten oder zur Kodierung von Datenstrukturen verwendet wird, von Webbrowsern dargestellt werden. Die Semantik der originalen XML-Elemente wird dabei durch die Seiten-Strukturbeschreibungen von HTML ersetzt. Man kann mit XSLT aber auch andere Dokumente im XML-Format, reinen Text, Vektorgrafiken (in SVG) oder JSON-Datenobjekte erzeugen. Mit den Komponenten von XSL können also aus einer einzigen XML-Datei unterschiedlichste Formen der Ausgabe erzeugt werden (»Single Source-Prinzip«).

Zu XSL gehört auch **XSL-FO** (eXtensible Styleheet Language, Formatting Objects), eine Sprache zur Erzeugung von abstrakten Beschreibungen von Druckdokumenten – die mit Hilfe von nachgeschalteten XSL-FO-Prozessoren als PDF ausgegeben werden können. Sie wird seit 2012 nicht mehr weiterentwickelt. Der XSLT-Standard befindet sich (Stand 2016) im Übergang von Version 2.0 zu 3.0. Während Version 2.0 eine Menge zusätzlicher Funktionen gebracht hat, ohne die ein professionelles Arbeiten kaum noch möglich ist, gibt es eine ganze Reihe von Technologien (Browser, Programmiersprachen wie PHP in seiner Standardinstallation), die nur die Befehle von XSLT 1.0 unterstützen.

Beispiel 3: Ein XSLT-Stylesheet, das die Strophen jedes Gedichts zählt und danach die Strophen als Absätze ausgibt.

```
<?xml version="1.0" encoding="UTF-8"?>
<xsl:stylesheet xmlns:xsl="http://www.w3.org/1999/XSL/Transform"
version="2.0">
  <xsl:template match="/">
    <h1>Meine Gedichtsammlung</h1>
    <xsl:apply-templates/>
  </xsl:template>
  <xsl:template match="gedicht">
    <xsl:value-of select="position()" />. Gedicht: <xsl:value-of select=
"bibliografisch/titel"/>
    <xsl:apply-templates/>
  </xsl:template>
  <xsl:template match="text">
    Das Gedicht hat <xsl:value-of select="count(strophe)"/> Strophen,
    nämlich:
    <xsl:apply-templates select="strophe"/>
  </xsl:template>
  <xsl:template match="strophe">
    <p><xsl:apply-templates select="vers"/></p>
  </xsl:template>
</xsl:stylesheet>
```

Wie wir sehen, werden die Befehle von XSL selbst in XML ausgedrückt. Nach der XML-Deklaration `<?xml version="1.0"?>` kommt das XSL-Wurzelement `<xsl:stylesheet xmlns:xsl="http://www.w3.org/1999/XSL/Transform">`.

Ein XSLT-Dokument besteht aus Verarbeitungsanweisungen, den sogenannten **Verarbeitungsmustern** oder **Schablonen (Templates, <xsl:template>)**. In der Verarbeitung wird das XML-Dokument durchgegangen und Aktionen werden ausgeführt, sobald eine Schablone auf den aktuellen Inhalt »passt«. Die Schablonen können sich außerdem Informationen von anderen Stellen des XML-Dokuments holen und verarbeiten. Welches Template für welches Element verwendet werden soll, entscheidet sich anhand von XPath-Mustern im Attribut `match` und durch die Position, an der ein Template aufgerufen wird.

```
<xsl:template match="strophe">...</xsl:template>
```

legt also die Regeln für die Verarbeitung aller Elemente mit dem Namen `strophe` fest. Der Parser verarbeitet das XML-Dokument immer von einer dem Wurzelknoten übergeordneten Struktur aus. Ein XSLT-Stylesheet besitzt deshalb in der Regel ein Template, das auf das gesamte Dokument passt, das als sein Wurzelement mit einem einfachen Schrägstrich angesprochen wird:

```
<xsl:template match="/">...</xsl:template>
```

Innerhalb einer Schablone können Elemente konstruiert, Texte geschrieben, andere XSL-Befehle ausgeführt oder weitere templates aufgerufen werden. Um Inhalte aus dem Ausgangsdokument auszulesen und z. B. im Zieldokument auszugeben, kann `<xsl:value-of>` mit einem XPath-Ausdruck im Attribut `select` verwendet werden (im Beispiel 3 wählt `<xsl:value-of select="bibliografisch/titel"/>` den Titel des Gedichts aus) oder man überlässt die weitere Verarbeitung einem anderen Template (z. B. mit `<xsl:apply-templates>`). Auch im letzteren Fall kann man das gewünschte Element des Ausgangsdokuments mit dem Attribut `select` ansprechen (das Beispiel `<xsl:apply-templates select="strophe"/>` lässt nur die Strophen des Gedichts verarbeiten). Wenn es für das aufgerufene Element kein passendes Template gibt, dann wenden die XSL-Prozessoren sogenannten »built-in-Regeln« an und geben automatisch den Inhalt des Elements und aller Unter Elemente aus.

Neben der Deklaration und dem Aufruf von templates (template, apply-templates) sowie dem Auslesen von Inhalten (value-of) werden die folgenden XSL-Elemente besonders häufig eingesetzt:

XSL-Befehl	Aufgabe
<code><xsl:for-each select="XPath"></code>	tue etwas für jedes Element der mit dem XPath-Ausdruck ausgewählten Knotenmenge
<code><xsl:sort select="XPath" datatype="text number" order="ascending descending"/></code>	sortiert eine Knotenmenge. Leeres Element! Unmittelbar nach <code><xsl:for-each></code> oder <code><xsl:apply-templates></code>
<code><xsl:if test="XPath"></code>	führe die folgenden Anweisungen nur aus, wenn der XPath-Ausdruck im Attribut <code>test</code> »true« zurückgibt
<code><xsl:choose></code> <code><xsl:when test="XPath"></code> <code><xsl:otherwise></code>	wählt unter beliebig vielen verschiedenen when-Bedingungen die erste, für die der XPath-Ausdruck im Attribut <code>test</code> »true« zurückgibt und führt sie aus. Sonst otherwise
<code><xsl:variable name="string"></code>	eine Variable mit dem namen im Attribut <code>name</code> ; der Variableninhalt kann innerhalb des Elements oder im Attribut <code>select="XPath"</code> aufgebaut werden. Variablen werden in XPath-Ausdrücken mit einem Dollar-Zeichen eingeleitet (<code>\$string</code>) aufgerufen. Sie können auch komplette Bäume enthalten.

Tab. 7 XSL-Befehle

Es gibt zwei Stile, mit den Befehlen von XSL umzugehen: Der eine bevorzugt die Verwendung von Verarbeitungsmustern in Templates und verwendet zum Aufruf von Inhalten bevorzugt das XSL-Element `<xsl:apply-templates/>` (**Push-Paradigma** – Der Inhalt des Ausgangsdokuments wird beim Durchgehen einfach passenden Schablonen überlassen). Der andere rückt den Gesamtaufbau des Zieldokuments in den Vordergrund und integriert an den jeweils passenden Stellen das XSL-Element `<xsl:value-of>`, um die Inhalte des Ausgangsdokuments abzurufen (**Pull-Paradigma**). Im Push-Paradigma geschriebener Code ist schwieriger zu lesen, aber leichter zu pflegen und letztlich meistens eleganter.

9.7 | X-Technologien im Einsatz

Einfache Erstellung: XML-Dateien lassen sich mit jedem beliebigen Textverarbeitungsprogramm erstellen, das es erlaubt, Texte als Plain Text ohne Formatierungen zu speichern. Einige Plain-Text-Editoren (z. B. »jEdit«, »gEdit«, »notepad++«) bieten auch eine Unterstützung bei der Erfassung von XML durch farbige Hervorhebung des Codes, automatische Ergänzungen und Validierung. Daneben gibt es spezielle **XML-Editoren**, die ein großes Arsenal an zusätzlichen Funktionen bereitstellen, um XML- und verwandte Dokumenttypen (Schemadateien, XSL-Stylesheets, XQuery-Routinen) nicht nur auf verschiedene Weise (im Code, als visuelle Eingabeumgebung) zu schreiben, sondern auch in größeren Projekten zu verwalten, in Datenbanken einzubinden oder Verarbeitungsszenarien zu entwickeln. In den digitalen Geisteswissenschaften ist vor allem das Programm »oXygen« von der Firma SyncRo-Soft verbreitet. Es bietet zu allen Aspekten rund um XML die am weitest gehende Unterstützung. Unter den Open Source-Lösungen bietet »XMLcopy« einige nützliche Funktionalitäten, ist aber bei weitem nicht so mächtig wie oXygen oder andere kommerzielle XML-Editoren (z. B. »XMLSpy«, »XMLMind«, »Stylus Studio«).

XML steht als Technologie nicht für sich alleine, sondern ist Teil einer größeren **Familie von Standards**. Wir hatten gesehen, dass Schemata, XPath und XSLT wichtige zusätzliche Mittel sind, um Daten nicht nur zu strukturieren und zu beschreiben, sondern auch durch Regelwerke zu kontrollieren, in den Daten zu navigieren und sie durch Transformationen weiterzuverarbeiten. Eine Reihe von Standards ist in diesen Kernkomponenten bereits mitgedacht oder können sie erweitern:

- **XML-Infoset** definiert grundlegende Konzepte und Begriffe für XML.
- **XInclude** erlaubt die Einbindung externer XML-Dokumente.
- **XPointer** unterstützt die Referenzierung von bestimmten Teilen von XML-Dokumenten.

Andere Standards decken weitere wichtige oder nützliche Funktionsbereiche ab:

- **XQuery** ist eine Abfragesprache, mit der komplexe, datenbankbasierte Anwendungen entwickelt werden.
- **XForms** beschreibt Eingabeformulare und ihre Funktionalitäten zur Erfassung von Daten auf einer abstrakten Ebene.
- **XProc** beschreibt Verarbeitungsketten für XML-Dokumente (processing pipelines).

Alle Standards aus der X-Familie werden vom World Wide Web Consortium (W3C) betreut. Manche Komponenten werden aktiv weiterentwickelt und enthalten bei neuen Versionen erweiterte Möglichkeiten. Dies ist z. B. bei XPath und XSLT der Fall, deren Funktionsumfang sich im Übergang von 1.0 nach 2.0 und aktuell 3.0 stark erweitert hat. Andere gelten als stabil oder werden nicht weiterentwickelt, weil sie in der Praxis nur von geringerer Bedeutung sind.

Weiterverarbeitung: XML beschreibt Daten, Information und Wissen. Andere Standards aus der X-Familie helfen dabei, mit diesen Daten weiter zu arbeiten. Um aus XML schließlich Publikationen oder Anwendungen zu erstellen, nutzt man verschiedene Softwarekomponenten. Hierzu gehören vor allem XML-Parser bzw. XPath-, XSLT- und XQuery-Prozessoren, bei denen das Programm »Saxon« in der Regel den aktuellen Entwicklungsstand der Standards zuverlässig abbildet. »Saxon« ist

in den großen XML-Editoren per Voreinstellung eingebunden, kann aber auch von anderen Programmiersprachen genutzt werden. Vorsicht ist geboten, wenn man Programmiersprachen oder Softwareumgebungen zur Verarbeitung von XML nutzen will, die den aktuellen Stand der XML-Standards in ihren Programmbibliotheken nicht vollständig abdecken.

Für die Entwicklung von **Anwendungen auf der Basis von XML-Daten** gibt es viele verschiedene Wege und Szenarien, die sich grob in fünf Gruppen unterteilen lassen:

1. **Statistische Ergebnisse generieren:** Mit XSL(T) lassen sich leicht statische Ergebnisse generieren. Dies können Visualisierungen, vorverarbeitete Daten für andere Anwendungen, Druckvorlagen (z. B. mittels XSL-FO in PDF) aber auch komplette Webseiten sein. Für die Mächtigkeit bereits dieses simplen Ansatzes ist zu beachten, dass mit XSLT auch beliebig viele Ausgangsdokumente zusammen zu beliebig vielen Zieldokumenten verarbeitet werden können.
2. **XML-Darstellung im Browser:** Grundsätzlich kann XML auch direkt an Webbrowser ausgeliefert werden. Wenn dabei eine XSLT-Datei mit referenziert ist, können die Browser die Verarbeitung zu Darstellungsformen selbst übernehmen. Dieser Ansatz hat sich bisher allerdings nicht durchgesetzt.
3. **Verarbeitungsketten:** Die Verarbeitung von XML mit XSLT kann noch komplexer und mächtiger gestaltet werden, wenn (z. B. mit XProc) Verarbeitungsketten aufgebaut werden oder XML-Publishing-Systeme wie »Apache Cocoon« oder »Kiln« genutzt werden. Auf XSLT aufbauende Verarbeitungsketten können aber auch genutzt werden, um XML-Daten in Content Management Systeme (CMS) wie Wordpress, Typo3 oder Drupal einzuspeisen.
4. **XML-Datenbanken und Schnittstellen:** Der konsequente XML-Weg zu professionellen Anwendungen verläuft heute oft über native XML-Datenbanken wie eXist oder BaseX. Damit werden dann nicht nur die Daten verwaltet, sondern häufig auch über XQuery-Abfragen komplexe Applikationen aufgebaut. In diesem Szenario kann man ganz in der Welt der aufeinander abgestimmten X-Technologien bleiben. Es ist aber auch möglich, mit XML, XML-Datenbanken und XQuery die Daten vorverarbeitet an Schnittstellen (wie z. B. im REST-Paradigma) zu platzieren und darauf eine weitere Programmierschicht (z. B. in PHP oder JavaScript) aufzusetzen, die die eigentliche Präsentation steuert.
5. **XML-Verarbeitung mit anderen Programmiersprachen:** XML kann schließlich auch in anderen Umgebungen eingesetzt oder mit anderen Programmiersprachen verarbeitet werden. Dies hat seine Reize in der Mächtigkeit, Ausgereiftheit und weiten Verbreitung von gängigen Datenbanksystemen wie MySQL oder PostgreSQL, von modernen Datenmodellen wie JSON oder Programmiersprachen wie PHP, Python, Ruby oder Java. Es kann aber seine Tücken haben, wenn damit das Potential von XML als komplexer Datenstruktur oder die Möglichkeiten aktueller Verarbeitungsstandards (wie XPath 2.0/3.0, XSLT 2.0/3.0) nicht ausgeschöpft werden.

Literatur

Dubinko, Micah: *XForms essentials*. Sebastopol 2003.

Kay, Michael: *XSLT 2.0 and XPath 2.0 Programmer's Reference*. Indianapolis ⁴2011. (Die Referenz.)

Krüger, Manfred: *XSL-FO verstehen und anwenden. XML-Verarbeitung für PDF und Druck*. Heidelberg 2006.

Lehner, Wolfgang/Schöning, Harald: *XQuery: Grundlagen und fortgeschrittene Methoden*. Heidelberg 2004.

Siegel, Erik/Retter, Adam: *eXist: A NoSQL Document Database and Application Platform*. Sebastopol 2015.

Vonhoeven, Helmut: *Handbuch: Einstieg in XML: Grundlagen, Praxis, Referenz*. Bonn ⁸2015. (Das beste deutschsprachige Einsteiger-Handbuch, auch wenn es dem datenzentrierten Blick auf XML verpflichtet ist und die dokumentorientierten Aspekte zu kurz kommen.)

Das Kapitel hat wesentlich von der Unterstützung durch die Mitglieder des IDE, insbesondere Martina Scholger und Ulrike Henny, profitiert.

Georg Vogeler und Patrick Sahle

10 Netzwerke

Das Internet, Verwandtschaften, Handelswege, Zitate in wissenschaftlichen Texten und vieles andere haben eines gemeinsam: Es handelt sich um **Netzwerke**. Dieser Blick scheint heute geradezu selbstverständlich, aber es hat einige Zeit gedauert, bis das Gemeinsame an diesen doch sehr unterschiedlichen Phänomenen gesehen worden ist. In den letzten fünfzig Jahren ist die Beschreibung und Analyse von Netzwerken sowie die Verwendung von Netzwerken zur Modellierung von Phänomenen der verschiedensten Art ein Forschungsfeld, an dem Mathematiker, Informatiker, Visualisierungsspezialisten und Fachwissenschaftler vieler anderer Disziplinen mitarbeiten. Das Konzept des Netzwerks stellt dabei ein Modell bereit, mit dem man unter einer gemeinsamen Perspektive beschreiben und analysieren kann, was die sehr unterschiedlichen Phänomene in einer relationalen Perspektive gemeinsam haben.

Einige Ergebnisse sind als Schlagworte in die populäre Kultur eingedrungen, wie etwa die berühmten *six degrees of separation*, die auf die überraschend kurzen Verbindungen in sogar sehr großen sozialen Netzen verweisen (s. Kap. 10.4). Die Netzwerkanalyse ist eines der zentralen Verfahren der Digital Humanities, und wie auch bei anderen Techniken, z. B. der relationalen Datenbank oder XML, gibt es eine logisch-mathematische Grundlage, die **Graphentheorie**. Denn erst durch die Verbindung von Konzepten zur Beschreibung von sozialer Gruppen mit den mathematischen Begriffen der Graphentheorie sowie der Entwicklung von effizienten Algorithmen zur Bearbeitung typischer Probleme und den Innovationen bei der Visualisierung von Netzwerken ist das leistungsfähige Instrumentarium der Netzwerkanalyse entstanden. Diese Fülle an Konzepten, Gedanken und Verfahren kann hier nur angedeutet werden und sollte bei Bedarf in der einschlägigen Fachliteratur weiter vertieft werden (vgl. Krishcke/Röpcke 2015; Newman 2010; Wasserman/Faust 1994). Im ersten Abschnitt werden Grundlagen der Graphentheorie dargestellt. Im zweiten Abschnitt werden einige wichtige Maße diskutiert, mit denen man zentrale Knoten von Netzwerken identifizieren kann. Dann folgt die Darstellung eines Algorithmus, mit dem man den kürzesten Weg in einem Graphen finden kann. Der letzte Abschnitt stellt ausgewählte Anwendungen der Netzwerkanalyse vor.

10.1 | Grundlagen

Die beiden grundlegenden Bausteine der Graphentheorie sind **Knoten** und **Kanten**. Ein Graph besteht aus nichts anderem als aus Knoten und Kanten die einige oder alle Knoten verbinden, wobei es auch isolierte Knoten geben kann, die nicht mit anderen verbunden sind. Abbildung 29 zeigt einen *einfachen* Graphen. Graphen dieser Art kann man gut verwenden, um reziproke Relationen zu repräsentieren, z. B. Familienbeziehungen. Einen Graphen dieser Art könnten wir sehr gut dadurch repräsentieren, dass wir einfach die Knotenpaare notieren, die durch Kanten verbunden sind, z. B. beschreibt das Folgende den Graphen in Abbildung 29: $\{\{1, 2\}, \{2, 3\}, \{2, 5\}, \{3, 4\}, \{3, 5\}, \{5, 6\}, \{6, 7\}, \{7, 2\}\}$. Die äußeren geschweiften Klammern besagen, dass es sich um eine Menge handelt. Jedes der acht Elemente ist wiederum eine Menge mit zwei Elementen. Zwei Knoten, die benachbart sind, also durch eine Kante verbunden sind, nennt man *adjacent*. Wir werden weiter unten eine Notationsweise




Abb. 29 Ein einfaches Netzwerk mit 7 Knoten und 8 Kanten. Die Länge der Kanten hat keine Bedeutung und verdankt sich nur der gewählten Visualisierung.

für Graphen, die **Adjazenzmatrix**, kennenlernen, was also nicht mehr besagt, als dass die Matrix festhält, welche Knoten benachbart sind.

Es ist wichtig, sich klar zu machen, dass Graphen ganz abstrakte, also merkmalsarme Strukturen sind. Viele Eigenschaften der Visualisierung von Graphen, z. B. die Größe der Knoten oder die Länge und Dicke der Kanten sind für die abstrakte Informationsstruktur ohne Bedeutung. Daraus ergibt sich die Freiheit, diese Elemente in Visualisierungen frei mit Bedeutungen zu versehen.

Für viele Zwecke ist ein einfacher Graph allerdings nicht ausreichend. Eine wichtige Möglichkeit, einem Graphen mehr Information hinzuzufügen, besteht darin, den Kanten eine Richtung zu geben: So entstehen *gerichtete* Graphen (Abb. 30a), die auch **Digraphen** (Abkürzung von *directed graph*) genannt werden. In einem gerichteten Graphen enthält jede Kante eine Richtungsinformation. Wenn wir einen solchen Graphen notieren wollen, dann können wir immer noch die Menge aller Knotenpaare nehmen, die durch eine Kante verbunden sind, aber diesmal ist es wichtig, in welcher Reihenfolge die Knoten notiert werden: Mit $\{(1, 3), (1, 2), (2, 3)\}$ beschreiben wir den Graphen in Abbildung 30a. Diesmal haben wir eine Menge mit drei Elementen vor uns. Jedes Element dieser Menge ist ein **geordnetes Paar**, das auch 2-Tupel genannt wird, also z. B. $(1, 3)$.




Abb. 30 a) ein gerichteter Graph, b) ein gerichteter Multigraph mit einer Schleife am Knoten 4

Sind mehrere Kanten zwischen denselben Knoten zugelassen, haben wir einen **Multigraphen** vor uns (Abb. 30b). In Multigraphen und anderen nicht-einfachen Graphen können Schleifen vorkommen, d. h. eine Kante verbindet einen Knoten mit sich selbst, z. B. $(4, 4)$.

Diese Kategorisierungen der Graphen könnten auf den ersten Blick wie unnötige Pedanterie wirken, aber tatsächlich handelt es sich um eine präzise Beschreibung der Graphen als ganz abstrakte Strukturen. Das wird noch deutlicher, wenn wir einen Blick auf die mathematische Definition werfen:

Formale Definition eines Graphen

Ein Graph G ist ein Paar von Mengen: $G = (V, E)$. V ist die Menge der Knoten des Graphen G und E die Menge der Kanten des Graphen.

Die Kürzel V und E haben sich übrigens wegen der englischen Bezeichnungen eingebürgert: *vertices* und *edges*. Eine Kante verbindet zwei Knoten, zumeist unterschiedliche, aber es kann auch derselbe sein. Jeder weitere Begriff, also ›gerichtet‹, ›gewichtet‹ usw., führt genau eine weitere Eigenschaft in diese Beschreibung von Graphen ein: Gerichtete Graphen haben Kanten mit Richtungen, gewichtete Graphen weisen Kanten mit Gewichten auf usw. Ein Graph kann somit durch eine Folge von solchen Attributen genau beschrieben werden. Ein einfacher Graph z. B. wird unter anderem dadurch beschrieben, dass seine Kanten eine Menge bilden, also das gleiche Element nicht zweimal vorkommen kann, womit Multigraphen ausgeschlossen sind. Außerdem wird jede Kante als ungeordnetes Paar von Knoten beschrieben; damit sind gerichtete Kanten ausgeschlossen. Und es darf sich nicht um den gleichen Knoten handeln, damit werden Schleifen ausgeschlossen.

Häufig interessiert man sich dafür, wie viele Verbindungen ein Knoten in einem Graphen hat. Der Knoten 2 des Graphen, den Abbildung 29 repräsentiert, hat vier Verbindungen zu anderen Knoten. Dies wird der **Grad** des Knotens genannt, d. h. Knoten 2 hat den Grad 4 oder kurz: $d(2) = 4$ (›d‹ steht für ›degree‹). Im Fall von gerichteten Graphen unterscheiden wir die Menge der **ausgehenden** Verbindungen von der Menge der **eingehenden**. In Abbildung 30a haben wir für den Knoten eine ausgehende Verbindung und eine eingehende oder kurz: $d^+(2) = 1$ und $d^-(2) = 1$.

Mit dem Begriff des Grads können wir Graphen schon ganz gut beschreiben, indem wir den kleinsten, kurz $\delta(G)$, den größten, $\Delta(G)$, und den durchschnittlichen Grad, $d(G)$, angeben. $d(G)$ wird berechnet, indem man die Grade aller Knoten summiert und dann durch die Anzahl der Knoten teilt. Für den Graphen, der in Abbildung 29. dargestellt wird, betragen $\delta(G) = 1$ (da die Knoten 1 und 4 nur den Grad 1 haben) und $\Delta(G) = 4$ (da der Knoten 2 mit Grad 4 die höchste Anzahl an Verbindungen aufweist). $d(G) = 1 + 4 + 3 + 1 + 3 + 2 + 2 = 16 / 7 \approx 2,3$ (die Summe aller Grade beträgt 16, geteilt durch 7 Knoten).

Ein häufig genutztes Verfahren, um einem Graphen weitere Informationen hinzuzufügen, besteht darin, den Kanten **Gewichte** hinzuzufügen. Damit ist gemeint, dass jeder Kante eine Zahl zugeordnet wird. Abbildung 31 zeigt ein Netzwerk mit gewichteten Kanten, so hat z. B. die Kante (1, 5) das Gewicht 2. Dadurch können wir nun schon recht komplexe Sachverhalte mit Graphen modellieren, z. B. ein **Briefnetzwerk**: Jeder Knoten repräsentiert einen Briefautor bzw. -verfasser und jede gerichtete Kante Briefe von einem Verfasser an einen Empfänger; die Anzahl der geschriebenen Briefe kann dann als Gewicht der Kante wiedergegeben werden (s. Abb. 31).




Abb. 31 Ein gerichteter Graph mit Gewichten. Er kann etwa ein Briefnetzwerk repräsentieren, wobei die Gewichte die Anzahl der verschickten Briefe repräsentieren.

Im Fall von gewichteten Graphen wird der Grad eines Knotens anders berechnet. Man zählt nicht einfach die Verbindungen, vielmehr werden nun die Gewichte der Kanten addiert. So ist $d^+(1) = 7$, weil der Knoten 1 drei ausgehende Kanten mit den Gewichten $1 + 2 + 4$ aufweist.

Wenn wir Graphen betrachten, dann stellt sich oft die Frage, wie man von einem bestimmten Knoten zu einem anderen gelangt. Wenn wir uns etwa für einen solchen ›Weg‹ oder ›Pfad‹ zwischen dem Knoten 1 und dem Knoten 4 in Abbildung 29 interessieren, dann können wir diesen als Folge von Knoten – Kante – Knoten – Kante – Knoten beschreiben, z. B. $1, \{1, 2\}, 2, \{2, 3\}, 3, \{3, 4\}, 4$. Oder kürzer in der Form: $1, 2, 3, 4$, d. h. nur durch Nennung der durch Kanten verbundenen Knoten. Aber auch $1, 2, 7, 6, 5, 3, 4$ wäre ein Pfad, der die Knoten 1 und 4 verbindet. Tatsächlich ist die Ermittlung des kürzesten Pfads in komplexen Netzwerken eine interessante Aufgabe, von deren effizienter Lösung viele Autofahrer bei der Verwendung von **Navigations-systemen** abhängen (s. in diesem Kapitel Abschnitt 10.3). Die Definition von ›Pfad‹ schließt aus, dass Knoten zweimal in dem Pfad auftauchen – mit einer Ausnahme: Der Anfangs- und der Endknoten können identisch sein. Dann haben wir einen **Zyklus** vor uns. In gerichteten Graphen kann ein Pfad nur in Richtung der Kanten verlaufen. Die Länge eines Pfads wird nach der Anzahl der Kanten berechnet; handelt es sich um einen gewichteten Graphen, dann werden die Gewichte der Kanten summiert. Es ist für viele Zwecke nützlich, sich klar zu machen, dass Pfade selbst wiederum Graphen definieren und diese Teilgraphen von größeren Graphen sind.

In den Graphen, über die wir bislang gesprochen haben, gab es keinen Unterschied zwischen den Knoten. Verwendet man solche Graphen zur Modellierung, dann repräsentieren die Knoten auch alle die gleiche Klasse von **Entitäten**, z. B. Menschen, die Briefe schreiben und lesen, oder Computer oder Städte usw. Will man aber etwa modellieren, welche Salons Künstler um 1800 in Berlin besucht haben, dann sprechen wir über zwei Klassen von Entitäten: die Künstler und die Salons. Für so etwas kann man **bipartite Graphen** verwenden. Sie zeichnen sich dadurch aus, dass wir zwei Mengen von Knoten haben und die Kanten nur Knoten der einen Menge mit Knoten der anderen Menge verbinden (Abb. 32).

In der Graphentheorie werden viele unterschiedliche Formen und Aspekte von Graphen diskutiert. Wir wollen uns hier auf einen Aspekt beschränken, nämlich die Möglichkeit, die Baumstrukturen, die im Kapitel über XML vorgestellt wurden (s. Kap. 9), als Graphen zu beschreiben. Dazu müssen wir erst einige Begriffe einführen. Beginnen wir mit dem zyklischen bzw. azyklischen Graphen. Oben wurde




Abb. 32 Ein bipartiter Graph mit zwei Mengen von Knoten. Die Kanten verbinden nur Knoten aus unterschiedlichen Mengen.

bereits erwähnt, dass ein Zyklus ein Pfad ist, in dem Anfangs- und Endknoten identisch sind. Ein zyklischer Graph ist demnach ein Graph, der einen oder mehrere Zyklen aufweist, z. B. in Abb. 33a) der Pfad 2, 3, 4, 2. Ein **azyklischer Graph** zeichnet sich dagegen dadurch aus, dass er keinen Zyklus enthält, z. B. Abb. 33b).

Wenn der azyklische Graph zusammenhängend ist, d. h. wenn alle Knoten miteinander verbunden sind, dann handelt es sich um einen **Baum**. Aber der Graph in Abbildung 33b. zeichnet sich durch eine zusätzliche Eigenschaft aus: Er hat eine Wurzel, den Knoten 1. Aber auch ein **Wurzelbaum** ist noch zu wenig, um das Baummodell von XML zu erfassen. XML dient ja bekanntlich vor allem der Auszeichnung von Texten, es ist also keineswegs gleichgültig, wie man die Knoten des Baums unter der Wurzel anordnet, vielmehr muss die Reihenfolge der Kanten bei jedem Knoten erhalten bleiben. Und die Beziehung zwischen den Knoten ist nicht reziprok; ein benachbarter Knoten, der näher an der Wurzel ist (z. B. 2 in Abb. 33c), ist ein Eltern-Knoten und der andere, z. B. 3, ein Kindknoten. Insgesamt kann man das, was in XML recht summarisch als Baum bezeichnet wird, im Rahmen der Graphentheorie als geordneten, azyklischen Graph mit einer Wurzel beschreiben (wenn ein Graph eine Wurzel hat, dann weisen alle Kanten weg von diesem Knoten, d. h. ein solcher Graph ist immer gerichtet).




Abb. 33 a) ein zyklischer Graph, b) ein azyklischer, ungerichteter Graph, c) ein azyklischer Graph mit Wurzel

Dieser Abschnitt hat mit der Erklärung von Begriffen wie Knoten, Kante, Grad, gerichteten, gewichteten, azyklischen und bipartiten Graphen nur einige basale Konzepte der Graphentheorie ansprechen können. Wir werden im Folgenden aber sehen, dass man auf dieser Grundlage schon einige sehr interessante Modellierungen und Analysen vornehmen kann und uns dabei zumeist auf einfache Graphen beschränken, also ungerichtete, ungewichtete Graphen ohne Schleifen, die keine Multigraphen sind.

10.2 | Rechnen mit Graphen

Bislang haben wir Graphen visualisiert und als Mengen von Mengen bzw. Mengen von **Tupeln** beschrieben. Letzteres ist zwar präzise, aber keine gute Repräsentation, wenn man rechnen möchte. Dafür gibt es eine Reihe von Formaten, von denen wir uns hier nur die sehr beliebte und oben schon angekündigte **Adjazenzmatrix** anschauen werden, die oft auch als Eingabeformat verwendet wird. Zur Erinnerung: Eine **Matrix** ist ein rechteckiges Gebilde aus Zahlen mit einer bestimmten Zahl von Spalten und Reihen. Für die Repräsentation von Netzwerken verwendet man quadratische Matrizen, deren Zeilen und Spalten für die Knoten stehen. In der folgenden

Abbildung wird außerdem bei jeder Zeile und jeder Spalte angegeben, welche Knoten gemeint sind. Das gehört nicht zur Matrix. Da die Knoten in diesem Graphen nicht mit sich selbst verbunden sind (sonst gäbe es Schleifen), ergibt sich eine Diagonale von Nullen.




Abb. 34 Ein einfacher Graph und seine Repräsentation in Form einer Matrix mit zusätzlichen Zeilen- und Spaltenangaben

Die Matrixdarstellung lässt sich leicht für andere Formen von Graphen anpassen. So werden gerichtete Graphen repräsentiert, indem die Zeile den Ausgangsknoten und die Spalte den Endknoten der gerichteten Kante anzeigen. Die so entstehende Matrix ist dann offensichtlich nicht mehr symmetrisch um die Diagonale von links oben nach rechts unten wie es die der einfachen Graphen ist. Und im Fall von gewichteten Graphen steht statt der 1 nun das Gewicht der Kante in der Matrix.

In vielen Netzwerken gibt es Unterschiede zwischen den Knoten. Bei einem sozialen Netzwerk wie einem Briefnetzwerk stehen häufig einige Akteure eher im Mittelpunkt, weil sie viele Briefe erhalten und auch schreiben, während die anderen deutlich weniger kommunizieren. Wenn man Datenleitungen und Knotenpunkte analysiert, dann gibt es sehr wichtige Knotenpunkte, z. B. die Endpunkte von Atlantikkabeln, und viele weniger zentrale. In der Netzwerktheorie bemüht man sich schon lange, **Zentralität** genauer zu definieren und zu analysieren. Ein wichtiges Ergebnis ist die Einsicht, dass Zentralität ein vielschichtiges Phänomen ist und kein einzelnes Maß dem gerecht wird. Ist derjenige wichtiger, der besonders viel Kontakte zu anderen hat, oder derjenige, der allein zwischen zwei großen Netzen vermittelt, die sonst nichts voneinander wüssten? Oder derjenige, der sehr kurze Verbindungen zu jedem anderen im Netz hat? Oder derjenige, der besonders viele andere zentrale Kontakte hat? Man muss sich also klarmachen, welche Form von Zentralität eigentlich von Interesse ist und das dazu passende Maß auswählen. Wir wollen uns im Folgenden einige solcher Maße sowohl für die Beschreibung einzelner Knoten als auch für die Be-




Abb. 35 Ein einfaches Netzwerk mit 9 Knoten

schreibung ganzer Netzwerke genauer anschauen und dabei auch die Mathematik zur Berechnung in den Blick nehmen.

Das einfachste Maß für einen einzelnen Knoten haben wir oben bereits kennengelernt: den Grad eines Knotens. Diesem Maß liegt die naheliegende Intuition zugrunde, dass ein Knoten in einem Netzwerk wichtiger ist, wenn er besonders viele direkte Verbindungen zu anderen Knoten hat. Der Graph in Abbildung 35 hat 9 Knoten. Der Knoten 1 hat den Grad 2 usw. Aber offensichtlich sind solche Zahlen kaum zu interpretieren; wenn man nicht die Gesamtzahl der Knoten im Netzwerk kennt, weiß man nicht, ob etwa Grad 8 viel, wenig oder durchschnittlich ist. Deshalb wird dieses **Zentralitätsmaß** (*degree centrality*) normalisiert. Üblicherweise geschieht dies, indem man die Summe – hier der Grade – durch die Anzahl der Elemente – hier die Anzahl der Knoten (n) – teilt. Dadurch liegen die Werte des Maßes zwischen 0 und 1. Da aber ein Knoten, der mit allen anderen verbunden ist, nicht mit sich selbst verbunden ist (wenn der Graph keine Schleifen zulässt), teilt man nur durch $n - 1$. Also:

$$C_{\text{degree}} = \frac{d(u)}{n-1}$$

Wobei gilt: u ist der analysierte Knoten
 $d(u)$ ist der Grad des Knoten u
 n ist die Anzahl der Knoten im Netzwerk

Hier die C_{degree} für alle Knoten des Netzwerks in Abb. 35: (1) 0.25, (2) 0.125, (3) 0.125, (4) 0.125, (5) 0.625, (6) 0.5, (7) 0.375, (8) 0.25, (9) 0.375. Unter dieser Perspektive ist also der Knoten 5 der wichtigste, während die Knoten 2, 3, und 4 randständig sind. Ein **Sternnetzwerk** weist idealtypisch einen Knoten in der Mitte auf, der mit allen anderen Knoten verbunden ist, die wiederum nur mit diesem zentralen Knoten verbunden sind und nicht untereinander. In einem solchen Sternnetzwerk hat der zentrale Knoten ein *degree centrality* von 1 und alle anderen $1 / (n - 1)$.

Ein weiteres Maß, die Nähe (*closeness centrality*), gibt an, wie kurz der Abstand eines Knotens zu allen anderen Knoten ist. Unter dieser Perspektive ist der Knoten zentral, der insgesamt am wenigsten weit von allen anderen Knoten entfernt ist. Die Berechnung der Nähe ist schon etwas komplizierter. Wie wir oben gesehen haben, gibt es zwischen zwei Knoten oft mehrere Pfade. Für uns ist aber nur die Länge des kürzesten Pfads von Interesse. Schauen wir uns das für den Knoten 1 an. Seine Abstände zu den anderen Knoten betragen (in Klammern der Name des Zielknotens): (2) 2, (3) 2, (4) 2, (5) 1, (6) 1, (7) 2, (8) 3, (9) 2. Wenn wir davon die Summe bilden, dann ist das Ergebnis, 15, noch wenig aussagekräftig, da offensichtlich die Anzahl der Knoten eine Rolle spielt. Wir müssen unsere Summe normalisieren, indem wir sie durch die Anzahl der Knoten teilen. Aber da der Abstand eines Knoten zu sich selbst immer 0 ist, interessieren uns wieder nicht alle Knoten, sondern alle minus eins, in unserem Beispiel also $9 - 1 = 8$. Wir teilen also die Summe aller Knotendistanzen durch die Anzahl der Knoten minus eins: $15 / 8$. Damit wäre man eigentlich fertig, aber so hat das Maß ein unglückliches Format: Im Fall von *degree centrality* ist es klar, dass ein höherer Wert bedeutet, dass ein Knoten wichtiger ist. Hier ist nun das Gegenteil der Fall: Der Wert wird immer größer, je größer der Abstand des untersuchten Knotens von allen anderen ist. Um auch hier zu erreichen, dass ein zentraler Knoten einen hö-

heren Wert hat als ein weniger zentraler, wird in der Literatur zumeist der umgekehrte Wert verwendet:

$$C_{\text{close}}(u) = \frac{n-1}{\sum_{v:v \neq u} \delta(u, v)}$$

Wobei gilt: u ist der analysierte Knoten
 v ist jeweils ein Knoten des Netzwerks, der nicht identisch mit u ist
 δ ist der kürzeste Pfad zwischen u und v
 n ist die Anzahl aller Knoten im Netzwerk

Closeness centrality für den Knoten 1 beträgt demnach $8 / 15 \approx 0,53$. Hier sind die Werte für alle Knoten aus Abb. 35: (1) 0.53, (2) 0.42, (3) 0.42, (4) 0.42, (5) 0.67, (6) 0.67, (7) 0.5, (8) 0.36, (9) 0.5. Unter dieser Perspektive sind die Knoten 5 und Knoten 6 zentral, während der Knoten 8 besonders randständig ist.

Das sind nur zwei unter zahlreichen Zentralitätsmaßen. Jedes hebt einen anderen Aspekt hervor. Die *betweenness centrality* z. B. macht die Intuition zum Ausgangspunkt, dass die Wichtigkeit eines Knotens auch daran bemessen werden kann, wieviele aller kürzesten Pfade über diesen Knoten laufen. Wenn man etwa einen Knoten hat, der selbst einen niedrigen Grad aufweist, aber zwei größere Netzwerke verbindet, dann werden die oben vorgestellten Maße diesen Knoten im Vergleich zur *betweenness centrality* deutlich geringer einschätzen. Zuletzt sei ein im heutigen Alltag recht häufig verwendetes Maß für gerichtete Graphen genannt, das die Intuition abbildet, dass ein Knoten, der der Endknoten vieler Kanten ist, die von wichtigen Knoten ausgehen, selbst wichtig sein muss. Das ist die Grundlage für das *PageRank*-Maß, das Google – inzwischen neben vielen anderen Informationen – dazu verwendet, Ergebnisse bei einer Websuche anzuordnen. Die Websites sind hierbei die Knoten und die Hyperlinks die gerichteten Kanten.

10.3 | Den kürzesten Weg finden

Wie wir gesehen haben, brauchen wir bei der Analyse von Graphen häufiger den kürzesten Weg zwischen zwei Knoten (u, v). Das ist tatsächlich nur ein Sonderfall des allgemeineren Problems, die kürzesten Wege von u zu allen anderen Knoten des Netzwerks zu ermitteln. Dafür wird ein Algorithmus eingesetzt, der **Breitensuche** (*breadth-first search*) genannt wird, weil zuerst alle Knoten identifiziert werden, die über eine direkte Kante mit dem Startknoten verbunden sind, dann alle Knoten, die über zwei Kantenschritte mit dem Startknoten verbunden sind usw. Wir verwenden dafür eine Datenstruktur, die wie eine Schlange an einem Schalter funktioniert: Wer sich zuerst anstellt, kommt auch zuerst dran. In diese *Queue* legen wir die Knoten ab (*enqueue*), die wir uns anschauen müssen. Von dort entnehmen wir sie dann später (*dequeue*). Der folgende Pseudo-Code beschreibt die Vorgehensweise. Zeilen, die mit ›#‹ beginnen, sind ergänzende Kommentare (Pseudo-Code nach dem Stichwort ›breadth-first search‹ in der englischsprachigen Wikipedia).

```

def breitensuche(Graph G, Startknoten start):

    # zuerst initialisieren wir alle Knoten mit Ausgangswerten für
    # die Attribute 'distanz' und 'eltern'. Das -1 informiert darüber, dass
    # diese Knoten noch nicht besucht wurden.
    for each knoten u in G:
        u.distanz = -1
        u.eltern = None

    # dann erzeugen wir eine leere Queue
    Q = Queue()

    # Am Anfang wird das Attribut 'distanz' für den Startknoten auf 0 gesetzt,
    # und der Startknoten in die Queue aufgenommen.
    start.distanz = 0
    Q.enqueue(start)

    # hier beginnt die Hauptschleife, die solange abgearbeitet wird,
    # wie Knoten in der Queue vorhanden sind.
    while Q is not empty:

        # ein Knoten wird aus der Queue genommen und
        # damit zu unsem aktuellen Knoten
        u_aktuell = Q.dequeue()

        # für jeden Nachbarn des aktuellen Knotens wird Folgendes gemacht
        for each Knoten u der ein Nachbar von u_aktuell:

            # wenn für den Knoten noch nicht sein Abstand vom Startknoten
            # eingetragen ist, d.h. wenn der Knoten noch nicht besucht wurde
            if u.distanz == -1:

                # dann wird der Abstand vom Startknoten eingetragen.
                # Er beträgt den Abstand des aktuellen Knotens vom
                # Startknoten +1
                u.distanz = u_aktuell.distanz + 1

                # es wird festgehalten, dass der Elternknoten der aktuelle Knoten
                # ist
                u.eltern = u_aktuell
                # Der Nachbarknoten u wird in die Schlange gestellt.
                Q.enqueue(u)

    # gibt als Ergebnis einen Graphen zurück, in dem für alle Knoten der
    # Abstand zum Startknoten eingetragen ist.
    return G

```

Wenn wir diesem Algorithmus den Graphen aus Abbildung 35 und als Startknoten den Knoten 5 übergeben, dann werden nach der Initialisierung der Knoten und der Queue folgende Schritte durchlaufen:

Der Startknoten 5 erhält den Distanzwert 0 und wird in die Queue eingestellt. Dann beginnt die Schleife: der Startknoten wird gleich wieder aus der Queue genommen. Die Nachbarknoten zu 5, also 1, 4, 2, 3, 6 werden behandelt: Zuerst wird bei jedem als Distanzwert $0 + 1$ festgehalten, dann wird als Eltern der Startknoten notiert. Zuletzt werden sie in die Queue eingestellt. In der Queue stehen nun die Knoten [1, 4, 2, 3, 6]. Nächster Durchlauf der Schleife: Da die Queue nicht leer ist, wird nun der Knoten 1 herausgenommen. Seine Nachbarn sind die Knoten 5 und 6. Da aber für 5 die Distanz 0 ist und für 6 die Distanz 1, ist die Bedingung `if k.distanz == -1` falsch. Auch bei der Bearbeitung der Knoten 4, 2, und 3 geschieht nichts. Erst wenn der letzte Knoten in der Queue, Nr. 6, herausgenommen wird, ändert sich das, da zwei der vier benachbarten Knoten, nämlich 7 und 9, noch nicht besucht worden sind. Für sie wird nun 6 als Elternknoten und die Distanz von $6 (= 1) + 1$ eingetragen; außerdem werden sie der Queue übergeben, die nun so aussieht: [7, 9]. Nächste Schleife: Nun wird der Knoten 7 aus der Queue genommen. Unter seinen Nachbarn ist der unbesuchte Knoten 8, für den die Distanz von $7 (= 2) + 1$ eingetragen wird, und 7 als Elternknoten. Queue: [9, 8]. Die letzten beiden Durchläufe der Schleife holen die Knoten 9 und 8 aus der Queue, aber keiner von ihnen hat einen unbesuchten Nachbarn. Dann ist die Queue leer und die Schleife wird beendet.

Für die Breitensuche sieht der Graph mit dem Startknoten 5 so aus:




Abb. 36 Abstände zu den anderen Knoten – als kürzeste Pfade – für den Startknoten 5

Algorithmen zur Lösung oder zur effizienteren Bearbeitung von graphenbezogenen Aufgaben füllen inzwischen umfangreiche Bände und sind eine wichtige Grundlage für die Analyse gerade der sehr großen Datenmengen, die heute z. B. bei sozialen Netzwerken vorliegen. Die Aufgaben reichen von der Berechnung von verschiedenen Maßen für Graphen, Pfaden in Graphen – etwa um eine bestimmte Menge von Knoten auf dem kürzesten Weg genau einmal zu durchlaufen –, der Identifikation von Teilgraphen eines Graphen bis hin zur Erzeugung von künstlichen Zufallsnetzwerken, die als Vergleich zu realen herangezogen werden können, um deren Gemeinsamkeiten und Differenzen zu studieren. Bibliotheken zur Analyse und Visualisierung von Graphen gibt es für die meisten bekannten Programmiersprachen, so dass man normalerweise die Algorithmen nicht selbst implementieren muss, sondern robuste Implementierungen verwenden kann.

10.4 | Angewandte Netzwerkanalyse

Netzwerkanalysen folgen dem gleichen – hier idealtypisch gezeichneten und stark verkürzten – Grundschemata: Zuerst wird ein fachwissenschaftlich interessantes Phänomen in den Begriffen der Netzwerktheorie modelliert: Knoten und Kanten werden ebenso definiert wie weitere Eigenschaften des Netzwerks, z. B. Gerichtetheit oder Gewichte. Im zweiten Schritt werden die Daten erhoben. Dieser Schritt ist üblicherweise, wenn man nicht gerade auf vorgefertigte Datensammlungen zurückgreifen kann, der bei weitem aufwendigste einer Netzwerk-Studie. Dann folgt die Datenanalyse und -auswertung und die Darstellung der Ergebnisse. Die Netzwerkanalyse hat inzwischen eine Reihe von interessanten und auch verblüffenden Ergebnissen vorgelegt, in populärer Darstellung z. B. (Barabási 2014) oder als Konzept eines neuen Forschungsfeldes (Newman 2010). Naheliegenderweise hat die Netzwerkanalyse in der Soziologie und Sozialpsychologie sehr viel mehr als in den Geisteswissenschaften im engeren Sinne gewirkt, aber gerade Fächer wie die Geschichtswissenschaften und die Philologien haben in den letzten Jahren die Netzwerkanalyse für sich entdeckt. Vier Beispiele sollen wenigstens einen kleinen Einblick in Arbeitsweise und Ergebnisse verschaffen.

Milgram-Experiment: Bekannt wurde eine Studie des Sozialpsychologen Milgram aus dem Jahre 1967 über kleine Welten (Milgram 1967). Milgrams Arbeitsgruppe suchte willkürlich 160 Erwachsene in Omaha, Nebraska aus und schickte ihnen einen Umschlag mit der Bitte, diesen als Teil eines sozialpsychologischen Experiments an einen Börsenmakler in Boston zu versenden – aber nur, wenn sie ihn persönlich kennen, ansonsten sollten sie den Umschlag an eine Person versenden, von der sie glauben, dass es wahrscheinlich ist, dass sie ihn kennen. Zwar erreichten nur 44 Briefe ihr Ziel, aber das erstaunliche Ergebnis war, dass der Median der Anzahl der verwendeten Zwischenträger lediglich bei 5 lag, während man eigentlich vermuten könnte, dass die Kette sehr viel länger sein würde. Dieses Ergebnis wurde durch die Formulierung *six degrees of separation* populär gemacht – auch wenn dies etwas irreführend ist, da es sich ja bei Milgram um eine Verteilung handelt, deren Extremwerte 2 und 10 sind.

Granovetter-Studie: Die Studie des Soziologen Granovetter aus dem Jahr 1973 beschäftigte sich mit einem anderen Phänomen sozialer Netzwerke: der Intensität der Verbindung zwischen Individuen und deren Auswirkungen. Er hebt hervor, dass gerade die schwachen Verbindungen, die manchmal sogar als Zeichen für entfremdete Sozialbeziehungen gesehen werden, häufig sehr wichtig für Individuen sind, da sich so neue Chancen ergeben, z. B. bei der Arbeitssuche. Starke Verbindungen dagegen, die man oft als die eigentliche Grundlage des Sozialen ansieht, führen zu einer zunehmenden Fragmentierung des Ganzen (Granovetter 1973).

Industrie-Netzwerke: In den sozialwissenschaftlich ausgerichteten Geschichtswissenschaften haben sich Netzwerkanalysen auf ganz unterschiedlichen Ebenen schon lange etabliert (Düring et al. 2016). Im Folgenden wird eine qualitativ arbeitende Studie vorgestellt, die mit vergleichsweise einfachen analytischen Mitteln sehr interessante Ergebnisse vorzeigen kann (Marx/Krenn 2012). Thema der Studie ist die Vernetzung der Aufsichtsräte und Unternehmensleitungen im Bereich der Finanz- und der Großindustrie vom Beginn des Ersten Weltkriegs bis 1938. In diese Zeit fallen drei Krisen: der Erste Weltkrieg, die Weltwirtschaftskrise und die Machtergreifung durch die Nationalsozialisten. Im Zentrum der Analyse steht die Frage, wie stabil dieses Netz-

werk war; dabei wird die Entsendung von Direktoren einer Firma in den Aufsichtsrat einer anderen Firma als gerichtete Beziehung modelliert und die Mitwirkung von Personen in den Aufsichtsräten zweier Firmen als ungerichtete Beziehung.

Das zentrale theoretische Konzept ist dabei die **zerbrochene Verbindung** (*broken tie*). Eine zerbrochene Verbindung liegt vor, wenn eine Verbindung, die am Anfang des jeweiligen Untersuchungszeitraums vorhanden war, am Ende nicht mehr vorlag. Eine gezielte Wiederherstellung einer Verbindung, wenn diese etwa durch Tod, Krankheit oder neue Gesetze gekappt wurde, wird als Hinweis auf den funktionalen und auch intentionalen Charakter dieser Verbindungen gesehen.

Datengrundlage bildet die Analyse der größten deutschen Unternehmen in drei Zeitabschnitten: 1914–1928, 1928–1933, 1933–1938. Am Anfang des Untersuchungszeitraums lag die Zahl der gerichteten Beziehungen bei 229 und der ungerichteten bei 2800, am Ende bei 1025 bzw. 10.760 – bei 180 Unternehmen am Anfang und 325 am Ende eine recht enge Verflechtung. Die Daten zeigen, dass 1914–1928 stabile und zerbrochene Verbindungen sich so ziemlich die Waage halten, dass zwischen der Weltwirtschaftskrise und Machtergreifung 1928–1933 über 60 % der Verbindungen zerbrechen und im Nationalsozialismus dann die Verhältnisse genau umgekehrt sind: Über 60 % der Verbindungen sind stabil, und es kommt insgesamt zu einer engeren Verflechtung. Die Autoren stellen selbst fest: »Die hohe Anzahl stabiler Verbindungen in diesem Zeitraum ist besonders vor dem Hintergrund der Vertreibung jüdischer Mitglieder aus dem Netzwerk frappierend« (Marx/Krenn 2012, 671). Auch die anderen Ergebnisse der Untersuchung, etwa zur Expansion des Netzwerks im ersten Untersuchungszeitraum oder zur Stabilität der Netzwerkbeziehungen gerade im Fall von Mehrfachbeziehungen beruhen auf solch einfachen Analysen der erhobenen Daten.

Romane: Die Netzwerkanalyse wird inzwischen auch in der Literaturwissenschaft verwendet (Trilcke 2013), und im Folgenden soll ein kleines Beispiel die Möglichkeiten und Probleme bei der quantitativen Untersuchung von literarischen Texten, in diesem Fall Romanen, zeigen. Grundlage ist eine größere Sammlung von Romanen, von denen rund 450 mit Metadaten zum Erstdruck und anderen Angaben versehen worden sind. Die inhaltliche Fragestellung richtet sich auf die **Figurenkonstellation**. Gibt es typische Figurenkonstellationen, z. B. den Roman um eine Hauptfigur vs. den Roman mit vielen gleichwichtigen Hauptfiguren? Wir nehmen also die Figuren als Knoten und, da sich eine Konstellation auf die Interaktion der Figuren bezieht, diese als Kante. Wir erhalten die Knoten, indem wir mit automatischer Namenserkennung (*named entity recognition*) alle Namen in den Texten annotieren. Um die Interaktion zu modellieren, gibt es mehrere Möglichkeiten, z. B. können wir zählen, wie häufig Figuren miteinander reden. Oder wir können einfach das gemeinsame Vorkommen in einem Textabschnitt, z. B. einem Satz oder einem Absatz zählen. Letzteres scheint ein recht grober Ansatz zu sein, hat sich aber im Vergleich mit anderen als robustes Verfahren erwiesen und soll deshalb auch hier verwendet werden. Die Namen der Figuren sind also die Knoten, während die Interaktionen die (ungerichteten) Kanten bilden und die Anzahl der Interaktionen das Gewicht der Kanten.

Die Forschungsthese kann man nun so formulieren: Wenn es typische Figurenkonstellationen gibt, dann müsste man etwa bei der Verteilung der *degree centrality* über das gesamte Korpus mindestens zwei Spitzen sehen, eine bei Werten, die eher einem Sternnetzwerk entsprechen, und eine andere bei Werten, die eher mehrere zentralen Figuren indizieren. Unsere Nullhypothese dagegen würde lauten, dass sich keine solche zweigipflige Verteilung finden lässt. Wenn wir hier über *degree centrality* sprechen, dann können wir aber nicht mehr das Maß für einzelne Knoten ver-

wenden, sondern müssen einen Kennwert für das ganze Netzwerk suchen. Freeman hat ein derartiges Maß vorgeschlagen, das einfach die Differenzen zwischen dem Knoten mit dem größten Grad und allen anderen aufsummiert. In einem Sternnetzwerk, in dem ein Knoten einen hohen Grad hat und alle anderen einen niedrigen, werden sich die Differenzen zu einem großen Wert aufsummieren. Sind dagegen die Unterschiede zwischen den Graden nicht sonderlich groß, dann wird auch die Summe klein bleiben. Aber auch hier muss man den Wert normalisieren, indem man ihn durch die maximal mögliche Summe der Differenzen bei einem Graphen dieser Größe teilt (Freeman 1978/79). Nach einigen Umformungen ergibt sich daraus das Maß:

$$C_{DG} = \frac{\sum_{i=1}^n [c_D(p^*) - c_D(p_i)]}{n^2 - 3n + 2}$$

Wobei gilt: $C_D(p_i)$ = Centrality Degree des Knoten p_i
 $C_D(p^*)$ = Höchster Centrality Degree eines Knotens in diesem Netzwerk
 n = Anzahl der Knoten

Wenn wir dieses Maß für die 452 Romane berechnen und es als **Histogramm** visualisieren, sehen wir tatsächlich eine Verteilung mit zwei Gipfeln, die aber ungleich groß sind (Abb. 37).

Der Schwerpunkt der Verteilung liegt ohne Zweifel zwischen 0,2 und 0,4, d. h. in den meisten Romanen finden wir mehrere wichtige Figuren. Einen weiteren Peak scheint es um 0,5 zu geben, was auf eine einzige zentrale Figur hindeutet, so hat etwa *Effi Briest* einen Wert von rund 0,53. Außerdem sehen wir ein deutliches Tal zwischen den Gipfeln: Es handelt sich also wohl wirklich um zwei unterschiedliche Typen der Figurenkonstellation. Man kann sicher noch nicht sagen, dass die These von den zwei Typen der Figurenkonstellation nun endgültig bestätigt ist; dazu sind




Abb. 37 Zweigipflige Verteilung des Graphen Centrality Degree nach Freeman (1978/79) für 452 deutschsprachige Romane

bei der Modellierung und der Datenerhebung noch zu viele Fragen offen. So muss man etwa prüfen, wie sehr die Romane mit einem Ich-Erzähler das Bild verfälschen, da dort die Hauptfigur ja namentlich nicht auftaucht und somit im Netzwerk fehlt. Außerdem sollte man das Experiment mit einer noch größeren Anzahl von Romanen wiederholen. Und zuletzt müsste man auch statistische Verfahren bemühen, um die Belastbarkeit der Ergebnisse zu überprüfen. Man kann aber immerhin feststellen, dass unsere These bislang noch nicht falsifiziert ist.

10.5 | Fazit

Die Netzwerkanalyse ist ein wichtiges und schon viel bewährtes Instrument der digitalen Geisteswissenschaften. Nicht zuletzt durch die Entwicklung und Verbreitung von Bibliotheken für Programmiersprachen, aber auch von kompletten Anwendungen, die etwa die Visualisierung ermöglichen (z. B. Gephi), ist es auch ohne umfangreiches Spezialwissen möglich geworden, Netzwerkanalysen durchzuführen. Aber auch hier gilt, dass man sich immer klarmachen muss, dass es sich um ein recht abstraktes Werkzeug handelt, d. h. wie ein realweltliches Phänomen auf einen Graphen abgebildet wird, ist keineswegs in der Sache vorgegeben und selbstverständlich. Was modellieren wir als Knoten was als Kante? Verwenden wir gerichtete bzw. gewichtete Kanten? Was bilden wir als Gewicht und Richtung ab? Dafür gibt es keine »natürlichen« Antworten – selbst wenn sich bestimmte Verfahren etabliert haben.

Zentral ist auch hier, wie immer, die fachwissenschaftliche Frage, die bearbeitet werden soll und zu deren Beantwortung eine adäquate und funktionale Modellierung gefunden werden muss. So haben wir bei dem letzten Beispiel, dem **Figurennetzwerk**, die Figuren als Knoten modelliert und die Interaktionen als Kanten. Das liegt nahe und entspricht auch vielen Untersuchungen in der sozialen Netzwerkanalyse, muss aber keineswegs so sein. So kann man auch, wenn man sich nicht für Figurenkonstellationen, sondern vielmehr für **Plotstrukturen** interessiert, die Interaktion von zwei Figuren als Knoten nehmen und die Folge der Interaktionen im Text als gerichtete Kante. Dann würde ein Knoten, der die Figurenkontakte A und B repräsentiert, ausgehende Kanten auf nachfolgende Figurenkontakte haben und eingehende Kanten von Knoten, die vorangehende Figurenkontakte repräsentieren. Nimmt man hierbei die Anzahl, also wie häufig einem Figurenkontakt ein anderer folgt, als Gewicht, erhält man ein Netzwerk, das typische Kontakt-Abfolgen in einem Text sichtbar macht. Auch hier ist vor allem die Phantasie und Kreativität des Forschers bei der Erfindung neuer und interessanter Anwendungen gefragt.

Literatur

- Barabási, Albert-László: *Linked: How Everything is Connected to Everything Else and What it Means for Business, Science, and Everyday Life*. New York 2014.
- Düring, Marten/Eumann, Ulrich/Stark, Martin/von Keyserlingk, Linda (Hg.): *Handbuch Historische Netzwerkforschung*. Münster 2016.
- Freeman, Linton: »Centrality in social networks. Conceptual clarification«. In: *Social Networks* 1 (1978/79), 215–239.
- Granovetter, Mark S.: »The strength of weak ties«. In: *American Journal of Sociology* 78/6 (1973), 1360–1380.

- Krischke, André/Röpcke, Helge: *Graphen und Netzwerktheorie. Grundlagen – Methoden – Anwendungen*. München 2015.
- Milgram, Stanley: »The small world problem«. In: *Psychology Today* 1/1 (1967), 61–67.
- Newman, Mark E. J.: *Networks: An Introduction*. Oxford 2010.
- Trilcke, Peer: »Social Network Analysis (SNA) als Methode einer textempirischen Literaturwissenschaft«. In: Philip Ajouri/Katja Mellmann/Christoph Rauen (Hg.): *Empirie in der Literaturwissenschaft*. Münster 2013, 201–247.
- Wasserman, Stanley/Faust, Katherine: *Social Network Analysis*. Cambridge 1994.

Fotis Jannidis

11 Ontologien

Im Zusammenhang der Digital Humanities verstehen wir unter ›**Ontologien**‹, in Anlehnung an entsprechende Konzepte aus der Informatik, formale Begriffssysteme zur Modellierung von Wissen über einen spezifischen Gegenstandsbereich und deren technische Umsetzung. Ontologien dienen damit als eine Form der Wissensrepräsentation, ähnlich wie wir das schon bei Markup-Sprachen und Datenbanken gesehen haben (s. Kap. 8 und 9). Im Vergleich zu diesen besitzen Ontologien in der Regel jedoch ein höheres Abstraktionsniveau. Außerdem haben sie einen an mathematische Logik angelehnten, ausdrucksstarken Formalisierungsgrad, durch den Informationen in ihrem Bedeutungskontext präzise erfasst und maschinell verarbeitbar gemacht werden sollen. Damit sind Ontologien vor allem im Bereich der Integration heterogener Datenquellen, des Austauschs und der Wiederverwendung von Wissensselementen sowie der Ermöglichung logischer Schlussfolgerungen interessant, wodurch sie zunehmend an Bedeutung auch in den Digital Humanities gewinnen.

11.1 | Begriff und Einordnung

Als ›Ontologie‹ (hergeleitet von altgr. *on*: seiend und *logos*: Lehre, Wissenschaft) wird ursprünglich eine Teildisziplin der Philosophie verstanden, die auch **Allgemeine Metaphysik** genannt wird. In ihr geht es um die Beschreibung der »allgemeinsten Strukturen und Unterscheidungen im Wirklichen und Nichtwirklichen« (Meixner 2004, 9), also um die Grundstrukturen alles Seienden. Dabei wählt man zumeist einen indirekten Weg, d. h. man legt nicht die eigene Erfahrung von der Welt zu Grunde, sondern studiert, wie sich diese Grundstrukturen des Seienden in der Sprache niedergeschlagen haben.

In der Informatik und Informationswissenschaft werden einige grundlegende Konzepte der philosophischen Ontologie übernommen; in ihrem Ansatz geht es aber um die konkrete Entwicklung von Begriffssystemen zum Zweck der Wissensrepräsentation für einen bestimmten Gegenstandsbereich (*Domain*). Damit beschreiben die Ontologien der Informatik (und mittelbar der Digital Humanities) auch Seiendes, tun dies aber pragmatischer und zweckorientiert. Seit den 1970er Jahren halten Ontologien so als Basis für die Entwicklungen sogenannter Künstlicher Intelligenz (KI) Einzug in die Informatik. Seit den späten 1990er Jahren stehen sie zunehmend im engen Zusammenhang mit der Entwicklung von Semantic-Web-Technologien. Ausgangspunkt hierbei ist, dass das WWW (traditionell) die **Semantik** von Informationen nicht explizit macht, sondern lediglich Zeichenketten (Symbole) transportiert. Die Auszeichnungssprache des WWW – »HTML« – beschreibt, wie Information dargestellt und untereinander verlinkt wird, aber nicht, was sie bedeutet. Dies führt u. a. zu Problemen im Information Retrieval (s. Kap. 19), und es erschwert den Austausch von Wissensbausteinen.

Web of Documents: In der Konzeption, die vor allem auf Tim Berners-Lee zurückzuführen ist, entwickelte sich das WWW damit zunächst als ein ›web of documents‹, dessen ursprüngliche Hauptfunktion es war, dass rein menschliche Nutzer über einen Webbrowser zielgerichteten Zugriff auf Information in Form von Web-Dokumenten erhalten. Die Erfolgsgeschichte des WWW beruht nun u. a. darauf, dass das Web ein riesiger potentieller Wissensspeicher geworden ist. Sein großer Nachteil

ist, dass trotz der massiven Verlinkung von Web-Dokumenten untereinander letztendlich Datensilos entstanden sind, die voneinander nichts wissen und vor allem für eine maschinengestützte Verarbeitung weitgehend unbrauchbar sind.

Berners-Lee selbst formuliert die Vision einer weiterreichenden, weltweiten, dezentralisierten Wissensdatenbank, die dieses Manko überkommt: »The web of human-readable documents is being merged with a web of machine-understandable data. The potential of the mixture of humans and machines working together and communicating through the web could be immense« (Berners-Lee 1998).

Was dem zunächst jedoch im Wege steht, sind eine Reihe von Architekturproblemen des WWW:

1. Für eine **maschinelle Verarbeitung** von Wissen sind die Informationseinheiten im ›web of documents‹ zu groß; anstatt dass Aussagen miteinander verknüpft werden und aus dieser Verknüpfung heraus neues Wissen entsteht, wird lediglich von Dokumenten auf Dokumente verlinkt.
2. Die **Verlinkung zwischen Informationseinheiten** ist unidirektional, nicht bidirektional (wenn A auf B verlinkt, ›weiß‹ B nichts davon), und sie ist nicht weiter ausdifferenziert, sondern stellt lediglich einen unspezifischen Verweis dar, der über seine eigene Qualität nichts aussagt. So ist es semantisch ein großer Unterschied, ob etwa, wenn A einen Sachverhalt beschreibt und A auf B verlinkt, B ein Beispiel für A ist oder B eine Begründung für A liefert oder B eine andere Meinung zu A darstellt. Diese Unterscheidung ist in HTML-Links nicht ausdrückbar.
3. Die in den **Dokumenten enthaltenen Aussagen** sind in ihrer Bedeutung nicht explizit formalisiert und werden vom Computer nicht ohne weiteres verstanden.

So versteht sich dann das als Folgeentwicklung konzipierte **Semantic Web** als eine Erweiterung des WWW, »in which information is given well-defined meaning, better enabling computers and people to work in cooperation« (Berners-Lee/Hendler/Lassila 2005, 34). Neben dem Lösen der oben genannten Architekturprobleme erfordert die Umsetzung dieser Idee eines semantischen Wissensnetzwerkes aber vor allem die Beantwortung der Frage, wie von Menschen sprachlich formulierte Informationen durch den Computer ›verstehbar‹ gemacht werden können.

Symbol – Begriff – Gegenstand

Das folgende, für Ontologien grundlegende Wechselspiel Symbol-Begriff-Gegenstand wird in unterschiedlichen Ausprägungen und Theorien der Sprachwissenschaft auch als **semiotisches Dreieck** bezeichnet. Betrachten wir einmal den Satz, der z. B. einer Webseite entnommen sein könnte: »Lincoln beeindruckt Obama.« Was ist mit ›Lincoln‹ gemeint? Abraham Lincoln, der 16. Präsident der Vereinigten Staaten von Amerika? Lincoln, die Hauptstadt des US-Bundesstaates Nebraska oder eine der anderen, zahlreichen Städte mit diesem Namen? Oder einer von mehreren Kino- und Fernsehfilmen mit diesem Titel? Das sprachliche Symbol, die Zeichenkette ›L-i-n-c-o-l-n‹, ist in jedem Fall das gleiche. Es kann aber für höchst unterschiedliche Dinge unserer Welt stehen. Wenn wir das sprachliche Symbol hören oder lesen, so erweckt es in uns eine mentale Vorstellung, die sich auf ein konkretes Ding, z. B. auf den Film bezieht. Nur erfordert diese Vorstellung, die wir auch ›Begriff‹ (oder Konzept) nennen, aber einen Kontext. Soll nun ein Computer den Satz »Lincoln hat ihn beeindruckt« auswerten, so muss er diesen Kontext kennen, um das Symbol ›L-i-n-c-o-l-n‹ zu disambiguieren und einem Begriff zuzuordnen.

Aus diesen Überlegungen leiten sich zwei Hauptstränge andauernder Grundlagenforschung und technologischer Entwicklung in der Informatik ab: erstens die Verfahren der Natursprachverarbeitung (Natural Language Processing, NLP), die die Bedeutung von in Textform transportierter Information automatisiert extrahieren sollen, wofür statistische Verfahren und *Machine Learning* eingesetzt werden (impliziter Zugang), sowie zweitens die formalisierte Annotation der Inhalte und zwar in einer Art und Weise, mit der sie anschließend maschinell gelesen und korrekt interpretiert werden kann. Für solche expliziten Zugänge greifen die Semantic-Web-Technologien auf die Begriffssysteme der Ontologien zurück. Durch diese Begriffssysteme soll im Idealfall eine eindeutige Abbildung vom symbolischen Ausdruck auf die Gegenstände der realen Welt geschaffen werden. Hiermit wollen wir uns im Weiteren beschäftigen.

11.2 | Grundlegende Konzepte

Jede Form der Wissensrepräsentation stützt sich auf eine Modellierung, die die Objekte ihres Gegenstandsbereichs sowie deren Beziehungen untereinander begreiflich machen soll, zunächst aber abstrakt bleibt (im englischen als *conceptualization* bezeichnet; s. auch Kap. 7). Eine Ontologie im hier betrachteten Sinn ist nunmehr ein formalisierter Ausdruck dieser Modellierung, »an explicit specification of a conceptualization« (Gruber 1993, 199). Um dies zu erreichen, definiert eine Ontologie zunächst mit Hilfe einer Menge von grundlegenden Bestandteilen ein Begriffssystem. Zu diesen Bestandteilen zählen:

Klassen (*classes*) sind Abstraktionen von Dingen, die bestimmte Eigenschaften teilen. Sie stehen somit für abstrakte Begriffe (*concepts*). Dabei lassen sich entweder Individuen (siehe unten) zu einer Klasse zusammenfassen, oder es definiert die Klasseneigenschaft, welche Individuen zu dieser Klasse gehören. Beispiele für Klassen könnten ›Person‹, ›Ereignis‹, ›Rolle‹ oder ›Ort‹ sein. Klassen lassen sich unter übergeordneten Klassen subsummieren, womit die Begriffswelt der Ontologie hierarchisch organisiert ist und einer Taxonomie ähnelt. So könnten etwa ›Frau‹ und ›Mann‹ als Unterklassen von ›Person‹ und diese wiederum als Unterklassen einer sehr weit gefassten Klasse ›Ding‹ aufgefasst werden. Individuen einer Klasse erben automatisch die Eigenschaften ihrer Oberklasse(n).

Attribute oder Eigenschaften (*attributes, properties*) charakterisieren die Objekte der Ontologie näher. Eine Beziehung zwischen einem Objekt und einem Attribut drückt dabei eine Tatsache aus, die für dieses Objekt spezifisch ist. Zum Beispiel kann die Klasse ›Person‹ dadurch charakterisiert sein, dass ihre Mitglieder einen Namen haben – ›hat Namen‹ stellt dann eine Eigenschaft zu ›Person‹ dar. Ziel der Attribution können dabei literale Werte (Daten), Instanzen oder selbst Klassen sein. Im letzteren Falle spricht man auch von **Relationen** (*relations*) zweier Klassen. So beruht die oben genannte Klassenhierarchie auf Relationen der Art ›ist Unterklasse von‹.

Für Attribute und Relationen kann eine Ontologie **Bedingungen** (*constraints*) festlegen, die ihren Gebrauch näher definieren und sicherstellen sollen, dass die Ontologie in sich logisch konsistent ist. So kann etwa bestimmt werden, dass eine Instanz der Klasse ›Person‹ genau einer ihrer beiden Unterklassen ›tote Person‹ und ›lebendige Person‹ zugehört, aber nicht beiden. Ein Individuum ist damit entweder tot oder lebendig, und die Schnittmenge der beiden Unterklassen ist leer (eine Bedin-

gung, die übrigens anders zu modellieren wäre, würden wir fiktive literarische Welten mit Zombies und Vampiren oder das Paradoxon von Schrödingers Katze berücksichtigen).

Klasseneigenschaften, Relationen und Bedingungen zusammen können als **Aussagen** (*propositions*) ein komplexes, logisches Regelwerk bilden. Dazu zählen auch Grundannahmen (**Axiome**), die nicht weiter begründet werden, wie z. B., dass eine Person nicht gleichzeitig an zwei Orten sein kann. Ontologien können damit im Vergleich zu anderen Formen der Wissensrepräsentationen (Datenbanken, Markupsprachen) sehr expressiv sein.

Klassen, Attribute, Relationen und Bedingungen beschreiben das **terminologische Wissen** (*terminological knowledge*) der Ontologie, sie bilden sozusagen das abstrakte Grundgerüst der beobachteten Welt. **Instanzen oder Individuen** (*instances, individuals*) repräsentieren schließlich Objekte aus dieser Welt. Sie sind Konkretisierungen von Begriffen und gehören in der Regel einer oder mehrerer Klassen an. Beispielsweise können ›München‹, ›Würzburg‹ und ›Passau‹ unterschiedliche Instanzen der Klasse ›Stadt‹ sowie ›Oberbayern‹, ›Unterfranken‹ und ›Niederbayern‹ der Klasse ›Bezirk‹ sein. Da über Instanzen auf Grundlage des terminologischen Wissens Aussagen getroffen werden (z. B. »Passau ist eine Stadt und liegt im Bezirk Niederbayern«), nennt man die Menge aller Individuen einer Ontologie auch **assertionales Wissen** (*assertional knowledge*, von lat. *assertio*: Behauptung). Terminologisches und assertionales Wissen bilden dann die Wissensrepräsentation über den Gegenstandsbereich.

Man kann sich leicht vorstellen, dass die Modellierung einer Ontologie ausgesprochen komplex werden kann. So wird man in der Regel den Modellierungszweck und/oder den Gegenstandsbereich stark einschränken. Damit werden Ontologien selbst klassifizierbar, wofür u. a. die zwei folgenden Ansätze beschrieben worden sind. Der erste Ansatz gliedert Ontologien nach dem Grad ihrer Abhängigkeit von einem bestimmten Standpunkt oder einer Aufgabenstellung (nach Guarino 1998; s. Abb. 38):

- Als **Top-Level Ontology** (auch: Upper Ontology) werden Ontologien bezeichnet, die sehr allgemeine Begriffe wie Zeit, Raum oder Ereignis beschreiben und somit unabhängig von einem spezifischen Gegenstandsbereich oder einer bestimmten Problemstellung anwendbar sein sollen.




Abb. 38 Klassifizierungsansatz für Ontologien anhand des Grades ihrer Abhängigkeit von einem bestimmten Standpunkt oder einer spezifischen Aufgabenstellung (in Anlehnung an Guarino 1998)

- Eine **Domain Ontology** beschreibt die grundlegenden Begriffe für einen groß gefassten Gegenstandsbereich (Domäne), die eine Top-Level-Ontology weiter spezifizieren.
- Das gleiche tut eine **Task Ontology**, allerdings nicht für einen Gegenstandsbereich, sondern für eine (generische) Aktivität oder Aufgabe.
- Die **Application Ontology** führt schließlich Domain und Task Ontology zusammen und spezifiziert die dort beschriebenen Begriffe für konkrete, fokussierte Gegenstandsbereiche und/oder Aufgaben.

Ein anderer Ansatz ordnet Ontologien nach dem Grad ihrer Ausdruckskraft und Formalisierung (Lassila/Mcguinnes 2001). Die Spannweite reicht dabei von sehr wenig formalisierten und wenig mächtigen Beschreibungssystemen wie kontrollierten Vokabularen, Glossaren und Thesauri (**Lightweight Ontologies**) über hierarchische Taxonomien bis hin zu stark formalisierten und daher auch sehr ausdrucksmächtigen Beschreibungssystemen (**Heavyweight Ontologies**), die Logikkalküle wie Aussagenlogik oder Prädikatenlogik erster Stufe zur Grundlage haben, was hier nicht vertieft werden kann.

11.3 | Ein Beispiel

Konstruieren wir uns nun ein einfaches Beispiel, um einige der oben angeführten Konzepte zu illustrieren. Betrachten wir hierzu einen kleinen Ausschnitt unserer Welt, nämlich die ›Welt des Nobelpreises‹, bestehend aus den Preisen selbst, den Preisträgern und den Berufen, die diese ausüben. Das hierzu entworfene Modell (Abb. 39) zeigt die Klassen und deren Relationen. Es besteht aus der generischen Oberklasse ›Ding‹ und den Unterklassen ›Person‹, ›Nobelpreis‹ und ›Beruf‹, die wir alle als ›Ding‹ auffassen (das Seiende in der Philosophie). Die Klasse der Personen spezifizieren wir weiter in die Unterklassen ›Mann‹ und ›Frau‹, weil Männer und Frauen im Sinne der Klassifikation Personen *sind*. Das Verhältnis von Beruf zu Person ist ein anderes, weil Personen Berufe *haben* aber konzeptionell keine Berufe sind. Eine weitere Unterklasse zu Person sind die Nobelpreisträger. Sie sind dadurch charakterisiert, dass sie einen Nobelpreis gewinnen. Außerdem beschreiben wir eine Unterklasse der intelligenten Personen, die zugleich eine weitere Oberklasse der Nobelpreisträger darstellen. Das gesamte Modell stellt somit das terminologische Begriffssystem dar, wie wir (korrekt: der Modellierer) diesen Ausschnitt der Welt sehen.

Betrachten wir nun zwei historische Personen in dieser Welt: Thomas Mann, Schriftsteller, Nobelpreis für Literatur (1929) sowie Marie Skłodowska Curie, Physikerin und Chemikerin, Nobelpreis für Physik (1903) und für Chemie (1911). Damit können wir Aussagen bilden, die dann das assertionale Wissen unserer Wissensrepräsentation bilden (wie wir diese Fakten formal ausdrücken, sehen wir im nächsten Abschnitt), wie z. B. ›Marie Skłodowska Curie ist eine Frau‹, ›Der Nobelpreis für Literatur ist ein Nobelpreis‹, ›Schriftsteller ist ein Beruf‹ usw. ›Marie Skłodowska Curie‹, ›Nobelpreis für Literatur‹ und ›Schriftsteller‹ sind konkrete Instanzen unserer Ontologie.

Mit diesem Modell lassen sich nun logische Schlussfolgerungen (engl. *inference*) ableiten. War Marie Skłodowska Curie eine intelligente Person? Aus unseren ursprünglichen Fakten wissen wir das zunächst nicht. Aber wir wissen, dass sie einen Nobelpreis gewonnen hat, und da, nach unserem Modell, nur Nobelpreisträger einen




Abb. 39 Beispielsmodell ›Welt des Nobelpreises‹. Die unbeschrifteten Relationen sind vom Typ ›ist Unterklasse von‹ und beschreiben die Klassenhierarchie.




Abb. 40 Instanzen der Beispiels-Ontologie ›Welt des Nobelpreises‹

Nobelpreis gewinnen und alle Nobelpreisträger intelligente Personen sind (in der Klassenhierarchie), folgt, dass auch Marie Skłodowska Curie eine intelligente Person war.

Fügen wir nun weitere Aussagen zu unserem Wissen hinzu: Der Schriftsteller Heinrich Mann war eine intelligente Person. Welche Schlussfolgerungen können wir hieraus ableiten? War Heinrich Mann ein (Literatur-)Nobelpreisträger? Explizit ist

dies nicht, und eine Herleitung über die Relation ›Nobelpreisträger‹ zu ›intelligente Person‹ wäre falsch: Zwar sind in unserem Modell alle Nobelpreisträger intelligente Personen, aber nicht alle intelligenten Personen sind zugleich Nobelpreisträger. Die Beantwortbarkeit dieser Frage mit Hilfe unserer Wissensrepräsentation hängt nun von unserem Grundverständnis der Ontologie ab. Und hier gibt es zwei verschiedene Ansätze.

Closed World und Open World: Bei der Closed World Assumption (CWA) gehen wir davon aus, dass das Beschreibungssystem vollständig und abgeschlossen ist und dass sämtliche Aussagen explizit spezifiziert sind. Mit anderen Worten: Alles was mittels der Ontologie nicht als wahr gezeigt werden kann, muss als falsch angenommen werden. Da Heinrich Mann nicht explizit als Nobelpreisträger beschrieben ist und dies auch nicht logisch hergeleitet werden kann (anders als bei der Frage, ob Marie Skłodowska Curie eine intelligente Person war), beantwortet ein CWA-System die gestellte Frage mit ›nein‹.

Die Open World Assumption (OWA) hingegen geht davon aus, dass das Modell grundsätzlich unterspezifiziert ist und erweitert werden kann. Dadurch ist zunächst grundsätzlich alles möglich, was nicht explizit ausgeschlossen wird. Im Fall von Heinrich Mann müssen wir dann sagen: unser Wissen, um zu entscheiden, ob er Nobelpreisträger war, reicht nicht aus; eine Entscheidung ist nicht möglich. (Tatsächlich hat er natürlich anders als sein Bruder nie den Nobelpreis erhalten).

Die Open World Assumption ist der Ansatz, der im Semantic Web verfolgt wird, wodurch insbesondere die Möglichkeit geschaffen werden soll, Wissenslücken durch Verlinkung mit anderen Wissensrepräsentationen zu schließen. Die CWA ist dafür ungeeignet und wird eher für abgeschlossene Wissenssysteme, z. B. in Unternehmen eingesetzt.

Stellen wir noch eine weitere Frage: Sind alle Literaturnobelpreisträger auch Schriftsteller? Für alle Instanzen, die wir bislang eingeführt haben, trifft das zu. Jedoch entspräche dies nicht der Realität, wenn man etwa die Instanz Theodor Mommsen, Historiker, Nobelpreisträger für Literatur 1902 betrachtet. Danach ist die Frage mit ›nein‹ zu beantworten. Deswegen wäre eine Erweiterung der Ontologie dahingehend, eine Bedingung einzubauen, die den Gewinn des Literaturnobelpreises an den Schriftstellerberuf bindet, ein Fehler gewesen, da dies nicht der Realität entspricht und bei der Einfügung der Instanz Theodor Mommsen zu Widersprüchen führt. Daher geht der OWA-Ansatz in der Modellierung davon aus, das Modell zunächst sehr offen zu gestalten und erst Schritt für Schritt restriktiver zu gestalten.

11.4 | RDF

Wir haben gesehen, dass Ontologien Denkmustern der Philosophie entlehnt sind, um Begriffssysteme zu schaffen, die Wissen repräsentieren sollen. Zugleich wird dieses System nun so formalisiert, dass es vom Computer ›verstanden‹ wird, d. h. dass die Bedeutung von Information automatisiert verarbeitet und implizite, nicht offensichtliche Information aus dem existierenden Beschreibungssystem geschlussfolgert werden kann, um somit neues Wissen zu erzeugen (wie etwa: Marie Skłodowska Curie ist eine intelligente Person). Einige der hierfür beschriebenen und entwickelten Techniken wollen wir uns im Folgenden ansehen.

Resource Description Framework (RDF)

Das 1999 eingeführte **Resource Description Framework (RDF)** ist ein Standard des W3C und gilt als zentraler Baustein des Semantic Webs. Im Kern geht es bei RDF darum, die oben genannten Architekturprobleme des WWW zu überwinden.

Für unsere Ontologien bedeutet dies, dass wir ein Mittel zur Verfügung haben, um Aussagen wie die, die wir im Beispiel diskutiert haben, nicht nur formal auszudrücken, sondern sie zugleich im Web zugänglich und untereinander sowie mit anderen Wissensrepräsentationen verknüpfbar zu machen.

RDF beruht auf folgenden Grundregeln:

1. **Tripel:** Jede Aussage besteht in RDF aus drei Einheiten, die zusammen ein Tripel bilden: Subjekt, Prädikat und Objekt. In diesem Sinne bilden das Subjekt `<Thomas_Mann>`, das Prädikat `<gewinnt>` und das Objekt `<Literaturnobelpreis>` ein Tripel.




Abb. 41 RDF-Tripel (Beispiel)

2. **Internationalized Resource Identifiers (IRI):** Subjekt und Prädikat sind sogenannte Ressourcen, die durch eindeutige Bezeichner identifiziert werden. Als Bezeichner werden Internationalized Resource Identifiers verwendet. Sie sind eine Verallgemeinerung der URIs und somit der URLs (s. Kap. 4.10) und stellen sicher, dass die Ressource eindeutig identifizierbar und über das Web adressierbar ist.
3. **Literal:** Objekt kann entweder eine Ressource oder ein sogenanntes Literal sein. Als Literale bezeichnen wir Datenwerte, denen im Gegensatz zu Ressourcen keine eigenständige Existenz unterstellt wird. So ist etwa `>6.6.1875<` ein Literal und kann Objekt zum Subjekt `<Thomas_Mann>` mittels des Prädikats `<istGeborenAm>` sein (hier nicht modelliert).

RDF stellt, ähnlich wie XML, lediglich eine Syntax dar und bringt von sich aus kein Vokabular mit. Als Erweiterung von RDF bietet nun **RDF Schema (RDFS)** ein formales Vokabular, mit dessen Hilfe sich auf einer sehr abstrakten Ebene v. a. Klassen, Attribute und (einfache) Bedingungen modellieren lassen. Als Syntax für RDFS stehen verschiedene, textbasierte Beschreibungssprachen bzw. Datenstrukturen (u. a. XML und JSON) zur Verfügung. Gängig und anschaulich ist die Serialisierung mittels der **Terse RDF Triple Language (Turtle)**.

Ein einfaches Beispiel soll die Funktionsweise von RDFS und ihre Repräsentation durch Turtle veranschaulichen. Dabei gehen wir davon aus, dass wir unser Beschreibungssystem in einer Ontologie namens `>bo<` (für Beispiel-Ontologie) zur Verfügung haben, die unter der (Fantasie-) URL `http://beispielontologie.de` hinterlegt ist. Diese unterteilen wir in das terminologische Wissen (`bot`) und das assertionale Wissen (`boa`). `boa` und `bot` bilden, wie auch die Standards `rdf` und `rdfs`, **Namespaces** – ein Konzept, das uns schon in XML begegnet ist. In Turtle ist dies als `@prefix` zur besseren Lesbar-

keit abgekürzt (so wird etwa mit Hilfe des Präfixes die Ressource `boa:Thomas_Mann` zur IRI `<http://beispielontologie.de/instanzen#Thomas_Mann>` aufgelöst).

Betrachten wir zunächst (in Auszügen) den Teil unserer Beispielontologie, der das terminologische Wissen beschreibt:

```
@prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#> .
@prefix bot: <http://beispielontologie.de/terminologie#> .
@prefix boa: <http://beispielontologie.de/instanzen#> .

bot:Ding                rdf:type          rdfs:Class .
bot:Person              rdfs:subClassOf    bot:Ding .
bot:Mann                rdfs:subClassOf    bot:Person .
bot:Frau                rdfs:subClassOf    bot:Person .
bot:Nobelpreis          rdfs:subClassOf    bot:Ding .
bot:istBruderVon        rdf:type          rdf:Property ;
                        rdfs:domain        bot:Mann ;
                        rdfs:range         bot:Person .
bot:Nobelpreisträger    rdfs:subClassOf    bot:Person .
bot:gewinnt             rdf:type          rdf:Property ;
                        rdfs:domain        bot:Person ;
                        rdfs:range         bot:Nobelpreisträger .
...
```

Nach der Definition der Namespaces als Präfixe folgen die eigentlichen Aussagen, die unsere Beispielwelt beschreiben. Sie sind jeweils wie bei einem Satz in natürlicher Sprache durch `>`,`<` abgeschlossen (sind sie durch ein `>`,`<` abgeschlossen, so bleibt das Subjekt der vorigen Aussage bestehen). In RDF ist zunächst grundsätzlich alles eine abstrakte Ressource, ohne weitere Bedeutung. Elementar für eine Ontologie ist es nun, wie gesehen, Dingen eine Bedeutung zu geben. In den ersten drei Zeilen unseres Beispiels bauen wir daher eine Klassenhierarchie auf, in der wir die Ressource `bot:Ding` (als IRI vollständig: `<http://beispielontologie.de/terminologie#Ding>`) als eine Klasse, und `bot:Person` und `bot:Nobelpreis` als ihre Unterklasse definieren, womit deren Abhängigkeit voneinander festgelegt ist und u. a. jeder Ort automatisch ein Ding ist. Dabei greifen wir auf das grundlegende, generische Vokabular zurück, das RDFS bietet. Außerdem unterteilen wir die Gruppe der Personen in Männer und Frauen.

Zur weiteren Spezifizierung wird `bot:istBruderVon` in der nächsten Zeile als Attribut definiert. Hier legen wir aber weitere Bedingungen fest, nämlich dass diese Relation erfordert, dass das Subjekt einer Aussage (`rdfs:domain`) vom Typ `bot:Mann` und das Objekt (`rdfs:range`) vom Typ `bot:Person` sein muss. Mit anderen Worten: wir haben modelliert, dass nur ein Mann ein Bruder sein (sonst wäre es eine Schwester) und nur eine Person (und nicht etwa ein Nobelpreis) einen Bruder haben kann. Eine vergleichbare Relation modellieren wir für das Gewinnen eines Nobelpreises.

Man sieht an diesem einfachen Beispiel, wie mittels RDF(S) die Semantik, d. h. die Bedeutung eines Gegenstandsbereichs erfasst werden kann. Bislang haben wir

uns aber nur auf das reine Begriffssystem beschränkt. Wenden wir uns nun den Instanzen, unserem assertionalen Wissen, innerhalb dieses Systems zu, die mit der gleichen Syntax formalisiert beschrieben werden:

```
boa:Literaturnobelpreis      rdf:type      bot:Nobelpreis .

boa:Thomas_Mann             rdf:type      bot:Mann ;
                             bot:gewinnt   boa:Literaturnobelpreis .

boa:Heinrich_Mann           rdf:type      bot:Mann ;
                             bot:istBruderVon  boa:Thomas_Mann .

...
```

Hier sehen wir, wie die zuvor definierten Ressourcen (z. B. die Klasse `bot:Mann` oder das Attribut `bot:istBruderVon`) verwendet werden, um neues Wissen in Form von Instanzen (`boa:Literaturnobelpreis`, `boa:Thomas_Mann` und `boa:Heinrich_Mann`) hinzuzufügen. Die Turtle-Notation repräsentiert damit die natursprachlichen Aussagen: ›Der Literaturnobelpreis ist ein Nobelpreis‹, ›Thomas Mann ist ein männlicher Gewinner des Literaturnobelpreises‹ usw.

Man muss noch anmerken, dass die Ressourcen in RDF lediglich Identifier sind und grundsätzlich arbiträr vergeben werden können, ohne die Aussagen zu verändern, die dahinter stehen. So könnten wir die Person Thomas Mann auch als `boa:TM` oder `boa:aljsdf4Z` auffassen, was ihrer Identifizierbarkeit durch den Computer keinen Abbruch tut (aber nicht unbedingt sinnvoll ist). Um zu wissen, dass diese Person (im Sprachgebrauch) Thomas Mann heißt, müssen wir ihr über ein zusätzliches Attribut einen Namen vergeben:

```
bot:name                     rdf:type      rdf:Property .
boa:Thomas_Mann              bot:name      "Thomas Mann" .
```

Als wichtige Erweiterung von RDF(S) gilt die 2004 eingeführte **Web Ontology Language (OWL)**, eine Familie von formalen Sprachen, die auf ausdrucksstarker Beschreibungslogik beruhen. So lässt sich in Web Ontology Language beispielsweise formalisiert ausdrücken, dass eine Person nicht zugleich lebendig und tot sein kann, indem die Schnittmenge der beiden Klassen als leer definiert wird:

```
bot:lebendePerson           rdfs:subClassOf      bot:Person .
bot:totePerson               rdfs:subClassOf      bot:Person .
bot:lebendePerson            owl:disjointWith    bot:totePerson .
```

Mit solchen Mechanismen lassen sich Begriffssysteme entwickeln, die es u. a. erlauben, implizites Wissen durch logische Schlussfolgerungen (Inferenzen) zu ziehen, Klassifizierungen vorzunehmen und im Begriffssystem selbst nach Widersprüchen zu suchen bzw. es auf Konsistenz zu prüfen. Beispiele hierfür sind: Wenn X eine Instanz der Klasse A ist und B eine Unterklasse von A ist, so ist X eine Instanz von B. Oder: Wenn X eine Instanz von Klasse A ist und X eine Instanz von Klasse B ist, aber A und B disjunkt sind, so ist die Ontologie inkonsistent (das ist genau das Beispiel der lebenden und toten Personen). Hieran sieht man, dass ausdrucksstarke Ontologien eng mit formaler Logik verknüpft sind.




Abb. 42 RDF-Graph zur Beispiel-Ontologie ›Welt des Nobelpreises‹ (Auszug)

Einige wichtige Aspekte der RDF-Technologie sollen jedoch noch besprochen werden. Zum einen kann eine Menge von RDF-Tripels als **gerichteter Graph** (s. Kap. 10.1) aufgefasst werden. Abbildung 42 illustriert an unserem Beispiel das Prinzip: Subjekt und Objekt werden als Knoten, Prädikat als eine (qualifizierte) Kante aufgefasst. Anhand eines solchen Graphen kann man sich vor Augen führen, dass eine Wissensrepräsentation mittels RDF leicht erweiterbar ist, indem man Knoten und Kanten hinzufügt.

Zum zweiten, und das ist gerade im Kontext der Digital Humanities von großem Interesse, bietet RDF die Möglichkeit, Aussagen über Aussagen zu machen (sog. **Reifikation**). Das ist bei geisteswissenschaftlichen Fragestellungen insofern besonders relevant, als dass wir es hier häufig mit subjektiven oder unsicheren Aussagen zu tun haben. So könnte man darüber streiten, ob der Wirtschaftsnobelpreis (eigentlich: Alfred-Nobel-Gedächtnispreis für Wirtschaftswissenschaften – ein Preis der Schwedischen Reichsbank) zur Klasse der Nobelpreise zählt oder nicht. Eine Aussage über eine Aussage wäre dann etwa ›Die Person X behauptet (oder bestreitet): ›Der Alfred-Nobel-Gedächtnispreis für Wirtschaftswissenschaften ist ein Nobelpreis‹. In RDF heißt dies, eine Aussage selbst zu einer Ressource werden zu lassen und sie dann zum Objekt einer anderen Aussage zu machen. Die Turtle-Notation hierfür ist gut verständlich, aber leider nicht sehr kompakt. Sie sei an diesem Beispiel ohne weitere Erläuterung dargestellt:

```

boa:PersonX          bot:behauptet      boa:AussageX .
boa:AussageX         rdf:type            rdf:Statement ;
                    rdf:subject          boa:A_N_Gedächtnispreis ;
                    rdf:predicate        rdf:type ;
                    rdf:object           bot:Nobelpreis .

```

11.5 | Speicherung, Retrieval und Datenintegration

Als Möglichkeit der Speicherung von RDF-Graphen werden spezielle Datenbanken verwendet, die **Triplestores** (auch: RDF Store) genannt werden. Sie erfüllen die gleiche Funktionalität wie andere Datenbank-Managementsysteme (s. Kap. 8), sind aber auf die Spezifika der Tripels optimiert. Insbesondere erlauben sie semantische Ab-

fragen und logische Schlussfolgerungen, wofür spezielle Abfragesprachen entwickelt wurden, die nach Graph-basierten Mustern suchen. Die wichtigste hiervon ist **SPARQL**, ein W3C-Standard, der neben der eigentlichen Abfragesprache ein XML-basiertes Ausgabeformat spezifiziert und die Möglichkeit der Kommunikation über HTTP bietet.

Die folgende SPARQL-Abfrage würde etwa in unserer Beispiel-Ontologie alle Personen (personA) ermitteln, die einen Nobelpreisträger (personB) zum Bruder haben:

```
SELECT ?personA ?personB
WHERE {
    ?personB      rdf:type          bot:Person ;
                  bot:gewinnt      bot:Nobelpreis .
    ?personA      bot:istBruderVon  ?personB .
}
```

Die Syntax von SPARQL erinnert ein wenig an SQL, aber wir sehen, dass in SPARQL die WHERE-Klauseln selbst als Tripels formuliert sind. Genau diese dort spezifizierten Muster (»ist eine Person«, »gewinnt Nobelpreis« und »ist Bruder von«) werden durch die Datenbank bei der Traverse durch den RDF-Graph in Einklang gebracht, wobei personA und personB als Variablen für die Knoten im Graph stehen.

Mit diesen Mitteln erlaubt SPARQL semantische Abfragen, wie z. B. »gib mir den Namen aller weiblichen Nobelpreisträger, die in einem Ort, der heute in Deutschland liegt, geboren wurden«. Dabei müssen nicht alle Informationen in *einer* Datenbank vorhanden sein, sondern SPARQL erlaubt die übergreifende Suche über verschiedene sogenannte Endpoints hinweg (*federated search*). So könnten die Nobelpreise mit unserer Beispielontologie repräsentiert und das assertionale Wissen dazu in einer eigenen Datenbank gespeichert, die Zugehörigkeit des Geburtsortes zu einem Land aber etwa mittels GeoNames, einer Ontologie mit über 10 Millionen Toponymen beschrieben werden:

```
@prefix gn: <http://www.geonames.org/#>
bot:istGeborenIn      rdf:type          rdf:Property .
boi:Thomas_Mann       bot:istGeborenIn
gn:2875601 .
```

Datenintegration: Darin zeigt sich die Stärke von Ontologien für die Datenintegration. Machen wir zudem unsere eigene Wissensrepräsentation als RDF-Graph über einen Endpoint zugänglich, so dass andere darauf zugreifen können, so entsteht ein semantisches Netz. Dieses Prinzip, Ontologie-basierte Datenbanken zu veröffentlichen und die Technologien des Semantic Webs zu nutzen, um diese zu vernetzen, wird **Linked Data** genannt. Sind die Daten zudem im Sinne von Open Access frei zugänglich und nutzbar, spricht man von **Linked Open Data (LOD)** und nennt die Gesamtheit dieser Daten auch LOD Cloud. Zentrale Bestandteile der LOD Cloud sind neben GeoNames unter anderem DBpedia, eine Ontologie-basierte Repräsentation von Wikipedia-Artikeln und FOAF (*Friend of a Friend*), eine Ontologie zur Beschreibung menschlicher sozialer Beziehungen. Im Bereich der Digital Humanities ist die Datenintegration, etwa von bibliographischen und biographischen Daten oder von Metadaten zu Kulturgut im Sinne von Linked (Open) Data ein aktueller Trend.

11.6 | Ontologien in den Digital Humanities

In den Digital Humanities werden derzeit vor allem eher leichtgewichtige Ontologien wie kontrollierte Vokabulare eingesetzt. Zu den wichtigsten zählen die **Normdateien** (*authority files*). Ihre Aufgabe ist es, auf Grundlage einer Ontologie normierte Begriffe wie Namen von Personen, Körperschaften oder Sachbegriffe semantisch zu erschließen, zu publizieren und somit als eine gemeinsame Datenbasis im Sinne von LOD nutzbar zu machen, wie die von der Deutschen Nationalbibliothek betreute Gemeinsame Normdatei (GND) oder für Personendaten die Virtual International Authority File (VIAF). Normdaten spielen eine zentrale Rolle bei der Verlinkung heterogener Datenbestände der Digital Humanities. So können beispielsweise personenbezogene Informationen aus digitalen Editionen von historischen Texten (sehr anschaulich zu sehen bei Korrespondenzen) per GND auf zu diesen Personen vorhandenen biographischen und bibliographischen Informationen in anderen Datenbeständen verlinkt werden, solange man mit deren Begrifflichkeit von ›Person‹ einverstanden ist.

Das Conceptual Reference Model: Der Einsatz schwergewichtiger Ontologien in den Digital Humanities steckt hingegen eher noch in den Kinderschuhen. Als umfassendster und ausgereiftester Ansatz gilt das bereits seit 1996 entwickelte und als ISO-Standard formulierte Conceptual Reference Model (CIDOC CRM) des Internationalen Museumsrates ICOM. CIDOC CRM bezeichnet sich selbst als ›fachübergreifende Ontologie für die Museen im kultur- und naturhistorischen Bereich‹ (Lampe/Krause/Doerr 2010: 7), die als Application Ontology vor allem der vernetzbaren Museumsdokumentation dienen soll. So ist eine formulierte Zielsetzung die Schaffung einer transdisziplinären ›wissenschaftlichen *lingua franca*‹ (ebd.: 8). CIDOC CRM gründet sich damit auf dem Anspruch der informationswissenschaftlichen Ontologien, nämlich ein System zur Wissensrepräsentation zu schaffen, dessen Begrifflichkeiten in dem Gegenstandsbereich der Museumssammlungen weiträumig geteilt wird. Somit stellt CIDOC CRM zugleich eine Domain Ontology dar. Ein besonderer Anspruch von CIDOC CRM ist es zudem, logische Schlussfolgerungen zu ermöglichen, wie sie z. B. in der Provenienzforschung der Museen erfolgen.

CIDOC CRM stellt hierzu eine terminologische Ontologie mit ca. 80 Klassen und 130 bedingten Relationen zur Verfügung. Ihre zentralen Klassen sind Ereignis, Sache und Akteur. An einem abschließenden Beispiel soll das Konzept veranschaulicht werden. Das Beispiel modelliert ein bestimmtes Ereignis, nämlich den Erwerb der Sammlung ›Amoudruz‹ durch das Ethnographische Museum der Stadt Genf (Abb. 43).

Ein Studium der Dokumentation der CIDOC-CRM, dem auch dieses Beispiel entnommen wurde (Lampe/Krause/Doerr 2010) und von weiteren Anwendungsbeispielen sei zur Lektüre empfohlen.

Man sollte sich stets vor Augen führen, dass eine Ontologie eine Realität beschreibt, wie der oder die Modellierer, beeinflusst durch subjektive Weltbilder, diese Realität sehen und dass Ontologien (wie jedes Modell) eine komplexe, durchaus auch widersprüchliche Welt auf ausgewählte Eigenschaften reduzieren. Vor allem bei den Gegenstandsbereichen, mit denen sich Geistes- und Kulturwissenschaften beschäftigen, führt dies immer wieder zur Kritik an Ontologien. Beispielsweise entspricht die disjunkte Klassifizierung der Personen in Männer und Frauen weder biologischen Erkenntnissen noch spiegelt sie die aktuelle Gender-Debatte wider. Daher




Abb. 43 Beispiel-Modellierung nach CIDOC-CRM (nach Lampe/Krause/Doerr 2010)

sollte einer Ontologie ein Konsens innerhalb der betreffenden Fachcommunity (sog. *shared conceptualization*) zu Grunde liegen, der allerdings Aushandlungsprozesse zwischen den beteiligten Institutionen und Wissenschaftlern erfordert, die oft langwierig, aber für ein funktionierendes Semantisches Netz notwendig sind.

Da das Ontologie-Design ein komplexer, aufwendiger Prozess ist, ist es in der Regel ratsam, bereits existierende Ontologien als Grundlage zu nehmen. Diese können fachlicher Natur sein. So steht etwa der Begriff »Person« unserer Beispiel-Ontologie u. a. bereits in der GND-Ontologie (siehe unten) als IRI < <http://d-nb.info/standards/elementset/gnd#Person> > zur Verfügung. Oder sie sind eher darauf ausgelegt, die Relationen zwischen Klassen und Instanzen zu modellieren. Gerade für letzteres steht mit dem **Simple Knowledge Organization System (SKOS)** ein weiterer W3C-Standard zu Verfügung. SKOS beruht auf RDF und RDFS und ist damit zwar nicht so ausdrucksstark wie OWL, aber gut anwendbar für die Beschreibung und Verlinkung von leichtgewichtigen Ontologien wie kontrollierten Vokabularen, die für die Digital Humanities eine wichtige Rolle spielen. SKOS bietet die Grundlage zur Modellierung einer ausdifferenzierten Klassenhierarchie, von Verwandtschaftsbeziehungen zwischen Begriffen (wie z. B. A ist eine Verallgemeinerung von B) und kann Synonyme behandeln. Die schon erwähnte GeoNames-Ontologie beispielsweise greift auf Konzepte von SKOS zurück.

Literatur

- Berners-Lee, Tim: »The World Wide Web: A very short personal history« (1998), <https://www.w3.org/People/Berners-Lee/ShortHistory.html> (31.10.2016).
- Berners-Lee, Tim/Hendler, James/Lassila, Ora: »The Semantic Web«. In: *Scientific American* 284/5 (2005), 34–43.
- Gruber, Thomas: »A Translation Approach to Portable Ontology Specifications«. In: *Knowledge Acquisition* 5/2 (1993), 199–220.

- Gruber, Tom: »Ontology«. In: Ling Liu/M. Tamer Özsu (Hg.): *Encyclopedia of Database Systems*. New York 2009, 1963–1965.
- Guarino, Nicola: »Formal Ontology and Information Systems«. In: Nicola Guarino (Hg.): *Formal Ontology in Information Systems. Proceedings of the first international conference (FOIS'98), June 6–8, Trento, Italy*. Amsterdam/Washington, DC/Tokyo (1998), 3–15.
- Lampe, Karl-Heinz/Krause, Siegfried/Doerr, Martin (Hg.): *Definition des CIDOC Conceptual Reference Model*. Berlin 2010.
- Lassila, Ora/McGuinness, Deborah: »The Role of frame-based Representation on the Semantic Web«. In: *Linköping Electronic Articles in Computer and Information Science* 6 (2001).
- Meixner, Uwe: *Einführung in die Ontologie*. Darmstadt 2004.
- Noy, Natalya/McGuinness, Deborah L.: »Ontology Development 101: A Guide to Creating Your First Ontology«, http://protege.stanford.edu/publications/ontology_development/ontology101-noy-mcguinness.html (31.10.2016).

Malte Rehbein

III Digitale Objekte

12 Digitalisierung

Erste Grundlage der computer-gestützten Untersuchung kultureller Artefakte ist ein digitales **Abbild** des (analogen) Originals. Handelt es sich hierbei um ein optisches, d. h. auf Licht basierendes, für die sehende Betrachtung erstelltes Abbild, so sprechen wir bei diesem Transformationsprozess vom Analogen ins Digitale von einer **Bilddigitalisierung**. In der Regel erfolgt diese Transformation durch bildgebende Verfahren, die durch dafür entwickelte Geräte, in unseren Anwendungsfällen zumeist Digitalkameras und Scanner, vorgenommen werden.

Ein digitales Abbild eines Objekts nennen wir auch ein **Digitalisat** desselben. Digitalisate ersetzen heute häufig Funktionen in Forschung und Lehre, die früher häufig den Originalen vorbehalten waren. Dennoch ist die Nutzung von Abbildern an Stelle der Originale keine Neuerung des digitalen Zeitalters. Gerade im Bereich der Lehre, aber auch der Forschung verzichtet man bereits seit langem aus pragmatischen und Kostengründen oft auf das Studium des Originals und greift stattdessen auf Abbilder, etwa in Form von Dia-Positiven, Mikrofilmen oder Reproduktionen zurück. Diese Abbilder erfüllen dann als **Surrogat** (von lat. *surrogare*: an die Stelle eines anderen wählen) den Zweck des Originals.

Mit der Einführung der **Bilddigitalisierung** ändern sich aber die Rahmenbedingungen maßgeblich. Frühere Formen von Abbildungen waren selbst gegenständlich (materiell), und der Zugang zu ihnen war an ihre physische Existenz und Zugänglichkeit gebunden. Um sie zu verbreiten, mussten wiederum Kopien dieser Abbilder (oder weitere Abbildungen des Originals) angefertigt werden. Hierdurch entstehen direkte Kosten (Material, Arbeitszeit); außerdem besteht bei analoger Reproduktion die Gefahr des Informationsverlustes durch Verschlechterung der Qualität bei wiederholter Kopie, wie man sich bei der Xerox-Kopie leicht vorstellen kann.

Digitalisate sind an sich immateriell; als Rastergrafiken (s. Kap. 12.1) sind sie lineare Abfolgen von Bits. Zwar erfolgt ihre Speicherung in der Regel auf einem physikalischen Medium, doch ist diese Speicherung grundsätzlich medienunabhängig möglich. Es ist denkbar (freilich nicht sehr sinnvoll), die Bitfolge (Bitstream) eines Digitalisats auf Papier zu notieren und auf diese Art weiterzugeben und zu bewahren. Grundsätzlich ist Übertragung oder Kopie eines Digitalisats verlustfrei und identisch möglich und macht einen wesentlichen Vorteil der Digitalisierung gegenüber analogen Verfahren der Reproduktion aus.

Neben der verlustfreien Kopie und neuen Formen des Zugangs sind die Möglichkeiten der computergestützten Vernetzung und Verarbeitung von Digitalisaten der größte Fortschritt der Digitalisierung im Vergleich zu traditionellen Methoden der Reproduktion und der Arbeit am und mit dem Original. Häufig ist die hier angesprochene Bilddigitalisierung aber nur der erste Schritt oder besser: eine grundlegende Voraussetzung für eine weitere Verarbeitung. In Kapitel 12.4 werden Verfahren der Transkription erläutert, mittels derer der in digitalen Bildern transportierte Text erfasst und extrahiert und seinerseits zu digitalen Daten wird. Für Forschung, die auf Textmaterial beruht, und dies gilt zumindest anteilig für alle Disziplinen der Kulturwissenschaften, ist dieser Schritt elementar. Grundlage für diese Extraktion von Text ist aber die Schaffung eines digitalen Abbildes des Trägers dieser Texte, sei er ein Buch, eine historische Zeitung, eine Handschrift auf Papier, Pergament oder Papyrus oder eine Inschrift auf einem Grabstein usw.

Analog-Digital-Wandlung: Durch Digitalisierung erzeugen wir ein digitales Ab-

bild von einem in der Regel materiellen, analogen Objekt. Diese Transformation erfolgt Technologie-gestützt durch sogenannte **Analog-Digital-Wandler**, die mittels physikalischer Sensoren das Objekt messen und die Messdaten in einer geeigneten Form speichern. Gängige Beispiele für Analog-Digital-Wandler sind Digitalkameras, die ein analoges Signal (Licht) in eine digitale Rastergrafik umsetzen, digitale Diktiergeräte, die akustische Signale in digitale Audiodaten transformieren, oder TV-Tuner für den Empfang analoger Fernsehsignale am Computer.

Das analoge Signal (von gr. *analogos*: verhältnismäßig) als Input der Digitalisierung besitzt unendlich viele Werte in beliebig feiner Abstufung; es ist zeit- und wertekontinuierlich, d. h. zwischen zwei Messpunkten, seien sie auch noch so dicht beieinander, befinden sich unendlich viele weitere Werte. Das digitale Signal (von lat. *digitus*: Finger) als Ziel der Digitalisierung ist hingegen zeit- und wertediskret, es stehen nur endlich viele, definierte Werte zur Verfügung. Zur Diskretisierung des analogen Signals wird dessen Messbereich daher in eine bestimmte Anzahl aneinander grenzender Intervalle (Wertebereiche) unterteilt und jedem dieser Intervalle ein diskreter Zahlwert (Code) zugeteilt (Quantisierung). Die Größe dieser Intervalle wird **Auflösung** der Digitalisierung genannt (im Schaubild ist dies die y-Achse); je kleiner die Intervalle, desto höher oder besser die Auflösung, denn es werden mehr Details des analogen Signals in das digitale Abbild übernommen. Die Häufigkeit, mit der das analoge Signal pro Zeiteinheit gemessen (abgetastet) wird, ist das zweite Maß für die Qualität der Digitalisierung, sie wird **Abtastrate oder Samplingrate** genannt (im Schaubild ist dies die x-Achse).




Abb. 44 Analog-/Digitalwandlung mit zeitlicher- und Wertequantisierung des analogen Signals

Grundsätzlich kann man jedes analoge Signal digitalisieren, das durch physikalische Sensoren gemessen werden kann. Für die Digital Humanities sind dabei vor allem akustische und optische Sensoren von Interesse, die Ton- bzw. Bilddigitalisierung ermöglichen. Die Bilddigitalisierung wird im Folgenden behandelt. Für bildbasierte Quellen z. B. in der Kunstgeschichte oder Geschichte hat dies naheliegendermaßen eine hohe Bedeutung. Aber auch als Grundlage zur Erzeugung von elektronischen Texten auf Basis materieller Textträger ist die Bilddigitalisierung ein wichtiger Schritt, denn Text an sich ist eine immaterielle Größe, die von seinem Schreiber oder Drucker auf einem Trägermaterial (Papier, Pergament, Papyrus, Stein), das als Bild betrachtet werden kann, manifestiert wurde. Der Text muss daher zunächst von seinem Träger (Dokument, Inschrift) abstrahiert werden, was der Mensch durch das Lesen implizit tut. Dem Computer aber muss dieser Schritt explizit beigebracht werden, bevor Texte als Zeichenketten digital vorliegen, die verarbeitet werden können. Hierauf wird in Kapitel 12.4 eingegangen.

12.1 | Grundlagen digitaler Bilder

Wir kennen zwei prinzipielle Möglichkeiten, um Bilder als digitale Daten zu repräsentieren. Die erste ist ihre Repräsentation als zweidimensionale Matrix der Bildpunkte (Pixel), aus denen sich das Bild zusammensetzt (Rastergrafik, Bitmap), die zweite ist eine Erklärung, wie das Bild auf Basis elementarer Zeichenroutinen erzeugt werden kann (Vektorgrafik). Beide Repräsentationsarten digitaler Bilder haben in den Digital Humanities ihre Relevanz; durch Digitalisierung werden jedoch vornehmlich Rastergrafiken erzeugt.

Rastergrafiken

In der Rastergrafik wird jeder Bildpunkt durch einen Wert beschrieben, der den Farbwert des Bildpunktes repräsentiert. Die Adressierung einzelner Bildpunkte erfolgt über zweidimensionale Koordinaten (x- und y-Wert); als Referenzpunkt wird in der Regel der Ursprung des Koordinatensystems links oben angesetzt. Abbildung 45 zeigt eine schwarz-weiße Rastergrafik, die nur die Werte 0 (für weiß) und 1 (für schwarz) kennt.

Rastergrafiken werden üblicherweise anhand von zwei Werten gemessen: ihrer Bildgröße und ihrer Farbtiefe.




Abb. 45 Schematisches Beispiel einer monochromen Rastergrafik

Die **Bildgröße** wird entweder als Wertepaar beschrieben, das die Anzahl der Bildpunkte in der Horizontalen und in der Vertikalen (bzw. der Spalten- und Zeilenzahl der Tabellierung) repräsentiert, oder sie wird als Zahlenwert angegeben, der durch Multiplikation der Spalten- und Zeilenzahl entsteht. Bei letzterem wird zwar die Gesamtzahl der Pixel ermittelt, aber das Seitenverhältnis geht verloren. So hat der Ausschnitt rechts in Abbildung 45 etwa eine Größe von 8×8 bzw. 64 Pixeln; die gleiche Pixelzahl würde aber zum Beispiel auch mit einem Bild der Größe 4×16 erreicht.

Die **Farbtiefe** bestimmt, wie viele Helligkeits- und Farbwerte zur Beschreibung jedes einzelnen Pixels zur Verfügung stehen. Das Beispiel oben kennt nur zwei Farbwerte, schwarz und weiß, und hat damit eine Farbtiefe von 1, da mit einem Bit zwei Zustände repräsentiert werden können (mathematisch gilt: $\log_2 2 = 1$). In der Regel haben digitale Bilder, die uns in den Geistes- und Kulturwissenschaften begegnen, jedoch eine deutlich größere Farbtiefe. Schwarz/weiß-Bilder besitzen genau einen **Farbkanal**; man spricht hierbei in der Ausdifferenzierung der Farb- bzw. Helligkeitswerte von **Graustufen**. Bei einer Farbtiefe von 8 Bit sind es $2^8 = 256$, bei 16 Bit sind es $2^{16} = 65.536$ verschiedene Werte, die jeder Pixel annehmen kann. Digitale schwarz/weiß-Bilder begegnen uns in den Geistes- und Kulturwissenschaften nicht nur bei der Digitalisierung originär schwarz/weißer Objekte (etwa Fotografien), sondern auch aus früheren Digitalisierungskampagnen, als etwa Farbscanner, vor allem großformatige, deutlich teurer waren als gegenwärtig und der Speicherbedarf von Farbbildern die damals zur Verfügung stehenden Speicherkapazitäten gesprengt hätte (so noch in den 1990er Jahren).

Heute ist die Bilddigitalisierung in Farbe das gängige Verfahren. Zur Repräsentation der Farben solcher Bilder existieren verschiedene Modelle, von denen hier nur das **RGB-Farbmodell** vorgestellt werden soll, bei dem die Farben aus den drei Grundfarben (Primärfarben) Rot, Grün und Blau (RGB) additiv zu Mischfarben zusammengesetzt werden. Mischt man Rot und Grün in gleichem Verhältnis, so erhält man die Mischfarbe Gelb; Rot und Blau ergeben Magenta; Blau und Grün ergeben Cyan. Die Addition aller drei Grundfarben führt zu Weiß; schaltet man alle aus, so bleibt Schwarz. Das RGB-Farbmodell ist damit an das menschliche Auge angelehnt, das drei Rezeptoren für den kürzeren, mittleren und längeren Wellenbereich besitzt.

Bei der Repräsentation eines Bildes mittels des RGB-Farbmodells werden daher drei Farbkanäle verwendet, für die entsprechend den schwarz/weiß-Bildern gilt, dass die Anzahl der Bits die unterschiedlichen Abstufungen des Tonwerts pro Farbkanal angeben. Da die kleinste Einheit für die Farbtiefe 1 Bit pro Farbkanal ist, benötigt ein Farbbild mindestens 3 Bit und erlaubt damit $2^3 = 8$ verschiedene Farbwerte, diese sind: Schwarz, Rot, Grün, Blau und die Mischfarben Cyan, Magenta, Gelb und Weiß. Für gegenwärtige Digitalisierungsprojekte sind Farbtiefen von 24 Bit (8 Bit je Kanal) und 48 Bit (16 Bit je Kanal) üblich. Sie erlauben eine Differenzierung von 16.777.216 bzw. 281.474.976.710.656 Farbwerten. Neben dem RGB-Modell existieren andere Farbmodelle, etwa das subtraktive CMYK-Modell, das von Druckern verwendet wird.

Da das Produkt aus Bildgröße und Farbtiefe den Speicherbedarf einer Rastergrafik determiniert, können die Datenmengen, die bei Digitalisierungsprojekten entstehen, gewaltig sein. Trotz des im Moore'schen Gesetz beschriebenen ständigen Anstiegs von Rechenleistung und (physischer) Speicherkapazität, verursachen diese Datenmengen Kosten und Arbeit, die sich nicht nur aus den reinen Kosten für die Anschaffung von Speichermedien, sondern insbesondere aus deren Betrieb inkl. Sicherung

und ggf. notwendiger Migration der Daten in neue Formate sowie dem Zugänglichmachen (Übertragungszeit) dieser Daten ergeben.

Bildkompression: Daher wendet man Kompressionsalgorithmen an, um die Größe der Dateien im Speichermedium zu reduzieren. Dabei ist zwischen verlustfreier und verlustbehafteter Kompression zu unterscheiden. Die verlustbehaftete Kompression bemüht sich, als überflüssig betrachtete Information aus den Daten zu eliminieren und somit die Datenmenge zu verkleinern. Was überflüssig sein kann, lässt sich am besten am Beispiel der Kompression von Musikdateien erläutern. Hier wird zu Grunde gelegt, dass das menschliche Ohr in der Lage ist, Töne nur innerhalb eines bestimmten Frequenzbereichs wahrzunehmen und die Töne auch nur bis zu einem bestimmten Grad auszudifferenzieren. Damit können Nuancen in der Frequenzdifferenzierung zusammengefasst und Frequenzen außerhalb des Bereichs subjektiver menschlicher Wahrnehmung, die aber dennoch von den Instrumenten produziert und von Aufnahmegegeräten erfasst wurden, eliminiert werden.

Für die Kompression von Bilddaten gilt analog: Es wird zusammengefasst bzw. weggelassen, was vom menschlichen Auge nicht mehr ausdifferenziert werden kann bzw. was über die Aufnahmefähigkeit der menschlichen Bildwahrnehmung hinausgeht (man sagt, die Kompression ist dann »visuell verlustfrei«). Im Gegensatz zur Kompression von Audiodaten, ist dies allerdings nicht explizit formuliert, sondern ist geleitet von der Frage, was für einen bestimmten Anwendungsfall tolerabel ist bzw. ob in einem bestimmten Kontext der Informationsverlust unmerklich und ästhetisch erträglich bleibt. So wird bei der Anwendung von Kompressionsverfahren für Bilder in der Regel nicht davon ausgegangen, dass der menschliche Betrachter sich diese Bilder mit einer Lupe anschaut oder beliebig auf dem Bildschirm vergrößert.

Bei der **verlustfreien Kompression** geht keine Information verloren, da die Daten lediglich durch Zusammenfassung von Redundanzen anders organisiert werden. Weist zum Beispiel ein Bild eine große weiße Fläche oder ein anderes, wiederkehrendes Muster auf, so wird der Kompressionsalgorithmus dies erkennen und lediglich die Information über Gestalt und Position dieser Fläche abspeichern anstatt jeden einzelnen Pixel. Dies ist zwar mit Rechenaufwand verbunden, erfordert in der Regel aber deutlich weniger Speicherplatz, denn eine Anweisung etwa der Form »wiederhole den folgenden Pixel 10.000 Mal« ist kürzer als 10.000 Mal den gleichen Pixel zu speichern. Da diese Operation umkehrbar ist, d. h. die Beschreibung von Gestalt und Position der fraglichen Fläche wieder in exakt die ursprüngliche Rasterung überführt werden kann, ist die Kompression verlustfrei.

Zwar können verlustfrei komprimierte Bilder wieder exakt (eben verlustfrei) in das Original zurückgeführt werden, dies geht aber nur dann, wenn der Kompressionsalgorithmus offengelegt, dokumentiert und auch in der Zukunft programmiert werden kann bzw. die zur Dekompression notwendige Software zur Verfügung steht. Dies ist gerade bei kommerziellen Kompressionsalgorithmen nicht unbedingt der Fall; selbst bei offengelegten Standards stellt dies einen Unsicherheitsfaktor für die Zukunft dar, weswegen die Praxisregeln »Digitalisierung« der Deutschen Forschungsgemeinschaft DFG die auf Dauer ausgerichtete Erstellung und Speicherung eines unkomprimierten **Bildmasters** empfehlen, von dem dann auch in der Zukunft andere Formate erzeugt werden können.

	Formate (Auswahl)	Übertragung / Speicher	Anwendungen
Verlustbehaftete Kompression	jpeg, jpeg2000, gif, png	Netz (statische Bilder)	Betrachtung mit menschlichem Auge
Verlustfreie Kompression	tiff	Netz (Kacheltechnik)	Bildanalyseverfahren
keine Kompression	tiff	Speicherung als Digitalisierungsmaster	Langzeitarchivierung

Tab. 8 Bildkompression (Überblick)

Das Bildformat TIFF

Unter der Menge der zur Verfügung stehenden Bildformate, hat sich das **Tagged Image File** Format (kurz: TIFF, auch TIF) als Quasi-Standard durchgesetzt und wird von der DFG für den digitalen Bildmaster empfohlen. Die Möglichkeiten, die TIFF bietet, sind relativ komplex (so lässt sich etwa TIFF als Container für andere Bildformate verwenden oder es können verlustbehaftete Kompressionsalgorithmen unterstützt werden), und nicht alle werden von allen Programmen unterstützt. Als kleinstes gemeinsames Vielfaches, das alle Programme, die TIFF erzeugen oder verarbeiten, unterstützen sollen, ist das *Baseline TIFF* spezifiziert, das verlustfreie Kompression, Kachelung und das RGB-Farbmodell bis zu einer Farbtiefe von 24 Bit unterstützt.

TIFF dokumentiert einige technische Parameter des Bildes, wie etwa die Bildgröße(n) und ob und wenn ja welcher Kompressionsalgorithmus verwendet wurde, im sogenannten Image File Directory, eine Art Metadaten des digitalen Bildes. Diese Angaben sind auch bei der Beurteilung der Qualität von Digitalisaten von Interesse. Über die Baseline hinaus bietet TIFF sogenannte *Extensions*, deren Unterstützung aber nicht notwendigerweise durch jede Software gewährleistet ist, ebenso wie die Verwendung von *private Tags* zur Beschreibung von Metadaten innerhalb der Bilddatei.

Eine unkomprimierte Bilddatei kann in andere Formate übertragen werden, die anderen Anwendungszwecken dienen als die der Langzeitarchivierung, wofür sich die unkomprimierte Rastergrafik anbietet. Cohen und Rosenzweig (2005, 97–98) führen etwa das Beispiel von Dorothea Langes Fotografie *Migrant Mother* an, deren Digitalisat die Library of Congress in Washington im unkomprimierten TIFF-Format archiviert, das auf Grund seiner Größe von 6.849×8.539 Pixeln und einer Farbtiefe von 8 Bit (256 Graustufen) 55 Megabyte beansprucht. Online wird jedoch eine Fassung der *Migrant Mother* dem Benutzer zur Betrachtung angeboten, die im JPEG-Format lediglich 163 Kilobyte beansprucht, etwa 0,12 % der ursprünglichen Größe, die sich, neben dem geringeren Speicherbedarf auf dem Webserver (im Gegensatz zum internen Archivserver), vor allem in der deutlich schnelleren Ladezeit und dem Traffic der Website bemerkbar macht.



Abb. 46 Qualitätsverlust im jpeg durch Kompression

Die Joint Photographic Experts Group (**JPEG**, sprich: »JAY-Peg«) beschreiben Methoden zur in der Regel verlustbehafteten Kompressionen für digitale Bilder, die unter anderem im Grafikformat JPEG File Interchange Format (JFIF) Verwendung finden, die gemein gebräuchlich nicht ganz korrekt »JPEG-Bilder« genannt werden. JPEG erlaubt verschiedene Kompressionsgrade, bei denen, vereinfacht gesagt, eine höhere Komprimierung eine kleinere Dateigröße bewirkt, aber auch einen größeren Informations- und damit je nach Anwendungsfall höheren Qualitätsverlust nach sich zieht (s. Abbildung 46). JPEG wurde vor allem zur Speicherung von Fotografien oder fotoähnlicher Bilder entwickelt.

Das verbesserte Nachfolgeformat JPEG 2000, ebenfalls von der Joint Photographic Experts Group, findet seit einiger Zeit ebenfalls Verwendung im Bereich der kulturwissenschaftlichen Digitalisierung, konnte sich bislang noch nicht durchsetzen. Andere verbreitete Bildformate sind etwa das Graphics Interchange Format (GIF) und Portable Network Graphics (PNG), die auf Grund ihrer hohen, verlustfreien, Kompressionsrate neben JPEG die am häufigsten verwendeten Bildformate im Internet sind. Eine Alternative zur Archivierung von Bildmastern stellen sie wie auch JPEG und JPEG 2000 jedoch nicht dar.

Vektorgrafiken

Beispiel Vektorgrafik / SVG

Um etwa ein Rechteck zu zeichnen, können folgende Informationen beschrieben werden: eine Anweisung, dass es sich um das grafische Primitiv vom Typ Rechteck handelt; die Position der linken oberen Ecke des Rechtecks; seine Breite und Höhe; Linienstärke und -farbe, mit der es gezeichnet werden soll; die Füllung des Rechtecks.

Das folgende Code-Beispiel im XML-basierten SVG-Format (scalable vector graphics) zeichnet mit einer schwarzen Linie der Stärke 20 Pixel ein grün ausgefülltes Rechteck, das 500 Pixel breit und 200 Pixel hoch ist und um jeweils 100 Pixel vom Koordinatenursprung nach rechts unten versetzt wird:

```
<svg>
  <rect x="100" y="100" width="500" height="200" fill=
    "green" stroke="black" stroke-width="20px"/>
</svg>
```

Aus solchen Anweisungen lassen sich komplexe Grafiken bis zu fotorealistischen Szenen erzeugen.

Typische Anwendungsbereiche in den Digital Humanities für Vektorgrafiken sind etwa zwei- und dreidimensionale Modelle oder die Darstellung von Geoinformationen. Im Gegensatz zu Rastergrafiken beschreiben Vektorgrafiken, wie ein Bild auf Basis einfacher Zeichenroutinen, sogenannter **grafischer Primitive**, zusammengesetzt ist. Dazu zählen u. a. Punkte, Linien, Polygone, Kreise und Ellipsen, außerdem Informationen über Farbe, Strichform und Füllung sowie Operationen auf den grafischen Primitiven wie etwa Drehungen und Spiegelungen. Grundlage zur Beschreibung der Zeichenroutinen ist ein zweidimensionales Koordinatensystem und die so-

genannte z-Ordnung, die festlegt, welches Objekt der Grafik bei Überlappung über dem anderen erscheint. Neben zweidimensionalen existieren auch dreidimensionale Vektorgrafiken.

Raster- und Vektorgrafiken im Vergleich

Für Computerbildschirme ist die Vektorgrafik das ältere Verfahren. Ähnlich einem Oszilloskop setzten frühe Vektorbildschirme jedes Bild per Kathodenstrahlen aus einzelnen Linien (daher der Begriff »Vektor«) zusammen, die Befehle hierzu (Ursprung des Vektors, Länge und Richtung) erhielten sie vom Prozessor. Eine Rastergrafik ermöglichte hingegen den zeilenweisen Aufbau eines Bildes.

Ein wesentlicher Unterschied zwischen den beiden Repräsentationsarten von digitalen Bildern tritt bei der Skalierung, d. h. bei der Größenänderung des Bildes zu Tage. Bei Rastergrafiken wird durch die Skalierung die Bildauflösung geändert. Das heißt, dass aus einer vorgegebenen Rastergrafik ein neues Bild mit einer höheren (oder niedrigeren) Anzahl von Bildpunkten erzeugt wird. Möchte man beispielsweise eine Rastergrafik der Bildgröße 100×100 auf 200×200 vergrößern, erzeugt man dadurch viermal so viele Bildpunkte. Da bei Rastergrafiken der Pixel die kleinste Informationseinheit bildet, müssen die Pixel des Originalbildes für die Vergrößerung wiederholt oder interpoliert werden. Es entstehen im Grunde größere Pixel. Möchte man das ursprüngliche Bild etwa auf 50×50 verkleinern, erzeugt man nur noch ein Viertel der Bildpunkte, wodurch Bildpunkte und damit Information unweigerlich verloren geht. Daher ist die Skalierung von Rastergrafiken in der Regel mit einem Qualitätsverlust verbunden. Bei der Skalierung einer Vektorgrafik hingegen werden die grafischen Primitiven, aus denen sich die Vektorgrafik zusammensetzt, durch geometrische Transformation gestreckt. Die Skalierung von Vektorgrafiken ist damit verlustfrei und umkehrbar.

Ein zweiter Unterschied zeigt sich im Speicherbedarf. Bei unkomprimierten Rastergrafiken berechnet sich der Speicherbedarf aus dem Produkt aus Bildgröße und Farbtiefe. Er ist grundsätzlich unabhängig vom Bildinhalt und von daher gut kalkulierbar. Kompressionsalgorithmen für Rastergrafiken beruhen in ihrer Effektivität hingegen sehr wohl auf dem dargestellten Bild. Bessere Kompressionsraten und damit niedrigeren Speicherbedarf erreichen Bilder mit vielen wiederkehrenden Mustern. Der Speicherbedarf von Vektorgrafiken ist unabhängig von Bildgröße und Farbtiefe, sondern steigt mit der Komplexität des dargestellten Bildes.

Die Wiedergabe von Vektorgrafiken auf dem Bildschirm führt zu einem Rechenaufwand, denn das Bild muss aus den grafischen Primitiven, die in der Vektorgrafik beschrieben sind, für jede Wiedergabe errechnet werden (**Rendering**). Dieser Rechenaufwand ist abhängig von der Komplexität der Grafik und daher zunächst unbekannt. Rastergrafiken haben in der Regel einen geringeren Wiedergabeaufwand, der zudem konstant und inhaltsunabhängig ist.

Eine Umwandlung einer Rastergrafik in eine Vektorgrafik (**Vektorisierung**) ist in der Regel sehr aufwendig, obwohl es hierfür viele Anwendungsgebiete gibt. Eine Vektorgrafik lässt sich hingegen jederzeit durch Rendering in eine Rastergrafik beliebiger Größe umwandeln, was auch Voraussetzung für die Anzeige auf modernen Bildschirmen ist.

Rastergrafiken und Vektorgrafiken lassen sich auf unterschiedliche Art und Weise manipulieren. Bei Rastergrafiken kommen hierfür in der Regel Bildbearbeitungspro-

gramme zum Einsatz, die eine Fülle von Möglichkeiten bieten, die Grafiken zu verändern, die allerdings – naturgemäß – stets auf Rechenoperation auf den digitalen Rasterdaten beruhen. Möchte man ein Detail aus einem digitalen Foto entfernen, so ist hierfür in der Regel ein recht hoher kreativer Aufwand sowie Rechenaufwand erforderlich, insbesondere müsste in diesem Fall der Hintergrund des zu entfernenden Details aus nicht vorhandener Information hochgerechnet werden. Bei Vektorgrafiken würde man hingegen schlicht die Anweisungen, die dieses Detail beschreiben, streichen.

12.2 | Bilddigitalisierung

Digitalisierung ist ein bildgebendes Verfahren und bedeutet die Erzeugung eines digitalen Abbildes eines oder mehrerer realer Objekte. Im Allgemeinen messen bildgebende Verfahren physikalische Größen der Objekte, die sie abbilden (siehe oben). Bei den optischen Verfahren wie die der Bilddigitalisierung ist dies das Licht, das von den Objekten reflektiert wird. Bildgebende Verfahren an sich sind lange bekannt; schon Aristoteles beschrieb das Prinzip einer Lochkamera, bei der Licht durch eine Öffnung eingefangen wurde und auf einer Projektionsfläche ein (auf dem Kopf stehendes) Abbild erzeugte. Man denke zudem etwa an die im 13. Jahrhundert von Astronomen zur Beobachtung eingesetzte *Camera obscura* (lat. dunkle Kammer), an Fernrohre oder Mikroskope. Diese Instrumente erzeugen ein optisches Abbild der Realität, halten allerdings das Bild nicht dauerhaft fest, sondern projizieren es für die unmittelbare Betrachtung durch das menschliche Auge. Diese Bilder dienten, im Falle der Lochkamera, unter anderem als Vorlage für die Anfertigung von realitätsgetreuen Zeichnungen (Abbildern) auf Papier.

Mit der Erfindung der Fotografie in der ersten Hälfte des 19. Jahrhunderts, durch die das durch die Optik der Kamera eingefangene, reflektierende (transiente) Licht eine chemische Reaktion auf lichtempfindlichem Fotopapier erzeugt, welche dauerhaft (persistent) fixiert werden kann, wurde der manuelle Prozess des Übertragens des durch Licht hervorgebrachten Abbildes der Realität in ein anderes Medium (Papier) erstmalig automatisiert.

Digitalisierung funktioniert nun ähnlich dieser analogen Fotografie, nur dass kein Fotopapier verwendet wird, sondern Bildsensoren das Signal, also das durch die Optik des Instruments (Kamera, Scanner) reflektierte Licht der realen Objekte, erfassen und in digitale Daten umwandeln, die wiederum als Rastergrafiken dauerhaft auf digitalen Medien gespeichert werden können.

Verfahren

Für die Bilddigitalisierung in den Kulturwissenschaften kommen vor allem zwei Gruppen bildgebender Instrumente zum Einsatz: Digitalkameras und Scanner. Dennoch darf man nicht vergessen, dass auch vor dem digitalen Zeitalter Verfahren angewandt wurden, um Abbilder realer Objekte ortsunabhängig bzw. ohne direkten Zugang zum Objekt bzw. Besitz derselben in Forschung und Lehre zu verwenden. Zeichnungen, (analoge) Fotografien oder Fotokopien können gedruckt und somit in Buchform verbreitet werden. Insbesondere Fotografien halten in Vervielfältigung als Abzug oder Dia-Positiv Einzug in Bildarchive, oder es werden hochwertige optische

Reproduktionen etwa von mittelalterlichen Handschriften in den Tafelwerken der Paläographie verwendet.

Mikroformen (Mikrofiche, Mikrofilm) sind stark verkleinerte analoge Abbildungen von gedruckten Vorlagen auf Polyester-basiertem Filmmaterial. Da man davon ausgeht, dass die Haltbarkeit dieses Materials bis zu 500 Jahre beträgt, werden Mikroformen seit ihrer Erfindung im 19. Jahrhundert vor allem für **revisionssichere Langzeitarchivierung** verwendet (Backup-Funktion). Stellvertretend als für das Original zu benutzendes Surrogat leisten sie zudem bei der Sekundärnutzung (Überprüfen von Stellen, Vorlage zur editorischen Transkription, etc.) einen Beitrag, um ein wertvolles Objekt wie etwa eine licht- und fettempfindliche mittelalterliche Handschrift zu schützen. Kritiker der Digitalisierung von Kulturgut stellen die nachgewiesene, lange Haltbarkeit von Mikroformen immer wieder der noch nicht abschließend beantworteten Frage nach der Langzeitverfügbarkeit digitaler Daten gegenüber. Dabei betonen sie auch die technologische Unabhängigkeit der Mikroformen und stellen dies als einen wesentlichen Vorteil im Vergleich zur schnelllebigen Entwicklung von Computertechnologie dar.

Neben ihrer archivalischen Funktion bieten Mikroformen außerdem die Möglichkeit der (allerdings qualitätsmindernden) Vervielfältigung. So kann zum Beispiel eine ganze Jahresausgabe einer Tageszeitung in Kleinstformat verschickt und gelagert werden. Mikroformen sind im Vergleich zur abgebildeten Vorlage sehr klein (daher der Name). Daher ist zum Betrachten ein spezielles Lesegerät erforderlich. Da Mikroformen weiterhin Verwendung finden und längst nicht alle Mikroformen digitalisiert wurden, finden sie sich nebst ihrer Lesegeräte in Bibliotheken und Archiven.

Mikroformen können durch spezielle Mikrofilm- oder Mikrofiche-Scanner digitalisiert und damit digitale Daten ohne Rückgriff auf das (unter Umständen nicht mehr existierende Original) erzeugt werden. Dieser Prozess ist weitgehend automatisierbar. Dabei kann allerdings die Qualität dieser Digitalisierung bestenfalls genauso gut sein wie die ursprüngliche Verfilmung auf Mikroform, die jedoch unter bestimmten Umständen wiederum von besserer Qualität sein könnte als das Original heute, das seit dem Zeitpunkt der Mikroverfilmung beschädigt oder verloren gegangen sein könnte.

Digitalkameras arbeiten im Wesentlichen wie analoge Kameras, nur dass an Stelle des lichtempfindlichen Films ein elektronischer Bildsensor (meist CCD-Sensoren: Charge-coupled Device) tritt. Der Standardaufbau einer Fotokamera besteht aus einer Öffnung (Blende), vor der eine oder mehrere optische Linsen (Objektiv) angebracht sind, die das einfallende Licht bündeln und das Scharfstellen (Fokussieren) des gesamten Bildes oder eines Ausschnittes ermöglichen.




Abb. 47 Schematischer Aufbau einer Digitalkamera

Die wesentlichen Parameter, die entweder von der Kamera automatisch berechnet oder vom Benutzer manuell eingestellt werden, sind die Fokussierung (Anpassung der Optik an die Entfernung zwischen Objekt und Kamera) sowie die Größe der Blendenöffnung (beeinflusst die Schärfentiefe) und die Verschlusszeit (regelt die Dauer der Belichtung des lichtempfindlichen Films oder Bildsensors). Darüber hinaus bestimmt die Brennweite des Objektivs den Aufnahmewinkel.

Durch Betätigen des Auslösers der Kamera öffnet sich die Blende in der eingestellten Weite und lässt das Licht durch das Objektiv für die Dauer der eingestellten Verschlusszeit auf den elektronischen Bildsensor. Grundsätzlich werden zwei Sensortypen unterschieden: Flächensensoren für handelsübliche Digitalkameras und Zeilensensoren für spezielle Scannerkameras.

One-Shot-Sensoren registrieren gleichzeitig die drei Grundfarben der additiven Farbmischung (Rot, Grün und Blau). Der Chip an sich arbeitet monochrom, d. h. er kann nur hell oder dunkel, nur schwarz oder weiß sehen. Daher wird eine Farbfilter-schicht benötigt, die das Licht in seine Spektralbestandteile zerlegt. Three-Shot-Sensoren nehmen die drei Grundfarben nacheinander auf. Sie benötigen daher jeweils einen Filter für rot, grün und blau und setzen das Farbbild anschließend zusammen. Zeilensensoren werden in speziellen Scannerkameras eingesetzt, die, ähnlich wie ein Flachbettscanner, das Bild zeilenweise abtasten.

Scanner: Scanner sind allgemein Datenerfassungsgeräte, die Objekte systematisch, nach vorgegebenen Mustern oder Rastern abtasten (von engl. *to scan*: untersuchen) und das in diesem Verfahren durch Bildsensoren aufgenommene analoge Signal in digitale Form umwandeln. Scanner existieren in vielfältigen Formen und Anwendungsgebieten (so etwa in der Medizin), im Kontext der Geisteswissenschaften interessieren uns vornehmlich (allerdings nicht ausschließlich) zunächst die verschiedenen Ausprägungen der Bildscanner.

Scanner arbeiten in der Regel nach folgendem Prinzip: Die Bildvorlage wird beleuchtet, und das reflektierte Licht wird über eine Stablinse, welche das reflektierte Licht bündeln und das Streulicht eliminieren soll, an einen optoelektronischen Zeilensensor geleitet. Die analogen Lichtsignale werden vom Analog-Digital-Wandler pixelweise in Digitalsignale umgewandelt, während gleichzeitig entweder die Vorlage oder die Sensoroptik schrittweise senkrecht zum Sensor zur nächsten Zeile bewegt wird. Ein frühes Beispiel für einen solchen Scanner ist das Fax-Gerät, bei dem allerdings die Datenübertragung auf analogem Signal erfolgte. Bei der Abtastung mit einem Flächensensor kann die gesamte Vorlage oder flächenhafte Teile der Vorlage gleichzeitig gescannt werden.

Beim **Flachbettscanner** wird das Objekt mit der zu scannenden Seite nach unten auf eine Glasplatte gelegt. Zum Scannen fährt ein beweglicher Spiegel in einem »Bett« unter dieser Glasplatte durch (das Objekt selbst wird nicht bewegt) und wirft das Licht auf einen fest installierten Spiegel, der es wiederum durch die Linse auf den Bildsensor wirft. Beim Flachbettscanner werden die Objekte einzeln auf die Vorlage gelegt, weswegen Flachbettscanner (zweidimensionale) Objekte unterschiedlichster Größe und Beschaffenheit, je nach Bauart bis zu einem Format von DIN A0 scannen können.

Buchscanner: Da die Optik des Flachbettscanners keine Schärfentiefe besitzt, muss die Vorlage ganz flach auf der Glasplatte aufliegen, um ein durchgängig scharfes Bild zu erreichen. Dies bereitet beim Scannen von Büchern auf Grund der Buchbindung häufig Probleme. Einen anderen Ansatz verfolgt der **Buchscanner**, der speziell auf die Digitalisierung von Büchern spezialisiert ist und daher in den Digital Humanities eine große Rolle einnimmt. Buchscanner verwenden im Gegensatz zum Flach-

bettscanner eine oder zwei Digitalkameras (trotz des Namens »Scanner«), die zu Beginn des Scanprozesses auf die Lichtverhältnisse sowie auf die Größe der Buchseiten eingestellt werden und pro Scanvorgang eine Einzel- bzw. eine Doppelseite des Buches ablichten. Die einfachste Vorrichtung hierbei ist die sogenannte **Buchwippe**, bei der das Buch an der gewünschten Stelle aufgeschlagen und mechanisch fixiert bzw. unter eine Glasplatte gedrückt wird, um Wölbungen der Seite und damit Unschärfen in der Aufnahme zu vermeiden. Buchwippen erfordern häufig einen Öffnungswinkel des zu scannenden Buchs von 90 bis 180 Grad, was zur Belastung von Heftung, Bindematerial, Einbandrücken und Gelenken des Buches führen kann. Als eine Institution, die konservatorisch tätig ist und viele historisch wertvolle Altbestände besitzt, hat die Herzog-August-Bibliothek in Wolfenbüttel daher die Buchwippe zu einem System weiterentwickelt, das einen Öffnungswinkel von 45 Grad erlaubt (*Wolfenbüttler Buchspiegel*). Dabei wird ein Spiegel in das Objekt eingeführt, das Spiegelbild anstatt der Buchseite digitalisiert und das Abbild anschließend umgerechnet.

Das Weiterblättern bei einfachen Buchscannern, bei Buchwippe und Buchspiegel erfolgt von Hand. Bei umfangreichen Digitalisierungsprojekten kommen zudem vollautomatische Buchscanner, sogenannte **Scan-Roboter**, zum Einsatz. Bei Scan-Robotern mancher Bauart wird die Seite nach dem Scanvorgang angesaugt und automatisch umgeblättert. Luftströme werden hierbei auch verwendet, um das Papier für die Aufnahme zu glätten und ersetzen Glasplatte oder mechanische Fixierungen. Scan-Roboter anderer Bauart verwenden andere Mechanismen zum Glätten und Umblättern der Seite. Im überwachten Betrieb der Digitalisierungspraxis schaffen moderne Scan-Roboter mehrere Bücher pro Tag.

Parameter

Der Digitalisierung liegen technische Parameter zu Grunde, die wir auch als Parameter einer Modellierung auffassen können, denn jedes Digitalisat ist als Abbild ein Modell seiner Vorlage. Daher gelten auch bei der Digitalisierung die allgemeinen Grundsätze der Modellbildung. Insbesondere müssen wir uns vor Augen führen, dass jede Digitalisierung ein zweckgebundener, reduzierender und subjektiver Vorgang ist.

Die Aussagekraft eines Digitalisats und letztendlich sogar dessen Verwendbarkeit sind im wissenschaftlichen Kontext an die Parameter seiner Entstehung gebunden. Wird etwa die Farb-Fotografie einer Straßenszene in Graustufen digitalisiert, kann man das Digitalisat nicht zur Analyse von Modefarben verwenden (das Original aber sehr wohl). Hier greift das Verkürzungsprinzip der Datenmodellierung. Wird dem Benutzer zusätzlich die Information vorenthalten, dass die Vorlage kein schwarz-weiß-Bild war, sondern lediglich mit Graustufen gescannt wurde, kann dies zu problematischen Fehlinterpretationen führen. Daher ist es elementar, bei der Nutzung digitaler Daten die Parameter ihrer Entstehung zu kennen und kritisch zu prüfen, ob und wie die Daten für den jeweiligen Forschungszweck geeignet sind. Dies ist nicht immer einfach, und viele der Eignungskriterien digitaler Daten für die eigene Forschungsfrage drücken sich nicht in simplen technischen Parametern der Digitalisierung aus. Cohen und Rosenzweig führen aus:

»[...] the quality of the digital image rests on the quality of the original, the digitizing method employed, the skill of the person doing the digitizing, and the degree to which the digital copy has adequately »sampled« the analog original« (Cohen/Rosenzweig 2005, 95).

Liegt eine Unschärfe im Digitalisat einer Fotografie an der Fokussierung oder Verwacklung der Kamera, mit der das ursprüngliche Bild erzeugt wurde, also am Fotografieren, oder an der Fokussierung oder Verwacklung der Digitalkamera, mit der die Fotografie digitalisiert wurde? Ist der Text einer Randglosse in einem mittelalterlichen Codex wirklich nicht lesbar, oder ist er lediglich auf Grund der starken Wölbung der Buchseiten im Digitalisat verzerrt, was man durch geeignetere Apparaturen hätte ausgleichen können? Besitzt die Gedenktafel keine Inschrift auf der Rückseite, oder wurde sie lediglich nicht mit abgeleuchtet? Für den Bildwissenschaftler oder den Historiker sind dies entscheidende Fragen.

Technische Parameter der Digitalisierung: Auch technische Parameter spielen bei der Digitalisierung und bei der kritischen Beurteilung der Nutzbarkeit digitaler Bilder eine wichtige Rolle. Die in vielen Fällen wichtigsten Messgrößen sind dabei die schon besprochene Farbtiefe sowie die **Auflösung**. Der Begriff der Auflösung wird häufig mit der Bildgröße synonym verwendet (»Auflösung von 1920×1200 «), was im Grunde falsch ist. Bei der Auflösung im eigentlichen Sinne geht es um eine Punktdichte pro Streckeneinheit. Erst wenn man die Abtastrate eines Scanners in Relation zur Größe der zu scannenden Vorlage betrachtet, erhält man ein Maß der Qualität der Digitalisierung. Je mehr digitale Pixel von einer Vorlage abgetastet werden können, d. h. je feiner die Abtastrate ist, umso höher die Qualität. Umgekehrt ist die Auflösung auch ein Maß der Schärfe eines digitalen Bildes auf einem Ausgabemedium (Bildschirm, Drucker). Je mehr Pixel des digitalen Bildes etwa auf einem DIN A4-Blatt ausgedruckt werden können, desto schärfer der Ausdruck.

Die Auflösung wird in Bildpunkten pro Streckeneinheit gemessen. In der Regel wird das Maß **pixel per inch (ppi)** oder dots per inch (dpi) verwendet, die, sieht man von Druckern ab, synonym verwendet werden können. Ein *inch* (deutsch: Zoll) sind 25,4 mm, das Maß *ppi* gibt also an, wie viele Bildpunkte auf einer Strecke von 25,4 mm abgetastet oder ausgegeben werden. Höhere Auflösungen verursachen dabei größere Bilddateien, die wiederum übermittelt und gespeichert werden müssen und einen Kosten- und Zeitfaktor darstellen.

In den Digitalisierungsprojekten der Digital Humanities werden Auflösungen daher in der Regel pragmatisch und zweckgebunden gewählt. Als Untergrenze definiert die Deutsche Forschungsgemeinschaft eine Auflösung, »bei der die Details einer Vorlage vollständig in einer gleich großen Reproduktion wiedergegeben werden können. Ein Ansatz zur Ermittlung der notwendigen Mindestauflösung eines Digitalisats ist das Auflösungsvermögen des menschlichen Auges bei deutlicher Sehweite [25 cm]« (DFG 2013, 8–9). Für Vorlagen, die für die Betrachtung mit bloßem Auge gedacht sind, ergibt sich damit eine Mindestauflösung von 300ppi. Für bestimmte Anwendungsfälle ist jedoch eine höhere Auflösung sinnvoll, etwa bei Medien, deren Bildinformationen nur in Vergrößerung vollständig erfassbar sind (Miniaturen, Dias). Hier können Auflösungen von 3000ppi und mehr notwendig sein.

Die Wahl der Auflösung bei der Digitalisierung unterliegt dem allgemeinen Prinzip der Zweckgebundenheit bei der Erzeugung von Abbildern/Modellen. Schwierig ist es jedoch, sämtliche Nutzungsszenarien der Digitalisate für die Zukunft vorherzusagen. So werden etwa im Bereich der digitalen Paläographie heute deutlich höhere Auflösungen als 300ppi bei der Digitalisierung von Handschriften gefordert, weil zukünftig nicht nur die Betrachtung des digitalen Abbildes der Handschrift mit dem bloßen Auge berücksichtigt werden sollen, sondern auch detaillierte Analyseverfahren aus dem Bereich der Computer Vision, die über die Sehkraft des menschlichen Auges hinausgehen (Hassner et al. 2014).

12.3 | Erschließung der Digitalisate

Metadaten: »Die Erzeugung von Metadaten, welche erst die Auffindbarkeit der Objekte gewährleisten und eine kontextualisierende Präsentation ihrer digitalen Images erlauben, ist zentraler Bestandteil der Digitalisierung« (DFG 2013, 25). Für die Nutzung von Bilddigitalisaten sind **technische, deskriptive, strukturelle und administrative Metadaten** von Bedeutung. Diese vier Typen von Metadaten unterscheiden sich in Hinblick auf ihre Anwendung.

- **Deskriptive Metadaten:** werden vorrangig zum Auffinden eines bestimmten Objektes herangezogen
- **Strukturelle Metadaten:** werden verwendet, um das aufgefundene Objekt in seinem Aufbau zu erfassen
- **Technische Metadaten:** werden verwendet, um die Qualität des Objekts zu beurteilen
- **Administrative Metadaten:** werden verwendet, um etwa Nutzungsrechte zu dokumentieren

Dies sind zwar in ihrer Erzeugung recht eindeutig festgelegte Kategorien, in der Anwendung aber keine starren Beschränkungen, denn natürlich können etwa auch technische Metadaten zum Auffinden eines Objektes herangezogen werden (z. B. »finde alle Digitalisate von mittelalterlichen Urkunden, die mit mindestens 600ppi digitalisiert wurden«).

Es folgt eine Übersicht über einige international gängige Metadaten-Standards und Spezifikationen, die im Rahmen der Digitalisierung des kulturellen Erbes eine Rolle spielen. Da sich deskriptive und strukturelle Metadaten je nach Objekttyp (z. B. Fotografie, mittelalterliche Urkunde, Roman) stark unterscheiden, kann im Rahmen dieser Einführung nicht auf Details eingegangen werden.

- **Dublin Core** ist ein internationaler Standard zur Beschreibung von digitalen und realen Dokumenten sowie anderen Objekten. Das *Dublin Core Metadata Element Set* besteht dabei im Kern lediglich aus 15 Elementen, die in verschiedenen Formaten (RDF/XML, OpenDocument, HTML) ausgedrückt werden können. Dublin Core wird von der Dublin Core Metadata Initiative entwickelt.
- **METS** (Metadata Encoding and Transmission Standard) ist ein Standard zur XML-basierten Kodierung von deskriptiven, administrativen und strukturellen Metadaten von Objekten innerhalb einer digitalen Bibliothek. METS wirkt dabei als ein Container, bei dem in einzelnen Abschnitten andere Formate (z. B. Dublin Core, MODS, MARC) untergebracht werden können. Der METS-Standard wird von der Library of Congress gepflegt und das zugehörige Datenschema von der Digital Library Federation, einem nordamerikanischen Bibliotheksverbund weiterentwickelt.
- **MODS** (Metadata Object Description Schema) ist ein XML-Format für bibliografische (deskriptive) Metadaten. Es gilt als Kompromiss zwischen der Komplexität des Bibliothekskatalogsformats MARC (Machine Readable Cataloging) und der Einfachheit von Dublin Core. MODS wird von der Library of Congress entwickelt.
- **TEI** (Text Encoding Initiative). Die TEI bietet Richtlinien und XML-Schemata vornehmlich für die Kodierung elektronischer Texte. Die Richtlinien enthalten aber auch eigene Sektionen, u. a. `<teiHeader>`, `<msDesc>` und `<bibl>`, die für deskriptive und strukturelle Metadaten herangezogen werden können. TEI wird von

einem internationalen Konsortium mit gleichem Namen gepflegt und weiterentwickelt.

- **EAD** (Encoded Archival Description) ist ein XML-Standard zur Kodierung deskriptiver Metadaten für Archivalien (Findmittel), der von Archiven, Museen und Bibliotheken genutzt wird. EAD wird von der Library of Congress gepflegt.
- **SAFT** (Standardaustauschformat). SAFT-XML ist ein XML-Austauschformat zur Kodierung deskriptiver Metadaten für Archivalien (Findmittel). SAFT wurde im Auftrag der Deutschen Forschungsgemeinschaft entwickelt.

12.4 | Textdigitalisierung

Die zuvor besprochenen Verfahren zur Digitalisierung bilden eine Vorlage als zweidimensionale Tabelle von Farbwerten in Form einer digitalen Rastergrafik ab. Dabei werden lediglich die geometrischen Positionen der einzelnen Pixel gespeichert, nicht aber ihre Bedeutung im Bild oder gar der Bedeutungszusammenhang einzelner Pixel untereinander. Eine Information zum Beispiel dergestalt, dass eine Gruppe von schwarzen Pixeln die Tinte repräsentiert, mit der ein bestimmter Buchstabe eines Textes gedruckt wurde, liegt in der Rastergrafik nicht vor. Handelt es sich bei der Vorlage also um einen Träger von Text (etwa ein Buch), ist folglich ein weiterer Bearbeitungsschritt notwendig, um diesen Text zu erkennen, aus der Rastergrafik zu extrahieren und daraus maschinenlesbare Zeichencodes zu generieren. Diesen Vorgang nennen wir Texterfassung oder **Transkription** (von lat. *trānscrībēre*: abschreiben, übertragen). Wir können zwischen manuellen und automatischen Verfahren unterscheiden.

Die **manuelle Texterfassung**, auch *keying* genannt, erfolgt durch Abtippen der Vorlage per Hand. Hierbei erfolgt implizit durch den Erfasser des Texts eine Kodierung in ein maschinenlesbares Zeichensystem (Unicode). Da bei der manuellen Texterfassung Lese- und Flüchtigkeitsfehler auftreten bzw. bei schlechter Vorlage oder unbekannter Schrift Interpretationsmöglichkeiten bestehen, wird häufig das Verfahren des *double-keying* angewandt, bei dem zwei Erfasser unabhängig voneinander den gleichen Text transkribieren. Beide Transkriptionen werden anschließend verglichen und Differenzen durch einen Dritten korrigiert. In großen Digitalisierungsprojekten wird das *keying* oft mittels **Outsourcing** durch externe Dienstleister durchgeführt, die eine Texterkennungsqualität von bis zu 99,997 % korrekt erfasster Buchstaben anstreben (DFG 2013, 33).

Bei der **automatischen Texterfassung** kommen Verfahren der **Optical Character Recognition** (Optische Zeichenerkennung, OCR) zum Einsatz. OCR-Verfahren wurden erstmalig bereits gegen Ende des 19. Jahrhunderts beschrieben und kamen mit der Erfindung der Digitalcomputer in den 1940er und 1950er Jahren zum kommerziellen Einsatz (Eikvil 1993). Da für automatische Texterfassung auch außerhalb der Wissenschaften ein großer Bedarf besteht, werden die Verfahren seitdem kontinuierlich weiterentwickelt. Für OCR kommen kommerzielle und frei verfügbare Software-Produkte in Frage, die entweder generisch für den breitgefächerten Einsatz oder für spezielle Dokumentarten und Schrifttypen entwickelt werden. In den Digital Humanities werden zumeist generische Software-Produkte eingesetzt, die gegebenenfalls für besondere Anwendungsfälle speziell trainiert werden.

Der Prozess der Texterkennung gliedert sich in der Regel in mehrere Phasen: einer Vorverarbeitung der grundlegenden Rastergrafiken, der eigentlichen Zeichenerkennung und einer Nachbereitung des erkannten Textes. Was im Folgenden lediglich modellhaft

dargestellt werden kann, variiert dabei in den verschiedenen Software-Implementierungen. Auch werden zahlreiche Optimierungsverfahren diskutiert (Mühlberger).

In der **Vorverarbeitung** (*pre-processing*) wird zunächst versucht, die Rastergrafik als Vorlage für die OCR zu optimieren. Hierzu zählt die Ausgleichung eventueller Verzerrungen oder Rotationen der Vorlage, wobei eine gute Bilddigitalisierung diesen Schritt vorwegnehmen kann und idealerweise auch sollte. Mit der anschließenden **Binarisierung** wird jeder Pixel der Rastergrafik entweder Text oder Hintergrund zugeordnet, was die OCR-Software auf Basis eines Algorithmus entscheidet. Hierbei können fließende Übergänge, Verunreinigungen oder Zerfall der Vorlage (bei historischen Dokumenten) ebenso Probleme verursachen wie eine zu geringe Auflösung des Digitalisats.

Es folgt eine Analyse des Layouts und die Segmentierung der Vorlage. Ziel ist es, die Bereiche zu identifizieren, die überhaupt Text enthalten. Andere Elemente wie Bilder oder Grafiken werden als solche markiert, fließen aber nicht in die weitere Texterkennung ein. In den Textbereichen werden anschließend Zeilen und häufig auch Wörter voneinander separiert. Moderne OCR-Software speichert die Layout-Information (Koordinaten) von Textblöcken, einzelner Zeilen, Wörter oder auch Zeichen zusammen mit dem erfassten Text, so dass bei einer späteren Volltextsuche auch die Position des Treffers im Bilddigitalisat visuell hervorgehoben werden kann.

Moderne OCR-Software bemüht sich außerdem darum, das Dokument in seiner logischen Struktur zu erfassen, etwa Kopfzeilen, Fußzeilen, Marginalien und andere Paratexte vom eigentlichen Text zu trennen, Überschriften und Absätze zu erkennen, eingebettete Bilder und Grafiken als solche zu markieren oder eine Tabellenstruktur zu rekonstruieren. Dies geschieht zunächst rein auf Basis typographischer Kriterien, wie Abstandsmessungen zwischen Textblöcken oder dem Wechsel von Schriftarten (*fonts*) und kann daher letztendlich nur als Indikator für eine logisch-inhaltliche Struktur des Textes dienen, die in der Regel nachkorrigiert werden muss.

Für die eigentliche **Zeichenerkennung** sind mehrere Verfahren beschrieben, die von den Software-Produkten in verschiedenen Konstellationen und Konfigurationen eingesetzt werden. Ausgehend von der Extraktion der einzelnen Glyphen wird diese beim Musterabgleichsverfahren auf eine Matrix reduziert (s. Abb. 48) und berech-




Abb. 48 OCR-Musterabgleich nach Li (1991)

net, welchem Zeichen eines modellhaften Zeichensatzes (Klassifikatoren) diese Glyphe am wahrscheinlichsten entspricht (Li 1991). Einen anderen Ansatz verfolgt das fortgeschrittenere Verfahren der *feature extraction*, bei der die Glyphe als Komposition von Einzelbestandteilen (z. B. Abstriche, Bögen) betrachtet, in diese zerlegt (Vektorisierung) und mit Prototypen verglichen wird.

In beiden Verfahren basiert die Zeichenerkennung auf Datenbanken mit bereits bekannten Glyphen-Mustern. Moderne OCR-Software kennt dabei die gängigen (Druck-)Schriftarten und kann zudem bei unbekannten und stark abweichenden Schriftarten ihre Datenbank durch Training entsprechend erweitern.

In der **Nachbereitung** (*post-processing*) wird schließlich versucht, die Qualität des erkannten Textes zu verbessern. Hier werden häufig fachspezifische Wörterbücher zum Abgleich der Texterkennung eingesetzt, in dem in einem Rückkopplungsprozess zweifelhafte Transkriptionen gegen Wörter im Lexikon ausgetauscht werden, zum Beispiel bei Verwechslungen von Buchstaben und Ziffern. Auch computerlinguistische Verfahren werden in der Nachbereitung angewendet. Aufwändiger werden die Nachkorrekturen vor allem bei historischen Texten und bei Texten mit nicht normierten Schreibweisen oder hohem Anteil von Eigennamen, die schwer in Wörterbüchern zu finden sind.

Qualitätskriterien für die Texterkennung: Das Maß für die Qualität der Texterkennung ist die **Erkennungsgenauigkeit**. Wir können zunächst zwischen Wort- und Buchstabengenauigkeit unterscheiden, die im Wesentlichen aussagen, wie hoch der Prozentsatz der korrekt repräsentierten Wörter bzw. Zeichen in Bezug auf die Vorlage ist. Sie wird in der Regel durch Stichproben ermittelt. Auch die Varianz in der Verteilung der Erkennungsfehler spielt eine Rolle, kann hier aber nicht vertieft werden. Die Erkennungsgenauigkeit entscheidet darüber, ob und wie brauchbar ein erfasster Text für verschiedene Anwendungszwecke ist. Als Richtgröße gibt die DFG eine Buchstabengenauigkeit von 99,95 % als »wissenschaftlich zuverlässig« an, da sie auch Negativsuchen erlaubt (d. h. liefert eine Volltextsuche nach einem bestimmten Wort keinen Treffer, so kann davon ausgegangen werden, dass dieses Wort nicht im Text vorkommt). Deutliche schlechtere Genauigkeiten im Bereich von 80–90 % können je nach Betrachtungsperspektive noch für positive Suchen im Retrieval verwendet werden, wobei jedoch vor allem ein deutlich geringerer Recall zu erwarten ist. Eine Buchstabengenauigkeit von unter 80 % gilt als »fragwürdig« (DFG 2013, 32). Wichtig ist in jedem Fall, sich vor Benutzung digitalisierter Texte über deren Qualität zu informieren.

Sehr hohe Erkennungsgenauigkeiten werden bei modernen Buchdruck- und Computerschriftarten erreicht. Auch Typoskripte (Schreibmaschine) werden in der Regel gut erkannt, solange das Schriftbild sauber ist. OCR-Software stößt jedoch häufig an die Grenze, wenn es sich um historische Texte handelt. Als Faustregel gilt: je älter der Druck, desto geringer die Wahrscheinlichkeit einer ausreichend hohen Qualität in der Texterkennung. Während etwa ein Frakturdruck des 19. oder frühen 20. Jahrhunderts mittlerweile oft verhältnismäßig gut erkannt werden kann, stellen frühere Drucke häufig noch ein Problem dar und weisen eine deutlich geringere Erkennungsgenauigkeit auf.

Im Bereich der **Handschriftenerkennung**, die vor allem für historische Texte relevant ist, werden verschiedene Verfahren diskutiert. Ein allgemeingültiger Ansatz, der eine gedruckten Vorlagen entsprechende hohe Erkennungsgenauigkeit bietet, ist auf Grund der Individualität und starken Varianz der menschlichen Schrift auch in nächster Zeit nicht zu erwarten (Hassner et al. 2014). Hier bleibt weiterhin die ma-

nuelle Transkription der einzig gangbare Weg der Texterfassung für wissenschaftliche Zwecke, auch wenn diese durch verschiedene computerbasierte paläographische Hilfsmittel unterstützt werden kann. Von dieser retrospektiven (offline) Handschriftenerkennung zu unterscheiden ist die sogenannte online-Handschriftenerkennung, wie sie etwa auf Tablet-Computern oder Smartphones erfolgt. Da hierbei der Duktus, d. h. die Stiftführung beim Schreiben, mit aufgezeichnet wird und somit ausgewertet und die Erkennungs-Software zudem auf den spezifischen Schreiber trainiert werden kann, sind sehr hohe Erkennungsgenauigkeiten erzielbar.

12.5 | Weitere Digitalisierungsverfahren

In diesem Kapitel haben wir uns vorrangig mit zwei Facetten der Digitalisierung beschäftigt: der (zweidimensionalen) Bilddigitalisierung und der daraus abgeleiteten Erfassung von Text. So vielseitig wie die geisteswissenschaftlichen Disziplinen und so divers ihre Gegenstände sind, so weit gestreut ist aber auch das Feld der Digitalisierung. Abschließend sollen nun weitere Bereiche thematisiert werden. Dies kann jedoch nur exemplarisch und skizzenhaft erfolgen.

Schon bei der Digitalisierung von Schriftgut fällt auf, dass bei einer zweidimensionalen (flachen) Abbildung – wie sie eine Kamera oder ein Buchscanner liefert – manche Eigenschaften, wie etwa die Wellung eines mittelalterlichen Pergaments, die Beschaffenheit eines Bucheinbandes oder die Tiefe von Gravuren, nicht oder nicht vollständig erfasst werden. Bei anderen Gegenständen der Digital Humanities, etwa historische oder archäologische Artefakte, ist die Dreidimensionalität der Objekte noch offensichtlicher, wie man sich leicht an einer Münze vergegenwärtigen kann: Vorderseite, Rückseite, Tiefe der Prägung und der umlaufende Münzrand lassen sich durch eine zweidimensionale Bilddigitalisierung nicht vollständig abbilden.

Multispektralfotografie

Zu den spezialisierten und fortgeschrittenen Verfahren zählt auch die Digitalisierung durch Multispektralkameras. Multispektralfotografie ist eine Methode für spezielle Anwendungen wie die geographische Fernerkundung (Luftbilder), deren Möglichkeiten seit einiger Zeit auch verstärkt in den Geisteswissenschaften genutzt wird.

Im Unterschied zur herkömmlichen Farbfotografie wird das Lichtspektrum bei der Multispektralfotografie nicht in nur drei Bereiche (rot, grün, blau), sondern in eine größere Zahl variabel abgrenzbarer Spektralbänder unterteilt, die separat von digitalen Sensoren erfasst werden. Dies gewährleistet eine große Flexibilität bei der Erfassung der Farben, weshalb eine Einsatzmöglichkeit die hochgradig farbgetreue Reproduktion von Gemälden ist.

Über den Bereich des Sichtbaren hinaus werden auch die angrenzenden Bereiche des für das menschliche Auge nicht unmittelbar sichtbaren ultravioletten und infraroten Lichtes erfasst. Diese Lichtbereiche können wissenschaftlich wertvolle Informationen über Oberfläche oder tieferliegende Schichten der Objekte sowie ihre chemischen Bestandteile liefern. In Gemälden können bestimmte Farbpigmente (z. B. Bleiweiß) nachgewiesen oder kunsthistorisch bedeutsame Unterzeichnungen (Entwurfszeichnungen) wie auch konservatorisch relevante Schäden am Objekt aufgedeckt und Originale von Fälschungen unterschieden werden. Die unterliegenden älteren Textschichten mehrfach beschriebener Pergamente

(Palimpseste wie das berühmte »Archimedes-Palimpsest«) können ebenso sichtbar gemacht werden wie Text auf ausgebleichenen oder beschädigten Manuskripten. Multispektralfotografie ist eine nichtinvasive Methode, d. h. das untersuchte Objekt wird dabei nicht beschädigt oder zerstört. Sie ist daher auf fragile und kostbare Objekte des kulturellen Erbes (und damit für dessen Erforschung) anwendbar.

In diesem Kontext gewinnt die dreidimensionale **Objektdigitalisierung** zunehmend an Bedeutung. Vorreiter sind hier die Archäologie und die Museen. Es sind unterschiedliche Verfahren beschrieben worden, wobei die Spannbreite von multiperspektivischen 2D-Aufnahmen mit anschließender softwarebasierter Berechnung eines 3D-Modells über Laserscan-Verfahren bis hin zur Computertomographie reicht. Im Gegensatz zur Bilddigitalisierung von »Flachware« erfordert die Objektdigitalisierung gegenwärtig jedoch noch einen deutlich höheren Aufwand und setzt häufig die Anwendung mathematischer Verfahren der Modellbildung voraus, um wissenschaftlich brauchbare Ergebnisse zu erzielen.

Die bislang hier vorgestellten Digitalisierungsarten beruhen auf optischen Verfahren. Auf Akustik beruht hingegen die **Audiodigitalisierung**. Wir verstehen hierunter eine Retrodigitalisierung, also die Umwandlung bereits vorliegender analoger Tonaufzeichnungen, von der die unmittelbare digitale Aufnahme zu unterscheiden ist. Da Töne transient (flüchtig) sind, besteht in ihrer Aufzeichnung die einzige Möglichkeit, sie möglichst authentisch zu dokumentieren. Handelt es sich dabei um gesprochene Sprache, ist zwar die Transkription als geschriebener Text ebenfalls möglich, doch gehen dabei in der Regel wichtige Eigenschaften (z. B. Intonation, Sprechpausen, Dialekt) verloren. Tondokumente sind seit dem Ende des 19. Jahrhunderts in analoger Form bekannt, gängige Medien waren Wachswalzen, Schallplatten und Tonbänder. Ihre Digitalisierung erfolgt mittels Analog-Digital-Wandlung. Auf die technischen Verfahren im Einzelnen kann in dieser Einführung nicht eingegangen werden.

Digitalisierung ist für die Digital Humanities ebenso zentral wie facettenreich. Für manche Aufgaben wie die Buchdigitalisierung in Bibliotheken oder die Schriftgutdigitalisierung in Archiven sind die Verfahren inzwischen wohl bekannt und skalierbar. Eine gute Orientierung bieten die Praxisregeln der DFG 2013. Bei jeder Digitalisierung sind jedoch die besonderen Eigenschaften des Objekts und der Digitalisierungszweck zu berücksichtigen. Hieraus sind die Digitalisierungsparameter abzuleiten, konsequent anzuwenden und in den Metadaten zu dokumentieren.

Literatur

- Cohen, Daniel/Rosenzweig, Roy: *Digital History. A Guide to Gathering, Preserving, and Presenting the Past on the Web*. Philadelphia 2005.
- DFG: »Praxisregeln Digitalisierung« (2013), http://www.dfg.de/formulare/12_151/12_151_de.pdf (19.10.2015).
- Eikvil, Line: »OCR. Optical Character Recognition« (1993), <https://www.nr.no/~eikvil/OCR.pdf> (19.10.2015).
- Hassner, Tal/Rehbein, Malte/Stokes, Peter A./Wolf, Lior: »Computation and palaeography: potentials and limits«. In: *Dagstuhl Manifesto 2/1* (2014), 14–35.
- Li, Ning: *An Implementation of OCR System Based on Skeleton Matching*. Canterbury 1991.

- Mühlberger, Günter: »Digitalisierung Historischer Zeitungen. Aus dem Blickwinkel der Automatisierten Text- und Strukturerkennung (OCR)«. In: *Zeitschrift für Bibliothekswesen und Bibliographie* 58/1 (2011), 10–18.
- Mori, Shunji et al.: »Historical review of OCR research and development«. In: *Proceedings of the IEEE* 80/ 7 (1992), 1029–1058.
- Saffady, William: *Micrographics: Technology for the 21st Century*. Prairie Village, Kan. 2000.
- Tanner, Simon et al.: »Measuring mass text digitization quality and usefulness. Lessons learned from assessing the OCR accuracy of the British Library's 19th century online newspaper archive«. In: *D-Lib Magazine* 15/78 (2009).
- Terras, Melissa: *Digital Images for the Information Professional*. Farnham 2008.
- The Library of Congress: »Technical standards for digital conversion of text and graphic materials« (2006), <http://memory.loc.gov/ammem/about/techStandards.pdf> (19.10.2015).

Internetquellen

Spezifikationen von Metadaten-Standards (Auswahl):

- Dublin Core: <http://dublincore.org/specifications/>.
- EAD: <http://www.loc.gov/ead/>.
- METS: <http://www.loc.gov/standards/mets/>.
- MODS: <http://www.loc.gov/standards/mods/>.
- NISO: »Understanding Metadata« (2004), <http://www.niso.org/publications/press/UnderstandingMetadata.pdf> (19.10.2015).
- SAFT: <http://www.archivschule.de/DE/forschung/retrokonversion/vorstudien-und-saft-xml/>.
- TEI: <http://www.tei-c.org>.

Malte Rehbein

13 Digitales Publizieren

13.1 | Eine Revolution

Die Möglichkeit, digital und online zu publizieren, hat ganze Wirtschaftszweige erleben lassen. Das Zeitungswesen befindet sich in einer Krise, da das Anzeigenwesen als ein wesentliches Standbein von dessen Finanzierung vermehrt ins Internet abwandert und die Auflage fast überall zurückgeht. Professionelle Journalisten, und damit die etablierten Informationshüter, fühlen sich verstärkt dem Druck von Amateur-Publizisten ausgesetzt, die von einem sehr persönlichen, häufig aber näher am Geschehen befindlichen Standpunkt aus ihre Berichte im Netz veröffentlichen. Selber (teilweise) ins Internet abzuwandern, schien manchen Zeitungen ein gangbarer Weg, um Aufmerksamkeit zu erzeugen, aber zuletzt überwiegt doch die Vorstellung, es sei unsinnig, teuer bezahlte Inhalte gratis wegzuschenken. So experimentieren aktuelle Pressehäuser mit dem, was hellsichtige Beobachter der Szene als die flächendeckende ›**Granularisierung der Gesellschaft**‹ bezeichnen (vgl. Kuklick 2014) und verkaufen ihre Ausgabe nicht mehr als Ganzes, sondern in einzelnen Artikeln. Alternativ ist aber auch das genaue Gegenteil gängige Praxis, wenn Zeitungen oder sogar ganze Bündel von Presseprodukten per Flatrate angeboten werden.

Fast genauso stark durcheinandergewirbelt wird zur Zeit der **Buchmarkt**. Ein massiv expandierendes Segment dieses Marktes wird vom sogenannten *self-publishing* besetzt, in dem auf die Hilfe traditioneller Intermediäre wie die der Verlage verzichtet und das Produkt direkt über einen online-Vermarkter angeboten wird. Überkommene Filter- und Qualitätssicherungsmechanismen werden dadurch zugunsten eines nachgelagerten, viralen Empfehlungswesens ausgeschaltet, das die *top down* strukturierte klassische Kulturwirtschaft verstärkt durch *bottom up*-Elemente ersetzt. In der Verlagswirtschaft selber zeichnet sich ein Konzentrationsprozess ab, da viele kleinere Unternehmen die hohen Technologiekosten nicht stemmen können, die eine moderne Publizistik verlangt. An der Spitze dieses Konzentrationsprozesses wirkt ein Unternehmen wie Amazon mit seinem universalistischen Ansatz, der nicht nur Bücher ebenso wie Fahrräder und Babywindeln im Programm hat, sondern mit seinem *Kindle* auch in das klassische Verlagsgeschäft einsteigt, das er anfänglich nur vertriebstechnisch zu unterstützen schien.

Zeitung, Buch und Enzyklopädie: Ein wissenschaftsnahes Medium ist die **Enzyklopädie**, bei der sich der Umbruch des Publikationswesens im digitalen Zeitalter besonders deutlich zeigte. Es ist noch nicht lange her, dass eine vielbändige Enzyklopädie wie die *Encyclopaedia Britannica* oder der *Brockhaus* (schon die Abkürzung ist ein Zeichen für dessen universellen Anspruch) als Ausweis für gediegenes Wissen stand. Fragt man heute den akademischen Nachwuchs, dann kann es passieren, dass weder das eine noch das andere Medium überhaupt bekannt ist. Ersetzt wurden sie durch die **Wikipedia**, die ihren Siegeszug übrigens genau zu dem Zeitpunkt begann, als sie aufhörte, das alte Lexikon nachzuahmen (Autorbindung, aufwändiges *peer-review*-Verfahren) und die neuen Möglichkeiten des Internets zu nutzen. Diese bestehen vor allem in der interaktiven Gestaltung und der permanenten Aktualisierungsmöglichkeit, darüber hinaus in der sehr viel feinkörnigeren Definition der Lemmata (s. Kap. 14.4). Dass darüber hinaus die kostenlose Nutzung einen entscheidenden Vorteil gegenüber den mit vierstelligen Preisen kalkulierten Enzyklopädien ausmacht, liegt auf der Hand. Und auch der Nachweis, dass die Wikipedia zumin-

dest im naturwissenschaftlichen Bereich nicht schlechter ist als das traditionelle Lexikon, hat ihren Ruf bestätigt (Casebourne et al. 2012).

Die Breite der von der Digitalisierung betroffenen Veröffentlichungsformen spiegelt die Eindringlichkeit des Problems. In kaum einem anderen Feld äußert sich die disruptive Wirkung der Digitalisierung tiefgreifender als im Publikationswesen. Im Weiteren soll vor allem das wissenschaftliche Veröffentlichungswesen im Zentrum des Interesses stehen.

13.2 | Neue Medien imitieren alte Medien

Wir haben es am Beispiel der Wikipedia gesehen: Digitale Publikationsformen ahmen in ihren frühen Erscheinungsformen alte, analoge Veröffentlichungsarten nach. Das allseits verbreitete **PDF-Format** (*Portable Document Format*) – eine vom *postscript*-Format abgeleitete Seitenbeschreibungssprache, bei der die relevanten Informationen zu Schriftart und Schriftgröße sowie zum Zeilenumbruch in die Beschreibung eingehen – simuliert im Digitalen die Buchseite und setzt alles daran, diese in ihrer Integrität auch im virtuellen Raum unverändert, zitierfähig und Plattform-unabhängig zu erhalten, dies aber um den Preis einer mangelhaften Anpassbarkeit z. B. an unterschiedliche Bildschirmformate. Das passt in eine Übergangsphase, in der das digitale Format vielfach nur Zwischenstation für den Druck ist.

Wenn man bedenkt, dass das digitale Veröffentlichen im Vergleich zur Geschichte des gedruckten Buches noch ein sehr junges Phänomen ist – das WWW ist 25, das gedruckte Buch über 550 Jahre alt –, so wird man zugestehen müssen, dass auch die elektronische Publikationsform sich noch in einer Frühphase befindet. Es steht daher zu vermuten, dass die Zukunft in diesem Bereich noch manche Überraschung bereithalten wird – und dass sie auf Voraussetzungen reagiert, in denen der Druck nicht mehr die primäre, sondern nur noch sekundäre Verbreitungsform von Texten darstellt.

Andere Formate zielen darauf ab, die Vorteile von PDF zu erhalten, die Nachteile aber auszuschalten. So ist das ebenfalls verbreitete **EPUB-Format** in der Lage, Texte an die Bildschirmgröße anzupassen, was in Zeiten, in denen Handy und Tablet zu immer wichtigeren Ersatz-Computern werden, von großer Bedeutung ist. EPUB ist ein offener Standard des *International Digital Publishing Forum* für die technische Spezifikation von E-Books und verwendet eine ganze Reihe anderer offener Standards wie XHTML, CSS und Bild-, Audio- und Filmformate sowie Dublin Core für die Metadaten.

Warum digital publizieren? Warum sollte man überhaupt digital publizieren, also nicht nur die Herstellung des Textes digital bewerkstelligen (heute ist der digitale Prozess eine Selbstverständlichkeit), sondern auch das Produkt in digitaler Form herausbringen? Dafür gibt es eine ganze Reihe von Gründen. Aus Sicht der Verlage resultiert eine erhebliche Erleichterung durch die Tatsache, dass die gesamte Druckstufe wegfällt und die Verteilung des Produktes in jeden Winkel der Welt und in Sekundenschnelle möglich ist. Bibliotheken gehören zu den entschiedensten Vorkämpfern der digitalen Publikationsform, ein Grund dafür dürfte in der Platzersparnis zu finden sein, da insbesondere Institute in Innenstadtnähe immer mehr Probleme haben, die permanent wachsenden Bestände noch sachgerecht unterzubringen. Dementsprechend haben sich Bibliotheken in dem Bereich auch häufig zu technischen Kompetenzzentren entwickelt und verwenden z. B. anspruchsvolle Software, mit der

sie die komplexen Produktionsprozesse managen: **Open Journal System** (<https://pkp.sfu.ca/ojs/>) für Zeitschriften und **Open Monograph Press** (<https://pkp.sfu.ca/omp/>) für Bücher.

Autoren schätzen die elektronische Publikationsform verstärkt, weil sich mit ihr ein weiterer Aufmerksamkeitskanal ergibt, der die eigene Bekanntheit erhöht bzw. Verkaufschancen verbessert. Häufig nämlich ist die elektronische Version eines Buches nur *eine* Form der Verbreitung, neben der die traditionelle im Druck weiterbesteht (hybrid-Publikation). Insbesondere in den Wissenschaften kommt für die Autoren ein weiteres Argument hinzu, das in der leichteren Vernetzungsmöglichkeit mit Gleichgesinnten und *peers* besteht. Auf Aggregationsplattformen wie academia.edu, das mehr als 40 Millionen akademische Autoren verbindet und ansonsten Werbung damit macht, dass es für eine 70 % höhere Zitationshäufigkeit Sorge, kann man nicht nur seine eigenen Veröffentlichungen zugänglich machen, sondern sich zu Interessengemeinschaften zusammenschließen, die interne Kommunikation pflegen und sich jeweils über Neuerscheinungen in seinem Gebiet informieren lassen.

Digital publizieren ist hier mit online publizieren gleichgesetzt worden. Das ist sachlich natürlich falsch, aber in der Praxis meistens treffend. Denn lokale elektronische Publikationsformate wie die CD-ROM oder DVD dürften sich, wie in der Musikindustrie, als Übergangsphänomen herausstellen, weil sie die Vernetzungspotentiale des Elektronischen vernachlässigen. Zudem weisen sie auch ein Nachhaltigkeitsproblem auf, das grundsätzlich von vielen Skeptikern für einen Generalangriff auf das Internet als Publikationsmedium genutzt wird: Die Lebensdauer einer CD-ROM wird auf 10 bis 50 Jahre geschätzt, ein im Vergleich zum Papier bescheidener Wert (s. auch Kap. 15).

Forschungsdaten: Der praktisch unbegrenzt zur Verfügung stehende **Speicherplatz** im Digitalen ermöglicht eine viel intensivere Publikationstätigkeit als dies unter naturgemäß begrenzten Druckbedingungen gegeben ist. Es wird dadurch auch vorstellbar und zur Zeit schon sporadisch praktiziert, dass die der wissenschaftlichen Darstellung zugrundeliegenden Forschungsdaten, also alle empirisch erschlossenen Grundlagendaten, wie sie bei Messungen, Umfragen etc. entstehen, ebenfalls veröffentlicht werden (vgl. Büttner et al. 2011). Selbst wenn dies zuerst im natur- und sozialwissenschaftlichen Bereich eine Rolle spielen dürfte, ließe sich auch in den Geisteswissenschaften eine entsprechende Praxis realisieren, etwa dort, wo die genutzten Archivalien ebenfalls mit herausgebracht werden.

13.3 | Eigenschaften der digitalen Publikation

Die digitale Publikation ist volatil, flüchtig, ungreifbar. Damit bietet sie sich für Veränderungen an, die teils negativ, teils positiv zu bewerten sind. Wer in seiner Veröffentlichung einen Fehler entdeckt und diesen klammheimlich ändert – technisch eine Lappalie – gefährdet ganz grundsätzlich deren Zitierfähigkeit, weil schließlich ein Zitat aus der vorhergehenden Version dann falsch werden kann. Werden die Veränderungen aber gekennzeichnet, indem man klare Versionierungen vornimmt, die den alten gedruckten Auflagen entsprechen, ergibt sich die Möglichkeit, mit der Veröffentlichung aktueller zu bleiben, als das im Druck machbar ist. Die Briefedition eines Heroen der Geistesgeschichte ist somit zeitnah nach jeder Entdeckung eines neuen Briefes zu ergänzen, während man in traditioneller Buchform sicherlich mehrere Jahrzehnte warten müsste, bis die gesammelten Funde dann in einer Neuauflage

lage greifbar würden. Die Veränderbarkeit der Veröffentlichungen wird an manchen Stellen so weit getrieben, dass sogenannte *living documents* entstehen, zu denen z. B. auch die erwähnte Wikipedia gehört: Artikel in dieser Enzyklopädie können kontinuierlich verändert werden, und hier kommt sogar noch hinzu, dass das gängige **Autorprinzip** aufgehoben scheint: An einem einzigen Artikel können Dutzende, ja Hunderte verschiedene Verfasser mitwirken (s. Kap. 14.4). Manche sehen in der Wikipedia-Veröffentlichungsform und insbesondere in deren Kollaborativität die Zukunft des wissenschaftlichen Publizierens überhaupt. Enorm wichtig bleibt in jedem Fall die Forderung, dass die Veröffentlichung dauerhaft greifbar sein muss. Das betrifft erstens die Identität des Servers, auf dem sie abgespeichert wird: Ein privat gemieteter Platz bei einem kommerziellen Anbieter eignet sich in jedem Fall weniger als der professionell gepflegte einer Institution. Zweitens und vor allem ist aber auch die URL kritisch: Deren erfahrungsgemäß häufig kurze Lebensdauer kann dadurch verstetigt werden, dass sie durch einen *Persistent uniform resource locator* (PURL) ergänzt wird.

Retrodigitalisierung: In den weiteren Bereich der digitalen Publikation gehören auch die online-Reprints von älteren Büchern, die unter dem Begriff der Retrodigitalisierung firmieren. Bekannt geworden ist vor allem die Initiative des kalifornischen Suchmaschinen-Betreibers **Google**. Hier werden ganze Bibliotheken komplett digitalisiert und je nach Urheberrechtslage ausschnittsweise (*snippets*) oder vollständig zur Verfügung gestellt. Dabei entstehen nicht nur *images* der Vorlagen, sondern diese werden auch in suchbaren Text konvertiert. In Deutschland hat die Bayerische Staatsbibliothek für Furore gesorgt, die ihren alten Buchbestand weitgehend vollständig retrodigitalisieren lässt, insgesamt soll Google inzwischen rund 20 Millionen Bücher verdatet haben, immer noch nur ein Bruchteil der jemals veröffentlichten Werke. Aufzufinden sind sie über www.books.google.com, allerdings aus besagtem Grund meist nur mit Erscheinungsdatum vor 1900, denn das Urheberrecht untersagt die nicht ausdrücklich erlaubte Nutzung von geistigen Erzeugnissen bei Autoren, die noch leben oder (in Deutschland) weniger als 70 Jahre tot sind (s. Kap. 24.1).

Die Google-Initiative ist in Europa vielfach mit Schrecken zur Kenntnis genommen worden, weil man in ihr den Ausdruck einer weiter fortschreitenden amerikanischen Dominanz erblicken wollte (vgl. Jeanneney 2006). Immerhin hat sie Gegenbewegungen provoziert und z. B. die Gründung von Europeana (www.europeana.eu) befördert, mit der europäisches Kulturgut im Internet zur Verfügung gestellt wird.

13.4 | Open Access

Aufgrund ihrer technischen Verfasstheit ist eine digitale Publikation entschieden leichter zu kopieren und vor allem zu verteilen, als ein gedrucktes Buch. Das ist für Anbieter ein Problem, weil natürlich deren Geschäft bedroht ist, wenn sich ihr Produkt unkontrolliert und vor allem unbezahlt im Internet verbreitet. Verlage entscheiden sich daher häufig für ein proprietäres Datenformat, wie wir es in Amazons Kindle schon kennengelernt haben, oder sie versehen ihre als E-Book erscheinenden Produkte mit aufwändigen **Digital Rights Management-Systemen**, die eine Kopie verhindern.

Alternativ zu solchen kommerziell vertriebenen Büchern, die sich unter dem Oberbegriff des E-Books kategorisieren lassen, hat sich ein Publikationsmodell etabliert,

das von vielen als Allheilmittel gepriesen wird und das unter dem Begriff **Open Access** (OA) firmiert (vgl. Suber 2012). Open Access meint die kostenlose Zurverfügungstellung von (wissenschaftlichen) Texten im Internet ohne jede Einschränkung der Nutzung. Apologeten dieses Modells preisen vor allem, dass hiermit der Geist endlich wehen könne, wo er will und nicht mehr abhängig von der Finanzkraft eines Lesers oder einer Institution wie einer Universität ist. Hinzu kommen weitere, nicht zu unterschätzende Vorteile wie die Möglichkeit einer intelligenten Entwicklungshilfe für Länder, die sich die hohen Buch- und Zeitschriftenpreise der führenden Wissenschaftsnationen nicht leisten können, gleichzeitig aber verstärkt auf das Wissen als zentrale Ressource der Zukunft setzen; ein leichter Plagiatsnachweis; aber auch die zuletzt deutlich besser werdenden automatischen Übersetzungen, die natürlich auf elektronisch vorliegende Texte angewiesen sind. Die radikale Offenheit eines konsequent konzipierten Open Access kann zudem eingeschränkt werden, ohne dass die grundsätzliche Greifbarkeit der Publikation behindert wird. Die **Creative Commons-Lizenz** erlaubt eine abgestufte, vom Autor festzulegende Rechteeinschränkung, die etwa die Integrität und die kommerzielle Nutzung eines Textes betrifft bzw. festlegt, dass der Autor benannt werden muss (vgl. Lessig 2006; s. Kap. 24.2).

Finanzierung: Den vielen Vorteilen von Open Access steht ein zentraler Nachteil entgegen, der bislang noch nicht befriedigend neutralisiert wurde, und das ist die problematische Finanzierbarkeit des Open Access-Modells. Wurden bislang mindestens Teile der Publikationskosten von den Erlösen des Verkaufes bestritten, so fallen diese unter Open Access-Bedingungen weg. Eines nämlich ist klar: Auch Open Access ist nicht umsonst zu bekommen, weil alle bislang anfallenden Kosten, außer denen des Druckes, bestehen bleiben. ›Author pays‹ heißt die häufig genannte Lösung, und bei institutionell verankerten Wissenschaftlern mag die jeweilige Institution für die Kosten einspringen. Andererseits hat eine viel diskutierte Studie der Max Planck Digital Library gezeigt, dass die komplette Konversion des bisherigen Druck-Publikationswesens in Open Access mit den vorhandenen Mitteln, die zur Zeit vor allem in die wissenschaftlichen Bibliotheken fließen, bestritten werden kann (vgl. Schimmer 2006). Ein Anzeichen für dieses Faktum mag man in der Entstehung der *knowledge unlatched*-Initiative erblicken (www.knowledgeunlatched.org), in der Bibliotheken Verlage dafür bezahlen, dass ein bestimmtes Buch oder eine ganze Gruppe von Büchern in das Open Access überwechseln.

Für institutionell gebundene Wissenschaftler ist Open Access eventuell machbar, und sie können sich dafür auch der Kompetenz eines Verlages bedienen. Denn auch Verlage entdecken immer häufiger, dass Open Access ein Geschäftsmodell sein kann. Aber unabhängige Forscher können auf die Finanzkraft der Institution nicht zurückgreifen. Sie sind gezwungen, eine immerhin auch mögliche Billiglösung zu wählen, die im simplen Hochladen einer Datei auf ein Repositorium besteht – und greifen damit auf das schon erwähnte Modell des *self-publishing* im allgemeinen Buchmarkt zurück.

Auch **Werbung** hierfür kann in Internet-Zeiten von den Autoren selber geleistet werden, wenn sie sich der vorhandenen Social Media bedienen und Aggregationsplattformen wie das erwähnte *academia.edu* einsetzen. Das ist im Übrigen eine Perspektive, die auch für etablierte Wissenschaftler und insbesondere den Aufmerksamkeit suchenden wissenschaftlichen Nachwuchs immer wichtiger wird. Das sind vor allem die Verfasser von Qualifikationsschriften wie Dissertation und Habilitation, für die viele Universitätsbibliotheken inzwischen eigene Repositorien angelegt haben, die teilweise, wie in der Kunstgeschichte, auch fachorientiert sind und

nicht nur Erzeugnisse aus dem eigenen Haus publizieren (<http://archiv.ub.uni-heidelberg.de/artdok/>). Eines allerdings kann ein verlagsunabhängig betriebenes Open Access nicht auf Anhieb leisten, denn auch Reputation entscheidet über Akzeptanz: Ein zuweilen mehrere hundert Jahre alter Verlag hat ein Renommee aufgebaut, das unmöglich in kurzer Zeit zu reproduzieren ist.

13.5 | Neue Publikationsmodelle im Digitalen

Nano-Publikationen: Ein großer Teil der Kosten, von denen hier die Rede ist, entsteht dadurch, dass Lektorat und satztechnische Einrichtung auch unter Open Access-Bedingungen zu leisten sind, mindestens dort, wo man sich an Vorgaben hält, die aus dem traditionellen, gedruckten Publikationswesen stammen. Andere, erst mit dem Internet ins Zentrum der Aufmerksamkeit gerückte Modelle sind hiervon, wenn überhaupt, weniger betroffen. Typischerweise sind dies kleinformatigere Veröffentlichungsformen, die im Umfang noch unterhalb der üblichen Länge eines Zeitschriftenaufsatzes liegen und damit tendenziell auch eher einen Statement-Charakter besitzen bzw. sich dem Typus der mündlichen Kommunikation annähern. Gemeint ist das *Weblog* (*Blog*), das inzwischen auch in den Wissenschaften großen Zulauf hat, der *Tweet*, der die schon im Weblog üblicherweise eingeschränkte Beitragslänge auf gerade einmal 140 Zeichen reduziert, und die radikalste Form, die ihre Kürze schon im Namen eingeschrieben hat, die sogenannte Nano-Publikation (vgl. Mons/Velterop 2009). In der gängigsten Definition besteht eine solche Publikation nur aus einem RDF (*Resource Description Framework*)-Tripel, der wiederum aus Subjekt, Prädikat, und Objekt aufgebaut ist, zusätzlich aber annotiert werden kann (s. Kap. 11.4). Die Idee dahinter ist, dass über geeignete Software diese Kleinstinformationseinheiten zu beliebig komplexen Aussagen zusammengestellt werden können.

An diesem radikalen Ende der Möglichkeiten, nur noch im Digitalen zu realisieren und denkbar weit von dem vorhin als rückwärtsgewandt bezeichneten PDF-Format entfernt, kann eine einzige Aussage zu einer Publikation werden. Genau genommen besteht ja ansonsten jede auch größere Veröffentlichung aus einer Ansammlung von Tripeln, nur dass diese nicht entsprechend kodiert und damit interoperabel gemacht werden, so dass der automatisierte Aufbau *bottom up* von komplexeren Sinneinheiten unmöglich wird.

Digitales Publizieren hat viele Facetten, aber die wichtigste soll hier erst am Schluss benannt werden. All die in diesem Buch beschriebenen analytischen Operationen, die an Texten und anderen Medieninhalten unternommen werden können, haben zur Voraussetzung, dass die analysierten Objekte in **digitaler Form** vorliegen, seien es solche wissenschaftlicher oder belletristischer Art. So wie das zu analysierende historische Material digital vorhanden sein muss, um wie beschrieben behandelt zu werden, kann man Entsprechendes auch von den Texten erwarten, die solche Untersuchungen vornehmen: Eine zukünftige Kunst-, Literatur- und Wissenschaftsgeschichte wird dann auch auf der Grundlage von Digitalisaten stattfinden können und den traditionellen Verfahren eine bedeutsame Dimension hinzufügen.

Literatur

- Büttner, Stephan/Hobohm, Hans-Christoph/Müller, Lars (Hg.): *Handbuch Forschungsdatenmanagement*. Bad Honnef 2011.
- Casebourne, Imogen et al.: *Assessing the accuracy and quality of Wikipedia entries compared to popular online encyclopaedias: A comparative preliminary study across disciplines in English, Spanish and Arabic*. Brighton 2012. Online: http://commons.wikimedia.org/wiki/File:EPIC_Oxford_report.pdf (31.10.2016).
- Fitzpatrick, Kathleen: *Planned Obsolescence. Publishing, Technology, and the Future of the Academy*, New York 2011.
- Jeanneney, Jean-Noël: *Googles Herausforderung. Für eine europäische Bibliothek*. Berlin 2006.
- Kuklick, Christoph: *Die granulare Gesellschaft. Wie das Digitale unsere Wirklichkeit auflöst*. Berlin 2014.
- Lessig, Lawrence: *Freie Kultur: Wesen und Zukunft der Kreativität*. München 2006.
- Mons, Barend/Velterop, Jan: »Nano-Publication in the e-science era« (2009), [https://www.w3.org/wiki/images/4/4a/HCLS\\$ISWC2009\\$Workshop\\$Mons.pdf](https://www.w3.org/wiki/images/4/4a/HCLS$ISWC2009$Workshop$Mons.pdf) (31.10.2016).
- Schanze, Helmut: *Handbuch der Mediengeschichte*. Stuttgart 2001.
- Schimmer, Ralf/Geschuhn, Kai Karin/Vogler, Andreas: *Disrupting the subscription journals' business model for the necessary large-scale transformation to open access. A Max Planck Digital Library Open Access Policy White Paper* (2006), <http://pubman.mpg.de/pubman/faces/viewItemOverviewPage.jsp?itemid=escidoc:2148961> (15.12.2016).
- Suber, Peter: *Open Access*. Cambridge, Mass. 2012.

Hubertus Kohle

14 Digitale Wissensproduktion

»The tools we use to think
change the ways in which we think.«
(Sherry Turkle 2004)

14.1 | Was ist digitale Wissensproduktion?

Die Produktion gesicherten Wissens in der Forschung ist (gemeinsam mit der Vermittlung solchen Wissens und entsprechender Methoden in der Lehre) eine der grundlegenden Aufgaben des Wissenschaftssystems. Dabei ist mit dem Begriff der Wissensproduktion der Prozess gemeint, in dem aus vorgefundenen oder eigens erhobenen **Daten** durch das Erkennen und Dokumentieren von Regelmäßigkeiten, Strukturen und Bedeutungen **Informationen** extrahiert werden und aus diesen Informationen wiederum, durch ihre kontextualisierende Verbindung mit bestehendem Wissen, durch ihre Perspektivierung auf Forschungsfragen oder -hypothesen hin und durch ihre kritische Überprüfung, **Wissen** gewonnen wird. Wissen in diesem Sinne sind strukturierte, bedeutungsvolle und wahre (genauer: bisher nicht falsifizierte) Informationen (vgl. Floridi 2010; kritisch, Frické 2008).

Um dies an einem vereinfachten Beispiel zu veranschaulichen: Eine Sammlung von 2000 Historienbildern in Form (analoger oder digitaler) Reproduktionen kann man als Daten auffassen. Wenn man nun einerseits die jeweils dominanten Farben in all diesen Bildern identifiziert und andererseits das Entstehungsdatum jedes Bilds erhebt und so feststellt, wie sich die dominanten Farben über die Entstehungszeit der Bilder hinweg verteilen, haben die Daten eine Struktur bekommen und es liegen Informationen vor. Erst wenn man diese Informationen nun z. B. mit Wissen zu den technischen Grundlagen der Farbherstellung verbindet und dafür nutzt, um eine spezifische Hypothese zur Entwicklung der Farbgebung in der Historienmalerei zu verifizieren, entsteht auf Grundlage der Daten und Informationen neues Wissen, neue wissenschaftliche Erkenntnis.

Unter welchen sozialen, historischen und technischen Rahmenbedingungen die Produktion wissenschaftlicher Erkenntnis vonstattgeht und wie sich dies über die Zeit verändert, ist Gegenstand der **Wissenschaftsforschung** (vgl. Felt et al. 1995; Weingart 1999). Im vorliegenden Kapitel steht die wesentlich spezifischere Frage im Vordergrund, wodurch die *digitale* Wissensproduktion gekennzeichnet ist: Wie verändern sich die Methoden und Verfahren der Wissensproduktion, wenn die Untersuchungsgegenstände in digitaler Form verfügbar sind? Die Digital Humanities sind die zunehmend sichtbare Manifestation dieser Veränderungen in den Geisteswissenschaften. Diese betreffen den gesamten Prozess der Wissensproduktion, vom Erheben der Daten über ihre Strukturierung bis hin zur Formulierung neuen Wissens und seiner Verbreitung. In mancherlei Hinsicht wird wissenschaftliches Arbeiten hier schlicht einfacher oder effizienter, ohne sich in seinen grundlegenden Annahmen und Funktionsweisen zu verändern. Zugleich gibt es aber auch zahlreiche Aspekte der Wissensproduktion, die tiefgreifenden qualitativen Veränderungen unterworfen sind, weil hier Verfahren eingesetzt werden, die nur im digitalen Medium realisierbar sind, ganz eigene Herausforderungen mit sich bringen und neue Fragestellungen ermöglichen oder aufwerfen (s. Kap. 2).

Einige ausgewählte Bereiche dieser veränderten Formen der Wissensproduktion in den digitalen Geisteswissenschaften werden im Folgenden vorgestellt: der Umgang mit Datenbanken, das Crowdsourcing und das kollaborative Schreiben. (Weitere relevante Bereiche sind u. a. das wissenschaftliche Publizieren und die quantitative Analyse; s. Kap. 13 bzw. 20.) Dabei sollen die beschriebenen Ansätze auch als Grundlage dienen, um nach maßgeblichen Konsequenzen der digitalen Revolution für den Prozess der Wissensproduktion zu fragen.

14.2 | Umgang mit Datenbanken

Welchen Unterschied macht es im Vergleich zu etablierten Verfahren der Wissensproduktion, wenn die Untersuchungsgegenstände nicht als reale Gegenstände der analogen Welt vorliegen (als Bücher, Filme, Gemälde, Urkunden oder Artefakte), sondern als digitale Daten, die diese Gegenstände repräsentieren? Dieser Frage wird hier am (hypothetischen) Beispiel der Arbeit mit einer **relationalen Datenbank** zu metaphorischen Ausdrücken in einer Gedichtsammlung nachgegangen (zu Datenbanken s. auch Kap. 8; vgl. Ramsay 2004).

Zunächst zur Datenbank. Sie beinhaltet, so sei angenommen, Informationen zu allen in einer Sammlung von 500 französischen Gedichten aus dem 19. Jahrhundert vorgefundenen Metaphern. Zu jeder Metapher enthält die Datenbank die relevante Textpassage aus dem Gedicht sowie eine Kategorisierung der Metapher nach ihren Gegenständen und ihren formalen Charakteristika. Die Datenbank enthält zudem zu jedem Gedicht sein Entstehungsjahr, seinen Autor und seinen Typ.

Der zentrale Unterschied der digitalen Verfügbarkeit der Daten in Form einer Datenbank (etwa gegenüber einer einfachen Liste) ist ihre computergestützte **Manipulierbarkeit**. Dies bedeutet einerseits, dass die Daten mit Hilfe des Computers durchsucht, gefiltert und geordnet werden können, was einen schnellen und flexiblen Zugriff erlaubt und einen produktiven Umgang mit größeren Datenbeständen überhaupt erst ermöglicht. So erleichtert die Datenbank beispielsweise das Entdecken von ähnlichen Metaphern in unterschiedlichen Gedichten. Andererseits werden die Metaphern und die über sie festgehaltenen Eigenschaften quantifizierbar, wodurch unter anderem die Frage beantwortet werden kann, welche Dichter in größtem Umfang Metaphern verwendet haben. Aber auch komplexere Zusammenhänge, beispielsweise Korrelationen zwischen dem Thema der Metaphern und ihrer formalen Ausgestaltung oder Präferenzen von Autoren für bestimmte Typen von Metaphern, können so entdeckt werden.

Die für den sinnvollen Einsatz einer Datenbank notwendige Erschließung der digitalen Untersuchungsgegenstände erfordert dabei große Explizitheit, Formalisierung und Kohärenz. Nur wenn für jedes Gedicht die Information zum Entstehungsjahr vorliegt, kann sich eine **Suchfunktion** darauf stützen. Nur wenn eine eindeutige, formal ausgedrückte Definition dessen vorliegt, was eine Metapher ist, können die Metaphern tatsächlich gezählt werden. Schließlich: nur wenn für die Klassifikation der Metaphern ein System klar definierter und gut voneinander abgegrenzter Klassen verwendet wurde, können sinnvolle Suchanfragen erfolgen (s. Kap. 11 zu »Ontologien«).

Einen zentralen Effekt des Arbeitens mit einer Datenbank kann man als **Rekonfiguration** des Materials bezeichnen. Damit ist gemeint, dass es zu einer Auflösung der linearen Lektüre kommt, bei der ein Gedicht nach dem anderen von Anfang zum

Ende gelesen wird. Stattdessen werden die metaphorischen Passagen je nach Filterung selektiv und je nach Suchabfrage in immer neuen Konstellationen gelesen. Jede Metapher wird aus ihrem Kontext im Gedicht, in dem sie ursprünglich stand, herausgerissen. Zugleich wird sie aber in den neuen Kontext all derjenigen Metaphern gestellt, die das Ergebnis eines bestimmten Filters, einer Suche oder Sortierung sind. Schließlich ist damit auch der iterative Charakter der Arbeit mit einer Datenbank bezeichnet, denn Suchabfragen führen zu einem verbesserten Verständnis des Gegenstands und gegebenenfalls auch zu neuen Klassifikationen. So kann eine Datenbank zu einem flexibel und produktiv einsetzbaren Werkzeug der Datenererschließung und -strukturierung werden.

14.3 | Crowdsourcing

Digitale Daten sind nicht nur computergestützt manipulierbar, sondern dank des Internets auch unabhängig von Zeit und Ort verfügbar. Dies ermöglicht u. a. die Bearbeitung von Datenbeständen durch größere Gruppen von Personen in der Form des sogenannten Crowdsourcing, bei dem eine (größere) Aufgabe durch zahlreiche kleinere Beiträge vieler verschiedener Menschen bearbeitet wird. Allgemeiner fasst man unter dem Begriff der »Citizen Science« all jene wissenschaftlichen Unternehmungen, bei denen die Öffentlichkeit in den Forschungsprozess eingebunden wird (vgl. DICKEL/Franzen 2015).

Ein mit diesen Konzepten eng verwandtes Prinzip ist das des »Web 2.0« (O'Reilly 2005). Gemeint ist damit eine (im Vergleich zum Printmedium bzw. klassischen Geschäftsmodellen) radikale Verschiebung des Verhältnisses zwischen den Anbietern und den Rezipienten von Inhalten bzw. Produkten. Um nur drei Beispiele zu nennen: statt dass ein Händler lediglich seine Produkte an Kunden verkauft, werden auf Online-Verkaufsplattformen nicht nur die Produktbeschreibungen der Hersteller durch Bewertungen und Kommentare der Kunden ergänzt, sondern die Kunden können auch selbst wiederum als Verkäufer auftreten; statt dass wenige etablierte Experten eine Enzyklopädie schreiben, die dann von vielen Lesern rezipiert wird, werden bei Wikipedia die Leser selbst zu Textproduzenten und rezipieren den sogenannten »user-generated content« gegenseitig (siehe unten). Und statt dass eine Firma Programmierer dafür bezahlt, eine bestimmte Software zu entwickeln und diese dann verkauft, wird open-source Software auf Plattformen wie GitHub kollaborativ entwickelt und kann frei genutzt und jederzeit verändert werden.

Auf die Wissenschaft übertragen bedeutet dies, dass nicht mehr nur wenige hochspezialisierte Experten wissenschaftliche Erkenntnis generieren, die dann von einer interessierten Leserschaft rezipiert werden, sondern dass alle Mitglieder einer Gesellschaft am Prozess der Wissensproduktion aktiv teilhaben können. Bedingung für erfolgreiches wissenschaftliches Crowdsourcing ist, dass die Aufgabe in geeigneter Weise in kleinere Einzelschritte (sog. *microtasks*) zerlegt werden kann, die sich für die Bearbeitung durch interessierte Laien eignen. Besonders passend für wissenschaftliches Crowdsourcing erscheinen Projekte, bei denen es um die Transkription von digitalen Faksimiles oder um die Annotation von Ressourcen geht. Zudem müssen **Anreizstrukturen** geschaffen werden, welche die beteiligten Personen dazu motivieren, präzise und konstruktiv zu arbeiten. Diese Anreize können finanzieller Art sein oder auf einem psychologischen Belohnungssystem beruhen, beispielsweise indem konstruktiven Nutzern einer Plattform nach und nach weiterreichende Hand-

lungsoptionen auf der Plattform eingeräumt werden. Eine Alternative hierzu ist die sogenannte »**Gamification**«, bei der spielähnliche Strukturen geschaffen werden, indem eine symbolische Welt, eine Konkurrenzsituation und/oder Zeitdruck inszeniert werden und die Teilnehmer so zu Spielern mit intrinsischer Motivation werden.

Beispiele für Crowdsourcing-Projekte aus den Digital Humanities

- *Transcribe Bentham* (University College London) – <http://blogs.ucl.ac.uk/transcribe-bentham/>.
- *Letters of 1916* (University of Maynooth) – <http://letters1916.maynoothuniversity.ie/>.
- *Artigo* (LMU München) – <http://www.artigo.org>.
- *L-Crowd* (National Diet Library, Japan) – <http://crowd4u.org/en/projects/lcrowd>

Ein prominentes und sehr gelungenes Beispiel für diesen Ansatz ist das kunsthistorische Projekt **Artigo**. Das Projekt befasst sich mit der Erschließung einer Sammlung von 25.000 digitalisierten Gemälden. Ohne Informationen über die dargestellten Inhalte und stilistischen Merkmale kann eine solche Bildsammlung nicht sinnvoll durchsucht werden. Anstatt nun eine kleine Gruppe Kunsthistoriker mit der Annotation der Bilder zu beauftragen, wurde ein Spiel entwickelt, bei dem Spieler ein Bild präsentiert bekommen, beschreibende Schlagworte angeben sollen und dafür Punkte erhalten. Das Anreizsystem beruht hier erstens darauf, dass die Spieler unter Zeitdruck stehen, denn pro Bild haben sie nur 60 Sekunden Zeit. Und sie befinden sich in einer Konkurrenz-Situation, denn es gibt immer mehrere Spieler und es wird ein Ranking der besten Spieler geführt.

Dieses Annotationsspiel ist so erfolgreich, dass seit dem Start im Jahr 2008 durchschnittlich 150 aktive Spieler pro Tag auf die Plattform kommen und bisher rund 10 Millionen Schlagwörter für die Bilder vergeben haben (vgl. Kohle 2011; Bry et al. 2015). Die erhobenen Informationen machen allerdings auch deutlich, wo die Grenzen eines solchen Ansatzes liegen, denn die Mehrzahl der Schlagwörter bezieht sich auf Inhalte oder Farben der Bilder. Diese Informationen sind zwar für Suchfunktionen außerordentlich nützlich, ebenfalls interessante, kunsthistorisch relevante Eigenschaften der Bilder wie deren epochenspezifische oder stilistische Merkmale werden von den Spielern aber wesentlich seltener erfasst.

14.4 | Kollaboratives Schreiben: Wikipedia

Während es beim Umgang mit der Datenbank um die Datenmanipulation und beim Crowdsourcing um das Explizitmachen von beschreibenden Informationen ging, wird mit dem **kollaborativen Schreiben** ein Aspekt der digitalen Wissensproduktion angesprochen, der diesen Prozessen meist folgt und Wissen festhält und vermittelt. Lange Zeit war Schreiben ein individueller und nach außen hin abgeschotteter Vorgang, der in einem ausgefeilten, stabilen Text gipfelte. Zugleich ist Schreiben schon immer auch ein, allerdings vermittelt, kommunikativer Prozess, insofern bereits vorhandene Diskurse zu einem Thema in den neuen Text einfließen.

Einige Tools für kollaboratives Schreiben

Mediawiki: Präzise Versionierung, vielfältige Funktionen, separate Diskussions-Seiten; Open Source. <https://www.mediawiki.org/>.

Etherpad: Leichtgewichtig und einfach; wenige Formatierungsoptionen; Open Source; kostenfreie, gehostete Angebote. <http://etherpad.org/>.

Google Docs: Nutzerfreundlich, weit verbreitet, großer Funktionsumfang; kosten-freies Angebot eines Unternehmens mit kommerziellen Interessen. <https://www.google.com/intl/de/docs/about/>.

Wordpress: Bewährt und stark erweiterbar; Blog-Software, die sich zu einem voll-wertigen CMS (Content Management System) entwickelt hat; <https://wordpress.com/>.

Etablierte elektronische Textverarbeitungsprogramme unterstützen den Schreibprozess seit Jahrzehnten, allerdings eher im Sinne einer **Remedialisierung** des Printmediums, dessen Eigenschaften in vielerlei Hinsicht nachgeahmt werden. Das seitenbasierte Layout und die Fußnoten oder das isolierte Schreiben des Textes auf dem persönlichen Rechner sind nur einige Aspekte dieser Remedialisierung. Kollaboratives Schreiben hingegen wird idealer Weise von web-basierten Tools unterstützt.

Das herausragendste Beispiel für kollaboratives Schreiben unter den Vorzeichen des Web 2.0 ist sicherlich *Wikipedia* (vgl. Haber 2007), wo alle Leser potentiell auch Autoren sein können. Aufgabe der Plattform ist es, den technischen, institutionellen und nicht zuletzt sozialen Rahmen anzubieten, der es ermöglicht, dass hunderttausende Menschen gemeinsam das Wissen der Menschheit zusammentragen. Zu jedem eigentlichen Artikel gibt es beispielsweise eine Diskussionsseite (wo Nutzer über die Artikel diskutieren können) und eine Versionsgeschichte (die jede noch so kleine Änderung an einem Artikel dokumentiert). Dabei ist der Slogan von *Wikipedia*, »the encyclopedia that anyone can edit« zwar richtig, aber auch etwas irreführend: In der Tat kann jeder die Inhalte von *Wikipedia* verändern, allerdings geschieht dies unter sehr strukturierten Rahmenbedingungen, zu denen neben redaktionellen Vorgaben insbesondere einige Grundprinzipien sowie Mechanismen der Qualitätssicherung gehören.

Zu den **Grundprinzipien** von *Wikipedia* gehören das Ideal des neutralen Standpunkts und die Verbannung von Theoriefindung. Das Ideal des »Neutralen Standpunkts« soll dazu führen, dass die Inhalte sachlich dargestellt werden, ohne dass die Autoren ihren persönlichen Standpunkt einbringen. Genauer gesagt, zielt ein guter Artikel (durchaus nicht nur bei kontroversen Themen) darauf ab, verschiedene wichtige Standpunkte in einem ausgewogenen Verhältnis zur Sprache zu bringen. Die Verbannung von Theoriefindung meint, dass Autoren nicht auf der Grundlage eigener, forschender Auseinandersetzung mit einem Gegenstand, sondern stets unter Bezug auf vorhandene Forschungsliteratur schreiben und dies durch Belege nachweisen sollen.

Über diese normativen Vorgaben hinaus bestehen bei *Wikipedia* auch Mechanismen der **Qualitätssicherung**, zu denen konstruktive Mechanismen wie der Artikel-Review (hier prüfen erfahrene Wikipedia-Autoren neuere Artikel und machen Verbesserungsvorschläge), Anreizsysteme (wie die Auszeichnung von Artikeln als »lesenswert« oder »exzellent«) und repressive Mechanismen (wie der Löschantrag bzw. die Löschprüfung) gehören. In der Praxis zeigt sich in diesem Kontext, dass *Wikipedia* nicht so frei von Hierarchien ist, wie es gelegentlich dargestellt wird: Erfahrene

Autoren dominieren häufig diese Prozesse der Qualitätssicherung und sogenannte Administratoren (Nutzer mit besonderen Rechten) entscheiden in Streitfällen (hierzu ausführlich Stegbauer 2009).

Schreibprozesse, die wie Wikipedia die Möglichkeiten des Digitalen und des Internets genuin nutzen, sind **kollaborativ und kommunikativ, offen und unabgeschlossen** sowie **vernetzt**. Sie sind kollaborativ und kommunikativ, weil an einem gegebenen Text mehrere Personen gleichzeitig oder nacheinander schreiben können und zugleich bei der Kommunikation über den Text unterstützt werden. Sie sind offen und unabgeschlossen, weil der Entstehungsprozess des Textes prinzipiell bereits öffentlich von statten gehen kann und häufig transparent nachvollziehbar bleibt und weil ein bereits publizierter Text prinzipiell weiter kommentiert und verändert werden kann. Und sie sind vernetzt, insofern bestehende Diskurse, wie andere Wikipedia-Artikel und Forschungsliteratur, direkt eingebunden oder verlinkt werden können.

14.5 | Konsequenzen

Die drei beschriebenen Bereiche der digitalen Wissensproduktion haben weitreichende Konsequenzen nicht nur für den Prozess der Wissensproduktion im jeweiligen konkreten Projekt selbst, sondern auch für das Selbstverständnis der Wissenschaftler und die disziplinäre Verfasstheit von Wissenschaft insgesamt. So wirft das Crowdsourcing die Frage auf, ob dieses die **Demokratisierung** und Offenheit der Wissenschaft fördert, insofern auch Bürger, die nicht an einer wissenschaftlichen Einrichtung arbeiten, aktiv an der Wissensproduktion teilhaben. Oder nutzt die Wissenschaft hier nur billige oder gar kostenlose Arbeitskräfte für ihre Zwecke?

Datenbanken, insofern sie ein explizites und systematisches Datenmodell erfordern, können als Motoren einer **Formalisierung** der Wissenschaft angesehen werden, auch wenn der kreative und flexible Umgang mit Datenbanken und ihren Datenmodellen nicht unterschätzt werden sollte. Schließlich ist eine Konsequenz des kollaborativen Schreibens, dass **Arbeitsteilung** und damit Spezialisierung möglich werden, wenn zahlreiche Autoren mit unterschiedlichen Kompetenzen und Interessen an einem gemeinsamen Text arbeiten. Insgesamt gilt sicherlich, dass die Bearbeitung geisteswissenschaftlicher Fragestellungen mit digitalen Methoden und Technologien eine inhärente **Transdisziplinarität** befördert, weil informatische und domänenspezifische Kompetenzen in einem Projekt zusammengeführt werden müssen. Zwischen diesen Bereichen zu vermitteln und eine genuin digitale, konstruktive und erfolgreiche Wissensproduktion zu ermöglichen, ist eine der zentralen Aufgaben digitaler Geisteswissenschaftler.

Literatur

- Bry, François/Schemainda, Corina/Schefels, Clemens: *A Gaming Ecosystem Crowdsourcing Deep Semantic Annotations*. München 2015.
- Dickel, Sascha/Franzen, Martina: *Wissenschaft im digitalen Wandel: Demokratisierung von Wissensproduktion und Wissensrezeption?* Berlin 2015. Online: <http://hdl.handle.net/10419/108962> (31.10.2016).
- Felt, Ulrike/Nowotny, Helga/Taschwer, Klaus: *Wissenschaftsforschung. Eine Einführung*. Frankfurt a. M. 1995.
- Florida, Luciano: *Information. A Very Short Introduction*. Oxford 2010.

- Frické, Martin: »The knowledge pyramid: A critique of the DIKW hierarchy«. In: *Journal of Information Science* 35/2 (2008), 131–42.
- Haber, Peter: »Weltbibliothek oder Diderots Erben? Traditionslinien von Wikipedia«. In: *Informatik* 37 (2007).
- Kohle, Hubertus: »Kunstgeschichte goes social media«. In: *Aviso* 3 (2011).
- O'Reilly, Tim: »What is Web 2.0?«, <http://oreilly.com/web2/archive/what-is-web-20.html> (31.10.2016).
- Ramsay, Stephen: »Databases«. In: Susan Schreibman/Ray Siemens/John Unsworth (Hg.): *A Companion to Digital Humanities*. Oxford 2004. Online: <http://www.digitalhumanities.org/companion/>.
- Stegbauer, Christian: *Wikipedia: Das Rätsel der Kooperation*. Wiesbaden 2009.
- Turkle, Sherry: »How computers change the way we think«. In: *The Chronicle Review* 50/21 (2004), B26.
- Weingart, Peter: »Neue Formen der Wissensproduktion: Fakt, Fiktion und Mode«. In: *TA-Datenbank Nachrichten* 3/4, 8 (1999), 48–57.

Christof Schöch

15 Bibliothek, Archiv, Museum

15.1 | Gedächtnisinstitutionen

Bibliotheken, Archive und Museen werden unter dem Sammelbegriff **Gedächtnisinstitutionen** gefasst, da alle drei Organisationstypen die Hauptaufgabe haben, Informationen und Wissen zu sammeln, zu bewahren und zur Verfügung zu stellen. Sie stellen wesentliche Informationseinrichtungen in Deutschland dar und werden überwiegend durch die öffentliche Hand finanziert. Die Gedächtnisinstitutionen sind ein wichtiger Eckpfeiler des kulturellen und wissenschaftlichen Erbes und bieten durch die Bereitstellung und Erforschung der dort gesammelten Informationen den Schlüssel für das Verständnis der Vergangenheit, Gegenwart und Zukunft. Daneben gibt es einige bedeutende, privat finanzierte Einrichtungen zum Beispiel von Firmen oder Privatleuten.

Der Begriff **Bibliothek** kommt aus dem Alt-Griechischen (*biblio-thékē*) und bezeichnet Behältnisse für Papyrusblätter und -rollen. Heutzutage wird er hauptsächlich auf Sammlungen von Büchern, Zeitschriften, Hochschulschriften etc. bezogen und mit dem Einzug der Digitalisierung auch auf Sammlungen von E-Books (z. B. Lehrbücher), Digitalisaten (s. Kap. 12) von zum Beispiel alten Handschriften etc. Zentrale Aufgaben von Bibliotheken sind das ›Sammeln‹, ›Erschließen‹, ›Vermitteln‹ und ›Archivieren‹ von analogen sowie digitalen Informationen. Bibliotheken sind verantwortlich für die Versorgung der Gesellschaft und Wissenschaft mit Literatur aller Lebensbereiche aus Gegenwart und Vergangenheit und leisten damit einen zentralen Beitrag zur **Informationsversorgung** von Bevölkerung und Wissenschaft.

Das Kompetenznetzwerk Bibliotheken (knb, das Bibliotheksportal des Deutschen Bibliotheksverbandes) bietet ein umfassendes Angebot zu Bibliotheken in Deutschland. Das Portal Deutsche Bibliotheksstatistik (dbs) gibt einen Überblick über alle wichtigen Kennzahlen in den Bereichen Ausstattung, Bestand, Entleihungen, Ausgaben, Finanzen und Personal der Öffentlichen und Wissenschaftlichen Bibliotheken Deutschlands. Die Deutsche Nationalbibliothek hat per Gesetz die Verantwortung, lückenlos alle deutschen und deutschsprachigen Publikationen ab 1913 zu sammeln, dauerhaft zu archivieren, zu katalogisieren sowie der Öffentlichkeit zur Verfügung zu stellen. Daneben gibt es verantwortliche wissenschaftliche Bibliotheken für die Verzeichnisse der im deutschen Sprachraum erschienenen Drucke (VD) der verschiedenen Jahrhunderte, zum Beispiel für das 16. und 17. Jahrhundert die Bayerische Staatsbibliothek.

Der Begriff **Archiv** kommt aus dem Lateinischen (*archivum*) bzw. Alt-Griechischem (*archeíon*) und bezeichnet einen Aktenschrank bzw. ein Amtsgebäude. Darin wird das sogenannte Archivgut gesammelt, aufbewahrt und unter bestimmten Voraussetzungen zur Verfügung gestellt. Archive der öffentlichen Hand unterliegen Archivgesetzen, die genau regeln, was gesammelt und aufbewahrt werden muss, und erfüllen somit gesetzliche Pflichtaufgaben wie zum Beispiel die unbefristete Aufbewahrung von Behördenunterlagen. Archive sammeln Akten und Urkunden, die als Ergebnis schriftlicher Geschäftsprozesse bei zum Beispiel Regierungsstellen, Behörden und Gerichten entstehen. Daneben gibt es noch Archive von Privatunternehmen, von Zeitschriftenverlagen (z. B. Pressearchiv) etc. Das Bundesarchiv hat den gesetzlichen Auftrag, das Archivgut des Bundes auf Dauer zu sammeln, langfristig zu sichern und für die Nachnutzung bereit zu stellen. Dabei kann es sich um Unter-

lagen wie Akten, Karten, Bilder etc. aber auch um Tonaufzeichnungen (z. B. Reden im Bundestag) handeln. Archive bewahren nur etwa 2 % bis 5 % der potentiell möglichen Unterlagen auf. Dies bedeutet, dass Archivare entscheiden müssen, welche Unterlagen, Akten und Dokumente einen relevanten Wert für die Erforschung oder das Verständnis der deutschen Geschichte (z. B. schriftliche Nachlässe von bedeutenden Personen), die Sicherung berechtigter Belange der Bürger (z. B. Unterlagen von Parteien) oder die Bereitstellung von Informationen für Gesetzgebung, Verwaltung und Rechtsprechung haben.

Der Begriff **Museum** leitet sich aus dem Alt-Griechischen (*mouseion*) ab und bezeichnet ursprünglich einen Musentempel wie zum Beispiel einen Ort, an dem Musenkünste veranstaltet wurden. Heutzutage ist damit eine (wissenschaftliche) Institution gemeint, die wichtige, lehrreiche oder einmalige Musealien in physischer Form sammelt, aufbewahrt, kategorisiert und ausstellt. Einige Sammlungen sind dabei immer wieder Gegenstand der Forschung in unterschiedlichen Disziplinen (z. B. Archäologie, Kunstgeschichte etc.). Die Musealien werden zu einem bestimmten Thema fachgerecht und dauerhaft gesammelt und in Dauer- oder Wechselausstellungen der Öffentlichkeit zugänglich gemacht. Neben den öffentlichen Museen, gefördert von der öffentlichen Hand, gibt es namhafte Privatmuseen (z. B. private Kunstsammlungen), Firmenmuseen und kirchliche Museen. Das Institut für Museumsforschung in Berlin ist das einzige Forschungsinstitut in Deutschland und beschäftigt sich u. a. mit den Themen Besucherforschung, Digitalisierung und Langzeitarchivierung, Museumsmanagement und -dokumentation, Neuen Medien und Museumsdidaktik (vgl. Walz 2016). Das Pergamonmuseum als archäologisches Museum ist eines der bedeutendsten Museen in Deutschland und verzeichnet eine der höchsten Besucherzahlen.

Alle Gedächtnisinstitutionen stehen im digitalen Zeitalter vor besonderen Herausforderungen. Es gilt in den nächsten Jahren, die immerhin öffentlich finanzierten Bestände zu digitalisieren und der Wissenschaft und Gesellschaft möglichst kostenfrei zur Weiterverwendung zur Verfügung zu stellen. Dazu muss spezielle Expertise in den jeweiligen Institutionen aufgebaut werden, die von der reinen Digitalisierung, über standardisierte Beschreibungen bis hin zu dem technischen Know-How reicht, um die einzelnen digitalisierten Objekte über geeignete Suchinstrumente zur Verfügung zu stellen. Dabei ist es unerheblich, ob es sich um reine Textseiten (z. B. digitalisierte Bücher oder Artikel), um Akten oder Museumsexponate (z. B. chinesische Ming-Vase) handelt. Da zunehmend mehr und mehr Informationen bereits in digitaler Form (z. B. E-Books, Videos) vorliegen, braucht es parallel dazu bereits eine geeignete Infrastruktur, um diese Digitalisate jetzt schon für potentielle Nutzergruppen nachhaltig auffindbar vorzuhalten und langfristig so zu speichern, dass auch zu einem späteren Zeitpunkt darauf zugegriffen bzw. bei Bedarf in einem geeigneten Dateiformat in Originalgröße heruntergeladen werden kann. Gerade Letzteres ist für die verschiedenen Fachdisziplinen sehr wichtig; jede Komprimierung in der Dateigröße führt z. T. zu erheblichen Qualitätsverlusten und z. B. Buchstaben bzw. Zeichen im Text werden undeutlich oder können gänzlich verschwinden.

15.2 | Einheitliche Beschreibung von Objekten und Sammlungen

Alle drei Organisationstypen erschließen ihre Materialien, d. h. Experten (Bibliothekare, Archivare, Museologen oder auch Fachwissenschaftler) beschreiben jedes einzelne Objekt in strukturierter und wenn möglich in standardisierter Form. Ohne diese einheitlichen Beschreibungen wäre es nicht möglich, die Objekte zu finden und zu wissen, welche Institution oder Einrichtung sie besitzt, unter welchen Bedingungen das Objekt vor Ort angeschaut, gegebenenfalls über Fernleihe ausgeliehen oder das entsprechende Digitalisat in einem Portal (s. u.) angeschaut bzw. heruntergeladen werden kann. Natürlich können nicht alle Objekte aus jeder Einrichtung ausgeliehen werden. Bibliotheken haben per se den Auftrag, ihre Informationsobjekte zugänglich zu machen, Museen stellen ihre Objekte in Ausstellungen zur Ansicht bereit und nur in Ausnahmefällen darf ein museales Objekt für z. B. Forschungszwecke ausgeliehen werden.

Die Archive wiederum dokumentieren in erster Linie den Kontext und den Entstehungsprozess bestimmter Vorgänge zum Beispiel in Behörden sowie Verwaltungen, die dann zu Entscheidungen und Gesetzen etc. führen. Hier ist das öffentliche Interesse, Unterlagen u. Ä. einzusehen, nicht so ausgeprägt wie die Suche nach wissenschaftlichen Publikationen in Bibliotheken oder nach Exponaten in Museen. Nichtsdestotrotz geht es allen drei Einrichtungen darum, jedes einzelne Objekt nachzuweisen und damit auffindbar zu machen. Der **Erschließung** kommt dabei besondere Bedeutung zu. Je besser ein Objekt beschrieben, d. h. erschlossen wird, desto präziser kann danach gesucht werden bzw. desto relevanter gestaltet sich die Trefferliste. Präziser suchen meint hier, nicht nur eine sogenannte »Einfache Suche« anzubieten, wie sie bei dem Suchmaschinendienst Google zu weit über 90 % von den Nutzern eingesetzt wird, sondern über bestimmte **Metadaten** die Möglichkeit zu haben:

- die Suche an Hand definierter Beschreibungselemente (Metadaten wie Titel, Autor etc.) durchzuführen,
- entlang inhaltlicher Metadaten (z. B. Schlagwort, Klassifikation) thematisch zu browsen,
- die Ergebnisliste weiter einzuschränken bzw. zu filtern,
- die Trefferliste nicht nur alphabetisch nach dem Titel zu sortieren, sondern andere Rankingoptionen wie z. B. Sortierung nach Erscheinungsjahr, nach der Sprache (z. B. des Fachartikels) etc. zu ermöglichen oder
- die Ergebnisse nach bestimmten, vorher gewählten Kriterien zu visualisieren (z. B. mit Hilfe von Orts- und Zeitangaben auf geographischen Karten).

Je ausgefeilter das Erschließungskonzept ist und je umfangreicher das einzelne Objekt beschrieben wird, desto besser sind die Möglichkeiten, in den Sammlungen zu recherchieren und auch wirklich relevante Treffer zu erhalten (s. Kap. 19). Neben der **formalen Erschließung**, die formale (objektive) Aspekte wie Autor, Erscheinungsjahr, Verlag etc. behandelt, gibt es auch die **inhaltliche Erschließung**, die zum Teil umfangreiches Fachwissen zum Beispiel zu dem Entstehungsprozess eines Objektes, der Provenienz zur Klärung von Besitzverhältnissen (Stichworte hier sind z. B. Raubgut, Echtheitszertifikate etc.) und thematischen Einordnung voraussetzt. Für die drei Organisationen wie Bibliothek, Archiv und Museum gibt es internationale, standardisierte

Metadatenkonzepte, die für eine einheitliche und strukturierte Beschreibung der analogen und digitalen Objekte verwendet werden.

Im Bereich Bibliothek ist dies **Resource Description and Access** (RDA, <https://www.loc.gov/aba/rda/>), ein internationaler Standard, der den Austausch von Katalogisaten weltweit erleichtern soll und in Deutschland die ›Regeln für die alphabetische Katalogisierung (RAK)‹ ablöst. Mit dem neuen RDA-Standard ist es auch möglich, die neuen, digitalen Objekte besser zu beschreiben und damit insgesamt dem digitalen Wandel weltweit Rechnung zu tragen.

Die Archive haben mit dem Standard **Encoded Archival Description** (EAD, <https://www.loc.gov/ead/>) eine Möglichkeit zur einheitlichen Kodierung von **Findmitteln und mit International Standard Archival Description** (ISAD-G, <http://www.ica.org/en/isadg-general-international-standard-archival-description-second-edition>) **eine Möglichkeit für den Nachweis** von Archivgut von Körperschaften, Personen und Familien und damit ebenfalls einen Standard für den weltweiten Austausch und Nachweis ihrer Objekte in relevanten Portalen.

Für den Bereich der Museen wurde mit dem **CIDOC Conceptual Reference Model** (CIDOC CRM, <http://www.cidoc-crm.org/>) der internationale Standard ISO 21127:2006 definiert, der für die einheitliche Erschließung von Kulturgütern gedacht ist. Dieser Standard ermöglicht ebenfalls den weltweiten Austausch und Nachweis von wissenschaftlichen und kulturell relevanten digitalen Objekten.

Erschließung: Einheitliche und strukturierte Beschreibung

Um eine Sammlung von analogen oder digitalen bzw. digitalisierten Objekten unter einer Such-Oberfläche (z. B. Portal, OPAC) durchsuchbar zu machen, müssen die Objekte einheitlich und strukturiert beschrieben werden. Einheitlich meint hier, dass ein gemeinsames Verständnis darüber herrschen muss, was ein Titel, ein Autor oder eine Datumsangabe ist. Gerade letzteres führt öfters zu Missverständnissen: Die amerikanische und europäische strukturierte Angabe zu einem Datum unterscheidet sich, in Deutschland wird meistens erst der Tag angegeben, dann der Monat und zum Schluss das Jahr (z. B. 04-06-1966 für den 4. Juni 1966). In den USA wird zuerst der Monat, dann der Tag und zuletzt das Jahr angegeben (z. B. 06-04-1966 für June 4th, 2016). Der internationale Standard für eine Datumsangabe (ISO 8601) nennt zuerst das Jahr, dann den Monat und zuletzt den Tag (z. B. 1966-06-04 für den 4. Juni 1966). Auch die Definition eines Datums muss eindeutig sein, sonst kann es passieren, dass von Zeitangaben mit unterschiedlichen Bedeutungen gesprochen wird. Das Erstveröffentlichungsdatum (z. B. bei Publikationen) ist inhaltlich eine andere Zeitangabe als ein Aktualisierungsdatum (z. B. bei einer digitalen Edition). Auch bei Dissertationen sind Datumsangaben wie Einreichung der Promotionsarbeit, Datum der Prüfung etc. unterschiedliche Informationen über das Objekt ›Dissertation‹.

Der Vorgang der Beschreibung von Objekten, unabhängig davon, ob es sich um gedruckte Bücher oder digitale Skulpturen handelt, wird **Erschließung** genannt. Dem Vorgang der Erschließung liegt optimaler Weise ein (internationaler) Metadatenstandard zugrunde, der die einzelnen Metadatenelemente wie Titel, Autor etc. inhaltlich definiert (z. B. bei Dublin Core der ›Titel‹: DC.Title – A name given to the resource) und bei Bedarf syntaktisch weiter definiert (z. B. bei Dublin Core das ›Datum‹ mit der Empfehlung, den Standard ISO 8601 zu verwenden: DC.Date – A point or period of time associated with an event in the lifecycle of the resource, mit der Syntax YYYY-MM-DD).

Je umfangreicher ein Metadatenstandard ist und je mehr Metadatenelemente zur Beschreibung von Objekten vorhanden sind, desto detaillierter und genauer kann ein Objekt oder eine Sammlung von Objekten beschrieben werden. Dabei ist es wichtig, international anerkannte (Metadaten-)Standards zu verwenden, um den Informationsaustausch über geographische und sprachliche Grenzen hinweg zu ermöglichen – gerade in Zeiten der Globalisierung und Digitalisierung!

15.3 | Wichtige Informationsportale

Die zunehmende Digitalisierung von Wissenschaft, Wirtschaft und Gesellschaft hat auch Auswirkungen auf die Gedächtnisinstitutionen, die die Nachweise ihrer Schriftgüter, Exponate, Akten, Ton- oder Videoaufzeichnungen etc. bereits seit Jahrzehnten in Online-Katalogen verzeichnen, die für jede Person von jedem Ort aus recherchierbar sind. Digitalisierung meint aber nicht nur die Recherche auf Verzeichnisebene, also etwa die Frage, in welcher Institution welches Buch oder welche Zeitschrift für die Ausleihe bereitliegt, sondern verstärkt den direkten Onlinezugriff auf das digitalisierte oder digitale Objekt. Im Textbereich können dies digitalisierte Bücher, Zeitschriftenartikel oder E-Books sein, im Bereich der Bilder z. B. digitalisierte Fotografien oder abfotografierte Gemälde, historische Karten etc. und bei den 3D-Objekten digitalisierte Skulpturen usw. Die Bundesregierung hat im Rahmen ihrer ›Digitalen Agenda‹ für den Bereich ›Bildung, Forschung, Wissenschaft, Kultur und Medien‹ einige Handlungsfelder definiert, dort heißt es u. a.: »Vor diesem Hintergrund werden wir Deutschland zu einem digitalen Kulturland weiterentwickeln. Dazu gilt es, ein qualitativ hochwertiges Angebot digitaler Inhalte zu sichern. [...] Ferner treiben wir die Digitalisierung von Kulturgut weiter voran und verbessern die Zugänglichkeit zum kulturellen und wissenschaftlichen Erbe in Archiven, Bibliotheken und Museen.«

Seit ca. 2005 hat es eine Reihe von Initiativen und Projekten gegeben, die sich mit der Digitalisierung und online-Bereitstellung von wissenschaftlicher Information beschäftigen. Dabei ist es wichtig zu beachten, dass einige Informationen ›nur‹ auf der Nachweisebene zugänglich sind, während andere Informationen auch zu dem Digitalisat direkt führen.

Recherche auf Nachweisebene bzw. direkter Zugriff auf das digitale Objekt

Aus dem analogen Zeitalter stammt die Idee, jedes Objekt wie z. B. ein Buch, eine Zeitschrift, eine CD-ROM oder ein Objekt im Museum wie zum Beispiel eine spät-römische Münze oder eine chinesische Ming-Vase mit Hilfe von (standardisierten) Metadaten zu erfassen, sprich zu katalogisieren. Dabei werden neben dem Titel des Objektes auch weitere Informationen in strukturierter Form erfasst, sei es der Autor des Objektes, das Entstehungsdatum, inhaltliche Schlagworte zur Beschreibung etc. Die gebündelten Informationen zu einem Objekt heißen auch **Katalogisat** oder bibliographische Aufnahme. Dafür gab es in früheren Jahrzehnten des 20. Jahrhunderts in den Bibliotheken die sogenannten Zettelkataloge, in denen meist mühevoll und händisch die einzelnen Katalogisate gesichtet und durchsucht werden mussten. Heutzutage geschieht dies fast nur noch elektronisch, d. h. die Katalogisate werden in einem Datenbanksystem gespeichert und über den

OPAC (Online Public Access Catalogue), einem öffentlich zugänglichen Online-Katalog, für die Suche zur Verfügung gestellt. Die Ergebnis- oder Trefferlisten bieten dabei in der Regel nur den Nachweis über ein Objekt an und nicht immer den direkten Zugriff auf den Volltext bzw. das Digitalisat. Damit weiß die suchende Person aber immerhin, in welcher Institution das Buch oder der Artikel (z. B. in welcher Bibliothek) vorhanden ist, ob es über die Fernleihe bestellt oder vor Ort eingesehen werden kann. Mit der zunehmenden Digitalisierung wird es in den kommenden Jahren selbstverständlicher werden, über die Suchanfrage in Portalen auch direkt auf das digitale Objekt zugreifen und (nach)nutzen zu können. Es ist wichtig zu verstehen, dass zwischen Nachweis (»dieses Objekt gibt es«) und Direktzugriff (»ich kann es mir direkt anschauen und unter Umständen für die Nachnutzung herunterladen«) unterschieden wird.

Im Folgenden wird eine Auswahl an relevanten Portalen vorgestellt, die zumindest auf der Nachweisebene sehr umfassend die verschiedenen Sammlungen und Bestände nachweisen und zum Teil auch den Direktzugriff auf das digitale Objekt erlauben.

Die Deutsche Digitale Bibliothek (DDB) (<https://www.deutsche-digitale-bibliothek.de/>) stellt das nationale Zugangsportal für Kultur und Wissenschaft in Deutschland dar mit dem Ziel, die digitalen Angebote der deutschen Kultur- und Wissenschaftseinrichtungen zugänglich zu machen und ist damit das digitale Einstiegsportal zu dem deutschen wissenschaftlichen und kulturellen Erbe. Nachgewiesen werden Digitalisate von zum Beispiel Büchern, Urkunden, Akten, Gemälden, Statuen, Installationen, Denkmälern, Filmen, Musik etc. In der DDB kann eine Suchanfrage (Recherche) eingeschränkt nach Zeit, Ort, Person bzw. Organisation, Schlagwort, Sprache, Rechtsstatus, Verwendbarkeit, Medientyp, Sparte etc. erfolgen. Eine Suche nach Ergebnissen, die einen direkten Zugriff auf den Volltext oder das digitalisierte Objekt erlauben, ist möglich. Die DDB ist der deutsche Beitrag zu Europeana (<http://www.europeana.eu/>), dem EU-Portal zu dem kulturellen und wissenschaftlichen Erbe der europäischen Mitgliedsländer. Mittlerweile weist EUROPEANA über 30 Millionen Filme, Fotos, Gemälde, Tonaufzeichnungen, Karten, Manuskripte, Bücher, Zeitungen und Textdokumente etc. nach und bietet zu zahlreichen Ergebnissen einen direkten Zugang zu dem Digitalisat an.

Das Archivportal-D (<https://www.archivportal-d.de/>) bündelt unter einer Such-Oberfläche sehr umfänglich Informationen über die deutschen Archiveinrichtungen und stellt archivische Materialien sowie digitalisiertes Archivgut für die Recherche bereit. Es ist auf diesem Weg möglich, übergreifend in den bisher digital zur Verfügung gestellten Archivalien zu suchen, sich die Ergebnisse und, falls vorhanden, die digitalisierten Archivalien anzeigen zu lassen. Es bleibt zu hoffen, dass das digitale Angebot zügig weiter ausgebaut wird, so dass zukünftig mehr und mehr auf die digitalisierten Inhalte zugegriffen und diese direkt für die Weiternutzung heruntergeladen werden können. Auch dieses Portal beteiligt sich bei Europeana und stellt die Informationen zu den Archivalien für die europaweite Suche zur Verfügung.

Das **Zentrale Verzeichnis Digitalisierter Drucke (zvdd)** (<http://www.zvdd.de>) ist das Nachweisportal für die Digitalisate von Druckwerken vom 15. Jahrhundert bis heute. Damit wird eine einheitliche Recherche über ein Such-Portal mit zurzeit über 1,3 Millionen Katalogisaten ermöglicht. Gesucht werden kann, neben der einfachen

Suche, auch nach Titel, Autor, Druckern, Druckorten, Erscheinungszeit etc. So wird zum Beispiel über die Sammlungen der SUB Göttingen die Karte »Asia partium orbis maxima«, 1593 in Antwerpen erschienen, als Digitalisat angeboten. Es ist möglich, die digitalisierte Karte in Großansicht anzuschauen und zum Beispiel mit Hilfe des DFG-Viewers in die digitalisierte Karte hineinzuzoomen. Der Nachweis und der Direktzugriff auf das Digitalisat sind nur möglich, weil die verantwortlichen Bibliotheken, die zum Beispiel den Sammelauftrag für ein bestimmtes Jahrhundert haben (s. o.) oder über eine spezifische Sammlung verfügen (wie die SUB Göttingen im Bereich der thematischen Karten) ihre Bestände nach und nach digitalisieren und kostenfrei zur Nutzung über Portale wie zvdd anbieten.

Der WorldCat (<https://www.worldcat.org/>) ist der größte internationale Bibliothekskatalog und weist zurzeit über 2 Milliarden Katalogisate von über 72.000 teilnehmenden Bibliotheken aus der ganzen Welt nach. Es kann nach Büchern, Artikeln, CD-ROMs und DVDs gesucht werden. Die Datenbank wird quasi sekundärlich erweitert, und die Suche kann ebenfalls auf bestimmte Metadaten wie Titel, Autor oder Jahr eingegrenzt werden.

Hathi Trust's Digital Library (<https://www.hathitrust.org/>) ist eine bibliografische Datenbank, in der Digitalisate von Google Books und dem Internet Archive überwiegend im Volltext von den teilnehmenden Einrichtungen (über 60 Forschungsbibliotheken hauptsächlich aus den USA und Europa) angeboten werden. Zurzeit bietet die Datenbank Zugang zu ca. 14 Millionen Titeln, davon knapp ein Drittel gemeinfrei zur sofortigen Nachnutzung, sprich herunterladbar als z. B. pdf-Datei, an.

Neben diesen eher organisationstypischen Portal-Angeboten gibt es eine Reihe fachspezifischer, wissenschaftlich relevanter Angebote zu digitalen Sammlungen, die überwiegend von wissenschaftlichen Bibliotheken angeboten und dauerhaft gepflegt werden. Im Folgenden kann hier nur eine kleine Auswahl vorgestellt werden.

Die **Digitale Bibliothek/TextGrid Repository** bietet den kostenfreien Zugang zu XML/TEI-erschlossenen Volltexten aus Belletristik und Sachliteratur vom Anfang des Buchdrucks bis zu den ersten Jahrzehnten des 20. Jahrhunderts in digitaler Form an. Die Volltexte können einzeln oder als Teil-Sammlung heruntergeladen, weiterverarbeitet und wieder publiziert werden.

In der **Generischen Suche/DARIAH-DE** kann zurzeit in 180 wissenschaftlichen digitalen Sammlungen mit über 300.000 Dokumenten gesucht werden. Dabei können auch verschiedene Visualisierungsinstrumente für die bessere Darstellung der Ergebnisse eingesetzt werden.

Die **Bielefeld Academic Search Engine (BASE)** ist eine der größten Such-Portale für wissenschaftliche Publikationen weltweit, die Open Access sind, d. h. kostenfrei genutzt werden können. Zurzeit werden auf diese Weise ca. 80 Millionen Dokumente mit zum Teil sehr detaillierter Beschreibung für die Suche angeboten.

Das **Deutsche Textarchiv (DTA)** weist einen Bestand deutschsprachiger Texte aus dem Zeitraum von ca. 1600 bis 1900 nach, die nach vorab bestimmten Kriterien ausgewählt wurden (z. B. von Akademiemitgliedern erstellte und ausführlich kommentierte, umfangreiche Bibliographien). In Ergänzung wurden einschlägige Literaturgeschichten und (Fach-)Bibliographien ausgewertet. Für die Digitalisierung und Erstellung der Volltexte werden dabei in der Regel die Erstaussagen zugrunde gelegt. Zu jedem Werk werden das Digitalisat (die eingescannten Seiten), der Volltext, eine TEI-Kodierung und die zugehörigen bibliographischen Angaben angeboten. Der Gesamtbestand kann durchsucht werden und die Einzelwerke können in verschiede-

nen Formaten (XML/TEI, HTML, PDF etc.) heruntergeladen und weiterverwendet werden.

Prometheus – Das verteilte Bildarchiv für Forschung und Lehre weist zurzeit einen Bestand von über 1,5 Millionen qualitativ hochwertigen digitalisierten Bildern aus Kunst, Kultur und Geschichte von über 80 teilnehmenden Einrichtungen nach. Im Rahmen von Forschung und Lehre dürfen die Bilder genutzt werden, ohne dass eine Genehmigung eingeholt oder eine Gebühr entrichtet werden muss. Im Gegensatz dazu sind die oben gelisteten Angebote, die sich alle auf Textsammlungen beziehen, kostenfrei.

15.4 | Gedächtnisinstitutionen als Forschungs- und Informationsinfrastrukturen für die Digital Humanities

Die Gedächtnisinstitutionen Bibliotheken, Archive und Museen bieten den Zugang zu unserem kulturellen und wissenschaftlichen Erbe und stellen die Grundlage für die Forschung in den Geistes- und Kulturwissenschaften dar. Auch wenn viele Objekte zurzeit noch in analoger Form vorliegen und nur vor Ort besichtigt oder per Fernleihe bestellt werden können, so durchdringt die Digitalisierung zunehmend auch diese Sparten: Sei es, dass vermehrt in die Digitalisierung dieser analogen Objekte investiert wird wie in die Volltextdigitalisierung von Büchern (z. B. Google Books) oder in die 3D-Objektdigitalisierung in Museen etc., sei es, dass es nur noch genuin digitale Objekte wie bei zahlreichen **Open Access Zeitschriften** gibt (vgl. z. B. DOAJ – Directory of Open Access Journals), die zum Teil über kein gedrucktes Pendant mehr verfügen – der Fortschritt der Digitalisierung ist nicht mehr aufzuhalten.

Neben all den Herausforderungen und noch ungelösten Problemen, liegen die (zukünftigen) Vorteile klar auf der Hand: Jede Person kann von jedem Ort aus zu jeder Zeit auf ein digitales Objekt zugreifen und es für die eigene Fragestellung nutzen. Dies bedeutet auch, dass sich der Zugang zu Information und Wissen demokratisieren könnte und es nicht nur bestens ausgestatteten Einrichtungen vorbehalten bleibt, ihre Nutzer vor Ort optimal mit Information zu versorgen. Sollten alle Objekte, die zurzeit in Bibliotheken, Archiven und Museen vorgehalten werden, irgendwann in digitaler Form vorliegen, so bilden sie zusammen oder in einzelnen, wissenschaftlich relevanten Sammlungen gruppiert eine hervorragende Basis für (zukünftige) Forschungsfragen, die bisher so nicht gestellt werden konnten.

Ein **digitales Korpus**, das zum Beispiel aus qualitativ hochwertigen Volltexten wichtiger Literatur aus verschiedenen Jahrhunderten besteht, kann mit den heutigen digitalen Methoden und Verfahren nach bestimmten Kriterien so durchsucht werden, wie es ein menschliches, lesendes Auge ein Leben lang rein aus zeitlichen Gründen nicht schaffen würde. Dies bedeutet, dass sich rein quantitativ das zu untersuchende Material-Corpus wie zum Beispiel eine Sammlung aus digitalen Volltexten oder eine Sammlung digitaler Exponate aus Museen weltweit durch die Digitalisierung immens vergrößert und damit neue Forschungsfragen erlaubt, die bisher so nicht gestellt werden konnten (Stichworte hier sind Text Mining, Data Mining etc.). Die über Jahrhunderte und zum Teil Jahrtausende alte Idee der Gedächtnisinstitutionen, eine analoge Forschungs- und Infrastruktur für die Versorgung von Gesellschaft und Wissenschaft zur Verfügung zu stellen, unterliegt in der heutigen Zeit ebenso der digitalen Transformation wie die wissenschaftlichen Fachdisziplinen selber auch. Aus analog wird zunehmend digital, eine digitale Forschungs- und Informati-

onsinfrastruktur für die digital forschenden Geistes- und Kulturwissenschaften – den Digital Humanities.

Herausforderungen: Im Rahmen der digitalen Transformation gilt es noch eine Reihe von Herausforderungen zu bewältigen, zahlreiche noch ungelöste Probleme warten auf Lösungen und sind zum Teil Gegenstand gegenwärtiger Forschung oder Diskussionen. Einige davon werden im Folgenden exemplarisch benannt.

- Die **digitale Langzeitarchivierung** ist zwar seit über 10 Jahren international Gegenstand von Initiativen und Forschungs- und Entwicklungsprojekten, trotzdem zeichnen sich hier für viele Bereiche noch keine systematischen und einheitlichen Lösungen ab. Bücher in gedruckter Form existieren bei entsprechender Sorgfalt und geeigneter Maßnahmen seit Jahrhunderten, eine Sammlung digitaler Objekte muss auch auf Grund des schnellen technologischen Wandels (z. B. Speichermedium wie CD-ROM; Festplatte oder Speicherformat wie PDF-A) quasi permanent kuratiert werden, damit die Datei lesbar und interpretierbar bleibt.
- **Forschungsdatenmanagement**, d. h. Management digitaler Forschungsdaten als Grundlage wissenschaftlicher Erkenntnisprozesse und Publikationen, steht erst seit wenigen Jahren auf der Agenda der Forschungseinrichtungen. Ohne die nachvollziehbare Dokumentation und Publikation von Forschungsdaten können wissenschaftliche Ergebnisse oft nicht reproduziert und validiert werden. Die Nachnutzung bereits existierender Forschungsdatensammlungen für neue Fragestellungen ist nicht möglich, meistens existiert noch nicht einmal das Wissen darüber. Um diesem zu begegnen, gibt es internationale Anstrengungen (z. B. Research Data Alliance, RDA) und Förderinitiativen.
- Auch wenn es nationale oder internationale Ansätze (z. B. **Open Access**) und Quasi-Standards (z. B. **Creative Commons**) für die Beschreibung der rechtlichen Rahmenbedingungen, unter denen digitale Objekte angeschaut, heruntergeladen, für eigene Zwecke weiterverarbeitet und wieder publiziert werden dürfen (s. Kap. 24), gibt, so muss insgesamt festgestellt werden, dass es für die Nutzer offenbar keine Rechtssicherheit gibt im Umgang mit digitalen Objekten. Dies verhindert den offenen Austausch, der freien (Nach)Nutzung und des ›Teilens‹ von Informationen, Daten und Wissen im digitalen Raum.

Eine Idee, wenn nicht sogar Vision darüber, wie sich die zukünftige digitale Welt und der Zugang zu digitalen Informationen und damit letztendlich dem Wissen gestalten kann, gibt die im November 2015 veröffentlichte Stellungnahme »Empfehlungen für die Umsetzung von Open Access in Österreich«. Dort heißt es zum Beispiel in der Empfehlung 14: »Alle öffentlich finanzierten Archive, Museen, Bibliotheken und Statistikämter sollten ihre Bestände bis 2025 soweit als möglich digitalisieren und in der Zusammenarbeit mit den Forschungsstätten unterstützt werden. Bereits digitalisierte Bestände sollten bis 2020 der Wissenschaft und der Öffentlichkeit zur freien und kostenlosen Weiterverwendung zur Verfügung gestellt werden.«

Welche Möglichkeiten ergeben sich für Bürger und Wissenschaftler, wenn diese Bestände in digitaler Form kostenfrei zur Verfügung stehen? Welche spannenden Fragestellungen können für die Digital Humanities gestellt werden, wenn es diese digitale Forschungs- und Informationsinfrastruktur in einigen Jahren auch in Deutschland, in Europa oder sogar weltweit geben sollte?

Literatur

- Brenner-Wilczek, Sabine/Cepl-Kaufmann, Gertrude/Plassman, Max: *Einführung in die moderne Archivarbeit*. Darmstadt 2006.
- Gantert, Klaus/Hacker, Rupert: *Bibliothekarisches Grundwissen*. Berlin/Boston 2008.
- Kohle, Hubertus: *Digitale Bildwissenschaft*. Glückstadt 2013.
- Krause, Celia/Reiche, Ruth: *Ein Bild sagt mehr als tausend Pixel? Digitale Forschungsansätze in den Bild- und Objektwissenschaften*. Glückstadt 2015.
- Lepper, Marcel/Raulff, Ulrich: *Handbuch Archiv: Geschichte, Aufgaben, Perspektiven*. Stuttgart 2016.
- Müller, Carl Christian/Truckenbrodt, Michael: *Handbuch Urheberrecht im Museum: Praxiswissen für Museen, Ausstellungen, Sammlungen und Archive. Schriften zum Kultur- und Museumsmanagement*. Bielefeld 2016.
- Neuroth, Heike/Strathmann, Stefan/Oßwald, Achim et al.: *Langzeitarchivierung von Forschungsdaten. Eine Bestandsaufnahme*. Boizenburg 2012. Online: http://nestor.sub.uni-goettingen.de/bestandsaufnahme/nestor_1za_forschungsdaten_bestandsaufnahme.pdf (31.10.2016).
- Plassmann, Engelbert/Rösch, Hermann/Seefeldt, Jürgen/Umlauf, Konrad: *Bibliotheken und Informationsgesellschaft in Deutschland. Eine Einführung*. Wiesbaden 2011.
- Reimann, Norbert/Nimz, Brigitta/Bockhorst, Wolfgang: *Praktische Archivkunde. Ein Leitfaden für Fachangestellte für Medien- und Informationsdienste, Fachrichtung Archiv*. Münster 2014.
- Schleh, Bernd: »Der große Traum von der Demokratisierung des Wissens. Interview mit Professor Hermann Parzinger zum Aufbau der Deutschen Digitalen Bibliothek«. In: *Buch und Bibliothek* 64/3 (2012), 208–213.
- Tauschek, Markus: *Kulturerbe: eine Einführung*. Berlin 2013.
- Umlauf, Konrad/Gradmann, Stefan: *Handbuch Bibliothek: Geschichte, Aufgaben, Perspektiven*. Stuttgart 2012.
- Walz, Markus (Hg.): *Handbuch Museum. Geschichte, Aufgaben, Perspektiven*. Stuttgart 2016.

Internetquellen

- Bayerische Staatsbibliothek: <http://www.bsb-muenchen.de/>.
- Das Bundesarchiv: <http://www.bundesarchiv.de/>.
- Deutsche Bibliotheksstatistik – dbs: <https://www.hbz-nrw.de/angebote/dbs/>.
- Deutsche Nationalbibliothek: <http://www.dnb.de/>.
- Deutscher Museumsverbund: <http://www.museumsbund.de/>.
- Die Bundesregierung: Digitale Agenda 2014 – 2017: <https://www.digitale-agenda.de/>.
- Institut für Museumsforschung, Staatliche Museen zu Berlin: <http://www.smb.museum/museen-und-einrichtungen/institut-fuer-museumsforschung/home.html>.
- Kompetenznetzwerk Bibliotheken – knb, das Bibliotheksportal des Deutschen Bibliotheksverbandes: <http://www.bibliothekportal.de/>.
- Open Access (Informationsplattform): <https://open-access.net/>.

Heike Neuroth

16 Aufbau von Datensammlungen

16.1 | Einleitung: Was sind Datensammlungen?

Forschung in den digitalen Geisteswissenschaften ist in der Regel datenbasiert, insofern in der Regel eine digitale Repräsentation der Untersuchungsgegenstände vorliegt, die mit Hilfe des Computers bearbeitet, analysiert und/oder verbreitet werden kann. Zudem wird meist nicht nur ein einzelnes Beispiel, sondern eine Gruppe von Gegenständen untersucht, d. h. mit einer Datensammlung gearbeitet. Als **Datensammlung** gilt in diesem Zusammenhang jede Zusammenführung einzelner (bereits existierender oder eigens erstellter) Datensätze nach einer Einheit stiftenden Systematik. Der Begriff der Datensammlung wird hier als Überbegriff und in Abgrenzung zum spezifischeren Begriff des **Korpus** verwendet, mit dem in der Regel digitale Sammlungen von Text oder gesprochener Sprache bezeichnet werden, die linguistisch annotiert wurden sowie (in vielen Fällen) für eine bestimmte Domäne repräsentativ sind und somit als Referenz fungieren können (vgl. McEnery/Wilson 2001, Kap. 2). Digitale Editionen hingegen sind im Vergleich zu Datensammlungen meist weniger umfangreich oder zumindest inhaltlich enger definiert, leisten aber eine detailliertere Erschließung von Struktur und Inhalt der Daten, als dies bei einer Datensammlung der Fall ist (s. Kap. 17 zu »Digitale Editionen«). Schließlich ist der Begriff der Datensammlung nicht mit dem der Datenbank zu verwechseln, die allerdings eine mögliche technische Umsetzungsform von Datensammlungen darstellt (s. Kap. 8 zu »Datenbanken«).

Mit dem Begriff des **Datensatzes** ist hier die digitale Repräsentation eines bestimmten, einzelnen Gegenstands geisteswissenschaftlicher Forschung gemeint. Solche Datensätze können im Prinzip alle geisteswissenschaftlich relevanten Untersuchungsgegenstände repräsentieren: gesprochene Äußerungen (als Transkription oder Audioaufzeichnung), Texte (gedruckt oder handschriftlich, literarisch oder funktional), Filme (als Drehbuch oder Videoaufzeichnung), historische Dokumente (wie Urkunden oder Briefe), Bilder (wie Gemälde oder Zeichnungen), Musik (in Form von Noten oder Audioaufzeichnungen), dreidimensionale Artefakte (wie Skulpturen oder Werkzeuge) und vieles mehr. Datensätze enthalten nicht die Gegenstände selbst, sondern sind mit spezifischen Techniken und Zielen angefertigte Digitalisate, d. h. selektive, digitale Repräsentationen oder Modelle dieser Gegenstände (s. Kap. 7 zu »Grundlagen der Datenmodellierung« und Kap. 12 zu »Digitalisierung«).

Der Aufbau von Datensammlungen ist ein wesentlicher Teilbereich der sogenannten »Data Curation«, die mit der Sammlung, Strukturierung, Pflege, Verfügbarmachung und langfristigen Archivierung von Forschungsdaten befasst ist (vgl. Oßwald et al. 2013). Die folgende Beschreibung der wichtigsten Schritte beim Aufbau von Datensammlungen soll die Leser in die Lage versetzen, nicht nur für sich selbst und andere nützliche Datensammlungen zu erstellen, sondern auch existierende Datensammlungen bezüglich ihrer wesentlichen, allgemeinen Eigenschaften zu beurteilen und einzuordnen, um sie angemessen nutzen zu können. Die Darstellung folgt einem idealtypischen Ablauf beim Erstellen von Datensammlungen: Sie beginnt mit der Abgrenzung des Gegenstands und der Auswahl der Datensätze, behandelt dann deren Zusammenführung und Vereinheitlichung sowie das Erheben von Informationen, die die Datensätze beschreiben und endet mit dem Verfügbarmachen der Datensammlung.

In einem ersten Schritt wird in Abhängigkeit vom spezifischen Forschungsinteresse der Gegenstand der Datensammlung definiert. Dadurch wird explizit gemacht, welche Untersuchungsgegenstände und damit auch welche Datensätze grundsätzlich für die Sammlung relevant sind und welche nicht. Das Forschungsinteresse sollte die dafür notwendige Datensammlung bestimmen, nicht umgekehrt. Daraus folgt auch, dass die Vielfalt bestehender und möglicher Datensammlungen ebenso groß ist wie die Vielfalt geisteswissenschaftlicher Forschungsvorhaben. Dabei ist zu unterscheiden zwischen Datensammlungen, die gezielt für die Bearbeitung einer speziellen Forschungsfrage erstellt werden und solchen Datensammlungen, die den Anspruch erheben, auch für die Bearbeitung weiterer, eventuell noch nicht absehbarer Forschungsfragen durch andere Forschende geeignet zu sein.

Die Definition des Gegenstands einer Textsammlung kann nach einer Reihe von Kriterien erfolgen, die zeitlich (z. B. begrenzt auf bestimmte Jahre, Jahrzehnte oder Jahrhunderte) und räumlich (z. B. begrenzt auf einen oder mehrere Orte, Regionen, Länder oder Kontinente) sein können, bestimmte Urheber (z. B. nach verschiedenen Kriterien ausgewählte Autorinnen oder Künstler) betreffen oder sich auf bestimmte Genres beziehen (z. B. nur Romane, nur Symphonien, oder nur Druckgrafiken) können, oder die den Umfang (z. B. minimale und/oder maximale Textlänge) sowie weitere Kriterien berücksichtigen. Neben solchen auf den Gegenstand bezogenen Kriterien können unter Umständen auch externe Kriterien eine Rolle spielen, wie beispielsweise die (technische oder rechtliche) Verfügbarkeit der entsprechenden Dokumente oder Digitalisate.

Typen von Datensammlungen: Unabhängig vom jeweiligem Gegenstand können Datensammlungen ihrem Anspruch an die Standardisierung, die Breite der Nutzungsszenarien und ihrer langfristigen Verfügbarkeit nach eingeordnet werden (vgl. National Science Board 2005, 20–21):

Projektbezogene Datensammlungen (*research data collections*): von einer spezifischen Forschungsgruppe für einen spezifischen Forschungszweck erstellt; nicht sehr umfangreich; durch opportunistische oder balancierte Auswahl entstanden; beruht auf wenig verbreiteten oder proprietären Daten- und Metadatenformaten; häufig nur für die Nutzung während der Projektlaufzeit konzipiert.

Gemeinschafts-Datensammlungen (*community data collections*): von verschiedenen Vertretern einer Forschendengemeinschaft genutzt; eignen sich für die Bearbeitung unterschiedlicher Fragestellungen aus einem bestimmten Forschungsfeld; recht umfangreich und/oder balanciert; deutliche, aber disziplinspezifische Standardisierung; darauf angelegt, mittelfristig archiviert zu werden und nachnutzbar zu sein.

Referenz-Datensammlungen (*reference data collections*): auf stark institutionalisierter Basis erstellt; für die Bearbeitung von Fragestellungen aus mehreren Disziplinen geeignet; oft sehr umfangreich und/oder repräsentatives Sample des Gegenstandsbereichs; hohe Ansprüche an die Erschließungstiefe und -qualität sowie die Einhaltung von internationalen und disziplinübergreifenden Standards; langfristige, institutionalisierte Archivierung der Daten; technische und inhaltliche Nachnutzbarkeit ist sichergestellt.

16.2 | Erheben von Informationen über den gesamten Gegenstandsbereich

Nach der Definition des Gegenstands kann die Erhebung der Gesamtmenge der existierenden, relevanten Gegenstände vorgenommen werden, z. B. alle (bekannten) kartographischen Darstellungen Asiens aus dem 17. Jahrhundert oder alle Kirchenbücher einer bestimmten Region. Diese Menge wird die **Grundgesamtheit** (engl. *population*) genannt. Meist ist eine solche Erhebung nur realistisch, wenn man sich auf bereits vorhandene Arbeiten stützen kann, die bestimmte Gegenstandsbereiche mit dem Anspruch der Vollständigkeit erschlossen haben, wie Bibliographien (z. B. *Der deutsche Roman 1815–1830*), Werkverzeichnisse (z. B. das *Corpus of Rembrandt Paintings* in sechs Bänden) oder Datenbanken (z. B. *César*, eine Datenbank aller bekannten Aufführungen französischer Theaterstücke von 1600–1800). Sofern diese digital vorliegen, können sie durchsucht und unter Umständen auch automatisch abgefragt werden.

Auf der Grundlage solcher Hilfsmittel können die folgenden beiden Fragen zumindest annäherungsweise beantwortet werden: Wie viele relevante Gegenstände (Romane, Symphonien, Druckgrafiken) sind in dem definierten Zeitraum an dem definierten Ort publiziert, aufgeführt oder angefertigt worden? Wie können diese sinnvoll weiter beschrieben und untergliedert werden, beispielsweise bezüglich ihrer Urheber, ihres Entstehungsdatums, ihrer Untergattungen oder auch bestimmter formaler Aspekte (Erzählperspektive beim Roman; Prosa oder Vers bei Theaterstücken; Ölgemälde oder Aquarell bei Gemälden)?

Diese und ähnliche Fragen zu beantworten, ist primärer Zweck einer solchen Erhebung. Es kann dabei aber zusätzlich auch ermittelt werden, welcher Teil dieser Gesamtmenge in Bibliotheken, Archiven oder Museen verfügbar ist, sei es in analoger oder digitaler Form. Diese Frage hat hohe praktische Relevanz, wobei nicht nur die reine Verfügbarkeit relevant ist, sondern auch die Fragen, in welcher Qualität, in welchen Datenformaten, mit welchen Metadaten und unter welchen Zugangs- und Nutzungsbedingungen die entsprechenden Datensätze vorhanden sind.

Auf der Grundlage der im vorigen Schritt erhobenen Informationen kann man nun abschätzen, welche Strategie für die Auswahl der Datensätze realistisch ist, die tatsächlich in die Datensammlung eingehen sollen. Gar nicht auszuwählen, sondern eine **vollständige Datensammlung** anzustreben, wird nur in den seltensten Fällen möglich sein, z. B. bei einem sehr präzise umgrenzten und bereits gut erschlossenen Untersuchungsgegenstand (z. B. alle Sonette Arthur Rimbauds oder alle Klaviersonaten Mozarts). Der wünschenswerte **Umfang** einer Datensammlung kann ohnehin nicht absolut festgelegt werden, sondern hängt von der spezifischen Fragestellung ab. Grundsätzlich gilt aber, dass eine Datensammlung umso größer sein sollte, je seltener und/oder ungleichmäßiger verteilt die im Fokus des Interesses stehenden Phänomene vorkommen (vgl. McEnery/Wilson 2001, 80). Beispielsweise wird man erst in einem sehr umfangreichen linguistischen Korpus ausreichend Vorkommen einer sehr spezifischen grammatikalischen Konstruktion finden, um statistisch valide Aussagen über ihre typischen Kontexte oder ihre Verteilung treffen zu können. Der Umfang einer Datensammlung kann als Anzahl der aufgenommenen Datensätze (z. B. 100 Romane oder 200 Historienbilder) oder gegebenenfalls auch als Anzahl kleinerer Einheiten (wie der Wortformen bei linguistischen Korpora) angegeben werden.

Repräsentative Stichprobe: Eine denkbare Strategie ist es, eine repräsentative

Stichprobe (*sample*) zu erstellen: »representativeness refers to the extent to which a sample includes the full range of variability in a population« (Biber 1993, 243). Das bedeutet, dass aus der Grundgesamtheit aller relevanten Datensätze durch zufällige und damit unvoreingenommene Auswahl eine Teilmenge von Datensätzen gebildet wird. Dieses Vorgehen erlaubt dann auf der Grundlage der Stichprobe gültige Aussagen über die Grundgesamtheit und bedeutet zudem, dass die Datensammlung als Referenz geeignet ist, also als Vergleichsmaßstab für Untersuchungen mit anderen Datensammlungen. Allerdings ist das Erstellen eines wirklich repräsentativen Samples in der Praxis sehr voraussetzungsreich. Zunächst einmal muss die Grundgesamtheit selbst endlich und bekannt sein, was die erschöpfende Aufarbeitung und Dokumentation des Gegenstandsbereichs voraussetzt, die häufig nicht gegeben oder sehr aufwändig sind. Zudem muss die digitale Verfügbarkeit aller zufällig gewählten Datensätze gegeben sein, oder deren analoge Verfügbarkeit und ausreichende Ressourcen für die gezielte Digitalisierung. Schließlich müssen schwierige Entscheidungen getroffen werden: Werden alle relevanten Werke gleichbehandelt, oder spielen auch Faktoren wie deren Verbreitung und Rezeption und damit Kanonisierungseffekte eine Rolle? Sollen beispielsweise Romane abhängig von ihrer Auflagenhöhe in der Auswahl mehr oder weniger stark gewichtet sein?

Balancierte Sammlung: Eine Alternative zum repräsentativen Sample ist die gezielte Konstruktion einer nach einer kleinen Anzahl von Kriterien balancierten Sammlung. Welche Kriterien als wesentlich erachtet werden, hängt von der jeweiligen Forschungsfrage ab. Ziel ist es hier in der Regel, dass für alle Kombinationen wesentlicher Merkmale eine Mindestanzahl von Datensätzen (oder eine vergleichbare Textmenge) verfügbar ist, wobei zusätzlich angestrebt werden kann, dass die jeweiligen Anteile an der Sammlung ungefähr den Verhältnissen in der untersuchten Epoche entsprechen. Andere Merkmale hingegen sollten möglichst gleichmäßig variiert werden. Interessiert man sich beispielsweise für die Differenzierung und zeitliche Entwicklung literarischer Untergattungen des Romans, kann es sinnvoll sein, eine Textsammlung so aufzubauen, dass für mehrere Jahrzehnte und mehrere Untergattungen jeweils mehrere Romane eines insgesamt vergleichbaren Umfangs vorliegen, die bezüglich ihrer Autoren, der Erzählperspektive und des Handlungsortes breit gemischt sind.

Bei balancierten Datensammlungen sind unerwünschte **Korrelationen**, also statistische Abhängigkeiten, zwischen den als wesentlich betrachteten Kriterien und weiteren Eigenschaften der einzelnen Datensätze zu vermeiden. Interessiert man sich beispielsweise als Theaterwissenschaftler für den Unterschied zwischen Tragödie und Komödie, so ist es notwendig, darauf zu achten, dass diese Gattungsunterscheidung nicht auch mit Autorengruppen übereinstimmt. Dies kann man dadurch erreichen, dass man (soweit möglich) Stücke von Autoren auswählt, die sowohl Komödien als auch Tragödien geschrieben haben oder dass man zumindest für beide Gattungen eine möglichst große Bandbreite von Autoren berücksichtigt. Solche Korrelationen zu vermeiden, ist nicht immer einfach, allerdings wesentlich für die Aussagekraft der Ergebnisse.

Opportunistische Auswahl: Die letzte denkbare Strategie der Datenauswahl ist die opportunistische Auswahl, womit gemeint ist, dass vor allem die Verfügbarkeit digitaler Datensätze bestimmt, welchen Inhalt und welche Struktur eine Datensammlung bekommt oder welche Metadaten enthalten sind. Dies ist ein pragmatischer Ansatz, der beispielsweise für wenig erschlossene Gegenstandsbereiche oder Pilotstudien in Frage kommt, aber letztlich unbefriedigend bleibt. Wesentlich ist in jedem Fall, die Auswahlstrategie klar zu dokumentieren.

16.3 | Sammeln, Zusammenführen und Säubern von Datensätzen

In zunehmendem Maße stehen eine Vielzahl von Gegenständen des geisteswissenschaftlichen Interesses heute bereits in digitaler Form zur Verfügung, weil sie von Bibliotheken, Archiven, Museen (s. Kap. 15), Verlagen, Forschungsprojekten oder anderen Initiativen digitalisiert und veröffentlicht wurden. Oft folgen diese Digitalisierungsaktivitäten allerdings nicht einem spezifischen Forschungsinteresse, sondern reflektieren beispielsweise die historisch gewachsenen Bestände der jeweiligen digitalisierenden Institution. Sind diese Daten in geeigneter Weise lizenziert, können Teile mehrerer existierender Sammlungen für das Erstellen eigener Datensammlung verwendet werden. Meist ist es notwendig, die Daten in ein geeignetes, einheitliches Datenformat zu bringen. Stehen keine geeigneten Digitalisate in ausreichender Zahl zur Verfügung, muss die Digitalisierung (aller oder einiger) Untersuchungsgegenstände selbst vorgenommen oder in Auftrag gegeben werden. Auch hier ist wesentlich, dass die entstehenden Datensätze in ihrer Qualität, ihrem Format und den verwendeten Standards den Anforderungen der Datensammlung entsprechen (s. Kap. 12 zu »Digitalisierung«).

Für verschiedene Untersuchungsgegenstände bestehen eine Reihe von Datenformaten, die je nach Verwendungszweck und Forschungsinteresse mehr oder weniger gut geeignet sein können. Allgemein gilt, dass offene, gut institutionalisierte, weit verbreitete Standards vorzuziehen sind. Für die geisteswissenschaftliche Arbeit mit Texten eignen sich insbesondere Formate, die nicht auf die Darstellung fokussiert sind und es erlauben, Strukturen, Annotationen und Metadaten mit abzubilden. Ein Beispiel hierfür sind die Richtlinien der **Text Encoding Initiative** (TEI; s. Kap. 17.7 zu »Digitale Edition«). Für andere Bereiche, wie die Musikwissenschaft oder die Geschichte, bestehen ähnliche Standards.

Häufig werden Digitalisate aus verschiedenen Quellen für eine neue Datensammlung zusammengeführt, um den Aufwand einer erneuten Digitalisierung zu vermeiden. Die Digitalisate sind dann allerdings in unterschiedlichen Kontexten und mit unterschiedlichen Strategien entstanden und in vielerlei Hinsicht nicht einheitlich. Diese Heterogenität kann die sinnvolle Nutzung der Daten behindern und muss durch eine systematische Vereinheitlichung der Daten so weit wie möglich behoben werden. Die Strategie der Vereinheitlichung sollte hierbei dokumentiert werden. Das Ziel der Verwendung von **Standards** bei der Erstellung von Daten und ihrer Beschreibung durch Metadaten ist es, dass die Daten und Metadaten auch von anderen genutzt werden können. Dieser Umstand wird häufig unter dem Begriff der **Interoperabilität** verhandelt, also der Benutzbarkeit der Daten und Metadaten in unterschiedlichen Kontexten. Dabei geht es nicht nur um technische Interoperabilität (Nutzung von Daten auf unterschiedlichen Betriebssystemen und mit verschiedenen Werkzeugen), sondern auch um inhaltliche Interoperabilität (die Verständlichkeit der Datenstrukturen und der Metadaten). Nur wenn beides gegeben ist, können die Daten in sinnvoller Weise von anderen analysiert und verstanden werden.

Die Aspekte der Daten, die vereinheitlicht werden müssen, hängen stark von den Datentypen ab, die bearbeitet werden. Daher hier nur einige Beispiele, die bei der Arbeit mit Textdaten relevant sind (für ein konkretes Beispiel zum Aufbau sehr umfangreicher Web-Korpora, vgl. Biemann et al. 2013):

- Textdateien liegen häufig in unterschiedlichen **Zeichenkodierungen** vor (z. B. ANSI oder ASCII), und sollten mit Hilfe geeigneter Editoren oder Tools einheitlich nach UNICODE/UTF-8 konvertiert werden (s. Kap. 5 zu »Zahlen und Zeichen«).
- Textdateien liegen, je nach Datenquelle, häufig in unterschiedlichen Dateiformaten vor, z. B. als »plain text« (in einer TXT-Datei), als »ePUB (für Ebook-Reader) oder als HTML-Datei (für die Ansicht im WWW). Diese Formate sollten in ein einheitliches Format gebracht werden, idealerweise in ein semi-strukturiertes **XML-Format**, das den Richtlinien der TEI folgt. Hierfür können sogenannte **Reguläre Ausdrücke** (vgl. Friedl 2008) oder speziellere Technologien eingesetzt werden.
- Es können unterschiedliche Vorgehensweisen bei der Textkonstitution (z. B. bezüglich der orthographischen Normalisierung oder der Korrektur von Fehlern in der Vorlage) eingesetzt werden; diese sollten im Einzelnen dokumentiert und/oder vereinheitlicht werden.
- Auch die Aufnahme von **Metadaten** kann stark variieren (z. B. mit unterschiedlichen Begrifflichkeiten, unterschiedlicher Granularität und nicht zuletzt unterschiedlichen Metadaten-Standards). Hier sollten alle vorhandenen Metadaten zunächst aufgenommen und dann auf ein einheitliches Metadaten-Schema bezogen werden.

Nach Abschluss dieser Phase liegt eine klar definierte Auswahl an Datensätzen in einem einheitlichen Dateiformat vor. Es fehlt aber noch die systematische Erfassung von Informationen über die Datensätze.

16.4 | Erheben und Hinzufügen von Informationen über die Daten

Die Nützlichkeit einer Datensammlung begründet sich nicht nur im Vorhandensein der Daten selbst, sondern auch im Umfang und der Präzision der Informationen über die Daten (die bereits erwähnten **Metadaten**), die zugleich verfügbar gemacht werden. Metadaten sind Daten über Daten, genauer: Metadaten dienen zur systematischen und einheitlichen Beschreibung von Datensätzen und Datensammlungen. Es ist hier zunächst zu unterscheiden zwischen **dokumentbezogenen Metadaten**, die sich auf einen einzelnen Datensatz als Ganzes beziehen, und **lokalen Annotationen** verschiedener Art, die sich auf kleinere Teile eines Datensatzes beziehen. Nicht immer wird diese Unterscheidung begrifflich klar getrennt; auch lokale Annotationen sind im weitesten Sinne Metadaten – nur eben nicht dokumentbezogene Metadaten – und auch Annotationen können sich theoretisch auf ganze Dokumente beziehen. Zudem gibt es Metadaten, die sich auf eine Datensammlung als Ganzes beziehen (s. Kap. 7 und Kap. 18).

Dokumentbezogene Metadaten stellen den einzelnen Datensatz in einen Kontext, machen ihn vergleichbar mit anderen einzelnen Datensätzen und erlauben es, in einer größeren Datensammlung relevante Datensätze zu entdecken und auszuwählen. Im Allgemeinen wird zwischen **deskriptiven, strukturellen, administrativen und technischen Metadaten** unterschieden (s. Kap. 12 zu »Digitalisierung« sowie NISO 2004 und Burnard 2004).

- **Deskriptive Metadaten** identifizieren (durch Nennung des Urhebers, des Entstehungsdatums oder des Entstehungsorts) und beschreiben ein Dokument inhaltlich (z. B. bezüglich der enthaltenen Themen oder Gegenstände, der erwähnten

oder repräsentierten Personen oder Orte, oder der Zugehörigkeit zu einem Genre) oder in formaler Hinsicht (z. B. bezüglich des Umfangs eines Textes in Worten oder des Formats eines Gemäldes in Zentimetern). Eine kleine Menge solch deskriptiver Metadaten war meist schon Grundlage für die Auswahl der relevanten Datensätze.

- **Strukturelle Metadaten** beschreiben, aus welchen kleineren Einheiten sich ein Datensatz zusammensetzt (beispielsweise Teile und Kapitel eines Romans).
- **Administrative Metadaten** dagegen beziehen sich unter anderem auf die Entstehungsgeschichte des digitalen Dokuments selbst (z. B. die Quelle des Digitalisats und die Art der Digitalisierung) oder darauf, welche Institution für die Erstellung verantwortlich ist oder unter welcher Lizenz das Digitalisat verfügbar ist.
- **Technische Metadaten** schließlich beziehen sich beispielsweise darauf, in welchem Dateiformat ein Digitalisat vorliegt oder welchen Umfang die entsprechende Datei hat, z. B. in Kilobyte (kB). (Einige konkrete Metadatenformate werden in Kapitel 12.3 »Erschließung der Digitalisate« beschrieben.)

Lokale Annotationen beziehen sich nicht auf eine Datensammlung oder einen Datensatz, sondern auf einzelne, unter Umständen sehr kleine Teile eines Datensatzes. Im Fall von Texten oder Musikstücken ist hier unter anderem an die Annotation von strukturellen Einheiten zu denken. Für Texte sind diese Einheiten u. a. Absätze, Sätze und Wörter und für musikalische Kompositionen u. a. Phrasen, Takte und Noten. Im Fall von Bildern können durch die Angabe räumlicher Koordinaten ebenfalls Teile des Dokuments identifiziert und durch Annotationen beschrieben werden. Auch die linguistische Annotation ist hier zu nennen; dabei wird der Text in einzelne Einheiten (z. B. Sätze, Teilsätze oder Wörter) segmentiert und jede so definierte Einheit in ihren Eigenschaften beschrieben (ein Wort z. B. hinsichtlich seines Lemmas und seiner Wortart; vgl. McEnery/Wilson 2001, Kap. 2.2). Sowohl Strukturinformationen als auch linguistische Annotationen werden häufig mit spezialisierten Werkzeugen automatisch oder semi-automatisch erhoben und eingetragen (s. Kap. 18 zu »Manuelle und automatische Annotation«). Auch Crowdsourcing kann für solche Zwecke genutzt werden (s. Kap. 14.3 zu »Digitale Wissensproduktion«).

Entscheidend ist, sei es beim Erheben dokumentbezogener Metadaten oder beim Hinzufügen lokaler Annotationen, dass nach einem einheitlichen und expliziten Metadaten- bzw. Annotationschema vorgegangen wird, das möglichst einem etablierten Standard folgt. Um nur zwei Beispiele zu geben: Bei der Identifikation von historischen Personen (sei es als Urheber, sei es als erwähnte Figuren in Texten oder in Bildern) sollte nicht nur auf ein standardisiertes Metadatenformat, sondern auch auf geeignete **Normdaten** zurückgegriffen werden. Normdaten sind standardisierte und eindeutig zuzuordnende Einträge für bestimmte Gegenstandsbereiche. Die Gemeinsame Normdatendatei (GND) oder das Virtual International Authority File (VIAF) definieren beispielsweise für jede dort erfasste Person einen eindeutigen Identifier, über den weiterführende, standardisierte Informationen verfügbar sind. Für die Annotation von Ortsdaten kann unter anderem der Getty Thesaurus of Geographic Names (Getty TGN) verwendet werden. Auf diese Weise wird nicht nur die Person oder der Ort eindeutig identifiziert (unabhängig von alternativen Schreibweisen, Pseudonymen oder Namensänderungen), es wird auch möglich, automatisch weitere Informationen zu einer Person (z. B. Geburtsdatum oder -Ort) oder einem Ort (z. B. geographische Koordinaten oder Schreibung in anderer Sprache) abzurufen.

16.5 | Verfügbarmachen der Datensammlung

Nun liegt die Datensammlung in einem einheitlichen, standard-basierten Format und mit Metadaten vor. Die Datensammlung kann jetzt an geeigneter Stelle, beispielsweise in einem Repositorium, archiviert und verfügbar gemacht. Die **Archivierung** meint dabei die langfristige, sichere Speicherung der Datensammlung. Zugleich wird die Datensammlung aber auch verfügbar gemacht, was zwei Zwecken dient: Erstens können so die Grundlagen der eigenen, auf der Datensammlung beruhenden Forschungsergebnisse offengelegt werden, so dass diese auch von anderen reproduziert und überprüft werden können. Zweitens wird es anderen Forschenden ermöglicht, die Datensammlung auch für die Bearbeitung eigener, neuer Fragestellungen (oder das Erstellen neuer Datensammlungen) zu nutzen.

Die sichere Langzeitarchivierung kann nicht von einzelnen Forschenden oder Forschungsprojekten, sondern nur von Institutionen gesichert werden, die strukturell auf eine langfristige Existenz hin angelegt sind. Aus diesem Grund ist hier insbesondere an öffentliche Einrichtungen wie Bibliotheken und Archive, an projektübergreifende Infrastrukturinitiativen (wie DARIAH und CLARIN) oder an langfristig finanzierte Repositorien (wie das europäische Zenodo) zu denken. Die Daten sollten mit eindeutigen, dauerhaften **Identifiern** – sogenannten DOIs (*Digital Object Identifier*) oder URIs (*Uniform Resource Identifier*) – versehen und mehrfach unabhängig voneinander gesichert werden.

Die Verfügbarkeit wird erstens dadurch gesichert, dass beim Erstellen der Daten selbst sowie der Metadaten geeignete Standards verwendet wurden, die andere in die Lage versetzen, die Daten zu verstehen (Stichwort Interoperabilität). Zweitens dadurch, dass die Daten tatsächlich auch technisch verfügbar sind, das heißt sowohl als Ganzes als auch in ausgewählten Teilen heruntergeladen werden können, und dies mit möglichst wenigen technischen, finanziellen oder lizenzrechtlichen Hürden (zu Letzterem s. Kap. 24). Drittens sollte die Datensammlung, in einem für die Disziplin einschlägigen Repositorium publiziert oder einem einschlägigen Nachweissystem referenziert werden, falls es solche gibt, damit sie auch tatsächlich von Forschenden gefunden werden kann.

Beispiele für Datensammlungen

Die folgenden (überwiegend) frei verfügbarer Datensammlungen unterschiedlichen Typs können als Erschließungsinstrumente oder als Datenquellen für selbst erstellte Datensammlungen dienen.

- Archivportal-D, <https://www.archivportal-d.de/>. Bündelt Informationen über die deutschen Archiveinrichtungen; referenziert digitale Archivmaterialien.
- Corpora from the Web (COW); FU Berlin, <http://hpsg.fu-berlin.de/cow/>. Sehr umfangreiche, linguistisch annotierte Korpora in einer Reihe europäischer Sprachen.
- Deutsch Diachron Digital (DDD); HU Berlin, <http://www.deutschdiachron.digital.de/>. Annotiertes Referenzkorpus für Altdeutsch (etwa 750 bis etwa 1050) mit derzeit rund 300.000 Tokens.
- Deutsche Digitale Bibliothek (ddb), <https://www.deutsche-digitale-bibliothek.de/>. Das nationale Zugangsportal für Kultur und Wissenschaft in Deutschland; kooperiert mit dem europäischen Portal Europeana.

- Deutsches Textarchiv (DTA), BBAW Berlin, <http://deustextarchiv.de/>. Referenzdatensammlung des Deutschen in TEI, enthält derzeit rund 2400 Texte des 17.–19. Jahrhunderts.
- Forschungs- und Lehrkorpus Gesprochenes Deutsch (FOLK); IDS Mannheim, <http://agd.ids-mannheim.de/folk.shtml>. Audioaufnahmen mit Transkriptionen für gesprochene deutsche Sprache; Teil der Datenbank für Gesprochenes Deutsch (DGD).
- Hathi Trust Digital Library, <https://www.hathitrust.org/>. Datenbank mit 14 Millionen Volltext-Digitalisaten; große Teile der Volltexte sind unter Bedingungen verfügbar.
- International Corpus of English (ICE); Chinese University of Hong Kong, <http://ice-corpora.net/ice/index.htm>. Jeweils 1 Million Tokens geschriebener und transkribierter gesprochener Sprache aus der Zeit nach 1990.
- Internet Movie Scripts Database (IMSDb); <http://www.imsdb.com/>. Umfangreiche Sammlung der Drehbücher von Filmen und TV-Serien in HTML.
- Musopen; <https://musopen.org/>. Sammlung von Musik in Form von Noten und Audioaufnahmen.
- Old Maps Online; Klokant Technologies & University of Portsmouth, <http://www.oldmapsonline.org/>. Meta-Katalog, der rund 400.000 frei verfügbare Karten unterschiedlicher Institutionen verzeichnet.
- Open Movie Database (OMDb API); <http://www.omdbapi.com/>. Datenbank mit Metadaten zu Filmen, die über eine Schnittstelle (API) automatisch abgefragt werden kann.
- Oxford Text Archiv (OTA); Oxford University, <https://ota.ox.ac.uk/>. Umfangreiche Textsammlung überwiegend in englischer Sprache, u. a. in TEI. Gegründet 1976.
- Prometheus, <http://www.prometheus-bildarchiv.de/>. Bildarchiv für Forschung und Lehre; 1,5 Millionen qualitativ hochwertiger digitalisierter Bilder aus Kunst, Kultur und Geschichte. Frei nutzbar für Forschung und Lehre.
- Regesta Imperii Online; Akademie der Wissenschaften und der Literatur, Mainz <http://www.regesta-imperii.de/>. Referenziert mehr als 130.000 Regesten von Herrscher- und Papsturkunden von den Karolingern bis hin zu Maximilian I. (751–1519).
- TextGrid Digitale Bibliothek, <http://textgridrep.de/>. Umfangreiche Textsammlung überwiegend literarischer Texte in deutscher Sprache, in TEI.
- Théâtre classique, Université Paris-IV, <http://www.theatre-classique.fr/>. Rund 840 französische Theaterstücke des 17. und 18. Jahrhunderts in TEI.
- Victoria and Albert Museum Collections, <http://collections.vam.ac.uk/>. Bilddatenbank mit derzeit rund 1,7 Millionen Einträgen.
- WorldCat, <https://www.worldcat.org/>. Der größte internationale Bibliothekskatalog; über 2 Milliarden Katalogisate, über 72.000 teilnehmende Bibliotheken.
- Zentrales Verzeichnis Digitalisierter Drucke (zvdd), <http://www.zvdd.de>. Nachweisportal für die Digitalisate von Druckwerken vom 15. Jahrhundert bis heute; verzeichnet derzeit 1,4 Millionen Digitalisate.

16.6 | Fazit

Der Aufbau von Datensammlungen ist eine ebenso komplexe wie für die Forschung grundlegende Aufgabe in den digitalen Geisteswissenschaften. Sie ist Teil der *Data Curation*, eng verbunden mit Digitalisierung, Datenmodellierung und Digitaler Edition und geht der digital gestützten Erforschung geisteswissenschaftlicher Fragestellungen notwendig voraus. Der Aufbau von Datensammlung umfasst folgende idealtypisch abgegrenzte Schritte:

1. Abgrenzung des Gegenstands der Datensammlung
2. Erheben von Informationen über den gesamten Gegenstandsbereich
3. Auswahl von Datensätzen nach verschiedenen Strategien
4. Sammeln, Zusammenführen und Säubern von Datensätzen
5. Erheben und Hinzufügen von Informationen über die Daten
6. Verfügbarmachen der Datensammlung

Diese Schritte verlaufen nicht streng nacheinander, sondern sind durch vielfältige Abhängigkeiten miteinander verbunden. So ist beispielsweise schon die Auswahl der Datensätze eng mit der Aufnahme von Metadaten verknüpft. Nicht zuletzt beeinflusst die geplante Nutzung vielfältige Entscheidungen in jeder Phase des Aufbaus einer Datensammlung, wobei auch Wechselwirkungen regelmäßig vorkommen.

Jeder der hier beschriebenen Schritte kann in Abhängigkeit der Ziele und Ressourcen eines Vorhabens mit einem mehr oder weniger hoch angesetzten Anspruch umgesetzt werden. Zentral ist dabei, die Prinzipien, die den Aufbau der Datensammlung geleitet haben und die Entscheidungen, die jeweils getroffen wurden, zu dokumentieren. Wichtig ist zudem, sich vor dem Beginn des Aufbaus einer eigenen Datensammlung über die Positionierung des eigenen Vorhabens im hier beschriebenen Spektrum der Möglichkeiten Klarheit zu verschaffen. Sowohl in einem bestimmten Kontext unrealistische Ansprüche als auch nicht berücksichtigte grundlegende Anforderungen können sich im weiteren Verlauf als problematisch oder frustrierend erweisen. Vermeidet man beides, kann am Ende eine auch von anderen gewinnbringend nutzbare Datensammlung entstehen, für die sich der Aufwand lohnt.

Literatur

- Biber, Douglas: »Representativeness in corpus design«. In: *Literary and Linguistic Computing* 8/4 (1993), 243–257. Online: <http://llc.oupjournals.org/cgi/doi/10.1093/llc/8.4.243> (31.10.2016).
- Biemann, Chris et al.: »Scalable construction of high-quality web corpora«. In: *Journal for Language Technology and Computational Linguistics* 28/2 (2013), 23–59.
- Burnard, Lou. »Metadata for corpus work«. In: Martin Wynne (Hg.): *Developing Linguistic Corpora: a Guide to Good Practice*. Oxford 2004. Online: <http://ota.ox.ac.uk/documents/creating/dlc/> (31.10.2016).
- Friedl, Jeffrey E. F.: *Reguläre Ausdrücke*. Beijing ³2008.
- McEnery, Tony/Wilson, Andrew: *Corpus Linguistics: An Introduction*. Edinburgh ²2001.
- National Science Board: *Long-Lived Digital Data Collections Enabling Research and Education in the 21st Century*. Arlington 2005. Online: <http://www.nsf.gov/pubs/2005/nsb0540/> (31.10.2016).
- Oßwald, Achim/Neuroth, Heike/Scheffel, Regine: »Digital curation of research data: An introduction«. In: Heike Neuroth/Stefan Strathmann/Achim Oßwald/Jens Ludwig (Hg.): *Digital Curation of Research Data*. Glückstadt 2013, 9–17.

Internetquellen

César: <http://www.cesar.org.uk/cesar2/home.php>.
CLARIN (Common Language Resources and Technology Infrastructure): <http://clarin.eu/>.
DARIAH (Digital Research Infrastructure for the Arts and Humanities): <http://dariah.eu/>.
forschungsdaten.org: <http://www.forschungsdaten.org>.
GND (Gemeinsame Normdatei): <http://www.dnb.de/gnd>.
MEI (Music Encoding Initiative): <http://music-encoding.org/>.
nestor: <http://www.langzeitarchivierung.de/>.
TEI (Text Encoding Initiative): <http://www.tei-c.org>.
TGN (Getty Thesaurus of Geographic Names): <http://vocab.getty.edu/tgn/>.
VIAF (Virtual International Authority File): <https://viaf.org/>.
Zenodo: <http://www.zenodo.org>.

Christof Schöch

17 Digitale Edition

17.1 | Drei Beispiele zur Einführung

The screenshot displays the digital edition interface for the work of Petrus Plaoul. At the top, there is a navigation bar with 'SCTA', 'Text', 'Search Corpus', 'Submit', 'About', and 'Log in'. The main content area is titled 'Lectio 1, de Fide' by Petrus Plaoul, edited by Jeffrey C. Witt, with an edition date of 2011-10-dev-master | October 04, 2011. The original publication is by LombardPress, Sacramento, CA, March 23rd, 2011, under a Creative Commons Attribution-NonCommercial-NoDerivs 3.0 License.

The text itself is 'Lectio 1, de Fide' with a preface: '[Quaestio: utrum in causa iudiciali fidei contra traditionem pure humanitus adinventam iudex idoneus ferret pro fide sententiam]'. The main text begins with '1 Circa prologum Sententiarum' and includes a reference to '4 -- contra traditionem | contradictionem R SV'. A tooltip for the reference '4' shows '4 -- contra traditionem | contradictionem R SV'.

Below the text is the 'Apparatus Fontium' (Sources Apparatus) listing:

- 1 -- LOMBARD, *Sentences*, I, prologus, (I:1)
- 2 -- Iacobus 1:17

Below that is the 'Apparatus Criticus' (Critical Apparatus) listing:

- 1 -- Sententiarum | Magistri Petri Plaoul add. R SV
- 2 -- clypeis | om. V
- 3 -- in | om. R SV S
- 4 -- contra traditionem | contradictionem R SV
- 5 -- quod | om. R V

At the bottom, there is a 'Text Tool Bar' with 'Text Home', 'Text Outline', 'Previous', 'Next', 'Available Transcriptions', and 'Text Tools'. Below this is a 'Text Tool Bar' with 'Max', '100%', 'Min', and 'Close' buttons. The main text area is divided into 'Base Text: critical' and 'Comparison: reims'. The 'Base Text' shows the critical text with annotations, and the 'Comparison' shows the text from the Reims manuscript.

Abb. 49 Petrus Plaoul: Sentenzenkommentar, ediert von Jeffrey C. Witt, Ohne Ort, 2011–2013. Neue Weboberfläche 2016. <petrusplaoul.org>. Screenshots mit oben = edierter Text, mitte = Apparat der Textbezüge und textkritischer bzw. Variantenapparat, unten = generierter Textvergleich

Diese Edition zielt auf einen **kritisch bearbeiteten »besten Text«**, der aus den überlieferten Dokumenten (Textzeugen) durch Vergleich (Kollation) und durch die Anwendung philologischer Kritik hergestellt wird. Während die vorhandenen Kopien der Texte (die »Handschriften«) relativ genau abgeschrieben (transkribiert) werden, ist der edierte Text gemäß der Grammatik und Orthografie des Lateinischen reguliert und mit einer neuen Interpunktion versehen. Die Edition bietet zwei Anmerkungsapparate: Nummern bezeichnen textliche Abweichungen bei den

Dokumenten (im Beispiel hat bei Stelle 4 der edierte Text ›contra traditionem‹, während die Handschriften aus Reims und St. Victor, die mit den Abkürzungen R bzw. SV bezeichnet werden, ›contradictionem‹ haben; in den Apparateinträgen steht ›add‹ = addidit/addiderunt für ›hat/haben hinzugefügt‹ und ›om‹ = omisit/omiserunt für ›hat/haben weggelassen‹); kleine Buchstaben bezeichnen Anmerkungen zu Bezügen zu anderen Texten. Die Edition bietet außerdem einen automatischen Vergleich zwischen dem edierten Text und den Fassungen der einzelnen Handschriften.




Abb. 50 Theodor Fontane: Notizbücher, Digitale genetisch-kritische und kommentierte Edition, herausgegeben von Gabriele Radecke, Göttingen 2015 ff. <fontane-nb.dariah.eu>. Screenshot zu Notizbuch C7

Die Fontane-Notizbücher werden sehr quellentreu und genau (sogar topografisch genau) abgeschrieben, um die zeitliche Entstehung des Textes (die **Textgenese**) verständlich zu machen. Dieses sehr genaue Vorgehen wird manchmal als ›diplomatishche‹ bzw. ›hyperdiplomatishche‹ Transkription bezeichnet. Die parallele Anzeige von Bild (›Faksimile‹) und Text nennt man **synoptische Darstellung**. Eine dritte hinzuschaltbare Darstellungsoption ist die Anzeige der zugrundeliegenden Daten im Format XML (s. Kap. 9). Der Text wird durch die Edition weiter **erschlossen**: Entitäten wie Orte oder Personen aber auch Datierungen und Verweise (Referenzierungen) werden ausgezeichnet, können farbig hervorgehoben (Personen = Magenta, Orte = Grün, Zeitangaben = Türkis) und in Registern zusammengeführt werden.

Jahrrechnungen der Stadt Basel 1535 bis 1610 – digital
Beta-Version

HOME **Jahrrechnungen** Projekt Erweiterte Suche

Einnahmen

- Einnahmen Stadt
- Weinungeld
- Mehlungeld
- Stadtviehroll
- Bischofsviehroll
- Pferdroll
- Torroll
- Wegroll Neuer Weg
- Wiesenbrückenroll
- Gipsroll
- Weinstücherbüchse
- Wirtshausweinungeld
- Kaufhausroll
- Pfundroll
- Haungeld
- Schultheissenstock Grossbas...
- Lade
- Gewinn Satzhandel
- Schultheissenstock Kleinbasel
- Brotkarren
- Kornausfuhrroll
- Kaufhauswaage
- Gerberroll
- Kernbaser Zoll
- Diepfinger Zoll
- Schiffroll
- Wiesenflosserroll

☐ Alles in den Datenkorb übernehmen

fol. 1r [^]

Jarrechnung a festo
Johannis Baptistae
anno xv^o xxxv^o usque ad
festum Johannis Bap-
tistae anno xv^o xxxvj^o

fol. 1v [^]
fol. 2r [^]
fol. 2v [^]
fol. 3r [^]

☐ Empfangen

☐ Vom winungelt

- ☒ Prima angaria
- ☒ Secunda angaria
- ☒ Tercia angaria
- ☒ Quarta angaria

Suma iij^o vj^o ix lb

1^o boovij lb
vij^o bovj lb
vij^o boovij lb
ix^o xovij lb

**Jahrrechnung Stadt Basel
1535/1536**

StaBS Finanz H 92.1

Rechnungslegungszeitraum:
26.6.1535 bis 24.6.1536

Transkription vort:
Sonja Calvi
Lukas Meili

Zitiervorschlag: Jahrrechnung Stadt Basel
1535/1536, bearb. v. Sonja Calvi und Lukas
Meili, in: Die Jahrrechnungen der Stadt
Basel 1535-1610 - digitale Edition, hg. v.
Susanna Burghartz, Basel/Graz 2015
(zuletzt verändert am 2.3.2016), permalink
über DOI: 11471/1010.1.1535

Datenkorb

Gesamtsumme:	3677,45 lb.
1535:	3677,45 lb.
Gesamtsumme:	3677,45 lb.

```

<pb facs="#fol_3r" xml:id="fo1.3r"/>
<div ana="#bk_1 #bs_Einnahmen" xml:id="bs_Einnahmen-div-0">
  <head xml:id="d2e145">Empfangen</head>
  <div ana="#bs_StadtEinnahmen" xml:id="bs_StadtEinnahmen-div-0">
    <div ana="#bs_Weinungeld" xml:id="bs_Weinungeld-div-0">
      <head xml:id="d2e152">Vom winungelt</head>
      <metamark function="aggregate" name="Klammer"
        open="<#bs_Weinungeld-total-1" target="#bs_Weinungeld-1"/>
        <#bk_entry" cond="Klammer" xml:id="bs_Weinungeld-1">
          Prima angaria<seg ana="#bk_amount" cond="rb" xml:id="d2e159">
            <measure quantity="1653" type="currency" unit="lb">j</seg> <sup>bo</sup> <seg>xxxvij lb</measure></seg>

```

**Empfangen
Vom Winungelt**

Prima Angaria 1653 lb
Secunda Angaria vij bovj lb
Tercia Angaria vij boovij lb
Quarta Angaria ix xovij lb

Abb. 51 Jahrrechnungen der Stadt Basel 1535 bis 1610. Hg. von Susanna Burghartz, Basel/Graz 2015. DOI: 11471/1010.1.1535. Drei Screenshots: oben = Weboberfläche, unten links = XML-Code der Edition, unten rechts = Faksimile (jeweils Folio 3 recto)

Für die geschichtswissenschaftliche Forschung stehen die **Inhalte der Dokumente** im Vordergrund. Zugleich erschließt sich die Bedeutung der Texte und Zahlen aus der Struktur der Seite und der Einträge. Der Text wird deshalb nicht nur transkribiert, sondern in Form einzelner Einträge mit Werten und als Teile größerer Blöcke mit Summen erfasst. Die Rechnungsbereiche und Einzelposten können selektiert und in einem Datenkorb gesammelt werden. Verschiedene Export- und Download-Optionen (siehe die Icons oben rechts: tabellarische Darstellung, Faksimile, PDF, Basisdaten in TEI-XML, Daten im RDF-Format, Daten im CSV-Format) führen zu anderen Ansichten und ermöglichen die Weiterarbeit mit den Daten auch außerhalb der Edition.

17.2 | Worum geht es?

Wenn wir – im wissenschaftlichen Kontext, aber auch weit in die Alltagssprache hinein – von **Editionen** reden, dann sind fast immer ›kritische Editionen‹ gemeint: Wissenschaftlich aufbereitete Ausgaben von literarischen Texten oder historischen Dokumenten. Bei digitalen Editionen als einem der prominentesten Themen der Digital Humanities geht es dementsprechend um digitale wissenschaftliche Ausgaben, mit denen Grundlagenmaterial für die weitere Forschung bereitgestellt wird. Diese Forschung umfasst alle Bereiche und Disziplinen der Geistes- und Kulturwissenschaften und reicht von den verschiedenen Sprach- und Literaturwissenschaften (Bsp. 2: Neuere Deutsche Literaturwissenschaft), über die Geschichte (Bsp. 3: Wirtschafts- und Sozialgeschichte der frühen Neuzeit), die Kunstgeschichte bis hin zu den Medienwissenschaften, der Theologie oder der Philosophie (Bsp. 1: Theologie und Philosophie des Mittelalters).

Eine sehr alte wissenschaftliche Tätigkeit: Die Tradition der kritischen Auseinandersetzung mit den überlieferten Dokumenten und der Versuch, gute Fassungen und Ausgaben herzustellen, reichen sehr weit zurück. In der Kultur handschriftlicher Überlieferung bestand das Problem, dass originale Textfassungen verlorengingen, nur in Abschriften weitergegeben wurden und sich dadurch Fehler einschleichen konnten. Die Aufgabe der kritischen Philologie bzw. **Editionsphilologie** bestand deshalb darin, die Überlieferung zu sichten, die Abstammungsverhältnisse zwischen den Kopien zu ermitteln und aus den vorhandenen Varianten die jeweils besten zu ermitteln oder die ursprüngliche Textform einer bestimmten Stelle zu rekonstruieren um am Ende den **Urtext** (also jenen ersten, ursprünglichen Text, von dem letztlich alle Abschriften abstammen), den Autortext, den ›authentischen Text‹ oder zumindest einem dem Original möglichst nahe kommenden Text zu gewinnen und veröffentlichen zu können (s. Bsp. 1). Diese Methode der Sichtung der Überlieferung (Rezension), des Textvergleichs (Kollation), der Kritik der einzelnen Varianten (Examination) und ggf. der Textverbesserung (Emendation) gilt als editorische Methode der Textkritik und wird oft mit dem Namen Karl Lachmann verbunden verallgemeinert auch Lachmannsche Methode genannt, wenn sie mit dem Ziel der Konstruktion (**Konstitution**) eines idealen oder besten Textes verbunden ist. In den neu-philologischen Editionen ist man, da man häufig Autorhandschriften vorliegen hat, weniger an Überlieferungsvarianten als an Entstehungsvarianten interessiert, die einen Einblick in die Genese der Werke erlauben.

Dabei muss man beachten, dass die Herstellung eines Urtextes dort Sinn macht, wo die ältesten Fassungen verloren sind und Wert auf kanonische Fassungen gelegt wird, die sich auch stilistisch einem philologischen Ideal annähern. Dies ist vor allem für Texte aus der Antike oder dem Mittelalter der Fall. Neben der Erarbeitung eines »edierten Textes« kann es bei Editionen aber noch eine ganze Reihe weiterer **Zielstellungen** geben. Außerdem erstrecken sie sich auf ganz unterschiedliche **Materialarten, Dokumentsorten und Textgattungen**. Neben der »Lachmannschen« hat es immer schon andere Schulen und methodische Ansätze gegeben, die eine Konstruktion von Textfassungen jenseits der Wirklichkeit der Dokumente abgelehnt haben. Das kämpferische Schlagwort für diese letztlich historisch unbelegten und hypothetischen Editionstexte lautet dann: »*the text that never was*«.

Unterschiedliche Zielsetzungen: Jenseits der Rekonstruktion eines Urtextes, der Realisierung der Autorintention oder der Erfüllung des letzten Autorwillens (»Aus-

gabe letzter Hand«) kann es auch darum gehen, dem besten verfügbaren Zeugen zu folgen (Leithandschriftenprinzip), den tatsächlich rezipierten Text in den Vordergrund zu stellen, die Breite der Varianz sichtbar zu machen (Variorum-Edition), den Entstehungsprozess zu analysieren (genetische Edition; Bsp. 2), einen möglichst gut benutzbaren, »lesernahen« Text herzustellen (Bsp. 1 und 3), der Form der überlieferten Dokumente möglichst nahe zu kommen (diplomatische Ausgabe; s. Bsp. 2) oder vor allem den Informationsgehalt von Dokumenten herauszuarbeiten (Bsp. 3). Während der Schule der Textkonstitution und Textmischung aus den verschiedenen Textzeugen der Vorwurf des Eklektizismus gemacht worden ist, ist z. B. die amerikanische Editorik lange dem Prinzip des »copy text« (Leittext) gefolgt. Die französische Schule der »critique génétique« mit ihrer Konzentration auf die Genese literarischer Werke oder das amerikanische Konzept des »documentary editing« für die Erschließung historischer Dokumente ohne tiefere philologische Kritik sind weitere Beispiele für verschiedene methodische Strömungen.

Die **Zielstellungen** und die gewählte **Methode** hängen wesentlich vom jeweiligen Fachhintergrund und damit den Forschungsinteressen ab. So zielen Editionen aus den **Literaturwissenschaften** häufig auf einen philologisch bearbeiteten Text als Ausdruck eines sprachlichen Kunstwerks das z. B. früher orthografisch durchaus angepasst werden durfte (Bsp. 1). Dagegen muss es aus **sprachhistorischer Sicht** gerade um die Bewahrung schriftsprachlicher Eigenheiten gehen und die Edition näher an der spezifischen Form der Dokumente bleiben. Für die moderne Literaturwissenschaft sind auch die eigenhändigen Entwurfs- oder Notizhandschriften von Schriftstellern für die Erforschung des Schaffensprozesses besonders interessant – diese müssen dann ebenfalls so genau wie möglich – und sogar in ihrer zeitlichen Entstehungs- und Bearbeitungsfolge – wiedergegeben werden (Bsp. 2). Aus **historischer Sicht** wiederum bestehen zwei sich widersprechende Prinzipien: Auf der einen Seite geht es um eine historische Durchdringung und leichte Verständlichkeit des Inhalts, so dass Sacherkklärungen wichtig sind und der Text selbst lesernah normiert und (z. B. die Orthografie) gestaltet werden darf; auf der anderen Seite ist der Inhalt häufig nur in der Berücksichtigung der Form der Dokumente richtig zu verstehen, so dass hier detaillierte äußere Beschreibungen und sehr quellennahe Formen der Abschrift (Transkription) der Zeichen bis hin zur Berücksichtigung der zweidimensionalen Gestaltung (Layout, »mise en page«) der Dokumente wichtig sein können (Bsp. 3). Insgesamt hat in den letzten Jahrzehnten die Materialität der Dokumente, vom Zeichenträger bis zum Layout in den unterschiedlichen Disziplinen, die mit Editionen befasst sind, sehr zunehmende Aufmerksamkeit erfahren. Diese Tendenz ist durch die digitalen Editionen noch verstärkt worden.

17.3 | Definitivischer Rahmen

Editionen, und damit auch die digitalen Editionen, sollen **Grundlagen** für die Beantwortung geisteswissenschaftlicher Forschungsfragen bereitstellen. Sie befassen sich dazu mit den vorhandenen (überlieferten) Objekten, untersuchen sie, reichern sie mit **kritischem Wissen** an und führen schließlich zu Veröffentlichungen, die für einen breiten Nutzerkreis zugänglich sein sollen. Ein allgemeines Verständnis von Editionen muss alle historischen Zeiträume, alle theoretischen Ausgangspunkte, alle editorischen Schulen, alle Zielstellungen und alle zu edierenden Gegenstände abdecken. Dabei sind auch die folgenden beiden widerstreitenden Positionen zu verein-

nen: Für manche Forscher geht es bei der Edition um **Texte als abstrakte Objekte**, um Werke, die von physischen Objekten nur ›bezeugt‹ werden und die erst durch die Edition ›realisiert‹ werden. Andere sehen nur **Dokumente als reale Objekte** an, und die Editionen sind dann auch als Stellvertreter und erneute Medialisierungen abstrakter Texte wiederum kulturelle Artefakte. Da beide Seiten für sich eine ›realistische‹ Position beanspruchen, kann der Unterschied am ehesten durch die Begriffe ›Platonismus‹ versus ›Materialismus‹ gekennzeichnet werden. Im Spannungsfeld dieser Sichtweisen entfalten sich die möglichen Gegenstände der Edition. Sie umfassen alle schrifttragenden Objekte (also z. B. auch Inschriften) oder die Notation musikalischer Werke. Grundsätzlich ist aber alles edierbar, was einer kritischen Aufbereitung bedarf. Theoretisch also z. B. auch Bildwerke für die kunsthistorische Forschung oder ganz allgemein museale physische Objekte der Kulturgeschichte.

Allgemeine Definition

Edition ist die erschließende Wiedergabe historischer Dokumente. Dabei meint »historisch« eine zu überbrückende Distanz zwischen unserem heutigen Verständnis und dem Erklärungsbedarf zur historischen Wirklichkeit. »Dokumente« ist ein Oberbegriff für beschreibbare physische Gegenstände *und* die Texte, die mit ihnen kommuniziert werden. »Wiedergabe« bezeichnet das notwendige Kriterium der vollständigen Repräsentation des Editionsgegenstandes (merke: Eine Beschreibung, ein Katalog, ist noch keine Edition!) auf bildlicher und/oder (meistens) textlicher Ebene. »Erschließung« schließlich ist ein Oberbegriff für alle kritischen Operationen, von der Auswahl der zu edierenden Objekte über die äußere Beschreibung, die selbst in einer Transkription unvermeidlichen Entscheidungen, die Identifikation von referenzierten »Dingen« in Texten, die (historischen) Sachanmerkungen bis hin zur Textkritik im engeren Sinne (merke: Eine Reproduktion ohne Kritik ist noch keine Edition!).

Während hiermit die Edition im Allgemeinen beschrieben ist, wird die digitale Edition dadurch bestimmt, dass sie gewissen ›**digitalen Paradigmen**‹ folgt. Im Ergebnis geht sie damit über die traditionelle Edition hinaus und kann z. B. nicht ohne wesentliche Verluste an Inhalt oder Funktionalität in eine traditionelle (gedruckte) Edition verwandelt werden. Deshalb gilt auch: Eine (retro-)digitalisierte (vormals gedruckte) Edition ist (noch) keine (echte) digitale Edition. Denn eine digitalisierte Druckausgabe muss doch von ihrer Methode, ihren Inhalten und ihren Nutzungsformen her in der Denkwelt des Buchdrucks gefangen bleiben.

Breite versus tiefe Erschließung: Digitale Editionen stehen methodisch vielen anderen Objekten der Digital Humanities nahe. Ihr Inhalt ist zunächst das Ergebnis von Digitalisierungsmaßnahmen und besteht maßgeblich aus elektronischen Texten, die weiter ausgezeichnet und annotiert werden. Dadurch entstehen Datensammlungen, wie sie auch in Textkorpora, digitalen Bibliotheken, digitalen Archiven oder digitalen Museen vorliegen (s. Kap. 15 und 16). Im Unterschied zu diesen steht aber bei Editionen nicht eine möglichst große Menge gleichartig erschlossener Objekte im Vordergrund, sondern die **kritische, tiefe Erschließung eines thematisch begrenzten Gegenstandes**, der inhaltlich eingeführt, unter Umständen mehrfach (durch Abbildung, Transkription, kritischen Editionstext) repräsentiert, intern und extern vernetzt und durch zusätzliche Informationen und Materialien kontextualisiert wird. Schließlich ist die digitale Edition ein Sonderfall für Digitales Publizieren, weil sie häufig zu maßgeschneiderten, individuellen, sehr komplexen Publikationen führt.

17.4 | Paradigmen digitaler Editionen

Traditionelle und digitale Editionen unterscheiden sich durch die allgemeinen Paradigmen, denen sie folgen. Dies sind methodische Leitvorstellungen, die letzten Endes auch von den jeweiligen technischen Rahmenbedingungen abhängen. Für die traditionelle Edition sind es die Möglichkeiten und Beschränkungen der Druckkultur, die z. B. über die Ökonomie des Platzes die Menge der Inhalte einer Edition begrenzen und die Fokussierung auf »die Seite« als Grundfolie auf der etwas präsentiert werden kann. Die digitalen Medien kennen diese Grenze kaum, und so ist die digitale Edition durch eine grundsätzliche **Offenheit** gekennzeichnet, die es nahelegt, immer weitere Kontexte in die Edition einzubeziehen und schließlich zu einem Problem der **Entgrenzung** führt. Dagegen müssen Editoren mit der genauen Definition des zu edierenden Gegenstandes und seiner Grenze teilweise aktiv umgehen.

Work in progress: Die Bedingungen der Drucktechnologie sind auch Ursache für eine Fokussierung auf die *eine*, typografisch gefasste, kanonisierbare Form des konstituierten Textes. Die digitalen Medien führen dagegen zu einer weitgehenden Öffnung der Edition in verschiedenster Hinsicht: Das gedruckte Buch markiert einen Endzustand, es friert einen Wissensstand ein. Die digitale Edition ist leicht veränderlich und kann eine potentiell anhaltende Auseinandersetzung dokumentieren. Die Edition wird vom **Produkt** zum **Prozess**, schafft damit aber auch neue, bisher ungelöste Herausforderungen, was die Nachvollziehbarkeit von Eingriffen und Änderungen oder die stabile Zitierung betrifft. Die gedruckte Edition verweist implizit auf andere Texte und Informationen. Paratexte, Variantenapparate, Sachanmerkungen und Register bilden ein typografisch basiertes Informationsnetz, das in digitalen Editionen über Links unmittelbar nutzbar gemacht wird. Dabei wird die innere und äußere **Vernetzung** von ihrer typografischen Gebundenheit (Seite, Zeile, Fußnotennummer etc.) gelöst, »logifiziert«, systematisiert und verdichtet. Der digitale Link bezieht sich nicht auf eine Position in einer Publikation, sondern auf ein modelliertes Datum in einer digitalen Wissensbasis. Die gedruckte Edition war aus ökonomischen Gründen tendenziell bildfeindlich und monotextuell. In der digitalen Edition ist die Untermuerung durch Faksimiles nicht die Ausnahme, sondern die Regel. Diese Form der **Multimedialität** erhöht die **Transparenz** der wissenschaftlichen Bearbeitung, fördert damit aber auch eine materialistischere Sicht auf Texte.

Damit haben technische Veränderungen letztlich einen grundlegenden Einfluss darauf, was wir eigentlich unter den zu edierenden Texten verstehen und wie wir mit ihnen umgehen. Technologien verändern unseren **Textbegriff**. Digitale Editionen erlauben **mehrfache Textwiedergaben** auf der **Skala zwischen Quellennähe und Benutzernähe**: von topografischen über diplomatische, korrigierte, normierte, modernisierte Fassungen bis hin zu emendierten, konstituierten Texten. Auch das digitale Faksimile erscheint dann als erste Form der Textwiedergabe. Am anderen Ende der Skala markieren auch eine Übersetzung oder die Auflösung eines Textes in seine semantischen Aussagepartikel (z. B. in Form einer Datenbank) nur jeweils weitere Verarbeitungsschritte.

Grundlage dieser vielfachen Textformen sind reichhaltige Daten, die sowohl die Befunde aus den Dokumenten genau verzeichnen, als auch Deutungen und Interpretationen aufnehmen. In der elektronischen Recodierung wird davon gesprochen, dass die vorgefundene **Form** in ihren abstrakten **Inhalt** übersetzt wird. Oder umge-

kehrt, dass der Inhalt um Informationen zur Form ergänzt wird. Denn letztlich gibt es in der Haltung zum Text diese zwei gegensätzlichen Positionen: Ich habe einen Text als Dokument, das ich als solches beschreibe und recodiere und in dem ich dann einen Text als Zeichenkette finde – oder ich habe einen Text als Zeichenkette, zu der ich die Informationen zum Text als Dokument hinzufüge. Um zwischen der Datenbasis und ihrer Publikation zu unterscheiden, kann man die Begriffe **Repräsentation** (in modellbasierten Daten) und **Präsentation** (in Medien) verwenden.

Digitale Publikationen können nach dem *single-source*-Prinzip aus einer Datenquelle synchron und diachron immer wieder anders generiert werden. Man kann deshalb sagen, dass der eigentliche Wandel in der Editorik nicht so sehr in einem Wechsel der Medien liegt, als in ihrer **Transmedialisierung**: Bei Editionen geht es nicht nur um ihre mediale Erscheinung, sondern vor allem um das als Daten gefasste akkumulierte Wissen und das ihnen zugrundeliegende Modell als Explikation der editorischen Methode.

17.5 | Methoden und die Realisierung digitaler Editionen

Methodisch sind digitale Editionen von einigen wenigen zentralen Geboten geleitet. Hier ist zunächst der **wissenschaftliche Anspruch** grundlegend. Digitale Editionen sind Grundlagenforschung, die das bestehende Wissen zu einem bestimmten Thema bündeln, auf die Überlieferung anwenden und dadurch eine Basis schaffen, auf der weitere Forschungsfragen aufsetzen können. Die Edition nimmt in der Konfrontation der Befunde aus den Dokumenten mit dem Wissen über ihre Entstehung und ihre Intentionen eine **kritische Haltung** ein und verspricht, alle Teile gleichermaßen genau zu bearbeiten um am Ende einen gleichmäßig erschlossenen und bearbeiteten Dokument- oder Textbestand der Forschung zur Verfügung stellen zu können. Damit hängt das oberste, klar zu benennende Gebot der Editorik zusammen, das ausnahmslos für jedes Vorhaben gilt.

Grundregeln der Editorik

In Kenntnis der editorischen Methodologie im jeweiligen Gegenstandsbereich sollen für eine Edition sinnvolle, eindeutige und zielführende Regeln des Vorgehens aufgestellt werden. Dabei ist wichtig, diese einzuhalten und sie vollständig zu dokumentieren.

Nur dadurch kann gewährleistet werden, dass die editorischen Prozesse der Befundaufnahme, der Textbearbeitung und editorischer Entscheidungen **transparent** werden und die Entstehung der Edition **nachvollziehbar** bleibt. Dabei ist auch wichtig zu dokumentieren, *wer* für welche editorischen Arbeiten und Entscheidungen verantwortlich ist. Wenn eine Edition das Ergebnis der Anwendung des besten Wissens über einen Gegenstand ist, dann geht es auch um das Vertrauen in Akteure als Träger dieses Wissens.

Jenseits der editorischen Grundvoraussetzung eines regelgeleiteten wissenschaftlichen kritischen Prozesses kann eine digitale Edition als spezielle Form eines digitalen Informationssystems betrachtet werden. Eines der bekanntesten Architekturmuster in diesem Bereich hilft auch dabei, die einzelnen Arbeitsbereiche digitaler Editionen besser zu verstehen: Das »Model View Controller«-Paradigma (MVC) be-

schreibt Systeme, bei denen drei Dinge grundsätzlich getrennt voneinander betrachtet werden, auch wenn sie erst im Zusammenspiel gut benutzbare inhaltsreiche Anwendungen ergeben. *Model* steht dabei sowohl für das **Datenmodell** als auch die **Daten** selbst; *View* betrifft die Präsentation, die **Publikation**, die Darstellung der Edition; *Controller* beschreibt die technische Schicht dazwischen, die **Transformation** der Inhalte in eine digitale Präsentation, die auch durch Interaktion der Anwendung mit dem Benutzer bzw. der Benutzerin gesteuert wird. Die folgenden Abschnitte zeigen an beispielhaften Fragen, wie diese Bereiche abzudecken sind, wenn z. B. eine neue Edition konzeptionell entwickelt werden soll.

Model – Daten und Datenmodelle

Editionsmodelle: Die Grundlage aller digitalen Editionen sind Modelle. Dabei müssen verschiedene Bereiche explizit modelliert werden, die in den traditionellen Editionsprojekten teilweise nur nach impliziten »so hat man es schon immer gemacht«-Methoden gehandhabt wurden. Die Bereiche und Herausforderungen sind hier aber grundsätzlich immer schon ähnlich gewesen:

1. **Die Edition insgesamt:** Was ist der Gegenstand, was soll Inhalt der Edition sein? Welche Fragestellungen sollen mit der Edition bearbeitbar werden? Welche Kontexte (Dokumente, Informationen) sollen mitgegeben werden? Wie verhalten sich die Teile der Edition zueinander? Welche Bezüge zu Ressourcen außerhalb der Edition gibt es?
2. **Die Erschließung der Inhalte der Edition:** Wie sollen die Dokumente beschrieben werden? Welcher Metadatenstandard ist zu verwenden?
3. **Die Wiedergabe der edierten Gegenstände:** Wie sollen die visuellen Aspekte der Dokumente repräsentiert werden? Was sind die Parameter einer Bilddigitalisierung? Wie sollen Texte transkribiert werden? Wie dokumentnah soll die Transkription erfolgen? Geht die Repräsentation vom abstrakten Text zu seiner materiellen Erscheinung oder vom dokumenthaften Befund zu seiner Deutung über? Sollen topografische, grafematische, orthografische Phänomene berücksichtigt werden? Ob und wie sollen Abkürzungen (stillschweigend oder kenntlich) aufgelöst oder Normierungen vorgenommen werden? Dies sind nur wenige Beispiele für den potentiell sehr umfangreichen Regelungsbedarf, wenn es um die Transkription geht. Grundsätzlich ist hier zu modellieren, welche Dimension der Textualität wie abgedeckt werden soll: Visualität – Materialität – Zeichenbestand – Sprachlicher Ausdruck – (Werk-/Text-)Strukturen – Bedeutung / Semantik.
4. **Die weitere Kritik und Annotation der edierten Gegenstände:** Soll es eine philologische Kommentierung oder Annotation geben? Soll emendierend in den Text eingegriffen werden? Soll es einen historischen oder Sachkommentar geben? Wie ist mit Varianz bei mehrfach überlieferten Texten umzugehen? Werden variante Fassungen zusammengeführt oder als einzelne Texte belassen? Sollen benannte Entitäten (Personen, Orte etc.) identifiziert werden? Soll eine Erschließung durch Schlagworte erfolgen?

Auf der Grundlage der Modellierung stellt die Edition Inhalte bereit. Diese lassen sich grob zwei Gruppen zuordnen:

1. **Repräsentationsformen der edierten Gegenstände oder anderer Materialien:** Digitale Abbildungen und Transkriptionen, die immer weiter ausgezeichnet, an-

gereichert und annotiert werden, können verschiedene Sichten auf die Dokumente abbilden und erlauben in der Publikation mehrfache Wiedergabeformen.

2. **Zusätzliche Informationen:** Editionen haben vielfältige Paratexte: Vorworte, Einleitungen und eine Dokumentation ihrer selbst; oft gibt es weitere erläuternde Texte, Diskussionen oder eingebundene Sekundärliteratur. Zusätzliche Informationen können auch biografische Dossiers sein. Aus den Transkriptionen und Erschließungsdaten werden eigenständige Register und Wissensbasen generiert. Viele Editionen verfügen über Bibliografien zu ihrem Forschungsgegenstand.

View – Präsentation und Publikation

Hybridpublikation: Editionen können auf mehrfache Weise bereitgestellt werden. Auch bei digitalen Editionen spricht nichts gegen eine »Hybrid-Ausgabe«, also eine doppelte Publikation in digitalen und analogen Medien. Eine zusätzliche gedruckte **Buchausgabe** ist dann sinnvoll, wenn ein entsprechendes Nutzungsszenario, z. B. eine sequentielle, kontemplative Rezeption, zu erwarten ist. Es ist aber klar, dass eine solche Ausgabe gegenüber dem Editionsprojekt insgesamt nur spin-off-Charakter haben kann. Auf der anderen Seite können Editionen einfach als **Daten** an einer Schnittstelle, an einer Programmierschnittstelle (API) oder als Bulk-Download an einer Adresse bereitgestellt werden – um eine Weiterverwendung in anderen Kontexten oder eine systematische Auswertung zu erlauben. Der Regelfall ist aber die Veröffentlichung als **digitale Publikation**, für die dann die gleichen Regeln gelten, wie für andere komplexe Informationssysteme auch. Dabei ist dann u. a. zu regeln,

- wie das Gesamtsystem aussehen soll, wie es alle Inhalte gleichermaßen einfach zugänglich macht und welche Funktionalitäten es umfassen soll
- wie übersichtliche Browsing-Zugänge zu den Inhalten aufzubauen sind
- welche Formen einer allgemeinen oder spezialisierten Suche es geben soll
- wie mittels Registern, Indizes oder visualisierenden Aufbereitungen zusätzliche Wege zum Material geschaffen werden können
- wie die Inhalte selbst präsentiert werden
- wie verschiedene Formen der Inhalte (z. B. Faksimile und Transkription) zusammen dargestellt werden
- wie die Vernetzung der Inhalte untereinander oder mit externen Ressourcen umgesetzt wird
- wie die Inhalte über dauerhafte (persistente) Adressen feingranular ansprechbar, referenzierbar und zitierbar gemacht werden

Controller – Die technische Schicht

Digitale Editionen können als Publikationen verstanden werden. Man kann darunter aber auch die Daten der Edition fassen. Die vermittelnde Schicht, die die Daten verwaltet und die Publikation generiert ist dagegen eine grundsätzlich austauschbare Komponente. Ihre Aufgabe kann über die Generierung statischer Präsentationsformen hinausgehen, wenn der Benutzer bzw. die Benutzerin z. B. über Suchformulare, über Einstellungsmöglichkeiten oder über die Auswahl von zu vergleichenden Fassungen die Rückmeldung und das Verhalten der Edition selber steuern kann. Streng genommen kann deshalb zwischen einer **Publikationskomponente** und einer **Con-**

troller-Komponente im engeren Sinne unterschieden werden, die Nutzeraktionen aufnimmt und regelt, welche Ansicht (»View«) generiert werden soll. Für die Veröffentlichung der Edition gibt es viele verschiedene technische Lösungen. Zu den typischen Szenarien gehören ...

- die Generierung von eher statischen Webseiten aus den zugrundeliegenden Daten, z. B. mittels XSLT
- die Präsentation von Editionen mittels Content Management Systemen
- die Verwendung von Datenbanken mit einer zusätzlichen Programmierschicht zur Abfrage und Generierung von Webseiten
- der Einsatz von XML-*publication frameworks*

In letzter Zeit hat sich bei vielen großen, anspruchsvollen Editionen eine Architektur etabliert, die davon ausgeht, dass die zugrundeliegenden XML-Daten in XML-Datenbanken (»eXist«, »BaseX«) oder anderen Repository-Systemen (z. B. »fedora«) verwaltet und mit einer eigens programmierten Abfragelogik angesprochen und in eine Web-Präsentation verwandelt werden. Welche Technologien in einer Edition für die Schicht zwischen den Daten und der Publikation eingesetzt werden, hängt vor allem von den Gegenständen und der Komplexität der Edition, von den Kompetenzen und Vorlieben der Verantwortlichen und vom finanziellen und zeitlichen Rahmen eines Projektes ab.

17.6 | Editionen als Projekte

Komplexitätsfragen: Digitale Editionen werden fast immer als private Vorhaben (z. B. im Rahmen einer Dissertation), als öffentlich geförderte Drittmittelprojekte oder als Teil der Grundaufgaben von bestimmten Institutionen (Forschungseinrichtungen, Bibliotheken, Archive) durchgeführt. Sie neigen dazu, noch komplexer zu werden als ihre traditionellen Vorgänger. Es ist deshalb oft wichtig, für die vielen verschiedenen Aufgaben und Arbeitsbereiche in einem Team **Spezialisten** zu versammeln, die unterschiedliche Rollen wahrnehmen. Während dies in großen, anspruchsvollen Projekten tatsächlich zu einem Cast führen kann, der dem Abspann eines Kinofilms nahekommt, sind allein agierende Editoren oder Editorenteams in kleineren Projekten gezwungen, viele Rollen zu übernehmen und die unterschiedlichsten Aufgaben selbst durchzuführen.

Für die Erstellung von digitalen Editionen gibt es kaum umfassende, leicht einsetzbare spezielle **Werkzeuge**. Vielmehr arbeiten die meisten Projekte mit allgemeinen, nicht auf Editionen ausgerichteten Werkzeugen, einem selbst zusammengestellten Baukasten, eigens entwickelten Werkzeugen oder angepassten Werkzeugen, um z. B. Transkriptionen zu erstellen und weiter zu bearbeiten. Gerade im Bereich der **Transkriptionstools** gibt es zwar einerseits eine sehr große Fülle von Entwicklungen, es hat sich aber andererseits bisher keine bestimmte Lösung durchgesetzt, die für verschiedene Arten von Texten und Editionen und für verschiedene methodische Herangehensweisen und Zielstellungen ohne hohen Anpassungsaufwand in einer größeren Zahl von Editionsprojekten einsetzbar wäre.

17.7 | Technologien und Standards

Für die unterschiedlichen Bereiche digitaler Editionen sind verschiedene **Datenformate, Standards** und **Technologien** zu berücksichtigen. Für die Inhaltsdaten selbst, also für digitale Bilder und Texte, gilt zunächst das gleiche wie in den Kapiteln zu Digitalisierung, Bibliothek, Archiv, Museum oder Datensammlungen gesagt. Hinter die Standards ›guter Digitalisierung‹ können vor allem Editionen nicht zurückfallen. Weil Editionen meistens komplexe, stark informationsangereicherte Textdaten enthalten, basieren sie heute fast immer auf **XML**. Hier sind zwar auch lokale ›XML-Dialekte‹ zur Modellierung und Kodierung von Editionstexten anzutreffen, als gegenwärtiger Leitstandard spielen aber die Empfehlungen der ›**Text Encoding Initiative**‹ (**TEI**) eine entscheidende Rolle (s. u.). Im Bereich der allgemeinen Wissenscodierung kommen dann auch noch die Normdaten oder auch Thesauri ins Spiel, die verschiedenen Formaten (z. B. wiederum XML) und konzeptionellen Standards (wie SKOS – Simple Knowledge Organization System) folgen können.

Als Publikationen sind Digitale Editionen heute in der Regel **Webanwendungen**, die auf den gängigen Webstandards beruhen und als HTML-Webpages auf Stilinformationen in Cascading Style Sheets (CSS) beruhen und häufig Javascript benutzen, um bestimmte zusätzliche Funktionalitäten zu ermöglichen. Die Inhalte von Editionen werden häufig zusätzlich als Druckexport angeboten wobei meistens PDF als Ausgabeformat verwendet wird. Vorlagen für den Druck von Büchern werden dagegen über manchmal komplizierte Verarbeitungspipelines mit »TUSTEP«, »LaTeX« oder »Adobe InDesign« erzeugt. Wenn Editionsdaten an technischen Schnittstellen bereitgestellt werden, dann können hier außer dem ursprünglichen Format (in der Regel XML) auch Exportformate wie Dublin Core (DC), METS, RDF (Resource Description Framework) oder andere fachspezifische Standards eine Rolle spielen.

In der Transformation der Daten für eine Publikation werden heute für anspruchsvolle Editionsprojekte häufig XML-Datenbanken mit einer Abfrageschicht aus XQuery und ggf. weiteren Skripten (z. B. in PHP) eingesetzt. Es gibt daneben aber viele andere Architekturen, die auf unterschiedlichen Datenbanksystemen und dem Einsatz verschiedener Programmiersprachen beruhen. Ein allgemeiner Standard ist heute noch nicht zu erkennen.

Text Encoding Initiative (TEI)

Der Editionsstandard: Das Herzstück der Edition ist die **Modellierung ihres Gegenstandes**, in der Regel ein oder mehrere Texte bzw. Dokumente. Für digitale Editionen gibt es im Bereich der grundlegenden Codierung von Dokumenten und Texten mit den Richtlinien der Text Encoding Initiative einen Standard, der unverzichtbar ist. Die aktuelle Fassung, P5 (Proposal 5) ist eine XML-basierte Sprache mit über 500 Elementen. Dabei wird zum einen eine Grundstruktur für die Beschreibung aller möglichen Texttragenden Objekte festgelegt; zum anderen bieten die Guidelines etliche Kapitel zur Auszeichnung von:

- **Textsorten:** Dichtung, Aufführungstexte, Wörterbücher, Handschriftenbeschreibungen, Gesprochene Sprache
- **Textphänomenen:** Namen, Daten, Personen, Orte; Tabellen und Grafiken
- **wissenschaftlichen Anwendungen:** Sprachkorpora, Kritische Apparate

- **textanalytischen Zwecken:** Verknüpfung, Segmentierung, Parallelisierung; Merkmalsstrukturen

Grundsätzlich wird in **TEI-Dokumenten** zwischen dem eigentlichen Text und einem *Header* für die Titeldaten, Beschreibung und Dokumentation der digitalen Fassung unterschieden. Der Text selbst wird meistens als abstrakter Text verstanden, der in einem Element `<text>` enthalten ist und sich dann über z. B. eine Buchstruktur (front, body, back) und Buchteile (div = Teil) zu einzelnen Absätzen (p = paragraph) weiter entfaltet. Er kann aber auch als Transkription aufgenommen werden, die sich an der physisch-visuellen Form von Quelldokumenten orientiert und in einem Element `<sourceDoc>` enthalten ist, das über `<surface>` einzelne »Schreiboberflächen« (z. B. Seiten) und darauf über `<zone>` einzelne »Schriftbereiche« bestimmt, die Text enthalten. Sieht man davon ab, dass selten eine abstrakte und eine materialistische Textsicht zusammen gegeben werden, dann sieht die Grundstruktur von TEI-Dokumenten ungefähr wie folgt aus, wobei die zunehmende Einrückung die formale Hierarchie von XML-Elementen andeutet:

TEI	
teiHeader	Alle Angaben außer dem Text selbst
fileDesc	Angaben zur vorliegenden Datei
titleStmt	Alle Titelinformationen
title	Titel des Dokuments
publicationStmt	
p	Informationen zur Publikation
sourceDesc	
p	Beschreibung der Quelle oder Vorlage
sourceDoc	Das transkribierte Dokument
surface	Eine beschriebene Oberfläche
zone	Ein Schriftraum
line	Eine Zeile mit Schrift
text	Ein (abstrakter) Text
body	Der Text selbst (ohne Paratexte)
div	Ein Textteil (z.B. ein Kapitel)
p	Ein Absatz

Nach den Regeln der TEI ausgezeichnete Texte folgen dem Prinzip von Auszeichnungssprachen im Allgemeinen und XML im Besonderen, nach denen Informationen einerseits in hierarchisch strukturierten Elementen organisiert werden und andererseits ein fortlaufender Text (Zeichenbestand) durch Elemente und Attribute annotiert wird. Die TEI realisiert die Idee, dass Texte **Ordered Hierarchies of Content Objects** (OHCOs) sind, also eine Abfolge von Inhaltsobjekten, die Teil einer

Hierarchie sind. Zugleich folgt sie dem Ansatz der **Übersetzung von Form in Inhalt**. Die visuelle Form von Texten repräsentiert dabei abstrakte Textstruktureinheiten, die im Code explizit gemacht werden können. Abgesetzte Blöcke sind dann Paragraphen (`<p>`) und zentrierte, größer gedruckte, vertikal abgesetzte Zeilen können als Überschriften (`<head>` = headline) erkannt werden. Textabschnitte, die kursiv gesetzt sind, sind dann herausgehobene Passagen (`<hi>` = highlighted) oder in einem ›Nachdrücklichkeitsmodus‹ (`<emph>` = emphasized). Auf diese Interpretation kann aber auch verzichtet werden, wenn einfach ein Segment (`<seg>`) markiert wird, zu dem man festhält, wie es auf der Seite erscheint: `<seg rend="italics">` (`rend` = rendition). Auf der anderen Seite kann die Deutung bis zur **semantischen Explikation** vorangetrieben werden: `<persName key="gnd_118580914">Adolph Menzel</persName>` – Die Zeichenkette »Adolph Menzel« steht für einen Personennamen der wiederum auf eine Person verweist, die in der Gemeinsamen Normdatei (GND) durch die Nummer 118580914 identifiziert wird.

Auf diese Weise unterstützt die TEI ein sehr breites Verständnis von Text, nach dem der digitale Text der Edition als Repräsentation texttragender Dokumente das Ergebnis einer filternden Wahrnehmung von Textphänomenen und der darauf aufbauenden Anwendung von regelgeleiteten Verarbeitungs-, Deutungs- und Annotationsprozessen ist. Mit der TEI können nicht nur **verschiedene Sichten auf Text**, also verschiedene Wahrnehmungs- und Interpretationsebenen codiert werden, sondern verschiedene **gleichzeitig**.

Begrenzungen von TEI: In seiner großen Fülle an Elementen und Attributen scheint die TEI auf den ersten Blick allumfassend und vollständig. Jeder Benutzer wird aber sehr schnell merken, dass für die eigenen, in der Regel sehr speziellen Fragestellungen die Haltung der TEI nicht ganz genau passend sein wird und gewünschte Elemente zur Beschreibung von Textphänomenen und zur Textannotation fehlen oder in bestimmten Kontexten nicht erlaubt sind. Die Richtlinien der TEI sind ein historisch gewachsenes Corpus, das methodische und fachliche Schief lagen hat. Manche Bereiche (Disziplinen, Textsorten, Betrachtungsweisen) sind besser ausgebaut als andere. Dies wird zum Teil dadurch gemildert, dass die TEI eine sehr große und aktive Community bildet, die beständig an der Weiterentwicklung der Richtlinien, des Element-Satzes und zusätzlichen Hilfsmitteln arbeitet. Zu der weiten **TEI-Infrastruktur** gehören neben der umfassenden Dokumentation verschiedene Gremien, Special Interest Groups, eine Mailingliste, eine jährliche Konferenz, eine eigene Zeitschrift und vielfältige Werkzeuge zur Erzeugung und Verarbeitung von TEI-Daten.

Wegen der Vielfalt der Gegenstände, der theoretischen Grundannahmen, der editorischen Schulen und der Zielstellungen ist für die Codierung von Texten in kritischen Editionen kein allgemeiner Standard im Sinne einer strikten Vorschrift möglich. Die TEI ist in den meisten Fällen nicht unmittelbar als Direktive für die editorische Arbeit anwendbar. Die vorgeschlagene Grundstruktur passt tatsächlich auf fast alle Anwendungsbereiche. Jenseits davon sind aber in der Regel **Anpassungen** nötig. Aus dem Gesamtset werden dazu meist lokal passende Elemente ausgewählt, Attributwertlisten festgelegt, Verwendungsregeln formuliert und zur Not auch neue Elemente geschaffen. Dieser Prozess führt dann auch technisch und formal zu lokalen XML-Schemata, für deren Erstellung die TEI mit ODD (One Document Does it All) eine Schema-Metasprache und mit »Roma« ein Werkzeug zur Entwicklung lokaler Schemata bereitstellt.

17.8 | Fragestellungen

Digitale Editionen als prominentes Anwendungs- und Forschungsgebiet der Digital Humanities befinden sich immer noch in der Entwicklung. Es bieten sich deshalb viele Fragestellungen für eine vertiefende Auseinandersetzung und für die Untersuchung aktueller Tendenzen an, die aus drei Bereichen kommen können.

1. Empirie

- Beschreibung, Evaluation und Kritik von einzelnen Editionen in ihren verschiedenen Aspekten (Faksimiles, Transkription, Textkonstitution, Kommentierung, Such- und Browse-Zugänge, Register, Paratexte etc.)
- Diskussion der Datenmodelle (z. B. des jeweiligen XML-Schemas oder der TEI-Regeln) für einzelne Editionen
- vergleichende Betrachtung der Ästhetik und Funktionalität digitaler Editionen: entwickelt sich ein neues Standardmodell der Publikation?
- Editionen als Daten, die an Schnittstellen bereitgestellt werden
- Beschreibung und Evaluation von Werkzeugen zur Transkription und Editions-erstellung

2. Praxis, Simulation

- Hypothetische Konzeption eines Editionsprojekts auf der Basis eines bestimmten Werkes oder Materialbestandes
- Entwicklung eines angepassten TEI-Modells für vorliegende Dokumente bzw. Texte
- TEI-Codierung exemplarischer Dokumente

3. Theoriebildung, offene Fragestellungen

- Mögliche Gegenstände der Editorik und dafür geeignete Methoden
- Adressierbarkeit und Zitation von Editionen und ihrer Inhalte auf einer feingranularen Ebene
- Rolle der Editoren und anderer Akteure in der Erarbeitung von Editionen
- Öffnung von Editionen für ihr Publikum als aktiver Teil des Editionsprozesses; Crowdsourcing.
- Umgang mit Textvarianz; was wird aus den kritischen Apparaten?
- Begriff und Konzept der Edition im Auflösen der Grenzen zu Digitales Archiv oder Virtuelle Forschungsumgebung

Literatur

- Apollon, Daniel/ Bélisle, Claire/Régnier, Philippe (Hg.): *Digital Critical Editions*. Urbana/Chicaco/ Springfield 2014.
- Pierazzo, Elena: *Digital Scholarly Editing. Theories, Models and Methods*. Farnham 2015.
- Plachta, Bodo: *Editionswissenschaft – Eine Einführung in Methode und Praxis der Edition neuerer Texte*. Stuttgart 1997.
- Sahle, Patrick: *Digitale Editionsformen*. Norderstedt 2013. Online: [http://kups.ub.uni-koeln.de/5351/bzw. 5352, bzw. 5353](http://kups.ub.uni-koeln.de/5351/bzw.5352,bzw.5353) (31.10.2016).
- Sahle, Patrick: »Kriterien für die Besprechung digitaler Editionen« (2014), <http://www.i-d-e.de/publikationen/weitereschriften/kriterien-version-1-0/> (31.10.2016).

Internetquellen

A Catalog of Digital Scholarly Editions: www.digitale-edition.de. Eher retrospektive Sammlung von erschienenen »Editionen«, nicht von aktuellen Editionsprojekten.

Lexicon of Scholarly Editing: <http://uahost.uantwerpen.be/lse/> (2012 f.).

ride – A Review Journal for Digital Editions and Resources. Hg. vom Institut für Dokumentologie und Editorik: <http://ride.i-d-e.de>.

Text Encoding Initiative: <http://www.tei-c.org>.

Patrick Sahle

IV Digitale Methoden

18 Manuelle und automatische Annotation

18.1 | Was sind Annotationen?

Die folgenden Szenarien, darunter auch ein Blick in die vordigitale Geschichte, erlauben eine Annäherung an den Begriff und die Tätigkeit des Annotierens. Sie sollen auch verdeutlichen, welche Relevanz das Annotieren generell im wissenschaftlichen Kontext hat und welche Rolle Annotationen in einer digitalen Arbeits- und Forschungsumgebung spielen.

Texte wurden bis zur Erfindung des **Buchdrucks** manuell abgeschrieben, in unikatlichen Handschriften tradiert und anhand dieser Handschriften studiert. Zu allen Zeiten beinhaltete dieses Textstudium das Bearbeiten ›mit dem Stift in der Hand‹ – Passagen wurden angestrichen und mit Zeigehinweisen versehen (lat. *notabene*: merke wohl!), schwierige Wörter übersetzt und glossiert, Erläuterungen an den Rand notiert, ganze Passagen kommentiert – der Text wird annotiert (lat. *annotare*: anmerken, bemerken, notieren). Dabei reicht das Spektrum vom einfachen Hinweisen auf eine bemerkenswerte Stelle (auch als Gedächtnisstütze) bis hin zu komplexen Erläuterungen. Auf diese Weise entstehen ›Paratexte‹ (Beitexte), die unverzichtbar für das Verständnis und die Tradition eines Textes und daher fester, manchmal auch namentlich einem Glossator bzw. Kommentator zugewiesener, Teil der Tradierung werden können. Beispiele dafür bieten der Talmud als Kommentar zur Bibel, der aufzeigt, wie die biblischen Gesetze von den Rabbinern verstanden und ausgelegt wurden, Auslegungen zu Gesetzestexten (z. B. das *Decretum Gratiani*, eine hochmittelalterliche, reich kommentierte Rechtssammlung) oder Marginalien in Handschriften antiker Texte, z. B. in der Überlieferung des hoch geschätzten und viel gelesenen Philosophen Aristoteles.

Standardisierung: Mit der neuen Technologie der Texttradierung und Vervielfältigung, dem Buchdruck, ergibt sich mit den Setzer-Anweisungen ein Annotationsszenario mit deutlicher Tendenz zu Professionalisierung und Standardisierung: Autoren markierten ihre Manu- oder Typoskripte mit bereits standardisierten Satzanweisungen und Korrekturanweisungen, um beispielsweise anzugeben, welche Textpassagen in anderen Schriftgraden, kursiviert, hervorgehoben oder als Überschriften zu setzen waren (in der Handschriftenkultur gab es im Ansatz Vergleichbares, die Handschriftenplaner gaben den Skriptoren auch bereits entsprechende Anweisungen zur **Layouteinrichtung**, z. B. für Initialen, Einfügung von Illustrationen, rote Tinte usw.). Die entsprechenden DIN-Normen (DIN 16511 zuletzt 1/1966 und DIN 16549-1 zuletzt 11/1996) wurden mit praktischen Handreichungen auch breit über Bände des

Mit der neuen Technologie, der Texttradierung und

Vervielfältigung, dem Buchdruck, ergibt sich mit

den Setzeranweisungen ein Annotationsszenario mit

deutlicher Tendenz zu Professionalisierung und

Standardisierung.

H S
Kursiv
.....

Abb. 52 Typoskript mit Setzeranweisungen

Dudenverlags vermittelt (Duden 1969; Duden 2009). Diese Annotationen beziehen sich darauf, wie der Text auf der Buchseite arrangiert (layoutet) werden soll, zielen also ganz auf seine äußere Einrichtung. Eine solche Annotation ist in aller Regel in Bezug auf die Inhalte ambig, d. h. mehrdeutig, sie sagt nur, dass eine Textpassage kursiviert werden soll, jedoch nicht warum, z. B. Hervorhebung, Fremdwort, Zitat usw.

Die digitalen ›Nachfahren‹ solcher Setzer-Auszeichnungen, die eine ganz ähnliche Funktion wahrnehmen, können wir beispielsweise in der Hypertext Markup Language (HTML) sehen, die vor allem die Gestaltung und den Aufbau von Websites organisiert. Das Postscript-Format und das Portable Document Format (PDF) dienen in erster Linie der Fixierung des Seitenlayouts beim Dokumentenaustausch und lassen sich daher ebenfalls in diese Reihe stellen.

Simulation des Analogen: Verfolgt man das Annotieren im digitalen Umfeld weiter, sieht man ebenfalls ein breites Spektrum an Anwendungen: Softwaretools imitieren das aus dem **Analogen** Bekannte, indem sie z. B. das Anheften von Notizzetteln nachbilden oder mit Stift- und Sprechblasen-Icons Anstreichungen und Anmerkungen in Dateien erlauben. Mit webfähigen E-Book-Readern können Annotationen sogar mit der Öffentlichkeit geteilt werden, wodurch eine Art gemeinsames Lese-Erlebnis erzeugt wird. Mit Hilfe von **Normdaten** werden nicht nur Artikel in der kollaborativen (also gemeinschaftlich erstellten) Enzyklopädie Wikipedia oder in Bibliothekskatalogen und wissenschaftlichen Verzeichnissen annotiert: Ziel ist hier ihre automatisierte wechselseitige Verlinkung. Digitale Annotationen dienen damit sowohl der individuellen Gedächtnis- und Wissensarbeit als auch der Kommunikation, ferner der (automatischen) Erschließung und Vernetzung von Weltwissen. Die theoretischen und technologischen Entsprechungen sind in der Idee des *Semantic Web* und den *Linked Open Data* (LOD) zu sehen, worauf noch zurückzukommen sein wird (s. Kap. 11.5).

Das in diesen drei kurzen Szenarien beschriebene Annotieren ist demnach ein produktiver Teil individueller und gemeinsamer Wissensarbeit, es dient der Organisation, Strukturierung, Aneignung und Weitergabe von Wissen. Die beobachteten Tendenzen zur **Standardisierung** machen auf eine weitere wichtige Eigenschaft von Annotationen aufmerksam: Sie können der Abstrahierung von Einzelvorkommen und deren Ordnung und Zusammenfassung in übergreifenden Klassen dienen und damit sowohl Teil des wissenschaftlichen Forschungsprozesses als auch dessen Ergebnis sein. Das Annotieren gehört demnach zu den ältesten und grundlegendsten wissenschaftlichen Praktiken und wird deshalb auch zu den sogenannten *scholarly primitives* gerechnet (Unsworth 2000). In digitaler Form erlauben Annotationen das effiziente Recherchieren bestimmter Muster (*pattern*) und Phänomene sowie die Weiterverarbeitung (Transformation, Manipulation) auch über große Datenmengen.

Aus den bisherigen Beobachtungen lassen sich unterschiedliche funktionale Bereiche von Annotationen ableiten:

- Annotationen können Informationen über Dokumente abbilden und (z. B. für ihre Weitergabe oder den Druck) organisieren,
- Annotationen können das Ergebnis einer inhaltlichen Analyse sein,
- Annotationen können einen Zwischenschritt oder ein Zwischenergebnis im wissenschaftlichen Prozess darstellen und Voraussetzung für Auswertungen sein,
- Annotationen können Teil eines ›Forschungslebenszyklus‹ (*research life cycle*) und damit eines iterativen Prozesses der Wissensgenerierung und -weitergabe sein.

Formen von digitalen Annotationen: Digitale Annotationen sind jedoch noch wesentlich vielfältiger, als in diesen einfachen Beispielen skizziert. Im diesem Kapitel soll ein erster Überblick darüber gegeben werden, welche Funktionen digitale Annotationen im Forschungsprozess erfüllen, wie sich der Prozess der Formalisierung organisieren lässt, welche Typen von Annotationen und welche Standards es gibt, mit welchen Verfahren (manuell, automatisch, semiautomatisch) unterschiedliche Objekte (z. B. Text, Bild, Video) annotiert werden können, und schließlich welche Auswertungsmöglichkeiten damit verbunden sind. Der letzte Punkt wird dabei nur kurz angerissen, da die folgenden Kapitel ausführlich spezifische **Auswertungsverfahren** vorstellen. In der Literatur findet sich darüber hinaus häufig die Unterscheidung zwischen prozeduralem und deklarativem Markup: Das prozedurale, darstellende Markup hat seine Wurzeln in den typographischen Markierungen, die Anweisungen wie »schalte um auf Kursivfont« geben (z. B. Postscript), das deklarative Markup erlaubt die (inhaltliche) Beschreibung des Dokuments (z. B. XML, TEI).

18.2 | Formalisierung und Operationalisierung

Die Ausführungen in diesem Kapitel nehmen ihren Ausgangspunkt häufig in Verfahren der Text-Annotation, nicht allein weil hier auf die umfangreichsten Erfahrungen zurückgegriffen werden kann, sondern auch weil in diesem Feld zentrale, zum Teil modellbildende Anwendungen entwickelt wurden und zahlreiche Beispiele zu finden sind. Dennoch sollen exemplarisch auch Verfahren für andere Objekttypen, hier vor allem Bilder sowie Audio und Video herangezogen werden. Andere Datentypen wie beispielsweise 3D-Rekonstruktionen oder Musikdaten bleiben unberücksichtigt, finden sich zum Teil jedoch in anderen Kapiteln dieser Einführung behandelt. Da die Datenmengen für alle Datentypen und auch die Rechenleistung, die für ihre Auswertung benötigt wird, kontinuierlich wachsen, entwickeln sich die entsprechenden Verfahren rasch weiter. Hier bietet sich also ein zukunftssträchtiges Feld auch für die Digital Humanities.

Weitere relevante Begriffe

Neben dem Begriff ›Annotation‹ finden weitere Begriffe in diesem Kontext Verwendung: Mithilfe von **Auszeichnungssprachen** (*markup languages*) wie beispielsweise XML können Daten annotiert werden. Die einzelnen Marker, die zum Annotieren benutzt werden, werden auch als **Tag** (engl. Etikett, Anhänger) bezeichnet. Wir kennen sie z. B. in HTML als die in spitzen Klammern eingeschlossenen Kürzel, die den Text für die Darstellung im Web strukturieren (zur Verwendung und zur Struktur im Kontext von Auszeichnungssprachen s. Kap. 9). Gruppen von zusammengehörigen Tags werden als **Tagsets** (z. B. TEI-Tagset) bezeichnet, der Vorgang des Annotierens mit Tags wird auch **tagging** (dt. taggen) genannt, insbesondere in der Linguistik (z. B. Part-of-Speech-Tagging; s. u.).

Digitale Repräsentationen eines Textes, eines kulturellen Artefakts, Vorgangs oder Objekts sind für den Computer Abfolgen von Bits, eine Matrix von Bildpunkten oder eine lineare Sequenz von Einzelzeichen (s. Kap. 5). Zwar kann auch auf diesen Daten eine Reihe von Recherchen oder Auswertungen gemacht werden, dennoch

sind die Möglichkeiten der präzisen und tiefen Auswertung solcher Daten derzeit noch limitiert. Das Einbringen von Annotationen, das **Kodieren** von Daten – man spricht auch von ›Anreicherung‹ – hilft dagegen der Software, bestimmte gezielte, zum Teil sehr avancierte Aktionen auszuführen. Die gesamte Bandbreite von der Präsentation über Sortierung, Auswertung und Auszählung bis zur Manipulation wird über Annotationen gesteuert. Ein weiterer Vorteil besteht darin, dass sie als ›Paratexte‹ oder ›Metadaten‹ ganz unterschiedliche maschinelle Analysen auf demselben Text bzw. Digitalisat erlauben, ohne in das Digitalisat selbst einzugreifen (Hockey 2000, 33).

Darüber hinaus hilft das Annotieren auch den Forschenden: Das Bilden von Annotationskategorien, das Auffinden entsprechender Phänomene und das Anreichern mit geeigneten Annotationen ist Teil des hermeneutischen Analyseprozesses. Digitales Annotieren führt wie gesehen eine analoge Praxis fort, entwickelt sie jedoch auch konsequent weiter, denn inhärentes und implizites Wissen wird expliziert und (idealerweise) in einer algorithmischen Strenge, Konsequenz und Ausnahmslosigkeit (engl. *rigor*) formalisiert, die aufgrund der maschinellen Weiterverarbeitung erforderlich und die Voraussetzung dafür ist, mit diesen Explizierungen ›rechnen‹ zu können. Durch diese Form der Rechenschaft über das (wissenschaftliche) Verständnis der Quelle bzw. des Forschungsgegenstands wird zugleich eine neue Qualität von Transparenz und Nachvollziehbarkeit erreicht, die den Anforderungen guter wissenschaftlicher Praxis genügt.

Auch als **Abstrahierungen** von (z. B. sprachlichen) Einzelvorkommen sind Annotationen in aller Regel sprachlich verfasst, insofern muss der prinzipiellen Mehrdeutigkeit natürlicher Sprachen durch klare Begriffsbildung und Dokumentation des Abstraktionsverfahrens begegnet werden. Da dem intellektuellen Vorgang der Kategorienbildung, ihrer Formalisierung in Tagsets und ihrer Operationalisierung entscheidende Bedeutung für die effiziente Annotation sowie die damit verbundenen Auswertungsmöglichkeiten zukommt, ist dieser Vorgang essenzieller Bestandteil wissenschaftlicher Forschungsarbeit. Für die Kategorienbildung und die konkrete Anreicherung mit Annotationen – gleich ob manuell oder automatisch – hat sich ein iterativer zyklischer Prozess bewährt (Zinsmeister 2015, 87):

1. Dieser Prozess beginnt mit einer einleitenden **Datenanalyse** (Exploration, s. auch Kap. 7), die einen ersten Eindruck über Frequenz und Verteilung der interessierenden Phänomene gibt. Auch mögliche Fehlerquellen, wie Mehrdeutigkeiten oder Varianzen, werden ermittelt.
2. Es folgt eine erste Definition der **Annotationskategorien** und die Formulierung von Annotationsrichtlinien. Alle weiteren Präsentations- und Analyseschritte werden entscheidend dadurch beeinflusst, welcher Grad an Abstraktion gewählt wird – oder andersherum, wie spezifisch auf den Forschungsgegenstand und die Forschungsfrage das Tagset ausgerichtet ist. Auch die Granularität der Annotationen – d. h. die adäquate Beschreibungstiefe der Phänomene – hat Einfluss auf Analysemöglichkeiten. Die Granularität hängt darüber hinaus von pragmatischen Rahmenbedingungen ab, etwa von den vorhandenen Ressourcen und der entsprechenden Umsetzbarkeit mit vertretbarem Aufwand. Das ausgewogene Ausarbeiten solcher oft widerstreitender Bedingungen gehört zu den zentralen Aufgaben an der Schnittstelle zwischen **geisteswissenschaftlicher Forschungsfrage** und **informatischen Möglichkeiten**. Weitere Voraussetzung für den praktischen Vorgang des Annotierens einerseits und die spätere Beurteilung der Ergebnisse und die Nachnutzung der Daten andererseits ist die Formulierung von Richtlinien

(*Guidelines*), die genau dokumentieren und festlegen, was und wie zu annotieren ist.

3. Im dritten Schritt erfolgt das eigentliche **Annotieren** unter Berücksichtigung der Richtlinien. Eine wichtige Voraussetzung für die Gewährleistung einer zuverlässigen Annotationsqualität ist ein *Intra-* bzw. *Interannotator Agreement*. Da zum einen jeder Annotierende im Lauf der Zeit – tagesformabhängig oder mit steigender Annotierungserfahrung und verbesserter Quellenkenntnis – ein gewisses Maß an Subjektivität und Entwicklung mitbringt, zum anderen häufig mehrere Personen zumeist auch über einen längeren Zeitraum an einem Datenbestand annotieren, stellt das Agreement sicher, dass Annotationen ein Höchstmaß an **Einheitlichkeit** und **Vergleichbarkeit** aufweisen. Um das zu erzielen, annotieren mehrere Personen (gegebenenfalls auch nur eine Person) parallel und unter Umständen wiederholt denselben Datenbestand.
4. Nach einer **Evaluierung** von Übereinstimmungen und Qualität müssen die Richtlinien gegebenenfalls überarbeitet werden. Der Übereinstimmungsgrad bzw. Abweichungen werden ermittelt und geprüft, die Anweisungen und das Verfahren gegebenenfalls (iterativ) optimiert.
5. Das Annotieren erfolgt erneut bzw. es wird korrigiert. Die Schritte 3 bis 5 können wiederholt werden bis zum gewünschten Ergebnis. Dies ist ein geeignetes Verfahren, um Annotierungsanweisungen und Dokumentationen auf Einheitlichkeit, Transparenz und Stimmigkeit zu überprüfen.

Auch Annotierungen von Annotationen als Qualitätskontrolle und Dokumentation sind denkbar. In der Praxis ist die Zahl und Intensität der Iterationen eine Ressourcenfrage und eine Abwägung von Aufwand und Ergebnis. Ferner muss immer mit einer gewissen Menge an Fehlern gerechnet werden, denn die hundertprozentig perfekt annotierte Datei kann es nicht geben. Wichtig ist daher, den Auswertenden die Möglichkeit zu geben, Vorgehen und Entscheidungen der Annotierenden bewerten zu können, damit sie eine Grundlage haben, um zu entscheiden, ob Digitalisat und Annotat für die Verwendung in bestimmten Forschungskontexten geeignet sind.

18.3 | Annotationstypen und -funktionen

Entlang der beschriebenen Funktionen im Rahmen des Forschungsprozesses lassen sich auch verschiedene Typen von Annotationen identifizieren: Sie können die individuelle Textarbeit für den Einzelforschenden festhalten bzw. systematisieren, aber auch in den öffentlichen Diskurs gegeben werden, als Abstrahierungen ermöglichen sie automatische Auswertungen und Analysen, und sie können digitale Dokumente und Inhalte miteinander verknüpfen und auf diese Weise intertextuelle Bezüge sichtbar machen und Dokumente neu kontextualisieren, und schließlich sind sie Ergebnisse wissenschaftlichen Arbeitens im Sinne von **Mikro-** oder **Nanopublikationen** (s. Kap. 13.5). In der Konsequenz bedeutet dies, dass an Annotationen dieselben Anforderungen an Referenzierbarkeit, Zitierfähigkeit und Nachhaltigkeit gestellt werden müssen wie an die Quellen, die durch sie erschlossen werden. Sie bilden damit eigentlich **einen eigenen Textsortentyp** aus. Prinzipiell sind Annotationen in allen Formaten und in freier Form denkbar, sie entfalten jedoch ihr eigentliches Potenzial durch ein gemeinsames Format, durch Interoperabilität und Offenheit. Ein wichtiges Annotationsformat ist XML, das ausführlich in Kapitel 9 vorgestellt wurde. Nicht nur

das Format, sondern auch die Inhalte, die Grammatik und die Semantik der Metasprache müssen ausgehandelt und eine Ausgewogenheit zwischen Flexibilität und Normierung erreichen.

Schnittstellen und Protokolle

Professionelle Metadaten- und damit auch Annotationsanbieter sind die erschließenden Gedächtnisinstitutionen, die **Bibliothekskataloge** bzw. **Museumsverzeichnisse** und **archivische Findmittel** unter Berücksichtigung strenger Qualitäts- und Formatstandards erzeugen (s. Kap. 15) – das gilt für die analogen Artefakte wie für ihre Digitalisate (s. Kap. 12) bzw. für digitale Sammlungen. Allerdings gibt es in diesen Institutionen unterschiedliche Standards – was sich z. T. mit ihren unterschiedlichen, gewachsenen Strukturen und ihrem unterschiedlichen Bildungsauftrag begründen lässt – sowie auch internationale Unterschiede. Eine Lösung für eine übergreifende Auswertung solcher Daten sind sogenannte offene Schnittstellen und Protokolle, wie etwa OAI-PMH (Open Archives Initiatives – Protocol for Metadata Harvesting), die die Maschine-Maschine-Kommunikation und die Synchronisation großer Datenbestände erlauben.

Technische Annotationen: Einige ihrer Funktionen sind generisch, einige fachspezifisch bzw. an einer bestimmten Fragestellung ausgerichtet. **Generisch**, d. h. für praktisch alle weiteren Schritte und Arbeitszusammenhänge grundlegend, sind Annotationen, die technische Angaben zum Digitalisat enthalten, sowie Annotationen, die das Dokument z. B. durch die Vergabe von persistenten Identifikatoren (PID) dauerhaft referenzierbar und zitierbar machen. Auch Angaben zu den Bearbeitern, Zeitstempel, Versionsierungsangaben und nicht zuletzt Lizenzbedingungen, also Angaben zu den Bedingungen für eine Weiternutzung der Digitalisate und gegebenenfalls der Annotationen gehören zu diesem Typ. In diesem Zusammenhang spricht man dann häufig auch eher von »Metadaten« als von »Annotationen« (zu diesen generischen Metadaten s. auch Kap. 7.1).

Sie bilden eine Annotationsebene, die vor allem die Verortung und Verwaltung, also die Logistik des Digitalisats organisiert. So unscheinbar und »trocken« das im ersten Augenblick klingt, so essenziell ist dennoch diese Schicht und ihre Funktion: Ohne solche Metadaten fehlen die im wissenschaftlichen Prozess unabdingbaren Informationen, die Ergebnisse **zitierfähig**, **transparent**, **überprüfbar** und gegebenenfalls **wiederholbar** machen und die zur wissenschaftlichen Qualitätssicherung dazugehören. Diese generischen Basis-Annotationen sollten also qualitativ hochwertig und gesichert sein. Bei sehr großen Datenmengen besteht zwar auch die Möglichkeit, das »Rauschen« oder den »Schmutz« (*noise*) fehlerhafter oder fehlender Metadaten mit statistischen Verfahren »herauszurechnen« – dennoch sind die Fragestellungen dann in gewisser Weise »begrenzt«.

Semantische und fachspezifische Annotationen: Die Übergänge zu **semantischen**, also inhaltlichen und (aus)wertenden Annotationen sind gewiss fließend. Diese weisen die größte Flexibilität und das breiteste Spektrum auf – sie sind so vielfältig wie die Forschungsfragen, die sie repräsentieren. Formate und Standards wie XML und TEI bieten als Metasprachen den Vorteil, dass sie wie natürliche Sprachen mit einem begrenzten Inventar und grammatischen Regeln quasi eine unendliche Anzahl von Dingen formulieren und formalisieren können.

Fachspezifisch sind beispielsweise linguistische Annotationen – wobei auch in diesem eingegrenzten Bereich das Spektrum je nach Forschungsinteresse oder zu-

grunde gelegtem linguistischen Modell sehr breit ist. Eine linguistische Basisannotation würde etwa die Einteilung in Sätze, die Segmentierung in Wörter und eine Wortartenbestimmung umfassen (*Part of Speech* = POS), in der Linguistik wird dafür meist der Terminus **POS-Tagging** verwendet. Dieser Bereich ist sehr gut erforscht, und die Automatisierung ist vor allem für große, moderne Standardsprachen und verbreitete Genres wie Zeitungskorpora sehr weit fortgeschritten, dennoch bleibt hier für historische oder variante Spracherzeugnisse oder bestimmte literarische Genres noch viel zu tun.

Weitere Annotationen bzw. »Metadaten« zu den Texten erlauben dann erst eine angemessene Bewertung der beobachteten Phänomene (Perkuhn/Keibel/Kupietz 2012) – dazu zählen sowohl Angaben aus dem genannten generischen Spektrum, wie Provenienz- und Datumsangaben, aber auch weitere semantische Kategorien, wie Einordnungen in Genres und anderes mehr. Zur weiteren »Bereinigung« der Daten kann die Erkennung von Zahlen, Symbolen, Eigennamen oder weiterem »Rauschen« hinzukommen, was die Auswertungsergebnisse präziser macht. Mit auf diese Weise aufbereiteten Daten lassen sich beispielsweise Auswertungen zu linguistischen Phänomenen wie Satzlängen, Worthäufigkeiten, Kollokationen, grammatischer Varianz u. a. m. durchführen.

Sarah/NE schreibt/VVFIN einen/ART wissenschaftlichen/ADJA Artikel/NN ./\$.

Abb. 53 Beispielsatz mit POS-Tagging nach dem Stuttgart-Tübingen-Tagset

Solche linguistischen Basisannotationen können jedoch auch in weitere Forschungsszenarien eingebunden werden, für viele weitere Analysen, die auf Auswertungen von sprachlichen Phänomenen und Text basieren, sind sie sogar unabdingbare Voraussetzungen. Beispiele aus der Literaturwissenschaft sind etwa stilometrische oder narratologische Fragestellungen, über die Kapitel 20.2 in diesem Band ausführlich informiert.

Unterschiedliche **Layer** von Annotationen können also an verschiedenen Stellen im Forschungsprozess unterschiedliche Funktionen übernehmen: In einem Fall sind sie eines der wissenschaftlichen Ergebnisse, auf das in einem anderen Fall aufgebaut wird, um die eigenen Fragestellungen differenzierter und effizienter bearbeiten zu können. Annotationen werden auf diese Weise multi-funktional und überqueren Fächergrenzen, wie die geschilderten Beispiele zeigen konnten. In diesem Zusammenhang wird nochmals besonders deutlich, dass Annotationen dieses Potenzial nur entfalten können, wenn sie formalen und qualitativen Richtlinien und Standards folgen.

Auch in den den Geistes- und Kulturwissenschaften verwandten Disziplinen, wie den qualitativ arbeitenden Sozialwissenschaften etwa, werden Quellen unterschiedlichster Art annotiert. Hier werden ebenso Kategorien gebildet und Texte und Objekte angereichert, gängige und weit verbreitet Software-Tools zu einer solchen Qualitativen Datenanalyse sind beispielsweise »atlas.ti« und »MaxQDA«. Es gibt jedoch derzeit nur wenig Austausch zwischen den Communities (Ausnahme ist z. B. die Soziolinguistik).

18.4 | Annotationsverfahren

Händische und maschinelle Verfahren: Grundsätzlich lassen sich regelbasierte, in Richtlinien oder Guidelines niedergelegte Verfahren, die von Menschen ausgeführt werden, und modellbasierte, algorithmische, also maschinelle Verfahren unterscheiden (zur weiteren Differenzierung der maschinellen s. u.). In der Praxis werden beide Verfahren häufig kombiniert: Händisch sorgfältig annotierte Daten werden als Goldstandard (s. u.) für die Entwicklung und Evaluierung automatischer Tools genutzt, und automatische Verfahren liefern Bearbeitern Vorschläge, die manuell nur bestätigt oder abgelehnt bzw. korrigiert werden müssen, was den händischen Bearbeitungsprozess wesentlich beschleunigen kann.

Manuelle Verfahren

Im Kontext manueller Annotationszenarien lässt sich ein breites Spektrum an Akteuren, Akteursgruppen und Funktionszusammenhängen sowie ein fließender Übergang von geschlossenen und offenen Nutzerkreisen beobachten: Private, nicht für die Veröffentlichung bestimmte Annotationen beispielsweise können allein dazu dienen, den eigenen Forschungsprozess zu organisieren und zu gestalten, ohne diese spezifischen Daten zu publizieren oder zu teilen. Dies kann für den Einzelforscher gelten wie auch für Forschergruppen, die in einem begrenzten, kontrollierten Kreis ihre Annotationen teilen – sie können jedoch auch für die (ggf. namentlich gezeichnete) Publikation sowie die Nachnutzung durch andere Wissenschaftler gedacht sein.

Crowd Sourcing: Eine weitere Facette bietet ein verteiltes Annotieren, das sogenannte *Crowd Sourcing* (oder auch *User-generated Content*), was genutzt wird, um große Mengen an Daten zu annotieren (Pscheida et.al. 2013). Eine Möglichkeit spielerischer ›Belohnung‹ bieten sogenannte *Serious Games*, die spielerischen Spaß und Erfolge vermitteln (*Gamification*). Auch im kommerziellen Sektor hat das Annotieren eine große Bedeutung: Eine Reihe von Plattformen ermöglicht ein *Crowd Sourcing* digitaler Arbeitskraft, bei dem das Annotieren in ›Kleinstjobs‹ aufgesplittet wird, und bei denen die Annotierenden entlohnt werden (*micropayment*); zu nennen wären etwa »Amazon Mechanical Turk«, »Clickworker« oder »Workhub«. Es sei wenigstens erwähnt, dass Qualitätssicherungs- und ethische Aspekte in diesem Zusammenhang relevant und zumindest in einigen Punkten diskussionswürdig sind, obwohl diese Aspekte an dieser Stelle nicht vertieft werden können.

Automatische Verfahren

Automatische Verfahren zum Erzeugen von Annotationen verwenden Tools, die für diese Aufgabe und häufig für bestimmte Datentypen entwickelt wurden, obwohl es z. B. im Kontext des World Wide Web Consortiums (W3C) auch Ansätze zu generischen Datenmodellen und Tools gibt, z. B. das **Open Annotation Modell** (OAM). Nutzt man vorhandene Tools und Tagsets nach, ist zu prüfen, inwiefern sie für den neuen Datenbestand und die ggf. anders gelagerte Aufgabe geeignet sind. In aller Regel müssen vorhandene Tools an den neuen Datenbestand, ggf. auch eine andere oder modifizierte Forschungsfrage angepasst werden, so dass Aufwand und Ergebnis

von Anpassung bzw. Neuentwicklung gegeneinander abgewogen werden müssen. Generell kann man sagen, dass normierte und standardisierte Daten präziser bearbeitet werden können als Nichtstandard- oder nichtkanonische Daten. Im Bereich von Sprachkorpora betrifft das z. B. Daten in neuhochdeutscher Standardsprache gegenüber historischen Texten mit höherer (grafischer und formaler) Varianz, wie auch Daten gesprochener Sprache oder dialektale Daten.

Annotationstools können auf **Regeln** aufbauen (wie händische Verfahren) oder **statistisch** basiert sein, wobei manche Tools auch beide Ansätze mischen. Da der menschliche Bearbeiter die Regeln formuliert, können regelbasierte Tools nur so gut sein, wie die zugrunde gelegten Regeln. Bieten die Daten Phänomene, die durch das Regelsystem nicht abgedeckt sind, ›versagt‹ das Tool. Aufwendig ist ferner die Anpassung an neue Daten und Fragestellungen, da die Regeln überprüft, adaptiert und ggf. weiterentwickelt werden müssen. Sind die Daten jedoch vergleichsweise einheitlich und die Regeln gut formuliert, hat man ein sehr präzises und effizientes Tool.

Statistische Tools, die auf maschinellem Lernen (*machine learning*) basieren, haben demgegenüber einige Vorteile. Sie lassen sich schneller entwickeln und testen, da sie Regeln und Wahrscheinlichkeiten aus Vorgaben ableiten und auf neue, auch ›unbekannte‹, von den Entwicklern nicht vorhergesehene Phänomene in Daten anwenden, das macht sie also ›robust‹. Hier ist ferner zu unterscheiden zwischen sogenannten überwachten und unüberwachten Verfahren. Für die überwachten Verfahren benötigt man ein sehr gut annotiertes Trainingskorpus als **Goldstandard**, aus dem die Regeln abgeleitet werden müssen – hier ist also auch einiges an vorbereitendem Aufwand zu leisten. Die Qualität des Goldstandards bestimmt den Leistungsumfang und die Präzision des Tools. Bei den unüberwachten Verfahren wird auf ein solches Trainingskorpus verzichtet und aus den zu annotierenden Daten Kategorien errechnet; dieses Verfahren macht daher eine gewisse Korpusgröße erforderlich.

Ein Vorteil automatischer Tools liegt darin, dass sich Fehler oft besser erkennen lassen und dass Fehler häufig systematischer Natur sind, wenn etwa die Regeln unvollständig oder ambig formuliert wurden. Fehler werden damit ›erklärbar‹. Die Präzision eines Tools lässt sich durch Abgleich mit dem Goldstandard, der als absolute Referenzgröße verwendet wird, bestimmen, wofür es standardisierte Verfahren und Maße gibt.

Eine Strategie, die bei automatischen linguistischen Annotation häufig angewendet wird, ist die Verwendung mehrerer Tools, die jeweils auf unterschiedlichen Modellen basieren (z. B. bei der **Disambiguierung**). Man kann beispielsweise dann so vorgehen, dass man die Annotation, die von allen Tools gleichgemacht wurde, für ›richtig‹ annimmt, also einer Art Mehrheitsentscheidung folgt, oder man nimmt die Ergebnisse der Tools als Basis für die manuelle Kontrolle. Letztlich muss dann der Forschende abwägen, entscheiden und dokumentieren, wie er mit den erzielten Ergebnissen umgeht und welche (wissenschaftlichen) Schlüsse aus den Ergebnissen gezogen werden können.

Vergleicht man dieses Vorgehen mit einem rein analogen Verfahren, das häufig einzelstellenbasiert bzw. aus der Verallgemeinerung vergleichsweise weniger Beobachtungen erfolgt, darüber hinaus zumeist nicht die Kategorien an den Daten expliziert, zeigt sich klar der Vorteil dieses auf eine breitere Datenbasis und Explizierung, also auf Nachvollziehbarkeit hin optimierten Verfahrens. Man sollte auch nicht unterschätzen, dass die auf diese Weise erzielten und dokumentierten Forschungsergebnisse auf eine ganz andere Weise in den Forschungskreislauf eingebracht werden können, wenn sie unter offener Lizenz publiziert werden.

Precision und Recall

Annotationsqualität: Um automatische Annotationsergebnisse zu evaluieren, gibt es Standardverfahren. Zur Beurteilung der Qualität von automatischen Annotationen werden häufig die Qualitätsmaße *precision* (Präzision) und *recall* angegeben, die wir schon aus dem **Information Retrieval** kennen (s. Kap. 19.1). *Precision* benennt den Prozentsatz an korrekten Annotationen und ignoriert die fehlerhaft oder nicht getätigten Annotationen. *Recall* dagegen benennt den Prozentsatz an Vorkommen, die in Bezug auf ein Phänomen richtig annotiert wurden, wobei ignoriert wird, ob Vorkommen falsch annotiert wurden, also nicht dem eigentlich Gewollten entsprechen. Gehen wir davon aus, dass es zwei Annotationsmöglichkeiten für ein bestimmtes Phänomen geben kann, <anno1> und <anno2>, und nehmen wir an, <anno1> sei laut Goldstandard korrekt. Für die Berechnung unterscheidet man vier Ergebnistypen: Hat das Tool <anno1> (*positive*) oder <anno2> (*negative*) eingesetzt und stimmt das Ergebnis mit der Goldstandard-Referenz überein (*true*) oder nicht (*false*).

Goldstandard	<anno1>	<anno2>	<anno1>	<anno2>
Annotationsergebnis	<anno1>	<anno2>	<anno2>	<anno1>
Ergebnistyp	<i>true positive</i>	<i>true negative</i>	<i>false positive</i>	<i>false negative</i>

Zufällige Übereinstimmungen werden über weitere statistische Maße herausgerechnet (Zinsmeister 2015, 87).

Alle digital verfügbaren Daten können annotiert werden, die Verfahren und die Erfahrungen, damit verbunden auch der Grad der Standardisierung unterscheiden sich jedoch. Die Verfahren zur Annotation von Textdaten sind am weitesten verbreitet und gut dokumentiert. Aber auch für Notentexte, Bild-, Ton-, 3D- oder Videodaten werden Verfahren entwickelt und Standards diskutiert und etabliert.

18.5 | Objekte

Text

Die Annotation von Text hat – wie die Entwicklung von SGML und XML zeigt (s. Kap. 9) – eine lange Geschichte und ist insbesondere durch die Arbeit der 1987 gegründeten **Text Encoding Initiative** (TEI) sehr avanciert. In diesem Community-getriebenen und -organisierten Konsortium werden Richtlinien zur Kodierung von Text ausgehandelt und propagiert. Die Annotationen der TEI beispielsweise sind so gestaltet, dass sie sowohl maschinenlesbar als auch für den Menschen noch gut lesbar sind. Im Rahmen von Special Interest Groups werden Tagsets neu- oder weiterentwickelt (derzeit z. B. zu *computer mediated communication* oder zu *text and graphics*).

Text encoding initiative: Eine TEI-Datei ist strukturiert in einen *header* sowie einen *body*. Der Header beinhaltet nur Metainformationen über den Text – wie die bibliographische Beschreibung (*fileDesc*), die Richtlinien der Annotation (*encodingDesc*), die Beschreibung weiterer Textmerkmale (*profileDesc*) und die Bearbeitungshistorie (*revisionDesc*), im Body findet sich der Text selbst mit allen weiteren Annotationen und Anhängen.

Die TEI verfolgt zum einen das Prinzip der Trennung von **Inhalt** und **Layout**, zum anderen ergeben sich als inhaltsorientiertes Gliederungskriterium textsortenspezifische

sche bzw. gattungs- und genrespezifische Abstrahierungen, die in entsprechenden Tagsets formuliert sind, indem sie ein Set von XML-Elementen und Attributen deklarieren: Im Ausdruck `<div1 type="chapter">` z. B. erhält das Element *division* ein *type*-Attribut, das klarmacht, dass es sich um die Markierung einer Kapiteleinteilung handelt. Neben generischen, in allen Dokumenten vorkommenden Einheiten wie ›Überschrift, Absatz‹ usw., Tagsets für Zeichenkodierung oder für Entitäten wie Namen, Orte, Daten gibt es spezifische Sets beispielsweise für Linguistische Korpora, für Wörterbücher, Transkription gesprochener Sprache oder Damentexte, Lyrik sowie Handschriften bzw. Faksimiles, textkritische Apparate u. a. m. Diese Klassifizierungen sind dabei durchaus pragmatisch zu sehen; da übergreifende Systematisierungsansätze aufgrund von unterschiedlichen Perspektiven aus Linguistik und Literaturwissenschaft und aufgrund der historischen Dynamik von Gattungen und Textsorten noch am Anfang stehen, ist eine standardisierte Systematik auf rein struktureller Ebene kaum umzusetzen und noch Teil des Aushandlungs- und Forschungsprozesses.

TEI-Header und Tagsets decken also die Bandbreite von technischen, bibliographischen, strukturellen und semantischen Metadaten ab und erlauben den Rückgriff auf Vorhandenes für eine Vielzahl von Anwendungen. Dennoch kann (und darf) auch das umfänglichste Regelwerk nicht alle Forschungsfragestellungen abdecken, so dass in vielen Zusammenhängen neue Annotationskategorien und neue Tagsets empirisch-hermeneutisch wie oben beschrieben anhand der zu bearbeitenden Daten entwickelt werden müssen. Wichtig ist dann die Orientierung an bereits definierten ›Grammatiken‹ und die Dokumentation der Kategorien in formalen Schemata wie *Document Type Definitions* (DTDs) oder *RelaxNG Schema*.

Obwohl die TEI sich vorrangig mit der Annotation von Textdaten befasst, trägt sie auch dem Umstand Rechnung, dass Texte zum einen als Image-Digitalisate verfügbar sind und dass sie zum anderen in der Überlieferung über eine materiale Dimension verfügen, dass also die Texttopographie und das Layout (insbesondere, aber nicht nur bei Autographen und Handschriften) zu den Eigenschaften von Texten gehören, die in bestimmten Forschungszusammenhängen annotiert werden. Die Elemente `<figure>`, `<graphic>` und `<figDesc>` erlauben es beispielsweise, graphische Phänomene oder Bilder in Texten zu lokalisieren und zu beschreiben, dabei kommt dem Text jedoch immer das Primat zu. Eine eigenständige Repräsentation bildlicher (oder anderer) Informationen jenseits sprachlich verfasster Textualität ist demnach nicht beabsichtigt, obwohl die Special Interest Group *Text and Graphics* die graphischen Komponenten in Texten systematisch behandelt. Eine Erweiterung der

```
<text>
  <front>
    <head>1755</head>
  </front>
  <body>
    <l>To make a prairie it takes a clover and one bee,</l>
    <l>One clover, and a bee,</l>
    <l>And revery.</l>
    <l>The revery alone will do,</l>
    <l>If bees are few.</l>
  </body>
</text>
```

Abb. 54 Einfaches Beispiel für die Strukturierung eines Verstextes: <http://www.tei-c.org/release/doc/tei-p5-doc/en/html/VE.html> (1.9.2016)

TEI in Richtung mehr graphisch orientierter Genres wie Comics oder Graphic Novels adressieren Initiativen wie die *Comic Book Markup Language*.

Annotation von Textimages: An der Schnittstelle von Textannotation und Bildannotation steht die Annotation von Textdaten, die als Image digitalisiert worden sind (s. Kap. 12.2). Hier wären z. T. dieselben textstrukturellen Elemente zu annotieren, allerdings ist die dahinterliegende Technologie eine andere, da nicht auf *characters* zurückgegriffen werden kann, sondern auf **Pixelpunkte** und **Koordinaten**. Ferner ist die Recherchierbarkeit eine andere: Es kann nur in den Annotationen recherchiert werden, nicht in Kombination mit den Textinhalten. Da jedoch eine sehr große Masse an Textdaten auf diese Art und Weise digitalisiert worden ist, ferner z. B. historische Schriften und Handschriften oft mit derzeit vorhandenen OCR-Systemen (noch) nicht in überzeugender Qualität erkannt werden können, ist die Annotation von Text im Image ein wichtiger Aspekt, da sie als eine strukturierte Form der Erschließung von Quellen dient, an die wiederum Suchalgorithmen, Auswertungs- und Visualisierungsverfahren, z. B. aus dem Bereich des ›distant reading‹ anknüpfen können. Nicht zuletzt gibt es Anwendungen und Forschungsinteressen, die sich auf die Annotation des ›Originals‹ beziehen, z. B. im Bereich der genetischen Editionen oder der Materialitätsforschung.

Digitale Editionen stellen häufig Transkription oder edierten Text und das Originalfaksimile nebeneinander, so dass Verknüpfungen von Text und Bild wichtig sind. Im TEI-Instrumentarium wird für die Repräsentation des Imagedigitalisats das Element `<facsimile>` verwendet, im `<surface>`-Element werden die Koordinaten der Grafik abgelegt:

```
<facsimile>
  <surface ulx="0" uly="0" lrx="200" lry="300">
    <graphic url="example.png"/>
  </surface>
</facsimile>
```

Abb. 55 TEI-Markup für die Verknüpfung von Text und Bild

Werkzeuge wie **TextGrids** Text-Bild-Link-Editor ermöglichen das Verknüpfen beliebiger Segmente von Bildausschnitten mit strukturiertem Text in TEI-konformer Notation, wobei die auf diese Weise entstandenen Verknüpfungen (Links) als eigenständige Objekte behandelt und gespeichert werden können. Ausführliche Informationen zu diesem und weiteren TextGrid-Werkzeugen gibt das Online-Manual: <https://textgrid.de/dokumentation-und-manuals> (1.9.2016).

Bild

Bildannotation: Anders sieht es aus, wenn man Annotation als Teil bildwissenschaftlicher Forschungen betrachtet. Zumeist sind die Annotationen zu Bildern (oder zu bildender Kunst) – wie im Übrigen auch zu den meisten anderen Objekttypen – textuell verfasst und damit mit denselben Verfahren recherchierbar und auswertbar wie Annotationen zu Texten. Bei kunsthistorischen Anwendungen werden mit digitalen Werkzeugen polygone Markierungen auf dem digitalen Image angebracht, die über **Pixelkoordinaten** abgelegt und als XML gespeichert werden können, was auch TEI-konform möglich ist. Ein gängiger XML-Standard für die Beschreibung zweidimensionaler Vektorgrafiken (s. Kap. 9.4) ist das SVG-Format (*Scalable Vector Graphics*). Für die inhaltliche Erschließung stehen Vokabulare und Ontologien wie Icon-

class, die Getty Vocabularies oder das CIDOC Conceptual Reference Model zur Verfügung (s. Kap. 11.6).

Andere Werkzeuge, wie das auch als Webtool einsetzbare Werkzeug »Digilib«, verknüpfen solche markierten Bildbereiche direkt, also ohne den Umweg über eine textuelle Bildbeschreibung oder Verschlagwortung und liefern die Markierungen als URL, so dass präzise markierte Bilddetails mit anderen Bilddetails, Bildsammlungen und Texten hypertextuell verknüpft werden können (Casties/Wintergrün 2015). Ein ähnliches Konzept verfolgt auch die mächtige Forschungsumgebung **HyperImage**, die in Lüneburg gemeinsam mit weiteren Partnern entwickelt wird. Auch hier werden Anmerkungen bzw. bildhafte Fußnoten direkt an Bilder oder Bildausschnitte geheftet und »hypertextuelle« Verknüpfungen zwischen mehreren Bildern ermöglicht. Dabei wird mit gestischen Mitteln wie Zeigern oder Pfeilen gearbeitet ebenso wie mit sprachlichen bild-topographischen Angaben, wie Vordergrund/Hintergrund, oben/unten usw. (Kuper/Loebel 2014).

Automatische Bilderkennung: Da in den letzten Jahren vor allem **Bilddigitalisate** massenhaft zur Verfügung stehen, entwickeln sich hier die Verfahren zur Annotierung und weiteren Verarbeitung rasch weiter. Aber auch die automatische Erkennung und das Tagging von Bildsegmenten werden auf unterschiedlichsten Ebenen vorangetrieben. Ein Projekt in Heidelberg erschließt wiederkehrende Motive (Muster) in mittelalterlicher Buchmalerei, ausgehend von illustrierten Handschriften des *Sachsenspiegels*, der sich dafür besonders gut eignet, da die Illustrationen als bildlicher Kommentar von Gesetzestexten einen hohen Grad an Normierung aufweisen. So können bestimmte relevante Motive wie Kronen oder Schwurgesten aufgespürt werden (Takami/Bell/Ommer 2014). Andere Forschungen bemühen sich um die automatische Erkennung von Layoutstrukturen in mittelalterlichen Handschriften und deren Vermessung, um diese Messwerte TEI-konform im Digitalisat zu annotieren (Embach et al. 2013). Automatische Bilderkennungsverfahren, die eine textuelle Beschreibung erzeugen, beschreiben Karpathy/Li 2015. Die Interessen und Anwendungen außerhalb der engeren Wissenschaft sind riesig, die Bild- und Mustererkennung ist daher ein lebhafter Forschungs- und Entwicklungszweig.

Audio und Video

Bei der Annotation von gesprochener Sprache und von Videodaten kommt als wesentliche Erweiterung die zeitliche Dimension hinzu. Gesprochene Sprache wird in aller Regel transkribiert, also verschriftlicht, und kann dann wie geschriebener Text annotiert werden, wobei suprasegmentale Merkmale (Pausen, Räuspern, Intonation, Prosodie usw.) hinzukommen. Ein Übergangsbereich zwischen Mündlichkeit und Schriftlichkeit ist die computervermittelte Kommunikation (z. B. SMS, Chat), für die an verschiedenen Stellen Korpora aufgebaut und auch im Kontext der TEI Annotationsstandards entwickelt werden.

- Das führende Korpustool für gesprochene Sprache ist **EXMARaLDA** (EXtensible MARKup Language for Discourse Annotation), das sowohl einen Partitur-Editor für die manuelle Annotation von Audio- und Video-Daten als auch ein Such- und Analysewerkzeug anbietet (Schmidt/Wörner 2014).
- Mit **MusicXML** steht ein Dateiformat zur Kodierung von Musiknoten zur Verfügung, das die Kodierung, den Austausch und den Satz von Musik ermöglicht. Nach dem Vorbild der TEI definiert die **Music Encoding Initiative** (MEI) Richtli-

nien für die Repräsentation musikalischer Dokumente und Strukturen und ist insbesondere für die wissenschaftliche Erfassung und Edition musikalischer Werke im Einsatz.

Annotation von Bewegungsbildern: Das Bewegungsbild mit seiner zeitlichen Dimension baut sich aus einer Abfolge von Einzelbildern, sogenannten Frames, auf. Das bedeutet, dass sowohl die einzelnen Frames in der üblichen Weise annotiert werden, als auch frameübergreifend Abschnitte eines Videos annotiert und miteinander und mit externen Quellen verlinkt werden können. Das Innovationspotenzial liegt u. a. darin, dass ohne Umweg über textuelle Annotationen unmittelbar mit dem audiovisuellen Material selbst gearbeitet werden kann. Werden Werte wie Helligkeit oder Sättigung einzelner Frames oder Schnitte und Schnittfolgen analysiert und annotiert, können Durchschnittswerte für das gesamte Video berechnet und als Metadaten bereitgestellt oder in Form einer Timeline visualisiert werden. Automatisierte Analysen, Annotierungen und Visualisierungen von Videomaterial sind derzeit in der Entwicklung und werden die Auseinandersetzung mit Bewegungsbildern und der ihnen eigenen Sprache auch in den Digital Humanities unterstützen.

Annotation und Annotationsverfahren sind zentrale Bereiche der Digital Humanities in allen Facetten, denn sie bilden die Schnittstelle zwischen Mensch und Maschine und organisieren effizient und transparent die Wissensgenerierung und -tradierung.

Literatur

- DFG: »Handreichungen: Empfehlungen zu datentechnischen Standards und Tools bei der Erhebung von Sprachkorpora« (2013), http://www.dfg.de/download/pdf/foerderung/grundlagen_dfg_foerderung/informationen_fachwissenschaften/geisteswissenschaften/standards_sprachkorpora.pdf (31.10.2016).
- DFG: »Förderkriterien für wissenschaftliche Editionen in der Literaturwissenschaft« (2015), http://www.dfg.de/download/pdf/foerderung/grundlagen_dfg_foerderung/informationen_fachwissenschaften/geisteswissenschaften/foerderkriterien_editionen_literaturwissenschaft.pdf (31.10.2016).
- Duden. *Satzanweisungen und Korrekturvorschriften. Mit ausführlicher Beispielsammlung*. Hg. von der Dudenredaktion und der Dudensetzerei. Band 5. Mannheim/Zürich 1969.
- Duden *Rechtschreibung*. Mannheim ²⁵2009, auch separat erhältlich: »Duden – Korrekturzeichen: 6 Originalseiten aus dem Rechtschreibduden (²⁵2009) in Adobes PDF-Format mit den amtlichen Korrekturzeichen nach DIN 16 511 und weiteren Empfehlungen der Dudenredaktion« (2014), <http://www.duden.de/Shop/Duden-Korrekturzeichen> (31.10.2016).
- Embach, Michael/Krause, Celia/Moulin, Claudine/Rapp, Andrea/Rindone, Francesca/Tonne, Danah/Vanscheidt, Philipp: »eCodicology – Algorithms for the automatic tagging of medieval manuscripts«. In: Fabio Ciotti/Arianna Ciula (Hg.): *The Linked TEI: Text Encoding in the Web. TEI Conference and Members Meeting 2013. Book of Abstracts*. Rom 2013, 172–178.
- Hockey, Susan: *Electronic Text in the Humanities. Principles and Practice*. Oxford 2000.
- Iglesia, Martin de la/Moretto, Nicolas/Brodhun, Maximilian: »Metadaten, LOD und der Mehrwert standardisierter und vernetzter Daten«. In: Heike Neuroth/Andrea Rapp/Sibylle Söring (Hg.): *TextGrid: Von der Community – für die Community. Eine Virtuelle Forschungsumgebung für die Geisteswissenschaften*. Göttingen 2015, 91–102. DOI: <http://dx.doi.org/10.3249/webdoc-3947> (31.10.2016).
- Kuper, Heinz-Günther/Loebel, Jens-Martin: »HyperImage: Of layers, labels and links«. In: *Proceedings of RENEW – the 5th edition of the International Conference on the Histories of Media Art, Science and Technology*. Riga 2014.
- McGann, Jerome: »Marking texts of many dimensions«. In: Susan Schreibman/Ray Siemens/John Unsworth (Hg.): *A Companion to Digital Humanities*. Oxford 2004. Online: <http://www.digitalhumanities.org/companion/> (31.10.2016).

- Müller-Birn, Claudia et al.: *neonion – combining human and machine intelligence. To appear CSCW'15: Proceedings of the ACM 2015 conference on Computer Supported Cooperative Work Companion* (2015).
- Perkuhn, Rainer/Keibel, Holger/Kupietz, Marc: *Korpuslinguistik*. Paderborn 2012.
- Pscheida, Daniela/Albrecht, Steffen/Herbst, Sabrina/Minet, Claudia/Köhler/Thomas: »Nutzung von Social Media und onlinebasierten Anwendungen in der Wissenschaft. Erste Ergebnisse des Science 2.0-Survey 2013 des Leibniz-Forschungsverbunds »Science2.0« (2013), http://www.qucosa.de/fileadmin/data/qucosa/documents/13296/Science20_Datenreport_2013_PDF_A.pdf (31.10.2016).
- Renear, Allen H.: »Text encoding«. In: Susan Schreibman/Ray Siemens/John Unsworth (Hg.): *A Companion to Digital Humanities*. Oxford 2004. Online: <http://www.digitalhumanities.org/companion/> (31.10.2016).
- Sauermann, Henry/Franzoni, Chiara: »Crowd science user contribution patterns and their implications«. In: *Proceedings of the National Academy of Science of the United States of America* 112/3 (2015), www.pnas.org/content/early/2015/01/02/1408907112 (31.10.2016).
- Schmidt, Thomas/Wörner, Kai: »EXMARaLDA«. In: Ulrike Gut/Jacques Durand/Gjert Kristoffersen (Hg.): *Handbook on Corpus Phonology*. Oxford 2014, 402–419.
- Takami, Masato/Bell, Peter/Ommer, Björn: »An approach to large scale interactive retrieval of cultural heritage«. In: *Eurographics Workshop On Graphics And Cultural Heritage, The Eurographics Association* (2014).
- Unsworth, John: »Scholarly primitives: What methods do humanities researchers have in common, and how might our tools reflect this«. In: *Humanities Computing: Formal Methods, Experimental Practice Symposium, King's College, London* (2000).
- Zinsmeister, Heike: *Chancen und Grenzen von automatischer Annotation. Themenheft zu Automatisierte Textanalyse für Sozial- und Kulturwissenschaften. Zeitschrift für Germanistische Linguistik* 43/1 (2015), 84–110.

Internetquellen

Bürger schaffen Wissen. Die Citizen Science Plattform: <http://www.buergerschaffenwissen.de/>.
 Forschungsumgebung HyperImage: <http://www.hyperimage.eu>.

Spezifikationen von Metadaten- und Annotationsstandards (Auswahl):

CEI: Charters Encoding Initiative <http://www.cei.lmu.de/>.
 CIDOC CRM: Comité International pour la Documentation – Conceptual Reference Model <http://www.cidoc-crm.org/>.
 Comic Book Markup Language <http://dcl.slis.indiana.edu/cbml/>.
 DC: Dublin Core <http://dublincore.org/specifications/>.
 EAD: Encoded Archival Description <http://www.loc.gov/ead/>.
 Getty Vocabularies <http://www.getty.edu/research/tools/vocabularies/>.
 Iconclass <http://www.iconclass.nl/>.
 MEI: Music Encoding Initiative <http://music-encoding.org/>.
 MusicXML: <http://www.musicxml.com/>.
 METS: Metadata and Encoding Transmission Standard <http://www.loc.gov/standards/mets/>.
 MODS: Metadata Object Description Schema <http://www.loc.gov/standards/mods/>.
 Open Annotation Collaboration: <http://www.openannotation.org/>.
 TEI: Text Encoding Initiative <http://www.tei-c.org>.

Andrea Rapp

19 Information Retrieval

Liegen Daten digital vor, ist noch nicht sichergestellt, dass innerhalb dieser Daten auch relevante Informationen gefunden werden. Je größer die Datenmenge, desto größer ist die Herausforderung, etwas Gesuchtes darin auch zu finden. Jede Form der Wiedergewinnung von gespeicherten Daten mit der Möglichkeit, auch unscharf gestellte Fragen zu bestimmten Themen aufgrund eines Datenbestandes beantworten zu können, wird Information Retrieval (IR) genannt.

Was ist Information Retrieval?

Ziel des Information Retrieval ist es, relevante Informationen in Datenquellen zu finden und nicht-relevante Informationen zu erkennen und auszuschließen. Die bekannteste Anwendung dafür sind Suchmaschinen für das Web, aber auch für das Auffinden von Objekten in geisteswissenschaftlichen Korpora spielt diese Informationsgewinnung eine entscheidende Rolle.

Im Gegensatz zum Data Mining, bei dem es um das Auffinden verborgener Zusammenhänge oder Strukturen geht, soll das Information Retrieval sicherstellen, dass bestehende Informationen in Form von Texten, Bildern, Audiodateien, Videos oder anderen Dokumenten gefunden werden können. Dies basiert entweder auf den Metadaten oder dem beispielsweise durch einen Index vollständig erschlossenen Inhalt. Die Problematik liegt dabei zum einen in der Unsicherheit des Retrieval Systems gegenüber der Suchanfrage. So beinhaltet eine Datenbank möglicherweise nicht ausreichend Informationen über die Inhalte und kann somit keine oder nur fehlerhafte Ergebnisse liefern. Beispielsweise müssen vor allem Bilder, Videos etc. erst über Verschlagwortung (Tagging) erschlossen werden, um ihre Inhalte findbar zu machen. Zum anderen ist es dem Benutzer nicht immer möglich, seine Suchanfrage ausreichend präzise zu formulieren. So findet man in einer Internetsuchmaschine nur dann die gewünschten Webseiten, wenn man die richtige Kombination an Schlagworten eingibt.

Ein Teil des Problems liegt darin, dass an einem solchen System zwei verschiedene Personengruppen beteiligt sind. Auf der einen Seite diejenigen, die die Informationen erzeugen und bereitstellen. Auf der anderen Seite diejenigen, die auf der Suche nach bestimmten Informationen sind und daher dieses System nutzen. Zu dieser Anfrage muss der Informationsbedarf auf eine bestimmte Weise dargestellt werden. Dies ist abhängig von dem Modell der Interaktion mit dem System bzw. dem Modell der Repräsentation der Objekte.

Im Folgenden wird zunächst dargestellt, wie die Ergebnisse eines Information-Retrieval-Systems bewertet werden können. Anschließend wird deutlich gemacht, wie Dokumente mithilfe von Indexierung erfasst werden und wie diese Indizes durchsucht werden können. Dabei spielt zunächst die Stringsuche eine Rolle, aber auch die Definition von Teilmengen mithilfe der **Booleschen Suche**, Möglichkeiten der Gewichtung und des Rankings sowie die Ähnlichkeitssuche über den Vektorraum. Schließlich wird gezeigt, wie die besondere Struktur von Hypertexten zum Information Retrieval herangezogen werden kann.

19.1 | Messwerte für IR-Systeme

Aus Sicht des Benutzers ist ein IR-System dann besonders hilfreich, wenn es die Informationsüberflutung (*Information Overload*) begrenzt und gezielt eine Auswahl an relevanten Dokumenten zur Suchanfrage präsentiert. ›Relevant‹ bezeichnet dabei ein Verhältnis zwischen dem Informationsbedürfnis des Nutzers und den ausgegebenen Dokumenten. Auf der einen Seite kann die Relevanz je nach angelegten Kriterien objektiv bewertet werden (**objektive Relevanz**), auf der anderen Seite wird die Nützlichkeit eines ausgegebenen Dokuments vom Benutzer jedoch als subjektiv empfunden (**subjektive Relevanz**). Schließlich bezieht sich die Relevanz auf die effektive Nützlichkeit des jeweiligen Dokuments für die Aufgabe, aus der das Informationsbedürfnis ursprünglich entstand (**situative Relevanz**).

In der Praxis ist es zudem nicht immer möglich, nur den Teil der Dokumente vom System zurückzugeben, der relevant entsprechend der Suchanfrage ist. Tatsächlich kann die ausgegebene Trefferliste auch falsche, also nicht relevante Ergebnisse enthalten (**False Positives**). Und meist wird auch nur eine Teilmenge aller relevanten Dokumente als relevant erkannt (**True Positives**). Die relevanten Dokumente, die nicht erkannt und damit nicht angezeigt werden, werden als **False Negatives** bezeichnet. Und schließlich gibt es noch einen Rest, der weder relevant noch Teil der Ergebnisliste ist und als **True Negatives** bezeichnet wird.

	Relevante Objekte	Nicht relevante Objekte
Gefundene Ergebnisse	True Positives	False Negatives
Nicht gefundene Ergebnisse	False Negatives	True Negatives

Um Retrieval Systeme zu vergleichen und zu optimieren, werden zwei Maßeinheiten an die Ergebnisse angelegt. Zum einen wird das Maß der Fähigkeit eines Systems, alle relevanten Dokumente auszugeben (Ausbeute), **Recall** genannt. Dabei werden die True Positives (die angezeigten relevanten Ergebnisse) in ein Verhältnis zu allen tatsächlich relevanten Treffern (auch jenen, die nicht gefunden werden, dies ist also ein theoretischer Wert) gesetzt:

$$\text{Recall} = \frac{\text{gefundene relevante Dokumente}}{\text{alle relevanten Dokumente}}$$

Dieser Recall-Wert, der zwischen 0 und 1 liegt, gibt also an, wie viele der relevanten Objekte tatsächlich in der Liste erscheinen (Trefferquote). Je mehr das ausgegebene Ergebnis sich der theoretischen Menge an relevanten Dokumenten nähert, desto höher ist dieser Wert. Oder anders ausgedrückt: Wenn ein System wenige Ergebnisse der tatsächlichen Menge an relevanten Dokumenten zurückliefert, ist der Recall-Wert niedrig. Werden alle relevanten Dokumente zurückgeliefert, ist Recall = 1.

Zum anderen kann es sein, dass viele, vielleicht alle relevanten Ergebnisse angezeigt werden, darunter aber auch nicht relevante Dokumente (Ballast). Das Maß dafür lautet **Precision**. Dabei werden die gefundenen relevanten Dokumente (True Positives) in ein Verhältnis zu allen Dokumenten (relevant oder auch nicht relevant) gesetzt:

$$\text{Precision} = \frac{\text{gefundene relevante Dokumente}}{\text{alle gefundenen Dokumente}}$$

Der Precision-Wert, der ebenfalls zwischen 0 und 1 liegt, gibt also an, wie viele relevante Ergebnisse in der Trefferliste erscheinen (Genauigkeit). Je mehr relevante Treffer darin enthalten sind, desto höher ist der Wert. Werden also nur relevante Dokumente gefunden, ist Precision = 1, werden mehr Dokumente gefunden, ist also der Ballast höher, sinkt der Quotient.

Die Leistung jedes IR-Systems kann auf diese Weise gemessen werden. Allerdings stehen beide Werte in einem Abhängigkeitsverhältnis zueinander: Eine Suche, die alle Dokumente ausgibt (und damit auch alle relevanten, aber auch viele irrelevanten), hat einen hohen Recall bei niedriger Precision. Ein Suchergebnis, das aus einem einzigen, aber richtigen Dokument besteht, hat eine hohe Precision, aber einen niedrigen Recall.

Aus beiden Werten wird häufig ein gewichtetes harmonisches Mittel, der **F-Score**, errechnet, um einen einzelnen Wert zu erzeugen, der Ergebnisse eines Information Retrieval Systems bewertet.

$$F = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Diese Werte bieten jedoch nur näherungsweise ein Vergleichsmaß an, da nur selten bekannt ist, wie viele relevante Objekte tatsächlich in der Datenbank vorhanden sind, mit denen die gelieferten Ergebnisse verglichen werden.

Um für den Nutzer optimale Ergebnisse zu liefern, kommen verschiedene Techniken zum Einsatz. Aus Systemsicht werden daher einerseits Suchmöglichkeiten angeboten, die sequentiell den gesamten Korpus durchsuchen. Da die Suchzeit in größeren Datenmengen sehr hoch ist, kommen andererseits Techniken zur Anwendung, die auf einen Index zugreifen, der auf die Objekte verweist.

19.2 | Indexierung

Ein Retrieval von textbasierten Informationen besteht aus zwei Elementen: einerseits aus Dokumenten wie Buchinhalten, Artikeln, E-Mails etc. und andererseits aus den daraus extrahierten Begriffen (*terms*). Eine sequentielle Suche, bei der eine Datenbank von vorne bis hinten nach Begriffen durchsucht wird, wäre zeitaufwändig und unökonomisch. Daher kommen bei der Erschließung von Dokumenten, aber auch des World Wide Webs **Crawler** zum Einsatz. Diese extrahieren aus den Textdokumenten Begriffe und schreiben diese in einen **Index**, um nicht auf das vollständige Originaldokument, sondern schnell auf dessen abstrahierten Inhalte zugreifen zu können.

Dabei werden meist Begriffe, die nicht zur Verbesserung der Suche beitragen, herausgefiltert. Dazu gehören Stoppwörter wie bestimmte und unbestimmte Artikel Konjunktionen und Präpositionen. Zudem hängt die Art und Weise, wie ein solcher Index angelegt wird, von der Art der Information und dem Umfang der bereitgestellten Suchmöglichkeiten ab. So können zu einem Textdokument nur Wörter, ganze Phrasen oder auch deren Position im Dokument etc. aufgenommen werden. Hier kann die Struktur des Textes eine Rolle spielen, genauso können aber auch mithilfe eines kontrollierten Vokabulars Synonyme zusammengefasst und Homonyme getrennt werden, um den Textsinn im Index sinnvoll wiederzugeben.

Kommen beispielsweise zu einem Textkorpus weitere Dokumente hinzu oder werden welche entnommen, muss dies bei einem weiteren Durchlauf erkannt und

sie in den Index aufgenommen bzw. von diesem entfernt werden. Sind die Dokumente von dem Retrieval-System mithilfe des Crawlers indiziert, erlaubt das System dem Benutzer die Formulierung einer Anfrage. Das Ergebnis der Indexsuche in einem solchen alphabetisch sortierten Register enthält die gewünschten Dokumente.

19.3 | Suchstrategien

Um in diesem Index einen Eintrag zu finden, sind verschiedene Suchalgorithmen denkbar.

Lineare Suche: Die einfachste Methode ist das sequentielle Durchsuchen der Wortliste nach dem Vorkommen der gesuchten Buchstabenkette. Dabei werden die Elemente der Liste nacheinander mit dem Zielwert verglichen, bis dieser gefunden wird. Dieser Vorgang ist leicht umsetzbar, bei großen Dateimengen jedoch zeitaufwändig. Die durchschnittliche Suchzeit beträgt bei n Elementen $n/2$, steigt also mit zunehmender Dokumentenzahl linear. Bei großen Korpora wie dem World Wide Web wäre dies nicht vertretbar.

Binäre Suche: Liegt die Wortliste jedoch alphabetisch sortiert vor, kann diese entsprechend gezielter durchsucht werden. Bei der **binären Suche** wird zunächst das Element untersucht, das in der Mitte der Liste zu finden ist. Ist der gesuchte Anfangsbuchstabe im Alphabet weiter vorne oder weiter hinten, wird die erste bzw. die zweite Hälfte auf die gleiche Weise untersucht, der Suchbereich also in jedem weiteren Schritt halbiert bis das gesuchte Element gefunden wurde oder die Suche ohne Ergebnis beendet wird (ausführlich dazu Kap. 6).

Interpolationssuche: Da die Teilung bei der Hälfte nicht immer die sinnvollste Entscheidung ist, prüft die **Interpolationssuche** zunächst die Grenzen der Liste, um dann zu entscheiden, an welcher Stelle der Teiler zu setzen ist. Beginnt eine Liste beispielsweise nicht mit einem Element mit dem Anfangsbuchstaben A, sondern mit L und endet mit Z, ist es nicht sinnvoll, den Teiler bei der Mitte des Alphabets, sondern in der Mitte der vorhandenen Elemente anzusetzen, in diesem Fall also bei R. Die Suchzeit liegt hier bei $\log n$, wächst also nicht linear mit der Anzahl an Elementen.

Solche Suchalgorithmen sind vergleichsweise einfach umsetzbar, jedoch müssen die Elemente stets vorsortiert vorliegen.

Boolesches Retrieval

Eine Suchanfrage, die nur aus einem Wort besteht, würde bei einem großen Datenbestand ein zu umfangreiches Ergebnis liefern, da alle Dokumente zurückgegeben werden, in denen der Begriff vorkommt – ohne die Möglichkeit, das Gesuchte näher zu definieren und damit die Anzahl der Suchergebnisse einzugrenzen. Daher ist es angebracht, innerhalb einer Suche Teilmengen zu bestimmen, indem mehrere Worte miteinander logisch verknüpft und andere aus den Ergebnissen ausgeschlossen werden. Zur Definition solcher Teilmengen kommen **Boolesche Operatoren** zum Einsatz. Zu den wichtigsten gehören AND, OR, NOT und XOR.

Mithilfe dieser Operatoren wird ein Index nach Begriffen, die auf diese Weise logisch verknüpft sind, durchsucht und bei Erfüllung aller Bedingungen die Teilmenge an Dokumenten zurückgegeben. So ergibt eine Suche nach Albrecht AND




Abb. 56 Boolesche Operatoren

Dürer AND Lucas AND Cranach die Ausgabe von Dokumenten, in denen alle diese Begriffe vorkommen. Eine Anfrage nach Albrecht OR Dürer würde eine größere Liste ergeben, da darin Dokumente enthalten sind, die nicht nur von Albrecht Dürer, sondern auch von Andreas Dürer und Hans Dürer etc. sowie von verschiedenen Personen mit dem Namen Albrecht handeln. Eine Anfrage (Albrecht AND Dürer) NOT (Lucas AND Cranach) würde nur Dokumente ausgeben, die sich mit Albrecht Dürer, aber nicht mit Lucas Cranach beschäftigen. Würde hier das NOT durch XOR ersetzt, erhielte man als Ergebnis Texte, die sich ausschließlich mit einem der beiden Künstler, aber nicht mit beiden beschäftigen. Die Umsetzung dieser Anfragen kann von System zu System jedoch variieren. So wird die NOT-Anweisung beispielsweise bei Google mit einem Minuszeichen umgesetzt, also folgendermaßen formuliert: "Albrecht Dürer" -"Lucas Cranach"

Der Vorteil des **Booleschen Retrievals** liegt in der logischen Klarheit des Modells. Nachteil ist jedoch, dass der Benutzer gute Kenntnisse über die Suchbegriffe in Kombination mit den Operatoren besitzen muss, um ein angemessenes Ergebnis zu erzielen – was oftmals nicht der Fall ist (Chowdhury 2010, 206). Ist die Anfrage nicht exakt, führt dies dazu, dass zu viele oder zu wenige Ergebnisse geliefert werden. Die binäre Entscheidung, ob ein Objekt zu der Suchanfrage passt oder nicht, erlaubt zudem keine Sortierung nach Relevanz. So werden alle Dokumente zurückgeliefert, auf die diese Anfrage passt und beispielsweise Dokumente, in denen die Suchbegriffe häufiger als in anderen vorkommen, nicht vorrangig aufgelistet.

Reguläre Ausdrücke

Häufig werden nicht nur Wörter als atomare Einheiten (*tokens*) gesucht. Bei komplexeren Datenstrukturen ist es sinnvoll, **String-Anfragen** zu stellen, die mithilfe von syntaktischen Metazeichen formuliert werden und sich so nach bestimmten Mustern durchsuchen lassen. Andernfalls würde eine Anfrage nach Selbstbildnis in einer Bilddatenbank nur Werke mit exakt diesem Titel ergeben. ›Selbstbildnis von Albrecht Dürer‹ oder ›Selbstporträt‹ würden nicht angezeigt werden. Daher gibt es mithilfe von Regulären Ausdrücken die Möglichkeit, die exakte Suche in ihren Bedingungen zu lockern, um auch unscharf zu suchen und Varianten, Wiederholungen etc. zu finden. Dabei handelt es sich um Zeichenketten, die mit bestimmten syntak-

tischen Regeln komplexe Suchmuster beschreiben. Auf diese Weise lassen sich Strings auf bestimmte Zusammensetzungen prüfen. So lässt sich beispielsweise mit der Eingabe von `^Selbst` jede der oben erwähnten Variationen mit der Buchstabenfolge am Beginn der Zeichenkette finden. Ohne den vorangestellten Zirkumflex wird sie auch irgendwo in dem String, beispielsweise auch in ›Kopie nach Ingres‹ Selbstbildnis von 1804, gefunden. Sollen auch Werke Dürers gefunden werden, die statt dem Umlaut ›ue‹ verwenden, ist mit der Variation `D(ü|ue)rer` zu suchen. Eine Auswahl an weiteren Suchmöglichkeiten stellt die folgende Tabelle dar:

Ausdruck	Beschreibung
<code>abc</code>	Findet die Zeichenfolge <code>abc</code>
<code>[abc]</code>	Findet jeden der Buchstaben <code>a</code> , <code>b</code> oder <code>c</code>
<code>[^abc]</code>	Findet alle Buchstaben außer <code>a</code> , <code>b</code> und <code>c</code>
<code>[a-z]</code>	Findet alle Kleinbuchstaben von <code>a</code> bis <code>z</code>
<code>[A-Za-z0-9]</code>	Findet alle angegebenen Buchstaben und Ziffern
<code>[0-9]</code>	Findet alle Ziffern von <code>0</code> bis <code>9</code>
<code>[^0-9]</code>	Findet alle Ziffern außer <code>0</code> bis <code>9</code>
<code>(x y)</code>	Findet sowohl den Buchstaben <code>x</code> wie auch <code>y</code>
<code>.</code>	Findet irgendeinen Buchstaben
<code>\.</code>	Findet einen Punkt
<code>\w</code>	Entspricht <code>[A-Za-z0-9_]</code>
<code>^n</code>	Findet das Zeichen <code>n</code> am Anfang der Zeile
<code>n\$</code>	Findet das Zeichen <code>n</code> am Ende der Zeile
<code>\bn</code>	Findet das Zeichen <code>n</code> am Anfang eines Wortes
<code>n\b</code>	Findet das Zeichen <code>n</code> am Ende eines Wortes
<code>n\B</code>	Findet ein Zeichen <code>n</code> , das nicht am Ende eines Wortes steht
<code>+</code>	Mindestens eines der vorigen Zeichen kommt vor
<code>?</code>	Das vorangegangenen Zeichen kann vorkommen, muss aber nicht

Tab. 9 Reguläre Ausdrücke

In eckigen Klammern lassen sich eine Reihe an zu suchenden Zeichen angeben `[ab]`, dies ist auch als Intervall möglich `[a-z]`. Möchte man nach etwas suchen, was nicht in dem String enthalten sein soll, ist innerhalb der eckigen Klammer ein ›^‹ voranzustellen. `[^äöü]` findet auf diese Weise einen String, der keine Umlaute enthält. Um Zeichenfolgen zu finden, die als Wort alleine stehen, aber nicht innerhalb anderer Wörter vorkommen, setzt man davor und dahinter einen Schrägstrich. Würde die Suche nach dem Begriff `und` in dem String ›Hund und Hunde‹ drei Ergebnisse liefern, wird mit dem Ausdruck `\bund\b` nur das mittlere der drei Wörter als Ergebnis angezeigt. Ein Punkt `.` ist ein Platzhalter für jedes beliebige Zeichen. Soll aber nach einem Punkt gesucht werden, ist diesem ein Escape-Zeichen `\` voranzustellen.

Erweitertes Retrieval mit Gewichtung und Ranking

Um zu verstehen, wie das Boolesche Retrieval erweitert werden kann, ist es notwendig, sich noch einmal genauer anzusehen, wie der Index abgelegt wird, auf den zugegriffen wird. Im Booleschen Retrieval wird jeder Begriff mit einem Dokument über eine Matrix verknüpft, in deren Zellen eine 1 steht, wenn dieser Begriff in diesem Dokument erscheint, bzw. eine 0, wenn dies nicht der Fall ist. Dieser Wert $d_{t,d}$ beschreibt die Anzahl des Begriffs t in dem Dokument d . Kommt der Begriff t_1 = Dürer in dem Dokument d_1 vor, so ist $d_{1,1} = 1$.

	t_1	t_2	t_3
D_1	1	0	0
D_2	0	1	0
D_3	1	1	0
D_4	0	0	1

Eine solche **Dokument-Begriff-Matrix** repräsentiert alle Terme in allen Dokumenten, weshalb sie sehr groß werden kann und entsprechend viel Speicher und Prozessorlast in der Verarbeitung benötigt. Zudem besteht sie vorwiegend aus Nullen, da beispielsweise Begriffe, die nur in einem Dokument erscheinen, in allen anderen mit 0 gelistet werden. Daher wird sie in der Praxis als invertierte Dateistruktur dargestellt. Das bedeutet, eine Liste an Termen wird mit Dokumenten verknüpft, in denen sie vorkommen. Dokumente, in denen sie nicht vorkommen, erscheinen so nicht. So kann schneller das relevante Dokument gefunden und neue Dokumente leichter hinzugefügt werden.

Auf diese Weise lässt sich feststellen, ob ein Begriff in einem Dokument vorkommt, oder nicht. Dabei werden alle Begriffe gleichwertig behandelt, unabhängig davon, wie relevant sie sind. Das Boolesche Retrieval bevorzugt so längere Dokumente, da mit zunehmender Länge des Dokuments Begriffe wahrscheinlicher enthalten sind. Eine Suche auf diese Weise ergibt eine Liste von Dokumenten, die der Anfrage entsprechen. Um die Ergebnisse jedoch in ihrer Reihenfolge nach Relevanz zu sortieren (**Ranking**) wurde das **Erweiterte Boolesche Retrieval** entwickelt, das neben der binären Entscheidung (trifft zu/trifft nicht zu) auch die **Gewichtung** der Begriffe erlaubt (Buell 1981). Dazu stehen verschiedene Möglichkeiten zur Auswahl.

Zunächst liegt es nahe, die reine Häufigkeit der Begriffe in den einzelnen Dokumenten zur Gewichtung heranzuziehen. Die **Termfrequenz (TF)** wird als $tf_{t,d}$ angegeben und stellt die Anzahl der Terme t in einem Dokument d dar. Je höher die TF eines Suchbegriffs in einem Dokument, desto höher wird dessen Relevanz eingeschätzt. Jedoch erzeugen lange Dokumente tendenziell höhere TF-Werte und damit eine höhere Relevanz in den Suchergebnissen. Um längere Dokumente nicht zu bevorzugen, die eine größere Häufigkeit haben, wird die Vorkommenshäufigkeit normalisiert, also in Bezug zum häufigsten Term im Dokument gesetzt:

$$ntd_{t,d} = \frac{tf_{t,d}}{\max tf_d}$$

Da jedoch ein Wort, das in vielen Dokumenten vorkommt, weniger geeignet ist, um Dokumenten differenzierende Relevanz zuzuweisen (in einem kunsthistorischen Korpus beispielsweise Begriffe wie ›Kunst‹, ›Bild‹ oder ›Gemälde‹), als ein Wort, das

in wenigen Dokumenten vorkommt (z. B. ›Kartusche‹, ›Acheiropoieton‹ oder ›Pelzschabe‹) wird zudem die **inverse Dokumentenhäufigkeit (IDF)** zur Gewichtung herangezogen. Diese berechnet sich aus der Zahl aller Dokumente im Korpus (N) und der Anzahl der Dokumente, in denen der Begriff vorkommt (*document frequency*):

$$idf_t = \log \left(\frac{N}{df_t} \right)$$

Wobei N die Anzahl aller Dokumente im Korpus ist und df_t die Anzahl der Dokumente, die den Term t enthalten. Je seltener ein Begriff ist, desto größer ist dieser Wert. Wenn er in allen Dokumenten auftritt ist, dieser Wert gleich 0.

TF-IDF bezeichnet schließlich das Produkt der beiden Werte. In der Praxis erreicht damit ein Retrieval System bessere Precision-Recall-Werte:

$$tfidf_{t,d} = tf_{t,d} \times idf_t$$

Vektorraum-Retrieval

Neben einer Suche durch reguläre Ausdrücke und dem Booleschen Mengenverfahren kann man Informationen auch finden, indem man die **Ähnlichkeit** zwischen Suchanfrage und den vorhandenen Dokumenten als Relevanzkriterium heranzieht. Ähnlichkeit kann sich aus der Häufigkeit von Worten in einem Text berechnen lassen, die eine inhaltliche Nähe zwischen einzelnen Dokumenten vermuten lässt. Beim Vektorraum-Retrieval werden die Begriffe in dem Index als Koordinaten in einem n-dimensionalen Vektorraum aufgefasst. Dadurch werden die einzelnen Dokumente zu Punkten in diesem kartesischen Koordinatensystem. Die Suchanfrage wird nun ebenfalls zu einem solchen Koordinatenpunkt und der Abstand zu den Dokumenten berechnet. Je weiter Vektoren von dem Suchvektor abweichen, desto geringer ist deren Relevanz für die Suchanfrage und desto niedriger werden diese in der Ergebnisliste gerankt (Salton et al. 1975).

Zwei Dokumente mit den Begriffen ›Albrecht Dürer‹ (D_1) und ›Albrecht Altdorfer‹ (D_2) würden bereits durch einen dreidimensionalen Vektorraum dargestellt werden, dessen Achsen die Häufigkeit der Begriffe ›Albrecht‹ (t_1), ›Dürer‹ (t_2) und ›Altdorfer‹ (t_3) repräsentieren (hier jeweils einmalig), zwischen denen die beiden Dokumente platziert werden.

$$D_1 = (t_{11}, t_{21}, t_{31}) = (1, 1, 0)$$

$$D_2 = (t_{12}, t_{22}, t_{33}) = (1, 0, 1)$$

Eine Suchanfrage (Q) nach Hans Dürer entspricht einem weiteren Vektor (nicht gesuchte Terme und Terme, die nicht im relevanten Dokument vorkommen, werden im Suchvektor gleich Null gesetzt).

$$Q = (t_1, t_2, t_3) = (0, 1, 0)$$




Abb. 61 Suchvektoren

Bei einem Dokumentvektor D und einem Vektor der Suchanfrage Q berechnet sich die Ähnlichkeit s über das **Skalarprodukt**:

$$s(D_j, Q) = t_{1d} \times t_{1q} + t_{2d} \times t_{2q} + t_{3d} \times t_{3q}$$

In diesem Beispiel berechnet sich die Ähnlichkeit der Suchanfrage Q zu ›Albrecht Dürer‹ mit

$$s(D_1, Q) = 1 \times 0 + 1 \times 1 + 0 \times 0 = 1$$

Die Ähnlichkeit zu ›Albrecht Altdorfer‹ fällt mit 0 dagegen geringer aus und ist damit in der Relevanz geringer:

$$s(D_2, Q) = 1 \times 0 + 0 \times 1 + 1 \times 0 = 0$$

Obiges Beispiel besteht aus jeweils nur drei unterschiedlichen Begriffen. Dokumente, die t Indexterme erzeugen, erzeugen dagegen einen t -dimensionalen Vektorraum. Zudem wurden in diesem Beispiel binäre Vektoren verwendet, die also nur 0 (Begriff kommt nicht vor) und 1 (Begriff kommt vor) annehmen können. Für binäre Vektoren ist das Skalarprodukt die Anzahl der übereinstimmenden Begriffe (Größe der Intersektion). Bei gewichteten Termvektoren stellen diese die Anzahl der Vorkommen dar und mit der Häufigkeit verlängert sich der Vektor. Das Skalarprodukt berechnet sich dann folgendermaßen:

$$s(D_j, Q) = \sum_{i=1} w_{ij} \times w_{iq}$$

Hierbei ist w_{ij} das Gewicht von Term i in Dokument j und w_{iq} das Gewicht von Term i in der Anfrage.

Da das Skalarprodukt die Ähnlichkeit der Vektoren über die Beträge der Termwerte berechnet, ist die Länge der Vektoren entscheidend. Da dadurch kürzere und längere Dokumente sehr unähnlich zueinander werden, wird stattdessen häufig die **Kosinus-Ähnlichkeit** bevorzugt, bei der ausschließlich der Winkel zwischen den Vektoren berechnet und verglichen wird (s. Kap. 20.3). Bei einem Wert von 1 sind sie identisch und bei einem Wert von -1 ist der eine Vektor dem anderen entgegengerichtet. Zwischenwerte bestimmen folglich den Ähnlichkeitsgrad.

Der Vorteil des Vektorraum-Modells liegt in der einfachen Berechnung von genauen Distanzen zwischen Suchanfrage und Textdokumenten und damit in der Möglichkeit der Gewichtung und der Lieferung von sortierten Ergebnissen, auch wenn nur ein Teil der Begriffe übereinstimmt.

Hypertext-Retrieval

Eine besondere Art von Textdokumenten stellen **Hypertexte** dar, die als HTML-Dokumente im World Wide Web vorliegen. Das Besondere daran ist, dass sie miteinander über Links verknüpft sind, also aufeinander netzartig verweisen. Um aus diesem Gewebe eine Gewichtung zu errechnen, die nicht alleine aufgrund der Auswertung des Inhalts basiert, lassen sich linktopologische Verfahren anwenden. Dabei werden aufgrund der Verlinkung einer Seite Schlüsse auf deren Relevanz gezogen.

Ähnlich wie beim *Science Citation Indexing*, bei dem die Bedeutung einer Veröffentlichung daran bemessen wird, wie häufig sie in Fußnoten erwähnt wird, werden dabei die Gewichtungen aufgrund der Anzahl der Links berechnet. Doch nicht jeder Link zählt dabei gleich viel; Links von relevanten Seiten zählen mehr, und die Relevanz steigt, wenn viele andere relevante Seiten darauf verweisen. Auf diese Weise lässt sich für jede Seite im Web ein Wert berechnen. Der **PageRank-Algorithmus**, der den grundlegenden Algorithmus der Google-Suche darstellt, berechnet die Bedeutung einer Seite nach der Anzahl und der Bedeutung der auf sie verlinkenden Seiten. Dieser Wert geht anschließend wiederum in die Berechnung der Werte der von dieser Seite verlinkten Seiten ein etc. (Page et al. 1998). Die mithilfe eines Crawlers automatisiert vorgenommene Gewichtung aller im Web vorhandener Seiten dient schließlich der Sortierung der ausgegebenen Ergebnisseiten.

Der Wert von PageRank ist jedoch solange statisch, bis der Crawler erneut die Seite indiziert und den Wert neu berechnet. Der Wert sagt zudem nichts über die Relevanz der Seite in Relation zur Suchanfrage aus, er ist also anfragenunabhängig. Bei der **Hypertext-Induced Topic Selection (HITS)** wird dagegen zwischen Seiten unterschieden, die auf viele andere Seiten verweisen (*hubs*), und Seiten, auf die besonders viele andere Seiten verweisen (*authorities*). Dabei wird zunächst eine Menge an Dokumenten ermittelt, die der Suchanfrage entsprechen, und für diese werden im Augenblick der Anfrage Gewichtungen berechnet: Der Authority-Wert ist umso höher, je mehr Hubs darauf verweisen und der Hub-Wert ist umso höher, je mehr die Seite auf viele Seiten mit hohem Authority-Wert verweist. Da beide Werte voneinander abhängig sind, müssen diese in mehreren Durchläufen iterativ berechnet werden und eine Anfrage dauert daher länger. Dadurch entstehen aber zwei sortierte Listen: Die eine enthält die besten **Authorities**, also die wichtigsten Inhaltsseiten, die anderen die besten **Hubs**, also Übersichtsseiten (Kleinberg 1999).

19.4 | Weitere Retrieval-Systeme

Da in einem Information Retrieval-System sowohl eine Anfrageabhängigkeit als auch eine hohe Antwortgeschwindigkeit erzielt werden sollen, wurden weitere Retrieval-Modelle entwickelt. So werden im **Clustermodell** ähnliche Dokumente gruppiert, um einen schnellen Zugriff darauf zu ermöglichen. Das PageRank-Modell basiert auf der Bedeutung von Links, die von Webseitenbetreibern gesetzt werden. Zunehmend wird jedoch auch versucht, die tatsächliche Nutzung der Seite sowie vorherige Suchanfragen und den Standort des Nutzers in die Ergebnisbewertung einfließen zu lassen.

Wurde in diesem Kapitel vor allem auf Textdokumente eingegangen, liegt das vor allem daran, dass diese vergleichsweise einfach statistisch zu analysieren sind. Auch hier geht die Entwicklung weiter. So kommen beispielsweise zunehmend Abfragesysteme für die spezielle Struktur von XML-Dokumenten mithilfe von der Abfragesprache XML Path Language (**XPath**) zum Einsatz. Bild-, Video- und Audiodokumente benötigen dagegen umfangreichere Aufbereitungen der Inhalte, um sie für Anfragen verfügbar zu machen. So ist das **Content-Based Image Retrieval** (Datta et al. 2008) mithilfe von **Feature Extraction** und **Pattern Recognition** gegenwärtig in der Entwicklung und erhält zunehmend Bedeutung für bildbasierte Geisteswissenschaften.

In den digitalen Geisteswissenschaften geht es um die Verarbeitung von Daten zu Wissen. Die zunehmende Datenmenge ist dann eine Chance für die Fächer, wenn sie effektiv erschlossen werden kann. Dem Information Retrieval kommt daher in diesem Kontext eine große Bedeutung zu, und ihre Weiterentwicklung zu intuitiven, für den Forscher leicht zu bedienenden Systemen, die relevante Inhalte mit guten Recall- und Precision-Werten verfügbar machen, wird zu einem entscheidenden Element in den Digital Humanities. In Zukunft werden sich diese Systeme möglicherweise zu Assistenz-Systemen mit künstlicher Intelligenz weiterentwickeln, beispielsweise mithilfe von **Deep Learning** (Jarosch 2007). Umso wichtiger ist es, aus der Wissenschaft heraus die Anforderungen an solche Systeme zu formulieren und gemeinsam mit der Informatik zu entwickeln.

Literatur

- Buell, Duncan A.: »A general model of query processing in information retrieval systems«. In: *Information Processing & Management* 17 (1981), 249–262.
- Chowdhury, G. G.: *Introduction to Modern Information Retrieval*. London 32010.
- Datta, Ritendra/Joshi, Dhiraj/Li, Jia/Wang, James Z.: »Image retrieval: Ideas, influences, and trends of the new age«. In: *ACM Computing Surveys* 40/2 (2008), 1–60.
- Henrich, Andreas: *Information Retrieval 1. Grundlagen, Modelle und Anwendungen*. Bamberg 2009.
- Jarosch, Helmut: *Information Retrieval und Künstliche Intelligenz*. Wiesbaden 2007.
- Kleinberg, Jon: »Authoritative sources in a hyperlinked environment«. In: *Journal of the ACM* 46/5 (1999), 604–632.
- Manning, Christopher D./Raghavan, Prabhakar/Schütze, Hinrich: *Introduction to Information Retrieval*. Cambridge 2009.
- Page, Larry/Brin, Sergey/Motwani, R./Winograd, T.: »The PageRank citation ranking: Bringing order to the Web« (1998), ilpubs.stanford.edu/422/1/1999-66.pdf (31.10.2016).
- Salton, Gerard/Wong, Andrew/Yang, Chungshu S.: »A vector space model for automatic indexing«. In: *Communications of the ACM* 18/11 (1975), 613–620.
- Schmitt, Ingo: *Ähnlichkeitssuche in Multimedia-Datenbanken*. München 2006.

Harald Klinke

20 Quantitative Analyse

20.1 | Was ist quantitative Analyse?

Quantitative Methoden der Datenanalyse werden in den digitalen Geisteswissenschaften in den unterschiedlichsten Bereichen und mit vielfältigen Motivationen eingesetzt. Mit der zunehmenden Verfügbarkeit größerer digitaler Bestände an geisteswissenschaftlich relevanten Daten wird der Einsatz quantitativer Methoden zugleich möglich und erforderlich. Solche Methoden werden unter programmatischen Schlagworten wie »distant reading« (Moretti 2005), »macroanalysis« (Jockers 2011) oder »cultural analytics« (Piper 2016) auch über die digitalen Geisteswissenschaften hinaus diskutiert. Beispiele für quantitative Methoden sind statistische Analysen und das sogenannte maschinelle Lernen sowie die Netzwerkanalyse (s. Kap. 10) und das Topic Modeling (vgl. Blei 2012).

Quantitative Analysemethoden grenzen sich von qualitativen Analysemethoden ab, die Bestandteile und Eigenschaften von Forschungsgegenständen beschreiben und dabei besondere Aufmerksamkeit auf nuancierte Differenzierungen, individualisierende Detailanalysen und herausragende oder beispielhafte Einzelbeispiele legen. Quantitative Analysemethoden hingegen sind in erster Linie darauf ausgerichtet, Merkmale von Forschungsgegenständen zu identifizieren und ihre Häufigkeiten zu erheben, was möglichst klare und teils auch vereinfachende Kategorisierungen erfordert. Auf Grundlage solcher zahlenmäßiger Informationen können dann mit statistischen Verfahren die Forschungsgegenstände beschrieben, Gruppen ähnlicher Gegenstände entdeckt oder automatische Klassifikationen vorgenommen werden. Zwischen qualitativen und quantitativen Methoden gibt es zahlreiche Brücken: So entstehen im Rahmen qualitativer Analysen häufig Hypothesen, die in einer Weise formalisiert und operationalisiert werden können, die sie einer Bearbeitung mit quantitativen Methoden zugänglich macht. Oder die Ergebnisse quantitativer Untersuchungen führen umgekehrt zu neuen Fragestellungen, denen mit qualitativen Methoden vertiefend nachgegangen werden kann (vgl. Jannidis 2010).

Quantitative Analysemethoden grenzen sich zudem vom **Information Retrieval** ab (s. Kap. 19). Letzteres ist damit befasst, wie die in einer Datensammlung explizit vorhandenen Informationen möglichst effizient und präzise abgerufen und die Fundstellen oder relevanten Dokumente in sinnvoller Weise gewichtet und sortiert werden können. Die quantitative Analyse hingegen zielt unter anderem darauf ab, relevante Bestandteile eines Datensatzes oder Strukturen in den Daten überhaupt erst zu identifizieren sowie weiterführende statistische Auswertungen von Datensammlungen durchzuführen.

Ziel dieses Kapitels ist es, einen Überblick über quantitative Methoden der Datenanalyse in den digitalen Geisteswissenschaften zu geben. Hierzu werden zunächst einige Grundlagen der deskriptiven Statistik vermittelt und ihre Nutzung für vergleichende Analysen erläutert. Dann werden die beiden grundlegenden Typen des maschinellen Lernens, das überwachte und unüberwachte Lernen, beschrieben und anhand konkreter Anwendungsbeispiele illustriert.

20.2 | Statistische Grundlagen

Merkmalserhebung: Viele quantitative Methoden der Datenanalyse beruhen darauf, dass zunächst für jeden einzelnen Untersuchungsgegenstand verschiedene **Merkmale** erhoben werden, was heute oft automatisch geschieht. Beispielsweise könnte man in einer Sammlung von Gedichten die Häufigkeit jedes Wortes in jedem Gedicht erheben, in einer Briefsammlung die Anzahl verschiedener Orts- und Personennamen pro Brief, oder in einer Gemäldesammlung, welche Objekte in jedem Bild dargestellt sind. Solche Informationen werden üblicherweise in einer Tabelle festgehalten, in der beispielsweise jede Spalte ein Werk (Gedicht, Brief bzw. Gemälde) und jede Zeile ein bestimmtes Merkmal (Wort, Personennamen bzw. Objekt) betrifft. Jede Zelle repräsentiert dann den Kreuzungspunkt eines Werks und eines Merkmals und enthält eine zahlenmäßige Charakterisierung des Merkmals in dem Werk. Man nennt eine solche Tabelle **Merkmals-Matrix**, im besonderen Fall der Textanalyse auch Term-Dokument-Matrix. Eine solche Matrix bedeutet einerseits einen Informationsverlust: Beispielsweise werden bei Texten die Reihenfolge der Wörter oder bei Gemälden die Position der Objekte im Bild nicht berücksichtigt. Im Gegenzug erleichtert die Tabellenform aber zahlreiche nützliche Berechnungen: Beispielsweise beantwortet die spaltenweise bzw. zeilenweise Summenbildung die Frage, wie viele Wörter ein bestimmter Text insgesamt enthält bzw. wie oft ein bestimmtes Objekt in der Bildsammlung insgesamt dargestellt wird.

Was ist mit den Merkmalen eines Objekts gemeint? Zur Beantwortung dieser Frage sei hier die Unterscheidung zwischen **Types** und **Tokens** eingeführt. Im engeren (und auf Texte bezogenen) Sinne sind Tokens die als solche identifizierten Wortformen, wobei es unterschiedliche Auffassungen dessen gibt, wie die Grenzen zwischen Wortformen bestimmt werden und wie Interpunktion und Groß-/Kleinschreibung behandelt werden. Types hingegen sind die unterschiedlichen Tokens. Der Satz »A rose is a rose is a rose.« hat neun Tokens, aber nur fünf Types, wenn man Interpunktion und Groß-/Kleinschreibung berücksichtigt. In einem erweiterten Sinne (der nicht nur für Texte geeignet ist) kann man Tokens als die grundlegende Analyseeinheit verstehen und Types als das jeweils eine solche Einheit beschreibende Kriterium. Noch einmal auf Einzelwörter bezogen, wäre eine einzelne Wortform die Analyseeinheit (Token) und die jeweilige Schreibung das definitorische Kriterium (alle Wortformen gleicher Schreibung gelten als ein Type). Ebenso könnte aber jeder Satz eine Analyseeinheit (Token) sein und das ihn beschreibende Kriterium (Type) beispielsweise, ob es sich um einen einfachen oder komplexen Satz handelt. Oder jedes in einem Bild dargestellte Objekt wäre die Analyseeinheit (Token) und das beschreibende Kriterium (Type) wäre dadurch bestimmt, welches Objekt dargestellt ist. Zu den relevanten Merkmalen eines Untersuchungsgegenstands gehören dann die Häufigkeiten jedes Types, also wie viele der jedem Type entsprechenden Tokens beobachtet werden können. Daraus lassen sich weitere Merkmale ableiten, wie die Gesamtzahl der vorhandenen Types oder Tokens, die schlichte An- oder Abwesenheit eines oder mehrerer Types, oder auch das Verhältnis bestimmter Types zueinander.

Beispiel Romane: Zur Veranschaulichung wird im Folgenden eine Sammlung von zehn Romanen des britischen Autors Arthur Conan Doyle verwendet, von denen vier Kriminalromane sind (mit Sherlock Holmes als Protagonisten), sechs dagegen verschiedenen anderen Romangattungen angehören. Eine Merkmals-Matrix der Doyle-Sammlung erhält man, indem man die Liste aller Types (unterschiedlicher Wortfor-

men) erstellt und dann die Häufigkeit jedes Types in jedem der zehn Romane ermittelt (einen Ausschnitt aus der Matrix zeigt Tabelle 10):

Rang	Type	The Hound of the Baskervilles	The Sign of Four	A Study in Scarlet	The Valley of Fear	Lost World	The Mystery of Cloomber	Poison Belt	Raffles Haw	The Refugees	The White Company	Summe
1	the	3056	2147	2319	1994	4156	2632	1618	1842	7264	9124	37152
2	and	1505	1154	1313	1343	2000	1442	732	1042	3899	5226	19656
3	of	1580	1105	1195	1424	2502	1362	864	1018	3362	4781	19121
4	to	1381	1070	1070	1256	1678	1218	646	936	2606	3131	14992
...	...											...
21	which	417	235	315	307	639	341	203	280	751	844	4332
22	my	420	323	274	221	542	466	175	213	541	918	4093
23	at	335	311	289	341	430	288	172	196	813	821	3996
24	be	328	260	248	302	413	310	189	262	650	763	3725
...	...											...
101	know	115	69	49	104	74	55	32	73	146	142	859
102	eyes	69	36	59	54	77	34	26	49	219	225	848
103	like	51	58	33	59	127	56	47	47	164	204	846
...	...											...
1001	pocket	7	8	14	14	4	6	1	3	7	7	71
1002	extraordi- nary	8	5	7	5	16	7	3	8	2	8	69
1003	long	9	4	1	10	6	6	0	2	16	9	63
...	...											...
Summe		69802	51583	51218	69676	88221	56534	34544	44910	146303	178233	791024

Tab. 10 Ausschnitt aus der Merkmals-Matrix für die Doyle-Sammlung. Die Matrix enthält die absoluten Häufigkeiten der Types, absteigend sortiert. Es sind die Häufigkeiten für alle zehn Romane, aber nur für Ausschnitte aus verschiedenen Bereichen der Matrix enthalten.

Man kann dieser Matrix bereits einige Informationen entnehmen. Die absolute Häufigkeit eines Types in einem Roman steht jeweils in der entsprechenden Zelle (z. B. kommt das Type »eyes« in *Poison Belt* 26 Mal vor). Die Häufigkeit eines Types in allen Texten ergibt sich aus der Zeilensumme (»eyes« kommt insgesamt 848 Mal vor). Unterschiedliche Häufigkeitsbereiche entsprechen unterschiedlichen Wortarten: Die Types der ersten etwa 100 Ränge sind überwiegend Funktionswörter, diejenigen höherer Ränge sind dagegen überwiegend Inhaltswörter. Je höher der Rang eines Types, desto spezifischere Begriffe erscheinen, die dann oft auch gar nicht in allen Texten vorkommen (z. B. kommt »long« in *Poison Belt* nicht vor). Der Merkmals-Matrix ist außerdem die Länge der Texte zu entnehmen; sie entspricht der Spaltensumme (*Lost World* hat beispielsweise eine Länge von 88.221 Tokens). Die Summe

aller Zellen entspricht der Anzahl der Tokens in der Textsammlung (hier: 791.024). Die Länge der Tabelle schließlich zeigt an, wie viele Types vorkommen.

Grundlegende Operationen auf der Merkmals-Matrix

Absolute und relative Häufigkeit: Die absoluten Häufigkeiten haben ihre Berechtigung, allerdings erlauben sie keinen sinnvollen Vergleich der Häufigkeiten zwischen verschiedenen Werken, wenn der Umfang der Werke unterschiedlich ist. **Relative Häufigkeiten** erlauben einen solchen Vergleich und liegen vor, wenn die absoluten Häufigkeiten der Types durch die spaltenweisen Summen (Anzahl der Tokens pro Text, also Textlänge) geteilt werden. Die relative Häufigkeit eines Types in einem Roman beschreibt dann, wie häufig ein bestimmtes Type im Verhältnis zur Länge des Romans anzutreffen ist. Beispielsweise kommt das Type ›know‹ in *Lost World* 74 und in *Raffles Haw* 73 Mal vor, die absolute Häufigkeit ist also fast identisch. Allerdings hat *Lost World* eine Länge von 76.975, *Raffles Haw* dagegen nur von 38.571 Tokens, also etwa die Hälfte. Die relative Häufigkeit und damit der Anteil am Text von ›know‹ ist daher für *Lost World* $74/76975 = 0,0009$, für *Raffles Haw* aber $73/38571 = 0,0019$ und damit gut doppelt so hoch. Oft multipliziert man alle relativen Häufigkeiten noch um den Faktor 1000, um Häufigkeiten pro 1000 Tokens zu erhalten, was intuitiv besser erfassbar ist. Das Wort ›know‹ kommt in *Lost World* also 0,9 Mal pro 1000 Tokens vor (wir rechnen im Folgenden mit solchen Zahlen).

Die relativen Häufigkeiten erlauben zwar den Vergleich zwischen Texten, häufig möchte man aber genauer wissen, ob ein Type in einem bestimmten Einzeltext einer größeren Sammlung vergleichsweise häufig oder selten vorkommt. Hierfür kann es zweckmäßig sein, die (relative) Häufigkeit des Types in dem Einzeltext mit dem Mittelwert oder Median des Types in der Textsammlung zu vergleichen. Sowohl Mittelwert als auch Median sind sogenannte **Maße der zentralen Tendenz**, die eine Verteilung mehrerer Werte in einem Wert zusammenfassen. Den (arithmetischen) Mittelwert der relativen Häufigkeit eines Types in der Romansammlung berechnet man, indem man die Zeilensumme des Types durch die Anzahl der Romane teilt. Für ›know‹ ergibt sich eine mittlere Häufigkeit von 1,4 (pro 1000 Tokens). Der Mittelwert ist sensibel gegenüber wenigen extrem hohen oder extrem niedrigen Werten und verschiebt sich dann spürbar in deren Richtung. Beim Median ist dies nicht der Fall. Man berechnet den Median, indem man die Häufigkeiten eines Types nach ihrem Wert sortiert und den Wert auswählt, der in der Mitte der geordneten Liste steht. (Hat die Liste eine gerade Anzahl von Einträgen, wird der Mittelwert zwischen den beiden um die Mitte liegenden Werten gebildet.) Für ›know‹ liegt der Median bei 1,2, also etwa 15 % niedriger als der Mittelwert, der von vergleichsweise hohen Werten in *The Hound of the Baskervilles* (1,94) und *Raffles Haw* (1,92) beeinflusst ist. Wenn solche extremen Werte vorliegen, fasst der Median die Verteilung der Type-Häufigkeiten besser zusammen als der Mittelwert. Vergleicht man nun die relative Häufigkeit von ›know‹ in *Lost World* (0,9) mit dem Median des Worts in der Textsammlung (1,2) zeigt sich, dass ›know‹ in *Lost World* bezogen auf die Gesamtsammlung eher selten ist.

Streuungsmaße: Mittelwert und Median beschreiben wesentliche Eigenschaften einer Häufigkeitsverteilung, lassen aber eine weitere wichtige Eigenschaft unberücksichtigt, nämlich wie stark die Häufigkeiten in verschiedenen Texten schwanken. Verschiedene Streuungsmaße beschreiben, wie stark die Häufigkeiten eines Types in

verschiedenen Texten um den Mittelwert (den durchschnittlich zu erwartenden Wert) herum variieren. Zu diesen Maßen gehören insbesondere die Spannweite und die Standardabweichung. Die Spannweite ist schlicht der Abstand zwischen dem höchsten und dem niedrigsten Wert (für ›of‹ im Doyle-Korpus liegt die Spannweite demnach bei $3,3 - 2,4 = 0,9$). Die **Standardabweichung** eines Types beschreibt die Streuung genauer und berechnet sich als die Wurzel aus dem Mittelwert der quadrierten Abweichungen jedes Einzelwertes vom Mittelwert aller Werte.

Eine hohe Standardabweichung weist darauf hin, dass die Werte breit um den Mittelwert streuen, während eine niedrige Standardabweichung darauf hinweist, dass die Werte eng um den Mittelwert herum liegen. Die verschiedenen Einzelwerte (hier: die relativen Häufigkeiten pro 1000 Tokens) für ein Type sind auf Grundlage der Matrix zu berechnen (für ›at‹ beträgt der Wert in *Poison Belt* beispielsweise $172/34544 \times 1000 = 5,0$). Der Mittelwert von ›at‹ in der Doyle-Sammlung beträgt 6,0. Die quadrierte Abweichung eines Einzelwerts vom Mittelwert erhält man, indem man den Mittelwert vom Einzelwert abzieht und diesen Wert quadriert (für ›at‹ in *Poison Belt* also: $(5 - 6)^2 = 1$).

Nun summiert man alle Abweichungen auf, bestimmt ihren Mittelwert und zieht aus dem Ergebnis die Wurzel. Für ›at‹ erhält man so eine Standardabweichung von 0,49. Nimmt man die gleiche Berechnung für ›my‹ vor (das einen ganz ähnlichen Mittelwert wie ›at‹ hat und im Rang direkt davorliegt), ergibt sich eine deutlich höhere Standardabweichung von 1,35. Dies leuchtet auch ein, insofern erwartbar ist, dass das Reflexivpronomen der ersten Person stärker in Abhängigkeit der unterschiedlichen Erzählperspektiven und Romangattungen in der Doyle-Sammlung schwankt, als dies für die Präposition ›at‹ der Fall ist. (Möchte man die Standardabweichungen von Verteilungen vergleichen, die unterschiedliche Mittelwerte haben, empfiehlt es sich, den sog. Variationskoeffizient zu berechnen, indem man die Standardabweichungen durch den Mittelwert der Verteilungen teilt.)

Normalisierung und Standardisierung von Verteilungen

Mittelwert bzw. Median und Standardabweichung charakterisieren zwei wesentliche Aspekte einer Verteilung. Auf ihrer Grundlage kann man zudem eine Normalisierung einer Verteilung vornehmen. Dies dient u. a. dazu, die Verteilungen mehrerer Types besser untereinander vergleichbar zu machen.

Abbildung 58 (oben) zeigt die Verteilungen mehrerer Types aus unterschiedlichen Bereichen der Wortliste als relative Häufigkeiten ohne weitere Normalisierung (die gewählten Types entsprechen denjenigen aus der Merkmals-Matrix in Tabelle 10). Jeder Boxplot in der Abbildung repräsentiert die Verteilung eines Types in den verschiedenen Texten. Der Median der Verteilung ist als dicke horizontale Linie markiert (für ›of‹ liegt er beispielsweise bei 0,028). Die gefüllte Fläche repräsentiert 50 % aller Werte (5 der 10 relativen Häufigkeiten für ›of‹ liegen zwischen 0,026 und 0,030). Diese und die übrigen Werte liegen innerhalb des Bereichs, der von den kurzen horizontalen Linien begrenzt wird (für ›of‹ zwischen 0,024 und 0,033) und zeigen demnach die Spannweite der Verteilung. Gut erkennbar ist der starke Abfall der Häufigkeiten mit zunehmendem Rang, d. h. die Verteilungen haben sehr unterschiedliche Mediane und Mittelwerte, was ihre Vergleichbarkeit erschwert. Die absolute Streuung der Werte nimmt ebenfalls ab, je höher der Rang des Types ist.

Eine einfache **Mittelwert-Normalisierung** erleichtert den Vergleich von Werten




Abb. 58 Die Verteilungen von 16 Types nach relativen Häufigkeiten (oben), mit Mittelwert-Normalisierung (mittig) und als z-scores (unten)

eines Types in verschiedenen Dokumenten (s. Abbildung 58, mittig). Die Formel lautet $x' = x - \mu$, das heißt man zieht von jeder Häufigkeit (x) eines Types in einem Einzeltext den Mittelwert des Types (μ – sprich ›mü‹) in der Textsammlung ab. Die Werte eines Types in einem Einzeltext sind dann positiv oder negativ, je nachdem ob das Type in einem Roman überdurchschnittlich oder unterdurchschnittlich häufig ist. Beispielsweise liegt der Mittelwert für das Type ›of‹ bei 0,028. Zieht man diesen Mittelwert jeweils von den einzelnen Häufigkeiten ab, erhält man die normalisierten Häufigkeiten. Für *The Valley of Fear* ergibt sich dann beispielsweise $0,024 - 0,028 = -0,004$, womit ›of‹ in diesem Roman seltener ist als im Mittel der Sammlung. Die so normalisierten Verteilungen haben identische Mittelwerte von Null. Dies erleichtert den Vergleich der Werte, ihre Streuung bleibt aber sehr unterschiedlich.

Um auch die Streuung vergleichbar zu machen, ist es darüber hinaus möglich, eine weitergehende Standardisierung der Verteilungen vorzunehmen und die Werte zu sogenannten **z-scores** zu transformieren (s. Abbildung 58, unten). Die Formel lautet $z = (x - \mu) / \sigma$. Hier wird von jedem Wert (x) der Mittelwert des Types (μ) in der Sammlung abgezogen und das Ergebnis durch die Standardabweichung (σ – sprich ›sigma‹) des Types geteilt. Der z-score beschreibt, wie weit ein Einzelwert vom Mittelwert der Verteilung entfernt ist, ausgedrückt in Standardabweichungen. Jede Verteilung hat nun nicht nur einen identischen Mittelwert von 0, sondern auch eine identische Standardabweichung von 1. Die unterschiedlich starke Richtung der Streuung hängt nun nicht mehr von Rang, Häufigkeit und Standardabweichung des Types ab, sondern bildet einen besser interpretierbaren Hinweis auf das Verhalten des Types in der Textsammlung. Eine solche sogenannte Merkmalskalierung bietet sich nicht nur bei Worthäufigkeiten an, sondern generell immer dann, wenn Merkmale mit stark unterschiedlichen Häufigkeiten gemeinsam in eine Berechnung eingehen sollen.

Die bis hierher behandelten Kenntnisse der deskriptiven Statistik bilden die Grundlage für die weitere Darstellung quantitativer Methoden in den Geisteswissenschaften.

Kontrastierende Analysen

Für eine große Anzahl an Fragestellungen kann es interessant sein, die gesamte **Datensammlung** in zwei Partitionen genannte Teilmengen aufzuteilen und diese Partitionen kontrastiv zu analysieren, also ihre Unterschiede herauszuarbeiten. Man geht häufig explorativ vor und ermittelt, welche Merkmale für eine Partition (die Zielpartition) gegenüber der anderen Partition (der Vergleichspartition) besonders deutlich überrepräsentiert sind und damit als typisch, charakteristisch oder distinktiv gelten können. Derartige kontrastierende Analysen können nicht nur für Texte, sondern für vielfältige Datentypen durchgeführt werden. Die grundlegende Annahme einer solchen Analyse ist, dass ein Merkmal nicht nur durch seine reine Häufigkeit in der Zielpartition für diese charakteristisch ist, sondern dass dies auch davon abhängt, ob das Merkmal in der Vergleichspartition deutlich weniger häufig ist.

Ein Funktionswort wie ›of‹ mag in Doyles Kriminalromanen sehr häufig vorkommen, da es aber in allen anderen vertretenen Romangattungen ebenfalls sehr häufig ist, kann es nicht als charakteristisch für den Kriminalroman gelten. Ein Wort wie ›murder‹ hingegen, das in Kriminalromanen sehr häufig, in allen anderen Romangattungen aber eher selten ist, kann viel eher als charakteristisch für den Kriminalro-

man gelten. Um diese Intuition algorithmisch abzubilden, werden Testverfahren so konstruiert, dass sie die Häufigkeit eines Types in der Zielpartition in Abhängigkeit seiner Häufigkeit in der Vergleichspartition (oder der gesamten Datensammlung) gewichten. So bekommen diejenigen Types in der untersuchten Teilmenge einen besonders hohen Wert zugewiesen, die in der untersuchten Teilmenge sehr häufig sind und zugleich in den übrigen Teilmengen bzw. der gesamten Sammlung sehr selten sind.

Kontrastmaße: Das denkbar einfachste Vorgehen, das eine solche Gewichtung beinhaltet, betrachtet das **Verhältnis der relativen Häufigkeiten** der Types in zwei Partitionen (vgl. Gries 2010). Für jedes Type ermittelt man die relative Häufigkeit in jeder der beiden Partitionen und dividiert den Wert in der Zielpartition durch den Wert in der Vergleichspartition. Sortiert man anschließend die resultierenden Verhältnisse absteigend, enthält der Anfang der Liste die für die Zielpartition am deutlichsten überrepräsentierten oder präferierten Types, das Ende der Liste dagegen die am deutlichsten unterrepräsentierten oder vermiedenen Types. In der Mitte der Liste finden sich diejenigen Types, die in beiden Partitionen etwa gleich häufig sind, also weder vermieden noch präferiert werden. Prüfen wir mit diesem Instrument einmal die oben formulierte Hypothese zum Verhalten von ›of‹ und ›murder‹. Zunächst erheben wir die mittleren relativen Häufigkeiten pro 1000 Tokens von ›of‹ in den vier Kriminalromanen und in den übrigen sechs Romanen. Sie lauten 26,0 für die Krimis und 29,3 für die übrigen Romane. Das Verhältnis der relativen Häufigkeiten für ›of‹ ist also $26,0/29,3 = 0,88$. Die gleiche Berechnung für ›murder‹ ergibt hingegen: $0,34/0,018 = 18,7$. Obwohl ›murder‹ eine viel geringere relative Häufigkeit in den Kriminalromanen hat als ›of‹, weist es ein vielfach höheres Verhältnis der relativen Häufigkeiten auf und ist damit deutlich charakteristischer für den Kriminalroman.

Dieses einfache Verfahren kann erste Hinweise geben, doch wird es in den meisten Fällen sinnvoll sein, etwas komplexere Berechnungen vorzunehmen (vgl. den ausgezeichneten Überblick bei Lijffijt et al. 2014). Das bisher dargestellte Verfahren betrachtet die Partitionen als Ganze und vergleicht lediglich zwei Mittelwerte. Dadurch wird die Variabilität der Werte innerhalb der Texte, die eine Partition bilden, nicht berücksichtigt. Je größer die Streuung der Werte aber ist, und je weniger symmetrisch sich die Werte um den Mittelwert verteilen, desto weniger gut repräsentieren die Mittelwerte die Verteilung und desto größer ist die Wahrscheinlichkeit, dass die Verteilungen stark überlappen, selbst wenn sich die Mittelwerte unterscheiden.

Zahlreiche Testverfahren berücksichtigen diese Überlegungen. Beim Welchs t-Test fließt die Standardabweichung und damit ein Maß für die Streuung der Häufigkeiten mit in den Vergleich zweier Partitionen ein (vgl. Oakes 1998, Kapitel 1.3). Das von John Burrows vorgeschlagene **Zeta-Maß** (Burrows 2007) berücksichtigt auf andere Weise die Streuung der Werte bzw. die konsistente Verwendung der Types in zwei Partitionen. Eine Variante des von Hugh Craig weiterentwickelten Zeta (Craig/Kinney 2009) wird hier genauer beschrieben und bringt zwei entscheidende Faktoren ins Spiel:

Erstens werden nicht ganze Partitionen verglichen, sondern einzelne Texte in den beiden Partitionen. Mehr noch, auch die einzelnen Texte werden noch einmal in gleich lange kleinere Segmente (z. B. von 2000 oder 5000 Tokens) aufgeteilt. Dies verfeinert die Analyse insbesondere dann entscheidend, wenn sehr lange Texte wie beispielsweise Romane verglichen werden. Zweitens werden nicht die Häufigkeiten

der Types in den Segmenten erhoben, sondern es wird stattdessen ermittelt, in wie vielen der Segmente ein Type mindestens einmal vorkommt. In den resultierenden Wert fließt damit vor allem ein, wie konsistent das Type in den beiden Partitionen verwendet wird. Für jedes Type wird erhoben, in wie vielen Segmenten der Zielpartition einerseits, der Vergleichspartition andererseits, es vorkommt. Diese Werte werden zu Anteilen umgerechnet, indem sie durch die Anzahl der Segmente der jeweiligen Partition geteilt werden. Und schließlich wird von dem Anteil, zu dem das Type in der Zielpartition vorkommt, der Anteil, zu dem das Type in der Vergleichspartition vorkommt, subtrahiert. Der resultierende Wert liegt zwischen -1 und 1 und drückt aus, wie charakteristisch ein Type für die Zielpartition ist. Der maximale Zeta-Wert von 1 für besonders charakteristische Types entsteht, wenn das Type in allen Segmenten der Zielpartition (Anteil = $1,0$) vorkommt, also sehr konsistent verwendet wird, und zugleich in keinem Segment der Vergleichspartition (Anteil $0,0$) vorkommt ($1 - 0 = 1$). Der minimale Zeta-Wert von -1 für extrem uncharakteristische Types entsteht, wenn das Type in keinem Segment der Zielpartition vorkommt, aber in allen Segmenten der Vergleichspartition vorkommt ($0 - 1 = -1$). Types, die in jedem Segment beider Partitionen mindestens einmal vorkommen, wie äußerst verbreitete Funktionswörter, bekommen einen neutralen Wert von 0 ($1 - 1 = 0$).

Anwendung: Um Zeta auf die Doyle-Sammlung anzuwenden, können wir die Implementierung des Stilometrie-Pakets ›stylo‹ für die Statistikumgebung R verwenden (vgl. Eder et al. 2016). Wir definieren die vier Kriminalromane als die Zielpartition, die übrigen sechs Romane als die Vergleichspartition. Die Berechnung von Craigs Zeta resultiert in der folgenden Liste der Types mit den höchsten bzw. niedrigsten Zeta-Scores (s. Abbildung 59). Ein Zeta-Wert über Null drückt aus, dass ein Type in den Kriminalromanen überrepräsentiert bzw. für diese besonders charakteristisch ist. Ein Zeta-Wert unter Null drückt aus, dass ein Type in den Kriminalromanen unterrepräsentiert ist bzw. für diese uncharakteristisch ist. Anders ausgedrückt: Es ist charakteristisch für die Kriminalromane, dass diese Wörter selten in ihnen vorkommen.

Es ist unmittelbar erkennbar, dass das Verfahren für diese Textsammlung funktioniert. Die Namen der Protagonisten der Kriminalromane (Sherlock Holmes und Watson) haben die höchsten Scores, weil sie in den Kriminalromanen sehr konsistent, in den übrigen Romanen hingegen überhaupt nicht vorkommen. Und auch viele der weiteren Begriffe sind offensichtlich dem Krimi-Genre zugehörig: ›crime‹, ›police‹, ›detective‹, ›case‹, ›murder‹. Die unterrepräsentierten Begriffe zeigen die Abgrenzung der Kriminalromane von den übrigen Romangattungen auf, wobei man einige der Types sicherlich mit den enthaltenen historischen Romanen assoziieren kann (›lord‹, ›france‹, ›king‹, aber auch ›nay‹, ›ere‹ oder ›hath‹ mit ihren historischen Schreibweisen).

Zum Abschluss dieses Abschnitts noch der Hinweis, dass die hier besprochenen Kennwerte für Verteilungen (wie Mittelwert, Median oder Standardabweichung) und vergleichenden Maße (wie das Verhältnis der relativen Häufigkeiten oder die Zeta-Berechnung) rein deskriptiver Natur sind. Über die Beschreibung von Daten hinaus geht die **Inferenzstatistik**, mit der spezifische Hypothesen über die Daten überprüft werden können. Ein wichtiger Anwendungsbereich der Inferenzstatistik ist die Frage, ob Beobachtungen, die anhand einer spezifischen Datensammlung gemacht wurden, auch auf den Untersuchungsgegenstand insgesamt verallgemeinert werden können. Beispielsweise könnte man festgestellt haben, dass in einer Sammlung von 100 Spielfilmen aus den 1960er Jahren die Western weniger Figuren haben als die




Abb. 59 Zeta-Scores. Überrepräsentierte (rechts, positives Zeta) und unterrepräsentierte (links, negatives Zeta) Types für die Kriminalromane im Vergleich zu den übrigen Romanen in der Doyle-Sammlung

Road Movies. Ist der Unterschied zwischen den Western und den Road Movies nur in der untersuchten Filmsammlung vorhanden, oder gilt dies tatsächlich für die Western und Road Movies der 1960er Jahre insgesamt?

Für die Beantwortung dieser Frage müssen eine Reihe von Faktoren berücksichtigt werden. So spielt es eine Rolle, wie deutlich der Unterschied in der Figurenanzahl ist (eine Frage der sog. Effektgröße), aber auch wie die Figurenanzahl in den Western und Road Movies jeweils verteilt ist (Form und Streuung der Verteilung). Entscheidend ist zudem das Verhältnis zwischen den analysierten 100 Filmen (der sog. Stichprobe) und allen Filmen der 1960er Jahre (der Grundgesamtheit): nur wenn die Stichprobe eine zufällige Auswahl aus allen relevanten Filmen ist – und damit ein sogenanntes »repräsentatives Sample« darstellt (s. Kap. 16.1 zu »Datensammlungen«) –, kann zuverlässig von der Stichprobe auf die Grundgesamtheit geschlossen werden. Eine Reihe von Verfahren für das Testen solcher Hypothesen und zum Schließen von der Stichprobe auf die Grundgesamtheit sind wesentlicher Bestandteil der Inferenzstatistik, können aber im Rahmen dieser Einführung nicht behandelt werden (vgl. hierfür Bortz/Schuster 2010, Kapitel I.6).

20.3 | Maschinelles Lernen

Überwachtes und unüberwachtes Lernen: Die bisher behandelten Verfahren beruhen auf einfachen Algorithmen, d. h. ein Input wird in einer genau festgelegten Folge von Rechenoperationen in ein Output überführt. Allerdings gibt es nicht für alle denkbaren Fragestellungen solche Algorithmen, weil die Fragestellungen oft neu und/oder sehr spezifisch sind und die Zusammenhänge zwischen Input und Output nicht eindeutig formuliert werden können. **Maschinelles Lernen** beruht auf der Grundidee, dass Computer anhand gegebener Beispiele selbständig Zusammenhänge und Muster erkennen und insofern »lernen« können. Dabei kann man mindestens zwei Typen des maschinellen Lernens unterscheiden: überwachtes und unüberwachtes Lernen (für anspruchsvolle Überblicksdarstellungen, vgl. Alpaydin 2010 sowie Han et al. 2012).

Beim **überwachten Lernen** ist es Aufgabe des Computers, aus einer Reihe von Beispielen einen Zusammenhang zwischen den Eigenschaften der Beispiele und den Klassen, denen die Beispiele zugehörig sind, zu erkennen. Es könnte beispielsweise darum gehen, Gemälde aufgrund ihrer Farbprofile einer Epoche zuzuordnen. In dieser Sichtweise zeichnen sich zu untersuchende Gegenstände einerseits durch eine Reihe von Merkmalen aus (hier: die Anteile verschiedener Farben), andererseits durch eine Klassenzugehörigkeit (hier: die Epochen), wobei die möglichen Klassen vorgegeben sind. Der Computer »lernt« dann aus den Beispielen, für die Merkmale und Klassenzugehörigkeit bekannt sind, den Zusammenhang zwischen bestimmten Merkmalsausprägungen und -kombinationen und der Klassenzugehörigkeit.

Die Zusammenhänge zwischen Merkmalen und Klassen können auf vielfältige Weise modelliert sein, unter anderem als Regelsystem (»wenn die Merkmale A und B beide vorhanden sind, dann gehört das Objekt zu Klasse 2«) oder als Set von Wahrscheinlichkeiten (»je stärker Merkmal A ausgeprägt ist, desto höher ist die Wahrscheinlichkeit, dass das Objekt zu Klasse 2 gehört«). Der Computer ermittelt selbständig den **Algorithmus**, mit dem sich aus den Merkmalen als Input die Klassenzugehörigkeit als Output ermitteln lässt. Anschließend kann dieser eigens ermittelte Algorithmus zunächst mit weiteren bereits klassifizierten Daten getestet und dann auf neue Daten angewendet werden, für die die Klassenzugehörigkeit nicht bekannt ist. Diese werden auf dieser Grundlage ebenfalls klassifiziert, so dass bisher unbekannte Informationen vorliegen. Dieses dreischrittige Verfahren beruht auf der Trennung von Lern-, Evaluations- und Anwendungsphase und damit auch auf der Trennung der Trainings- und Evaluationsdaten (die vorab bereits zu den richtigen Klassen zugeordnet wurden) und den Anwendungsdaten (deren Merkmale zwar bekannt sind bzw. leicht erhoben werden können, deren Klassen aber automatisch ermittelt werden sollen).

Das **unüberwachte Lernen** unterscheidet sich in zwei wesentlichen Aspekten vom überwachten Lernen. Erstens gibt es keine Trennung zwischen den verschiedenen Phasen und damit auch keine Trennung zwischen verschiedenen Datensätzen. Vielmehr operiert das Verfahren auf einem einzigen Datensatz. Zweitens werden keine Klassen vorgegeben. Stattdessen ist es das Ziel des unüberwachten Lernens, Regelmäßigkeiten, Korrelationen und andere Zusammenhänge zwischen den Merkmalen für die Bildung von möglichst gut abgegrenzten Gruppen innerhalb der Daten zu nutzen. Statt einen Zusammenhang zwischen Merkmalen und Klassen zu lernen, ermittelt das unüberwachte Lernen also Gruppen von Untersuchungsgegenständen,

die sich untereinander möglichst ähnlich, als Gruppe aber von anderen Gruppen möglichst unterschiedlich sind.

Der Computer »lernt«, Gruppen ähnlicher Gegenstände (sogenannte **Cluster**) zu bilden und voneinander zu unterscheiden, ohne diese Cluster aber mit vorgegebenen Klassenlabels zu versehen. Zu entscheiden, worin sich die Kohärenz der Cluster inhaltlich begründet und damit das Ergebnis zu interpretieren, ist dann Aufgabe des Forschers.

Maschinelles Lernen kann dabei mit zwei Motivationen durchgeführt werden: Einerseits können die Datensätze umfangreicher Datensammlungen so **klassifiziert** (überwachtes Paradigma) oder **geclustert** (unüberwachtes Paradigma) werden, wodurch neue Informationen über die Datensätze und die Struktur der Datensammlung entstehen. Andererseits kann eine Analyse der für die Klassifikation oder das Clustering entscheidenden Merkmale oder Regeln auch für ein besseres Verständnis des Untersuchungsgegenstandes genutzt werden.

Maschinelles Lernen wird in vielen Bereichen eingesetzt, die für die digitalen Geisteswissenschaften relevant sind, unter anderem für die *Optical Character Recognition* bei der Volltextdigitalisierung (s. Kap. 12 zu »Digitalisierung«) oder im *Natural Language Processing*. Dieses Forschungsgebiet ist zwischen Informatik, Computerlinguistik und Künstlicher Intelligenz angesiedelt und befasst sich mit der anwendungsbezogenen, computergestützten Verarbeitung natürlicher Sprache. Hier wird maschinelles Lernen eingesetzt, um sprachliche Äußerungen mit linguistischen Kategorien zu annotieren (u. a. Tokenisierung, Lemmatisierung, *Part-of-Speech-Tagging*) oder verschiedenste andere Merkmale zu extrahieren (u. a. Personennamen, Ortsangaben, Zeitausdrücke). Letztlich geschieht dies mit dem Ziel, Anwendungen zu entwickeln, die dazu in der Lage sind, sprachliche Äußerungen inhaltlich zu verstehen oder Sprache zu generieren (vgl. Manning/Schütze 1999).

Auch für die Bearbeitung geisteswissenschaftlicher Fragestellungen wird maschinelles Lernen eingesetzt, was hier exemplarisch anhand zweier konkreter Anwendungsbeispiele vorgestellt wird: Erstens die automatische Klassifikation von Gemälden nach verschiedenen Epochenstilen (ein Beispiel für überwachtes maschinelles Lernen), zweitens die stilometrische Clusteranalyse von Dramentexten (ein Beispiel für unüberwachtes Lernen).

Automatische Klassifikation von Gemälden

Das erste Anwendungsbeispiel für Verfahren des maschinellen Lernens kommt aus der Kunstgeschichte. Die Darstellung folgt einem Beitrag von Babak Saleh und Ahmed Elgammal, zwei US-amerikanischen Informatikern (Saleh/Elgammal 2015). Die Autoren berichten von der Nutzung von *Wikiart* (<http://www.wikiart.org>), einer digitalen Sammlung von 81.449 Gemälden, um Algorithmen zu entwickeln, die Gemälde auf der Grundlage visueller Merkmale dem passenden Künstler, Epochenstil und Genre zuordnen können. Diese Fragestellung zu automatisieren, ist ein Beispiel für überwachtes maschinelles Lernen. Die denkbaren Klassen liegen bereits fest, fraglich ist die Zuordnung der Gemälde zu diesen Klassen. Anhand der Wikiart-Studie (und mit einem vereinfachenden Fokus auf den Epochenstil der Bilder) wird nun der typische Ablauf des überwachten maschinellen Lernens illustriert.

1. Vorbereitung: Die Datensammlung wird in mehrere Teile aufgeteilt: ein Referenzset für die Trainings- und Evaluationsphase sowie ein Anwendungsset. Das Re-

ferenzset ist in der Regel kleiner als das Anwendungsset, weil die hierfür notwendige Annotation (siehe Folgeschritt) aufwändig ist. In der Wikiart-Studie gab es kein Anwendungsset, da es in der Studie zunächst um die Entwicklung geeigneter Algorithmen ging, noch nicht um die Anwendung auf ganz neue Datensätze. Für die Epochenstil-Klassifikation wurde ein Subset der Gemäldesammlung verwendet, in das nur Gemälde aus 10 verschiedenen Epochenstilen aufgenommen wurden, für die mindestens 1500 Gemälde vorhanden waren (insgesamt 63.691 Gemälde).

2. Annotation: Das Referenzset wird annotiert, das heißt die enthaltenen Datensätze werden manuell den jeweiligen Klassen zugeordnet. Durch diese Annotation wird ein Bestand an Beispielen geschaffen, bei denen die Klassenzugehörigkeit von menschlichen Experten festgestellt wurde und der damit als Referenz dienen kann, sowohl zum Lernen des Zusammenhangs zwischen Merkmalen und Klassen, als auch zur Evaluation des Algorithmus. Je schwieriger die Lernaufgabe, d. h. je komplexer oder indirekter der Zusammenhang zwischen Merkmalen und Klassen, desto mehr Daten müssen in dieser Weise annotiert werden. In der Wikiart-Studie war die Datensammlung bereits annotiert, so dass für jedes Gemälde bereits bekannt war, welchem Epochenstil (u. a. Renaissance, Expressionismus oder Pop Art) es angehört.

3. Merkmalsgenerierung: Nun wird eine geeignete Anzahl von Eigenschaften der Gemälde modelliert, d. h. so beschrieben, dass sie ohne größeren Aufwand automatisch identifiziert oder gemessen werden können, und für jedes Beispiel erhoben. Häufig muss abgewogen werden, wie einfach die Merkmale zu erheben sind, einerseits, und wie vielversprechend sie für die Klassifikation sind, andererseits. Im Fall der hier beschriebenen Studie wurden nicht nur sehr einfache, visuelle, nicht unmittelbar bedeutungstragende Merkmale extrahiert (512 Merkmale, darunter visuelle Kanten mit ihrer Länge und Richtung sowie Farbprofile), sondern auch anspruchsvollere, bedeutungstragende Merkmale (darunter ein Set von 2659 Merkmalen, die im Bild repräsentierten Objekte festhalten, wie Haus, Wolke oder Fisch). Die Erkennung solcher komplexen Merkmale ist selbst eine Aufgabe für Verfahren des maschinellen Lernens, hier konnten die Autoren aber auf bestehende Algorithmen zurückgreifen. Die Daten (Gemälde mit Merkmalen und Klassen) werden nun als eine sehr große Merkmals-Matrix repräsentiert.

4. Trainingsphase: Der Computer ›lernt‹ oder ›entdeckt‹ nun auf der Grundlage der händisch annotierten Beispiele aus dem Trainingsset den Zusammenhang zwischen den Merkmalen und der für das Trainingsset ja bekannten Klassenzugehörigkeit. Hierfür werden *classifier* verwendet, von denen zahlreiche, sehr unterschiedliche Typen zur Verfügung stehen. Im Fall der Wikiart-Studie wurde unter anderem eine Variante der sogenannten »Support-Vector-Machines« eingesetzt (vgl. Han et al. 2011, Kapitel 9.3). Dieser Typ von Klassifikatoren dient dazu, in einem vieldimensionalen Merkmalsraum die Trennung des Raums in Unterräume vorzunehmen, in denen sich jeweils Objekte möglichst nur einer Klasse befinden und dabei möglichst breite Trennbereiche zu identifizieren, in denen keine Objekte sind. Auf diese Weise soll die Klassenzuordnung möglichst eindeutig und zuverlässig erfolgen.

5. Evaluationsphase: Für die Evaluation des gelernten Zusammenhangs wird das händisch annotierte Evaluationsset genutzt. Die Evaluation dient dazu, die Erkennungsqualität einzuschätzen, die der jeweilige Algorithmus auf der Grundlage der Trainingsdaten erreichen konnte, indem die Vorhersagen des Algorithmus mit den tatsächlichen Kategorien verglichen werden. Dabei werden üblicherweise **Precision** (welcher Anteil der Objekte, die einer Klasse zugeordnet wurden, gehören auch tatsächlich dieser Klasse an) und **Recall** (welcher Anteil der Objekte, die einer be-

stimmten Klasse zugehören, wurden auch tatsächlich dieser Klasse zugeordnet) erhoben und zu einer F-Score genannten Einschätzung der Güte des Classifiers kombiniert (s. Kap. 19 zu »Information Retrieval«). Außerdem wird in der Regel eine sogenannte »Baseline« definiert. Damit ist die Klassifikationsgüte gemeint, die man mit einem sehr einfachen oder dem aktuellen Standard-Verfahren erreichen könnte. Ein neuer Algorithmus sollte zumindest besser als eine solche Baseline sein. Die Baseline in der Wikiart-Studie lag bei 0,23. Mit dem SVM-ähnlichen Verfahren und auf Grundlage der 2659 Objekt-Merkmale konnte eine Klassifikationsgüte von 0,27, mit einem anderen Classifier immerhin knapp 0,32 erreicht werden. Das ist zwar eine spürbare Verbesserung gegenüber der Baseline, angesichts der großen Anzahl von Beispielen pro Klasse und der geringen Anzahl von Klassen jedoch trotz der äußerst großen Komplexität der Aufgabe noch weit von einer endgültigen Lösung der Aufgabe entfernt.

6. Anwendungsphase: Schließlich erfolgt die Anwendung des gelernten Zusammenhangs auf die nicht annotierten Beispiele aus dem Anwendungssatz. Der Algorithmus annotiert nun automatisch (mit der bei der Evaluation festgestellten Güte) die bisher nicht annotierten Objekte ebenfalls dahingehend, welcher Klasse sie zuzuordnen sind. Dadurch können bisher nicht annotierte Objekte ebenfalls mit einer Klassenzuordnung versehen werden, so dass sie beispielsweise bei einer Schlagwortsuche in einer Datenbank gefunden werden können oder für kontrastive Analysen genutzt werden können. (Dieser Schritt entfiel bei der Wikiart-Studie, bei der es vor allem um die Entwicklung der neuen Methode selbst ging.)

Auch wenn die Herausforderungen bei der Bildklassifikation noch enorm sind: Das überwachte maschinelle Lernen ist ein mächtiges Instrument, um mit verhältnismäßig geringem manuellen Annotationsaufwand auch sehr große Datenbestände nach komplexen Kategorien durchsuchen und analysieren zu können.

Stilometrie mit Burrows' Delta

Die **Stilometrie** ist ein computergestütztes Verfahren der Erhebung stilistischer (oder allgemeiner: sprachlicher) Merkmale und ihrer Häufigkeiten in Texten, sowie der Nutzung dieser Merkmale und Häufigkeiten für die Bestimmung der Ähnlichkeit der Texte zueinander und die Klassifikation oder das Clustering der Texte (für einen Überblick vgl. Juola 2006 und Stamatatos 2009). Ursprünglich wurde die so festgestellte große Ähnlichkeit zweier Texte vor allem als Hinweis dafür interpretiert, dass die beiden Texte vom gleichen Autor geschrieben worden sind, das heißt die Methode wurde für die Autorschaftsattributions eingesetzt. Als Pionierarbeit sind die Studien von Alvar Ellegård (1962) zu einer Reihe unter dem Pseudonym »Junius« erschienener politischer Briefe sowie die Arbeiten von Frederik Mosteller und David Wallace (1963) zu den *Federalist Papers* zu nennen. Ein Meilenstein in der jüngeren Geschichte der Stilometrie ist außerdem ein Artikel von John Burrows, in dem er das stilometrische Distanzmaß »Delta« vorschlägt (Burrows 2002). Seit einigen Jahren wird zunehmend deutlich, dass auf diese Weise erhobene Ähnlichkeiten nicht nur für die Autorschaftsattributions, sondern auch für andere Fragestellungen, insbesondere Fragen der Gattungs- und Epochenzugehörigkeit, von Interesse sind.

Vieldimensionaler Vektorraum: Stilometrische Analysen dieser Art beruhen auf einer Repräsentation der Textsammlung als Merkmals-Matrix, wie sie einleitend bereits beschrieben wurde. Dies erlaubt es, die Sammlung als vieldimensionalen **Vek-**

torraum aufzufassen, was den Vorteil hat, dass dadurch unter anderem die Nutzung verschiedener Ähnlichkeitsmaße für Vektoren ermöglicht wird (s. unten und Kap. 19 zu »Information Retrieval«). Genauer: In diesem Modell wird jeder Text als ein Vektor in einem vieldimensionalen Vektorraum repräsentiert, wobei jedes Type als eine Dimension verstanden wird und die Häufigkeit eines Types in einem Text als der Wert des Vektors dieses Textes in dieser Dimension gilt. Das ermöglicht wiederum, den Grad der Ähnlichkeit bzw. Differenz zwischen einzelnen Datensätzen als räumliche Nähe bzw. Distanz zwischen den Merkmalsvektoren aufzufassen und diese Nähe bzw. Distanz mit verschiedenen Distanzmaßen zu erheben.

Stilometrische Analysen können sowohl in überwachten wie auch in unüberwachten Szenarien eingesetzt werden. In einem überwachten Szenario lernt der Computer den Zusammenhang zwischen einem bestimmten Bereich im Vektorraum und einer Klasse (wie z. B. einem Autor) und kann diese dann auf neue Texte anwenden, d. h. beispielsweise einen Text unbekannter Autorschaft in Abhängigkeit von seiner Position im Vektorraum einem der in der Textsammlung vertretenen Autoren zuordnen. In einem unüberwachten Szenario dagegen steht die Erkenntnis über die mehr oder weniger große Nähe oder Distanz (d. h. Ähnlichkeit oder Unterschiedlichkeit) von mehreren Untergruppen von Texten in der analysierten Textsammlung und die Platzierung einzelner Texte innerhalb solcher Gruppen im Fokus.

Anwendungsbeispiel: Der folgende Anwendungsfall betrifft die Analyse einer Sammlung französischer Komödien aus dem 17. Jahrhundert und ist ein unüberwachtes Szenario. Die hier verfolgte Fragestellung ist die, ob das Stück *Dom Garcie de Navarre* von 1661, das üblicherweise Molière zugeschrieben wird, nicht doch von Pierre Corneille verfasst wurde, wie dies vereinzelt vorgeschlagen wurde (vgl. Schöch 2014). Im Vordergrund steht also die Ähnlichkeit dieses Stücks zu den übrigen, Molière und Pierre Corneille eindeutig zuzuordnenden Stücken. Das konkrete Vorgehen (das sich methodisch an dem inzwischen klassischen Burrows' Delta-Verfahren orientiert), gliedert sich in die folgenden Schritte:

1. Vorbereitung der Textsammlung: Zunächst einmal müssen eine für die verfolgte Fragestellung geeignet zusammengesetzte Textsammlung erstellt und die zu analysierenden Texte so vorbereitet werden, dass sie sinnvoll vergleichbar sind (s. Kap. 16 zu »Aufbau von Datensammlungen«). Insbesondere die Auswahl der zu analysierenden Texte in Abhängigkeit von der Fragestellung gehört zur Vorbereitung der Textsammlung. Im Fall der Komödien-Studie ist die Quelle der digitalen Texte eine dem französischen Theater gewidmete Plattform (<http://www.theatre-classique.fr>). Die hier verwendete Textsammlung enthält 46 Komödien aus der zweiten Hälfte des 17. Jahrhunderts, die von verschiedenen Autoren (Pierre Corneille, Thomas Corneille, Molière, Regnard und Scarron) verfasst wurden, zudem die strittige Komödie *Dom Garcie de Navarre*.

2. Merkmals-Matrix: Nun werden die Liste aller in der Textsammlung vertretenen Types erstellt, die Häufigkeiten jedes Types in jedem Text ermittelt und die Ergebnisse in einer Merkmals-Matrix festgehalten. Im Fall der Dramenanalyse erfolgen dieser und die weiteren Schritte mit dem stilometrischen Analysetool »styleo«, das als ein Paket für die Statistik-Umgebung R zur Verfügung steht (Eder et al. 2016). Für die Komödien-Studie ergibt sich eine Merkmals-Matrix mit 47 Spalten (eine Spalte pro Drama) und 5000 Zeilen (für die häufigsten 5000 Types in der Sammlung; für weitere Types werden die Häufigkeiten nicht erhoben).

3. Merkmals-Behandlung: Erstens wird die Merkmals-Matrix nun nach absteigender Häufigkeit der Types in der Textsammlung insgesamt sortiert und eine Be-

grenzung auf eine bestimmte Anzahl der häufigsten Types (sog. *most frequent words*) festgelegt. Zweitens werden die absoluten Häufigkeiten in »z-scores« überführt (wie im Abschnitt zu »Normalisierung von Verteilungen« beschrieben). Die Begrenzung der Wortliste legt u. a. fest, ob nur Funktionswörter oder auch weitere Wörter in den Vergleich der Texte mit einbezogen werden. Die Transformation der Häufigkeiten in z-scores vermeidet, dass nur die 20 oder 30 häufigsten Types den Merkmalsvektor und damit auch die Ähnlichkeitsbestimmung dominieren bzw. sorgt dafür, dass die Häufigkeitsunterschiede aller berücksichtigter Types in gleicher Weise in die Messung der stilistischen Ähnlichkeit der Texte zueinander eingehen. Im Fall der Komödien-Studie werden die 2000 häufigsten Types berücksichtigt.

4. Distanzmaß: Nun wird ein Distanzmaß angewandt, um die relative stilistische Unterschiedlichkeit bzw. Ähnlichkeit aller Texte zueinander zu ermitteln. Zweck eines Distanzmaßes ist es, die zahlreichen kleinen Unterschiede in der Häufigkeit der Types in zwei Texten zu einem einzigen Wert zusammenzufassen, der dann die zusammengenommene Unterschiedlichkeit bzw. Ähnlichkeit der beiden Texte ausdrückt. Verschiedene Distanzmaße unterscheiden sich darin, wie sie diesen zusammenfassenden Wert ermitteln. Drei wichtige Distanzmaße sind in Abbildung 60 dargestellt.

Bei der **Manhattan-Distanz** werden die absoluten Distanzen zweier Vektoren in jeder einzelnen Dimension addiert. Der Name leitet sich von dem Weg ab, den man in Manhattan wegen der rechtwinklig angelegten Straßenblocks von einem Ort zum anderen nehmen muss. Die Distanz in jeder einzelnen Dimension fließt mit gleichem Gewicht in die Gesamtdistanz ein.

Die **euklidische Distanz** hingegen entspricht der Vogelfluglinie zwischen zwei Orten; hier werden die Distanzen in jeder Dimension erst quadriert, dann summiert, bevor die Wurzel aus der Summe gezogen wird. Große Distanzen in einer einzelnen Dimension werden durch die Quadrierung stärker gewichtet als kleinere Distanzen.




Abb. 60 Drei Distanzmaße. Es liegen zwei Texte A und B vor, sowie zwei Dimensionen x und y.
Manhattan-Distanz = $|4-2| + |2-5| = 2 + 3 = 5$.
Euklidische Distanz = $(|4-2|^2 + |2-5|^2)^{1/2} = (4 + 9)^{1/2} = 3,6$.
Kosinus $\alpha = 41,6^\circ$

Beim **Kosinus-Maß** schließlich wird nicht die Distanz zwischen den Vektoren, sondern der Winkel der Vektoren zueinander berechnet. Das wirkt sich dergestalt aus, dass nur die Richtung, nicht aber die Länge eines Vektors für das Ergebnis der Berechnung entscheidend ist. In jedem Fall drückt der resultierende Wert die Nähe der beiden jeweiligen Vektoren im Vektorraum aus und damit, so die Annahme, auch die stilistische bzw. sprachliche Ähnlichkeit der beiden jeweiligen Texte.

Im Fall der Komödien-Studie wurde das klassische Burrows' Delta verwendet, bei dem die standardisierten Häufigkeiten (z-scores) in Kombination mit der Manhattan-Distanz verwendet werden. Es ergibt sich hieraus eine Ähnlichkeits-Matrix von 47 mal 47 Einträgen, in der die Distanzen aller Komödien zueinander festgehalten sind.

5. Clustering und Visualisierung: Um diese immer noch große Menge an Informationen in eine lesbare Form zu bringen, wird die Ähnlichkeitsmatrix nun (mit einem von mehreren denkbaren Verfahren) in eine Cluster-Matrix überführt, auf deren Grundlage ein hierarchisches **Baumdiagramm** (ein sogenanntes **Dendrogramm**) erstellt wird. Im Fall der Komödien-Studie wurde das weit verbreitete Ward-Clustering verwendet, womit sich das in Abbildung 61 gezeigte Dendrogramm ergibt. Es liest




Abb. 61 Stilometrisches Dendrogramm der Ähnlichkeitsbeziehungen zwischen 47 französischen Komödien des 17. Jahrhunderts, darunter ein Stück umstrittener Autorschaft (Label: #DomGarcie)

sich wie folgt: Ganz rechts stehen alle analysierten Komödien, sie sind die Blätter des Baumdiagramms; zwei Dramen, die durch eine Linie direkt verbunden werden, sind sich zueinander ähnlicher, als zu irgendeinem anderen Drama und bilden einen Ast des Diagramms. Zwei Äste, die durch eine Linie direkt verbunden sind, bilden wiederum zwei Gruppen von Dramen, die sich zueinander sehr ähnlich sind. Je weiter links im Diagramm zwei Dramen bzw. Äste aufeinandertreffen, desto weniger ähnlich sind sie sich. Den Wert des Distanzmaßes an einem bestimmten Knotenpunkt kann man bestimmen, indem man vertikal nach unten auf die X-Achse projiziert und dort den entsprechenden Wert abliest. Ein Wert von 0 würde zwei identische Texte kennzeichnen, im Fall der Komödien-Studie liegt die Mehrzahl der Werte zwischen 0,5 und 1,5.

6. Interpretation: Der letzte Schritt ist die Interpretation des Dendrogramms im Licht des über die Textsammlung bekannten Wissens (u. a. Autoren, Gattungen, Entstehungszeit, Inhalt) und dem Wissen um die Parameter des Verfahrens (u. a. Anzahl der Wörter, Distanzmaß). Die im Dendrogramm sichtbaren Ähnlichkeitsbeziehungen und Gruppenbildungen sind nicht als absolute, objektive Ergebnisse zu verstehen, sondern als interpretationsbedürftiges Produkt zahlreicher Faktoren, die in komplexer Weise miteinander interagieren können.

Im Fall der Komödien-Studie wird zunächst einmal deutlich, dass die Textsammlung sich in zwei große Gruppen gliedert, die der Unterscheidung von Komödien in **Prosa** (untere Gruppe mit Komödien von Molière und Regnard) und in **Versform** (obere Gruppe mit Komödien aller Autoren) entsprechen. Innerhalb dieser Gruppen zeigen sich weitere Untergruppen, die jeweils den Komödien eines Autors entsprechen. Mit den gewählten Parametern ist also eine zuverlässige Gruppierung von Stücken nach ihren Autoren möglich. Das umstrittene Stück aber, *Dom Garcie de Navarre*, erscheint an einem überraschenden Ort: nicht bei Molière, aber auch nicht bei Pierre Corneille, sondern in geringem Abstand zu zwei Stücken von Thomas Corneille.

Dieses Ergebnis, das sich auch bei anderen Parametersetzungen in relativ robuster Weise so ergibt, wirft Fragen auf: Hat sich die Forschung zu *Dom Garcie* gleicht doppelt getäuscht, oder spielen andere Faktoren hier eine Rolle? Es stellt sich heraus, dass vermutlich die Gattungszugehörigkeit des Stücks für das Ergebnis entscheidend ist. Denn *Dom Garcie* ist eine sogenannte ›heroische Komödie‹, die Merkmale von Komödie und heroischem Roman vermischt und der Tragikomödie nicht unähnlich ist. Molière hat nur eine einzige Komödie dieses Typs geschrieben, so dass sich in seinem Werk kein unmittelbar verwandtes Stück finden lässt, dem *Dom Garcie* besonders ähnlich wäre. Thomas Corneille dagegen hat mehrere Komödien geschrieben, die als heroische Komödien gelten können oder eine ihnen ähnliche Thematik haben. Dass *Dom Garcie* nun Thomas Corneille zugeordnet wird, ist demnach weniger als Hinweis auf die Autorschaft des Stücks zu werten, denn als Hinweis auf die gattungsbezogene Verwandtschaft des Stücks zu denen Thomas Corneilles. Und es zeigt, dass stilometrisch gewonnene Aussagen zur Autorschaft auch dann von Faktoren wie der literarischen Gattung beeinflusst sein können, wenn es sich um eine eigentlich relativ homogene Textsammlung wie derjenigen der Komödien des 17. Jahrhunderts handelt.

20.4 | Neuere Entwicklungen

Quantitative Verfahren können in den digitalen Geisteswissenschaften für zahlreiche Anwendungsfelder und Fragestellungen eingesetzt werden, unter anderem im Sinne statistischer Beschreibungen von Datensammlungen, der kontrastiven Analyse mehrerer Datensammlungen oder ihrer Teile, der überwachten Klassifikation von Untersuchungsgegenständen oder der explorativen und unüberwachten Gruppenbildung auf der Grundlage der Ähnlichkeit von Untersuchungsgegenständen. Diese und ähnliche Verfahren der statistischen Analyse und des maschinellen Lernens werden für die Bearbeitung vielfältiger geisteswissenschaftlicher Fragestellungen verwendet. Für die digitalen Geisteswissenschaften vielversprechende, neuere Entwicklungen im Bereich quantitativer Verfahren der Datenanalyse sind vektorenbasierte Modelle für die Repräsentation des semantischen Gehalts von Wörtern (*word embeddings* vgl. Mikolov et al. 2013) sowie das »Deep Learning«, eine moderne Form neuronaler Netze, die für besonders herausfordernde Aufgaben wie die Objekterkennung in Bildern eingesetzt werden (*Word embeddings* vgl. LeCun et al. 2015). Diese und weitere Verfahren weisen auf das Potential hin, neueste Entwicklungen im Bereich der Künstlichen Intelligenz (vgl. Russel und Norvig 2009) zukünftig auch für die Bearbeitung geisteswissenschaftlicher Fragestellungen einzusetzen.

Literatur

- Alpaydin, Ethem: *Introduction to Machine Learning*. Cambridge ²2010.
- Baroni, Marco/Evert, Stefan: »Statistical methods for corpus exploitation«. In: Anke Lüdeling/Merja Kytö: *Corpus Linguistics. An International Handbook* 2. Berlin 2009, 777–803.
- Blei, David M.: »Probabilistic topic models«. *Communications of the ACM* 55.4, 2012: 77–84.
- Burrows, John: »Delta«: A measure of stylistic difference and a guide to likely authorship«. In: *Literary and Linguistic Computing* 17/3 (2002), 267–87.
- Burrows, John: »All the way through: Testing for authorship in different frequency strata«. In: *Literary and Linguistic Computing* 22/1 (2007), 27–47.
- Bortz, Jürgen/Schuster, Christof: *Statistik für Human- und Sozialwissenschaftler*. Berlin 2010.
- Craig, Hugh/Kinney, Arthur F.: *Shakespeare, Computers, and the Mystery of Authorship*. Cambridge 2009.
- Eder, Maciej/Kestemont, Mike/Rybicki, Jan: »Stylometry with R: A package for computational text analysis«. In: *The R Journal* 16/1 (2016), 1–15.
- Ellegård, Alvar: *A Statistical Method for Determining Authorship: The Junius Letters, 1769–1772*. Gothenburg 1962.
- Gries, Stefan Th.: »Useful statistics for corpus linguistics«. In: Aquilino Sánchez/Moisés Almela (Hg.): *A Mosaic of Corpus Linguistics: Selected Approaches*. Frankfurt a. M. 2010, 269–291.
- Han, Jiawei/Kamber, Micheline/Pei, Jian: *Data Mining: Concepts and Techniques*. Burlington ³2011.
- Jannidis, Fotis: »Methoden der computergestützten Textanalyse«. In: Ansgar Nünning/Vera Nünning (Hg.): *Methoden der literatur- und kulturwissenschaftlichen Textanalyse*. Stuttgart/Weimar 2010, 109–132.
- Jockers, Matthew L.: *Macroanalysis – Digital Methods and Literary History*. Champaign, Ill. 2013.
- Juola, Patrick: »Authorship attribution«. In: *Foundations and Trends in Information Retrieval* 1/3 (2006), 233–334.
- LeCun, Yann/Bengio, Yoshua/Hinton, Geoffrey: »Deep learning«. In: *Nature* 521/7553 (2015), 436–444.
- Lijffijt, Jeffrey/Nevalainen, Terttu/Säily, Tanja/Papapetrou, Panagiotis/Puolamäki, Kai/Mannila, Heikki: »Significance testing of word frequencies in corpora«. In: *Digital Scholarship in the Humanities* 31/2 (2014), 374–97.
- Manning, Christopher S./Schütze, Hinrich: *Foundations of Statistical Natural Language Processing*. Cambridge 1999.

- Mikolov, Tomas/Chen, Kai/Corrado, Greg/Dean, Jeffrey: »Efficient estimation of word representations in vector space« (2013), <http://arxiv.org/abs/1301.3781> (31.10.2016).
- Moretti, Franco: *Graphs, Maps, Trees: Abstract Models for a Literary History*. London 2005.
- Mosteller, Frederick/Wallace, David L.: »Inference in an authorship problem«. In: *Journal of the American Statistical Association* 58/302 (1963), 275–309.
- Oakes, Michael P.: *Statistics for Corpus Linguistics*. Edinburgh 1998.
- Piper, Andrew: »There will be numbers«. *Cultural Analytics* 1 (2016). Online: <http://culturalanalytics.org/2016/05/there-will-be-numbers/> (31.10.2016).
- Russell, Stuart J./Norvig, Peter: *Artificial Intelligence. A Modern Approach*. Boston ³2009.
- Saleh, Babak/Elgammal, Ahmed: »Large-scale classification of fine-art paintings: Learning the right metric on the right feature« (2015), <http://arxiv.org/abs/1505.00855> (31.10.2016).
- Schöch, Christof: »Corneille, Molière et les autres. Stilometrische Analysen zu Autorschaft und Gattungszugehörigkeit im französischen Theater der Klassik«. In: Christof Schöch/Lars Schneider (Hg.): *Literaturwissenschaft im digitalen Medienwandel*. Beihefte von *Philologie im Netz* 7 (2014), 130–57. Online: <http://web.fu-berlin.de/phn/beiheft7/b7t08.pdf> (31.10.2016).
- Stamatatos, Efstathios: »A survey of modern authorship attribution methods«. In: *Journal of the Association for Information Science and Technology* 60/3 (2009), 538–556.

Christof Schöch

21 Geographische Informationssysteme

Unter der Prämisse des **Spatial Turn** sind Aspekte des Raums verstärkt in den Fokus geisteswissenschaftlicher Forschungen gerückt, wobei auch Methoden der Geographie adaptiert und für die jeweilige Disziplin mehr oder weniger modifiziert angewandt wurden und weiterhin werden (Warf/Arias 2009). Dieser Paradigmenwechsel vollzog sich beispielsweise in der Archäologie schon in den 1990er Jahren und in den Geschichtswissenschaften bereits kurz danach (vgl. Conolly/Lake 2008). Auch in den Philologien entstanden im neuen Jahrtausend einige Projekte mit deutlichem Raumbezug. Der Spatial Turn, wenn es denn ein ›Turn‹ in der jeweiligen Disziplin gab, ist weiterhin von großem Interesse in zahlreichen geistes- und kulturwissenschaftlichen Disziplinen. So wird mittlerweile prägnanter zusammenfassend von **Spatial Humanities** gesprochen, die alle Forschungsfragen mit Raumbezug gemein haben (Bodenhamer 2010).

Ein wichtiges Element dieses Feldes ist das Interesse an **Karten**. Dieses Interesse, das auch theoretisch ausgeprägt sein kann, zeigt sich in der vielfältigen Verwendung von Karten zur Visualisierung von Rauminformationen. Eine zentrale Komponente bei digitalen Visualisierungen sind **Geographische Informationssysteme** (GIS). Ein GIS ermöglicht die Visualisierung, Analyse und Archivierung von raumbezogenen Daten und darüber hinaus auch von weiteren Kontexten, z. B. Texte oder Bilder. Rückgrat des GIS ist ein Datenbanksystem, in dem die Daten erfasst, verwaltet, an-




Abb. 62 Modell eines archäologischen Informationssystems als Beispiel für ein fachspezifisches GIS

gereichert und ausgewertet werden. Im GIS können beispielsweise historische und topografische Karten mit ergänzenden Informationen aus schriftlichen Quellen und bildlichen Darstellungen, wie z. B. Landschaftsfotografien oder Gebäudeaufnahmen, in einem System umfassend bearbeitet werden. Als Adaption eines allgemeinen GIS werden beispielsweise in den archäologischen Wissenschaften auf die Fachbedürfnisse spezifisch angepasste ›Archäologische Informationssysteme‹ entwickelt (s. Abb. 62), die gleichzeitig als virtuelle Forschungsumgebung kollaboratives Arbeiten ermöglichen, dezentrale Datensätze mit Raumbezug durch Schnittstellen zusammenbringen (Karte, Bild, Text und Messdaten), diese kontextualisieren und durch Einbindung weiterer externer Werkzeuge, neben der herkömmlichen Visualisierung und Analyse, auch der Archivierung und Publikation der Raumdaten dienen.

Nach (21.1) einer knappen Einführung in die grundlegende Struktur eines GIS sowie die dort verwendeten Datenstrukturen werden (21.2) ein Problem von Karten und etablierte Lösungsansätze diskutiert: Zweidimensionale Karten sollen mit möglichst wenig Verzerrungen eine dreidimensionale Wirklichkeit abbilden, nämlich Teile einer Kugeloberfläche. Ein weiteres Problem (21.3), das GIS lösen müssen, ist der Umgang mit der Unsicherheit von Raumangaben, insbesondere in historischen Quellen. Nach einem Überblick über die beiden Typen von Karten, Raster- und Vektorkarten, folgt eine Darstellung des prinzipiellen Aufbaus eines GIS, sowie die Erläuterung einiger GIS-Methoden. Zuletzt wird der Zugriff auf Kartenrepositorien anhand eines wichtigen Beispiels diskutiert.

21.1 | GIS Datenmodelle

Datenbanken sind die konzeptionelle Grundlage eines jeden GIS, wobei die Daten in unterschiedlichen Modellen miteinander verknüpft werden können. Um möglichst komfortabel mit den Datenbanken arbeiten zu können, benötigt der Anwender einen schnellen Datenzugriff, so dass hohe Anforderungen an das Datenmodell in einem GIS gestellt werden. Im GIS wird dies durch **logische Datenmodelle** erreicht, die die logischen Zusammenhänge zwischen den Objektmengen in den Datensätzen der Datenbank berücksichtigen. Diese können als hierarchische, netzwerkartige, relationale, objektrelationale oder objektorientierte in sehr unterschiedlichen Modellierungs-Paradigmen umgesetzt werden, die grundlegend die kartierbare und auswertbare Basis eines GIS darstellen (Bill 2012, 397).

Relationale Datenbanksysteme (s. Kap. 8.1): diese haben sich in der Praxis jedoch seit längerem bewährt und im funktionalen Umfang durchgesetzt, da es in einem relationalen Datenbanksystem zu einer strikten Trennung von physikalischer Speicherung und logischer Datenmodellierung durch die Entkopplung der Datenbreitstellung und -anwendung kommt. In der fundamentalen Tabellenstruktur der relationalen Datenbanken werden Objekten und Beziehungen Attribute zugeordnet. Besonders von Vorteil ist die Eigenschaft der relationalen Datenmodelle, dass Beziehungen zwischen den Objekten als Werte in Tabellen, wie Objekte selbst, verwaltet werden, so dass Entitäten und auch Relationen einheitlich repräsentiert sind. Darüber hinaus ist die Tabellenform gut überschaubar, um die Daten einzusehen, zu überprüfen und zu bearbeiten. Relationale Datenbank-Modelle erlauben die qualitativ und quantitativ vollständige Abbildung von Geoobjekten durch ihre Nutzbarkeit mit in das GIS eingebundenen relationalen **Datenbankmanagementsystemen** (RDBMS) bzw. allgemeinen Datenbankmanagementsystemen (DBMS) (De Lange 2013, 308).

Datenbankmanagementsysteme ermöglichen den indirekten Datenzugriff und die -abfrage der Geometrieobjekte und ihre Sach- sowie Metainformationen über die **SQL-Schnittstelle** (Structured Query Language) der Datenbank. Und sie erlauben dadurch eine Konsistenzerhaltung zwischen Geometrie-, Sach- und Metadaten im GIS, wobei die Daten mittelbar miteinander verknüpft sind, d. h. z. B. die Koordinatenwerte eines Kartenpunktes mit ergänzenden und beschreibenden Informationen liegen in der Datenbank in jeweils separaten Tabellen vor. Die Auszeichnung der Daten in den Tabellen der Datenbank erfolgt im interoperablen Standard des GML (Geography Markup Language), das eine spezifische Adaption von XML darstellt (Kappas 2012, 164–168).

Die verschiedenen Datentypen der Geometrie- und Sachdaten können im einfachsten Fall aber auch in den Spalten nur einer Tabelle vorliegen, auf die im GIS unmittelbar zugegriffen wird, d. h. in diesem Fall: Die Koordinatenwerte X und Y eines Kartenpunktes im GIS befinden sich in zwei Spalten und die ergänzenden und beschreibenden Informationen in den weiteren Spalten ein und derselben Tabelle. Dies kann bei weniger komplexen Datensätzen bezüglich der Einfachheit und Übersichtlichkeit durchaus von Vorteil sein. Die Abfragemöglichkeiten sowie die Performanz werden aber bei großen Tabellen deutlich eingeschränkt, so dass nur im Ausnahmefall oder bei sehr wenig strukturierten Daten eine einzige Tabelle die Kartierungsgrundlage des GIS darstellen soll. Darüber hinaus sind die Abfragemöglichkeiten der Informationen aus einer einzelnen Tabelle gegenüber einer strukturierten Datenbank sehr eingeschränkt, was sich wiederum negativ auf die **Analysefunktionen** im GIS und die Interoperabilität mit anderen in GML ausgezeichneten Datensätzen aus bestehenden Repositorien, die mit dem GIS verknüpft werden können, auswirkt (s. Kap. 21.7: Kartenrepositorien via Web WMS).

Datentypen und -formate im GIS

Geodaten können in sehr unterschiedlichen Formaten verschiedener Standards vorliegen. Gemeinsam haben sie alle, dass sie einen eindeutigen Raumbezug in Form von **Koordinaten** aufweisen (Bill 2010, 263–295). Primär erhobene Geodaten sind beispielsweise GPS- (Global Position System) oder Laserscandaten (LiDAR – Light Detection and Ranging), die bereits bei ihrer Entstehung mit Koordinatenpaaren ausgezeichnet werden. Grundlegend muss eine Geometrie (z. B. ein Ort), die in einem GIS kartiert werden soll, mindestens neben den X- und Y-Koordinaten darüber hinaus noch eine unverwechselbare **Identifikations-Nummer** (ID) aufweisen, die meist aus einem in der Datentabelle fortlaufenden Zahlenwert besteht. Zusätzlich verfügen primär erhobene Geodaten oft noch über gemessene und mit den X- und Y-Koordinaten verbundene Höhenwerte (Z-Werte), sodass sie als 2,5-dimensionale Geländemodelle im GIS mit vielfältigen Verfahren interpolierbar sind, aber im Vergleich zu 3-dimensionalen Modellierungen nicht alle räumlichen Lagen in der dritten Dimension bei in Bezug zu den 2D-Koordinatenwerten bestehenden, senkrechten Überschneidungen, wie beispielsweise in einer Höhle, darstellen können.

Geographische Angaben bzw. Lokalitätsangaben aus einem literarischen Werk, wie z. B. aus Reiseberichten, sind noch keine **Geodaten**, da ihr eindeutiger Raumbezug nicht gegeben ist (Piatti/Hurni 2011). Erst durch Ergänzung der beispielsweise in einem mittelalterlichen Manuskript erwähnten Ortschaften in eine mit Geo- und Sachdaten strukturierte Ortsnamendatenbank mit den den Orten entsprechenden,

angereicherten X- und Y-Koordinaten (Latitude und Longitude) entstehen Geodaten, und zwar in sekundärer Form (s. Kap. 21.3: Unsicherheiten von Raum- und Zeitangaben in historischen Quellen; zum »Einsatz von Geoinformationssystemen in Geschichte und Archäologie« vgl. Dross 2006).

Auch Metadaten in den Archiven und Bibliotheken, die die Daten der Bücher oder deren Digitalisate beschreiben, enthalten teilweise Geodaten in den Datensätzen der »Integrated Authority File« (**Gemeinsame Normdatei** – GND). Diese Metadaten werden von den Bibliotheken kooperativ nach international genormten Standards aufgenommen und dienen primär der Literatur- und Autorenrecherche. Sie beinhalten Angaben u. a. zur Lebenszeit, zum Namen mit Aliase, thematischen Sachgebieten des Autors, Erscheinungsjahr, Koauthorschaften und Erscheinungsort (teils sogar mit internationalen Koordinaten versehen). Die GND ist somit eine interessante Quelle mit raumbezogenen Daten und in einem GIS prinzipiell auswertbar.

Im GIS werden die Geodaten synonym auch als **Raumdaten** bezeichnet, die minimal aus ID und Koordinatenpaaren bestehen und im einfachsten Fall einen Punkt als Geometrie darstellen. Sie können aber auch in etwas komplexerer Form Geometrien in Form von Linien und Flächen (Kreisen bzw. Polygonen etc.) vorliegen, wobei die bei einem Punkt einfachen Koordinaten eines Koordinatenpaars mit Koordinatenpaaren von/bis (für eine Linie oder ein Rechteck) oder mit entsprechenden Zwischenvektoren (für ein Polygon) versehen sein müssen (Bill 2012, 28). Geodaten können beispielsweise als georeferenzierte Rasterkarten, Vektorkarten (s. Kap. 12.1) oder aus verknüpften Datenbanken vorliegen. Sie sind als einzelne Layer in das GIS zu laden, was in Form eines **Shapefile**-Dateienbündels lokal oder von externen Laufwerken via World-Map-Server (WMS) geschehen kann.

Grundlegend werden im GIS in dreierlei Datentypen unterschieden: Raumdaten (Geodaten), Sachdaten und Metadaten (s. Kap. 7.1).

- Die **Raumdaten** enthalten als minimale Anforderung an die Kartierbarkeit die basalen georeferenzierten Objektinformationen mit den Koordinatenwerten enthalten (vgl. Kappas 2012, 49–52).
- **Sachdaten** stellen eine Erweiterung zu den zugehörigen Raumdaten dar und sind somit ergänzende Informationen in den dem GIS zugrundeliegenden Datentabellen (z. B. Kreis, Ort, Straßenname, Fundart etc.).
- **Metadaten** beschreiben die Daten (z. B. Datum, Bearbeiter, Koordinatensystem, Erhebungsgrund, Copyright etc.) beider zuvor genannten Datentypen (vgl. De Lange 2013, 256–258).

In einem GIS werden all diese Informationen in zusammenhängenden Dateienbündeln gespeichert, die in ihrer Gesamtheit jeweils einen **Layer** bilden. Die unterschiedlichen Datentypen, wie Raum- und Sachdaten, werden dabei in mindestens drei zugehörigen Dateiformaten des Dateienbündels im PC gespeichert, die nur im Zusammenspiel die koordinatengenaue Projektion im GIS ermöglichen. Die Dateienbündel dienen des Weiteren dem Datenaustausch von einem PC zu einem anderen via Datenträger oder USB-Stick etc., aber nur, wenn das Datenbündel mit allen drei Teildateien zusammenhängend (in einem Ordner) transferiert wird.

- **Shapefile**: Die Hauptdatei eines Layer-Dateienbündels ist die mit verschiedenen GIS-Software interoperable Shapefile (shp), die zur Speicherung der Geometriedaten (Raumdaten der Objekte) dient. In der Shapefile wird immer nur ein definierter Typ von Geometriedaten (Punkte, Linien, Flächen oder Polygone) mit der

Anzahl seiner Elemente abgelegt, was beim Kartieren zuvor bedacht werden muss, da Durchmischungen der Geometrien in einem Layer unterbleiben müssen.

- **dbase-file:** Eine zweite, dem Dateienbündel zugehörige Datei im dBASE-Format speichert die Sachdaten im zu fast allen relationalen SQL-Datenbanken kompatiblen dbf-Format.
- **shx-file:** Die dritte Datei des Dateienbündels wird im shx-Format gespeichert, das als Index der Geometrie der Verknüpfung zu den Sachdaten (auch teils Attributdaten genannt) dient.
- **prj-file:** Automatisiert wird von manchen GIS das verwendete Koordinatensystem in einer zusätzlichen Datei (im prj-Format) gespeichert.
- **shp.xml-file:** Optional können die zugehörigen Metadaten im GIS im shp.xml-Format gespeichert werden, das prinzipiell eine erweiterte Textdatei für den Datenaustausch darstellt.

In allen GIS müssen die einzeln bearbeitbaren Layer bei Veränderungen jeweils separat gespeichert werden. Und darüber hinaus kann die Lage der Layer zueinander, wie sie im Kartenfenster gezeigt wird, und die Verknüpfungspfade der einzelnen Layer auf internen Laufwerken oder externen Servern gespeichert werden, indem diese Informationen zum aktuellen Projekt-Arbeitsstand im, je nach verwendeter GIS-Software, spezifischen Format abgelegt werden. Dies ermöglicht das Wiederherstellen der letzten Arbeitssitzung am PC, ohne dass alle zuvor gemachten Projekteinstellungen in der Layerordnung etc. wieder neu eingestellt werden müssten.

21.2 | Raumprojektionen in gängigen Koordinatensystemen im Vergleich

Koordinatensysteme dienen als modellhafte Abbildungen der Realität der eindeutigen **Georeferenzierung**, d. h. der Verortung von Objekten im geometrischen Raum. Dabei bilden Breiten- und Längengrade ein geographisches, zweidimensionales Koordinatensystem der Erde, das in X- und Y-Koordinatenwerte (Latitude und Longitude, bzw. Hoch- und Rechtswert) unterteilt ist (Kappas 2012, 22 ff.). Die Breiten- und Längengrade sind Winkelmaße, die die Lage eines Objektes durch den Schnittpunkt des Abstands vom Äquator (geographische Breite) und des Abstands vom **Nullmeridian** (geographische Länge) eindeutig definieren (Hennermann/ Woltering 2012, 80–87). Der Nullmeridian ist eine willkürlich festgelegte Linie vom Nord- zum Südpol, der Ende des 19. Jahrhunderts ausgehend vom Observatorium Greenwich in London definiert wurde. Alternativ dazu kann der Nullmeridian auch in der geographischen Länge von Paris, Potsdam oder Moskau mit dem Wert 0 festgelegt sein.

Die Erde entspricht jedoch nicht einem geometrischen Kugelkörper, sondern eher einem Ellipsoid oder genauer einem asymmetrischen Geoid mit zahlreichen regionalen gravitationsbedingten Überhöhungen und Senken (Sansò/Sideris 2013). Um diesen regionalspezifischen Eigenheiten des **Erd-Geoids** (bzw. des sogenannten Bessel-Ellipsoids oder Referenzellipsoid für Europa; vgl. Bessel 1842) möglichst nahe zu kommen, was mit einer möglichst hohen Lagegenauigkeit der mit Koordinatenwerten beschriebenen Objekte einhergeht, sind weltweit viele hundert verschiedene Koordinatensysteme mit Subsystemen in Gebrauch (weiterführend: Bill 2012, 162–173).

Grundsätzlich kann die Position eines Punktes oder Objektes im Raum in verschiedenen Koordinatensystemen dargestellt werden, jedoch weisen die verwendete

ten Koordinatensysteme in unterschiedlichen Regionen der Erde verschieden hohe Genauigkeiten auf. In Deutschland sind in den Institutionen, Archiven, Hochschulen und Behörden der Bundesländer verschiedene Koordinatensysteme im Einsatz. Dies hat zur Folge, dass im Rahmen von überregionalen GIS-Projekten (mit einer hohen Anzahl verschiedener Karten aus unterschiedlichen Regionen) heterogene Georeferenzierungen vorliegen, die aufwendig auf ein Bezugssystem transformiert werden müssen, damit sie im GIS projektionskonform miteinander kombinierbar sind. Daher ist es vor Projektbeginn dringend ratsam, im Rahmen der Quellenrecherche auch die verwendeten Koordinatensysteme zu prüfen, um in der folgenden Datenzusammenführung möglichst wenige Karten auf ein einheitliches Projekt-Koordinatensystem transformieren zu müssen. Internationaler Standard im Bereich der Spatial Humanities ist das unten beschriebene **WGS 84-Koordinatensystem**, das aber gleichzeitig relativ ungenau in der Mikroebene im Detail einer Kartierung ist.

Geodaten mit regionalem Bezug (d. h. in diesem Zusammenhang bezogen auf die Fläche eines Bundeslandes) werden traditionell meist im kartesisch orthogonalen **Gauß-Krüger-Koordinatensystem** georeferenziert. Im Gauß-Krüger-Koordinatensystem werden die X- und Y-Koordinaten als Hoch- und Rechtswert bezeichnet. Die meisten topografischen Kartenwerte (wie TK25 oder TK50) liegen als in Gauß-Krüger georeferenzierte Kartierungen vor (Hennermann/Woltering 2014, 19–20). Jedoch unterteilt sich das mikroregional sehr genaue Gauß-Krüger-Koordinatensystem in zahlreiche Subsysteme mit regionalen Zonen der Meridianstreifen in der geographischen Länge, die einerseits die hochgenauen Lokalisationen der Objekte sicherstellen, jedoch andererseits zahlreiche Probleme in der Interoperabilität der regionalen Geodaten verursachen.

Im Gegensatz zum Gauß-Krüger-Koordinatensystem wird innerhalb des **Universal Transverse Mercator-Koordinatensystems** (UTM) die geographische Länge bezogen auf den Nullmeridian nicht längentreu abgebildet, sondern mit einem Faktor ein ›Mittelmeridian‹ für einen Streifen einer Längen-Zone berechnet. Dies hat den Vorteil, dass so die gesamte Erde einheitlich in gleich große Längen-Zonen eingeteilt werden kann. Das ursprünglich für das Militär in den 1940er Jahren entwickelte UTM-System ist prinzipiell ebenso genau, wie Gauß-Krüger-Systeme. UTM ist ebenfalls ein kartesisches Gitterachsen-Koordinatensystem mit X- und Y-Koordinatenwerten. Die regelmäßigen UTM-Zonen, die die gesamte Erde (ausschließlich der Polkappen) erfassen, basieren auf der transversalen Projektion von Zylinderstreifen der Mittelmeridiane, die eine winkeltreue Abbildung der Erdoberfläche darstellen, aber dadurch in Richtung der Pole zunehmend verzerrt sind (Hennermann/Woltering 2014, 99–100). UTM ist nahezu weltweit verwendbar ohne aufwendige, regionalbedingte Koordinatentransformationen, die zudem durch die Umrechnungen die Lagegenauigkeit stark beeinflussen können. Seit den frühen 1990er Jahren wird UTM auch zunehmend in den einzelnen Bundesländern Deutschlands und in den Staaten der Europäischen Union verwendet, um grenzüberschreitende Kartierungen basierend auf einem Referenzsystem zu ermöglichen.

Das **World Geodetic System** (WGS 84) ist ein geodätisches Referenzsystem, das als einheitliche Grundlage für koordinatenbedingte Lageangaben für die gesamte Welt im internationalen Konsens 1984 festgelegt wurde. Grundlage bildet ein Referenzellipsoid, der vereinfacht die Erdoberfläche wiedergibt, wobei die Breite den X- und die Länge den Y-Werten entspricht. Das WGS 84-System weist durch seinen kompromisshaften Charakter tendenziell Ungenauigkeiten in der exakten Geolokalisation auf, die sich aber (je nach Region) meist nur im cm-Bereich befinden. Noch

heute werden alle von Satelliten erhobenen Messdaten des **Global Positioning System** (GPS) im WGS 84 georeferenziert, da dieses System auch im erdnahen Weltraum eingesetzt werden kann. Die meisten Geobrowser, wie Google-Maps oder Openstreetmap, verwenden WGS 84, jedoch in einer noch einfacheren und damit schneller projizierbaren Adaption des WGS 84/Pseudo-Mercator. Dies geht jedoch mit weiteren Lageungenauigkeiten einher, da das Modell das Referenzellipsoid ignoriert und stattdessen eine minimalisierte, nicht-zonale Mercator-Projektion verwendet. So sind WGS 84 und WGS 84/Pseudo-Mercator zwar prinzipiell lagekonform, d. h. sie können als einzelne thematische Kartierungen in einem GIS jeweils in der Übersicht der Makroebene ausreichend genau und auch miteinander projiziert werden, jedoch weisen die Koordinaten in beiden Systemen für eine identische Lage unterschiedliche Koordinatenwerte auf, was wiederum schnell zu Fehlern in den folgenden GIS-Analysen führen kann, die ein eindeutiges, nicht-verwechselbares Koordinatenreferenzsystem benötigen.

Damit es zu keinen Verwechslungen bei diesen ähnlichen, aber auch bei den unterschiedlichen Koordinatensystemen kommt, die zudem sehr oft in den verschiedenen Geo-Browsern und GIS uneinheitlich benannt werden, sind von der European Petroleum Survey Group ›Geodesy‹ sogenannte **ETRS-Codes** mit internationaler Gültigkeit festgelegt worden. Diese eindeutigen 4- bis 5-stelligen Schlüsselnummern kodieren alle weltweit gebräuchlichen Koordinatensysteme, und können in nahezu allen GIS als Einstellungswerte verwendet werden. Beispielsweise entspricht das in Ostdeutschland (Zone 5) gebräuchliche Gauß-Krüger-System des ›Deutschen Hauptdreiecksnetzes‹ dem EPSG-Code 31469. Dieses Gebiet liegt hauptsächlich in der UTM-Zone 33N, die mit dem EPSG-Code 25833 identisch ist und die gleichzeitig im internationalen WGS 84 dem EPSG-Code 4326 entspricht. In WGS 84/Pseudo-Mercator ist die Region einschließlich des weltweiten Umfelds mit EPSG 3857 codiert, um nur die wichtigsten Codes exemplarisch zu nennen (<http://www.epsg.org/>).

21.3 | Unsicherheiten von Raum- und Zeitangaben in historischen Quellen

In den wenigsten Fällen basieren Untersuchungen der Spatial Humanities auf primär erhobenen Geodaten (siehe oben). Im Umfeld der Digital Humanities werden vielmehr meist Texte als Primärquelle für kartierbare Raum- und Zeitangaben genutzt, woraus einige anspruchsvolle Probleme in der Nichteindeutigkeit solcher Textangaben resultieren können. Raumangaben, wie beispielsweise zu einem Ort, sind zum einen im historischen Kontext, der sich im zeitlichen Verlauf verändernden Ortsbilder, zu sehen. So divergiert die schriftliche Erwähnung eines Ortsnamens in verschiedenen schriftlichen Quellen im Verlauf der Zeit oft stark. Beispielsweise sind in der **Ortsdatenbank** ›Orbus Latinus‹ für Ladenburg am Neckar 29 verschiedene Namen aus der Zeit vom 1. bis 19. Jahrhundert recherchierbar (<http://olo.rigéo.net/>). Die oft in Latein verfassten Ortsnamenbezeichnungen sind meist nicht identisch mit den heutigen Ortsnamen, so dass zu prüfen ist, ob sich diese historischen Bezeichnungen tatsächlich auf einen bestimmten heutigen Ort beziehen und ob dieser Ort eine Lagekonstanz aufweist oder möglicherweise verlegt wurde. Diese beiden historisch bedingten Aspekte werden in verfügbaren Repositorien heutiger Ortsnamen (wie z. B. <http://www.geonames.org/data-sources.html>) nicht berücksichtigt und sind daher für jede fundierte Kartierung zu prüfen. Jedoch können aus solchen Orts-

namen-Repositorien die Koordinatenwerte der heutigen Ortschaften gewonnen werden, die einen ersten Anhaltspunkt für weitere individuelle Überarbeitungen und Analysen der Kartierungen bieten.

Zum anderen sind Orts- oder Namenangaben in schriftlichen Quellen prinzipiell auf Wahrheitsgehalt der teils stilistisch bedingten Angaben von fiktionalem Charakter eines spezifischen literarischen Werks zu prüfen (Piatti et al. 2011; Haug 2003). Darüber hinaus können in schriftlichen Quellen auch bewusste Fälschungen, sowohl zur Lokalisation als auch zur zeitlichen Kontextualisierung, vorliegen, wie es z. B. in mittelalterlichen Urkunden zu Besitzverhältnissen und Erwähnungen schon vielfach belegt werden konnte. Dies verdeutlicht der Fall der bekannten »Konstantinischen Schenkung«, wobei es sich in Wirklichkeit um eine in Rom gefälschte Urkunde aus der Mitte des 8. bis 9. Jahrhunderts in der Amtszeit des Papsts Silvester I. handelt, die nicht im Jahr 315/317 von Konstantin dem Großen in Konstantinopel erstellt wurde (Zeillinger 1988, 509 ff.). Somit ist eine intensive **Quellenkritik**, die sich mit den verwendeten Texten auseinandersetzt, eine äußerst wichtige Grundvoraussetzung zur zutreffendsten Interpretation der literarischen Raum- und Zeitangaben. Bei den Zeitangaben ist konzeptionell auch zu bedenken, welche Zeitebene man in seinen Kartierungen zeigen möchte. Hierbei gibt es verschiedene Ansätze:

Einerseits kann versucht werden, eine möglichst kleine Zeiteinheit, wie ein Jahr oder ein Jahrzehnt, in der Karte darzustellen. Andererseits kann aber auch bezogen auf ein Artefakt oder auch Autor eine größere Zeitspanne kartiert werden. Im ersten Fall ist es notwendig, für alle Kartierungsobjekte eine gesicherte Gleichzeitigkeit nachzuweisen, wobei es sich um eine **Zeitkartierung** handelt, die temporäre Fragestellungen fokussiert. Im zweiten Fall steht das Kartenobjekt (Artefakt, Autor etc.) im Interessenfokus, und als **Objektkartierung** ist dabei die zeitliche Einheit weniger relevant, sondern vielmehr die Vergleichbarkeit der kartierten Objekte.

Erschwerend kommt bei beiden Kartierungsansätzen hinzu, dass Raum- und Zeitangaben oft nicht in vergleichbaren Einheiten im Text vorliegen. So müssen in den dem GIS zugrundeliegenden Datentabellen, die im Zuge der Informationsextraktion die relevanten Angaben aus dem Text aufnehmen, recht aufwendige Datenmodellierungen vorgenommen werden, die die räumlich und zeitliche Unschärfe der Textangaben adäquat wiedergeben. Um bei dem Beispiel der mittelalterlichen Urkunden zu bleiben, verdeutlicht sich dies bei den Datierungen und Lokalisationen der Angaben im Dokument, wobei manche Quellen auf ein Jahr genau datiert werden können und andere bestenfalls nur auf einige Jahrzehnte oder gar ein Jahrhundert. Ebenso ist dies der Fall bei Lokalisationen, die im Idealfall auf ein noch heute bestehendes Objekt, wie z. B. eine Kirche oder Brücke, bezogen werden können. Oft kann bei einer Ortsnamennennung aber nur allgemein die Mitte des alten **Ortskerns** kartiert werden, was im Mikrobereich der Kartierung unweigerlich zu Ungenauigkeiten führt. Zudem waren frühmittelalterliche ländliche Siedlungen bis in das 10. Jahrhundert hinein nicht immer standorttreu, wie heutige Dörfer, sondern die Lehm-Holzbauten wurden bei Abnutzung dem Verfall preisgegeben und die neuen Häuser in einiger Entfernung dazu wiedererrichtet, was zu sogenannten »wandernden Siedlungen« führte, die vielfach in archäologischen Befunden belegt werden konnten (vgl. Steuer 1988).

Diese Unsicherheitsfaktoren sollten möglichst genau im relationalen Datenbankmodell des GIS durch **Klassenbildungen** berücksichtigt werden, die Subklassen beinhalten, so dass z. B. bei jahrgenauen Zeitangaben die Klasse (bzw. Einheit – entity) »Mittelalter«, die Subklassen (bzw. Eigenschaften – properties) »Frühmittelalter«,

›Jahrhundert‹, ›Jahrzehnt‹ und ›Jahr‹ enthält, die alle Elemente der Klasse sind und somit bei einer entsprechenden Datenbankabfrage kartiert werden können. Synonym kann dies nicht oder nur bedingt auf unpräzise Lokalisationsangaben übertragen werden, da eine eindeutige hierarchische Ordnung im historischen Kontext mit meist unbekannten räumlichen Einheiten (Grenzen von Königreichen, Ländern, Herrschaften, *terrae* und Gemarkungen) nicht oder nur teilweise bekannt sind und somit nicht als Klassenbildungen verwendet werden können. Die räumliche Unschärfe wird in der Datenbankmodellierung durch Klassenbildungen in Wertebereichen ›von‹ und ›bis‹ mit den entsprechenden Koordinatenwerten erreicht, die nun ebenfalls durch eine SQL-Datenbankabfrage im GIS kartiert werden können. Im GIS können solche räumlichen Unsicherheiten darüber hinaus auch visuell in Form von *buffer* markiert werden, die als Pufferflächen das Spektrum des möglichen Lokalisationsbereiches in der Karte wiedergeben (vgl. Burrough et al. 2015, 137–145; 160–163). In der **Geoinformatik** kommen zunehmend auch Methoden der ›Fuzzylogik‹ zum Einsatz, die mit der Nichteindeutigkeit von Orts- oder Zeitangaben durch statistische Gewichtungen umgehen können und so im GIS kartierbare und auswertbare Wahrscheinlichkeiten wiedergeben (Kainz 2002; vgl. Burrough et al. 2015, 267–286). In den Spatial Humanities sind diese komplexen Datenbankmodellierungen und folgenden GIS-Analysen jedoch bisher die Ausnahme.

21.4 | Datenintegration und Kartentypen

Grundsätzlich können im GIS zwei Typen von Karten verwendet werden: Vektorkarten und Rasterkarten. Beide sind im GIS in der Layer-Anordnung miteinander voll kompatibel kartierbar und analysierbar (s. Abb. 63). Jedoch sind beide Kartentypen völlig verschiedenartig aufgebaut, was mit stark unterschiedlichen Analyseverfahren und visuellen Darstellungsmöglichkeiten einhergeht, wie im Folgenden aufgeführt wird (weiterführend: Bill 2012, 30–32).

Rasterkarten

Bei Rasterkarten handelt es sich oft um Retrodigitalisate, die ursprünglich in Form von gedruckten Karten, wie beispielsweise historische Kartenwerke, vorlagen und durch Scannen digitalisiert und anschließend georeferenziert wurden und somit im GIS Koordinaten-konform projizierbar sind (s. Abb. 63). Dabei ist zu beachten, dass diese Retrodigitalisate oft nicht verzerrungsfrei gescannt wurden oder sogar nur abfotografiert worden sind, wobei die perspektivische Verzerrung auch bei einer Senkrechtaufnahme durch die optische Linsenverzerrung der Kamera besonders in den Außenbereichen am Rand der Karte zunimmt. So erfolgt oft in einem zweiten, meist von der grundlegenden Datenerhebung völlig unabhängigen Arbeitsschritt die **Georeferenzierung**, im Zuge derer die Probleme der optischen Verzerrung möglichst gut durch die entsprechende Auswahl der verschiedenen Interpolationsverfahren im Georeferenzierungs-Algorithmus ausgeglichen werden müssen.

Für historische Karten eignet sich oft der *Thin Plate Spline*-Transformationstyp, der besonders die Aspekte der inneren und äußeren Orientierung der Kartenverzerrung älterer, ursprünglich handgezeichneter Papier- oder Foto-Quellen berücksichtigt (ein weiterführendes Tutorial zur Georeferenzierung von handgezeichneten Plänen:

bilden. Zuunterst ist die Open Street Map via WMS-Plugin in das GIS als aktuelle Hintergrundkartierung eingebunden. Aus der georeferenzierten historischen Rasterkarte können durch Umzeichnung (Vektorisierung) in einen neuen (Vektor-)Layer selektive Informationen extrahiert werden: So ist hier das historische Marstall-Gebäude mit einem Polygon in der Abbildungsmitte hervorgehoben und ein Vorgängerbau mit Linien dargestellt sowie mit einem Punkt die Lage des alten Stadttors, das mit diesem in Zusammenhang stand, markiert. Auf diese Weise kann nun die exakte Lage des historischen Marstalls im zeitlichen Verlauf auf unterschiedlich alten Kartenwerken (die im Layer-Fenster links zu sehen sind, jedoch bei dieser Darstellung nicht sichtbar sind) durch Anklicken des gewählten Layers verglichen und untersucht werden.

Vektorkarten

Der große Vorteil von Vektorkarten gegenüber Rasterkarten besteht in der theoretisch unendlichen **Skalierbarkeit** des Betrachtungsmaßstabs sowie in der vergleichsweise sehr geringen Dateigröße des Shapefile-Dateibündels. Darüber hinaus sind Vektorkarten im Dateibündel eines Layers direkt mit einer Datentabelle verbunden, deren Informationen in einem Datenbanksystem oder direkt im GIS auswertbar sind. Auf diese Weise können Sachdaten aus einzelnen Karten der Layer im GIS in strukturierte Datensätze übertragen werden, die wiederum die Grundlage für weitere Auswertungen, wie visuelle oder statistische Verfahren, bieten. Die Informationsextraktion aus dem GIS ist damit nicht nur auf die visuelle **Vektorisierung** (Umzeichnung) von besonders Interessanten Informationen aus anderen Layern, beispielsweise Rasterkarten, beschränkt, sondern in der verbundenen Tabelle der Vektorkarte können direkt im GIS besonders interessante Informationen, wie z. B. Gebäudestrukturen und Vorgängerbauten, Kartensignaturen zur Geologie, Angaben zum Höhenwert etc., eingetragen werden ohne auf ein zusätzliches Datenbankmanagementsystem (DBMS) rückgreifen zu müssen, da das GIS bereits ein eigenes DBMS integriert. Durch entsprechende Verknüpfungen können die im GIS in der Tabelle einer Vektorkartierung eingetragenen Werte darüber hinaus aus dem GIS ohne Zusatzaufwand in ein interoperables Datenbanksystem (meist im Structured Query Language – SQL, aber auch im Extensible Markup Language – XML) eingelesen werden (zu logischen Datenmodellen im GIS: Bill 2012, 397–409).

21.5 | GIS-Aufbau und -Komponenten

Ein GIS besteht grundlegend aus den vier Komponenten Software, Hardware, Daten und Anwender (vgl. »Vier-Komponenten-Modell« in De Lange 2013, 338–342). Die Software ist also nur ein Teil des gesamten Geographischen Informationssystems. Das GIS wird auch manchmal allgemeiner als Geoinformationssystem bezeichnet, sodass die Geodaten (siehe unten) und nicht deren räumliche Verteilung in diesem Fall namensgebend sind (Bill 2012, 8–9). GIS dienen der Erfassung, Bearbeitung, Organisation bzw. Verwaltung, Analyse und nur unter anderem der Präsentation räumlicher Daten. Bis vor wenigen Jahren mussten recht kostenintensive GIS-Software-Anwendungen angeschafft werden, wenn man mit vollfunktionalen GIS arbeiten wollte, die oft von kleineren Lehrstühlen oder Forschergruppen kaum dauerhaft im

Rahmen der Lizenzvereinbarungen finanziert werden konnten. Erst durch die fortlaufende Weiterentwicklung von stabiler und zudem nutzerfreundlicher **Open Source GIS-Software** sowie einhergehenden interoperablen Austauschformaten wurden raumorientierte Forschungen für einen stark erweiterten Nutzerkreis in den Geisteswissenschaften praktisch realisierbar (z. B. Quantum GIS; vgl. Volkmann et al. 2012). Ebenso ermöglichte die Bereitstellung von leistungsstarker Hardware in handelsüblichen PCs grundlegend den Einsatz von GIS. Besonders die Echtzeitberechnung zoombarer Rasterkartierungen aus georeferenzierten Bilddateien (Bitmaps), wie retrodigitalisierten Karten, erfordert sehr viel Rechenleistung und damit große Arbeitsspeicher, die bisher nur schwer verfügbar waren (zur Georeferenzierung von historischen Karten vgl. Volkmann 2015).

Innerhalb von verschiedenen räumlichen Informationssystemen ist zudem die Verfügbarkeit von Geodaten und deren Anwendbarkeit durch entsprechend implementierte GIS-Werkzeuge in den letzten Jahren deutlich verbessert worden, was wiederum mit steigenden Anzahlen von GIS-Studien einherging. So sind beispielsweise viele topografische Kartenwerke und auch historische Karten seit einigen wenigen Jahren über webbasierte Repositorien zugänglich, was mit der Umsetzung der sogenannten INSPIRE-Richtlinie der Europäischen Union für den Aufbau von zugänglichen Geodateninfrastrukturen im Zusammenhang steht (Bill 2012, 236–245; <http://inspire.ec.europa.eu/>).

Alle **Software-Komponenten** verschiedener Entwickler eines GIS (u. a. Graphical User Interface GUI, Database Management System DBMS etc.) sind grundlegend recht ähnlich aufgebaut. Auf dem Desktop des Nutzer-PCs ist meist eine Unterteilung in mindestens zwei, manchmal auch drei Arbeitsbereiche angeordnet: Minimal weisen sie ein Kartenfenster und ein Fenster für die Auswahl der einzelnen Teilkarten (bzw. thematischen Layer) auf (s. Abb. 63); optional zeigen sie ein zusätzliches

Name	Beschreibung	URL
Virtuelles Kartenforum 2.0 der Sächsischen Landes-, Staats- und Universitätsbibliothek	Georeferenzierte, historische Karten aus dem Deutschen Reich, teils georeferenziert	http://kartenforum.slub-dresden.de/
David Rumsey Map Collection	Georeferenzierte, historische Karten weltweiter Provenienz, teils georeferenziert	http://www.davidrumsey.com/
Geofabrik	Bestände der Openstreetmap in einzelnen thematischen Layern für alle Kontinente und Länder, georeferenziert	http://www.geofabrik.de/
Bundesamt für Kartographie und Geodäsie	Topographische Karten von Deutschland und historische Karten, teils georeferenziert	http://www.bkg.bund.de/
Euro Geographics	Topographische Karten, Verwaltungskarten, Übersichtskarten von Europa, georeferenziert	http://www.eurogeographics.org/
Old Maps Online	Suchmaschine für historische Karten, die die größten Kartenarchive einbindet	http://www.oldmapsonline.org/

Tab. 11 Ausgewählte Repositorien mit Raster- und Vektorkarten (s. Abb. 62). URLs können sich rasch ändern.

Fenster, das die Pfade der Layer oder Datenbanken darstellt. Im Kartenfenster wird die Visualisierung der Gesamtkartierung gezeigt, die aus einzelnen Teilkarten der Layer besteht. Das Grundprinzip ist hierbei, dass alle Layer, die manchmal treffend auch als ›Oberflächen‹ bezeichnet werden, in exakter räumlicher Lage zueinander als ein übereinanderliegender, ›virtueller Stapel‹ die Gesamtkartierung darstellen. Jeder einzelner Layer kann in seiner Anordnung zu den anderen Layern, d. h. ob oben- oder untenliegend, verändert werden, was in Fenster der Layer-Auswahl durch Änderung der Layer-Reihenfolge (mit *drag-and-drop*) oder das Aus- und Einschalten der Layer ermöglicht wird. Durch digitale Umzeichnungen können selektive Informationen aus interessant erscheinenden Teilen der Layern in neuen Layern zusammengebracht oder grafisch, durch hervorgehobene Signaturen oder Markierungen verstärkt werden, die die neue angereicherte Information visualisieren. Alle einzelnen Layer bestehen aus georeferenzierten Datentabellen, die in verschiedene Datenbanken eingebunden sein können und die im GIS durch Informationsextraktion und -anreicherung vielfältig, beispielsweise statistisch, ausgewertet werden können.

21.6 | GIS-Methoden

Ein modernes GIS ist schon lange nicht mehr nur eine einfache Ansammlung verschiedener Geo-Werkzeuge. Im Sinne einer virtuellen Forschungsumgebung können in einem GIS heterogene Daten hybriden Ursprungs kontextualisiert werden, und zwar kollaborativ via Web-basierten WMS Karten- und WFS Datendiensten (siehe unten). Erst durch das Zusammenbringen dieser oft in unterschiedlichen Repositorien weit verstreuten Daten können grundlegend neue Forschungsfragen generiert werden, die gleichzeitig mit der Entwicklung neuer Methoden einhergehen. Typisch für ein GIS ist das Wechselspiel von **Werkzeugen** und **Methoden**: Neue Werkzeuge gehen oft mit neuen Methoden einher und andersherum sind neue Methoden ursächlich verantwortlich für neue Werkzeugprogrammierungen. Viele Theorien und Methoden sind von Geografen bzw. Geo-Informatikern primär für ihre Disziplin entwickelt worden. Der Methodentransfer in eine andere Disziplin erfordert jedoch oft spezifische Anpassungen, die teils problematisch sind, wenn beispielsweise die Datengrundlage nicht auf empirischen Messdaten beruht, sondern auf hermeneutisch/interpretativ erhobenen Daten, die eine spezielle Quellengrundlage mit besonderen Herausforderungen darstellen (siehe unten). Dabei sind die Informationen über die Prozesse des Verstehens und Interpretierens der einzelnen Daten zu prüfen, die als Paradata die Umstände der Datenerhebung beschreiben (vgl. die ›Londoner Charta‹ für computergestützte Visualisierungen von kulturellem Erbe: <http://www.londoncharter.org/>).

So können einerseits Methoden aus den Geowissenschaften mit speziellen Anpassungen übernommen werden; andererseits müssen jedoch spezifische Methoden grundlegend erst erarbeitet werden, die geistes- und kulturwissenschaftlichen Datensätzen und deren Lückenhaftigkeit bzw. Imperfektion gerecht werden. GIS erweitern die klassischen Forschungsansätze der Geisteswissenschaft dahingehend, dass sie neben der reinen **Visualisierung** von räumlichen Verteilungen auf Karten darüberhinausgehend eine **Analyseplattform** der erhobenen Daten darstellen und zusätzlich gleichzeitig dem Nachweis von Thesen in Form eines Kataloges aus den verwendeten Datenbanken dienen können. Grundlage des GIS sind Datentabellen in einem Datenbanksystem, die einen eindeutigen, georeferenzierten Raumbezug auf-

weisen und auch von anderen Werkzeugen, z. B. der Statistik oder Text- und Bildbearbeitung, innerhalb und außerhalb des GIS genutzt werden können. Ein GIS weist also als Grundlage neben interdisziplinären methodischen Forschungsansätzen zudem **interoperable Datensätze** auf, die somit die Möglichkeiten des GIS potenzieren.

In den **philologisch** orientierten Disziplinen sind in einigen neueren Projekten neben der einfachen Kartierung der Befunde auch anspruchsvolle GIS-Analysen angewandt worden, wobei oft GIS-Methoden zu visuellen Befundintensitäten (Dichtegradient), zu Netzwerken (Distanz- und Konnektivitätsberechnungen mit Delaunay-Triangulationen oder Voronoi-Diagrammen) und/oder zur Einflussosphärenkalkulationen (Bufferung) eine solide Ausgangsbasis darstellen (De Lange 2013, 372–388; weiterführend zu den einzelnen GIS-Methoden: Burrough et al. 2015, 137–145; 160–163). Exemplarisch seien hier auf die Projekte »Mapping the Lakes: A Literary GIS« und »Ein literarischer Atlas Europas« verwiesen (<http://www.lancaster.ac.uk/mappingthelakes/>; <http://www.literaturatlas.eu/>).

Für **geschichtlich-archäologisch** orientierte Studien sind diese GIS-Methoden ebenso vielversprechende und schon oft angewandte Forschungsansätze, die jedoch durch die meist fokussierte Zeitkomponente mit einhergehenden Spatio-Temporal-Analyses sowie 2,5D (»Pseudo-3D«) und 3D-Verfahren, wie beispielsweise Sichtbarkeitsanalysen, Geländemodellierungen mit potentiellen Wegeverbindungen bzw. Cost Path-Analyses, deutlich an Komplexität zunehmen (Conolly/Lake 2008, 90 f.; 208 f.; 234 f.).

Name	Beschreibung	URL
World OSM WMS	Bestände der Openstreetmap in einem Layer, weltweit	http://wiki.openstreetmap.org/wiki/world_osm_wms
Bayerische Vermessungsverwaltung	Topographische Karten, Luftbilder und Verwaltungskarten Bayerns	http://geoportal.bayern.de/
Bundesamt für Kartographie und Geodäsie	Digitales Landschaftsmodell für Deutschland	http://www.bkg.bund.de/
NASA	Satellitenbilder, weltweit	http://neo.sci.gsfc.nasa.gov/about/wms.php
geometa.info	Suchmaschine für WMS	http://geometa.info/

Tab. 12 Beispielhafte Auflistung von World Map Services 2016, die die direkte Implementierung von digitalen Geländemodellen oder topographischen Karten ermöglichen.

21.7 | Kartenrepositorien via Web WMS (World Map Services)

Sowohl Raster- als auch Vektorkarten können über das Internet mit mittlerweile fast jeder GIS-Software als Layer hinzugeladen werden und theoretisch im GIS ebenso wie Layer auf einem lokalen Laufwerk analysiert werden (eine Übersicht zu WMS-kompatibler Open Source gibt Tyler 2008, 250 und 235 f.). Die Auswahl des Layerin-

halts sowie die Speichermöglichkeiten unterliegen jedoch oft Nutzungsbeschränkungen, die neben der Visualisation die Analysemöglichkeiten limitieren. Dabei ist wieder in zweierlei Arten der Kartendienste mit Geodaten zu unterscheiden: Es sind **Vektorkartendienste** (Web Feature Service) und **Rasterdatendienste** (Web Coverage Service). Beide werden zusammengefasst allgemein als **Web Map Service** (WMS) bezeichnet (Kappas 2012, 170–175).

Ein WMS stellt eine Schnittstelle (Interface) zu externen Kartenservern dar, die über eine URL (Uniform Resource Locator) im GIS angesteuert werden können. Durch die Integration von externen Kartendiensten wird das GIS zum webunterstützten GIS, was nun einen möglichst schnellen und stabilen Internetzugang benötigt, um die von externen Servern abgerufenen Karten auch ohne größeren Zeitverzug im GIS darstellen zu können. Ein **webunterstütztes GIS** ist jedoch nicht mit einem **Web-GIS** zu verwechseln, das beispielsweise durch eine Java Runtime Environment-Implementation als virtuelle Maschine betriebssystemunabhängig in einem Web-Browser ohne die Installation von GIS-Software, jedoch nur im beschränkten Funktionsumfang, nutzbar ist (De Lange 2013, 342–344). Dahingegen spricht man von einem Geo-Browser, wenn ein ausgewählter Funktionsumfang spezifischer GIS-Anwendungen, wie z. B. die Punktkartierung und Linien-Vektorisierung oder 3D Visualisierung mit WebGL (Web Graphics Library), browserbasiert realisiert wird. Die Übergänge zwischen Web-GIS und Geo-Browser sind jedoch teils fließend und daher manchmal nicht klar zu unterscheiden.

Bei den WMS-Kartendiensten sind die oft angebotenen, vergleichsweise großen Rasterkarten erheblich von Nachteil, da das GIS für jede Veränderung im gewählten Kartenausschnitt den Rasterkarten-WMS neu aus dem Web lädt, was das GIS, je nach Internetgeschwindigkeit, recht langsam machen kann. Es wird jedoch immer nur der jeweils gewählte Kartenausschnitt der WMS-Karte vom Kartenserver (und nicht die ganze Karte) abgerufen, um den Prozess des Kartenaufbaus zu beschleunigen. Das Open Geospatial Consortium (OGC; <http://www.opengeospatial.org/standards/wms>) legte dabei die Spezifikationen beim einhergehenden Abfrageprozess fest, der auf Kommunikation mit dem Hypertext Transfer Protocol (HTTP) basiert und in drei Schritte unterteilt stattfindet (Kappas 2012, 155–163):

- **HTTP-Anfrage:** In einer ersten HTTP-Anfrage (GetCapabilities) an den Kartenserver werden die Metadaten des Dienstes als XML/GML-basiertes Dokument abgefragt (vgl. De Lange 2013, 237–240; 243–248).
- **GetMap:** Dann können im GIS bestimmte Eigenschaften des WMS aus den Metadaten des Dateiübertragungsprotokolls ausgewählt werden, wobei im zweiten Schritt (GetMap) nun die selektierte Karte als neuer Layer dem GIS hinzugeladen wird.
- **GetFeatureInfo:** Optional können in einem dritten Schritt zusätzlich Angaben thematischer Informationen der zugrundeliegenden Daten bezogen auf den gewählten Kartenausschnitt und Maßstab im XML-Format abgefordert werden, die im GIS zusätzlich darstellbar sind (GetFeatureInfo).

WMS ermöglichen also, dass verschiedene GIS mit unterschiedlichen Betriebssystemen und heterogenen Software-Anwendungen oder Geo-Browsern an beliebigen Standorten basierend auf den vom OGC definierten Standards miteinander kommunizieren, Karten und Geo-Daten austauschen können und somit in einer interaktiven, verbundenen Geodaten-Infrastruktur agieren (zu »Free and Open Source GIS Software for Building a Spatial Data Infrastructure« vgl. Steiniger/Hunter 2009, 247 f.).

Literatur

- Bessel, Friedrich Wilhelm: »Ueber einen Fehler in der Berechnung der französischen Gradmessung und seinen Einfluß auf die Bestimmung der Figur der Erde«. In: *Astronomische Nachrichten* 19/438 (1842), 97–116.
- Bill, Ralf: *Grundlagen der Geo-Informationssysteme* [2010]. Berlin 2012.
- Bocher, Erwan (Hg.): *Geospatial free and open source software in the 21st century. Proceedings of the First Open Source Geospatial Research Symposium*. Nantes 2009.
- Bodenhamer, David J.: *Spatial Humanities: GIS and the Future of Humanities Scholarship*. Indiana 2010.
- Burrough, Peter A./McDonnell, Rachael A./Lloyd, Christopher D.: *Principles of Geographical Information Systems*. Oxford 2015.
- Conolly, James/Lake, Mark: *Geographical Information Systems in Archaeology*. Cambridge 2008.
- Dross, Kerstin: »Zum Einsatz von Geoinformationssystemen in Geschichte und Archäologie«. In: *Historical Social Research* 31/3 (2006), 279–287. Online: <http://www.ssoar.info/ssoar/handle/document/4999> (31.10.2016).
- Haug, Walter: *Die Wahrheit der Fiktion: Studien zur weltlichen und geistlichen Literatur des Mittelalters und der frühen Neuzeit*. Tübingen 2003.
- Hennermann, Karl/Woltering, Manuel: *Kartographie und GIS: Eine Einführung*. Darmstadt 2014.
- Kainz, Wolfgang: *Fuzzy Logic and GIS. Department of Geography and Regional Research*. Wien 2002.
- Kappas, Martin: *Geographische Informationssysteme*. Braunschweig 2012.
- De Lange, Norbert: *Geoinformatik in Theorie und Praxis*. Heidelberg 2013.
- Mitchell, Tyler: *Web-Mapping mit Open Source-GIS-Tools*. Beijing/Köln 2008.
- Piatti, Barbara/Hurni, Lorenz: »A Literary Atlas of Europe – Analysing the Geography of Fiction with an Interactive Mapping and Visualisation System«. In: Anne Ruas (Hg.): *Proceedings of the 25th International Cartographic Conference*. Paris 2011. Online: <http://www.literaturatlas.eu/2012/01/01/analysing-the-geography-of-fiction/> (31.10.2016).
- Sansó, Fernando/Sideris, Michael G. (Hg.): *Geoid Determination: Theory and Methods*. Berlin/Heidelberg 2013.
- Steiniger, Stefan/Hunter, Andrew J. S.: »Free and open source GIS software for building a spatial data infrastructure«. In: Erwan Bocher (Hg.): *Geospatial free and open source software in the 21st century. Proceedings of the First Open Source Geospatial Research Symposium*. Nantes 2009, 247–261.
- Steuer, Heiko: »Standortverschiebungen früher Siedlungen – von der vorrömischen Eisenzeit bis zum frühen Mittelalter«. In: Gerd Althoff (Hg.): *Person und Gemeinschaft im Mittelalter: Karl Schmid zum fünfundsechzigsten Geburtstag*. Sigmaringen 1988, 25–59.
- Volkmann, Armin et al.: »Geisteswissenschaft und Geografische Informationssysteme (GIS): Erstellung von Kartierungen mit kommerzieller und Open Source Software im Vergleich« (2012), <http://go.uni-wuerzburg.de/gisskriptum> (31.10.2016).
- Volkmann, Armin: »Archäologische Fundkartierung und Zeichnungs-Georeferenzierung mit QGIS. HeiDOK Heidelberger Dokumentenserver« (2015), <http://www.ub.uni-heidelberg.de/archiv/19929> (31.10.2016).
- Volkmann, Armin: »Tutorial Georeferencing of historical maps with QGIS. Georeferenzierung von historischen Karten mit QGIS – Ein Bilderbuch (2014), <http://archdigi.hypotheses.org/420> (31.10.2016).
- Warf, Barney/Arias, Santa: *The Spatial Turn: Interdisciplinary Perspectives*. New York 2009.
- Zeillinger, Kurt: »Otto III. und die Konstantinische Schenkung. Ein Beitrag zur Interpretation des Diploms Kaiser Ottos III. für Papst Silvester II. (DO III. 389)«. In: *Fälschungen im Mittelalter. Internationaler Kongreß der Monumenta Germaniae Historica, München, 16.–19. September 1986. Teil 2: Gefälschte Rechtstexte, der bestrafte Fälscher*. Hahn/Hannover 1988, 509–536.

Armin Volkmann

22 Digitale Rekonstruktion und Simulation

22.1 | Definitionen

Es ist gar nicht so einfach, das digitale **Rekonstruieren** vom digitalen **Simulieren** zu unterscheiden, denn in beiden Fällen haben wir es mit der Herstellung von etwas **Virtuellem** zu tun, also etwas nicht (mehr) Existentem. Das führt dazu, dass die beiden Begriffe immer wieder einmal durcheinandergeworfen werden und dass insbesondere eine digitale Rekonstruktion häufig Simulation genannt wird. Im Hinblick auf historische Sachverhalte wird man sagen dürfen, dass der Rekonstruierer etwas darstellt, »wie es einmal gewesen ist«, der Simulierer dagegen, »wie es einmal hätte gewesen sein können«. Die Simulation wird aber im Übrigen auch in Zusammenhängen verwendet, die mit den Geisteswissenschaften zwar verbunden sein können, aber eigentlich darüber hinausweisen, überall dort nämlich, wo ein zukünftiger Zustand »präkonstruiert« werden soll. Nicht mehr, »wie es hätte gewesen sein können« ist hier also von Interesse, sondern »wie es (zukünftig) einmal sein könnte«. Damit wird auch der Bereich angesprochen, für den die Simulation in der Hauptsache steht, nämlich die Analyse von Systemen anhand eines Modells, weil das Experiment in der Wirklichkeit lebensgefährlich, also ethisch nicht zu vertreten ist (Flugsimulator, Crashtest in der Automobilindustrie), oder weil man das System hier schlicht nicht beobachten kann (Schaltkreise, weil sich in ihnen die Elektronen zu schnell bewegen)

Rekonstruktion und Simulation

Mit einer Rekonstruktion will man einen einstmals vorhandenen Zustand wiederherstellen, entweder im Modell oder in der Wirklichkeit

Die Simulation strebt die retrospektiv-historische oder die prospektive Darstellung eines zeitlichen Verlaufes an

Sowohl Rekonstruktion als auch Simulation ist nicht an die Digitalität gebunden, Gebäude lassen sich auch in verkleinerten Holzmodellen oder in einzelnen Schnitten und Ansichten darstellen, historische Vorgänge zum Beispiel im Reenactment simulieren. Iterationen aber sind im Analogen ein mühsames Geschäft. Im Digitalen muss nur Code modifiziert werden, um ein Sattel- in ein Walmdach zu verwandeln oder ein Gebäude mit drei bzw. vier Etagen zu postulieren, das Holzmodell müsste entweder gewaltig beschnitten oder doch besser gleich ganz neu produziert werden.

22.2 | Digitale Rekonstruktion

Historische Sachverhalte in ihrer Originalgestalt zu bestimmen, ist eine Aufgabe, die alle geschichtlich orientierten Geisteswissenschaften angeht. In manchen Fällen ist das leichter, in anderen durchaus anspruchsvoller. Im Lauf der Zeit unleserlich gewordene Schriftstücke können nach Digitalisierung schon durch relativ einfache Kontraststeigerungen und ähnliche Bildverarbeitungsmechanismen wieder lesbar gemacht werden. Es ist nicht übertrieben, so etwas schon eine Rekonstruktion zu nennen. Ein literarisches Werk mag im Laufe seiner Überlieferung und im Prozess der Edition Veränderungen erfahren haben, diese aber dürften im Regelfall beschei-

dener oder doch wenigstens weniger sinnverändernd sein als dort, wo Bild-Kunstwerke z. B. durch Umwelteinflüsse, aber auch durch absichtliche Überformungen, Umbauten, Ergänzungen etc. im Lauf der Zeit eine teilweise völlig veränderte Gestalt angenommen haben.

Städte z. B. unterliegen als lebendige Gebilde nun einmal einem Prozess der Transformation, und je älter sie sind, desto größer wird sogar die Wahrscheinlichkeit, dass sie ganz aufhören zu existieren. Trotzdem (oder vielleicht gerade deswegen) bleiben sie für den Historiker interessant. Ist die Verwandlung in diesem Fall gewöhnlich durch menschliche Eingriffe verursacht, kann auch natürlicher Verfall den Originaleindruck eines Kunstwerkes verändern. In aufwändigen Berechnungen hat man etwa die Veränderungen der Farben in Georges Seurats Bild »Nachmittag auf der Grande-Jatte-Insel« kalkuliert, um damit auf dessen Aussehen im Jahr 1884 zurückzuschließen, also zur Zeit von dessen Entstehung (Berns et al. 2004). Angesichts der überragenden Bedeutung, die die Leuchtkraft der Farbe im Postimpressionismus besitzt, mag der Aufwand gerechtfertigt erscheinen, auch wenn jede technische Reproduktion des Farbeindrucks die im Übrigen nicht sonderlich großen Unterschiede wieder verzerrt. Immerhin müsste man die Ergebnisse ja auch auf manche anderen Bilder der Zeit übertragen können.

Für **Kunsthistoriker** und **Archäologen** gehört das Rekonstruieren demnach zu den zentralen wissenschaftlichen Tätigkeiten. In der Archäologie liegt das auf der Hand, da dort in vielen Fällen nur noch Reste überdauert haben, die auf ihre ursprüngliche Gestalt zu befragen sind. Aus eben diesem Grund ist die Anwendung des Computers in der Archäologie, die ja immer schon engere Verbindungen zu den Natur- und Technikwissenschaften pflegte als andere Geisteswissenschaften, auch so deutlich verankert, dass sogar eigene Professuren dafür ausgeschrieben werden und spezialisierte Unternehmen sich der digitalen Rekonstruktion widmen (<http://www.digitale-archaeologie.de/>). Aber auch in der Kunstgeschichte ist vieles zerstört und eigentlich alles verändert, sodass es sich häufig lohnt, frühere oder originale Zustände zu kennen. Hier gilt nach wie vor das berühmte historistische Diktum Leopold von Ranke, der sich im Unterschied zu seinen Vorgängern die Aufgabe gestellt hatte, als Historiker zu beschreiben, »wie es eigentlich gewesen« (Ranke 1885, 7).

Rekonstruieren und Restaurieren

Die wissenschaftlich wünschenswerte Kenntnis älterer Zustände von Kunstwerken ist streng zu unterscheiden von der Frage, ob es erstrebenswert sein kann, diese älteren Zustände auch zu realisieren. So gesehen ist der Rekonstruktionsbegriff missverständlich, da er ja die tatsächliche Durchführung des Aktes impliziert. Denn dort, wo etwa ein literarisches Werk in seiner ursprünglichen Gestalt neben das veränderte gelegt werden kann, ist das z. B. bei einem Bauwerk natürlich nicht möglich – oder wenn, dann nur so, dass die neuere Gestalt des Gebäudes dabei zerstört wird. Dass heute in China europäische Bauwerke komplett nachgebaut werden, darunter auch solche, die nicht mehr existieren, dürfte als eher skurriler Sonderfall die Regel bestätigen. Ähnliches gilt für die ebenfalls in China zu beobachtende Simulation von europäischen Stadttypen, die von dem (natürlich mittelalterlich inspirierten) deutschen Ort Anting bis zur Windmühlen-bestückten niederländischen Stadt Gaoqiao reicht (Hassenpflug 2008).

Historische Aspekte: Sehr aufschluss- und bis heute einflussreich war der um 1900 ausgetragene **Denkmalstreit**, bei dem es anlässlich der denkmalpflegerischen Behandlung des unter Ludwig XIV. von Frankreich weitgehend zerstörten **Heidelberger Schlosses** darum ging, ob dieses in seiner ursprünglichen Gestalt wiedererstanden sollte. Durchgesetzt hat sich hier eine Position, die davon Abstand zu nehmen riet und die **Restaurierung** eines vorhandenen der **Rekonstruktion** eines vergangenen Zustandes vorzog.

Das Problem taucht aber bis heute immer wieder auf (oder wird außerhalb Europas meist gar nicht als solches empfunden), was mit der Unmöglichkeit zusammenhängen dürfte, emotionale und wissenschaftliche Gesichtspunkte in Übereinklang zu bringen. Nach der Wiedervereinigung Deutschlands hatten konservative Preußenfreunde trotz intensiver und kontroverser Diskussion relativ leichtes Spiel, den Wiederaufbau des **Berliner Hohenzollern-Schlusses** durchzusetzen. Dabei ist hier wiederum der Wiederaufbau von der Rekonstruktion zu unterscheiden, da man ja nur auf einer der vier Seiten so etwas wie eine einigermaßen geschichtstreue Gestaltung plant und die anderen Seiten in modernerer Gestalt baut, einmal abgesehen davon, dass auch der historisch anmutende Teil in ganz und gar moderner Bautechnik errichtet wird. Und anlässlich einer Münchener Ausstellung tauchten 2010 ganz ähnliche Argumente pro und contra Rekonstruktion auf wie mehr als 100 Jahre zuvor (Nerdinger 2010). Aber selbst dann, wenn man der gebauten Rekonstruktion gegenübersteht, muss klar sein, dass sie aus Kostengründen nur in sehr seltenen, (kunst)historisch bedeutenden Fällen möglich ist.

Virtual Reality

Die Möglichkeiten, mit dem Computer zwischen dem wissenschaftlichen und dem emotionalen Aspekt zu vermitteln, sind bislang noch begrenzt, aber avancierte Versuche in dem Bereich deuten an, was hier noch alles zu erwarten ist. Analoge, also maßstäblich verkleinert gebaute Modelle von Architektur gibt es schon seit dem Spätmittelalter. Sie können aber immer nur eine Vorstellung von der Wirklichkeit bieten und niemals einen Ersatz. Digitale Modelle dagegen, vor allem dann, wenn sie zur **Virtual Reality** erweitert werden, in der sich der Betrachter bewegen und die er erfahren kann, kommen der Wirklichkeit schon entschieden näher, auch wenn sie diese natürlich ebensowenig ersetzen können. In einer **CAVE** oder mit einem **Head-Mounted Display** mit Bewegungssensoren wie z. B. der *Oculus Rift* kann die elektronische Substitution des Originals auf den Betrachter fast wie dieses selber wirken.

Augmented Reality: Einen solchen Effekt hat man sich auch bei Projekten wie dem zur virtuellen Rekonstruktion des Heidelberger Schlossgartens zunutze gemacht, indem man die Rekonstruktion – schon 2002 als Prototyp verwirklicht – abhängig von der Lage des Betrachterkopfes in eine Datenbrille heineingespiegelt hat, die sich dann im Auge über den Wirklichkeitseindruck legte und am Ort selber in dessen Vergangenheit zurückversetzte (Leiner/Schmickl 2003). Um analoge und virtuelle Wirklichkeit dabei aufeinander abbilden zu können, war es nötig, präzise **Geokoordinaten** (s. Kap. 21) zu erstellen, hinzu kommen Kompass und Bewegungssensor, um Bewegungs- und Blickrichtung zu verzeichnen. Was vor gut 10 Jahren noch eine schweißtreibende Angelegenheit war, weil man die ganze Technik in einem Rucksack mit sich herumschleppen musste, lässt sich heute auf einem Smartphone inszenieren. Und als im Sommer 2015 mittels **holographischer** Licht-Projektion die

zerstörten Bamyian-Skulpturen in Afghanistan dreidimensional in ihren Nischen wieder zum Leben erweckt wurden, konnte jeder sich leicht ausrechnen, was mit dieser Technologie auch sonst noch alles einmal praktikierbar werden würde. Schon jetzt ist es immerhin möglich, über **3D-Drucker** ein materielles, analoges Komplement der Skulpturen zu erstellen. Auch sonst haben inzwischen technisch generierte Duplikate eine Qualität erreicht, die es selbst Fachleuten verbietet, eine eindeutige Unterscheidung vom Original vorzunehmen.

Aspekte der Virtual Reality

Cave Automatic Virtual Environment (CAVE): ein durch mehrseitige digitale Projektionen illusionistisch überformter Raum

Head-Mounted Display: ein direkt am Kopf getragenes Ausgabegerät für digitale Projektionen zur Illusionssteigerung

Augmented Reality: eine digital erzeugte Erweiterung des Realitätseindrucks

Holographie: erzeugt scheinbar frei im Raum schwebende Bilder unter Ausnutzung des Wellencharakters des Lichtes

3D-Drucker: produziert dreidimensionale Objekte in schichtweisem Aufbau

Computer Aided Architectural Design

Bei architektonischen Rekonstruktionen können wir grundsätzlich solche unterscheiden, die aus Zeichnungen, Plänen, archäologischen Resten u. Ä. Extrapolationen auf die Gesamtgestalt unternehmen, und solche, die ein existierendes Bauwerk aufnehmen und hierin virtuelle Änderungen vornehmen, die eine geplante oder einstmals anders vorhandene Gestalt (wieder)herstellen. Computertechnisch gesehen, nähert man sich ersterer Aufgabe mit spezialisierter Software, die ursprünglich eher andere Einsatzbereiche hat. Das **Computer Aided Design (CAD)**, dessen Ausgangspunkt man in Ivan Sutherlands legendärem ›Sketchpad‹ aus den frühen 1960er Jahren sehen darf, dient in der modernen Industrie der Konstruktion von allen möglichen Gegenständen, vom Handy bis zum Wasserkraftwerk. Aber CAD kann eben auch zum Zeichnungs- oder Fotografie-gestützten Rekonstruieren von nicht mehr vorhandenen Kunstwerken, in erster Linie Bauwerken genutzt werden. Dabei bedient man sich einer Spezifikation des allgemeinen CAD im CAAD (*Computer Aided Architectural Design*), so wie es beispielsweise in *AutoCAD Architecture* der Firma Autodesk vorliegt, darüber hinaus aber Dutzenden anderen (Heine et al. 2011).

Das CAD, das ursprünglich 2-dimensional orientiert und dadurch in der Lage war, Grundrisse und Schnitte wie händisch auf Zeichnungspapier zu konstruieren, hatte dabei aber die Möglichkeit, mehrere Schichten (**layer**) übereinanderzulegen und für Standardlösungen weitgehend fertige Bibliotheken anzulegen, die dem klassischen Entwerfen überlegen waren. Die dritte Dimension hat es erst später erobert. Der Vorgang lässt sich gut über die Vervielfachung einer planen Fläche zu einem dreidimensionalen Körper verstehen, der in der sogenannten **Extrusion** weiterhin die Arbeit des Modellierers mitprägt. Auch das **Drahtgittermodell** kann als Vermittlungsstufe zwischen zweiter und dritter Dimension verstanden werden, da es Körper aus Linien (nämlich den Kanten) definiert und auch im CAD als Darstellungsform verwendet wird, weil es sehr schnell berechnet werden kann und vielfach ausreicht.

Lebensechtheit: Neben das **Modellieren** der Bauvolumen tritt in der digitalen Re-

konstruktion das **Texturieren** der Oberflächen, da sonst keine realistische Darstellung der historischen Erscheinung möglich ist. In einem Bildverarbeitungsprogramm lässt sich ausgehend von Oberflächeneigenschaften des Baumaterials und eventuell vorhandenen Resten der Verputzung ein mögliches Erscheinungsbild bestimmen, das dann digital auf die Volumenkörper der Modellierung »geklebt« wird. Gerade letzteres gehört zu den schwierigsten Modellierungsaufgaben und bedarf avancierter Software-Funktionen. Zur realistischen Darstellung hinzu kommt dann die Konstruktion eines Lichteinfalls mit der entsprechenden Schattenbildung. In der letzten Stufe werden die Vorgaben **gerendert**, also in eine wirklichkeitsgetreue, rastergraphisch gebildete Darstellung transformiert. Für entsprechende Visualisierungsaufgaben lassen sich CAD-geformte Modelle in 3D-Grafikprogrammen wie »Cinema 4D« umwandeln, die im Übrigen auch selber den Modellierungsprozess beherrschen und daher in den letzten Jahren die rein vermessungstechnischen Programme vielfach verdrängt haben.

Mit 4D ist hier die Zeit als vierte Dimension angesprochen. Die Software eignet sich damit vor allem für die Herstellung von Filmen. Das kann durchaus auch für historische Rekonstruktionsaufgaben genutzt werden. Einmal im Hinblick auf eine den dreidimensionalen Gegenstand aus allen Perspektiven erschließende Ansichtigkeit, die das Objekt wie in einem Flug durch den Raum erschließt; dafür wird häufig auch Apples *Quicktime VR* verwendet, entweder in **real time** (interaktiv) oder als vorher festgelegte Abfolge. Die hohen technischen Anforderungen an die Rechenkraft bei einer *real time*-Realisierung, in der der Nutzer frei wählen kann, in welcher Abfolge er »fliegen« will (immerhin müssen pro Sekunde mindestens 24 Ansichten berechnet werden, damit ein flüssiges Bild entsteht), zwingt allerdings zu einer Verkleinerung bzw. Vereinfachung des Modells. Dies gilt insbesondere dann, wenn das Ganze über das Internet vermittelt werden soll, wo auch noch Bandbreitenprobleme hinzukommen. Zweitens aber ist die Verfilmung auch deswegen relevant, weil damit historische Zeitabläufe von Bauphasen visualisiert werden können. Dass digitale Rekonstruktionen häufig trotz aller computertechnischen Perfektionierung so steril aussehen, hängt wohl in erster Linie damit zusammen, dass es nicht einfach ist, scheinbar nebensächliche, den Wirklichkeitseindruck aber entscheidend mitbestimmende Parameter adäquat zu modellieren. Dazu gehören sowohl atmosphärische Eigenschaften wie auch Gebrauchsspuren an Gegenständen.



Abb. 64 Schloss Friedrichstein bei Kaliningrad/Königsberg, historische Aufnahme des 1945 zerstörten Schlosses um 1900.



Abb. 65 Drahtgittermodell der virtuellen 3D Rekonstruktion des Schlosses ohne Interieur, Zustand 1. Hälfte 20. Jahrhundert, Version Februar 2015, Jan Lutteroth



Abb. 66 Alternative Rekonstruktion der Dachgauben. Dachvariante vor und nach dem Umbau im 19. Jahrhundert, Version Februar 2015, Jan Lutteroth




Abb. 67 Visualisierung des Interieur. Fiktive Innenansicht durch die Loggia in den Gartensaal ohne Einrichtung. Version Februar 2015, Jan Lutteroth/Anna Preiss



Abb. 68 Texturierte Endvisualisierung der virtuellen 3D Rekonstruktion des Schlosses, Zustand 1. Hälfte 20. Jahrhundert, Version Juni 2016, Architekturbüro Sarnitz, Königsberg
(Alle Abbildungen sind im Zuge des vom Herder-Institut in Marburg geleiteten Forschungsprojektes: Virtuelle Rekonstruktionen in transnationalen Forschungsumgebungen – Das Portal: Schlösser und Parkanlagen im ehemaligen Ostpreußen, gefördert von der Leibniz-Gemeinschaft (07/2013 bis 06/2016) entstanden. Ich danke Jan Lutteroth (Projektmitarbeiter) für seine Einführung in die Geheimnisse des CAD.)

Quellenkritik

Entscheidend für die Glaubwürdigkeit auch einer digitalen Rekonstruktion ist die strenge Orientierung an anschaulichen historischen Belegen. Selbst da aber, wo ein Bauwerk intensiv z. B. künstlerisch in Ansichten reproduziert wurde, bedarf es der **Quellenkritik**. Die Neigung nämlich, einen Körper maßstabsgerecht aufzunehmen, war historisch nicht weit verbreitet, an vielen Stellen muss man sogar von gewollter Verzerrung oder freihändiger Transformation ausgehen. Von modernen dokumentarischen Standards ist also nicht auszugehen. Behelfsweise kann auf vermutlich ähnliche Werke zurückgegriffen werden, also etwa zeit- und funktionsähnliche aus der gleichen Kunstlandschaft, bei denen wir von einer ähnlichen Gestaltungsweise ausgehen können. In jedem Fall aber spielt hier ein **spekulatives Element** hinein, das bei einer wissenschaftlich akzeptablen digitalen Rekonstruktion etwa durch unterschiedliche Darstellungstransparenz oder -farbigkeit zu kennzeichnen ist. Ein großer Vorteil der digitalen Rekonstruktion besteht aber darin, dass sie vergleichsweise unaufwändig alternative Möglichkeiten aufzeigen und dann auch der Plausibilitätsprüfung zur Verfügung stellen kann (s. die Dachgaubenrekonstruktion in Schloss Friedenstein in Abb. 66).

Bedeutung: Der Wert solcher digitaler Rekonstruktionen liegt für den Tourismus und überhaupt für die Erlebarmachung von Geschichte auf der Hand. Aber auch wissenschaftlich ist er nicht zu vernachlässigen. So konnte bei der Rekonstruktion der ursprünglichen Gestalt der frühchristlichen Kirche Santa Maria Maggiore in Rom alleine schon die Visualisierung des Kircheninnenraumes die für das Projekt herangezogenen Experten von bestimmten Thesen abbringen, die ohne die Ansichtigkeit plausibel geschienen hatten (Frischer et al., 2000). Und zuletzt zu diesem Komplex: So traurig der Anlass für das »Projekt Mosul« auch ist, in dem es um die virtuelle Rekonstruktion von Werken geht, die vom sogenannten »Islamischen Staat« in Syrien und im Irak zerstört werden, so eindrücklich zeigt es einen weiteren Bereich auf, in dem das Digitale seine Vorteile ausspielen kann (<http://projectmosul.org/>). Mittels **Crowdsourcing** werden hier frühere Besucher dieser Länder darum gebeten, Fotos von dortigen Kunstwerken einzusenden, mit denen dann, gestützt auf photogrammetrische Verfahrensweisen, die Werke wenigstens in 3D wiedererstehen.

Laserscanning

Die erwähnte zweite Form der Rekonstruktion bildet nicht etwas verloren Gegangenes nach, sondern verdoppelt virtuell etwas Vorhandenes. Auf dem Weg des terrestrischen oder airborne **Laserscanning** (aus einer Bodenposition bzw. aus der Luft) ist es möglich, komplette und hochdifferenzierte Bauaufnahmen zu generieren, die mehr und mehr photogrammetrische Verfahren und traditionelle Handaufmaße ersetzen. In beiden Fällen wird die Lichtlaufzeit des Laserstrahls gemessen und so die Entfernung einzelner Punkte am Objekt bestimmt. Dabei entsteht eine **Punktwolke**, die ein geometrisches Abbild des Gegenstandes liefert. Insbesondere zwei Bedingungen müssen erfüllt sein. Erstens müssen die exakte Position und die Ausrichtung des Aufnahmeapparates bekannt sein, was natürlich vor allem bei sich bewegenden Lasern im **airborne**-Verfahren nicht trivial ist. Und zweitens ist die Genauigkeit der Aufnahme dadurch zu steigern, dass man sie von möglichst vielen verschiedenen Standpunkten aus vornimmt, die dann softwaregesteuert zusammengesetzt werden. An-

sonsten sind Punkte, die durch andere Teile des Gegenstandes verdeckt werden, nicht zu bestimmen (Heine et al. 2011).

Die virtuelle Verdoppelung des Vorhandenen hat auch hier wieder in erster Linie touristischen Wert – oder dient scheinbar skurrilen Formen des Realitätsnachbaus wie der für China zu Beginn angedeuteten. Aber auch der wissenschaftliche Wert ist erkennbar, wenn auch zur Zeit noch weniger praktiziert. Denn gebaute Architektur ist immer nur die für gültig befundene Realisierungsform unter mehr oder weniger vielen Entwürfen. Wie etwa der **Berliner Hauptbahnhof** ausgesehen hätte, wenn er in der vom Architekten Meinhard von Gerkan vorgesehenen Langform realisiert worden wäre, lässt sich eindrücklicher als im Modell sicherlich auch in einer entsprechend virtuell modifizierten Form des gebauten Bahnhofs erleben. Auch hier hat das Ganze neben dem retrospektiven Aspekt einen prospektiven: Vielleicht hätte sich der Auftraggeber ja doch zum Bau der geplanten Anlage durchgerungen, wenn er ein entsprechendes digitales Modell vor Augen gehabt hätte.

22.3 | Digitale Simulation

So interessant solche Rekonstruktionen auch sind: Der Beobachtung historischer Wirklichkeit ein Stück näher kämen wir dadurch, dass wir die in ihrem reinen architektonischen Bestand rekonstruierten Gebäude auch als Orte geschichtlichen Lebens begriffen, also die tote Hülle mit handelnden Personen bestückten. Wir müssten Handlungsabläufe simulieren, die nicht beliebig (denn dann wäre Geschichte vollkommen kontingent), die aber doch so variantenreich sind, dass das geschichtlich Typische vom rein Zufälligen zu trennen wäre (McCarty 2016; Weber 2007). Mit Programmen wie dem erwähnten »Cinema 4D« kommen wir solchen Ansätzen schon näher, da sie ja wie erwähnt die Zeitdimension mit einschließen.

Der Begriff der **Simulation** ist durch das Werk Jean Baudrillards zu einem der zentralen, gleichzeitig schillerndsten der zeitgenössischen Theoriebildung geworden. Nach Baudrillard ist die medienbestimmte Gegenwart, die Postmoderne oder der Spätkapitalismus eine Zeit der omnipräsenten Simulakren, in der sich eine Wirklichkeit gegenüber deren Simulationen überhaupt nicht mehr postulieren lässt. Heruntergebrochen auf konkrete historische Wirklichkeit kann die Simulation aber auch eine empirisch fundierte Deutungsfunktion entfalten.

Ein Beispiel aus der historischen Literaturwissenschaft

Wie es eigentlich gewesen ist: Einen Schritt über die Rekonstruktion hinaus und schon in das Feld der Simulation hinein geht der amerikanische Literaturwissenschaftler John Wall mit seinem Projekt zur Zurückgewinnung historischer akustischer Räume (Wall 2012). Weniger stand hier eine spezifische historische Gestalt im Vordergrund als vielmehr ein spezifischer historischer Moment, und zwar derjenige einer Predigt John Donnes im Hof der Londoner Hauptkirche St. Paul's am 5. November 1622. Zentral war dabei ein **kontrafaktisches Element**, das für echte Simulationsmodelle noch bedeutsam werden wird, nämlich die Tatsache, dass diese Predigt zwar für den Hof geplant war, aber aus Witterungsgründen tatsächlich in der Kirche stattgefunden hat. Rekonstruiert, eher simuliert wird hier also eine eigentliche historische Wahrheit, gegenüber der die tatsächliche historische Wirklichkeit defizitär

ist. Für den historischen Empiriker sind solche Überlegungen zweifelhaft, da sie ins Feld der Spekulation hineinreichen. Sie können aber – auch wenn hierfür der untersuchte Fall wohl zu wenig hergibt – Vermutungen darüber provozieren, was gewesen wäre, wenn ein ursprüngliches Vorhaben realisiert, und nicht ein durch Zufälligkeiten zustande gekommenes Ereignis eingetreten wäre.

Im Einzelnen hat sich das Projektteam alle historisch überlieferten Ansichten und Pläne der im späten 17. Jahrhundert abgebrannten Kirche vorgenommen, für die Oberflächenerscheinung sogar die Wirkung von in der Frühen Neuzeit üblichen Holzverbrennungen auf das Aussehen der Gebäude berücksichtigt und darauf basierend ein dreidimensionales Architekturmodell erstellt, hier mit google *sketch-up*, einem kostenlos verfügbaren 3D-Modellierungsprogramm, das relativ leicht zu nutzen ist. *Sketch-up* verfügt über eine riesige Kollektion von vormodellierten Gegenständen – vom Frosch bis zum Wolkenkratzer –, die einerseits auf den konkreten Anwendungsfall adaptierbar sind, andererseits ein schnelles Arbeiten erlauben, da nicht alles ganz von vorne modelliert werden muss.

Da für das beschriebene Projekt aber die architektonische Gestaltung eigentlich gar nicht im Vordergrund stand, sondern die Predigt Donnes, liegt der Akzent der Forschungen eigentlich auf den **akustischen Überlegungen**, die die Wirkungsweise der Predigt in einem bestimmten räumlichen Umfeld, bestimmt durch Dimension, Raumverhältnisse und Baumaterialien betreffen. Historisch grundierte Vermutungen zu Sprechweise und -geschwindigkeit, Lautstärke der Stimme u. Ä. erlauben eine relativ klare Evokation alternativer, historisch nicht durchweg belegter Szenarien, etwa die Anzahl der Zuhörer betreffend und die Möglichkeit, die Stimme in bestimmten Entfernungen überhaupt noch hören zu können. Dabei hat die Wiederherstellung des performativen Charakters der Predigt im Unterschied zur rein textanalytischen Herangehensweise den Vorteil, dass durch sie auch bestimmte strukturelle Eigenschaften zu verstehen sind. So konnte ein Zusammenhang zwischen dem alle Viertelstunde einsetzenden Glockengeläut und den Sinneinschnitten im Text hergestellt werden.

Agent Based Modelling

Gegenüber einem Projekt wie dem zuletzt beschriebenen, das sowohl rekonstruktive als auch simulative Aspekte beinhaltet, scheinen sich für historische Fragestellungen vor allem solche Simulationen anzubieten, die man unter dem Schlagwort des **Agent Based Modelling** zusammenfasst. Im ABM werden heterogene und autonome Protagonisten geformt, deren Handlungsweise aus historischer Beobachtung in möglichst vielen Aspekten definierbar ist. Diese Protagonisten, die Menschen sein können aber nicht müssen, agieren in einer digitalen Umgebung. In seiner vorbildlichen Untersuchung nennt der Historiker Marten Düring drei entsprechende Vorhaben (Düring 2014).

Alternative Geschichtsverläufe: Ausgangspunkt für alle diese Vorhaben ist der Versuch, dem faktischen Verlauf eines Ereignisses alternative Verläufe an die Seite zu stellen, die den Grad der Notwendigkeit dieses Verlaufes belegen können. Ebenfalls denkbar ist es, in einer unklar oder unzureichend überlieferten historischen Situation verschiedene Verläufe hypothetisch zu (re-)konstruieren, um daraus dann den wahrscheinlichsten herauszufiltern. Machbar ist das nur, wenn die diversen Faktoren, also die *agents*, quantifiziert werden, wenn also ihr Gewicht im vermuteten

Handlungsverlauf eindeutig bestimmbar ist. Der einigermaßen abstrus wirkende Ansatz wird plausibler, wenn man sich die Beispiele vor Augen führt. Fühlt man sich dabei an historische Computerspiele erinnert, deren Verlauf ja ebenfalls durch alternative Ausstattungen der Protagonisten bestimmt wird, ist das völlig legitim (Vowinkel 2009).

Bei dem in Arizona siedelnden Volksstamm der Anasazi, der im späten 13. Jahrhundert ziemlich plötzlich von der Bildfläche verschwand, konnten Agent Based Models die Vermutung nahelegen, dass fortschreitende Entwaldung die Lebensgrundlagen zerstört hatte. Die Manitoba-Grippeepidemie nach dem Ersten Weltkrieg forderte in einer von drei Pelzjäger-Siedlungen fast 20 % Tote, während sie in den anderen beiden wirkungslos blieb, obwohl intensive Reisetätigkeit zwischen den drei Communities zu verzeichnen ist. Hier wurden einzelne Reisende, deren Eigenschaften, Reisezeiten etc. teilweise detailliert bekannt sind, als Agenten simuliert und man konnte feststellen, dass bei der Entfernung zwischen den Orten ein Reisender entweder während der Reise gestorben sein musste, oder dass er so spät im Nachbarort ankam, dass er nicht mehr ansteckend war. Für die Schlacht von Trafalgar (1805) hatte sich weithin die Überzeugung durchgesetzt, die Engländer hätten diese aufgrund der von Admiral Nelson gewählten originellen Schlachtordnung gewonnen. Eine *Agent Based* Modellierung, die auch eine Reihe von Umweltfaktoren wie die Windgeschwindigkeiten mit einbezog, konnte belegen, dass auch bei geläufiger Schlachtordnung die in der Feuerkraft überlegenen Engländer die Schlacht gewonnen hätten, dass ihre niedrige Verlustrate aber durchaus mit Nelsons genialem Trick zusammenhing.

Softwaretechnische Aspekte: Für solche Agent Based Modellings hat sich die an einer Universität entwickelte **open source** Software »Net Logo« durchgesetzt, die auf der **Java Virtual Machine** läuft und somit auf den meisten gängigen Betriebssystem-Plattformen funktionsfähig ist. Das Programm kann im wahrsten Sinne des Wortes komplexe Systeme verwalten, indem es Tausende voneinander unabhängige agents auf der Zeitschiene interagieren und den Forscher beobachten lässt, unter welchen Bedingungen welche Ergebnisse emergieren. Unter der Voraussetzung, dass hinreichend detaillierte Kenntnisse der Verhaltensmuster von historisch handelnden Personen vorhanden sind, ist es somit richtiggehend möglich, eine künstliche Gesellschaft zu inszenieren und auch Vermutungen darüber anzustellen, was passiert wäre, wenn bestimmte Parameter anders gewesen wären als dies tatsächlich der Fall war.

Die Möglichkeit (oder Gefahr), dass Entsprechendes in die Zukunft gewendet wird, dass also Voraussagen über das gemacht werden, was kommen wird, dürfte angesichts der ungeheuren Komplexität des Gesamtsystems, das sich schon nach kürzester Zeit in eine unendlich scheinende Anzahl von Alternativen ausdifferenziert, beschränkt sein. Für streng begrenzte Wirklichkeitsbereiche aber nutzen Futurologen auch heute schon computer-basierte Simulationen, die man aber kaum mehr den *Digital Humanities* zurechnen will. Wenn man zudem bedenkt, dass die ganze Prozedur von Daten abhängt, die in möglicher Vielfältigkeit vorliegen müssen, so wird man immerhin behaupten dürfen: Für die Vergangenheit sind alternative Geschichtsverläufe schon alleine deswegen nicht zu rekonstruieren, weil in aller Regel bei weitem zu wenige Daten vorliegen. Für die Zukunft allerdings sieht das angesichts der Tatsache, dass heute eine Unmenge von Daten produziert wird, durchaus anders aus.

Alternative Simulationsverfahren

Neben dem Agent Based Modelling können andere Simulationsverfahren beschrieben werden, die die Frage aufwerfen, wie es zukünftig einmal sein könnte. Das gilt für Verfahrensweisen, mit denen man die Erdbebenresistenz von historischen Bauwerken berechnen will (Kuhlmann/Butenweg 2012), aber auch für Stadtlandschaften, deren Aussehen für den Fall überprüft werden soll, dass ein geplantes Bauwerk hinzukommt. Das, was hier thematisiert wird, lässt sich aber auch retrospektiv praktizieren. Die Macher einer Studie zu Sebastiano Serlios »Loggia dei mercanti« in Lyon haben einen digitalen Grundriss dieses Gebäudes so lange auf dem ebenfalls digital vorliegenden Stadtplan der Renaissancestadt hin- und hergeschoben, bis sie mit einer gewissen Wahrscheinlichkeit den Punkt festlegen konnten, wo sich das Bauwerk wohl befunden hätte – wenn es jemals das Planungsstadium verlassen hätte und gebaut worden wäre (Günther 2001).

Die Simulation scheint historischem Denken diametral entgegengesetzt, da sie den Eindruck erweckt, der Beobachtung von Fakten die Konstruktion von Eventualitäten entgegenzusetzen. Dieser Eindruck aber täuscht. Wenn man die Experimente klar als Möglichkeitsmodelle kennzeichnet, können sie durchaus einen heuristischen historischen Erklärungswert entfalten.

Literatur

- Berns/Roy S. et al.: »Rejuvenating Seurat's palette using color and imaging science: A simulation«. In: Robert Herbert (Hg.): *Seurat and the making of »La Grande Jatte*. Chicago 2004, 214–227.
- Düring, Marten: »The Potential of Agent-Based Modelling for Historical Research«. In: Paul A. Youngman/Mirsad Hadzikadic (Hg.): *Complexity and the Human Experience: Modeling Complexity in the Humanities and Social Sciences*. Boca Raton FL: Pan Stanford Publishing 2014, 121–37.
- Frischer, Bernard et al.: »Virtual Reality and Ancient Rome: The UCLA CulturalVR Lab's Santa Maria Maggiore Project«. In: Juan A. Barcelo et al. (Hg.): *Virtual Reality in Archaeology, British Archaeological Reports International Series S 843*. Oxford 2000, 155–162.
- Günther, Hubertus: »Kritische Computervisualisierung in der kunsthistorischen Lehre«. In: Markus Frings (Hg.): *Der Modelle Tugend: CAD und die neuen Räume der Kunstgeschichte*. Weimar 2001, 111–122.
- Hassenpflug, Dieter: »Europäische Stadtfiktionen in China. Über urbane Travestien, Parodien und mimetische Transpositionen« (2008). <http://www.espacestemp.net/en/articles/europaische-stadtfiktionen-in-china-en/>.
- Heine, Katja/Rheidt, Klaus/Henze, Frank/Riedel, Alexandra (Hg.): *Erfassen. Modellieren. Visualisieren. Von Handaufmaß bis High Tech III. 3D in der historischen Bauforschung*. Mainz 2011.
- Kuhlmann, Wolfram/Butenweg, Christoph: »Simulation des Tragverhaltens des Aachener Doms im Erdbebenfall«. In: *Die karolingische Pfalzkapelle in Aachen, Arbeitsheft der rheinischen Denkmalpflege* 78 (2012), 237–247.
- Leiner, Richard/Schmickl, Simone: »Eine virtuelle 3D-Rekonstruktion des einstigen Heidelberger Schlossgartens (Hortus Palatinus)«. In: *Zeitschrift für die Geschichte des Oberrheins* 151 (2003), 175–198.
- McCarty, Willard: »Modelling the actual, simulating the possible«. In: Flanders, Julia/Jannidis, Fotis (Hg.): *The Shape of Data in Digital Humanities. Modeling Texts and Text-based Resources*. London 2017.
- Nerdinger, Winfried in Zusammenarbeit mit Markus Eisen und Hilde Strobl (Hg.): *Geschichte der Rekonstruktion, Konstruktion der Geschichte*. München/New York 2010.
- Ranke, Leopold von: *Sämtliche Werke* Bd. 33/34. Leipzig 1885.
- Vowinkel, Annette: »Past Futures: From Re-enactment to the simulation of History in Computer Games«. In: *Historical Social Research* 34/2 (2009), 322–332. <http://nbn-resolving.de/urn:nbn:de:0168-ssoar-286848>.

- Wall, John N.: »Recovering Lost Acoustic Spaces: St. Paul's Cathedral and Paul's Churchyard in 1622«. In: *Digital Studies/ Le champ numérique* (2012). http://www.digitalstudies.org/ojs/index.php/digital_studies/article/view/251/310 (15.12.2016).
- Weber, Karsten: »Erklärung historischer Abläufe mit Computersimulationen«. In: *Historical Social Research* 32/4 (2007), 94–121.

Internetquellen

Digitale Archäologie: <http://www.digitale-archaeologie.de/>.
Project Mosul / Rekrei: <http://projectmosul.org/>.
Architectura virtualis: <http://www.architectura-virtualis.de/>.

Hubertus Kohle

23 Informationsvisualisierung

Die Verwendung von grafischen Elementen zur Darstellung größerer Datenmengen und statistischen Auswertungen oder zur Illustration von Forschungsergebnissen ist kein Phänomen allein der Digital Humanities. ›Informationsvisualisierungen‹, wie wir sie im Folgenden nennen werden, sind jedoch zurzeit aus mehreren Gründen stark gefragt. Zum einen hat das Angebot visueller Darstellungsformen im Alltagsleben stetig zugenommen – vor allem die Medien setzen auf ihren Gebrauch – da sich bestimmte, vor allem komplexere Sachverhalte besser visuell, damit anschaulicher, als verbal vermitteln lassen (z. B. durch sog. ›Infografiken‹).

Zum anderen führt die Digitalisierung in vielen Bereichen der Wissenschaften zu einem hohen Aufkommen an Daten, was eben jene datenorientierten Ansätze befördert, die eine visuelle Aufbereitung bzw. visuell unterstützte Analyse nahelegen oder erfordern. Dies begründet sich nicht nur in der Unüberschaubarkeit der Datensammlungen auf Grund ihrer großen Menge, sondern auch in Bezug auf ihre komplexe Zusammensetzung. Eine starke Ausprägung hat die Informationsvisualisierung neben den Medien und der Wirtschaft so etwa auch in den empirischen Wissenschaften gewonnen. Insbesondere im Kontext der derzeit stark aufkommenden quantitativen Analyse (s. Kap. 20) in verschiedenen geisteswissenschaftlichen Disziplinen spielt sie in den Digital Humanities eine immer wichtigere Rolle. Zudem werden unter dem Schlagwort ›Visual Analytics‹ neue methodische Ansätze propagiert.

23.1 | Informationsvisualisierung in historischer Perspektive

Grafische Elemente als kommunikatives Mittel sind eine alte Kulturtechnologie; man denke etwa an die jungpaläolithischen Höhlenmalereien von Lascaux oder die neolithischen Wandmalereien von Catalhöyük mit frühen Kartendarstellungen. Die Schrift, wie wir sie als Repräsentationsform von Sprache kennen, entwickelte sich erst deutlich später, aber auch aus Bildzeichen heraus. Visuelle Darstellungen von statistischen Daten sind hingegen eine Erfindung der Neuzeit. Als Pioniere werden regelmäßig William Playfair (1758–1823), John Snow (1813–1858) und Charles Minard (1781–1870) genannt.

Insbesondere Snow führte uns dabei vor Augen, dass Visualisierungen nicht nur rein illustrativen, sondern auch analytischen Charakter haben können. Aus seiner thematischen Karte der Londoner Cholera-Epidemie von 1854 (Abb. 69), in der Snow die Erkrankungsfälle räumlich verortete, wurde auf Grund der Konzentration dieser Orte erkannt, dass die Ursache der Epidemie in einer kontaminierten Wasserpumpe lag, wodurch sie eingedämmt werden konnte.

Die »Carte Figurative des pertes successives en hommes de l'Armée Française dans la campagne de Russie 1812–1813« von **Charles Minard** 1861 (Abb. 70) ist ein eindrucksvolles Beispiel für eine Visualisierung komplexer, mehrdimensionaler Daten und ihrer Zusammenhänge. Sie zeigt den Zug napoleonischer Truppen auf Moskau und zurück. Die Breite des dargestellten Bandes gibt dabei die Truppenstärke wieder, vom Beginn des Marsches an der Memel (links im Bild) mit 422.000 Mann, über das Erreichen Moskaus (rechts) mit einer auf 100.000 Mann dezimierten Armee




Abb. 69 Räumliche Visualisierung von Cholera-Fällen in London 1845 (John Snow, Ausschnitt). Die kleinen Balken markieren die Erkrankungsfälle, die Wasserpumpen sind gesondert markiert. Die schadhafte Pumpe liegt in der Broad Street.




Abb. 70 Minards *Carte Figurative* von 1861 über die Truppenstärke Napoleons während des Russland-Feldzugs 1812/13 (Erläuterung im Text)

bis zum Ende des Rückzugs wieder an der Memel mit nunmehr nur noch rund 10.000 überlebenden Soldaten.

Die Darstellung ist eine Kombination aus mehrdimensionalen statistischen Daten mit einer Raum-Zeit-Visualisierung. Es werden fünf Variablen dargestellt: die Größe der Armee, ihre Position in der Ost-West-Ausdehnung, ihre Position in der Nord-Süd-Ausdehnung, die Bewegung der Armee, sowie (im unteren Teil) die Ortstemperatur zu ausgewählten Zeitpunkten des Rückzugs. Auf Grund der eleganten Verknüpfung verschiedenartiger Daten und ihrer Zusammenhänge untereinander sowie der nüchternen Ästhetik der Darstellung gilt Minards *Carte* als Klassiker der Informationsvisualisierung: »It may well be the best statistical graphic ever drawn« (Tuft 1983, 41). Die Darstellung macht eindrucksvoll deutlich, worin die Stärke der Visualisierung

gegenüber reinen Datentabellen aber auch gegenüber der Narration mittels Text liegt: »Grafische Kommunikation besitzt eine höhere Bandbreite als Schrift- und mathematische Zeichensprachen, die Informationen sequentiell kodieren. Bilder ermöglichen es dagegen, verschiedene Informationen simultan darzustellen und zu beurteilen« (Krempel 2005, 25).

Bedeutend für die Entwicklung der Informationsvisualisierung im wissenschaftlichen Kontext seit dem frühen 19. Jahrhundert war ihre Verwendung nicht mehr nur im unmittelbarem geographischen Bezug wie mittels Karten, sondern ihr Einsatz für abstrakte Daten. Nun konnten alle mess- oder anderweitig erhebbare Daten in Relation zu anderen Daten dargestellt werden, ohne dass es dazu einen Raum- oder Zeitbezug geben musste. Damit wurde die Informationsvisualisierung für jede Art der quantitativen Betrachtung interessant (vgl. Tufte 1983, 43–46).

23.2 | Definitionen und Funktionen

Was ist Informationsvisualisierung?

Informationsvisualisierung wird häufig **funktional definiert** als eine Entlastung des menschlichen Geistes oder eine Erweiterung und Verstärkung seiner kognitiven Fähigkeiten. Damit werden Visualisierungen zum Werkzeug im Umgang mit Mengen von Daten oder Informationen, die entweder so groß oder so komplex strukturiert sind, dass der menschliche Geist sie ohne externes Werkzeug nicht überblicken kann. In der Literatur werden diese visuellen Werkzeuge etwa als »method for seeing the unseen« (McCormick et al. 1987) bezeichnet. Da diese Werkzeuge heute in der Regel computergestützt sind, können wir Informationsvisualisierung einer weiteren gängigen Definition folgend auffassen als »the use of computer-supported, interactive, visual representations of abstract data to amplify cognition« (Card/MacKinlay/Shneiderman 1999, 7).

Die englischsprachige Literatur unterscheidet häufig zwischen **Information Visualization** und **Scientific Visualization**. Von letzterem wird gesprochen, wenn die räumliche Anordnung der zu visualisierenden Daten diesen Daten immanent ist. Beispiele aus den Naturwissenschaften sind etwa die Anordnung von Atomen in einem Molekül oder der Planeten unseres Sonnensystems. Solche Visualisierungen werden oft für das interaktive Lernen am Modell verwendet oder dienen der Simulation. Für abstrakte Daten der Information Visualization hingegen wird diese räumliche Anordnung erst durch die Visualisierung selbst gewählt. Diese Art von (abstrakten) Daten ist für die Digital Humanities vornehmlich relevant (vor allem im Umfeld quantitativer Analyse, s. Kap. 20; Daten mit Raumbezug behandelt Kap. 21) und soll im Weiteren betrachtet werden, wobei die Trennung der beiden Ausprägungen der Visualisierung selten scharf und eindeutig ist.

Als eine funktionale Erweiterung der reinen Informationsvisualisierung können die **Visual Analytics** betrachtet werden. Hierunter verstehen wir eine interdisziplinäre Wissenschaft, um das logisch-analytische Denken durch interaktive, visuelle Schnittstellen zu Daten und Informationen zu unterstützen (Thomas/Cook 2005). Die Visual Analytics betten damit die Informationsvisualisierung in den Forschungsprozess ein.

Mit der zunehmenden Bedeutung von Informationsvisualisierungen in vielen Bereichen der Wissenschaft, der Wirtschaft und der Gesellschaft ist neben den Visualisierungswerkzeugen auch die Forschungsliteratur in den 1990er Jahren enorm angestiegen. Hierin spiegeln sich die verschiedenen Perspektiven und das interdisziplinäre Zusammenspiel in der wissenschaftlichen Untersuchung von Informationsvisualisierungen wider, das neben den Fachdisziplinen die Statistik, Informatik, Design, Psychologie und Soziologie umfasst.

23.3 | Informationsvisualisierung im Forschungsprozess

Edward Tufte betont, dass es bei allen Formen der Informationsvisualisierung zunächst und primär darum gehen muss, die zu kommunizierenden Daten unverfälscht und transparent zu zeigen und den Betrachter zum Nachdenken anzuregen. In seinem wegweisenden Buch *The Visual Display of Quantitative Information* (1983) macht er dabei auch auf die manipulative Kraft von Bildern und die Gefahr von Fehlinterpretationen durch schlecht gestaltete Visualisierungen aufmerksam. Auf dies und auf einzelne der von Tufte vorgeschlagenen Gestaltungsprinzipien (»graphical excellence begins with telling the truth about data«, Tufte 1983, 53) werden wir im Folgenden noch eingehen.

Informationsvisualisierungen sollten dann zum Einsatz kommen, wenn die Datengrundlage reichhaltig, mehrdimensional oder komplex ist. Dabei ist es durchaus möglich, Millionen von Informationseinheiten auf einer Grafik aufzutragen. Am anderen Ende des Spektrums aber sollte für wenige, eindimensionale Datensätze auf den Einsatz von Visualisierungstechniken verzichtet werden; hier bieten sich Datentabellen oder bei nur wenigen Datensätzen auch der Fließtext als bessere Darstellungsformen an.

Funktion im Forschungsprozess: Anhand der Rolle, die Informationsvisualisierungen in einem Forschungsprozess spielen können, wollen wir diese Rollen funktional in drei grobe Kategorien einteilen: die Präsentation, die konfirmative Analyse sowie die explorative Analyse. Über diese Kategorien hinaus, die wir gleich näher besprechen, werden in der Literatur häufig weitere genannt, wie die künstlerische Visualisierung, die Visualisierung als Mittel zum Storytelling oder die Kombination der Informationsvisualisierung mit Verfahren der Simulation (s. Kap. 22.3) zur Exploration potentieller Gegebenheiten, ihrer Wahrscheinlichkeiten und Einflussfaktoren (Was-wäre-wenn-Szenarien; vgl. Dörk et al. 2013, 2194).

Die **Visualisierung als Präsentation** hat zum Ziel, wissenschaftliche Erkenntnisse (Fakten und Zusammenhänge) anschaulich zu kommunizieren. Dabei entstehen in der Regel Grafiken von hoher Qualität, die häufig auch ästhetischen Ansprüchen genügen sollen. Im Gegensatz zur Nutzung von Informationsvisualisierung als Analysewerkzeug sind bei der Präsentation sowohl deren Inhalte als auch die Art der Darstellung a priori durch den Erzeuger der Grafik determiniert. Exemplarisch zeigt Abb. 71 die Entwicklung des Arbeitsstellenmarktes in Niederbayern zur Zeit des Ersten Weltkriegs. Die Visualisierung ist das Ergebnis einer Analyse von rund 9000 Stellenanzeigen zweier niederbayerischer Tageszeitungen zwischen 1914 und 1918. Ohne auf Details einzugehen, lässt sich als klarer Trend ablesen, dass (mit saisonalen Spitzen) ab der zweiten Jahreshälfte 1916 deutlich mehr Anzeigen geschaltet wurden als in den ersten Kriegsjahren. Diese Trends sind aus den Datentabellen nicht ohne weiteres herauszulesen.




Abb. 71 Anzahl der in den Tageszeitungen *Passauer Zeitung* und *Kurier für Niederbayern* geschalteten Stellenanzeigen im Zeitraum 1914–1918 (Maurer/Rehbein 2016)

Konfirmative und explorative Analysen nutzen hingegen die Informationsvisualisierung als ein Werkzeug zum Erkenntnisgewinn. Dabei geht die **konfirmative Analyse** von einer zuvor formulierten Hypothese, einer wissenschaftlichen Annahme, aus. Ihr Ziel ist es, Sichtweisen (*views*) auf die Daten zu erzeugen, die es erlauben, diese Hypothese zu verifizieren oder zu falsifizieren. Das oben gezeigte Beispiel ist das Ergebnis einer solchen konfirmativen Analyse. Sie ging aus von einer an anderer Stelle formulierten Annahme, dass sich der Arbeitsmarkt im Deutschen Kaiserreich nach Erlass des sogenannten Hilfsdienstgesetzes am 6.12.1916 durch zunehmende Fluktuation (nur noch kurze Verweildauer auf einem Arbeitsplatz) dynamisierte. Die Daten bestätigen diese Annahme für den Untersuchungsraum, und die Visualisierung macht dies sichtbar (Maurer/Rehbein 2016).

Im Gegensatz dazu ist die **explorative Analyse** nicht hypothesengetrieben. Ihr Ausgangspunkt sind die Daten und die Suche nach ihnen innewohnenden latenten Strukturen, Mustern, Trends, Singularitäten oder sonstigen Auffälligkeiten. Auch hier dient die Informationsvisualisierung als ein interaktives Werkzeug, das Sichtweisen auf die Daten erzeugt, die diesmal aber dazu führen sollen, auf Grundlage der an den Daten gemachten Beobachtungen Forschungshypothesen zu formulieren. So sind im obigen Beispiel die saisonalen Spitzen explorativ gefunden worden.

Eine Informationsvisualisierung kann verschieden tief gestaffelte Sichtweisen ermöglichen. Auf einer makroskopischen Ebene (vgl. den Begriff ›distant reading‹ in Kap. 20) zeigt sie übergeordnete Strukturen auf, die die einzelnen Datenelemente bilden (siehe etwa die Trendlinien im Beispiel oben). Auf einer mikroskopischen Ebene kann sie aber auch detaillierte Einblicke in die Daten erlauben (etwa die Monatswerte im Beispiel oben). Schließlich kann sie auch Sachverhalte aufdecken, die nicht explizit in den Daten enthalten sind (etwa die Saisonalität der Daten im Beispiel oben).

Wie die Informationsvisualisierung in einen **Forschungsprozess** eingebettet ist, ist im Fall der Ergebnispräsentation eindeutig: Sie steht an dessen Ende. Die analytischen Formen der Informationsvisualisierung sind hingegen in den Erkenntnisprozess eingebunden und komplex mit ihm verwoben.

23.4 | Referenzmodell und Datenmodellierung

Bei der konfirmativen wie explorativen Analyse sind Inhalte und Art der Darstellung nicht a priori festgelegt, sondern durch den Forscher aufzubereiten und zu modellieren. Card, MacKinlay und Shneiderman haben diesen mehrstufigen Prozess in einem Referenzmodell zusammengefasst. Dieses Modell beschreibt den Übergang von Rohdaten (*raw data*) – der Auswahl der Quellen für unsere Analyse – mittels einer Datentransformation zu Datentabellen (*data tables*), die auf visuelle Strukturen (*visual structures*) abgebildet werden und aus denen mittels einer weiteren Transformation Sichten (*views*) auf die Daten erzeugt werden (s. Abb. 72).

Am Beispiel der oben kurz eingeführten quantitativen Analyse von Stellenanzeigen in niederbayerischen Tageszeitungen zur Zeit des Ersten Weltkriegs sei dies kurz erläutert. **Rohdaten** sind in diesem Fall die Stellenanzeigen (s. Abb. 73 für ein Beispiel) und die darin enthaltenen Inhalte (hier verkürzt auf die Merkmale, ob es sich um ein Stellengesuch oder ein -angebot handelt und ob es sich an Männer oder Frauen richtet). Diese Merkmale werden ausgewertet und fallweise (hier: Wochen) gezählt (Variablen). Dies bildet die **Datentabelle**, die einem vorher erarbeiteten Datenmodell unterliegt (s. Tab. 13). Obiges Beispiel (»kaufm. Lehrling«) ist ein Stellenangebot der *Passauer Zeitung* aus der 19. Woche 1914. Aber richtet es sich an einen Mann, oder ist es geschlechtsneutral formuliert? Bei jedem Transformations-schritt sind solche Fragen zu beantworten, vor allem auch bereits bei der Erhebung der Daten.




Abb. 72 Referenzmodell nach Card/MacKinlay/Shneiderman (1999, 17)



Abb. 73 Stellenanzeige aus der *Passauer Zeitung*, 30.4.1914

	Fälle →	Passauer Zeitung				Kurier für Niederbayern			
		1/1914	2/1914	3/1914	...	1/1914	2/1914	3/1914	...
Merkmale / Variablen ↓									
Gesamt		7	9	12	...	4	10	14	...
Stellenangebote an Männer		3	3	6	...	0	2	5	
Stellenangebote an Frauen		0	2	1	...	2	8	6	
Stellenangebote neutral		3	3	1	...	1	0	0	
Stellengesuche von Männern		0	0	1	...	0	0	3	
Stellengesuche von Frauen		1	1	3	...	1	0	0	

Tab. 13 Ausschnitt aus der Datentabelle Stellenanzeigen niederbayerischer Tageszeitungen (vgl. Maurer/Rehbein 2016)

Solche Modellierungsentscheidungen sind immer auf der Grundlage einer **konsistenten Theorie** zu treffen (in diesem Fall wurde der ›Lehrling‹ als männlich klassifiziert, da weibliche Lehrlinge in jenem Kontext üblicherweise als ›Lehrmädchen‹ bezeichnet wurden). Hieran wird auch noch einmal deutlich, dass derartige Transformationen immer den Modellierungsprinzipien (s. Kap. 7) unterliegen und damit auch eine (subjektive) Interpretation bedeuten. Die Rolle der Theorie sollte in der Informationsvisualisierung nicht unterschätzt werden: »A silly theory means a silly graphics« (Tuft 1983, 15).

Gerade bei der Aufbereitung historischer Daten für eine Visualisierung (wie bei einer quantitativen Analyse allgemein) sind oft weitere Vorverarbeitungsschritte zu berücksichtigen, wie etwa die Disambiguierung von Namen, Georeferenzierung oder die Umrechnung auf konstante Maßeinheiten. Wichtig für die Visualisierung ist die Konsistenz und Vergleichbarkeit der Daten; der Eintrag ›3‹ in unserer Datentabelle beispielsweise muss an jeder Stelle das Gleiche bedeuten (nämlich 3 Stellenanzeigen in dieser Kategorie in einer Woche).

Die Datentabellen werden auf **visuelle Strukturen** abgebildet. Dabei wird der für die Visualisierung vorgesehene Raum (dieser kann allgemein topologisch oder spezifisch euklidisch sein) strukturiert und mit grafischen Elementen angereichert, was eine konsistente Abbildung der Daten auf diese grafischen Elemente erforderlich macht. Im obigen Beispiel erfolgt die Visualisierung auf einer zweidimensionalen, euklidischen Fläche, und die Daten werden in einer Zeitverlaufskurve aufgetragen. Jeder ›Fall‹ (hier: wochenweise Datenerhebung) bildet eine Einheit auf der horizontalen, die Merkmalsausprägungen (Variablen; hier: Anzahl der Anzeigen) auf der vertikalen Achse. Welche typischen visuellen Strukturen grundsätzlich zur Verfügung stehen, betrachten wir in 23.6.

Abbildung 71 zeigt auch ein Beispiel für eine spezifische **Sicht** auf die Daten. Es sind nicht alle in der Datentabelle kodierten Informationen visualisiert, sondern nur die für eine bestimmte Fragestellung relevanten (hier: die Gesamtzahl der Anzeigen pro Tageszeitung, nicht aber die geschlechterspezifische Ausdifferenzierung). Sichten sind somit bedarfsgerechte Konfigurationen von visuellen Strukturen, die häufig mittels interaktiver Werkzeuge erzeugt werden.

23.5 | Datentypen

Wir haben oben gesehen, dass der Übergang von den Quellen oder Rohdaten zu durch den Computer verarbeitbare Datentabellen ein kritischer Schritt ist. Hierbei erfolgt neben der Strukturierung der Daten im Rahmen der Modellierung auch eine Abbildung bzw. Abstraktion der in den Rohdaten enthaltenen Information (z. B. »kaufm. Lehrling«) auf einen spezifischen Datentyp (hier die Kardinalzahl 1) als Wert einer Merkmalsausprägung oder Variablen (»Stellenangebot an Männer«).

Datentypen sind in der Literatur ausführlich beschrieben und verschiedentlich systematisiert worden. Ihre Spannweite reicht dabei von einfachen, eindimensionalen Zahlwerten bis hin zu komplexen mehrdimensionalen Strukturen. Hier können wir zunächst an Hand der **Dimensionalität** der Variable unterscheiden zwischen eindimensionalen (auch Skalare genannt), zweidimensionalen (Paare) und mehrdimensionalen (häufig als Vektoren abgebildet) Merkmalsausprägungen. Im obigen Beispiel ist die Merkmalsausprägung jeder Stellenanzeige prinzipiell zweidimensional (1. Merkmal: Angebot oder Gesuch, 2. Merkmal: Geschlecht), in der Datentabelle jedoch als mehrere eindimensionale Einzelmerkmale modelliert. Eine zweite wichtige Unterscheidung ist, ob die Merkmalsausprägung **diskret oder kontinuierlich** ist. Für diskrete Variablen steht a priori eine nur endliche Menge von Werten zur Verfügung, zwischen denen es keine sinnvollen Zwischenwerte gibt. Kontinuierliche Variablen können dagegen grundsätzlich alle Werte (innerhalb eines bestimmten Bereichs) annehmen. So kann das Alter eines Menschen einer statistischen Population mit »38,3457... Jahren« prinzipiell millisekundengenau und damit quasi kontinuierlich angegeben oder aber auch als »Angehöriger der Alterskohorte 35–40 Jahre« mit einem diskreten Wert modelliert werden.

Nominale Daten beschreiben eine eindeutige Zuordnung zu einer Kategorie (z. B. Geschlecht: männlich oder weiblich; gesuchter Beruf: Verkäufer, Bergmann, etc.; Typ: Stellengesuch oder -angebot) haben aber keine natürliche Ordnung untereinander. Sie ermöglichen Zugehörigkeitsoperationen (gehört zu, gehört nicht zu). Eine immanente Ordnung besitzen hingegen **ordinale Daten**. Sie können sortiert und verglichen werden (ist größer als, folgt auf usw.). Die Sukzession der christlichen Päpste oder anderer Herrscher besitzt beispielsweise eine solche Ordnung. **Metrische Daten** wie die Anzahl der Stellenanzeigen im obigen Fallbeispiel erlauben darüber hinaus arithmetische und weiterführende statistische Operationen.

Daten lassen sich an Hand dieser Kriterien typisieren. Darüber hinaus wollen wir zwei Spezialfälle hervorheben: Geodaten (s. Kap. 21) als zwei- bzw. dreidimensionale Koordinaten (Länge, Breite, Höhe), und Zeitabläufe mit Start- und Enddatum. Beide sind spezifische Ausprägungen der oben genannten Datentypen und spielen für die Informationsvisualisierung in den Digital Humanities häufig eine wichtige Rolle.

Eine weitere Systematik betrachtet eine **Datenmenge** (in der Statistik als Grundgesamtheit oder Population bezeichnet) als Ganzes und beschreibt sie an Hand der Relationen, in den die einzelnen Datenelemente zueinanderstehen. Wir bezeichnen das Bezugssystem von Datenmengen als

- **temporal**, wenn die Datenelemente einen Bezug zur Zeit aufweisen (auch Zeitreihe genannt), d. h. die einzelnen Datenmessungen (Fälle) erfolgen entlang einer zeitlichen Dimension; obiges Beispiel der Stellenanzeigen ist eine solche Zeitreihe.

- **raumbezogen**, wenn die Datenelemente einen Bezug zu einem georeferenzierten Raum aufweisen, d. h. die einzelnen Datenmessungen erfolgen an oder zu bestimmten Orten (wie bei Snow).
- **abstrakt**, wenn das Bezugssystem selbst keine immanente Ordnung wie Zeit oder Raum aufweist, d. h. die einzelnen Datenmessungen erfolgen an Objekten, die nicht per se in einem Zusammenhang stehen (das ist etwa bei der Autorschafts-attribuierung der Fall, wenn bestimmte Merkmale an verschiedenen Büchern unterschiedlicher Autoren gemessen werden).
- **relational**, wenn die einzelnen Datenelemente selbst untereinander in einer semantischen Beziehung stehen, wobei diese Beziehung z. B. hierarchisch sein oder sich als Netzwerk darstellen kann.

23.6 | Visuelle Strukturen

Es gibt verschiedene visuelle Strukturen und Repräsentationstechniken, die je nach Typisierung und Charakterisierung der Daten sowie in Bezug auf eine Fragestellung spezifisch angewendet werden können. Dabei werden Visualisierungen im wissenschaftlichen Bereich heute in der Regel mittels computergestützter Werkzeuge erstellt, deren Spannweite von Standardsoftware wie Tabellenkalkulationen mit ihren Diagrammfunktionen und Statistikprogrammen über Geoinformationssysteme für raumbezogene Visualisierungen und spezialisierter Software etwa für Netzwerkvisualisierungen bis zu Visualisierungsbibliotheken für Programmiersprachen wie JavaScript, Python oder R reicht.

Der folgende Überblick über ausgewählte visuelle Strukturen ist aus zweierlei Hinsicht wichtig. Zum einen soll er eine Hilfe bei der Entscheidung für geeignete Strukturen und Repräsentationstechniken zur Erstellung von Informationsvisualisierungen sein, zum anderen eine einführende Grundlage in das Lesen und Interpretieren solcher Visualisierungen bieten.

Datenkarten (thematische Karten) visualisieren raumbasierte Datenmengen. So kann etwa die Einwohnerdichte jedes Landkreises in Deutschland durch Einfärbung des entsprechend georeferenzierten Kreises über Graustufen von sehr niedrig (weiß) zu sehr hoch (schwarz) auf eine Karte projiziert werden. Snows Visualisierung der Londoner Cholera-Epidemie ist ein einfaches Beispiel einer Datenkarte; komplexere Datenkarten können Millionen von Datenelementen projizieren. Zumeist ist dabei das einzelne Datenelement eindimensional, d. h. es wird pro georeferenzierten Ort eine Merkmalsausprägung der Daten visualisiert.

Zeitreihen visualisieren temporale Datenmengen. Die Standardzeitreihe ist dabei eindimensional, d. h. sie enthält eine Merkmalsausprägung der Datenelemente. Innerhalb einer Visualisierung können aber mehrere Zeitreihen dargestellt werden und einen Vergleich untereinander ermöglichen. Minards Beispiel zeigt zudem, wie temporale und raumbasierte Darstellungen kombiniert werden können.

Abstrakte Datenvisualisierungen zeigen Daten ohne Raum- oder Zeitbezug. Wir können sie nach der Dimensionalität der Daten unterscheiden. Zur Darstellung **univariater (eindimensionaler) Daten** dienen unter anderem Punkt- und Liniendiagramm, Histogramm und Boxplot.

Das **Punktdiagramm** ist die abstrakte Form der Zeitreihe, bei der das Bezugssystem nicht temporal ist, sondern die einzelnen Messpunkte in eine andere (sinnvolle) Reihenfolge gebracht werden. Hierüber sollen Trends in der Verteilung der Merk-




Abb. 74 Visualisierung der Länge der 114 Koransuren (in Versen) nach ihrer Anordnung im Koran. Sie veranschaulicht, dass die Suren im Koran im Wesentlichen nach ihrer Länge angeordnet sind, oder mit anderen Worten: dass eine starke Korrelation zwischen der Verszahl und der Nummer der Sure vorliegt.

malsausprägungen (*frequency distribution*) der Daten visualisiert werden, oft unterstützt durch statistische Ausgleichsfunktionen. Verbindet man die einzelnen Datenpunkte untereinander, spricht man von einem **Liniendiagramm**.

Histogramm und Boxplot bilden die Häufigkeitsverteilung der Merkmale einer Datenmenge ab. Ein **Histogramm** stellt dabei im Überblick dar, in welchen Wertebereichen einer Datenmenge Häufungen auftreten. Hierzu werden die Merkmalsausprägungen in Intervalle zerteilt und gezählt, wie viele Datenelemente in jedes Intervall fallen. Diese Anzahl (oder deren Anteil an der Gesamtmenge) bestimmt die Höhe des jeweiligen Balkens (ein Beispiel findet sich in Kap. 10). Ein **Boxplot** gibt einen Überblick über statistische Kennwerte (Minimum, Maximum, Spannweite, Median, oberes und unteres Quartil) der Verteilung und bietet sich darüber hinaus dann an, wenn mehrere Datenmengen miteinander verglichen werden sollen (ein Beispiel findet sich in Kap. 20).

Als Standardrepräsentationstechnik für **bivariate (zweidimensionale) Daten** dient das Streudiagramm. Im **Streudiagramm** (engl. *scatter plot*) ist jedes Datenelement durch einen Punkt in einem kartesischen Koordinatensystem repräsentiert; seine Position ergibt sich aus den beiden Merkmalsausprägungen, die auf der horizontalen bzw. vertikalen Achse skaliert werden. Streudiagramme werden vor allem eingesetzt, um im Datensatz globale oder lokale Abhängigkeiten der beiden Variablen zu finden und zu visualisieren (Korrelationsanalyse) bzw. Datenelemente zu identifizieren, die sich an Hand ihrer Merkmalsausprägungen ähneln (Clusteranalyse).

Durch eine farbliche oder andere Kodierung der Datenelemente im Streudiagramm kann die Anzahl der zur Visualisierung herangezogenen Variablen auf drei erhöht werden (**trivariate Daten**), wobei sich als dritte Variable nominale bzw. in einzelne Klassen zusammengefasste Daten eignen. In der konfirmativen Analyse

kann diese dritte Variable a priori bestimmt und ihre zuvor hypothetisch formulierte Korrelation mit bestimmten Konstellationen der anderen beiden Variablen visuell bestätigt werden.

Streudiagramme werden häufig in Zusammenhang mit fortgeschrittenen Verfahren aus der Statistik und dem maschinellen Lernen eingesetzt, die dazu dienen, **multivariate (mehrdimensionale) Daten** in ihrer Komplexität zu reduzieren und einen visuellen Eindruck über ihre Struktur zu verschaffen. Zu nennen ist hier vor allem das Verfahren der Hauptkomponentenanalyse, das in verschiedenen Anwendungsfällen der Digital Humanities zum Einsatz kommt. Dabei werden komplexere Daten auf zwei Dimensionen reduziert, die wiederum gut visualisiert, wahrgenommen und kognitiv verarbeitet werden können. Daten mit einer Dimensionalität größer als drei direkt zu visualisieren, ist im Allgemeinen nicht möglich. Gängiger Ausweg ist die synoptische Darstellung mehrerer Einzelvisualisierungen, wobei allerdings der übergeordnete Zusammenhang leicht verlorengeht.

Graphen und Bäume ermöglichen die Darstellung von Beziehungen (Relationen) der Datenelemente untereinander. Sind die Daten als Menge von durch Kanten verbundenen Knoten modelliert, so bietet sich die Visualisierung als Graph bzw. Netzwerk an. Anwendungsbeispiele stammen unter anderem aus der Netzwerkanalyse (s. Kap. 10). Die Begriffe sind dabei unglücklicherweise mehrfach belegt: ›Graph‹ bezeichnet sowohl das Datenmodell als auch das zu Grunde liegende mathematische Modell sowie auch die Darstellungsform. Dies ist begrifflich auseinanderzuhalten. Gleiches gilt für ›Netzwerk‹: der Begriff bezeichnet das (soziale) Phänomen, das mit den Daten beschrieben ist ebenso wie die Darstellungsform.

Visuelle Graphen sollen einen Überblick über die Eigenschaften des Netzwerks als Ganzes sowie die Lage einzelner Knoten oder ihrer Beziehung untereinander bzw. Gruppen von Knoten (z. B. Cluster, Cliques) verschaffen. Hierzu werden die Knoten des Netzwerks und insbesondere ihre Lage zueinander mittels spezifischer Algorithmen im (in der Regel zwei-, manchmal dreidimensionalen) Darstellungsraum verortet (vgl. ausführlich: Krempel 2005). Es ist eine Vielzahl solcher Visualisierungsalgorithmen für unterschiedliche Anwendungszwecke entwickelt worden (s. auch Kap. 10). Deren Auswahl beeinflusst das Erscheinungsbild der Visualisierung und deren Aussagekraft maßgeblich.

Als eine Möglichkeit, hierarchische Strukturen von Daten zu visualisieren, dienen **Bäume**. Sie basieren auf azyklisch (gerichteten) Graphen mit designiertem Wurzelknoten und stellen einen Sonderfall eines Netzwerkes dar. Ein bekanntes Beispiel ist etwa die Organisation einer Verwaltung (häufig dargestellt als Organigramm). Hierarchische Strukturen dieser Art finden sich in den Geisteswissenschaften häufig, exemplarisch zu nennen seien Genealogien (familiäre Stammbäume), Handschriftenstemma oder Klassifikationssysteme von Bibliotheken. Als **Dendogramme** werden Bäume auch zur Visualisierung des Ergebnisses einer Clusteranalyse (z. B. in Verfahren der Stilometrie) verwendet.

Gestaltungsmittel

Vor allem, wenn eine Informationsvisualisierung als Präsentationsform, d. h. zum Zweck der Kommunikation eingesetzt wird, spielt ihre Gestaltung eine wichtige Rolle. Abzuwägen ist, ob überhaupt eine Grafik gewählt wird oder die Daten nicht in Tabellenform präsentiert werden. Tabellen sind bei kleinen Datensätzen zu bevorzu-

gen, vor allem wenn die exakten Werteausprägungen wichtig sind. Texte ergänzen die Grafiken und leiten in der reinen Illustration und Präsentation die Aufmerksamkeit des Betrachters. Bei der analytischen Form der Visualisierung dienen Begleittexte dem Betrachter, um zu verstehen, wie die Visualisierung zustande gekommen ist.

Visuelle Codes: Wie Zeichen (s. Kap. 5) kodieren auch grafische Elemente bestimmte Informationen, die erst durch die Dekodierung seitens des Betrachters eine Bedeutung erhalten. Dabei unterliegen die grafischen Codes bestimmten Konventionen. Diese gelten entweder spezifisch für ein bestimmtes Bild oder sind allgemein gültig. Im ersten Fall werden sie durch den Betrachter **implizit** über den Kontext ermittelt bzw. wurden vom Gestalter der Visualisierung durch Legende oder textuelle Erläuterung explizit kommuniziert. Im zweiten Fall folgt die Gestaltung der Visualisierung (vermeintlich) **allgemeinen Konventionen** wie etwa der Benutzung von Rot als Signalfarbe zur Hervorhebung besonderer Aspekte oder der höheren Bedeutung, die in der Grafik zentral angeordneten Elementen in der Regel beigemessen wird.

Hierbei ist zu berücksichtigen, dass vor allem in einem interkulturellen Kontext unterschiedliche Konventionen gelten können, die leicht zu einer **Fehlinterpretation** einer Grafik führen können. Auch persönliche Erfahrung, individuelles Vorwissen und Erwartungshaltungen, Sozialisierung und die Ausprägung spezifischer kognitiver Fähigkeiten bis hin zu Wahrnehmungspräferenzen beeinflussen, wie empfänglich ein Betrachter für eine Informationsvisualisierung ist und wie er diese interpretiert. Informationsvisualisierung wird deshalb auch wahrnehmungspsychologisch betrachtet, was wir hier jedoch nicht vertiefen können.

Grundlegend für die Semiotik grafischer Elemente und ihrer Nutzung innerhalb von Informationsvisualisierungen sind die Arbeiten von Jacques Bertin (1967). Jedes Element einer Visualisierung (z. B. ein Punkt in einem Punktdiagramm), von Bertin »Markierung« genannt, kann durch grafische Variablen verändert werden. Bertin definiert sieben solcher Variablen, die er »retinal« nennt, da sie durch die Netzhaut des Auges (Retina) aufgenommen und unterschieden werden können: Position, Größe, Helligkeit, Textur, Farbe, Orientierung und Form.

Jede dieser Variablen besitzt bestimmte Eigenschaften, die durch die Möglichkeiten der menschlichen Perzeption bestimmt sind: Sie können assoziativ (d. h. mehrere Elemente werden als zusammengehörend wahrgenommen), selektiv (Elemente werden als verschieden wahrgenommen), ordnend (Elemente werden als aufeinander folgend wahrgenommen) oder quantitativ (der Unterschied zweier Elemente wird numerisch interpretiert) wirken (s. o.: Datentypen). So ist die Variable »Farbe« beispielsweise geeignet, eine Datenmenge zu klassifizieren, da sie assoziativ wirkt. Weil für die menschliche Wahrnehmung Farben aber keine offensichtliche Ordnung besitzen, kann aus der Farbwahl keine Reihenfolge der einzelnen Datenelemente abgeleitet werden; sie wirkt nicht ordnend. Dies ist wohl aber mit der Variable »Helligkeit«, z. B. durch Verwendung von Graustufen, möglich. Das Modell von Bertin ist von späteren Autoren weiterentwickelt worden; in jüngerer Zeit wurde die Animation als zusätzliche Variable berücksichtigt.

Zu grundsätzlichen Gestaltungsprinzipien von Informationsvisualisierungen hält Tufte zusammenfassend fest: »Graphical elegance is often found in simplicity of design and complexity of data [...] What is to be sought in designs for the display of information is the clear portrayal of complexity. Not the complication of the simple; rather the task of the designer is to give visual access to the subtle and the difficult – that is, the revelation of the complex« (Tufte 1983, 177; 191). Die Erörterung einzel-

ner Prinzipien, *wie* dies erreicht werden kann, sprengt den Rahmen dieser Einführung (zur Vertiefung vgl. u. a. Tufte 1983; Meirelles 2013). Hervorzuheben ist aber, dass Visualisierungen im Kontext der Digital Humanities primär eine wissenschaftliche und keine ästhetische Funktion haben.

Interaktion

Wird die Informationsvisualisierung als analytisches Werkzeug gebraucht, so spielt die menschliche Interaktion mit diesem Werkzeug eine wichtige Rolle. Insbesondere lassen sich damit bedarfsgerechte Sichten auf die Daten erzeugen. Die Grundfunktionen umfassen dabei (nach Yi et al. 2007, 1226):

- Aus- und Abwählen (markiere etwas als (un-)interessant),
- Explorieren (zeige mir etwas anderes),
- Rekonfigurieren (zeige mir eine andere Anordnung),
- Rekodieren (zeige mir eine andere Repräsentation der Daten),
- Zusammenfassen/Vertiefen (zeige mir mehr oder weniger Details),
- Filtern (zeige mir etwas unter Bedingungen) und
- Verbinden (zeige mir verwandte Elemente).

Diese interaktiven Funktionen stellen damit eine Verfeinerung des sogenannten »Mantras der Informationsvisualisierung« von Ben Shneiderman dar: »Overview first, zoom and filter, then details-on-demand«. Damit wird der analytische, vor allem der explorative Charakter der Informationsvisualisierung unterstrichen.

Bei allen Interaktionen ist stets sorgfältig zu unterscheiden, ob die dafür durchgeführten Operationen auf den Daten erfolgen oder rein visuell sind. Wählt man etwa in einem Graphen Knoten mit bestimmten Eigenschaften ab, so ist dies eine rein visuelle Operation (andere Knoten verbleiben an ihrem Ort). Filtert man allerdings die zu Grunde liegenden Daten oder rekodiert sie, so entsteht durch den **Visualisierungsalgorithmus** unter Umständen ein gänzlich anderes Netzwerk.

An Interaktionsmodalitäten kann – je nach Anwendungsfall – grundsätzlich die gesamte technologische Palette zum Einsatz kommen, wobei in den Digital Humanities weiterhin die Interaktion über Maus, Tastatur und Touchscreen Standard sind. Darüber hinaus werden zur Visualisierung großer Datenmengen vermehrt sogenannte *Visualization Walls* (mehrere Screens in Form einer Matrix angeordnet). Dass 3D-Technologien, Datenbrillen und Instrumente der Virtual Reality in die Informationsvisualisierung im Kontext der Digital Humanities Einzug halten werden, ist absehbar. Als Präsentationsformen werden sie derzeit vor allem in der musealen Ausstellungspraxis erprobt.

Die Frage der Interaktion mit visuellen Werkzeugen gehört in ein weites Feld, das sich inzwischen als eigenständiges interdisziplinäres Forschungsgebiet zwischen Technologie und Psychologie bzw. Soziologie etabliert und hier nicht weiter vertieft werden kann: der Mensch-Maschine-Interaktion (engl. Human-Computer Interaction, HCI).

23.7 | Kritische Informationsvisualisierung

In der heutigen, stark visuell geprägten Welt haben Bilder eine starke Wirkmacht, die in allen Bereichen – nicht nur der Wissenschaft – genutzt aber auch missbraucht wird. Visualisierungen sollen dem Betrachter einen Zugang zu den Daten ermöglichen, sie können ihn aber auch beeinflussen und manipulieren (Dörk et al. 2013, 2195). Daher ist die Befähigung zu einem kritischen Umgang mit Visualisierungen elementar. In diesem Zusammenhang verstehen wir unter einer **Visual Literacy** zum einen die Fähigkeit, Informationen in Bildern und Grafiken zu ›lesen‹, zu verstehen und zu interpretieren und zum anderen, Informationen in Bilder und Grafiken zum Zweck der Kommunikation und Analyse zu transformieren. Diese Visual Literacy sollte Teil einer gesellschaftlichen Allgemeinbildung sein.

Kritischer Informationsvisualisierung liegt das Wort ›**kritisch**‹ in der Bedeutung zu Grunde, etwas nicht als einfach gegeben hinzunehmen, sondern es zu hinterfragen. Kritisches Denken heißt in unserem Zusammenhang, die eingesetzten Daten, Werkzeuge, Methoden und theoretischen Grundlagen in ihrem Zusammenwirken zu reflektieren. Dies gilt für die Digital Humanities ganz besonders, da ihnen, wie allen Wissenschaften, das kritische Denken immanent sein muss. Wie etwa die für eine Analyse herangezogenen Daten in Hinblick auf die Fragestellung bzw. Forschungshypothese begründet werden müssen, muss auch die Methodik, also die Frage, *wie* eine Visualisierung zustande gekommen ist, kritisch hinterfragt werden können, weswegen alle zu einer Visualisierung führenden Schritte transparent gemacht werden müssen.

Charakteristika geisteswissenschaftlicher Daten: Im Bereich der Geisteswissenschaften ist dies von essentieller Wichtigkeit, da wir es hier mit Daten zu tun haben, die häufig unscharf, mehrdeutig, unvollständig oder verzerrt sind. Wie komplex diese Zusammenhänge sind, zeigt modellhaft Abb. 75 Informationsvisualisierung im geisteswissenschaftlichen Forschungsprozess (Modell).

Dabei soll insbesondere deutlich werden, dass Informationsvisualisierungen uns kein direktes Abbild auf die Wirklichkeit der von uns untersuchten Systeme liefern. Stattdessen liegen zwischen uns und unserem Untersuchungsgegenstand mehrere Filter, die aus komplexen Gegebenheiten geisteswissenschaftlicher Interessen auf eine Grafik projizierte Datenpunkte erzeugen. Diese Filter sind oft gar nicht beeinflussbar, teils werden sie von anderen unter bestimmten Prämissen konfiguriert (wenn wir auf bestehende Datenquellen zugreifen) und nur teils vom jeweiligen Forscher selbst. Elementar für die Nutzung in der Forschung ist, dass alle Filter transparent und somit intersubjektiv überprüfbar gemacht und wir uns im Klaren darüber sind, was sie für die kritische Interpretation der Visualisierung bedeuten.

Zugleich ist immer die Frage nach der Aussagekraft der Daten in der Visualisierung zu stellen: Nur aus der bloßen Existenz von Daten kann nicht auf deren Bedeutsamkeit geschlossen werden, und nicht alles, was (in einem bestimmten Kontext) bedeutsam ist, hinterlässt messbare Datenspuren.

Ein weiterer Schritt ist durch den Forscher selbst zu vollziehen: Visualisierungen sind häufig gut geeignet, um Strukturen und Muster zu zeigen. Sie liefern allein für sich aber keine Erklärungen. Mit anderen Worten: Korrelationen oder Koinzidenzen,




Abb. 75 Informationsvisualisierung im geisteswissenschaftlichen Forschungsprozess (Modell). Hierin eingebettet ist das Referenz-Modell nach Card/MacKinlay/Shneiderman 1999 (s. Kap. 23.4).

wie sie sich vielleicht in den Daten erkennen lassen, bedeuten noch keine Kausalität, eine Wiederkehr noch keine Gesetzmäßigkeit. Erklärungen lassen sich erst durch Interpretation der Visualisierungen, oft unter Bezugnahme von anderen Daten, Quellen oder auch Methoden, durch den Forscher folgern.

Literatur

- Bertin, Jacques: *Sémiologie graphique. Les Diagrammes, les Réseaux, les Cartes*. Paris 1967.
- Card, Stuart: »Information visualization«. In: Andrew Sears/Julie A. Jacko (Hg.): *The Human-Computer Interaction Handbook. Fundamentals, Evolving Technologies, and Emerging Applications*. New York 2008, 509–543.
- Card, Stuart/MacKinlay, Jock/Shneiderman, Ben: *Readings in Information Visualisation. Using Vision to Think*. San Francisco 1999.
- Dörk, Marian/Collins, Christopher/Feng, Patrick/Carpendale, Sheelagh: »Critical InfoVis: Exploring the politics of visualization«. In: *Extended Abstracts of the SIGCHI Conference on Human Factors in Computing Systems* (2013), 2189–2198.
- Krempel, Lothar: *Visualisierung komplexer Strukturen. Grundlagen der Darstellung mehrdimensionaler Netzwerke*. Frankfurt a. M. 2005.
- Maurer, Stefanie/Rehbein, Malte: »Zur Entwicklung des Passauer Arbeitsmarktes im Ersten Weltkrieg anhand einer quantitativen Analyse regionaler Tageszeitungen«. In: *Passauer Jahrbuch* (im Erscheinen).
- McCormick, Bruce/DeFanti, Thomas/Brown, Maxine: »Visualization in scientific computing«. In: *Computer Graphics* 21 (1987), 1–14.
- Meirelles, Isabel: *Design for Information. An Introduction to the Histories, Theories, and Best Practices behind Effective Information Visualizations*. Beverly 2013.
- Thomas, James J./Cook, Kristin A.: *Illuminating the Path*. Los Alamitos 2005.
- Tufte, Edward R.: *The Visual Display of Quantitative Information*. Cheshire 1983.
- Yi, Ji Soo/Kang, Youn ah/Stasko, John/Jacko, Julie: »Toward a deeper understanding of the role of interaction in information visualization«. In: *IEEE Transactions on Visualization and Computer Graphics* 13/6 (2007), 1224–1231.

Malte Rehbein

V Recht und Ethik

24 Recht

Rechtsfragen gehörten bisher nicht zu den Themen, mit denen sich die Geistes- und Kulturwissenschaften intensiv beschäftigen mussten. Mit der zunehmenden Digitalisierung in Forschung und Lehre hat sich dies geändert. Der Grund für die gewandelte Bedeutung des Rechts ist in der Auflösung der festen Verbindung von Inhalt und Trägermedium zu suchen, wie sie vor allem im gedruckten Buch über Generationen hinweg selbstverständlich gegeben war.

Dieser Beitrag erläutert die rechtlichen Auswirkungen der Digitalisierung von Wissens(chafts)objekten und stellt die unterschiedlichen juristischen Aspekte dar, unter denen Digitalia betrachtet und eingeordnet werden. Daran anschließend werden Bedingungen und Möglichkeiten einer **rechtskonformen Nutzung** digitaler Inhalte behandelt. Sodann werden die Konsequenzen aufgezeigt, die sich für die Digital Humanities ergeben, wenn dort digitale Inhalte erarbeitet, publiziert und nachgenutzt werden sollen. Hier wird es zentral um das Prinzip von **Open Access** und dessen Funktionsweise gehen. Resümierend soll am Ende der Stellenwert von Rechtsfragen in den Digital Humanities bestimmt werden.

Im Rahmen einer Einführung kann es nicht darum gehen, aktuelle Einzelfragen zu diskutieren. Dies ist allein schon wegen der Dynamik der Rechtsentwicklung unmöglich. Daher sollen hier nur grundlegendes Strukturwissen und Problembewusstsein vermittelt werden. Auch wenn viele Rechtsfragen ständigen Veränderungen unterworfen sind, gibt es dennoch einige recht stabile Grundstrukturen, die man kennen sollte, wenn man in den Digital Humanities tätig ist. Sie helfen nicht nur, eine rechtssichere Forschungspraxis zu ermöglichen, sondern befähigen auch dazu, künftigen Diskussionen um die rechtliche Einordnung digitaler Inhalte folgen und deren Auswirkungen auf die Digital Humanities abschätzen zu können.

24.1 | Digitale Objekte – mehr als nur ein Medienwandel

Vordergründig betrachtet, unterscheiden sich die Digital Humanities von den konventionellen Geistes- und Kulturwissenschaften vor allem dadurch, dass sie mit digitalen Objekten arbeiten. Man ist leicht geneigt, hier einen bloßen Medienwandel anzunehmen, der zwar an der einen oder anderen Stelle methodische Auswirkungen hat, ansonsten aber die eingespielten Arbeitsweisen kaum berührt (s. Kap. 2). Diese Sicht ist, betrachtet man sie aus einer juristischen Perspektive, grundfalsch. Dass es neben einigen, im Zuge der **Plagiate-Debatte** aufgekommenen Fragen überhaupt eine juristische Sicht auf geistes- und kulturwissenschaftliches Arbeiten geben soll, ist freilich ungewohnt und verstellt noch einmal mehr den Blick auf die grundlegend andere Situation, in der sich die Digital Humanities im Vergleich zu den konventionell arbeitenden Disziplinen befinden.

Der Medienwandel in den Geistes- und Kulturwissenschaften ist durch die Digitalisierung von Inhalten einerseits und die Vorhaltung dieser Inhalte in Netzwerken andererseits geprägt. Digitale Inhalte können aber nur dann Bestandteil von Netzwerken sein, wenn sie unabhängig von konkreten Trägermedien wie beispielsweise gedruckten Büchern sind und allein im Wege der Kopie, also ohne einen physischen Transport von **Trägermedien** auf unterschiedlichen, mit dem Netzwerk verbundenen Systemen zugänglich gemacht werden können. Auf den ersten Blick scheint das

Verschwinden der Trägermedien ein Freiheitsgewinn zu sein, weil die jeweiligen Inhalte jetzt zeit- und ortsunabhängig einer unbegrenzten Anzahl von Nutzern verlust- und verschleißfrei zur Verfügung stehen können.

Übersehen wird hier aber, dass das Trägermedium nahezu alle Arten seiner Benutzung auf die simple Frage des erlaubten Zugangs zu einem Objekt hin bündelt und reduziert, obwohl es selbst Beschränkungen in der Benutzbarkeit mit sich brachte, denn es kann in der Regel nur von einer Person zugleich verwendet werden, unterliegt der Abnutzung, kann verloren gehen oder dergleichen mehr. Da die allermeisten für das wissenschaftliche Arbeiten relevanten Objekte in öffentlich zugänglichen Sammlungen wie Bibliotheken, Archiven und Museen vorhanden sind, ist mit der Zulassung zur Benutzung dieser Einrichtungen die Frage der rechtmäßigen Nutzung praktisch beantwortet.

Niemand muss sich darüber Gedanken machen, ob es neben dem Eigentümer an der konkreten Sache noch andere, an dem bloßen Inhalt Berechtigte gibt, die noch gefragt und berücksichtigt werden müssen. Man stellt ein Buch in eine Bibliothek, leiht es aus und liest es, ohne dass andere als die Eigentümer dieses Buches in diese Vorgänge involviert wären oder um Erlaubnis gefragt werden müssten. Wissenschaftliches Arbeiten in den konventionellen Geistes- und Kulturwissenschaften war im Wesentlichen Arbeiten mit konkreten Sachen und Objekten. Mit dem Wegfall der Trägermedien rücken nun die Inhalte selbst in den Fokus mit juristisch sehr unangenehmen Konsequenzen, vor allem im **Urheberrecht**.

Jede eigenschöpferische, sinnlich wahrnehmbare geistige Leistung unterliegt bis 70 Jahre nach Tod desjenigen Menschen, der sie geschaffen hat, dem Urheberrecht. Der Schöpfer bzw. Urheber kann umfassend bestimmen, in welcher Art und Weise sein Werk genutzt wird. Dieses Verwertungsrecht, das meist in Form von ausschließlichen Nutzungsrechten von Verlagen ausgeübt wird, ist bei jeder Vervielfältigung, bei jeder Online-Stellung und bei jeder Verbreitung von Trägermedien (sog. Werkstücken) betroffen. Allerdings gibt es gerade für die Verbreitung von Werkstücken eine wichtige Ausnahme, den sogenannten **Erschöpfungsgrundsatz** (§ 17 Abs. 2 UrhG Urheberrechtsgesetz). Danach erlischt das Verbreitungsrecht an einem konkreten Werkstück bei seiner rechtmäßigen Erstverbreitung, also in aller Regel durch den käuflichen Erwerb. Das weitere Schicksal des erworbenen Werkstückes richtet sich, von der Ausnahme einer Vermietung gegen Geld einmal abgesehen, allein nach dem Willen dessen, dem das konkrete Objekt als Sache gehört. Durch die Bündelung vieler Trägermedien in den Sammlungen und Bibliotheken wissenschaftlicher Institutionen, aber auch durch die eigene Handbibliothek entsteht so ein relativ unkomplizierter und von rechtlichen Vorgaben weitgehend freier Raum für wissenschaftliches Arbeiten.

Denkt man sich nun das Trägermedium weg, konzentriert man sich bei einem gedruckten Buch also allein auf den Text, der digital auf einem Server liegt und in Form von Kopien auf einer Unzahl von Endgeräten verfügbar ist und dort wiederum lokal abgespeichert wird, so bedeutet dies urheberrechtlich, dass jedes (!) Mal, wenn dieser Text aufgerufen wird, bei seiner Übertragung und seiner Anzeige rechtlich relevante Vervielfältigungen erzeugt werden. Gleiches gilt auch für Maßnahmen der digitalen **Langzeitarchivierung**. Ist der Text überdies Personen zugänglich, die nicht durch persönliche Beziehungen miteinander verbunden sind, liegt – selbst in passwortgeschützten Arbeitsumgebungen – auch noch eine **öffentliche Zugänglichmachung** vor (vgl. § 52a UrhG). Vervielfältigungen und öffentliche Zugänglichmachung aber sind jeweils Eingriffe in das Verwertungsrecht des Urhebers bzw. die ausschließ-

lichen Nutzungsrechte von Rechteinhabern wie Verlegern. Eine Erschöpfung dieser Rechte, wie dies beim Verbreitungsrecht eines gedruckten Buches der Fall ist, gibt es nicht. Daraus folgt, dass ausnahmslos jede Form von Nutzung eines trägerlosen Werkes unter urheberrechtlichen Gesichtspunkten zu bewerten ist.

Im Ergebnis hat also der bloße Medienwandel durch den Wegfall eines mit dem Werk fest verbundenen körperlichen Trägers zu einer juristisch vollkommen neuen Situation geführt. Man mag dieses Ergebnis als eine in der Sache verfehlte Übergriffigkeit des Urheberrechts auf digitale Rezeptions- und Kommunikationsbeziehungen kritisieren. Es ergibt sich gleichwohl als zwingende Konsequenz der Verwerterzentrierung des geltenden Rechts mit ihrer rein technisch-formalen Betrachtungsweise von Nutzungsvorgängen. Die Arbeit mit digitalen Inhalten ist daher untrennbar mit einer erhöhten Sensibilität für Rechtsfragen verbunden.

Digitale Objekte als Gegenstand verschiedener Schutzrechte

Bislang war allein vom Urheberrecht die Rede. Dieses Recht schützt bis 70 Jahre nach Tod des Urhebers kreative Leistungen; danach ist das Werk gemeinfrei. Darüber hinaus gibt es in der Rechtsordnung noch sogenannte verwandte Schutzrechte, die unter bestimmten Bedingungen auch solche Leistungen schützen, die keinen eigenschöpferischen Charakter haben. Für den Bereich der Digital Humanities sind hier die Leistungsschutzrechte für Lichtbilder (§ 72 UrhG), der nachgelassenen Werke (§ 71 UrhG: *editio princeps*) und der wissenschaftlichen Ausgaben (§ 70 UrhG) sowie der sogenannte *Sui-generis*-Schutz des Datenbankherstellers (§§ 87a ff. UrhG) von Bedeutung.

- **Lichtbilder:** Der Lichtbildner erwirbt ein dem Urheberrecht verwandtes Schutzrecht für fotografische Aufnahmen, zu denen auch Scans gehören, die mehr sind als eine bloß technische Reproduktion (Fotokopie). Dieses Schutzrecht ist unabhängig von dem konkret dargestellten Gegenstand. So kann beispielsweise ein wissenschaftlichen Anforderungen genügender Scan eines Papyrusfragments leistungsschutzrechtlich für 50 Jahre geschützt sein. Da bei einer zweidimensionalen Vorlage ein Lichtbild funktional aber mehr oder weniger identisch mit dem Original ist, ist umstritten, ob in diesem Fall tatsächlich ein Leistungsschutzrecht entsteht, weil durch die Hintertür des Lichtbilderschutzes die durch das Auslaufen des Urheberrechts erreichte Gemeinfreiheit der Vorlage umgangen würde.
- **Nachgelassene Werke:** Im Gegensatz zum Lichtbilderleistungsschutzrecht ist die Gemeinfreiheit einer Vorlage bei den Schutzrechten für nachgelassene und wissenschaftliche Ausgaben nicht nur unproblematisch, sondern sogar Voraussetzung für das Entstehen des Schutzrechts. Beim Schutz nachgelassener Werke geht es darum, dass derjenige, der ein bislang unpubliziertes Werk, für das kein Urheberschutz mehr besteht, herausgibt, ein 25 Jahre währendes Schutzrecht erhält. Dieses Recht soll die Investitionen für die Herausgabe sichern, indem es den fehlenden Urheberschutz durch einen Leistungsschutz ersetzt. Gleiches gilt für nach wissenschaftlichen Maßstäben erstellte neue Editionen gemeinfreier Werke (historisch-kritische Ausgaben).
- **Sui-generis-Schutz:** Speziell für digitale Inhalte ist der *Sui-generis*-Schutz für Datenbanken von besonderer Bedeutung. Er tritt neben einen möglichen Schutz der in den Datenbanken selbst enthaltenen Elemente. So sind die einzelnen Elemente

einer Datenbank mit Aufsätzen und Fotografien regelmäßig urheber- und leistungsschutzrechtlich geschützt. Die Datenbank als solche genießt darüber hinaus ebenfalls einen Schutz, wenn die Erstellung der Datenbank eine wesentliche Investition darstellt. In diesem Fall steht an der Datenbank als ganzer sowie an einem wesentlichen Teil von ihr dem Hersteller der Datenbank ein Leistungsschutzrecht zu. Da dieser Schutz unabhängig von einem Schutzrecht an den einzelnen Elementen besteht, ist auch eine Datenbank mit gemeinfreien Werken, beispielsweise Gedichten des 18. Jahrhunderts, rechtlich geschützt, wenn ihre Herstellung eine wesentliche Investition erfordert hat.

Werke, Lichtbilder, nachgelassene Werke und wissenschaftliche Ausgaben sowie Datenbanken können rechtlich geschützt sein. Unklar ist demgegenüber die rechtliche Ein- und Zuordnung von Forschungsdaten, wenn diese Daten mangels Schöpfungshöhe keine Werke oder durch Leistungsschutzrecht geschützte Inhalte, sondern wie etwa schlichte Wortlisten oder statistische Angaben bloße Informationen sind, die als solche keinem Schutzrecht unterfallen. Hier wird in aller Regel bloß ein Recht an der Datenbank in Betracht kommen.

Die rechtmäßige Nutzung digitaler Objekte

Die Existenz von Schutzrechten sagt noch nichts aus über die Frage, unter welchen Bedingungen Inhalte genutzt werden dürfen. In der konventionell arbeitenden Wissenschaft bildete im Wesentlichen das Eigentumsrecht an konkreten Sachen und Objekten eine ausreichende und einfache Arbeitsgrundlage. Bei **Digitalia** treten Nutzungsrechte an die Stelle des Eigentums, die entweder – mit sehr unterschiedlicher Reichweite im Einzelfall – vertraglich vereinbart werden oder sich aus einer gesetzlichen Erlaubnis, einer sogenannten **Schrankenbestimmung** ergeben, also einer Einschränkung der Verwertungs- und Nutzungsrechte von Rechteinhabern. Die wenigen Fotokopien, die in der analogen Welt angefertigt wurden, oder wörtliche Zitate sind die wohl bekanntesten Fälle solcher Schrankenregelungen (vgl. §§ 51, 53 UrhG).

Bei ihrer Arbeit mit digitalen Inhalten gehen die Digital Humanities über den eng umrissenen Bereich der Fotokopie und des Zitats hinaus. Sie benötigen allein schon zur bloßen Nutzung einer Ressource Nutzungsrechte bzw. weitergehende gesetzliche Schrankenbestimmungen, da der Abruf von Inhalten und deren Anzeige auf Endgeräten bereits durch die dabei erforderlichen Vervielfältigungshandlungen in **Verwertungsrechte** eingreifen (vgl. § 44a UrhG). Problematisch ist auch die durch technische Möglichkeiten besonders einfach mögliche Kooperation zwischen verschiedenen Wissenschaftlern und Institutionen, weil hier regelmäßig eine Öffentlichkeit im urheberrechtlichen Sinn gegeben ist.

Der Abruf von Inhalten und deren Nutzung setzen voraus, dass diese digital vorliegen. Ein nicht geringes Problem in den Digital Humanities ist es aber, analoge Inhalte zu digitalisieren. Soweit diese urheberrechtlich geschützt sind, sind dafür und für die anschließende Nutzung der Digitalisate entweder sehr aufwändig Nutzungsrechte bei möglichen Rechteinhabern einzuholen oder ausreichende Schrankenbestimmungen im Urheberrechtsgesetz erforderlich. Solche Schranken sind für die Digitalisierung als solche relativ gut vorhanden (Archivschränke in § 53 UrhG), für die öffentliche Nutzung gibt es demgegenüber nur wenige Bestimmungen (z. B. das Zitatrecht in § 51 UrhG). So gestattet die **Archivschränke** zwar die vollständige Digita-

lisierung von Vorlagen, deren Eigentümer man ist. Die Nutzung der so erstellten Digitalisate durch Dritte aber ist nur an stationären Leseplätzen (§ 52b UrhG), ausschnittsweise in passwortgeschützten Arbeitsumgebungen (§ 52a UrhG) oder in Form kurzer Zitate in eigenen Netzpublikationen (§ 51 UrhG) erlaubt.

Ein besonderes Problem stellen in diesem Zusammenhang die sogenannten verwaisten Werke dar; sie werden auch als **Orphan Works** bezeichnet. Dabei handelt es sich um Werke, die von ihrem Schöpfungszeitpunkt her sehr wahrscheinlich noch urheberrechtlich geschützt, bei denen aber für die Einholung von Nutzungsrechten keine Ansprechpartner bekannt sind. Auf der Grundlage einer europäischen Richtlinie wurde 2013 eine neue Schrankenbestimmung im Urheberrechtsgesetz geschaffen, die eine Digitalisierung und öffentliche Nutzung verwaister Werke unter bestimmten Bedingungen, zu denen vor allem eine sorgfältige und in der Praxis sehr umständliche Suche nach Rechteinhabern gehört, gestattet (§§ 61 ff. UrhG). Ergänzt wird diese Regelung im deutschen Recht durch die Möglichkeit, gegen Zahlung einer Gebühr an eine Verwertungsgesellschaft ältere, vor 1966 erschienene vergriffene Werke zu digitalisieren und über das Internet verfügbar zu machen (§§ 51 f. VGG Verwertungsgesellschaftengesetz).

Ein für die Digital Humanities wichtiger Fall der Nutzung digitaler Inhalte ist das **Text- und Datamining**. Rechtlich gesehen, ist dabei zum einen ein, wenn auch nur flüchtiger Vervielfältigungsvorgang zu unterscheiden von dem dabei gewonnenen Ergebnis, das man entweder als bloße Information verstehen kann, die als solche keinem Schutzrecht unterfällt, oder als rechtlich relevante Bearbeitung des Ausgangsmaterials. Ungeachtet der derzeitigen rechtlichen Einordnung, die eher davon ausgeht, dass mit dem rechtmäßigen Zugang zu einer Ressource auch das Recht des Mining als einer bloß technischen Form des Lesens verbunden sein soll, regeln Lizenzverträge von Inhalteanbietern diesen Punkt bereits gesondert. Man darf davon ausgehen, dass hier eine neue Nutzungsart im Entstehen begriffen ist, die in absehbarer Zeit auch gesetzlich näher umschrieben wird.

Gesetzliche Schrankenbestimmungen haben im Gegensatz zu vertraglich eingeräumten Nutzungsrechten den Vorteil, dass sie für eine Vielzahl von Anwendungsfällen gelten und den Anwendungsbereich auf den ersten Blick klar umschreiben. Allerdings müssen alle Schrankenbestimmungen mit Blick auf den sogenannten **Drei-Stufen-Test** hin verstanden werden. Dieser Test ist eine europa- und völkerprivatrechtliche Vorgabe, die besagt, dass Schranken nur Sonderfälle der Nutzung betreffen, die normale Auswertung eines Werkes durch die Rechteinhaber nicht beeinträchtigen und schließlich die Rechteinhaber nicht unangemessen benachteiligen dürfen. Dieser Test hat meist die Konsequenz, dass eine Schrankenbestimmung dann nicht mehr geboten ist, wenn Rechteinhaber am Markt eigene digitale Angebote vertreiben. Gerade dort, wo es um Digitalisierung analoger Vorlagen und die Nutzung der Digitalisate geht, ergeben sich oft Konflikte. Durch den Drei-Stufen-Test wird der Vorteil gesetzlicher Schrankenbestimmungen, nämlich erlaubtes Verhalten relativ eindeutig zu umschreiben, wieder relativiert.

Urheberrecht in den USA

In den USA ist das Urheberrecht übrigens anders ausgestaltet. Hier gibt es praktisch keine speziellen Schrankenbestimmungen, sondern mit der **Fair-Use-Regel** eine sehr flexible Generalklausel, die es gestattet, auch neue digitale Nutzungsmöglichkeiten anzuwenden, wenn und soweit die Interessen von Rechteinhabern nicht unangemessen beeinträchtigt werden. Das europäische Urheberrecht, das den Schutz von Werken als Regel und ihre Nutzung als begründungsbedürftige und eng zu fassende Ausnahme versteht, wird hier immer in Verlegenheit sein und bei neuen Anwendungsfällen auch neue gesetzliche Bestimmungen benötigen. Die enorme Bedeutung von Rechtsfragen bei der Arbeit der Digital Humanities hierzulande im Vergleich zu den USA liegt in dieser vollkommen anderen Urheberrechtssituation begründet.

24.2 | Digital Humanities und Open Access

Die bisherige Darstellung hat deutlich gemacht, dass Digitalia in ihrer Nutzung viel komplexer sind als verkörperte Wissensobjekte. Insbesondere die Reichweite von Nutzungsrechten und Urheberrechtsschranken ist im Einzelfall alles andere als klar und verkompliziert die praktische Arbeit mit und an digitalen Inhalten. Die Digital Humanities nutzen aber nicht nur geschützte Inhalte, sie erstellen sie auch. Angefangen mit statistischen Forschungsdaten und schlichten Digitalisaten analoger Vorlagen, an denen Leistungsschutzrechte entstehen können, über wissenschaftliche Publikationen bis hin zu komplexen elektronischen Arbeitsmitteln und digitalen Editionen (s. Kap. 12 und 17). Hier stellt sich die Frage, wie die Digital Humanities mit den dabei entstehenden Schutzrechten umgehen wollen.

Vor dem Hintergrund, dass für die Nutzung fremder Ressourcen ein möglichst einfacher und unkomplizierter Zugang gewünscht und gewollt wird, erscheint es angemessen, dass auch die Digital Humanities, soweit sie selbst produktiv sind, sich einer weitgehenden Offenheit verpflichtet wissen. Diese Offenheit in Bezug auf wissenschaftliche Inhalte wird gemeinhin als **Open Access** bezeichnet. Umgangssprachlich meint Open Access schlicht den Umstand, dass Inhalte für jeden kosten- und registrierungsfrei über das Internet zugänglich sind (s. Kap. 13).

In einem engeren Verständnis, wie es beispielsweise in der programmatisch sehr wichtigen »Berliner Erklärung über den offenen Zugang zu wissenschaftlichem Wissen« vom 22. Oktober 2003 niedergelegt ist, gehört zu Open Access noch eine nutzungsrechtliche Komponente. Unter bestimmten Bedingungen, etwa Namensnennung oder nicht kommerzielle Nutzung, werden Inhalte nicht nur jedem zugänglich gemacht, sondern zugleich auch einfache Nutzungsrechte eingeräumt, so dass der entsprechende Content eigenständig veröffentlicht und teilweise auch bearbeitet werden kann. Weit verbreitet sind hier die **Creative-Commons-Lizenzen** (CC-Lizenzen), bei denen in einer Art Baukastensystem sehr einfach und transparent Nutzungsbedingungen für digitale Inhalte festgelegt werden können. Der Lizenzvertrag selbst kommt schlüssig durch **lizenzkonforme Nutzung** zustande, wobei der Verwender der Lizenz auf den Zugang der Annahmeerklärung verzichtet hat. Man kann sich das plastisch wie beim Kauf eines Schokoriegels am Automaten in der Unibiblio-

thek vorstellen, wo auch keine direkte Kommunikation über den dabei zustande kommenden Kaufvertrag stattfindet.

Vor allem durch die Befugnisse, Inhalte selbst im Internet weiterzuverbreiten, wirken die Lizenzen funktional wie der Erschöpfungsgrundsatz bei körperlichen Werkstücken. So wie man sich bei gedruckten Büchern über deren Nutzung keine besonderen juristischen Gedanken machen muss, so ist es auch bei angemessen lizenzierten Digitalia.

24.3 | Rechtsfragen digitaler Geistes- und Kulturwissenschaft: Ein Forschungsgegenstand der Digital Humanities?

Die hier angesprochenen Rechtsfragen scheinen auf den ersten Blick bloß hilfswissenschaftliches Grundlagenwissen zu sein und lediglich instrumentelle Fähigkeiten zu thematisieren. Wenn man sich aber bewusst gemacht hat, dass es nicht so sehr technische Werkzeuge und Innovationen, sondern allein die durch gesetzliche Bestimmungen, vor allem aber durch eingeräumte Nutzungsrechte gegebenen Verwendungsmöglichkeiten, letztlich also allein rechtliche Aspekte sind, die den Umgang mit digitalen Inhalten in den Digital Humanities eröffnen, bestimmen und begrenzen, sollte klar sein, dass Rechtsfragen ein für die künftige Entwicklung der digital arbeitenden Geistes- und Kulturwissenschaften zentrales Themenfeld sind und daher nicht allein den Juristen überlassen werden können und dürfen.

Hier muss man den bereits angesprochenen fundamentalen Unterschied zur Situation beispielsweise in den USA sehen, wo sich die Digital Humanities mehr auf technische und konzeptionelle Weiterentwicklungen konzentrieren können, weil der sehr flexible *Fair-Use*-Grundsatz die allermeisten neuen Nutzungsszenarien abdeckt. Demgegenüber müssen die Digital Humanities im Bereich des europäischen Urheberrechts die aktuelle Rechtsentwicklung aufmerksam beobachten und gegebenenfalls im Dialog mit Rechtswissenschaft und Politik für ihre Interessen intervenieren. Die praktisch unbrauchbare Gesetzgebung zur Nutzung verwaister Werke ist ein abschreckendes Beispiel dafür, wie neue Regelungen nicht aussehen sollten, wollen sie die Wissenschaft voranbringen.

Fast wichtiger noch als gesetzliche Vorschriften aber sind Standards für **Lizenzen**. Hier sollten für die praktische Arbeit in den Digital Humanities angemessene und flexible Vertragsbedingungen entwickelt werden, die jedenfalls dort einen rechtssicheren Arbeitsraum schaffen, wo eigene Werkzeuge und Inhalte erzeugt werden. Dabei sollte in den Digital Humanities ein Konsens darüber erreicht werden, wie offen, nachnutzbar und nachhaltig entwickelte Werkzeuge, Arbeitsumgebungen und Forschungsergebnisse sein sollen. Um hierfür entsprechende Lizenzen sachgerecht ausgestalten zu können, sollten die Digital Humanities in ihrer konzeptionellen und methodischen Arbeit immer auch die juristische Dimension mitdenken. Dazu gehört auch, dass alle im Rahmen von Projekten bei den Beteiligten entstehenden Urheber- und Leistungsschutzrechte unter einheitlichen und offenen Bedingungen bei der Projektleitung bzw. bei der das Projekt tragenden Institution gebündelt werden, um eine möglichst einfache und weitreichende Nachnutzbarkeit der Projektergebnisse zu garantieren.

Literatur

- Dorschel, Joachim: »Verträge über Daten und Datenanalysen«. In: Ders. (Hg.): *Praxishandbuch Big Data. Wirtschaft – Recht – Technik*. Wiesbaden 2015, 245–250.
- Dreier, Thomas/Fischer, Veronika/van Raay, Anne/Spiecker gen. Döhmman, Indra (Hg.): *Informationen der öffentlichen Hand – Zugang und Nutzung*. Baden-Baden 2016.
- Euler, Ellen: *Das kulturelle Gedächtnis im Zeitalter digitaler und vernetzter Medien und sein Recht. Status Quo der rechtlichen, insbesondere urheberrechtlichen Rahmenbedingungen von Bestandsaufbau, Bestandserhaltung und kommunikativer sowie kommerzieller Bestandsvermittlung kultureller Äußerungen im Zeitalter digitaler und vernetzter Medien durch Bibliotheken, Archive und Museen in Deutschland und Regelungsalternativen*. Bad Honnef 2011.
- Fechner, Frank: *Medienrecht. Lehrbuch des gesamten Medienrechts unter besonderer Berücksichtigung von Presse, Rundfunk und Multimedia*. Tübingen ¹⁷2016.
- Hartmann, Thomas: »Zur urheberrechtlichen Schutzfähigkeit von Forschungsdaten«. In: *Zeitschrift zum Innovations- und Technikrecht* 2013, 199–202.
- Heckmann, Jörn: *Die retrospektive Digitalisierung von Printpublikationen*. Frankfurt a. M. 2011.
- Hinte, Oliver/Steinhauer, Eric W. (Hg.): *Die Digitale Bibliothek und ihr Recht – ein Stiefkind der Informationsgesellschaft? Kulturwissenschaftliche Aspekte, technische Hintergründe und rechtliche Herausforderungen des digitalen kulturellen Speichergedächtnisses*. Münster 2014. https://ub-deposit.fernuni-hagen.de/receive/mir_mods_00000397 (31.10.2016).
- Horn, Janine: *Rechtliche Aspekte digitaler Medien an Hochschulen*. Münster 2015. https://ub-deposit.fernuni-hagen.de/receive/mir_mods_00000454 (31.10.2016).
- Klimpel, Paul/Weitzmann, John H.: *Handreichung Rechtliche Rahmenbedingungen für Digitalisierungsprojekte von Gedächtnisinstitutionen*. Berlin ²2015. <http://dx.doi.org/10.12752/2.0.002.2> (31.10.2016).
- Kreutzer, Till: *Open Content. Ein Praxisleitfaden zur Nutzung von Creative-Commons-Lizenzen*. Berlin 2015.
- Lutz, Alexander: *Zugang zu wissenschaftlichen Informationen in der digitalen Welt. Ein urheberrechtlicher Beitrag zu den Wissenschaftsschranken und zu einem zwingenden Zweitveröffentlichungsrecht*. Tübingen 2012.
- Peifer, Karl-Nikolaus: »Die gesetzliche Regelung über verwaiste und vergriffene Werke. Hilfe für verborgene Kulturschätze«. In: *Neue Juristische Wochenschrift* 2014, 6–12.
- Steinhauer, Eric W.: »Juristische Methoden und Arbeitstechniken«. In: Konrad Umlauf/Simone Fühles-Ubach/Michael Seadle (Hg.): *Handbuch Methoden der Bibliotheks- und Informationswissenschaft*. Berlin 2013, 398–411.
- Talhoff, Oliver: *Die Nutzung verwaister und vergriffener Werke im Urheberrecht*. Baden-Baden 2016.
- Talke, Armin: »Lichtbildschutz für digitale Bilder von zweidimensionalen Vorlagen«. In: *Zeitschrift für Urheber- und Medienrecht* 2010, 846–852.
- Ulbricht, Carsten/Hubertus, Jenny: »Leistungsschutz«. In: Joachim Dorschel (Hg.): *Praxishandbuch Big Data. Wirtschaft – Recht – Technik*. Wiesbaden 2015, 213–225.

Internetquellen

- Berlin Declaration on Open Access to Knowledge in the Sciences and Humanities: <http://openaccess.mpg.de/Berliner-Erklärung>.
- Creative Commons Deutschland: <http://de.creativecommons.org/>.
- Urheberrechtsgesetz (UrhG): <https://www.gesetze-im-internet.de/urhg/>.
- Verwertungsgesellschaftengesetz (VGg): <http://www.gesetze-im-internet.de/vgg/>.

Eric Steinhauer

25 Ethik

Digitalisierung ist, so scheint es, der große Trend unserer Zeit. In den Wissenschaften führt die Digitalisierung zu mehr Daten und trägt zur Wissensproduktion bei. Je mehr Wissen produziert werden kann, umso größer ist aber auch die entsprechende Verantwortung, die mit diesem Wissen, seiner Produktion und seiner Verwendung einhergeht. Zugleich sind Wissenschaftler in der Regel mit vielen Freiheiten ausgestattet, was die Auswahl ihrer Themen, Methoden und Zielsetzungen betrifft. Damit tragen sie eine große Verantwortung für ihr Tun und dürfen auf moralische Reflexionen nicht verzichten. Die Auseinandersetzung mit normativen Fragen als Teil einer Wissenschaftsethik der Digital Humanities hat jedoch gerade erst begonnen (Rehbein 2016).

25.1 | Ethische Fragen in den Digital Humanities: Eine Fallstudie

2013 wurde ein recht prominenter Anwendungsfall von Methoden der Digital Humanities bekannt, als auf dem Buchmarkt der Kriminalroman *The Cuckoo's Calling* (deutsch: *Der Ruf des Kuckucks*) eines bis dahin unbekannten Autors namens Robert Galbraith erschien. Trotz wohlwollender Kritiken war das Buch zunächst nur ein mäßiger Erfolg. Drei Monate später jedoch machte das Gerücht die Runde, die wahre Autorin von *The Cuckoo's Calling* sei J. K. Rowling, jene Schriftstellerin, die durch die Harry-Potter-Serie einen sehr großen weltweiten Erfolg hatte. Von da an stiegen auch die Verkaufszahlen von Galbraith' Kriminalroman in die Höhe.

Mit Hilfe der forensisch-stilometrischen **Autorschaftsattribuierung** (s. Kap. 20.3) analysierten Patrick Juola und Peter Millicam den Text des vermeintlichen Autors Galbraith, in dem sie ihn – im Sinne eines *closed games* – mit Texten von Rowling verglichen. Sie gelangten zu der Überzeugung, dass es recht wahrscheinlich ist, dass tatsächlich Rowling unter Verwendung eines Pseudonyms *The Cuckoo's Calling* geschrieben hat, was sie schließlich zugab (Hui 2013).

In diesem Fall konnten die Methoden der Digital Humanities nicht nur sehr erfolgreich praktiziert werden, sondern es ist gelungen, ihr weitreichendes Potential für die wissenschaftliche Forschung aufzuzeigen. Schwelende Fragen, wie etwa zu unbekannten Autorschaften historischer Texte, scheinen nun beantwortbar zu sein, alte Hypothesen verifizier- oder falsifizierbar zu werden und gänzlich neues Forschungsterrain in Reichweite zu gelangen.

Zugleich scheint aber durch die Forschung in den Digital Humanities die Nutzung von Pseudonymen wirkungslos zu werden. Damit zeigt sich eine Kehrseite unserer Wissenschaft. Als Rowling zugab, unter einem Pseudonym veröffentlicht zu haben, äußerte sie sich zugleich mit Bedauern: »Being Robert Galbraith has been such a liberating experience [...] It has been wonderful to publish without hype and expectation and pure pleasure to get feedback under a different name« (Hui 2013).

Greift unsere Forschung somit in die individuellen Rechte von Menschen ein und raubt uns Möglichkeiten und zivile Errungenschaften, wie Privatheit und Anonymität, die wir zuvor besaßen? Denn Methoden wie diese der Autorschaftsattribuierung können, einmal entwickelt, nicht nur in wissenschaftlichen Kontexten, sondern auch darüber hinaus verwendet werden. Im Grunde kann, zumindest in der Theorie,

jeder Text seinem vermeintlichen Autor zugeschrieben werden und zwar durch jeden, der die entsprechenden Methoden beherrscht und – solange die Texte zugänglich sind – ohne Wissen und Zustimmung (sog. *informed consent*) des Betroffenen.

25.2 | Moral, Ethik, Angewandte Ethik

In unserer Alltagssprache werden die Ausdrücke ›Ethik‹ und ›Moral‹ oft austauschbar verwendet. Für die Wissenschaftssprache hat sich jedoch folgende Unterscheidung eingebürgert:

- **Moral** ist der Gegenstandsbereich, nämlich die Sphäre der Werte und Normen, an denen wir uns mit unseren Verhaltensweisen orientieren.
- **Ethik** (äquivalent meist ›**Moralphilosophie**‹) ist die wissenschaftliche Beschäftigung mit Moral, primär in der Philosophie, aber auch in der Theologie und den Rechtswissenschaften (theologische Ethik und Rechtsethik). Aufgrund der hohen Relevanz dieser Fragen ist die Literatur zur Ethik im Allgemeinen und zur Wissenschaftsethik im Besonderen äußerst umfangreich (einführend Birnbacher 2013 und Reydou 2013).

Innerhalb der Ethik gibt es drei Typen von Aussagen:

- **Metatheoretische Aussagen** beziehen sich auf die sprachlichen, methodologischen und ontologischen Voraussetzungen der Ethik. So gehört etwa der obige Absatz zur Metaethik.
- **Deskriptive Aussagen** beschreiben, wie etwas ist. Zusätzlich versuchen sie zu erklären, warum es so ist (explanative Aussagen). In Bezug auf Werte und Normen wird diese Aufgabe heute von verschiedenen empirischen Wissenschaften übernommen (Moralpsychologie, Moralsoziologie, Soziobiologie u. a.). Um Missverständnisse zu vermeiden, sollte man diesbezüglich am besten gar nicht von Ethik sprechen, sondern von Moraltheorien.
- **Normative Aussagen**, in denen nicht gesagt wird, wie etwas ist, sondern wie etwas sein sollte, sind zentral für die Ethik. In der (normativen) Ethik geht es also darum, welche Werte und Normen gelten sollen, wie wir handeln sollen, was moralisch gut ist. Immanuel Kant brachte es auf die kurze Frage: »Was soll ich tun?«

In den Diskussionen, die seit Sokrates geführt werden, haben sich verschiedene Hauptthemen herauskristallisiert. Auf der ersten Ebene ist der Wissenschaftsanspruch der Ethik gegen Relativismus, Skeptizismus und Nihilismus zu verteidigen. Auf der zweiten Ebene konkurrieren die wichtigsten Schulen der Ethik:

- der **Konsequentialismus**, insbesondere der von Jeremy Bentham und John Stuart Mill entwickelte Utilitarismus, der Handlungen oder Normen nach ihrer allgemeinen Nützlichkeit bewertet;
- die **Deontologie**, die Kants Ansatz folgend bestimmte Handlungen und Normen an sich als geboten ansieht sowie darüber hinaus eine moralische Motivation verlangt;
- der von Thomas Hobbes begründete **Kontraktualismus**, der die gesamte Moral auf (fiktiven) sozialen Verträgen aufbauen will;
- die auf Aristoteles zurückgehende **Tugendethik**, in der positive individuelle Charaktereigenschaften im Vordergrund stehen.

Auf einer dritten, weniger formalen Ebene geht es um die materialen Grundprinzipien der Ethik: Menschenwürde, Freiheit, Gleichheit, Gerechtigkeit, Solidarität, Toleranz usw.

Seit einigen Jahrzehnten wird zwischen **Allgemeiner und Angewandter Ethik** unterschieden (ähnlich wie etwa zwischen der Allgemeinen Soziologie und den sog. Bindestrich-Soziologien). Denn im 20. Jahrhundert führte der gesellschaftliche Wandel zu so vielen neuen und komplexen Problemen, dass diese nicht mehr innerhalb der herkömmlichen Disziplinen behandelt werden können, sondern eigene Expertendiskurse verlangen. So entstanden Medizinethik, Umweltethik, Wirtschaftsethik usw. Eine Teildisziplin dieser Art ist auch die Wissenschafts- und/oder Forschungsethik. Ein wichtiger Anstoß für diesbezügliche Reflexionsprozesse war der Zweite Weltkrieg, nach dem beispielsweise die Frage nach der Verantwortung der Atomphysiker aufgeworfen wurde. Die Fortschritte der Wissenschaften erfordern heute weitere Differenzierungen, so auch eine eigene Ethik der Digital Humanities.

25.3 | Verantwortung als analytische Schlüsselkategorie

Die Fallstudie zeigt, dass aus der Befähigung, wissenschaftliche Verfahren zu entwickeln (und anzuwenden), die Frage folgt, wie mit dieser Kompetenz verantwortlich umzugehen ist. Verantwortung ist dabei kein normatives Prinzip wie Menschenwürde oder Freiheit, sondern eine Kategorie, die sich zur Analyse komplexer Handlungssituationen eignet (vgl. Bayertz 1995). Verantwortung ist ein mehrstelliger Begriff, der sich – in Form einer Frage – in folgende Komponenten aufschlüsselt: Wer (1) ist für was (2) gegenüber wem (3) vor welcher Instanz (4) nach welchen Maßstäben (5) verantwortlich? Für konkrete Fragen und Anwendungsfälle müsste dieses Schema ausgefüllt, modifiziert und erweitert werden. Wir rollen die Teilfragen von hinten auf.

Zu (5): **An welchen Maßstäben bemisst sich Verantwortung?** Maßstäbe sind zunächst die **geltenden Rechtsnormen** (etwa die Einhaltung von Verträgen und die Beachtung verfassungsrechtlicher Grundsätze), darüber hinaus allgemein akzeptierte **soziale Normen** (etwa das Lügenverbot). Allerdings müssen im Zweifelsfall auch diese Normen kritisierbar sein. So ist ein Rechtspositivismus, der sich ausschließlich an faktischen Gesetzen orientiert, nicht vertretbar; sonst könnte man gegen totalitäre, aber formal korrekte Systeme nicht argumentieren. Oberster Maßstab sind deshalb **grundlegende normative Prinzipien** wie Menschenwürde, Freiheit und Gerechtigkeit. An diesen müssen sich auch die Angewandten Ethiken orientieren.

Hinzu kommen **spezifische Normen** des jeweiligen Bereichs. Für die allgemeine Wissenschaftsethik wären folgende Prinzipien zu nennen: intellektuelle Redlichkeit, Verständlichkeit und Nachprüfbarkeit, Öffentlichkeit der Forschungsergebnisse, Relevanz der Themen sowie die Distanz zu weltanschaulichen und religiösen Einflüssen. Welche speziellen Normen für die Digital Humanities gelten sollen, muss in Form eines ›Code of Conduct‹ noch entwickelt werden.

Zu (4): **Vor welcher Instanz ist man verantwortlich?** Das Wort ›verantworten‹ verweist etymologisch auf die Forderung, einer legitimen Instanz Rede und Antwort zu stehen. Es gibt mehrere solcher Instanzen, die sich ergänzen und überlagern, aber auch widersprechen können. Religiöse Menschen denken an Gott, für moralische Menschen ist es ihr Gewissen, für jeden Staatsbürger gibt es die zuständigen Gerichte, darüber hinaus die eher informelle Institution der Öffentlichkeit.

Hinzu kommen spezifische **Instanzen** in den Wissenschaften: Institutsvorstände, Universitätsleitungen, Berufsverbände, Wissenschaftsorganisationen, Drittmittelgeber usw. Für viele gesellschaftliche Bereiche gibt es inzwischen interdisziplinär besetzte Ethik-Kommissionen, meist aber nur mit beratender Funktion (etwa der Deutsche Ethikrat). Die Digital Humanities als junge wissenschaftliche Disziplin müssten entsprechende standes- und bereichsspezifische Institutionen noch entwickeln.

Zu (3): **Gegenüber wem ist man verantwortlich?** Die universalistischen Ansätze der Gegenwart pochen darauf, dass letztlich eine Verantwortung gegenüber der gesamten Menschheit besteht, einschließlich künftigen Generationen, vielleicht auch gegenüber leidensfähigen Tieren. Das kann zum Gefühl der moralischen Überforderung führen. Deshalb sind auch hier Differenzierungen notwendig. In der Wirtschaftsethik wird beispielsweise zwischen dem engeren Kreis der **Shareholder** (Anteilseigner) und dem weiteren Kreis der **Stakeholder** (Interessensinhaber) unterschieden.

In den Wissenschaften ist der einzelne Forscher primär verantwortlich gegenüber den Personen seines unmittelbaren sozialen Umfelds, also gegenüber Mitarbeitern, Kollegen, Vorgesetzten und Auftraggebern sowie der wissenschaftlichen Community. Darüber hinaus besteht eine Verantwortung gegenüber den Betroffenen, also gegenüber denjenigen, die von Forschung profitieren, aber auch durch sie Schaden erleiden könn(t)en, wie die Fallstudie eingangs dieses Kapitels illustriert. Dies kann – je nach Reich- und Tragweite der Forschung – einzelne Individuen oder Gruppen betreffen, aber auch langfristige Auswirkungen auf größere Systeme wie Gesellschaften oder die Umwelt haben.

Zu (2): **Für was ist man verantwortlich?** Verantwortlich sind wir Menschen in erster Linie für unsere Handlungen. Aber auch Entscheidungen (etwa ein Forschungsprojekt zu starten) und Unterlassungen (beispielsweise bei Verstößen von Mitarbeitern nicht einzugreifen) sowie Sprech- und Schreibakte sind Handlungen.

Allerdings sind wir nicht nur für unsere Handlungen (in diesem weiten Sinn) verantwortlich, sondern auch für deren Konsequenzen. Das ist sogar der Kern der Verantwortungsethik, wie sie vor allem in Max Webers berühmter Rede von 1919 »Politik als Beruf« skizziert wird. Wir sollten wissen, was aus unseren Handlungen folgt, welche kurz- und langfristigen Folgen sie haben (Weber 1988).

Ein wichtiger Punkt sind die **Nebenwirkungen**. Handlungen unterscheiden sich von bloßen Körperbewegungen dadurch, dass der Akteur mit ihnen eine Absicht (Intention) verbindet. Die Intention kann verwirklicht werden oder nicht, aber normalerweise hat jede Handlung vielerlei weitere Folgen, die nicht beabsichtigt waren. In der Wissenschaft erwächst daraus oft die sogenannte »**Dual-Use-Problematik**«: Eine Errungenschaft wird für andere als die ursprünglich intendierten Zwecke verwendet. So können im obigen Beispiel die Verfahren der Autorschaftsattribuierung etwa in totalitären Systemen genutzt werden, um Oppositionelle zu identifizieren.

Idealtypisch lassen sich folgende Fälle unterscheiden:

- a) Es gibt eine Hauptabsicht und mindestens eine Nebenabsicht. In einem Forschungsprojekt haben beispielsweise alle Beteiligten in der Regel neben ihren wissenschaftlichen Intentionen auch zusätzliche Interessen, etwa finanzieller oder sozialer Art. Die Verantwortung erstreckt sich in der Regel auf das gesamte Spektrum der Absichten.

- b) Es gibt Nebenwirkungen, die nicht intendiert sind, aber in Kauf genommen werden: Ich weiß, dass die Forschungsergebnisse Menschen bloßstellen werden, aber ich beabsichtige dies nicht. Dennoch ist man auch dafür verantwortlich.
- c) Es gibt Nebenwirkungen, deren Eintreten subjektiv nicht vorhergesehen wurde, über die man aber hätte Bescheid wissen können. In solchen Fällen besteht die Pflicht, sich im Vorhinein über mögliche Nebenwirkungen zu informieren.
- d) Es gibt Nebenwirkungen, die bei bestem Wissen und Gewissen nicht absehbar waren. In wissenschaftlichen Kontexten ist in solchen Fällen (anders als etwa in der Politik) schwerlich jemand berechtigterweise zur Verantwortung zu ziehen.

Zu (1): **Wer ist verantwortlich?** Subjekt einer Handlung ist eigentlich immer ein einzelner Mensch. Allerdings hat jedes **Individuum** in der modernen Welt verschiedene Rollen: als Privatperson, als Staatsbürger, als Wirtschaftsbürger (zumindest als Konsument, manchmal auch als Unternehmer oder Aktionär), als Teilnehmer an öffentlichen und halb-öffentlichen Prozessen (heutzutage auch als Prosument im Internet). Hinzu kommen unsere Aktivitäten im **Beruf**, also hier in der Wissenschaft. Im Universitätssystem wird zwischen den Rollen als Forscher und als Dozent unterschieden; darüber hinaus sind Wissenschaftler publizistisch, administrativ und hochschulpolitisch aktiv. Aus allen diesen Funktionen ergeben sich spezifische Verantwortlichkeiten.

Darüber hinaus gibt es **höherstufige Subjekte**. Diese setzen sich zwar aus individuellen Menschen zusammen, aber sind nicht bloß deren Summe. So kennen wir etwa juristische Personen wie Verbände und Firmen. Im Wissenschaftsbereich wäre an Korporationen und Institutionen zu denken: Berufsverbände, Institute, Fachschaften, Universitäten usw. In vielen Problemfeldern bin ich als einzelnes Individuum machtlos, sogar als Professor. Eine Gruppe, Korporation oder Institution kann meistens mehr bewirken, so dass sogar eine moralische Pflicht besteht, solche höherstufigen Subjekte zu schaffen. Letztlich ist also jeder Mensch in mehrfacher Weise verantwortlich, in verschiedenen Rollen und auf unterschiedlichen Ebenen.

Zudem stellt sich in der nahen Zukunft die spannende Frage, inwiefern nicht-menschliche Akteure die Rolle des verantwortlichen Subjekts übernehmen können, insbesondere intelligente Maschinen und autonome Systeme. Bevor es aber so weit ist, sollten sich in den Digital Humanities alle Wissenschaftler ihrer Verantwortlichkeiten bewusst werden.

Literatur

- Bayertz, Kurt (Hg.): *Verantwortung. Prinzip oder Problem?* Darmstadt 1995.
- Birnbacher, Dieter: *Analytische Einführung in die Ethik*. Berlin/New York ³2013.
- Hui, Sylvia: »J. K. Rowling confirms Robert Galbraith pseudonym«. In: *The Boston Globe*, 15.07.2013.
- Rehbein, Malte: »It's Our Department: On Ethical Issues of Digital Humanities«. In: Kristina Richts/Joachim Veit (Hg.): »*Ei, dem alten Herrn soll' ich Achtung gern*«. *Festschrift für Joachim Veit zum 60. Geburtstag*. München 2016, 631–654.
- Reydon, Thomas: *Wissenschaftsethik. Eine Einführung*. Stuttgart 2013.
- Weber, Max: »Politik als Beruf«. In: Johannes Winckelmann (Hg.): *Max Weber: Gesammelte politische Schriften*. Tübingen ⁵1988, 505–560.

Malte Rehbein und Christian Thies

VI Anhang

26 Auswahlbibliographie

26.1 | Allgemein

- Arthur, Paul L./Bode, Katharine: *Advancing Digital Humanities. Research, Methods, Theories*. New York 2014.
- Flanders, Julia/Jannidis, Fotis (Hg.): *The Shape of Data in Digital Humanities. Modeling Texts and Text-based Resources*. London 2017.
- Gold, Matthew K.: *Debates in the Digital Humanities*. Minneapolis, Minn. 2012.
- Gold, Matthew K./Klein, Lauren F. (Hg.): *Debates in the Digital Humanities 2016*. Minneapolis, Minn./London 2016.
- Hirsch, Brett (Hg.): *Digital Humanities Pedagogy: Practices, Principles and Politics*. Cambridge 2012.
- Klawitter, Jana/Lobin, Henning/Schmidt, Torben: *Kulturwissenschaften digital. Neue Forschungsfragen und Methoden*. (Interaktiva. Schriftenreihe des Zentrums für Medien und Interaktivität, Gießen, 12). Frankfurt a. M./New York 2012.
- McCarty, Willard: *Humanities Computing*. Houndmills/New York 2005.
- Schreibman, Susan/Siemens, Ray/Unsworth, John (Hg.): *A Companion to Digital Humanities*. Oxford 2004, <http://www.digitalhumanities.org/companion/>.
- Schreibman, Susan/Siemens, Ray/Unsworth, John (Hg.): *A New Companion to Digital Humanities*. Oxford 2015.
- Terras, Melissa/Nyhan, Julianne/Vanhoutte, Edward (Hg.): *Defining Digital Humanities. A Reader*. Farnham 2013.
- Thaller, Manfred (Hg.): *Historical Social Research/Historische Sozialforschung. Controversies around the Digital Humanities 37*. Köln 2012.
- Warwick, Claire/Terras, Melissa/Nyhan, Julianne: *Digital Humanities in Practice*. London 2012.

26.2 | Fachspezifisch

- Bodard, Gabriel (Hg.): *Digital Research in the Study of Classical Antiquity*. Farnham/Ashgate 2010.
- Borgman, Christine L.: *Scholarship in the Digital Age. Information, Infrastructure, and the Internet*. Cambridge, Mass. 2007.
- Burdick, Anne/Drucker, Johanna/Lunenfeld, Peter/Presner, Todd/Schnapp, Jeffrey: *Digital Humanities*. Cambridge 2012.
- Cohen, Daniel J./Rosenzweig, Roy: *Digital History: A Guide to Gathering, Preserving, and Presenting the Past on the Web*. Philadelphia 2006.
- Crawford, Tim: *Modern Methods for Musicology. Prospects, Proposals, and Realities*. Farnham/Ashgate 2009.
- Drucker, Johanna: *SpecLab: Digital Aesthetics and Projects in Speculative Computing*. Chicago 2009.
- Erlin, Matt/Tatlock, Lynne (Hg.): *Distant Readings. Topologies of German Culture in the long Nineteenth Century*. Rochester, N. Y. 2014.
- Evans, Thomas L./Daly, Patrick T.: *Digital Archaeology. Bridging Method and Theory*. Abingdon 2006, <https://enciklopediamoderne.files.wordpress.com/2014/09/patrick-daly-thomas-l-evans-digital-archaeology.pdf> (7.11.2016).
- Graham, Shawn/Milligan, Ian/Weingart, Scott: *Exploring Big Historical Data. The Historian's Macro-scope*. London 2015.
- Gregory, Ian N./Geddes, Alistair (Hg.): *Toward Spatial Humanities: Historical GIS and Spatial History*. Bloomington 2014.
- Haber, Peter: *Digital past: Geschichtswissenschaft im digitalen Zeitalter*. München/Oldenbourg 2011.
- Jockers, Matthew L.: *Macroanalysis. Digital Methods & Literary Theory*. Urbana, Ill. 2013.
- Kohle, Hubertus: *Digitale Bildwissenschaft*. Glückstadt/Hülsbusch 2013, http://archiv.ub.uni-heidelberg.de/artdok/2185/1/Kohle_Digitale_Bildwissenschaften_2013.pdf (7.11.2016).
- Leonhardt, Nic: *The Routledge Companion to Digital Humanities in Theatre and Performance*. London 2017.
- Moretti, Franco: *Distant Reading*. London 2013.
- Siemens, Ray/Schreibman, Susan (Hg.): *A Companion to Digital Literary Studies*. Malden 2007.

26.3 | Fachzeitschriften

Digital Humanities Quarterly

Digital Medievalist

Digital Scholarship in the Humanities (vormals: Literary & Linguistic Computing)

Digital Studies / Le champ numérique

Journal of Digital Humanities

Journal of the Association for History and Computing

Zeitschrift für Digitale Geisteswissenschaften

Autorinnen und Autoren

Fotis Jannidis ist Professor für Computerphilologie und Neuere Deutsche Literaturgeschichte an der Universität Würzburg (I.5 Zahlen und Zeichen; I.6 Grundbegriffe des Programmierens; II.7 Grundlagen der Datenmodellierung; II.10 Netzwerke).

Harald Klinke ist wissenschaftlicher Assistent am Institut für Kunstgeschichte an der Universität München (I.4 Aufbau des Computers und Vernetzung; II.8 Datenbanken; IV.19 Information Retrieval).

Hubertus Kohle ist Professor für Kunstgeschichte an der Universität München (III.13 Digitales Publizieren; IV.22 Digitale Rekonstruktion und Simulation).

Heike Neuroth ist Professorin für Bibliothekswissenschaft an der Fachhochschule Potsdam (III.15 Bibliothek, Archiv, Museum).

Andrea Rapp ist Professorin für Germanistik – Computerphilologie und Mediävistik an der Technischen Universität Darmstadt (IV.18 Manuelle und automatische Annotation).

Malte Rehbein ist Professor für Digital Humanities an der Universität Passau (II.11 Ontologien; III.12 Digitalisierung; IV.23 Informationsvisualisierung; V.25 Ethik, zus. mit Christian Thies).

Ramón Reichert ist Studienleiter des Masterstudienganges „Data Studies“ an der Donau-Uni Krems (I.3 Theorien digitaler Medien).

Patrick Sahle ist außerplanmäßiger Professor an der Universität zu Köln (II.9 XML, zus. mit Georg Vogeler; III.17 Digitale Edition).

Christof Schöch ist Leiter der Nachwuchsgruppe „Computergestützte literarische Gattungsstilistik“ an der Universität Würzburg (III.14 Digitale Wissensproduktion; III.16 Aufbau von Datensammlungen; IV.20 Quantitative Analyse).

Eric Steinhauer ist Bibliothekar an der Fernuniversität in Hagen (V.24 Recht).

Manfred Thaller ist Professor emeritus für Historisch-Kulturwissenschaftliche Informationsverarbeitung an der Universität Köln (I.1 Geschichte der Digital Humanities; I.2 Digital Humanities als Wissenschaft).

Christian Thies ist Professor für Philosophie an der Universität Passau (V.25 Ethik, zus. mit Malte Rehbein).

Georg Vogeler ist Professor für Digital Humanities an der Universität Graz (II.9 XML, zus. mit Patrick Sahle).

Armin Volkmann ist Leiter der Nachwuchsforschungsgruppe „Digital Humanities and Cultural Heritage“ an der Universität Heidelberg (IV.21 Geographische Informationssysteme).

Sach- und Personenregister

A

Abstraktion 106
Adjazenzmatrix 148, 151
Admiral Nelson 325
Aggregation 112
AJAX-Technologie 57
Algorithmus 21, 25–26, 30, 32, 147, 154,
156, 289, 291–292
Analog 220
Analogcomputer 42
Analog-Digital-Wandler 39, 42, 180, 189, 197
Analogie 16
Analytical Engine 20
Anasazi (Volksstamm) 325
Annotation 101, 253–256, 260–266
Anwendungsschicht 46–49, 53
Application Ontology 166, 174
Arbeitsspeicher 37–38
Archäologie 316
Archiv 213–216, 219–221
Archivierung 223–224, 230
Archivportal-D 218
Archivschränke 348
Artigo 209
Assertionales Wissen 165
Assoziatives Feld 82
Attribut 102–103, 130–132, 135, 137
Audiodigitalisierung 197
Auflösung 180, 191, 194
Augmented Reality 317–318
Ausgabeperipherie 39–40
Authorities 277
Automatische Verfahren 260
Autorschaftsattribuierung 292, 336, 353, 356

B

Bamyian-Skulpturen, 318
Baudrillard, Jean 323
Baumdiagramm 295
Baumstruktur 130–131
Bayerische Staatsbibliothek 202
Beamer 40
Benutzerschnittstelle 43
Bereichsintegrität 121
Berners-Lee, Tim 162
Bertin, Jacques 339
Betriebssystem 43–44
Betweenness Centrality 154
Bibliothek 213, 215, 217, 219–221
Bielefeld Academic Search Engine 219
Big Data 28–32, 127

Bilddigitalisierung 179, 181–182, 187, 194,
196–197
Bildgröße 181–182, 184, 186, 191
Bildmaster 183
Binäre Suche 91–92
Binarisierung 194
Binärsystem 35
Bit 59
Bitübertragungsschicht 46, 48
Boolean 139
Boole, George 22
Boolesche Algebra 22, 37
Boolesche Operatoren 271–272
Boolesches Retrieval 271
Boolesche Suche 268
Boxplot 336–337
Breadth-First Search 154
Breitensuche 154, 156
Brockhaus 199
Broken Tie 158
Brute-Force-Algorithmus 91
Buchdruck 253
Buchscanner 189–190, 196
Buchwippe 190
Burrows' Delta 292–293, 295
Busa, Roberto 3–4
Bush, Vannevar 26
Bussystem 38–39

C

C 68
Cascading Style Sheets 57
CAVE 317
Character 71
Character Entity 129
Chen, Peter 112
CIDOC Conceptual Reference Model 216
Citizen Science 208
Closed World Assumption 168
Closeness Centrality 153
Close Reading 18
Cloud 42–43
Cluster 290, 295
Clusteranalyse 337–338
Clustering 290, 292, 295
Clustermodell 278
Codd, Edgar F. 111
Collision Detection 51
Compiler 68, 71, 93
Computational Social Science 30–31
Computer Aided Architectural Design 318

Computer Aided Design 318
 Computerlinguistik 7, 290
 Conceptual Reference Model 174
 Content-Based Image Retrieval 278
 Content Management System 244
 Controller-Komponente 244
 Crawler 270, 277
 Creative-Commons-Lizenz 221, 350
 Critical Code Studies 25, 31
 Crowdsourcing 207–209, 211, 229, 260, 322
 Cyberspace 26

D

DARIAH-DE 219
 Darstellungsschicht 46–48
 Data Curation 223
 Data Mining 268
 Daten
 – nominale 335
 – quantitative 335
 Datenbank 8, 13–14, 109–112, 117–119, 121–127, 207, 209, 211, 300, 302–303, 311
 – relational 147
 Datenbankmanagementsystem 109, 111, 123, 172, 300, 309
 Datenbanksystem 109, 111
 Datenformat 227
 Datenkarten 336
 Datenmodell 100–102, 104, 107, 333, 338
 Datenmodellierung 99–100, 102–107, 333
 Datensammlung 223–230, 232, 239
 Datensatz 223, 228–229
 Datenstruktur 104
 Datentabelle 333–335
 Datentypen 70–71, 85, 104
 DBMS 109
 DBpedia 173
 Debugger 94
 Degree Centrality 153
 Dendrogramm 338
 Denkmalstreit 317
 Deontologie 354
 Descartes, René 21
 Deskriptive Auszeichnung 132
 Deskriptive Metadaten 228
 Deskriptive Statistik 279, 285
 Deutsche Digitale Bibliothek 218
 Deutsches Textarchiv 219
 Dictionary 82–83
 Digital 181, 189, 192
 Digital Curation 232
 Digital Divide 28
 Digitale Bibliothek 239
 Digitale Rekonstruktion 315

Digitales Publizieren 199, 204
 Digitalisat 113, 117, 122, 124, 179, 184, 190–191, 194, 223–224, 227, 229, 231, 256–258, 265
 Digitalisierung 19, 21–23, 26, 30, 213–214, 217, 219–220, 328, 353
 Digitalität 19–22, 30
 Digitalkameras 179–180, 187–190
 Digital Object Identifier 230
 Digital Rights Management-System 202
 Digraph 148
 Dimensionalität 335–336, 338
 Distant Reading 18, 332
 Distanzmaß 292, 294, 296
 Document Frequency 275
 Dokument-Begriff-Matrix 274
 Dokumentorientiertes Markup 133
 Domain Name System 53
 Domain Ontology 166
 Donne, John 323
 Drei-Stufen-Test 349
 Drucker 41, 43
 Dual-Use-Problematik 356

E

1:1-Beziehung 114
 1:n-Beziehung 114
 E-Books 213
 Editionsphilologie 13, 237
 Eingabeperipherie 39
 Ellegård, Alvar 292
 Eltern-Kind-Relation 130
 E-Mail 44, 47, 49, 54
 Emergenz 27
 Encoded Archival Description 216
 Encyclopedia Britannica 199
 ENIAC 36, 42
 Entität 103
 Entitätsintegrität 121
 Entitätstyp 112–113, 115
 Entity-Relationship-Modell 103, 112, 115–116
 Enzyklopädie 199, 202
 Episteme 29
 EPUB-Format 200
 Erschließung 215–216
 Erschöpfungsgrundsatz 346, 351
 Ethernet 49–52
 Ethik 353–356
 Euklidische Distanz 294
 Europeana 202, 218
 Explorative Analyse 331–332
 Extended Backus Naur 102
 eXtensible Markup Language 128, 309
 eXtensible Stylesheet Language 141

F

Faksimile 235–236, 240, 243
 False Negatives 269
 False Positives 269
 Farbkanal 182
 Farbtiefe 181–182, 184, 186, 191
 Faulstich, Werner 20
 Feature Extraction 278
 Federalist Papers 4
 Fermat, Pierre de 21
 Festplatte 41
 Feyerabend, Paul 15
 Figurenkonstellation 158–159
 Fließkommazahl 70
 Forschungsdatenmanagement 221
 Foucault, Michel 21
 Fremdschlüssel 114–117, 120–121
 F-Score 270

G

Gamification 209, 260
 Gauß-Krüger-Koordinatensystem 304
 Gedächtnisinstitution 213–214, 217, 220, 258
 Geisteswissenschaft 13–18
 Gemeinsame Normdatei 302
 Gemeinschafts-Datensammlung 224
 Generisch 258
 Generische Suche 219
 Geodaten 301–302, 304–305, 309–310, 313
 Geographisches Informationssystem 299
 Geoinformatik 307
 Geordnetes Paar 148
 Georeferenzierung 303, 307–308, 310
 Gephi 160
 Gerkan, Meinhard von 323
 Gesamtnetzwerk 49
 Getty Thesaurus of Geographic Names 229
 Gewichtung 268, 274–275, 277
 Github 94
 Global Positioning System 301, 305
 Goldstandard 260–262
 Google 202
 Google Books 219–220
 Google Maps 305
 Grad 149–151, 153–154, 159
 Grafikkarte 40
 Granovetter 157
 Granularität 256
 Graph
 – azyklischer 151
 – bipartiter 150
 – einfacher 148, 152
 – gerichteter 148
 – zyklischer 151

Graphdatenbankmodell 126
 Graphentheorie 147, 150–151
 Graphical User Interface 44, 310
 Grundgesamtheit 225–226
 Grundsatz der Medienwissenschaft 24

H

HathiTrust's Digital Library 219
 Hauptkomponentenanalyse 338
 Header 246
 Head-Mounted Display 317
 Heavyweight Ontology 166
 Hermeneutik 15
 Histogramm 336–337
 HTML 138, 141, 254–255
 Hubs 277
 Human-Computer Interaction 340
 Human-Machine-Interface 39
 Hybrid-Publikation 201
 Hypermedium 23
 Hyperrealismus 27
 Hypertext 277
 Hypertext-Induced Topic Selection 277
 Hypertext Markup Language 56, 254
 Hypertext-Retrieval 277
 Hypertext Transfer Protocols 56

I

Identifikationsnummer 113
 Implementierung 117
 Index 268, 270–271, 274–275
 Indirektion 105–106
 Inferenzstatistik 287–288
 Informatik 17, 290
 Information Overload 269
 Information Retrieval 162, 268, 270, 279, 292–293
 Informationstechnologie 3, 9
 Informationsverarbeitung 23, 29
 Informationsvisualisierung 328–332, 334–335, 338–342
 In-Memory-Datenbank 127
 Integer 70
 Interface 45, 47–48
 Internationalized Resource Identifiers 169
 International Organization for Standardization 46
 International Standard Archival Description 216
 Interoperabilität 227, 230
 Interpolationssuche 271
 inverse Dokumentenhäufigkeit 275
 IP-Adresse 52–53, 56
 Iterieren 79

J

Java 68, 71
 JavaScript 57, 336
 Java Virtual Machine, 325
 JPEG 184–185
 JSON 169

K

Katalogisat 217
 Klassifikation 215, 290–292
 kleine Welten 157
 Koaxial-Kabel 50
 Kollation 234, 237
 Kompression 183–184
 konfirmative Analyse 331–332
 Konkordanz 3–4, 8
 Konsequentialismus 354
 Kontraktualismus 354
 Korpus 223, 225
 Korrelation 226
 Korrelationsanalyse 337
 Kosinus-Ähnlichkeit 277
 Kosinus-Maß 295
 Kulturtechnik 16
 Kunstgeschichte, 316
 Künstliche Intelligenz 162, 290

L

Langzeitarchivierung 214, 221, 230, 346
 Laserscanning, 322
 Layer 302–303, 307–310, 312–313
 Leibniz, Gottfried Wilhelm 21
 Lemma 229
 Lemmatisierung 290
 Lightweight Ontology 166
 Linguistic Computing Centre 5
 Linked Open Data 173
 Literal 69, 169
 Literaturwissenschaft 237–238
 Local Host 52
 Loggia dei mercanti, 326
 Ludwig XIV. 317

M

Machine Learning 164
 Macroassembler 5
 Manhattan-Distanz 294–295
 Manitoba-Grippeepidemie, 325
 Manuelle Texterfassung 193
 Manuelle Verfahren 260
 Map 82
 Markup 99, 254–255, 264
 – deklarativ 255

Maschinelles Lernen 261, 289–290, 292
 Maße der zentralen Tendenz 282
 Median 282–283, 287
 Medienarchäologie 22–24
 Medienkonvergenz 23
 Medienwandel 345, 347
 Memex 26
 Mensch-Maschine-Interface 24
 Merkmals-Matrix 280–283, 291–293
 Metadaten 100–101, 103, 215, 219, 225–232,
 256, 258–259, 263, 266
 Metamodell 101, 104
 Metasprache 133
 Microsoft 44–45, 53
 Mikrochip 36, 42
 Mikroformen 188
 Milgram 157
 Minard, Charles 328
 Mittelwert 282–287
 Mixed Content 133–134, 137
 Mobilgeräte 39, 43
 Modellierung 16–17
 Model View Controller 241
 Modularisierung 84, 87–88
 Modulo 70, 76
 Multigraph 148–149, 151
 Multimedialität 240
 Multispektralfotographie 197
 Murray, Timothy 20
 Museum 213–217, 220–221
 Museumsmanagement 214
 Music Encoding Initiative 265

N

Namespace 137, 169–170
 Nano-Publikation 204
 Natural Language Processing 164, 290
 Naturwissenschaft 14–16
 Netztopologie 50
 Netzwerk 101, 147, 153–154, 157
 Netzwerkanalyse 157, 160
 Netzwerkmodell 19
 N:M-Beziehung 115
 Node 130
 Normalform 116–117
 Normalisierung 116, 283–284, 294
 Normdatei 105, 174
 Normdaten 174, 229, 254
 Normdatendatei 229
 NoSQL-Datenbank 127
 Nutzung
 – rechtskonform 345

O

Objektdigitalisierung 197
 OCR-System 264
 Ontologie 162–175
 OPAC 216, 218
 Open Access 173, 202–203, 219–221, 345, 350
 Open Journal System 201
 Open Monograph Press 201
 Open Source 325
 Open World Assumption 168
 Operationalisierung 255–256
 Optical Character Recognition 9, 193, 290
 Ordered Hierarchies of Content Objects 246
 Ordinale Daten 335
 Orphan Works 349
 OSI-Modell 46, 48
 OS Linux 44
 OS X 44

P

Packet Switching 52
 Padre Busa 13
 PageRank 277–278
 PageRank-Maß 154
 Paläographie 188, 191
 Parameter 84
 Paratext 243, 253, 256
 Parser 131, 142, 144
 Participatory Gap 28
 Part-of-Speech-Tagging 290
 Pattern Recognition 278
 PDF-Format 200, 254
 Peer-to-Peer-Netzwerk 53
 Pfad 150–151, 154
 Pixel 38, 40, 181–183, 186, 191, 193–194
 Pixel Per Inch 191
 Plagiate-Debatte 345
 Plain Text 144
 Playfair, William 328
 Portal Deutsche Bibliotheksstatistik 213
 POS-Tagging 259
 Postscript 254–255
 Precision 262, 269–270, 275, 291
 Primärschlüssel 114–116, 119–121
 Programmpaket 6
 Projektbezogene Datensammlung 224
 Prolog 68
 Prozedurale Auszeichnung 132
 Prozessor 36–38, 42
 Prozessorchip 36
 Python 68, 71–74, 76, 78–80, 83, 85, 88–89, 91, 336

Q

Quantitative Methoden 279–280

R

Ranke, Leopold von 316
 Ranking 272, 274
 Rastergrafik 179–182, 184–187, 193–194
 Rasterkarte 302, 307–309, 313
 RDF 168–173, 175
 RDF Schema 169
 Recall 262, 269–270, 275, 291
 Rechenwerk 36–37, 42
 Recherche 217–218
 Recht 345, 347–349
 Referentielle Integrität 121
 Referenz-Datensammlungen 224
 Register 37, 99, 243
 Reguläre Ausdrücke 228, 272
 Reifikation 172
 Rekonfiguration 207
 Relation 102–103, 106, 111, 117
 Relationale Datenbank 101, 207
 Relationales Datenbankmodell 111, 134
 Relationales Datenbanksystem 300
 Relative Häufigkeiten 282–283
 Relevanz
 – objektive 269
 – situative 269
 – subjektive 269
 Remedialisierung 210
 Rendering 186
 Repositories 94
 Repositorium 230
 Resource Description and Access 216
 Resource Description Framework 169, 204
 Retrodigitalisierung 202
 RGB-Farbmodell 182, 184
 Rohdaten 333, 335
 Router 47, 52
 Routing 52
 Rückgabewert 84–87

S

Samplingrate 180
 Santa Maria Maggiore 322
 Scanner 39, 179, 187–190
 Scan-Roboter 190
 Scatter Plot 337
 Schachtelung 130
 Schaltalgebra 22, 35
 Schaltnetz 37
 Schema 131, 135–138
 Scheme 68
 Schlacht von Trafalgar 325

- Schlagwort 215, 218
 Schleife 77–78, 80, 148, 151–153, 156
 Schrankenbestimmung 348–349
 Science Citation Indexing 277
 Scientific Visualization 330
 Self-Publishing 199, 203
 Semantic Web 163, 168, 254
 Semantic-Web-Technologie 162, 164
 Semiotik 339
 Semiotisches Dreieck 163
 Sentimentanalyse 30
 Sequentielle Ordnung 131
 Serious Games 260
 Serlio, Sebastiano 326
 Seurat, Georges 316
 SGML 262
 Shannon, Claude 59
 Shapefile 302, 309
 Sicherungsschicht 46–48
 Simple Knowledge Organization System 175
 Simulacra 27
 Simulation 315–316, 323, 326
 Sitzungsschicht 46–48
 Six Degrees of Separation 147, 157
 Skalarprodukt 276
 Sketchpad, 318
 Snow, John 328–329
 Social Media 203
 Social Monitoring 23
 Software Studies 22, 25
 Sokrates 354
 SPARQL 173
 Spatial Humanities 299, 304–305, 307
 Speicher 36–38, 42, 45
 Speicherperipherie 39, 41
 Sprachen
 – deklarativ 68
 – imperativ 68, 77, 88
 – objektorientiert 68
 SQL 68, 103
 Standard 229
 Standardabweichung 283, 285–287
 Standardized General Markup Language 132
 Statistik 18
 Steuerwerk 36–38, 42
 Stichprobe 225
 Stilometrie 287, 292, 338
 Streuungsmaß 282
 String-Anfragen 272
 Stringsuche 268
 Structured Query Language 117, 301, 309
 Suche
 – binäre 271
 – lineare 271
 Sui-generis-Schutz 347
 Surrogat 179, 188
 Sutherland, Ivan 318

T
 Tag 56–57, 99
 Tagged Image File 184
 Tagging 255, 265, 268
 Tagset 255–256, 259
 Task Ontology 166
 Tastatur 37, 39, 42–45
 TCP/IP-Referenzmodell 48
 Telegrafien 45–46
 Termfrequenz 274
 Terminologisches Wissen 165, 170
 Terms 270
 Terse RDF Triple Language 169
 Text Encoding Initiative 10, 107, 133, 138,
 227, 245, 262
 Textgenese 235
 TextGrid Repository 219
 Textkorpora 239
 TF-IDF 275
 Thesaurus 245
 Thomas von Aquin 3
 Tim Berners-Lee 54
 Token 272, 280–283, 286
 Tokenisierung 290
 Top-Level Ontology 165
 Touchscreen 39, 43, 45
 Trainingskorpora 261
 Transistor 36, 40
 Transkription 179, 188, 193, 196–197, 208
 Transmedialisierung 241
 Transportschicht 46–48
 Treiber 41
 Tripel 169
 Triplestore 172
 Trivariate Daten 337
 True Negatives 269
 True Positives 269
 Tugendethik 354
 Tukey, John 59
 Tupel 148
 Turing, Alan Mathison Turing 23
 Turing-Maschine 23, 35
 Tweet 204
 Twisted Pair-Kabel 50
 Type 280–288, 293–294
 Type Cast 72

U

Überwachtes Lernen 289
 Unicode 128, 132
 Uniform Resource Identifier 230
 Uniform Resource Locator 56
 Universal Transverse Mercator-Koordinaten-
 system 304
 Urheberrecht 346–347, 350
 USB-Anschluss 41
 UTF-8 128

V

Variable 69–73, 76, 78, 84, 86, 91
 Vektorgrafik 138, 141, 181, 185–187
 Vektorisierung 186, 195, 309, 313
 Vektorkarte 300, 302, 307–310, 312
 Vektorraum 293, 295
 Vektorraum-Retrieval 275
 Vermittlungsschicht 46–48, 52
 Verschlüsselung 47, 54
 Versionsverwaltung 94
 Virtual International Authority File 229
 Virtuelle Realität 17–18, 21, 26, 318
 Visual Analytics 328, 330
 Visual Literacy 341
 Volltext 219–220
 Volltextdigitalisierung 290
 Von-Neumann-Architektur 20

W

Wahrheitswert 70, 74, 76–78
 Web 2.0 27, 30, 208, 210
 Weblog 204
 Web Map Service 313
 Web Ontology Language 171

Webserver 53–54, 56
 WGS 84-Koordinatensystem 304
 While-Schleife 77, 80–81
 Wi-Fi 50
 Wikiart 290–292
 Wikipedia 199, 208–211, 254
 Windows 44–45, 56
 Wissensarbeit 254
 Wissensgenerierung 254, 266
 Wissensproduktion 206–209, 211
 Wohlgeformt 131
 WorldCat 219
 World Geodetic System 304
 World Wide Web 49, 54, 277
 World Wide Web Consortium 132, 144

X

XML 101, 103, 107, 127, 147, 150, 169, 173,
 245, 255, 257–258, 262–264
 XPath 138–145, 278
 XSLT 68, 138, 141–142, 144–145

Z

Zeichenerkennung 193–195
 Zeichenkette 70–71, 82, 241
 Zeitreihen 336
 Zentraleinheit 37–38
 Zentrales Verzeichnis Digitalisierter Dru-
 cke 218
 Zentralitätsmaß 153
 Zeta-Maß 286
 Zeta-Scores 287–288
 Z-score 285, 294–295
 Zuse, Konrad 36
 Zuweisungszeichen 69–70, 75